

模式识别与机器学习

樊超

March 5, 2026

目 录

1	引言	1
1.1	例子：多项式曲线拟合	3
1.2	概率论	9
1.3	模型选择	25
1.4	维度灾难	26
1.5	决策理论	30
1.6	信息论	38
2	概率分布	46
2.1	二元变量	46
2.2	多项式变量	51
2.3	高斯分布	54
2.4	指数家族	81
2.5	非参数方法	87
3	线性回归模型	93
3.1	线性基函数模型	93
3.2	偏差-方差分解	101
3.3	贝叶斯线性回归	104
3.4	贝叶斯模型比较	111
3.5	证据近似	114
3.6	固定基函数的局限性	120
4	线性分类模型	122
4.1	判别函数	123
4.2	概率生成模型	135
4.3	概率判别模型	141
4.4	拉普拉斯近似	150
4.5	贝叶斯逻辑回归	153
5	神经网络	156
5.1	前馈网络函数	157
5.2	网络训练	161
5.3	误差反向传播	168
5.4	黑塞矩阵	174
5.5	神经网络中的正则化	180
5.6	混合密度网络	192
5.7	贝叶斯神经网络	196
6	核方法	202
6.1	对偶表示	203
6.2	构造核函数	204
6.3	径向基函数网络	208

6.4 高斯过程	211
7 稀疏核机	225
7.1 最大间隔分类器	225
7.2 相关向量机	240
8 图模型	250
8.1 贝叶斯网络	250
8.2 条件独立	259
8.3 马尔可夫随机场	267
8.4 图模型中的推断	276
9 混合模型和 EM 算法	296
9.1 K 均值聚类	296
9.2 高斯混合模型	301
9.3 EM 的另一种视角	308
9.4 一般形式的 EM 算法	316
10 近似推断	321
10.1 变分推断	321
10.2 高斯混合的变分推断	330
10.3 变分线性回归	339
10.4 指数族分布	343
10.5 局部变分方法	345
10.6 变分逻辑回归	349
10.7 期望传播	355
11 采样方法	366
11.1 基本采样算法	367
11.2 马尔科夫链蒙特卡罗方法	377
11.3 吉布斯采样	380
11.4 切片采样	384
11.5 混合蒙特卡罗算法	385
11.6 估计配分函数	389
12 连续潜在变量	391
12.1 主成分分析	392
12.2 概率 PCA	399
12.3 核 PCA	412
12.4 非线性潜在变量模型	415
13 序列数据	423
13.1 马尔可夫模型	424
13.2 隐马尔可夫模型	426
13.3 线性动态系统	447


14 组合模型	458
14.1 贝叶斯模型平均	458
14.2 委员会 (Committees)	459
14.3 提升法 (Boosting)	460
14.4 基于树的模型	465
14.5 条件混合模型	468

1 引言

探索数据中的模式（pattern）是一个根本性问题，其相关研究历史悠久。比如，16 世纪第谷·布拉赫（Tycho Brahe）的大量天文观测，使约翰内斯·开普勒（Johannes Kepler）发现了行星运动的经验定律，这反过来又为经典力学的发展提供了跳板。同样，对原子光谱中规律性的发现，在 20 世纪早期量子物理学的发展和验证中发挥了关键作用。模式识别这一领域关注的是通过计算机算法自动发现数据中的规律，并利用这些规律来执行诸如将数据分类到不同类别等操作。

考虑识别手写数字的例子，如图 1.1 所示。每个数字对应一个 28×28 像素的图像，因此可以用一个由 784 个实数构成的向量 $\mathbf{x}$ 来表示。我们的目标是构建一台机器，它能够将这样的向量 $\mathbf{x}$ 作为输入，并输出数字 0, ..., 9 的身份。这是一个非平凡的问题，因为手写体存在极大的多样性。可以通过手工制定规则或启发式方法，根据笔画的形状来区分数字，但在实践中，这种方法会导致规则及其例外情况的大量增加，结果不可避免地会很差。

图 1.1 来自美国邮政编码（US zip codes）
的手写数字示例



通过采用机器学习的方法，可以获得更好的结果。在这种方法中，使用一个包含 N 个数字的集合 $\{\mathbf{x}_1, \dots, \mathbf{x}_N\}$ ，称为训练集，来调整自适应模型的参数。训练集中的数字类别是事先已知的，通常通过逐个检查并手工标注得到。我们可以用目标向量 $\mathbf{t}$ 来表示一个数字的类别，它刻画了对应数字的身份。关于如何用向量来表示类别的合适技术，将在后文讨论。需要注意的是，对于每一个数字图像 $\mathbf{x}$ ，都有一个相应的目标向量 $\mathbf{t}$ 。

运行机器学习算法的结果可以表示为一个函数 $\mathbf{y}(\mathbf{x})$ ，它以一个数字图像 $\mathbf{x}$ 作为输入，并生成一个输出向量 $\mathbf{y}$ ，其编码方式与目标向量相同。函数 $\mathbf{y}(\mathbf{x})$ 的精确形式是在训练阶段（也称为学习阶段）中根据训练数据确定的。一旦模型完成训练，它就可以识别新的数字图像，这些新的图像被称为测试集。能够正确分类与训练中使用的样本不同的新样本的能力，被称为泛化。在实际应用中，输入向量的变化范围通常非常大，以至于训练数据只能覆盖所有可能输入向量的一小部分，因此，泛化是模式识别中的核心目标。

在大多数实际应用中，原始输入变量通常会经过预处理，将其转换到某个新的变量空间中，在这个空间里，希望模式识别问题更容易解决。以数字识别问题为例，数字图像通常会被平移和缩放，使得每个数字都被包含在一个固定大小的方框中。这样大大减少了每个数字类别内部的变化，因为所有数字的位置和尺度都相同，从而使得后续的模式识别算法更容易区分不同的类别。这个预处理阶段有时也被称为特征提取。需要注意

的是，新的测试数据必须使用与训练数据相同的步骤进行预处理。

预处理也可能是为了加快计算速度。例如，如果目标是在高分辨率视频流中实现实时人脸检测，计算机必须每秒处理海量像素，而将这些像素直接输入复杂的模式识别算法在计算上可能不可行。相反，目标是找到既能快速计算、又能保留有用区分信息的特征，以便将人脸与非人脸区分开来。这些特征随后被用作模式识别算法的输入。例如，可以非常高效地计算图像在矩形子区域内的平均强度值（Viola 和 Jones，2004），而一组这样的特征在快速人脸检测中可能非常有效。由于这类特征的数量少于像素的数量，这种预处理也可以看作是一种降维。不过，在预处理过程中必须谨慎，因为往往会丢弃部分信息，如果这些信息对问题的解决是关键的，那么系统的整体准确率可能会受到影响。

在训练数据由输入向量及其对应的目标向量组成的应用中，这类问题被称为监督学习问题。像数字识别这种需要将每个输入向量分配到有限个离散类别之一的情况，被称为分类问题。如果期望的输出由一个或多个连续变量构成，那么任务就称为回归。一个回归问题的例子是预测化工制造过程中的产量，其输入由反应物的浓度、温度和压力组成。

在其他模式识别问题中，训练数据仅由一组输入向量 $\mathbf{x}$ 组成，而没有对应的目标值。在这种无监督学习问题中，目标可能是发现数据中相似样本的分组，这称为聚类；或者确定输入空间中数据的分布，这称为密度估计；或者将数据从高维空间投影到二维或三维空间，以便进行可视化。

最后，强化学习（Sutton 和 Barto，1998）所研究的问题是在给定情境下找到合适的动作，以使奖励最大化。与监督学习不同，这里的学习算法并不会得到最优输出的示例，而是必须通过试错的过程去发现它们。通常情况下，这涉及到一个状态和动作的序列，在其中学习算法不断与环境交互。在许多情形下，当前动作不仅影响即时奖励，还会对随后的所有时间步的奖励产生影响。

例如，通过使用合适的强化学习技术，神经网络可以学会高水平地玩西洋双陆棋（backgammon）（Tesauro，1994）。在这里，网络必须学会将棋盘位置与掷骰子的结果作为输入，并生成一个强有力的走棋作为输出。这通常通过让网络与它自己的副本对弈上百万局来实现。一个主要的挑战在于，一局西洋双陆棋可能包含数十步操作，而胜利这种奖励只会在游戏结束时才出现。此时必须将奖励合理地归因到导致它的所有动作上，即便其中有些动作很好，有些动作则不那么好。这就是所谓的信用分配问题（credit assignment problem）。

强化学习的一个普遍特征是探索与利用之间的权衡：探索是系统尝试新的动作方式以观察其效果，而利用则是系统使用那些已知能带来高奖励的动作。如果过度偏重探索或利用，都会导致较差的结果。强化学习仍然是机器学习研究中的一个活跃领域。然而，详细的讨论超出了本书的范围。


虽然这些任务各自需要不同的工具和技术，但支撑它们的许多关键思想在所有这类问题中都是共通的。本章的主要目标之一，就是以一种相对非正式的方式介绍其中若

干最重要的概念，并通过简单的例子加以说明。在本书后面的内容中，我们会看到这些思想再次出现，不过那时它们将出现在更复杂的模型背景下，而这些模型适用于现实世界中的模式识别应用。本章还提供了对三种重要工具的自成体系的介绍，即概率论、决策论和信息论。尽管这些主题听起来可能让人望而生畏，但实际上它们相对直观，并且要想在实际应用中最有效地使用机器学习技术，对它们的清晰理解是必不可少的

1.1 例子：多项式曲线拟合

我们首先介绍一个简单的回归（regression）问题，并将在本章中反复使用它作为示例，以引出若干关键概念。假设我们观察到一个实值输入变量 x ，并希望利用这一观测来预测一个实值目标变量 t 的值。为了当前的目的，考虑一个使用人工合成数据的例子是有启发性的，因为这样我们就确切知道生成数据的过程，可以将其与任何学习到的模型进行比较。本例中的数据由函数 $\sin(2\pi x)$ 生成，并在目标值中加入了随机噪声。关于这一数据生成过程的详细描述见附录??。

图 1.2 一个包含 $N = 10$ 个点的训练数据集的示意图，以蓝色圆点表示；每个点由输入变量 x 的一次观测及其对应的目标变量 t 构成。绿色曲线表示用于生成数据的函数 $\sin(2\pi x)$ 。我们的目标是在不知道这条绿色曲线的情况下，对某个新的 x 值预测对应的 t 值。



现在假设我们得到了一个包含 N 个观测值的训练集，其中输入记作 $\mathbf{x} \equiv (x_1, \dots, x_N)^T$ ，并且有与之对应的目标值观测，记作 $\mathbf{t} \equiv (t_1, \dots, t_N)^T$ 。图 1.2 显示了一个包含 $N = 10$ 个数据点的训练集。图 1.2 中的输入数据集 $\mathbf{x}$ 是通过在区间 $[0, 1]$ 上均匀选取 x_n 的值 ($n = 1, \dots, N$) 生成的；目标数据集 $\mathbf{t}$ 则是先计算相应的函数值 $\sin(2\pi x)$ ，然后在每个点上加入一个服从高斯分布（Gaussian distribution，见 1.2.4 节）的随机噪声，从而得到对应的 t_n 。通过这种方式生成数据，我们刻画了许多真实数据集的一个特性，即它们具有某种潜在的规律性，而我们希望学习到这一规律性，但同时单个观测值会受到随机噪声的干扰。这种噪声可能来自内在的随机过程（如放射性衰变），但更常见的情况是，由一些我们未能观测到的可变因素所导致。

我们的目标是利用这个训练集，在某个新的输入变量 $\hat{x}$ 的取值下预测目标变量 $\hat{t}$ 的值。正如我们稍后将看到的，这实际上涉及到隐式地试图发现潜在的函数 $\sin(2\pi x)$ 。由于我们必须从有限的数据集中进行泛化，这本质上是一个困难的问题。更进一步，观测数据中还包含噪声，因此对于给定的 $\hat{x}$ ，对应的 $\hat{t}$ 值存在不确定性。概率论（probability


theory，见 1.2 节）提供了一个框架，可以以精确且定量的方式表达这种不确定性；而决策论（decision theory，见 1.5 节）则使我们能够利用这种概率表示，依据合适的准则做出最优的预测。

不过，就目前而言，我们将采用一种比较非正式的方法，考虑一种基于曲线拟合（curve fitting）的简单思路。具体来说，我们将使用如下形式的多项式函数来拟合数据：

$$y(x, \mathbf{w}) = w_0 + w_1x + w_2x^2 + \cdots + w_Mx^M = \sum_{j=0}^M w_jx^j \quad (1.1)$$

其中， M 表示多项式的阶数， x^j 表示 x 的 j 次幂。多项式的系数 $w_0, \dots, w_M$ 共同记作向量 $\mathbf{w}$ 。需要注意的是，虽然多项式函数 $y(x, \mathbf{w})$ 是关于 x 的非线性函数，但它关于系数向量 $\mathbf{w}$ 却是线性的。像多项式这样的函数，在未知参数上是线性的，具有重要的性质，被称为线性模型（linear models），并将在第 3 章和第 4 章中进行深入讨论。

图 1.3 误差函数 (1.2) 对应于每个数据点与函数 $y(x, \mathbf{w})$ 之间偏差平方和的一半，其中这些偏差由垂直的绿色线段表示。



系数的取值将通过将多项式拟合到训练数据来确定。这可以通过最小化一个误差函数来实现，该误差函数用于度量函数 $y(x, \mathbf{w})$ （对于任意给定的 $\mathbf{w}$ ）与训练数据点之间的不匹配程度。一种简单且被广泛使用的误差函数选择是：计算每个数据点 x_n 的预测值 $y(x_n, \mathbf{w})$ 与对应目标值 t_n 之间误差的平方和。于是我们需要最小化

$$E(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N (y(x_n, \mathbf{w}) - t_n)^2 \quad (1.2)$$

其中的因子 $1/2$ 是为了后续推导的方便而引入的。我们将在本章后面讨论选择这种误差函数的动机。这里先简单指出，该误差函数始终是非负的，并且当且仅当函数 $y(x, \mathbf{w})$ 恰好通过每一个训练数据点时，其值才为零。平方和误差函数的几何解释如图 1.3 所示。我们可以通过选择使 $E(\mathbf{w})$ 尽可能小的 $\mathbf{w}$ 来解决曲线拟合问题。由于误差函数是系数 $\mathbf{w}$ 的二次函数，它对各个系数的导数关于 $\mathbf{w}$ 的各分量是线性的，因此该误差函数的最小化具有唯一解，记作 $\mathbf{w}^*$ ，并且可以通过闭式形式求解。最终得到的多项式由函数 $y(x, \mathbf{w}^*)$ 给出。

还剩下一个问题，即如何选择多项式的阶数 M 。正如我们将看到的，这将成为一个重要概念的例子，该概念被称为模型比较（model comparison）或模型选择（model selection）。在图 1.4 中，我们展示了将阶数分别为 $M = 0, 1, 3, 9$ 的多项式拟合到图 1.2

所示数据集上的四个结果示例。




图 1.4 不同阶数 M 的多项式拟合结果示意图，以红色曲线表示，并拟合到图 1.2 所示的数据集上。

我们注意到，常数多项式 ($M = 0$) 和一次多项式 ($M = 1$) 对数据的拟合效果较差，因此对函数 $\sin(2\pi x)$ 的表示也很差。三次多项式 ($M = 3$) 似乎在图 1.4 所示的几个例子中给出了对函数 $\sin(2\pi x)$ 的最佳拟合。当我们采用更高阶的多项式 ($M = 9$) 时，得到的结果在训练数据上的拟合非常好。事实上，该多项式恰好通过了每一个数据点，并且满足 $E(\mathbf{w}^*) = 0$ 。然而，拟合曲线出现剧烈震荡，对函数 $\sin(2\pi x)$ 的表示反而非常糟糕。这种现象称为过拟合 (over-fitting)。


正如前面提到的，我们的目标是通过对新数据做出准确预测来实现良好的泛化。为了定量分析泛化性能对 M 的依赖关系，我们可以考虑一个单独的测试集，该测试集包含 100 个数据点，这些数据点的生成方式与训练集完全相同，但在目标值中加入的随机噪声取值不同。对于每一个 M 的选择，我们都可以计算训练数据对应的残差值 $E(\mathbf{w}^*)$ (由公式 1.2 给出)，同时也可以计算测试数据集上的 $E(\mathbf{w}^*)$ 。有时使用均方根误差 (root-mean-square error, RMS error) 会更加方便，其定义为

$$E_{\text{RMS}} = \sqrt{\frac{2E(\mathbf{w}^*)}{N}} \quad (1.3)$$

在这里，除以 N 使我们能够在比较不同规模的数据集时保持一致，而开平方则确保 E_{RMS} 与目标变量 t 的量纲和单位相同。图 1.5 给出了在不同 M 值下，训练集和测试集的均方根误差的曲线。测试集误差衡量了我们在新输入 x 的观测值上预测目标变量 t 的效果。由图 1.5 可见，当 M 较小时，测试集误差相对较大，这是因为相应的多项式缺乏灵活性，无法刻画函数 $\sin(2\pi x)$ 的振荡特性。当 $3 \leq M \leq 8$ 时，测试集误差较小，同时对生成函数 $\sin(2\pi x)$ 的表示也较为合理，例如从图 1.4 中 $M = 3$ 的情况可以清楚地

看到这一点。

图 1.5 在不同 M 取值下，训练集与独立测试集上的均方根误差（由公式 1.3 定义）曲线图。



当 $M = 9$ 时，训练集误差为零，这是意料之中的结果，因为该多项式包含 10 个自由度，对应于 10 个系数 $w_0, \dots, w_9$ ，因此可以完全拟合训练集中的 10 个数据点。然而，此时测试集误差却变得非常大，并且正如图 1.4 所示，相应的函数 $y(x, \mathbf{w}^*)$ 出现了剧烈的震荡。

这看起来似乎是一个悖论，因为一个给定阶数的多项式包含所有低阶多项式作为特殊情形。因此， $M = 9$ 的多项式理应能够给出至少与 $M = 3$ 多项式一样好的结果。进一步来说，我们或许会认为，对新数据的最佳预测器应当是生成数据的函数 $\sin(2\pi x)$ （我们将在后面看到，这确实如此）。我们知道，函数 $\sin(2\pi x)$ 的幂级数展开包含所有阶的项，因此我们可能会预期，随着 M 的增大，结果应当单调改进。

我们可以通过考察不同阶数多项式所得到的系数 $\mathbf{w}^*$ 的数值（如表 1.1 所示），对这一问题获得一些直观认识。可以看到，随着 M 的增加，系数的数值大小通常会变得更大。特别是在 $M = 9$ 的多项式中，这些系数被精细地调节为较大的正值和负值，从而使得相应的多项式函数能够恰好通过所有数据点，但在数据点之间（尤其是在区间两端附近），函数表现出图 1.4 中所观察到的剧烈震荡。直观地讲，发生的情况是：当 M 较大时，多项式的灵活性增强，它们逐渐开始拟合目标值中的随机噪声。

表 1.1 不同阶数多项式对应的系数 $\mathbf{w}^*$ 表格。可以看到，随着多项式阶数的增加，系数的典型大小急剧增大。

	$M = 0$	$M = 1$	$M = 6$	$M = 9$
w_0^*	0.19	0.82	0.31	0.35
w_1^*		-1.27	7.99	232.37
w_2^*			-25.43	-5321.1
w_3^*			17.37	48568.31
w_4^*				-231639.30
w_5^*				640042.26
w_6^*				-1061800.52
w_7^*				-557682.99
w_8^*				125201.43

考察在数据集规模变化时给定模型的行为也很有趣，如图 1.6 所示。可以看到，对于一个固定的模型复杂度，随着数据集规模的增大，过拟合问题会减轻。换句话说，数

数据集越大，我们就能承受将越复杂（即更灵活）的模型拟合到数据中。有一种经验性启发认为，数据点的数量至少应当是模型中自适应参数数量的若干倍（例如 5 或 10）。然而，正如我们将在第 3 章中看到的，参数的数量并不一定是衡量模型复杂度的最合适指标。




图 1.6 通过最小化平方和误差函数所得到的 $M = 9$ 多项式解的曲线图：左图为 $N = 15$ 个数据点的情况，右图为 $N = 100$ 个数据点的情况。可以看到，增大数据集的规模能够减轻过拟合问题。

此外，将模型中的参数数量限制为与可用训练集的规模相适应，这种做法多少让人感到不够理想。更合理的方式似乎是根据所要解决问题的复杂性来选择模型的复杂度。我们将看到，用最小二乘法来求解模型参数可以看作是最大似然（maximum likelihood，见 1.2.5 节）的一个特例，而过拟合问题可以理解为最大似然的一种普遍性质。通过采用贝叶斯方法，可以避免过拟合问题。我们还将看到，从贝叶斯的角度来看，使用参数数量远大于数据点数量的模型并不存在困难。事实上，在贝叶斯模型中，有效参数数量会自动适应数据集的规模。

不过，目前继续采用当前的方法仍然是有启发性的，我们将考虑在实际中如何将其应用到规模有限的数据集上，同时又希望使用相对复杂和灵活的模型。在这种情况下，一个常用来控制过拟合现象的技术是正则化（regularization），其做法是在误差函数 (1.2) 中加入一个惩罚项，以抑制系数取过大的值。最简单的惩罚项形式是所有系数平方和，从而得到修正后的误差函数：

$$\tilde{E}(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N (y(x_n, \mathbf{w}) - t_n)^2 + \frac{\lambda}{2} \|\mathbf{w}\|^2 \quad (1.4)$$

其中， $\|\mathbf{w}\|^2 \equiv \mathbf{w}^T \mathbf{w} = w_0^2 + w_1^2 + \cdots + w_M^2$ ，系数 λ 控制正则化项相对于平方和误差项的重要性。需要注意的是， w_0 常常不包含在正则化项中，因为将其包括进去会导致结果依赖于目标变量的原点选择（Hastie 等，2001），或者它也可以被包括进去，但赋予一个单独的正则化系数（这一问题将在 5.5.1 节中更详细讨论）。同样，(1.4) 式中的误差函数可以通过闭式形式精确地最小化。这类技术在统计学文献中被称为收缩方法（shrinkage methods），因为它们会减小系数的数值。二次正则化的特殊情形被称为岭回归（ridge regression，Hoerl 和 Kennard，1970）。在神经网络的背景下，这种方法被称为权重衰减（weight decay）。




图 1.7 利用正则化误差函数 (1.4) 将 $M = 9$ 的多项式拟合到图 1.2 所示数据集的结果曲线图，其中正则化参数 λ 分别取 $\ln \lambda = -18$ 和 $\ln \lambda = 0$ 。无正则化的情况，即 $\lambda = 0$ （对应 $\ln \lambda = -\infty$ ），见图 1.4 的右下角。

图 1.7 展示了将阶数 $M = 9$ 的多项式拟合到与之前相同的数据集上，但这次使用的是正则化误差函数 (1.4) 的结果。可以看到，当 $\ln \lambda = -18$ 时，过拟合现象得到了抑制，此时得到的曲线更接近潜在函数 $\sin(2\pi x)$ 。然而，如果 λ 的取值过大，则同样会得到较差的拟合效果，如图 1.7 中 $\ln \lambda = 0$ 的情况所示。表 1.2 给出了对应拟合多项式的系数，结果显示正则化确实达到了减小系数数值大小的效果。


表 1.2 $M = 9$ 多项式在不同正则化参数		$\ln \lambda = -\infty$	$\ln \lambda = -18$	$\ln \lambda = 0$
λ 下的系数 $\mathbf{w}^*$ 表格。需要注意的	w_0^*	0.35	0.35	0.13
是， $\ln \lambda = -\infty$ 对应于无正则化	w_1^*	232.37	4.74	-0.05
的模型，即图 1.4 右下角的情况。	w_2^*	-5321.83	-0.77	-0.06
可以看到，随着 λ 的增大，系数	w_3^*	48568.31	-31.97	-0.05
的典型大小逐渐减小。	w_4^*	-231639.30	-3.89	-0.03
	w_5^*	640042.26	55.28	-0.02
	w_6^*	-1061800.52	41.32	-0.01
	w_7^*	1042400.18	-45.92	-0.00
	w_8^*	-557682.99	-91.53	0.00
	w_9^*	125201.43	72.68	0.01

通过绘制训练集和测试集的均方根误差 (1.3) 随 $\ln \lambda$ 变化的曲线（如图 1.8 所示），可以看到正则化项对泛化误差的影响。结果表明， λ 实际上控制了模型的有效复杂度，从而决定了过拟合的程度。

模型复杂度的问题非常重要，将在 1.3 节中进行详细讨论。这里我们只需注意，如果要用这种最小化误差函数的方法来解决一个实际应用，就必须找到确定合适模型复杂度的方法。前面的结果给出了一个简单的思路，即将可用数据划分为训练集和验证集（也称为留出集 **hold-out set**）：训练集用于确定系数 $\mathbf{w}$ ，验证集用于优化模型复杂度（无论是 M 还是 λ ）。然而，在许多情况下，这种方法会过于浪费宝贵的训练数据，因此我们需要寻找更复杂的方法。

到目前为止，我们对多项式曲线拟合的讨论主要依赖直觉。现在我们转向概率论，

图 1.8 $M = 9$ 多项式情况下，均方根误差（公式 (1.3)）随 $\ln \lambda$ 变化的曲线图。




以寻求一种更有原则的方法来解决模式识别中的问题。概率论不仅为本书后续几乎所有的发展奠定基础，同时还能帮助我们在多项式曲线拟合的背景下，对已介绍的概念获得更深入的理解，并使我们能够将这些概念扩展到更复杂的情形中。

1.2 概率论

模式识别领域的一个关键概念是不确定性。它既来源于测量中的噪声，也来源于数据集规模的有限性。概率论提供了一个一致的框架来刻画和处理不确定性，并构成模式识别的核心基础之一。当它与决策论（见 1.5 节）结合时，即使在信息不完整或含糊的情况下，也能使我们基于所有可用信息做出最优预测。

我们将通过一个简单的例子来介绍概率论的基本概念。设想有两个盒子，一个红色，一个蓝色：红色盒子里有 2 个苹果和 6 个橙子，蓝色盒子里有 3 个苹果和 1 个橙子，如图 1.9 所示。现在假设我们随机选择一个盒子，然后从该盒子中随机取出一个水果，观察它的种类后再将其放回原来的盒子中。我们可以想象将这一过程重复很多次。假设在这个过程中，选择红色盒子的概率为 40%，选择蓝色盒子的概率为 60%；并且当我们从某个盒子里取水果时，盒子里的每个水果被选中的可能性相同。

图 1.9 我们用一个简单的例子来引入概率（probability）的基本概念：两个有颜色的盒子，每个盒子里都装有水果（绿色表示苹果，橙色表示橙子）。



在这个例子中，被选中的盒子的身份是一个随机变量，记作 B 。该随机变量可以取两个可能的值： r （对应红色盒子）或 b （对应蓝色盒子）。类似地，水果的身份也是一

个随机变量，记作 F ，它可以取值 a （表示苹果）或 o （表示橙子）。


首先，我们将事件的概率定义为：当试验次数趋于无穷大时，该事件发生的频率。由此可得，选择红色盒子的概率为 $4/10$ ，选择蓝色盒子的概率为 $6/10$ 。我们将这些概率写作 $p(B=r) = \frac{4}{10}$ ， $p(B=b) = \frac{6}{10}$ 。需要注意的是，按照定义，概率必须落在区间 $[0, 1]$ 内。此外，如果事件是互斥的并且包含了所有可能结果（例如在本例中，盒子必须是红色或蓝色），那么这些事件的概率之和必须为 1。

现在我们可以提出这样的问题：“选出的水果是苹果的总概率是多少？”或者“在已知选中的是橙子的情况下，被选择的盒子是蓝色的概率是多少？”一旦掌握了概率的两个基本法则，即加法法则和乘法法则，我们就能回答这些问题，甚至是与模式识别相关的更复杂的问题。在介绍完这些法则之后，我们将回到水果盒子的例子。

为了推导概率法则，考虑图 1.10 所示的一个更一般的例子，其中包含两个随机变量 X 和 Y （例如可以对应上面提到的盒子和水果变量）。假设 X 可以取值 x_i ，其中 $i = 1, \dots, M$ ，而 Y 可以取值 y_j ，其中 $j = 1, \dots, L$ 。设进行 N 次试验，每次同时对变量 X 和 Y 取样。在 N 次试验中， $X = x_i$ 且 $Y = y_j$ 的次数记作 n_{ij} 。同时， X 取值为 x_i 的次数（不论 Y 取何值）记作 c_i ；类似地， Y 取值为 y_j 的次数记作 r_j 。

图 1.10 我们可以通过考虑两个随机变量来推导概率的加法

法则和乘法法则。设随机变量 X 的取值为 x_i ，其中 $i = 1, \dots, M$ ；随机变量 Y 的取值为 y_j ，其中 $j = 1, \dots, L$ 。在这个例子中，我们取 $M = 5$ ， $L = 3$ 。如果考虑这两个变量的总实例数为 N ，那么当 $X = x_i$ 且 $Y = y_j$ 时的实例数记作 n_{ij} ，它表示数组对应单元格中的点数。第 i 列的点数（对应 $X = x_i$ ）记作 c_i ，第 j 行的点数（对应 $Y = y_j$ ）记作 r_j 。



X 取值为 x_i 且 Y 取值为 y_j 的概率记作 $p(X = x_i, Y = y_j)$ ，称为 $X = x_i$ 与 $Y = y_j$ 的联合概率。它由落在单元格 (i, j) 中的点数占总点数的比例给出，因此有

$$p(X = x_i, Y = y_j) = \frac{n_{ij}}{N} \quad (1.5)$$

这里我们隐含地考虑极限 $N \rightarrow \infty$ 。类似地， X 取值为 x_i 的概率（不论 Y 取何值）记作 $p(X = x_i)$ ，它由第 i 列中点数占总点数的比例给出，因此有

$$p(X = x_i) = \frac{c_i}{N} \quad (1.6)$$

因为图 1.10 中第 i 列的实例数正好是该列中各个单元格实例数的总和，即 $c_i = \sum_j n_{ij}$ ，因此由 (1.5) 和 (1.6) 可得

$$p(X = x_i) = \sum_j p(X = x_i, Y = y_j) \quad (1.7)$$

这就是概率的加法法则。需要注意， $p(X = x_i)$ 有时也称为边缘概率，因为它是通过对其他变量（在本例中为 Y ）边缘化，即求和消去后得到的。

如果我们只考虑 $X = x_i$ 的那些实例，那么其中 $Y = y_j$ 的比例记作 $p(Y = y_j | X = x_i)$ ，称为在 $X = x_i$ 条件下 $Y = y_j$ 的条件概率。它由第 i 列中落在单元格 (i, j) 的点数占该列总点数的比例给出，因此有

$$p(Y = y_j | X = x_i) = \frac{n_{ij}}{c_i} \quad (1.8)$$

由 (1.5)、(1.6) 和 (1.8) 可推得如下关系

$$\begin{aligned} p(X = x_i, Y = y_j) &= \frac{n_{ij}}{N} = \frac{n_{ij}}{c_i} \cdot \frac{c_i}{N} \\ &= p(Y = y_j | X = x_i) p(X = x_i) \end{aligned} \quad (1.9)$$

这就是概率的乘法法则 (product rule)。

到目前为止，我们一直严格区分随机变量与其可能取的值。例如在水果的例子中，盒子 B 是随机变量，而它的一个取值可以是 r (表示红色盒子)。因此， B 取值为 r 的概率记作 $p(B = r)$ 。虽然这种写法有助于避免歧义，但符号会显得冗长，而在许多情况下并不需要如此繁琐。通常我们可以直接写 $p(B)$ 表示随机变量 B 的分布，或者写 $p(r)$ 表示分布在特定取值 r 处的值，只要上下文能保证含义清晰即可。

采用这种更简洁的符号，我们可以将概率论的两个基本法则写成如下形式：

概率法则

$$\text{求和法则} \quad p(X) = \sum_Y p(X, Y) \quad (1.10)$$

$$\text{乘法法则} \quad p(X, Y) = p(Y | X) p(X) \quad (1.11)$$

这里 $p(X, Y)$ 是联合概率，读作“ X 和 Y 的概率”。类似地， $p(Y | X)$ 是条件概率，读作“在 X 已知的条件下 Y 的概率”；而 $p(X)$ 是边缘概率，即“ X 的概率”。这两个简单的法则构成了本书中所使用的全部概率方法的基础。

由乘法法则及对称性 $p(X, Y) = p(Y, X)$ ，我们立刻可以得到条件概率之间的如下关系：

$$p(Y | X) = \frac{p(X | Y) p(Y)}{p(X)} \quad (1.12)$$

这被称为贝叶斯定理，它在模式识别和机器学习中起着核心作用。利用加法法则，贝叶斯定理中分母可以用分子中出现的量来表示：

$$p(Y | X) = \frac{p(X | Y) p(Y)}{\sum_Y p(X | Y) p(Y)} \quad (1.13)$$

在贝叶斯定理中，分母可以看作是归一化常数，其作用是确保 (1.12) 左边条件概率对所有 Y 的取值求和等于 1。

在图 1.11 中，我们展示了一个关于两个变量的联合分布的简单例子，用来说明边缘分布和条件分布的概念。这里从联合分布中抽取了 $N = 60$ 个数据点，显示在左上角。




图 1.11 关于两个变量分布的示意图：变量 X 取 9 个可能值，变量 Y 取 2 个可能值。左上图展示了从这两个变量的联合概率分布中抽取的 60 个样本点。其余图则展示了边缘分布 $p(X)$ 和 $p(Y)$ 的直方图估计，以及条件分布 $p(X|Y=1)$ ，该条件分布对应于左上图的最下一行。

右上角给出了 Y 取两个不同值时数据点比例的直方图。根据概率的定义，当 $N \rightarrow \infty$ 时，这些比例将等于相应的概率 $p(Y)$ 。我们可以将直方图视为一种简单的方法，用有限个从分布中抽取的点来建模概率分布。从数据建模分布是统计模式识别的核心问题，并将在本书中深入探讨。图 1.11 中剩下的两幅图展示了 $p(X)$ 和 $p(X|Y=1)$ 的直方图估计。

现在让我们回到水果盒子的例子。此时我们再次明确地区分随机变量及其取值。我们已经看到，选择红色盒子或蓝色盒子的概率分别为

$$p(B=r) = 4/10 \quad (1.14)$$

$$p(B=b) = 6/10 \quad (1.15)$$

分别如上所示。需要注意，它们满足 $p(B=r) + p(B=b) = 1$ 。

现在假设我们随机选择了一个盒子，结果发现是蓝色盒子。那么选择到苹果的概率就是蓝色盒子中苹果的比例，即 $3/4$ ，因此 $p(F=a|B=b) = 3/4$ 。事实上，我们可

以写出在给定选中盒子的情况下，水果种类四个条件概率：

$$p(F = a \mid B = r) = 1/4 \quad (1.16)$$

$$p(F = o \mid B = r) = 3/4 \quad (1.17)$$

$$p(F = a \mid B = b) = 3/4 \quad (1.18)$$

$$p(F = o \mid B = b) = 1/4 \quad (1.19)$$

同样需要注意，这些概率是归一化的，因此满足

$$p(F = a \mid B = r) + p(F = o \mid B = r) = 1 \quad (1.20)$$

$$p(F = a \mid B = b) + p(F = o \mid B = b) = 1 \quad (1.21)$$

现在我们可以利用概率的加法法则和乘法法则来计算选择苹果的总概率：

$$\begin{aligned} p(F = a) &= p(F = a \mid B = r) p(B = r) + p(F = a \mid B = b) p(B = b) \\ &= \frac{1}{4} \cdot \frac{4}{10} + \frac{3}{4} \cdot \frac{6}{10} = \frac{1}{10} + \frac{9}{20} = \frac{11}{20} \end{aligned} \quad (1.22)$$

由此可得，利用加法法则（sum rule），橙子的概率为 $p(F = o) = 1 - \frac{11}{20} = \frac{9}{20}$ 。

现在假设相反的情形：我们只被告知选出了一件水果，并且它是橙子，我们想知道它来自哪个盒子。这就需要评估在给定水果种类条件下盒子的概率分布（probability distribution），而 (1.16)-(1.19) 给出的则是在给定盒子的条件下水果的概率分布。我们可以利用贝叶斯定理（Bayes' theorem）来求解这种条件概率的反转，得到

$$p(B = r \mid F = o) = \frac{p(F = o \mid B = r) p(B = r)}{p(F = o)} = \frac{3}{4} \times \frac{4}{10} \times \frac{20}{9} = \frac{2}{3} \quad (1.23)$$


由加法法则（sum rule）可得 $p(B = b \mid F = o) = 1 - \frac{2}{3} = \frac{1}{3}$ 。

我们可以对贝叶斯定理给出一个重要的解释。如果在得知选出的水果种类之前，我们被问到选择的是哪个盒子，那么我们能利用的最完整信息就是概率 $p(B)$ 。我们称其为先验概率，因为它是在观察水果种类之前可用的概率。而一旦得知选出的水果是橙子，我们就可以利用贝叶斯定理计算 $p(B \mid F)$ ，我们称其为后验概率，因为它是在观察到 F 之后得到的概率。需要注意的是，在这个例子中，选择红色盒子的先验概率是 $4/10$ ，因此在未观察水果前，更可能选择的是蓝色盒子。然而，当我们观察到选出的水果是橙子后，红色盒子的后验概率变为 $2/3$ ，此时更可能选中的是红色盒子。这一结果与直觉一致，因为红色盒子中橙子的比例远高于蓝色盒子，因此观察到橙子为红色盒子提供了强有力的支持。实际上，这一证据强到足以推翻先验，使得红色盒子被选中的可能性超过蓝色盒子。

最后需要指出，如果两个变量的联合分布可以分解为各自边缘分布的乘积，即 $p(X, Y) = p(X) p(Y)$ ，那么称 X 与 Y 相互独立。由乘法法则可知，此时 $p(Y \mid X) = p(Y)$ ，因此在给定 X 的条件下， Y 的条件分布确实与 X 的取值无关。举例来说，在水果盒子的例子中，如果每个盒子中苹果和橙子的比例相同，那么就有 $p(F \mid B) = p(F)$ ，于是选择苹果的概率与选择哪个盒子无关。

1.2.1 概率密度

图 1.12 离散变量的概率概念可以扩展为连续变量 x 上的概率密度 $p(x)$, 此时 x 落在区间 $(x, x + \delta x)$ 内的概率为 $p(x)\delta x$, 当 $\delta x \rightarrow 0$ 。概率密度可以表示为累积分布函数 $P(x)$ 的导数。



除了考虑定义在离散事件集合上的概率之外, 我们还希望研究关于连续变量的概率。这里我们将仅作相对非正式的讨论。若实值变量 x 落在区间 $(x, x + \delta x)$ 内的概率在 $\delta x \rightarrow 0$ 时由 $p(x)\delta x$ 给出, 那么 $p(x)$ 就称为 x 上的概率密度。这一点在图 1.12 中有所展示。变量 x 落在区间 (a, b) 内的概率为

$$p(a \in (a, b)) = \int_a^b p(x) dx \quad (1.24)$$

由于概率必须为非负数, 并且 x 的取值必然落在实数轴上的某处, 概率密度 $p(x)$ 必须满足以下两个条件:

$$p(x) \geq 0 \quad (1.25)$$

$$\int_{-\infty}^{\infty} p(x) dx = 1 \quad (1.26)$$

在非线性变量变换下, 概率密度的变化方式不同于普通函数, 这是由于雅可比因子的存在。例如, 若我们考虑变量变换 $x = g(y)$, 那么一个函数 $f(x)$ 会变为 $\bar{f}(y) = f(g(y))$ 。现在考虑一个概率密度 $p_x(x)$, 它对应于新变量 y 下的概率密度 $p_y(y)$, 这里下标表示 $p_x(x)$ 和 $p_y(y)$ 是不同的密度。落在区间 $(x, x + \delta x)$ 内的观测点, 在 δx 很小时, 会被映射到区间 $(y, y + \delta y)$, 并且满足 $p_x(x) \delta x \simeq p_y(y) \delta y$, 因此有

$$\begin{aligned} p_y(y) &= p_x(x) \left| \frac{dx}{dy} \right| \\ &= p_x(g(y)) |g'(y)| \end{aligned} \quad (1.27)$$

这一性质的一个结果是: 概率密度的最大值这一概念依赖于变量的选择。

变量 x 落在区间 $(-\infty, z)$ 内的概率由累积分布函数定义如下:

$$P(z) = \int_{-\infty}^z p(x) dx \quad (1.28)$$

它满足 $P'(x) = p(x)$, 如图 1.12 所示。

如果我们有多个连续变量 $x_1, \dots, x_D$ ，并将它们统称为向量 $\mathbf{x}$ ，则可以定义联合概率密度 (joint probability density) $p(\mathbf{x}) = p(x_1, \dots, x_D)$ ，使得 $\mathbf{x}$ 落在包含点 $\mathbf{x}$ 的无穷小体积 $\delta\mathbf{x}$ 内的概率为 $p(\mathbf{x})\delta\mathbf{x}$ 。这种多元概率密度必须满足

$$p(\mathbf{x}) \geq 0 \quad (1.29)$$

$$\int p(\mathbf{x}) d\mathbf{x} = 1 \quad (1.30)$$

其中积分在整个 $\mathbf{x}$ 空间上进行。我们也可以考虑同时包含离散变量和连续变量的联合概率分布。需要注意的是，如果 x 是离散变量，那么 $p(x)$ 有时被称为概率质量函数，因为它可以看作是集中在 x 的允许取值上的一组“概率质量”。

概率的加法法则和乘法法则，以及贝叶斯定理，同样适用于概率密度，或者离散与连续变量的组合。例如，如果 x 和 y 是两个实值变量，那么加法法则和乘法法则形式为

$$p(x) = \int p(x, y) dy \quad (1.31)$$

$$p(x, y) = p(y | x) p(x) \quad (1.32)$$

对连续变量的加法法则和乘法法则的严格证明 (Feller, 1966) 需要用到数学中的测度论，这超出了本书的讨论范围。不过，可以通过一种非正式的方式理解其合理性：将每个实值变量划分为宽度为 Δ 的区间，并考虑这些区间上的离散概率分布。当取极限 $\Delta \rightarrow 0$ 时，求和就转化为积分，从而得到所需的结果。

1.2.2 期望与协方差

概率运算中最重要的操作之一是求函数的加权平均值。某个函数 $f(x)$ 在概率分布 $p(x)$ 下的平均值称为 $f(x)$ 的期望，记作 $\mathbb{E}[f]$ 。对于离散分布，其定义为

$$\mathbb{E}[f] = \sum_x p(x) f(x) \quad (1.33)$$

因此，平均值是由不同 x 取值的相对概率加权得到的。对于连续变量，期望可以通过对相应概率密度的积分来表示：

$$\mathbb{E}[f] = \int p(x) f(x) dx \quad (1.34)$$

在这两种情况下，如果我们给定从概率分布或概率密度中抽取的有限个 N 个样本点，那么期望可以用这些点的有限求和来近似表示：

$$\mathbb{E}[f] \simeq \frac{1}{N} \sum_{n=1}^N f(x_n) \quad (1.35)$$

在第 11 章讨论采样方法时，我们将广泛使用这一结果。当 $N \rightarrow \infty$ 时，(1.35) 式中的近似就变为精确结果。

有时我们会考虑多变量函数的期望，这种情况下可以用下标来指示对哪个变量取平均。例如：

$$\mathbb{E}_x[f(x, y)] \quad (1.36)$$

这表示函数 $f(x, y)$ 关于 x 的分布取平均。需要注意， $\mathbb{E}_x[f(x, y)]$ 将是 y 的一个函数。我们还可以考虑关于条件分布的条件期望，其形式为

$$\mathbb{E}[f | y] = \int p(x | y) f(x) dx, \quad (1.37)$$

在连续变量情况下有类似的定义。函数 $f(x)$ 的方差定义为

$$\text{var}[f] = \mathbb{E}[(f(x) - \mathbb{E}[f(x)])^2] \quad (1.38)$$

它刻画了函数 $f(x)$ 围绕其均值 $\mathbb{E}[f(x)]$ 的波动程度。将平方项展开后，可以看到方差也可以用 $f(x)$ 和 $f(x)^2$ 的期望来表示：

$$\text{var}[f] = \mathbb{E}[f(x)^2] - \mathbb{E}[f(x)]^2 \quad (1.39)$$

特别地，变量 x 本身的方差可以写作

$$\text{var}[x] = \mathbb{E}[x^2] - \mathbb{E}[x]^2 \quad (1.40)$$

对于两个随机变量 x 和 y ，协方差定义为

$$\begin{aligned} \text{cov}[x, y] &= \mathbb{E}_{x,y}[\{x - \mathbb{E}[x]\}\{y - \mathbb{E}[y]\}] \\ &= \mathbb{E}_{x,y}[xy] - \mathbb{E}[x]\mathbb{E}[y] \end{aligned} \quad (1.41)$$

它表示 x 和 y 共同变化的程度。如果 x 和 y 相互独立，那么它们的协方差为零。

对于两个随机向量 x 和 y ，协方差是一个矩阵：

$$\begin{aligned} \text{cov}[\mathbf{x}, \mathbf{y}] &= \mathbb{E}_{\mathbf{x}, \mathbf{y}}[\{\mathbf{x} - \mathbb{E}[\mathbf{x}]\}\{\mathbf{y}^T - \mathbb{E}[\mathbf{y}^T]\}] \\ &= \mathbb{E}_{\mathbf{x}, \mathbf{y}}[\mathbf{x}\mathbf{y}^T] - \mathbb{E}[\mathbf{x}]\mathbb{E}[\mathbf{y}^T]. \end{aligned} \quad (1.42)$$

如果我们考虑向量 x 各个分量之间的协方差，那么我们使用一个稍微简单的记号 $\text{cov}[\mathbf{x}] \equiv \text{cov}[\mathbf{x}, \mathbf{x}]$ 。

1.2.3 贝叶斯概率

到目前为止，在本章中我们将概率看作是随机、可重复事件出现频率的角度来理解的。我们称这种解释为经典或频率派的概率解释。现在我们转向更一般的贝叶斯观点，在这种观点下，概率被用来刻画不确定性的太小。

考虑一个不确定的事件，例如月球是否曾经独自绕太阳公转，或者在本世纪末北极冰盖是否会消失。这些事件无法像之前水果盒子的例子那样，通过大量重复试验来定义概率。尽管如此，我们通常还是会有一些判断，比如我们认为极地冰层融化的速度有多快。如果我们获得了新的证据，例如来自新的地球观测卫星的全新诊断信息，我们可能

会修正自己对冰层消融速度的看法。对这些问题的评估会影响我们所采取的行动，例如我们会在多大程度上努力减少温室气体的排放。在这种情况下，我们希望能够量化这种不确定性的表述，并在新的证据出现时对不确定性进行精确修正，同时因此能够采取最优的行动或决策。这一切都可以通过优雅而又非常通用的贝叶斯概率解释来实现。

然而，将概率用于表示不确定性并不是一种临时的随意选择，而是在我们希望在进行理性且自洽的推理时尊重常识的必然结果。举例来说，Cox (1946) 证明了：如果用数值来表示信念的程度，那么只要满足一组简单的公理，这些公理编码了这种信念应当符合的常识性性质，就会唯一地导出一套操作信念程度的法则，而这套法则恰好等价于概率的加法和乘法法则。这为概率论可以被看作布尔逻辑在涉及不确定性情形下的扩展提供了第一个严格的证明 (Jaynes, 2003)。许多其他作者也提出了不同的不确定性度量应当满足的性质或公理体系 (Ramsey, 1931; Good, 1950; Savage, 1961; de Finetti, 1970; Lindley, 1982)。在每种情况下，所得到的数值量都严格遵循概率的法则。因此，把这些数值称为（贝叶斯）概率是非常自然的。

在模式识别领域中，拥有一个更一般化的概率概念同样是有益的。以第 1.1 节讨论的多项式曲线拟合为例，将频率派的概率观念应用到观测变量 t_n 的随机取值似乎是合理的。然而，我们还希望能够处理并量化围绕模型参数 $\mathbf{w}$ 的合适选择所带来的不确定性。我们将看到，从贝叶斯 (Bayesian) 的角度出发，可以利用概率论的工具来刻画模型参数（例如 w ）的不确定性，甚至是模型选择本身所带来的不确定性。

贝叶斯定理在这里获得了新的意义。回忆水果盒子的例子：对水果种类的观测提供了相关信息，从而改变了所选盒子是红色盒子的概率。在那个例子中，贝叶斯定理被用来将先验概率转化为后验概率，其方式是结合观测数据所提供的证据。正如我们稍后将详细看到的，在对某些量进行推断时（例如多项式曲线拟合中的参数 $\mathbf{w}$ ），我们可以采取类似的方法。在观测数据之前，我们通过一个先验概率分布 $p(\mathbf{w})$ 来表达对 $\mathbf{w}$ 的假设。观测到的数据 $\mathcal{D} = \{t_1, \dots, t_N\}$ 的作用则通过条件概率 $p(\mathcal{D}|\mathbf{w})$ 来体现，而我们将在第 1.2.5 节看到如何将其显式地表示出来。贝叶斯定理的形式为

$$p(\mathbf{w}|\mathcal{D}) = \frac{p(\mathcal{D}|\mathbf{w})p(\mathbf{w})}{p(\mathcal{D})} \quad (1.43)$$

然后，这一定理就使我们能够在观测到数据 $\mathcal{D}$ 之后，以后验概率 $p(\mathbf{w}|\mathcal{D})$ 的形式来评估参数 w 的不确定性。

在贝叶斯定理右边的项中， $p(\mathcal{D}|\mathbf{w})$ 是针对观测数据集 $\mathcal{D}$ 计算的，并且可以被看作是参数向量 $\mathbf{w}$ 的函数，这时它被称为似然函数。它刻画了在不同的参数向量 $\mathbf{w}$ 取值下，观测到数据集的可能性有多大。需要注意的是，似然函数并不是关于 $\mathbf{w}$ 的概率分布，它对 $\mathbf{w}$ 的积分并不（必然）等于 1。

有了这种可能性的定义，我们可以用文字来表述贝叶斯定理

$$\text{后验分布} \propto \text{似然函数} \times \text{先验分布} \quad (1.44)$$

这里所有的量都被看作是关于 $\mathbf{w}$ 的函数。(1.43) 式中的分母是归一化常数，它保证左边的后验分布是一个有效的概率密度函数，并且积分为 1。实际上，对 (1.43) 式两边

关于 $\mathbf{w}$ 积分，我们可以将贝叶斯定理中的分母表示为先验分布和似然函数的形式：

$$p(\mathcal{D}) = \int p(\mathcal{D}|\mathbf{w}) p(\mathbf{w}) d\mathbf{w} \quad (1.45)$$

在贝叶斯和频率派这两种范式中，似然函数 $p(\mathcal{D}|\mathbf{w})$ 都扮演着核心角色。然而，两者使用它的方式在根本上是不同的。在频率派的设定下， $\mathbf{w}$ 被视为一个固定的参数，其值通过某种“估计量”来确定，而该估计值的不确定性（误差区间）是通过考虑所有可能的数据集 $\mathcal{D}$ 的分布来获得的。相比之下，从贝叶斯的角度看，数据集 $\mathcal{D}$ 只有一个（也就是实际观测到的那个），参数的不确定性则通过关于 $\mathbf{w}$ 的概率分布来表达。

一种被广泛使用的频率派估计量是最大似然，其中参数 $\mathbf{w}$ 被设定为使似然函数 $p(\mathcal{D}|\mathbf{w})$ 取最大值的那个值。这等价于选择能够使观测数据集概率最大化的参数 $\mathbf{w}$ 。在机器学习文献中，似然函数的负对数被称为误差函数。由于负对数函数是单调递减的，最大化似然等价于最小化误差。

一种确定频率派误差区间的方法是自助法 (Efron, 1979; Hastie et al., 2001)。其过程如下：假设我们的原始数据集包含 N 个数据点 $\mathbf{X} = \{x_1, \dots, x_N\}$ 。我们可以通过从 $\mathbf{X}$ 中有放回地随机抽取 N 个点来构造一个新的数据集 $\mathbf{X}_B$ 。这样， $\mathbf{X}$ 中的一些点可能在 $\mathbf{X}_B$ 中被重复出现，而另一些点可能没有出现在 $\mathbf{X}_B$ 中。这个过程可以重复 L 次，从而生成 L 个大小为 N 的数据集，每个数据集都是从原始数据集 $\mathbf{X}$ 抽样得到的。随后，可以通过考察不同自助数据集之间预测结果的差异性，来评估参数估计的统计精度。

贝叶斯观点的一个优势在于，先验知识的引入是自然而然的。举个例子，假设一枚看起来公平的硬币被抛掷三次，并且每次都朝上。如果采用经典的极大似然方法来估计正面朝上的概率，结果会得到 1，这意味着所有未来的抛掷都会是正面！相比之下，贝叶斯方法结合任意一个合理的先验，都会得出一个远不如此极端的结论。

关于频率派与贝叶斯这两种范式的相对优劣，一直存在大量的争议和辩论，而这种情况更加复杂的原因在于，既不存在唯一的频率派观点，也不存在唯一的贝叶斯观点。例如，对贝叶斯方法的一个常见批评是：先验分布往往是基于数学上的方便性而选择的，而不是对任何真实先验信念的反映。甚至，由于结论依赖于先验的选择而具有主观性，这一点也被一些人视为问题所在。减少对先验依赖性的需求，正是所谓非信息先验的动机之一。然而，这类方法在模型比较时会带来困难；事实上，如果先验选择不当，基于贝叶斯方法的推断可能会在高置信度下给出很差的结果。频率派的评估方法在一定程度上为此类问题提供了一些保护，而诸如交叉验证等技术在模型比较等方面仍然是非常有用的。

本书重点强调贝叶斯观点，这反映了近年来贝叶斯方法在实际应用中的重要性正迅速增长，同时也会在需要的地方讨论一些有用的频率派概念。

尽管贝叶斯框架起源于 18 世纪，但在很长一段时间里，贝叶斯方法的实际应用都受到严重限制，其原因在于难以完整地执行贝叶斯过程，尤其是需要在整个参数空间上进行边缘化 (求和或积分)。正如我们将看到的，这一步在进行预测或比较不同模型时是必需的。采样方法的发展，例如马尔可夫链蒙特卡罗 (第 11 章将讨论)，以及计算机在速度和存储容量上的巨大提升，使得贝叶斯技术在广泛的问题领域中得以实际应用。

蒙特卡罗方法非常灵活，可以应用于多种模型。然而，它们计算量巨大，因此主要被用于小规模问题。

近年来，高效的确定性近似方法得到了发展，例如变分贝叶斯和期望传播 (第 10 章将讨论)。这些方法为采样方法提供了互补的替代方案，并使得贝叶斯技术能够应用于大规模的问题 (Blei et al., 2003)。

1.2.4 高斯分布


我们将在第 2 章中专门研究各种概率分布及其关键性质。然而，在这里先介绍一种最重要的连续型概率分布——正态分布或高斯分布——是很方便的。在本章的后续部分乃至本书的大部分内容中，我们都会广泛使用这一分布。

对于单个实值变量 x ，高斯分布定义为

$$\mathcal{N}(x|\mu, \sigma^2) = \frac{1}{(2\pi\sigma^2)^{1/2}} \exp\left\{-\frac{1}{2\sigma^2}(x - \mu)^2\right\} \quad (1.46)$$

该分布由两个参数控制： μ ，称为均值；以及 σ^2 ，称为方差。方差的平方根记为 σ ，称为标准差；方差的倒数记为 $\beta = 1/\sigma^2$ ，称为精度。我们很快将看到这些术语的动机。图 1.13 展示了高斯分布的曲线图。

图 1.13 一维高斯分布的示意图，展示了均值 μ 和标准差 σ 。



由 (1.46) 式的形式可以看出，高斯分布满足

$$\mathcal{N}(x|\mu, \sigma^2) > 0 \quad (1.47)$$

此外，很容易证明高斯分布是归一化的，因此

$$\int_{-\infty}^{\infty} \mathcal{N}(x|\mu, \sigma^2) dx = 1 \quad (1.48)$$

因此，(1.46) 式满足一个有效概率密度的两个要求。

我们可以很容易地求出在高斯分布下函数 x 的期望。特别地， x 的平均值由下式给出：

$$\mathbb{E}[x] = \int_{-\infty}^{\infty} x \mathcal{N}(x|\mu, \sigma^2) dx = \mu \quad (1.49)$$

由于参数 μ 表示在该分布下 x 的平均值，因此称其为均值。类似地，对于二阶矩：

$$\mathbb{E}[x^2] = \int_{-\infty}^{\infty} \mathcal{N}(x|\mu, \sigma^2) dx = \mu^2 + \sigma^2 \quad (1.50)$$

由 (1.49) 和 (1.50) 可得， x 的方差为

$$\text{var}[x] = \mathbb{E}[x^2] - (\mathbb{E}[x])^2 = \sigma^2 \quad (1.51)$$

因此， σ^2 被称为方差参数。分布的最大值称为众数 (mode)。对于高斯分布，众数与均值是一致的。

我们同样关心定义在 D 维连续变量向量 $\mathbf{x}$ 上的高斯分布，其形式为

$$\mathcal{N}(\mathbf{x}|\boldsymbol{\mu}, \Sigma) = \frac{1}{(2\pi)^{D/2}|\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu})\right) \quad (1.52)$$


其中， D 维向量 $\boldsymbol{\mu}$ 称为均值， $D \times D$ 的矩阵 Σ 称为协方差，而 $|\Sigma|$ 表示 Σ 的行列式。在本章中我们会简单使用多元高斯分布，而它的性质将在第 2.3 节中进行详细研究。

现在假设我们有一个观测数据集 $\mathbf{x} = (x_1, \dots, x_N)^T$ ，表示对标量变量 x 的 N 次观测。需要注意的是，我们使用字体 $\mathbf{x}$ 来与单个向量值变量的观测 $(x_1, \dots, x_D)^T$ 区分开，后者记为 $\mathbf{x}$ 。我们假设这些观测是从一个均值 μ 和方差 σ^2 都未知的高斯分布中独立抽取的，而我们的目标是根据数据集来确定这些参数。如果数据点是从同一分布中独立抽取的，就称它们为独立同分布 (i.i.d.)。我们已经看到，两个独立事件的联合概率等于它们各自边缘概率的乘积。由于数据集 $\mathbf{x}$ 是 i.i.d. 的，因此在给定 μ 和 σ^2 的条件下，数据集的概率可以写成：

$$p(\mathbf{x}|\mu, \sigma^2) = \prod_{n=1}^N \mathcal{N}(x_n|\mu, \sigma^2) \quad (1.53)$$

当把它视为 μ 和 σ^2 的函数时，它就是高斯分布的似然函数。图 1.14 对其作了示意性的解释。

图 1.14 高斯分布似然函数的示意图由红色曲线表示。黑点表示数据集 x_n ，公式 1.53 给出的似然函数对应于这些蓝色数值的乘积。最大化似然的过程就是通过调整高斯分布的均值和方差，使得这个乘积最大化。



利用观测数据集来确定概率分布参数的一个常见准则是，寻找能使似然函数最大化的参数值。乍一看，这似乎是一个奇怪的准则，因为根据我们之前对概率论的讨论，更自然的做法似乎是最大化在给定数据条件下参数的概率，而不是在给定参数条件下数据的概率。事实上，这两个准则是相关的，我们将在曲线拟合的背景下对此进行讨论。

目前，我们将通过最大化似然函数 (1.53) 来确定高斯分布中未知参数 μ 和 σ^2 的取值。在实际操作中，更方便的方法是最大化似然函数的对数。由于对数函数是其自变量的单调递增函数，最大化函数的对数等价于最大化函数本身。

取对数不仅简化了后续的数学分析，同时在数值计算上也更有利，因为大量小概率值的乘积很容易导致计算机的数值精度下溢，而改为计算对数概率的和则可以避免这一问题。

由 (1.46) 和 (1.53) 可得，对数似然函数可以写成如下形式：

$$\ln p(\mathbf{x}|\mu, \sigma^2) = -\frac{1}{2\sigma^2} \sum_{n=1}^N (x_n - \mu)^2 - \frac{N}{2} \ln \sigma^2 - \frac{N}{2} \ln(2\pi) \quad (1.54)$$

对 (1.54) 式关于 μ 最大化，可得最大似然解：

$$\mu_{\text{ML}} = \frac{1}{N} \sum_{n=1}^N x_n \quad (1.55)$$

这就是样本均值 (sample mean)，即观测值 $\{x_n\}$ 的平均值。类似地，对 (1.54) 式关于 σ^2 最大化，可得方差的最大似然解为

$$\sigma_{\text{ML}}^2 = \frac{1}{N} \sum_{n=1}^N (x_n - \mu_{\text{ML}})^2 \quad (1.56)$$

这就是关于样本均值 μ_{ML} 计算的样本方差。需要注意的是，我们实际上是对 (1.54) 式关于 μ 和 σ^2 进行联合最大化，但在高斯分布的情形下， μ 的解与 σ^2 的解是解耦的，因此我们可以先计算 (1.55)，然后再利用该结果去计算 (1.56)。

在本章后续部分以及接下来的章节中，我们将强调最大似然方法的显著局限性。这里我们先通过单变量高斯分布参数最大似然解的情境来说明这一问题。特别地，我们将展示最大似然方法会系统性地低估分布的方差。这是一种称为偏差的现象，并且与多项式曲线拟合中遇到的过拟合问题相关。首先注意到，最大似然解 μ_{ML} 和 σ_{ML}^2 都是数据集取值 $x_1, \dots, x_N$ 的函数。而这些数据集本身是从一个参数为 μ 和 σ^2 的高斯分布中抽取的。考虑这些量相对于数据集取值的期望，可以很容易地证明：

$$\mathbb{E}[\mu_{\text{ML}}] = \mu \quad (1.57)$$

$$\mathbb{E}[\sigma_{\text{ML}}^2] = \frac{N-1}{N} \sigma^2 \quad (1.58)$$


因此，平均而言，最大似然估计能够得到正确的均值，但会以一个 $(N-1)/N$ 的因子低估真实方差。其直观解释如图 1.15 所示。

由 (1.58) 可得，下列方差参数的估计是无偏的：

$$\tilde{\sigma}^2 = \frac{1}{N-1} \sum_{n=1}^N \sigma_{ML}^2 = \frac{1}{N-1} \sum_{n=1}^N (x_n - \mu_{\text{ML}})^2 \quad (1.59)$$

在第 10.1.3 节中，我们将看到，当采用贝叶斯方法时，这一结果会自然而然地出现。

图 1.15 示意图展示了在使用最大似然方法确定高斯分布方差时偏差产生的原因。绿色曲线表示生成数据的真实高斯分布，三条红色曲线表示分别拟合三个数据集得到的高斯分布，每个数据集包含两个蓝色数据点，拟合采用最大似然结果 1.55 和 1.56。在三个数据集上取平均后，均值是正确的，但方差被系统性低估，因为它是相对于样本均值而不是相对于真实均值来计算的。



需要注意的是，随着数据点数量 N 的增加，最大似然解的偏差会逐渐减小，当 $N \rightarrow \infty$ 时，方差的最大似然解将等于生成数据的分布的真实方差。在实际应用中，除了在 N 很小的情况下，这种偏差通常不会成为严重问题。然而，在本书中我们将关注更复杂的、多参数的模型，在这种情形下，与最大似然相关的偏差问题会更加严重。事实上，正如我们将看到的，最大似然中的偏差问题正是之前在多项式曲线拟合中所遇到的过拟合问题的根源所在。

1.2.5 曲线拟合再探

我们已经看到，多项式曲线拟合问题可以用误差最小化来表达。这里我们重新回到曲线拟合的例子，从概率的角度来考察它，从而加深对误差函数和正则化的理解，并逐步走向完整的贝叶斯处理。

在曲线拟合问题中，我们的目标是：基于包含 N 个输入值的数据集 $\mathbf{x} = (x_1, \dots, x_N)^T$ 及其对应的目标值 $\mathbf{t} = (t_1, \dots, t_N)^T$ ，能够在给定新的输入变量 x 时，对目标变量 t 做出预测。我们可以通过一个概率分布来表达对目标变量取值的不确定性。为此，我们假设：在给定 x 的条件下，对应的 t 服从高斯分布，其均值等于由 (1.1) 式给出的多项式曲线 $y(x, \mathbf{w})$ 的值。于是有：

$$p(t|x, \mathbf{w}, \beta) = \mathcal{N}(t | y(x, \mathbf{w}), \beta^{-1}) \quad (1.60)$$


在这里，为了与后续章节的记号保持一致，我们定义了一个精度参数 β ，它对应于分布方差的倒数。这在图 1.16 中作了示意性的说明。

我们现在利用训练数据 $\{\mathbf{x}, \mathbf{t}\}$ 来通过最大似然的方法确定未知参数 $\mathbf{w}$ 和 β 的取值。若假设数据是从分布 (1.60) 中独立抽取的，则其似然函数为

$$p(\mathbf{t}|\mathbf{x}, \mathbf{w}, \beta) = \prod_{n=1}^N \mathcal{N}(t_n | y(x_n, \mathbf{w}), \beta^{-1}) \quad (1.61)$$

正如之前在简单高斯分布情形中所做的那样，这里最大化似然函数的对数会更加方便。将 (1.46) 给出的高斯分布形式代入后，可以得到对数似然函数为

图 1.16 高斯条件分布的示意图，表示在给定 x 的情况下 t 的分布（公式 (1.60)）。其中，均值由多项式函数 $y(x, \mathbf{w})$ 给出，精度由参数 β 决定，并且与方差的关系为 $\beta^{-1} = \sigma^2$



$$\ln p(\mathbf{t}|\mathbf{x}, \mathbf{w}, \beta) = -\frac{\beta}{2} \sum_{n=1}^N \{y(x_n, \mathbf{w}) - t_n\}^2 + \frac{N}{2} \ln \beta - \frac{N}{2} \ln(2\pi). \quad (1.62)$$

首先考虑多项式系数的最大似然解，记为 $\mathbf{w}_{\text{ML}}$ 。这些系数通过对 (1.62) 式关于 $\mathbf{w}$ 最大化得到。为此，我们可以忽略 (1.62) 式右边最后两项，因为它们与 $\mathbf{w}$ 无关。同时需要注意的是，将对数似然乘上一个正的常数系数并不会改变其关于 $\mathbf{w}$ 的极大值位置，因此我们可以把系数 $\beta/2$ 替换为 $1/2$ 。最后，与其最大化对数似然，我们也可以等价地最小化负对数似然。因此，就确定 $\mathbf{w}$ 而言，最大化似然等价于最小化由 (1.2) 定义的平方和误差函数。由此可见，平方和误差函数的出现，正是高斯噪声分布假设下最大化似然的结果。

我们同样可以利用最大似然来确定高斯条件分布的精度参数 β 。对 (1.62) 式关于 β 最大化可得：

$$\frac{1}{\beta_{\text{ML}}} = \frac{1}{N} \sum_{n=1}^N \{y(x_n, \mathbf{w}_{\text{ML}}) - t_n\}^2 \quad (1.63)$$

同样地，我们可以先确定控制均值的参数向量 $\mathbf{w}_{\text{ML}}$ ，随后再利用这一结果去求解精度 β_{ML} ，这与简单高斯分布的情形是相同的。

在确定了参数 $\mathbf{w}$ 和 β 之后，我们就可以对新的 x 值进行预测。由于我们现在有了一个概率模型，因此预测结果用预测分布来表示，即给出 t 的概率分布，而不仅仅是一个点估计。通过将最大似然参数代入 (1.60)，得到：

$$p(t|x, \mathbf{w}_{\text{ML}}, \beta_{\text{ML}}) = \mathcal{N}(t | y(x, \mathbf{w}_{\text{ML}}), \beta_{\text{ML}}^{-1}) \quad (1.64)$$

现在让我们向更加贝叶斯化的方法迈进一步，在多项式系数 $\mathbf{w}$ 上引入一个先验分布。为简单起见，我们考虑如下形式的高斯分布：

$$p(\mathbf{w}|\alpha) = \mathcal{N}(\mathbf{w}|\mathbf{0}, \alpha^{-1}\mathbf{I}) = \left(\frac{\alpha}{2\pi}\right)^{(M+1)/2} \exp\left\{-\frac{\alpha}{2}\mathbf{w}^T\mathbf{w}\right\} \quad (1.65)$$

其中， α 是该分布的精度，而对于 M 次多项式，向量 $\mathbf{w}$ 中的元素总数为 $M+1$ 。像 α 这样控制模型参数分布的变量称为超参数。利用贝叶斯定理， $\mathbf{w}$ 的后验分布正比于先验

分布与似然函数的乘积:

$$p(\mathbf{w}|\mathbf{x}, \mathbf{t}, \alpha, \beta) \propto p(\mathbf{t}|\mathbf{x}, \mathbf{w}, \beta) p(\mathbf{w}|\alpha) \quad (1.66)$$

我们现在可以通过在给定数据的条件下寻找 $\mathbf{w}$ 的最可能取值来确定参数 $\mathbf{w}$ ，换句话说，就是最大化后验分布。这种方法称为最大后验估计。

对 (1.66) 取负对数，并结合 (1.62) 和 (1.65)，可以得到后验分布最大值对应于以下表达式的最小值：

$$\frac{\beta}{2} \sum_{n=1}^N \{y(x_n, \mathbf{w}) - t_n\}^2 + \frac{\alpha}{2} \mathbf{w}^T \mathbf{w} \quad (1.67)$$

因此我们看到，最大化后验分布等价于最小化之前在 (1.4) 中出现过的正则化平方和误差函数，其正则化参数为 $\lambda = \alpha/\beta$ 。

1.2.6 贝叶斯曲线拟合

尽管我们已经引入了先验分布 $p(\mathbf{w}|\alpha)$ ，但到目前为止我们仍然是在对 $\mathbf{w}$ 做点估计，因此这还不能算作真正的贝叶斯处理。在完全的贝叶斯方法中，我们应当严格一致地应用概率的加法和乘法法则，这就要求我们（正如稍后将看到的）需要对所有可能的 $\mathbf{w}$ 取值进行积分。这种边缘化正是贝叶斯方法在模式识别中的核心所在。

在曲线拟合问题中，我们给定了训练数据 $\mathbf{x}$ 和 $\mathbf{t}$ ，以及一个新的测试点 x ，我们的目标是预测对应的 t 值。因此，我们希望计算预测分布 $p(t|x, \mathbf{x}, \mathbf{t})$ 。在这里，我们假设参数 α 和 β 是固定且已知的（在后续章节中，我们将讨论如何在贝叶斯框架下从数据中推断这些参数）。

贝叶斯处理只是严格一致地应用概率的加法和乘法法则，这使得预测分布可以写成如下形式：

$$p(t|x, \mathbf{x}, \mathbf{t}, \alpha, \beta) = \int p(t|x, \mathbf{w}, \beta) p(\mathbf{w}|\mathbf{x}, \mathbf{t}, \alpha, \beta) d\mathbf{w} \quad (1.68)$$

这里， $p(t|x, \mathbf{w})$ 由 (1.60) 给出，而我们为了简化记号省略了对 α 和 β 的依赖。 $p(\mathbf{w}|\mathbf{x}, \mathbf{t})$ 是参数的后验分布，可以通过对 (1.66) 右边进行归一化得到。

我们将在第 3.3 节中看到，对于诸如曲线拟合这样的例子，其后验分布是一个高斯分布，并且可以解析地求解。类似地，(1.68) 中的积分也可以解析地计算，其结果是预测分布本身也是一个高斯分布，其形式为：

$$p(t|x, \mathbf{x}, \mathbf{t}) = \mathcal{N}(t | m(x), s^2(x)) \quad (1.69)$$

其中，均值和方差分别为

$$m(x) = \beta \phi(x)^T \mathbf{S} \sum_{n=1}^N \phi(x_n) t_n \quad (1.70)$$

$$s^2(x) = \beta^{-1} + \phi(x)^T \mathbf{S} \phi(x). \quad (1.71)$$


这里矩阵 $\mathbf{S}$ 给定为

$$\mathbf{S}^{-1} = \alpha \mathbf{I} + \beta \sum_{n=1}^N \phi(x_n) \phi(x)^T \quad (1.72)$$

其中, $\mathbf{I}$ 是单位矩阵, 并且我们定义向量 $\phi(x)$, 其元素为 $\phi_i(x) = x^i$, $i = 0, \dots, M$ 。

我们可以看到, 在 (1.69) 中预测分布的方差和均值一样, 都是依赖于 x 的。式 1.71 中的第一项表示目标变量上的噪声所导致的对 t 预测值的不确定性, 这在最大似然预测分布 (1.64) 中已经通过 β_{ML}^{-1} 表达出来。然而, 第二项来源于参数 $\mathbf{w}$ 的不确定性, 这是贝叶斯处理的结果。图 1.17 展示了合成正弦回归问题的预测分布。

图 1.17 基于贝叶斯方法对 $M = 9$ 多项式进行曲线拟合所得到的预测分布 (predictive distribution), 其固定参数为 $\alpha = 5 \times 10^{-3}$ 和 $\beta = 11.1$ (对应已知的噪声方差)。红色曲线表示预测分布的均值, 红色区域表示均值上下一个标准差的范围。



1.3 模型选择


在利用最小二乘法进行多项式曲线拟合的例子中, 我们看到存在一个最优的多项式阶数, 它能带来最佳的泛化性能。多项式的阶数控制了模型中自由参数的数量, 从而决定了模型的复杂度。在正则化最小二乘法中, 正则化系数 λ 同样控制了模型的有效复杂度; 而在更复杂的模型中, 例如混合分布或神经网络, 则可能有多个参数共同决定复杂度。在实际应用中, 我们需要确定这些参数的取值, 其主要目标通常是使模型在新数据上的预测性能达到最佳。此外, 除了在给定模型中找到合适的复杂度参数取值之外, 我们还可能希望考虑多种不同类型的模型, 以便为特定的应用找到最优的模型。

我们已经看到, 在最大似然方法中, 由于过拟合问题, 训练集上的性能并不能很好地反映在未见数据上的预测性能。如果数据量充足, 一种方法是将部分可用数据用于训练一系列模型, 或者在给定模型下尝试不同复杂度参数的取值, 然后在独立数据 (有时称为验证集) 上对这些模型进行比较, 并选择预测性能最优的那个。如果在数据有限的情况下多次迭代模型设计, 就可能对验证集产生一定的过拟合, 因此通常需要保留第三个独立的测试集, 用于对最终选定的模型进行性能评估。

然而, 在许多应用中, 可用于训练和测试的数据往往有限, 而为了建立一个良好的模型, 我们希望尽可能多地利用已有数据进行训练。但是, 如果验证集太小, 它将只能给出一个带有较大噪声的预测性能估计。解决这一困境的一个方法是使用交叉验证, 如图 1.18 所示。它允许将可用数据中的 $(S-1)/S$ 部分用于训练, 同时利用所有数据来评估性能。当数据极其稀少时, 可以考虑取 $S = N$, 其中 N 是数据点的总数, 这就得到了留一法技术。

交叉验证的一个主要缺点是: 所需的训练次数增加了 S 倍, 对于训练过程本身计

图 1.18 S 折交叉验证的方法，这里以 $S = 4$ 的情况为例进行说明。该方法将可用数据划分为 S 个组（在最简单的情况下，这些组大小相等）。然后使用其中 $S - 1$ 个组来训练模型，并在剩下的一个组上进行评估。这个过程会对所有 S 种可能的留出组重复进行，这里用红色方块表示。最终将 S 次运行得到的性能指标取平均。



算开销很大的模型来说，这可能会成为严重问题。进一步的问题在于，像交叉验证这样依赖独立数据评估性能的方法，如果一个模型包含多个复杂度参数（例如可能存在多个正则化参数），那么探索这些参数组合的过程在最坏情况下可能需要指数级数量的训练次数。显然，我们需要一种更好的方法。理想情况下，这种方法应当只依赖于训练数据，并且能够在一次训练过程中同时比较多个超参数和不同类型的模型。换句话说，我们需要找到一种仅依赖训练数据的性能度量方式，并且这种方式不会因为过拟合而产生偏差。

在历史上，人们提出了多种“信息准则”，试图通过在最大似然上加入惩罚项来修正其偏差，从而补偿复杂模型的过拟合。例如，赤池信息准则 (Akaike information criterion, AIC) (Akaike, 1974) 选择使下式最大的模型：

$$\ln p(\mathcal{D}|\mathbf{w}_{\text{ML}}) - M \quad (1.73)$$


这里， $p(\mathcal{D}|\mathbf{w}_{\text{ML}})$ 表示最佳拟合下的对数似然 (log likelihood)，而 M 是模型中可调参数的个数。该量的一个变体称为贝叶斯信息准则，将在第 4.4.1 节中讨论。然而，这类准则并没有考虑模型参数中的不确定性，因此在实际中往往倾向于选择过于简单的模型。于是，在第 3.4 节中我们将转向一种完全贝叶斯化的处理方法，在那里我们会看到复杂度惩罚是如何以一种自然且有原则的方式出现的。

1.4 维度灾难

在多项式曲线拟合的例子中，我们只有一个输入变量 x 。然而，在模式识别的实际应用中，我们必须处理包含多个输入变量的高维空间。正如我们将要讨论的那样，这会带来一些严重的挑战，并且是影响模式识别技术设计的重要因素。


为了说明这个问题，我们考虑一个合成生成的数据集，该数据集代表了从一个包含油、水和气体混合物的管道中获得的测量结果 (Bishop and James, 1993)。这三种物质可以存在于三种不同的几何结构中，分别称为“均匀型”、“环状型”和“层流型”，并且三种物质的比例也可以变化。每个数据点由一个 12 维输入向量组成，这些向量来自伽马射线密度计的测量，该仪器测量伽马射线穿过管道时的衰减情况。该数据集的详细描述见附录 A。图 1.19 展示了该数据集中 100 个点，它们绘制在二维平面上，横纵坐标为其中的两个测量值 x_6 和 x_7 （其余 10 个输入值在这里被忽略）。每个数据点都根据其所属的三种几何类别之一进行了标注。我们的目标是利用这些数据作为训练集，以便能够对新的观测点 (x_6, x_7) 进行分类，例如图 1.19 中用“叉号”标记的那个点。我们可以看

图 1.19 油流数据中输入变量 x_6 和 x_7 的散点图，其中红色表示“homogenous”类别，绿色表示“annular”类别，蓝色表示“laminar”类别。我们的目标是对标记为“x”的新测试点进行分类。




到，叉号周围有许多红色点，因此我们可能会猜测它属于红色类别。然而，附近也存在不少绿色点，因此它也可能属于绿色类别。它属于蓝色类别的可能性似乎很小。这里的直觉是：该观测点的类别应当更多地由训练集中邻近点决定，而较远的点影响则较小。事实上，这种直觉是合理的，我们将在后续章节中对其进行更全面的讨论。

图 1.20 分类问题的一种简单解法示意图：将输入空间划分为若干单元格，并将新的测试点分配到与其所在单元格中占多数的类别。正如我们很快将看到的，这种过于简单的方法存在严重缺陷。



我们如何把这种直觉转化为一个学习算法？一种非常简单的方法是将输入空间划分为规则的网格单元，如图 1.20 所示。给定一个测试点并希望预测其类别时，首先判断它落在哪个单元格中，然后找到所有落在同一单元格内的训练数据点。将测试点的类别预测为：在该单元格中出现数量最多的那一类（若出现并列，则随机打破平局）。

图 1.21 维度灾难的示意图，展示了规则网格的区域数量如何随着空间维度 D 的增加而指数式增长。为了清晰起见，在 $D = 3$ 的情况下仅展示了部分立方区域。



这种朴素方法存在许多问题，其中最严重的一点在把它扩展到具有更多输入变量、也就是更高维的输入空间时会变得显而易见。问题的根源如图1.21所示：如果我们把空间中的一个区域划分为规则的网格单元，那么此类单元的数量会随空间维度呈指数式增长。单元数量指数级增长所带来的问题是：为了确保这些单元不至于为空，我们将需要同样指数级庞大的训练数据量。显然，在超过少数几个变量的空间中，我们不可能采用这种技术，因此必须寻找更为复杂的方法。

通过回到多项式曲线拟合的例子，并思考如何将其扩展到具有多个输入变量的情形，我们可以进一步理解高维空间中的问题。如果我们有 D 个输入变量，那么一个最高为三次的多项式的一般形式为：

$$y(\mathbf{x}) = w_0 + \sum_{i=1}^D w_i x_i + \sum_{i=1}^D \sum_{j=1}^D w_{ij} x_i x_j + \sum_{i=1}^D \sum_{j=1}^D \sum_{k=1}^D w_{ijk} x_i x_j x_k \quad (1.74)$$

随着 D 的增加，自由系数的数量也随之增长（由于变量 x 之间的交换对称性，并非所有系数都是独立的），其数量大致与 D^3 成正比。在实际问题中，如果要捕捉数据中的复杂依赖关系，可能需要使用更高阶的多项式。对于一个 M 阶多项式，其系数数量的增长大致像 D^M 。虽然这是一种幂律增长，而不是指数增长，但它仍然表明该方法会很快变得难以处理，并且在实际应用中用途有限。

我们的几何直觉是在三维空间的生活经验中形成的，但当考虑高维空间时，这种直觉往往会失效。举一个简单的例子：考虑一个在 D 维空间中的半径为 $r = 1$ 的球体，并问球体体积中有多少部分落在半径区间 $[r = 1 - \epsilon, r = 1]$ 内。我们可以通过注意到：在 D 维空间中，半径为 r 的球体体积随 r^D 缩放，来计算这个比例。因此可以写作：

$$V_D(r) = K_D r^D \quad (1.75)$$

其中常数 K_D 只依赖于维度 D 。因此，所需的体积分数为

$$\frac{V_D(1) - V_D(1 - \epsilon)}{V_D(1)} = 1 - (1 - \epsilon)^D \quad (1.76)$$

这一结果在图 1.22 中展示为不同维度 D 下的函数曲线。可以看到，当 D 很大时，即使 ϵ 很小，该分数也会趋近于 1。因此，在高维空间中，球体的大部分体积实际上都集中在靠近表面的一个薄壳层中！

再举一个与模式识别直接相关的例子：考虑高维空间中高斯分布的行为。若我们将坐标从笛卡尔坐标系转换为极坐标系，并将方向变量积分掉，就可以得到密度 $p(r)$ 的表达式，它是关于到原点的半径 r 的函数。于是， $p(r) \delta r$ 表示位于半径 r 、厚度为 δr 的薄壳中的概率质量。该分布在不同维度 D 下的曲线如图 1.23 所示，可以看到，当 D 很大时，高斯分布的概率质量同样集中在一个薄壳层中。

在多维空间中可能出现的严重困难有时被称为维度灾难 (Bellman, 1961)。在本书中，我们将广泛使用一维或二维输入空间的示例，因为这样能够更直观地用图形方式展示各种技术。然而，需要提醒读者的是，并非所有在低维空间中形成的直觉都可以推广到高维空间。

图 1.22 球体体积在半径范围 $r = 1 - \epsilon$ 到 $r = 1$ 内所占比例随空间维度 D 变化的曲线图。





图 1.23 高斯分布关于半径 r 的概率密度随维度 D 变化的曲线图。在高维空间中，高斯分布的大部分概率质量集中在某一特定半径处的薄壳内。



尽管维度灾难确实给模式识别应用带来了重要挑战，但它并不会阻止我们找到在高维空间中仍然有效的技术。原因主要有两个方面：首先，真实数据往往局限在空间中的某个较低有效维度的区域内，特别是目标变量发生重要变化的方向通常也仅限于该区域。其次，真实数据通常表现出某种光滑性特征（至少在局部上如此），也就是说输入变量的小变化通常只会引起目标变量的小变化。因此我们可以利用类似局部插值的方法，使得能够对新输入值预测其对应的目标值。成功的模式识别技术往往利用了上述一种或两种性质。举个例子，在制造业的一个应用中，相机会对传送带上的相同平面物体拍摄图像，其目标是判断物体的朝向。每幅图像都对应高维空间中的一个点，这个空间的维度由像素数量决定。由于物体在图像中可能出现不同的位置和不同的方向，因此图像之间的变化实际上只具有三个自由度。于是，这组图像分布在高维空间中一个三维流形上。由于物体的位置或方向与像素强度之间存在复杂的关系，这个流形会是高度非线性的。如果我们的目标是学习一个模型，使得它能接收一幅输入图像并输出物体的朝向，而不受物体在图像中位置的影响，那么在这个流形中真正重要的自由度实际上只有一个。

1.5 决策理论

我们在第 1.2 节中已经看到，概率论为刻画和处理不确定性提供了一个一致的数学框架。接下来我们将讨论决策理论。当它与概率论结合时，就能够使我们在涉及不确定性的情形下（例如模式识别中遇到的情况）做出最优决策。

假设我们有一个输入向量 $\mathbf{x}$ ，以及与之对应的目标变量向量 $\mathbf{t}$ ，我们的目标是在给定新的 $\mathbf{x}$ 时预测 $\mathbf{t}$ 。对于回归问题， $\mathbf{t}$ 由连续变量组成；而对于分类问题， $\mathbf{t}$ 表示类别标签。联合概率分布 $p(\mathbf{x}, \mathbf{t})$ 对这些变量相关的不确定性给出了完整的刻画。从训练数据集中确定 $p(\mathbf{x}, \mathbf{t})$ 是推断的一个例子，而这通常是一个非常困难的问题，也是本书的重要研究主题。然而，在实际应用中，我们往往必须对 $\mathbf{t}$ 的取值给出一个具体预测，或者更一般地，根据我们对 $\mathbf{t}$ 可能取值的理解采取某种具体行动。这一部分内容正是决策理论所研究的。

例如，考虑一个医学诊断问题：我们获得了一位病人的 X 光图像，希望判断该病人是否患有癌症。在这种情况下，输入向量 $\mathbf{x}$ 就是图像中的像素强度集合，而输出变量 t 表示癌症的有无。若病人患癌，则记为类别 C_1 ；若无癌症，则记为类别 C_2 。我们可以令 t 为一个二值变量，例如 $t = 0$ 对应类别 C_1 ，而 $t = 1$ 对应类别 C_2 。稍后我们会看到，这种标签取值的设定对于概率模型来说尤其方便。一般的推断问题是要确定联合分布 $p(\mathbf{x}, C_k)$ ，或等价地 $p(\mathbf{x}, t)$ ，它为我们提供了关于问题最完整的概率描述。尽管这个量非常有用且信息丰富，但最终我们必须决定是否对病人进行治疗，并且我们希望这一选择在某种合理意义下是最优的 (Duda and Hart, 1973)。这就是决策步骤，而决策理论的任务就是在给定合适的概率信息时告诉我们如何做出最优决策。我们将看到，一旦推断问题得到解决，决策阶段通常非常简单，甚至是微不足道的。

这里我们将介绍决策理论的核心思想，以便支撑本书其余部分的内容。更多的背景知识以及更详细的论述可以参考 Berger (1985) 和 Bather (2000)。

在进行更详细的分析之前，我们先非正式地思考一下概率在决策中可能发挥的作用。当我们获得一个新病人的 X 光图像 $\mathbf{x}$ 时，我们的目标是决定该图像应归入两个类别中的哪一个。我们关心的是在给定图像条件下两个类别的概率，即 $p(C_k|\mathbf{x})$ 。利用贝叶斯定理，这些概率可以写成如下形式：

$$p(C_k|\mathbf{x}) = \frac{p(\mathbf{x}|C_k)p(C_k)}{p(\mathbf{x})} \quad (1.77)$$

需要注意的是，贝叶斯定理中出现的任意量都可以通过对联合分布 $p(\mathbf{x}, C_k)$ 进行适当的边缘化或条件化来得到。我们可以将 $p(C_k)$ 解释为类别 C_k 的先验概率而将 $p(C_k|\mathbf{x})$ 解释为对应的后验概率。例如， $p(C_1)$ 表示一个人在进行 X 光检查之前患癌的概率，而 $p(C_1|\mathbf{x})$ 则是在结合 X 光图像信息后，通过贝叶斯定理修正得到的对应概率。如果我们的目标是最小化将 $\mathbf{x}$ 归入错误类别的概率，那么直觉上我们应选择后验概率较大的那个类别。接下来我们将证明这一直觉确实正确，同时还会讨论更一般的决策准则。

1.5.1 最小化误分类率

假设我们的目标仅仅是尽可能减少误分类的数量。我们需要一个规则，将每个输入 $\mathbf{x}$ 分配到某个类别中。这样的规则会把输入空间划分为若干区域 R_k ，称为决策区域，每个类别 C_k 对应一个决策区域，使得所有落在 R_k 内的点都被判为 C_k 。决策区域之间的边界称为决策边界或决策曲面。需要注意的是，每个决策区域不必是连通的，它可能由若干不相连的子区域组成。我们将在后续章节中看到决策边界与决策区域的具体示例。

为了找到最优的决策规则，先考虑只有两个类别的情况，例如癌症诊断问题。当一个属于类别 C_1 的输入向量被判为 C_2 ，或者反之，则会发生错误。该错误发生的概率为：

$$\begin{aligned} p(\text{mistake}) &= p(\mathbf{x} \in \mathcal{R}_1, C_2) + p(\mathbf{x} \in \mathcal{R}_2, C_1) \\ &= \int_{\mathcal{R}_1} p(\mathbf{x}, C_2) d\mathbf{x} + \int_{\mathcal{R}_2} p(\mathbf{x}, C_1) d\mathbf{x} \end{aligned} \quad (1.78)$$

我们可以自由选择决策规则，将每个点 $\mathbf{x}$ 分配给两个类别中的一个。显然，为了最小化 $p(\text{mistake})$ ，我们应当使每个 $\mathbf{x}$ 被分配给在 (1.78) 积分中对应项较小的那个类别。也就是说，如果对于某个 $\mathbf{x}$ ，有 $p(\mathbf{x}, C_1) > p(\mathbf{x}, C_2)$ ，那么就应当把该 $\mathbf{x}$ 判为类别 C_1 。根据概率的乘法法则 (product rule)，我们有 $p(\mathbf{x}, C_k) = p(C_k|\mathbf{x}) p(\mathbf{x})$ 。由于 $p(\mathbf{x})$ 在两个类别中是相同的，因此结果可以重新表述为：若希望误分类概率最小化，则应当把每个 $\mathbf{x}$ 判为其后验概率 $p(C_k|\mathbf{x})$ 最大的类别。这一结论在两个类别、单个输入变量 x 的情形下如图 1.24 所示。




图 1.24 关于两个类别的联合概率 $p(x, C_k)$ 随 x 变化的示意图，同时给出了决策边界 $x = \hat{x}$ 。当 $x \geq \hat{x}$ 时，被分类为类别 C_2 ，因此属于决策区域 $\mathcal{R}_2$ ；而当 $x < \hat{x}$ 时，被分类为类别 C_1 ，属于决策区域 $\mathcal{R}_1$ 。错误来源于蓝色、绿色和红色区域：在 $x < \hat{x}$ 时，错误来自类别 C_2 的点被误分类为 C_1 （由红色和绿色区域表示）；而在 $x \geq \hat{x}$ 时，错误来自类别 C_1 的点被误分类为 C_2 （由蓝色区域表示）。当我们改变决策边界 $\hat{x}$ 的位置时，蓝色和绿色区域的总面积保持不变，而红色区域的大小发生变化。最优的 x_b 选择是 $p(x, C_1)$ 与 $p(x, C_2)$ 曲线的交点，即 $\hat{x} = x_0$ ，因为此时红色区域消失。这等价于最小误分类率的决策规则，即将每个 x 分配给后验概率 $p(C_k|x)$ 较大的类别。

对于更一般的 K 个类别情形，处理起来稍微简单的方法是最大化判别正确的概率，

其表达式为:

$$\begin{aligned}
 p(\text{correct}) &= \sum_{k=1}^K p(\mathbf{x} \in \mathcal{R}_k, \mathcal{C}_k) \\
 &= \sum_{k=1}^K \int_{\mathcal{R}_k} p(\mathbf{x}, \mathcal{C}_k) d\mathbf{x}
 \end{aligned} \tag{1.79}$$

当决策区域 $\mathcal{R}_k$ 的选择使得每个 $\mathbf{x}$ 都被分配给满足 $p(\mathbf{x}, \mathcal{C}_k)$ 最大的那个类别时, 上式达到最大值。再次利用概率的乘法法则: $p(\mathbf{x}, \mathcal{C}_k) = p(\mathcal{C}_k | \mathbf{x}) p(\mathbf{x})$, 并注意到因子 $p(\mathbf{x})$ 对所有项都是相同的, 于是可以得到: 每个 $\mathbf{x}$ 应该被判为其后验概率 $p(\mathcal{C}_k | \mathbf{x})$ 最大的类别。

1.5.2 最小化期望损失

在许多应用中, 我们的目标会比单纯最小化误分类数量更为复杂。再考虑一次医学诊断问题: 如果一个没有癌症的病人被错误地诊断为患癌, 后果可能只是带来一些心理负担以及进一步检查的需要; 而如果一个真正患癌的病人被诊断为健康, 那么后果可能是由于缺乏治疗而导致的过早死亡。因此, 这两类错误所带来的后果可能截然不同。显然, 更好的做法是尽量减少第二类错误, 即使这意味着要容忍更多第一类错误。

我们可以通过引入损失函数 (也称为代价函数) 来形式化地处理这类问题。损失函数给出了在采取某个具体决策或行动时所造成的总体损失度量。我们的目标就是最小化总损失。需要注意的是, 有些作者使用效用函数, 并以最大化效用为目标。如果我们把效用定义为损失的相反数, 这两种方法是等价的。在本书中, 我们采用损失函数的约定。设对于某个新的 $\mathbf{x}$, 其真实类别为 $\mathcal{C}_k$, 而我们将其判为类别 $\mathcal{C}_j$ (其中 j 可以等于或不同于 k)。这样我们会产生某种程度的损失, 记为 L_{kj} , 它可以看作是损失矩阵的第 (k, j) 元素。例如, 在癌症诊断问题中, 我们可能会有如下形式的损失矩阵 (如图 1.25 所示)。如果决策正确, 则损失为 0; 如果一个健康患者被诊断为癌症, 则损失为 1; 如果一个患癌患者被诊断为健康, 则损失为 1000。

图 1.25 癌症治疗问题中的一个损失矩阵示例, 其元素为 L_{kj} 。矩阵的行对应真实类别, 而列对应于我们的决策准则所做的类别判定。

cancer	$\begin{pmatrix} 0 & 1000 \end{pmatrix}$
noemal	$\begin{pmatrix} 1 & 0 \end{pmatrix}$

最优解应当是使损失函数最小化的那个决策。然而, 损失函数依赖于真实类别, 而真实类别是未知的。对于给定的输入向量 $\mathbf{x}$, 我们对真实类别的不确定性由联合分布 $p(\mathbf{x}, \mathcal{C}_k)$ 表达。因此, 我们寻求最小化的是平均损失 (average loss), 其计算是相对于该分布的期望, 形式为:

$$\mathbb{E}[L] = \sum_k \sum_j \int_{\mathcal{R}_j} L_{kj} p(\mathbf{x}, \mathcal{C}_k) d\mathbf{x} \tag{1.80}$$

对于每个 $\mathbf{x}$, 选择区域 $\mathcal{R}_j$ 的分配可以独立进行。我们的目标意味着, 为了最小化期望损失 (1.80), 对于每个 $\mathbf{x}$ 应该最小化 $\sum_k L_{kj} p(\mathbf{x}, \mathcal{C}_k)$ 。如前所述, 我们可以利用乘法规则 $p(\mathbf{x}, \mathcal{C}_k) = p(\mathcal{C}_k | \mathbf{x}) p(\mathbf{x})$ 消去公共因子 $p(\mathbf{x})$ 。因此, 能够最小化期望损失的判别规


则是：将每个新的 $\mathbf{x}$ 分配到使下式最小的类别 j ，其最优类别就是使上述量达到最小值的那个类别。显然，一旦我们知道了后验类别概率 $p(C_k|\mathbf{x})$ ，这一决策就变得非常简单。

$$\sum_k L_{kj} p(C_k | \mathbf{x}) \quad (1.81)$$

1.5.3 拒绝选项

我们已经看到，分类错误主要发生在输入空间的某些区域，这些区域中最大的后验概率 $p(C_k|\mathbf{x})$ 显著小于 1，或者等价地说，此时各联合分布 $p(\mathbf{x}, C_k)$ 的数值相差不大。这些区域正是类别归属存在较大不确定性的地方。在一些应用中，面对这类难以判别的情况，避免强行做出决策反而更合适，这样可以在真正进行分类的样本上获得更低的错误率。这被称为拒绝选项。例如，在医学诊断的例子中，自动系统可以用于判别那些类别几乎没有疑问的 X 光图像，而将更模糊的病例留给人类专家判断。实现这一点的方法是引入一个阈值 θ ，当最大的后验概率 $p(C_k|\mathbf{x}) \leq \theta$ 时，就拒绝对输入 $\mathbf{x}$ 进行分类。图 1.26 展示了两个类别、单个连续输入变量 x 的情况。需要注意的是：当 $\theta = 1$ 时，所有样本都会被拒绝；若类别数为 K ，则当 $\theta < 1/K$ 时，没有样本会被拒绝。因此，被拒绝样本的比例是由阈值 θ 控制的。

图 1.26 拒绝选项的示意图：对于输入 x ，如果两类后验概率中较大的一个小于或等于某个阈值 θ ，则该输入将被拒绝分类。



我们可以很容易地将拒绝准则扩展到最小化期望损失，当给定一个损失矩阵时，可以考虑在作出拒绝决策时所带来的损失。

1.5.4 推断与决策

我们将分类问题分解为两个独立的阶段：推断阶段，在此阶段我们利用训练数据学习一个关于 $p(C_k|\mathbf{x})$ 的模型；以及随后的决策阶段，在此阶段我们使用这些后验概率来做出最优的类别分配。另一种可能性是将这两个问题一起解决，直接学习一个将输入 $\mathbf{x}$ 映射为决策的函数。这样的函数称为判别函数。

事实上，我们可以识别出三种解决决策问题的不同方法，这些方法都已经在实际应用中得到使用。按照复杂性递减的顺序，它们是：

- (a) 首先解决推断问题，即分别确定每个类别 C_k 的类条件密度 $p(\mathbf{x}|C_k)$ 。同时单独推

断先验类别概率 $p(C_k)$ 。然后使用贝叶斯定理，其形式为

$$p(C_k|x) = \frac{p(x|C_k)p(C_k)}{p(x)} \quad (1.82)$$

以此来求解后验类别概率 $p(C_k|x)$ 。像往常一样，贝叶斯定理中的分母可以通过分子中出现的量来表示，因为

$$p(x) = \sum_j p(x|C_j)p(C_j) \quad (1.83)$$

等价地，我们也可以直接对联合分布 $p(x, C_k)$ 建模，然后通过归一化得到后验概率。得到后验概率之后，我们利用决策理论来确定每个新输入 x 的类别归属。那些显式或隐式地同时对输入和输出分布建模的方法被称为生成模型，因为通过从它们中采样，可以在输入空间中生成合成的数据点。

- (b) 首先解决推断问题，即确定后验类别概率 $p(C_k|x)$ ，然后再利用决策理论将每个新的 x 分配到某个类别中。直接对后验概率建模的方法被称为判别模型。
- (c) 找到一个函数 $f(x)$ ，称为判别函数，它将每个输入 x 直接映射到一个类别标签上。举例来说，在二分类问题中，函数 $f(\cdot)$ 可以是一个二值函数，例如 $f = 0$ 表示类别 C_1 ，而 $f = 1$ 表示类别 C_2 。在这种情况下，概率不起作用。

让我们考虑这三种方法的相对优缺点。方法 (a) 是最具挑战性的，因为它涉及到寻找 x 和 C_k 的联合分布。对于许多应用来说， x 将具有高维性，因此我们可能需要一个很大的训练集，才能以合理的精度确定类条件密度 $p(x|C_k)$ 。注意，类别先验概率 $p(C_k)$ 通常可以简单地通过训练集中各类别数据点的比例来估计。然而，方法 (a) 的一个优点是它还能通过公式 (1.83) 确定数据的边缘密度 $p(x)$ 。这对于检测那些在模型下概率很低、因而预测精度可能较低的新数据点是有用的，这被称为异常点检测或新奇检测 (Bishop, 1994; Tarassenko, 1995)。

然而，如果我们只希望做分类决策，那么在实际上只需要后验概率 $p(C_k|x)$ 的情况下去寻找联合分布 $p(x, C_k)$ ，就可能对计算资源的浪费，并且对数据的要求也过高。而通过方法 (b) 就可以直接获得所需的后验概率。事实上，类条件密度中可能包含大量结构，但这些结构对后验概率几乎没有影响，如图 1.27 所示。对于生成方法和判别方法在机器学习中的相对优缺点，以及如何将它们结合起来，已经引起了广泛的研究兴趣 (Jebara, 2004; Lasserre 等, 2006)。

一个更简单的方法是 (c)，在该方法中我们利用训练数据找到一个判别函数 $f(x)$ ，它将每个 x 直接映射到一个类别标签上，从而把推断阶段和决策阶段合并为一个单一的学习问题。在图 1.27 的例子中，这对应于找到由绿色竖线表示的 x 值，因为这就是给出最小误分类概率的决策边界。

然而，在选择方法 (c) 时，我们将无法再获得后验概率 $p(C_k|x)$ 。即使最终是用它们来做决策，仍然有许多重要的理由需要计算后验概率，其中包括：




图 1.27 两个类别在单一输入变量 x 下的类条件密度示例（左图），以及对应的后验概率（右图）。需要注意的是，左图中蓝色表示的类条件密度 $p(x|C_1)$ 的左侧峰值对后验概率没有影响。右图中的竖直绿色线表示在 x 上给出最小误分类率的决策边界。

最小化风险。 考虑这样一个问题：损失矩阵的元素会不时地被修订（例如在金融应用中可能会发生这种情况）。如果我们知道后验概率，就可以通过适当修改公式 (1.81)，轻而易举地修订最小风险决策准则。而如果我们只有一个判别函数，那么损失矩阵的任何变化都将要求我们回到训练数据，重新解决分类问题。

拒绝选项。 后验概率使我们能够确定一个拒绝准则，该准则可以在给定比例的被拒绝数据点下，最小化误分类率，或者更一般地，最小化期望损失。

补偿类别先验。 再来考虑我们的医学 X 光问题。假设我们从普通人群中收集了大量 X 光图像作为训练数据，用于构建一个自动化筛查系统。由于癌症在普通人群中很少见，我们可能会发现，例如每 1,000 个样本中只有 1 个对应于癌症。如果我们用这样的数据集去训练一个自适应模型，就可能会遇到严重的问题，因为癌症类别的比例太小。例如，一个把所有点都判为正常类别的分类器就已经可以达到 99.9% 的准确率，而很难避免这种平凡的解。此外，即使是一个很大的数据集，也只会包含极少数对应癌症的 X 光图像，因此学习算法无法接触到这类图像的广泛样例，从而不太可能有良好的泛化能力。一个解决方案是构造一个平衡的数据集，在其中为每个类别选取相等数量的样本，这样可以帮助我们得到一个更准确的模型。然而，在这种情况下，我们必须对训练数据的修改进行补偿。假设我们使用了这样的平衡数据集并得到了后验概率的模型。根据贝叶斯定理 (1.82)，我们知道后验概率与先验概率成正比，而先验概率可以解释为每个类别中的样本比例。因此，我们只需将从人工平衡数据集中得到的后验概率，先除以该数据集中的类别比例，再乘以目标人群中的类别比例。最后，还需要进行归一化，以确保新的后验概率之和为 1。需要注意的是，如果我们直接学习的是判别函数，而不是后验概率，那么这一补偿过程就无法进行。

模型结合。 对于复杂的应用，我们可能希望将问题分解为若干较小的子问题，每个子

问题由一个单独的模块来解决。例如，在假设的医学诊断问题中，我们可能同时拥有来自血液检测和 X 光图像的信息。与其把这些异质信息合并到一个庞大的输入空间中，不如分别构建一个系统来解释 X 光图像，另一个系统来解释血液数据。只要这两个模型都能给出类别的后验概率，我们就可以利用概率论的规则系统地结合它们的输出。一个简单的方法是假设在每个类别下，X 光图像的输入分布（记作 $\mathbf{x}_I$ ）与血液数据的输入分布（记作 $\mathbf{x}_B$ ）相互独立，于是有

$$p(\mathbf{x}_I, \mathbf{x}_B | \mathcal{C}_k) = p(\mathbf{x}_I | \mathcal{C}_k) p(\mathbf{x}_B | \mathcal{C}_k) \quad (1.84)$$

这是条件独立性质的一个例子，因为独立性在分布以类别 $\mathcal{C}_k$ 为条件时成立。于是，在同时给定 X 光数据和血液数据的情况下，后验概率可以表示为

$$\begin{aligned} p(\mathcal{C}_k | \mathbf{x}_I, \mathbf{x}_B) &\propto p(\mathbf{x}_I, \mathbf{x}_B | \mathcal{C}_k) p(\mathcal{C}_k) \\ &\propto p(\mathbf{x}_I | \mathcal{C}_k) p(\mathbf{x}_B | \mathcal{C}_k) p(\mathcal{C}_k) \\ &\propto \frac{p(\mathcal{C}_k | \mathbf{x}_I) p(\mathcal{C}_k | \mathbf{x}_B)}{p(\mathcal{C}_k)} \end{aligned} \quad (1.85)$$

因此，我们需要类别先验概率 $p(\mathcal{C}_k)$ ，它可以很容易地通过各类别数据点的比例来估计。接着，我们需要对得到的后验概率进行归一化，使其和为 1。上述特定的条件独立假设 (1.84) 是朴素贝叶斯模型（naive Bayes model）的一个例子。需要注意的是，在该模型下，联合边缘分布 $p(\mathbf{x}_I, \mathbf{x}_B)$ 通常并不会因式分解。我们将在后续章节中看到如何构建不依赖于条件独立假设 (1.84) 的数据结合模型。

1.5.5 回归的损失函数

到目前为止，我们在分类问题的背景下讨论了决策理论。现在我们转向回归问题，例如之前讨论过的曲线拟合问题。在回归中，决策阶段就是为每个输入 $\mathbf{x}$ 选择一个关于 t 的具体估计 $y(\mathbf{x})$ 。假设这样做会带来一个损失 $L(t, y(\mathbf{x}))$ 。那么平均（期望）损失可以表示为

$$\mathbb{E}[L] = \int \int L(t, y(\mathbf{x})) p(\mathbf{x}, t) d\mathbf{x} dt \quad (1.86)$$

在回归问题中，一个常见的损失函数选择是平方损失（squared loss），其形式为 $L(t, y(x)) = \{y(x) - t\}^2$ 。在这种情况下，期望损失可以写作

$$\mathbb{E}[L] = \int \int \{y(x) - t\}^2 p(x, t) dx dt \quad (1.87)$$

我们的目标是选择 $y(\mathbf{x})$ 以最小化 $\mathbb{E}[L]$ 。如果我们假设 $y(\mathbf{x})$ 是完全灵活的函数，我们可以形式化地使用变分法得到


$$\frac{\delta \mathbb{E}[L]}{\delta y(\mathbf{x})} = 2 \int \{y(\mathbf{x}) - t\} p(\mathbf{x}, t) dt = 0 \quad (1.88)$$

解出 $y(x)$ ，并结合概率的求和法则和乘法法则，我们得到这是在给定 x 条件下 t 的条件均值，被称为回归函数（regression function）。这一结果在图 1.28 中有所展示。它

可以很容易地扩展到多个目标变量的情形，此时目标变量由向量 $\mathbf{t}$ 表示，而最优解是条件均值 $y(\mathbf{x}) = \mathbb{E}_{\mathbf{t}}[\mathbf{t} | \mathbf{x}]$ 。

$$y(\mathbf{x}) = \frac{\int \mathbf{t} p(\mathbf{x}, \mathbf{t}) d\mathbf{t}}{p(\mathbf{x})} = \int \mathbf{t} p(\mathbf{t} | \mathbf{x}) d\mathbf{t} = \mathbb{E}_{\mathbf{t}}[\mathbf{t} | \mathbf{x}] \quad (1.89)$$

图 1.28 使期望平方损失最小的回归函数 $y(x)$
由条件分布 $p(t|x)$ 的均值给出。



我们也可以用稍微不同的方法推导这一结果，这也有助于理解回归问题的本质。既然我们已知最优解是条件期望，就可以如下展开平方项：

$$\begin{aligned} \{y(\mathbf{x}) - t\}^2 &= \{y(\mathbf{x}) - \mathbb{E}[t | \mathbf{x}] + \mathbb{E}[t | \mathbf{x}] - t\}^2 \\ &= \{y(\mathbf{x}) - \mathbb{E}[t | \mathbf{x}]\}^2 + 2\{y(\mathbf{x}) - \mathbb{E}[t | \mathbf{x}]\}\{\mathbb{E}[t | \mathbf{x}] - t\} + \{\mathbb{E}[t | \mathbf{x}] - t\}^2 \end{aligned}$$

为使记号更简洁，我们以 $\mathbb{E}[t | \mathbf{x}]$ 表示 $\mathbb{E}_{\mathbf{t}}[t | \mathbf{x}]$ 。将其代回损失函数并对 t 积分，可见交叉项消失，从而得到损失函数的形式

$$\mathbb{E}[L] = \int \{y(\mathbf{x}) - \mathbb{E}[t | \mathbf{x}]\}^2 p(\mathbf{x}) d\mathbf{x} + \int \{\mathbb{E}[t | \mathbf{x}] - t\}^2 p(\mathbf{x}) d\mathbf{x} \quad (1.90)$$

我们要求解的函数 $y(\mathbf{x})$ 只出现在第一项中。当 $y(\mathbf{x}) = \mathbb{E}[t | \mathbf{x}]$ 时，这一项将被最小化并消失。这正是我们之前推导出的结果，表明最优的最小二乘预测器就是条件均值。第二项是 t 的分布的方差，对 $\mathbf{x}$ 取平均。它表示目标数据的内在变异性，可以视作噪声。由于它与 $y(\mathbf{x})$ 无关，因此它对应于损失函数不可约的最小值。

与分类问题类似，我们可以先确定相应的概率，再利用这些概率做出最优决策；或者我们也可以直接构建模型来做决策。实际上，我们可以识别出三种解决回归问题的不同方法，按照复杂性递减的顺序为：

- (a) 首先解决推断问题，即确定联合密度 $p(\mathbf{x}, t)$ 。随后通过归一化得到条件密度 $p(t | \mathbf{x})$ ，最后对其进行边缘化以得到由式 (1.89) 给出的条件均值。
- (b) 首先解决推断问题，即确定条件密度 $p(t | \mathbf{x})$ ，随后对其进行边缘化以得到由式 (1.89) 给出的条件均值。
- (c) 直接从训练数据中求得回归函数 $y(\mathbf{x})$ 。

这三种方法的相对优缺点与前面分类问题中的情况类似。

平方损失并不是回归中唯一可能的损失函数选择。实际上，在某些情况下，平方损失可能会导致非常糟糕的结果，这时我们需要更复杂的方法。一个重要的例子是条件分

布 $p(t | \mathbf{x})$ 为多峰分布的情形，这在求解逆问题时经常出现。这里我们简要讨论平方损失的一种简单推广形式，称为 **Minkowski 损失**，其期望形式为

$$\mathbb{E}[L_q] = \iint |y(\mathbf{x}) - t|^q p(\mathbf{x}, t) d\mathbf{x} dt, \quad (1.91)$$

当 $q = 2$ 时，这个形式就退化为期望平方损失。图 1.29 中绘制了不同 q 值下函数 $|y - t|^q$ 随 $y - t$ 的变化曲线。期望损失 $\mathbb{E}[L_q]$ 的最小值在以下情形下分别由不同的条件统计量给出：当 $q = 2$ 时是条件均值；当 $q = 1$ 时是条件中位数；而当 $q \rightarrow 0$ 时则是条件众数。




图 1.29 不同 q 取值下量 $L_q = |y - t|^q$ 的曲线图。

1.6 信息论

在本章中，我们讨论了概率论和决策理论中的一系列概念，它们将构成本书后续内容的重要基础。最后，我们将引入一些来自信息论（**information theory**）领域的附加概念，这些概念同样将在模式识别与机器学习技术的发展中发挥重要作用。这里我们依旧只关注关键概念，更多的细节性讨论可参考其他文献（Viterbi and Omura, 1979; Cover and Thomas, 1991; MacKay, 2003）。

我们先考虑一个离散随机变量 x ，并提出问题：当我们观测到该变量的一个具体取值时，接收到多少信息？信息量可以被理解为在得知 x 的取值后产生的“惊讶程度”。如果我们被告知一个极不可能发生的事件已经发生，那么我们接收到的信息量要比得知一个极有可能发生的事件时更多；而如果事件本来就是必然发生的，那么我们将不会获得任何信息。因此，我们对信息量的度量应依赖于概率分布 $p(x)$ ，并且我们寻找一个量 $h(x)$ ，它是概率 $p(x)$ 的单调函数，用来表达信息内容。 $h(\cdot)$ 的形式可以通过以下思路得到：如果我们有两个不相关的事件 x 和 y ，那么观测到它们的总信息量应当等于分别观测到它们的信息量之和，即 $h(x, y) = h(x) + h(y)$ 。对于不相关事件，它们统计上

是独立的，因此 $p(x, y) = p(x)p(y)$ 。由这两个关系可以容易证明， $h(x)$ 必须是 $p(x)$ 的对数函数，因此我们有

$$h(x) = -\log_2 p(x) \quad (1.92)$$

其中负号确保了信息量是非负的。需要注意的是，低概率事件 x 对应于较高的信息量。对数的底数选择是任意的，在此我们采用信息论中常见的约定，即使用以 2 为底的对数。这样一来，正如我们很快会看到的， $h(x)$ 的单位就是比特（bits，意为“二进制数字”）。

现在假设一个发送者希望将一个随机变量的取值传递给接收者。在这一过程中传递的信息的平均量，可以通过对式 (1.92) 在分布 $p(x)$ 下取期望来获得，其形式为

$$H[x] = \mathbb{E}[h(x)] = -\sum_x p(x) \log_2 p(x) \quad (1.93)$$

这个重要的量被称为随机变量 x 的熵（entropy）。注意到 $\lim_{p \rightarrow 0} p \ln p = 0$ ，因此，当某个取值满足 $p(x) = 0$ 时，我们约定 $p(x) \ln p(x) = 0$ 。

到目前为止，我们对信息定义 (1.92) 以及相应的熵 (1.93) 给出了一个比较直观的动机。现在我们来展示这些定义确实具有有用的性质。考虑一个随机变量 x ，它有 8 个可能的状态，并且每个状态出现的概率都相等。为了将 x 的取值传递给接收者，我们需要发送一条长度为 3 比特的信息。注意到这个随机变量的熵为

$$H[x] = -\sum_{i=1}^8 \frac{1}{8} \log_2 \frac{1}{8} = -8 \cdot \frac{1}{8} \log_2 \frac{1}{8} = 3\text{bits}$$

现在考虑一个例子 (Cover and Thomas, 1991)，随机变量有 8 个可能的状态 $\{a, b, c, d, e, f, g, h\}$ ，其对应的概率分别为 $(\frac{1}{2}, \frac{1}{4}, \frac{1}{8}, \frac{1}{16}, \frac{1}{64}, \frac{1}{64}, \frac{1}{64}, \frac{1}{64})$ 。在这种情况下，熵为

$$H[x] = -\frac{1}{2} \log_2 \frac{1}{2} - \frac{1}{4} \log_2 \frac{1}{4} - \frac{1}{8} \log_2 \frac{1}{8} - \frac{1}{16} \log_2 \frac{1}{16} - \frac{4}{64} \log_2 \frac{1}{64} = 2\text{bits}$$

我们看到，非均匀分布的熵比均匀分布要小，这一点在稍后讨论熵在“无序”意义下的解释时会更清晰。现在先考虑如何将该变量的状态传递给接收者。像之前一样，我们可以用一个 3 比特的数字来表示。但我们也可以利用分布的非均匀性：对概率较大的事件使用更短的编码，而对概率较小的事件使用更长的编码，从而希望获得更短的平均码长。例如，可以用如下编码方案表示状态 $\{a, b, c, d, e, f, g, h\}$: 0, 10, 110, 1110, 111100, 111101, 111110, 111111。此时所需传输的平均码长为

$$L = \frac{1}{2} \cdot 1 + \frac{1}{4} \cdot 2 + \frac{1}{8} \cdot 3 + \frac{1}{16} \cdot 4 + 4 \cdot \frac{1}{64} \cdot 6 = 2\text{bits}$$

这再次等于该随机变量的熵。需要注意的是，不能使用更短的编码串，因为必须能够将这些编码串的拼接唯一地分解为其组成部分。例如，序列 11001110 可以被唯一解码为状态序列 c, a, d。

熵与最短编码长度之间的这种关系是普遍成立的。无噪声编码定理 (noiseless coding theorem, Shannon, 1948) 指出：熵是传输一个随机变量状态所需比特数的下界。

从现在开始，我们将在熵的定义中改用自然对数，这样可以更方便地与本书其他部分的思想建立联系。在这种情况下，熵的度量单位是“纳特”(nats)，而不是比特(bits)，两者仅相差一个 $\ln 2$ 的因子。

我们已经从“指定随机变量状态所需信息的平均量”角度引入了熵的概念。事实上，熵在物理学中起源更早，它最初是在平衡热力学的背景下提出的，后来在统计力学的发展中被赋予了“无序度量”的更深层解释。为了理解熵的这种另一种观点，考虑这样一个问题：有 N 个相同的物体要分配到若干个盒子中，其中第 i 个盒子里有 n_i 个物体。我们来计算不同分配方式的数目。分配第一个物体有 N 种方式，第二个物体有 $(N-1)$ 种方式，依此类推，总共有 $N!$ 种方式将 N 个物体全部分配到盒子中，其中 $N!$ 表示乘积 $N \times (N-1) \times \cdots \times 2 \times 1$ 。然而，我们并不想区分同一盒子内物体的不同排列。在第 i 个盒子中，存在 $n_i!$ 种方式重新排列这些物体。因此， N 个物体分配到各个盒子的不同方式总数为

$$W = \frac{N!}{\prod_i n_i!} \quad (1.94)$$

这被称为多重度 (multiplicity)。熵在这里定义为多重度的对数，并乘以一个适当的常数：

$$H = \frac{1}{N} \ln W = \frac{1}{N} \ln N! - \frac{1}{N} \sum_i \ln n_i! \quad (1.95)$$

现在我们考虑极限 $N \rightarrow \infty$ ，在此过程中保持各个比例 n_i/N 不变，并应用 Stirling 近似：

$$\ln N! \simeq N \ln N - N \quad (1.96)$$

由此可得

$$H = - \lim_{N \rightarrow \infty} \sum_i \left(\frac{n_i}{N} \right) \ln \left(\frac{n_i}{N} \right) = - \sum_i p_i \ln p_i \quad (1.97)$$

这里我们利用了 $\sum_i n_i = N$ 。其中 $p_i = \lim_{N \rightarrow \infty} \left(\frac{n_i}{N} \right)$ 表示一个物体被分配到第 i 个盒子的概率。在物理学术语中，物体在盒子中的具体排列称为微观态，而通过比例 n_i/N 表示的总体占据数分布称为宏观态。多重度 W 也被称为宏观态的权重。

我们可以把这些盒子理解为离散随机变量 X 的状态 x_i ，其中 $p(X = x_i) = p_i$ 。于是随机变量 X 的熵为

$$H[p] = - \sum_i p(x_i) \ln p(x_i) \quad (1.98)$$

如果分布 $p(x_i)$ 在少数几个取值附近高度集中，那么其熵就会相对较低；而如果分布在多个取值上比较均匀地展开，那么熵就会更高，如图 1.30 所示。由于 $0 \leq p_i \leq 1$ ，熵总是非负的。当某个 $p_i = 1$ 且所有其他 $p_{j \neq i} = 0$ 时，熵取最小值 0。最大熵配置可以通过在概率的归一化约束下最大化 H 来找到。为此，我们使用拉格朗日乘子方法：

$$\tilde{H} = - \sum_i p(x_i) \ln p(x_i) + \lambda \left(\sum_i p(x_i) - 1 \right) \quad (1.99)$$




图 1.30 两个在 30 个区间上的概率分布的直方图，用来说明更宽的分布具有更大的熵 H 。最大熵出现在均匀分布的情况下，此时 $H = -\ln\left(\frac{1}{30}\right) = 3.40$ 。

由此我们得到，所有的 $p(x_i)$ 都相等，即 $p(x_i) = \frac{1}{M}$ ，其中 M 是状态 x_i 的总数。对应的熵为 $H = \ln M$ 。这一结果也可以通过 Jensen 不等式 (Jensen's inequality, 将在后面讨论) 推导出来。为了验证该驻点确实是最大值，我们可以计算熵的二阶导数，得到

$$\frac{\partial \tilde{H}}{\partial p(x_i) \partial p(x_j)} = -I_{ij} \frac{1}{p_i} \quad (1.100)$$

这里的 I_{ij} 是单位矩阵的元素。

我们可以将熵的定义扩展到连续变量 x 上的分布 $p(x)$ 。方法是：首先把 x 划分为宽度为 Δ 的小区间。然后，在假设 $p(x)$ 连续的条件下，根据平均值定理 (Weisstein, 1999)，对于每个区间，必定存在一个值 x_i ，使得

$$\int_{i\Delta}^{(i+1)\Delta} p(x) dx = p(x_i) \Delta \quad (1.101)$$

现在，我们可以通过量化连续变量 x 来处理：当 x 落入第 i 个区间时，就将其对应到值 x_i 。于是观测到值 x_i 的概率为 $p(x_i)\Delta$ 。这样我们得到一个离散分布，其熵为

$$H_\Delta = -\sum_i p(x_i) \Delta \ln(p(x_i) \Delta) = -\sum_i p(x_i) \Delta \ln p(x_i) - \ln \Delta \quad (1.102)$$

这里我们利用了关系 $\sum_i p(x_i) \Delta = 1$ ，这由式 (1.101) 可得。现在我们在式 (1.102) 的右边省略第二项 $-\ln \Delta$ ，然后考虑极限 $\Delta \rightarrow 0$ 。在这个极限下，右边的第一项将趋于积分形式 $\int p(x) \ln p(x) dx$ ，于是有

$$\lim_{\Delta \rightarrow 0} \left\{ \sum_i p(x_i) \Delta \ln p(x_i) \right\} = - \int p(x) \ln p(x) dx \quad (1.103)$$

右边的这个量被称为微分熵。我们可以看到，离散形式和连续形式的熵相差一个 $\ln \Delta$ 项，而当 $\Delta \rightarrow 0$ 时该项发散。这反映了一个事实：要非常精确地描述一个连续变量，需要大量的比特。

对于定义在多个连续变量上的密度（这些变量统称为向量 $\mathbf{x}$ ），其微分熵为

$$H[\mathbf{x}] = - \int p(\mathbf{x}) \ln p(\mathbf{x}) d\mathbf{x}. \quad (1.104)$$

在离散分布的情形中，我们看到最大熵配置对应于在所有可能状态上均匀分布的概率。现在我们来考虑连续变量的最大熵配置。为了使这个最大值有明确意义，我们需要在保持归一化约束的同时，对 $p(x)$ 的一阶和二阶矩加以限制。

因此，我们在以下三个约束条件下最大化微分熵：

$$\int p(x) dx = 1 \quad (1.105)$$

$$\int x p(x) dx = \mu \quad (1.106)$$

$$\int_{-\infty}^{\infty} (x - \mu)^2 p(x) dx = \sigma^2 \quad (1.107)$$

这个带约束的最大化问题可以通过拉格朗日乘子法来解决，因此我们需要对 $p(x)$ 最大化如下泛函：

$$\begin{aligned} & - \int_{-\infty}^{\infty} p(x) \ln p(x) dx + \lambda_1 \left(\int_{-\infty}^{\infty} p(x) dx - 1 \right) \\ & + \lambda_2 \left(\int_{-\infty}^{\infty} x p(x) dx - \mu \right) + \lambda_3 \left(\int_{-\infty}^{\infty} (x - \mu)^2 p(x) dx - \sigma^2 \right) \end{aligned}$$

使用变分法，令该泛函对 $p(x)$ 的变分导数为零，可得

$$p(x) = \exp\{-1 + \lambda_1 + \lambda_2 x + \lambda_3 (x - \mu)^2\} \quad (1.108)$$

将上述结果代回三个约束条件中求解拉格朗日乘子，最终得到的分布为

$$p(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right) \quad (1.109)$$

因此，能够最大化微分熵的分布就是高斯分布。需要注意的是，在最大化熵的过程中，我们并没有显式地约束分布必须为非负。然而，由于最终得到的分布本身确实是非负的，所以事后可以看出，这样的约束并不是必要的。

如果我们计算高斯分布的微分熵，可以得到

$$H[x] = \frac{1}{2} \{1 + \ln(2\pi\sigma^2)\} \quad (1.110)$$

因此我们再次看到，随着分布变得更宽（即方差 σ^2 增大），熵也随之增加。这个结果还表明，微分熵与离散熵不同，它可以为负值，因为当 $\sigma^2 < 1/(2\pi e)$ 时，由式 (1.110) 可得 $H(x) < 0$ 。

假设我们有一个联合分布 $p(x, y)$ ，从中抽取 (x, y) 成对的值。如果 x 的取值已经已知，那么确定相应 y 所需的额外信息量为 $-\ln p(y | x)$ 。因此，确定 y 所需的平均额外信息量可以写为

$$H[y|x] = - \iint p(y, x) \ln p(y | x) dx dy \quad (1.111)$$

这被称为在给定 x 的条件下的条件熵 y 。利用乘法法则可以很容易看出，条件熵满足以下关系：

$$H[x, y] = H[y|x] + H[x] \quad (1.112)$$

其中 $H[x, y]$ 是联合分布 $p(x, y)$ 的微分熵，而 $H[x]$ 是边缘分布 $p(x)$ 的微分熵。由此可见，描述 x 与 y 所需的信息量，等于单独描述 x 所需的信息量，加上在已知 x 的条件下进一步描述 y 所需的额外信息量。

1.6.1 相对熵与互信息

到目前为止，本节我们已经介绍了若干信息论的概念，其中最核心的是熵。现在我们开始把这些思想与模式识别联系起来。考虑某个未知分布 $p(\mathbf{x})$ ，假设我们用一个近似分布 $q(\mathbf{x})$ 来对其建模。如果我们基于 $q(\mathbf{x})$ 构造一个编码方案，用于将 $\mathbf{x}$ 的取值传输给接收者，那么由于使用 $q(\mathbf{x})$ 而不是真实分布 $p(\mathbf{x})$ ，在指定 $\mathbf{x}$ 的值时（假设选择了最优编码方案）所需的额外平均信息量（以 nats 为单位）为


$$\begin{aligned} KL(p \parallel q) &= - \int p(\mathbf{x}) \ln q(\mathbf{x}) d\mathbf{x} - \left(- \int p(\mathbf{x}) \ln p(\mathbf{x}) d\mathbf{x} \right) \\ &= - \int p(\mathbf{x}) \ln \left\{ \frac{q(\mathbf{x})}{p(\mathbf{x})} \right\} d\mathbf{x} \end{aligned} \quad (1.113)$$

这被称为相对熵或 Kullback-Leibler 散度（简称 KL 散度）（Kullback and Leibler, 1951），用于度量分布 $p(\mathbf{x})$ 与 $q(\mathbf{x})$ 之间的差异。需要注意的是，它不是对称的，即 $KL(p \parallel q) \neq KL(q \parallel p)$ 。

我们现在来证明 KL 散度满足 $KL(p \parallel q) \geq 0$ ，且当且仅当 $p(\mathbf{x}) = q(\mathbf{x})$ 时取等号。为此，首先引入凸函数的概念。若一个函数 $f(\mathbf{x})$ 具有如下性质，则称其为凸函数：它的任意一条弦都位于函数图像的上方或重合，如图 1.31 所示。区间 $[a, b]$ 内的任意一点 $\mathbf{x}$ 可以写成 $\mathbf{x} = \lambda a + (1 - \lambda)b$ ， $0 \leq \lambda \leq 1$ 。相应的弦上的点为 $\lambda f(a) + (1 - \lambda)f(b)$ ，而函数在该点的取值为 $f(\lambda a + (1 - \lambda)b)$ 。凸性意味着

$$f(\lambda a + (1 - \lambda)b) \leq \lambda f(a) + (1 - \lambda)f(b) \quad (1.114)$$

图 1.31 凸函数 $f(x)$ 的定义是：任意弦（蓝色部分）都位于函数曲线（红色部分）的上方或重合。



这等价于要求函数的二阶导数在其定义域内处处为正。凸函数的例子包括 $x \ln x$ （当 $x > 0$ 时）以及 x^2 。如果等号仅在 $\lambda = 0$ 和 $\lambda = 1$ 时成立，则称该函数为严格凸。与

之相反，如果函数的任意一条弦都位于函数图像的下方或重合，则称该函数为凹函数，并有相应的严格凹的定义。如果函数 $f(x)$ 是凸的，那么 $-f(x)$ 就是凹的。

利用数学归纳法可由式 (1.114) 推出：对于任意非负权重 $\{\lambda_i\}$ （满足 $\sum_i \lambda_i = 1$ ）与任意点集 $\{x_i\}$ ，凸函数 $f(x)$ 满足

$$f\left(\sum_{i=1}^M \lambda_i x_i\right) \leq \sum_{i=1}^M \lambda_i f(x_i) \quad (1.115)$$

其中 $\lambda_i \geq 0$ 且 $\sum_i \lambda_i = 1$ ，适用于任意点集 $\{x_i\}$ 。结果 (1.115) 被称为詹森不等式 (Jensen's inequality)。如果我们把 λ_i 解释为离散随机变量 x 取值 $\{x_i\}$ 上的概率分布，那么式 (1.115) 可以写作

$$f(\mathbb{E}[x]) \leq \mathbb{E}[f(x)] \quad (1.116)$$

其中 $\mathbb{E}[\cdot]$ 表示期望。对于连续变量，詹森不等式形式为

$$f\left(\int \mathbf{x} p(\mathbf{x}) d\mathbf{x}\right) \leq \int f(\mathbf{x}) p(\mathbf{x}) d\mathbf{x} \quad (1.117)$$

我们可以将詹森不等式 (1.117) 应用于 KL 散度 (1.113)，得到

$$KL(p||q) = - \int p(\mathbf{x}) \ln \left\{ \frac{q(\mathbf{x})}{p(\mathbf{x})} \right\} d\mathbf{x} \geq - \ln \int q(\mathbf{x}) d\mathbf{x} = 0 \quad (1.118)$$

这里我们利用了 $-\ln x$ 是凸函数这一事实，以及归一化条件 $\int q(\mathbf{x}) d\mathbf{x} = 1$ 。实际上， $-\ln x$ 是严格凸函数，因此仅当 $q(\mathbf{x}) = p(\mathbf{x})$ 对所有 $\mathbf{x}$ 都成立时才会取等号。由此我们可以将 KL 散度理解为度量分布 $p(\mathbf{x})$ 与 $q(\mathbf{x})$ 之间差异性的指标。

我们可以看到，数据压缩与密度估计（即对未知概率分布建模问题）之间有着紧密的联系。因为只有在知道真实分布的情况下，才能实现最有效的压缩。如果使用的分布与真实分布不同，那么编码必然会变得低效，平均而言所需传输的额外信息量（至少）等于这两个分布之间的 KL 散度。

假设数据是由某个未知分布 $p(\mathbf{x})$ 生成的，而我们希望对其进行建模。可以尝试用某个参数化分布 $q(\mathbf{x}|\theta)$ 来近似它，其中 θ 是一组可调参数，例如多元高斯分布。确定 θ 的一种方法是最小化 $p(\mathbf{x})$ 与 $q(\mathbf{x}|\theta)$ 之间的 KL 散度。由于我们并不知道 $p(\mathbf{x})$ ，因此无法直接进行这种最小化。然而，假设我们观测到了一个有限训练集 $\{x_n\}_{n=1}^N$ ，这些样本由 $p(\mathbf{x})$ 抽取。那么根据式 (1.35)，在 $p(\mathbf{x})$ 下的期望可以通过这些点的有限求和来近似，于是有

$$KL(p||q) \approx \sum_{n=1}^N \{-\ln q(\mathbf{x}_n|\theta) + \ln p(\mathbf{x}_n)\} \quad (1.119)$$

在式 (1.119) 的右边，第二项与参数 θ 无关，而第一项正是分布 $q(\mathbf{x}|\theta)$ 在训练集上的负对数似然函数。因此，我们看到，最小化这个 KL 散度等价于最大化似然函数。

现在考虑两组变量 $\mathbf{x}$ 和 $\mathbf{y}$ 的联合分布 $p(\mathbf{x}, \mathbf{y})$ 。如果这两组变量相互独立，那么它们的联合分布可以分解为边缘分布的乘积： $p(\mathbf{x}, \mathbf{y}) = p(\mathbf{x})p(\mathbf{y})$ 。如果它们不是独立的，我

们可以通过考察联合分布与边缘分布乘积之间的 KL 散度，来判断它们是否“接近”独立：

$$\begin{aligned} I[\mathbf{x}, \mathbf{y}] &\equiv \text{KL}(p(\mathbf{x}, \mathbf{y}) \| p(\mathbf{x})p(\mathbf{y})) \\ &= - \iint p(\mathbf{x}, \mathbf{y}) \ln \left(\frac{p(\mathbf{x})p(\mathbf{y})}{p(\mathbf{x}, \mathbf{y})} \right) d\mathbf{x}d\mathbf{y} \end{aligned} \quad (1.120)$$

这被称为变量 $\mathbf{x}$ 和 $\mathbf{y}$ 之间的互信息。根据 KL 散度的性质，我们知道 $I(\mathbf{x}, \mathbf{y}) \geq 0$ ，且当且仅当 $\mathbf{x}$ 和 $\mathbf{y}$ 独立时取等号。利用概率的求和法则和乘法法则，可以看出互信息与条件熵之间的关系为

$$I[\mathbf{x}, \mathbf{y}] = H[\mathbf{x}] - H[\mathbf{x}|\mathbf{y}] = H[\mathbf{y}] - H[\mathbf{y}|\mathbf{x}] \quad (1.121)$$

因此，我们可以把互信息理解为：由于获知了 $\mathbf{y}$ 的取值，从而对 $\mathbf{x}$ 的不确定性减少的量（反之亦然）。从贝叶斯的角度来看，可以将 $p(\mathbf{x})$ 视为关于 $\mathbf{x}$ 的先验分布，而在观测到新的数据 $\mathbf{y}$ 之后， $p(\mathbf{x}|\mathbf{y})$ 就是后验分布。于是，互信息就表示了由于新的观测 $\mathbf{y}$ 而导致的关于 $\mathbf{x}$ 的不确定性的减少。

2 概率分布

在第1章中，我们强调了概率论在解决模式识别问题中所起的核心作用。现在我们将探讨一些具体的概率分布及其性质。这些分布本身就具有重要的研究价值，同时它们也可以作为构建更复杂模型的基本单元，并将在全书中被广泛应用。本章介绍的分布还将发挥另一个重要作用，即为我们提供一个契机，在简单模型的背景下讨论一些关键的统计概念（例如贝叶斯推断），从而在后续更复杂的情形中遇到这些概念时能够更好地理解。

本章讨论的分布的一个作用，是在给定有限观测样本 $\mathbf{x}_1, \dots, \mathbf{x}_N$ 的情况下，用来建模随机变量 $\mathbf{x}$ 的概率分布 $p(\mathbf{x})$ 。这个问题被称为密度估计。在本章中，我们假设数据点是独立同分布的 (i.i.d.)。需要强调的是，密度估计问题在本质上是病态的，因为可能存在无穷多个概率分布都能够生成观测到的有限数据集。实际上，任何在数据点 $\mathbf{x}_1, \dots, \mathbf{x}_N$ 处取非零值的分布 $p(\mathbf{x})$ 都是潜在候选解。选择合适分布的问题，本质上与模型选择相关，这个问题我们在第1章的多项式曲线拟合中已经遇到过，并且它也是模式识别中的核心问题之一。

我们首先考虑离散随机变量的二项分布和多项分布，以及连续随机变量的高斯分布。这些都是参数化分布的具体例子，之所以这样称呼，是因为它们由少量可调参数决定，例如高斯分布中的均值和方差。要将这类模型应用于密度估计问题，我们需要一种方法，在给定观测数据集的情况下确定合适的参数值。在频率学派的处理方法中，我们通过优化某个准则（例如似然函数）来选择参数的具体数值。与此相对，在贝叶斯学派的处理方法中，我们为参数引入先验分布，然后利用贝叶斯定理，在给定观测数据的情况下计算相应的后验分布。

我们将看到，共轭先验在其中起着重要作用。它们的特点是使得后验分布与先验分布具有相同的函数形式，从而大大简化了贝叶斯分析。例如，多项分布参数的共轭先验是狄利克雷分布，而高斯分布的均值参数的共轭先验则是另一个高斯分布。这些分布都是指数族分布的例子。指数族分布具有许多重要性质，我们将在后续部分进行详细讨论。

参数化方法的一个局限在于它假设了分布具有特定的函数形式，而这种形式在某些应用中可能并不合适。另一种方法是非参数密度估计，在这种方法中，分布的形式通常依赖于数据集的规模。这类模型依然包含参数，但这些参数控制的是模型的复杂度，而不是分布的形式。本章最后我们将讨论三种非参数方法，它们分别基于直方图、最近邻以及核函数。

2.1 二元变量

我们先考虑一个二元随机变量 $x \in \{0, 1\}$ 。例如， x 可以表示一次抛硬币的结果，其中 $x = 1$ 表示“正面”，而 $x = 0$ 表示“反面”。我们可以设想这是一枚损坏的硬币，因此出现正面的概率不一定等于反面的概率。记 $x = 1$ 的概率为参数 μ ，于是有

$$p(x = 1 \mid \mu) = \mu \quad (2.1)$$

其中 $0 \leq \mu \leq 1$ ，由此可得 $p(x = 0 | \mu) = 1 - \mu$ 。因此，随机变量 x 的概率分布可以写成如下形式：

$$\text{Bern}(x|\mu) = \mu^x(1 - \mu)^{1-x} \quad (2.2)$$

这被称为伯努利分布。很容易验证该分布是归一化的，并且它的均值和方差分别为

$$\mathbb{E}[x] = \mu \quad (2.3)$$

$$\text{var}[x] = \mu(1 - \mu) \quad (2.4)$$

现在假设我们有一个观测数据集 $D = \{x_1, \dots, x_N\}$ 。在假设这些观测是独立地从分布 $p(x | \mu)$ 中抽取的前提下，可以构造似然函数，它是 μ 的函数：

$$p(\mathcal{D} | \mu) = \prod_{n=1}^N p(x_n | \mu) = \prod_{n=1}^N \mu^{x_n}(1 - \mu)^{1-x_n} \quad (2.5)$$

在频率学派的框架下，我们可以通过最大化似然函数来估计 μ 的值，等价地，也可以最大化似然函数的对数。在伯努利分布的情况下，对数似然函数为

$$\ln p(\mathcal{D} | \mu) = \sum_{n=1}^N \ln p(x_n | \mu) = \sum_{n=1}^N \{x_n \ln \mu + (1 - x_n) \ln(1 - \mu)\} \quad (2.6)$$

此时值得注意的是，对数似然函数依赖于 N 个观测值 x_n 的方式，仅通过它们的和 $\sum_n x_n$ 。这个和就是该分布下数据的一个充分统计量的例子。我们将在后面更详细地研究充分统计量的重要作用。如果令 $\ln p(D|\mu)$ 对 μ 的导数为零，就得到最大似然估计

$$\mu_{\text{ML}} = \frac{1}{N} \sum_{n=1}^N x_n \quad (2.7)$$

它也被称为样本均值。若记数据集中观测到 $x = 1$ （正面）的次数为 m ，那么式 (2.7) 可以写成

$$\mu_{\text{ML}} = \frac{m}{N} \quad (2.8)$$

因此，在最大似然框架下，硬币落到正面的概率由数据集中正面出现的比例给出。

现在假设我们掷一枚硬币 3 次，恰好观察到 3 次都是正面。此时 ($N = m = 3$)，于是最大似然估计得到 ($\mu_{\text{ML}} = 1$)。在这种情况下，最大似然的结果会预测所有未来的观察都将得到正面。常识告诉我们，这显然是不合理的，而事实上，这正是最大似然方法所带来的过拟合的一个极端例子。我们将会看到，通过为 (μ) 引入一个先验分布，可以得到更加合理的结论。

我们还可以求出在给定数据集大小为 N 的情况下，观察到 $x = 1$ 的次数 m 的分布。这称为二项分布，从 (2.5) 式中我们看到它与 $\mu^m(1 - \mu)^{N-m}$ 成比例。为了得到归一化系数，我们注意到在 N 次投掷硬币中，我们必须把所有可能得到 m 次正面的方式相加，因此二项分布可以写成：


$$\text{Bin}(m|N, \mu) = \binom{N}{m} \mu^m(1 - \mu)^{N-m} \quad (2.9)$$

其中

$$\binom{N}{m} \equiv \frac{N!}{m!(N-m)!} \quad (2.10)$$

是从总共 N 个相同对象中选择 m 个对象的方法数。图 2.1 展示了 $N = 10$ 且 $\mu = 0.25$ 时的二项分布图。

图 2.1 直方图绘制了二项分布 (2.9) 作为 m 的函数，其中 $N = 10$ 且 $\mu = 0.25$ 。



二项分布的均值和方差可以通过使用习题 1.10 的结果来求得，该习题表明对于独立事件，和的均值是均值的和，和的方差是方差的和。由于 $m = x_1 + \dots + x_N$ ，并且对于每个观测，其均值和方差分别由 (2.3) 和 (2.4) 给出，因此我们有：

$$E[m] = \sum_{n=1}^N E[x_n] = \sum_{n=1}^N \mu = N\mu \quad (2.11)$$

$$\text{var}[m] = \sum_{n=1}^N \text{var}[x_n] = \sum_{n=1}^N \mu(1-\mu) = N\mu(1-\mu) \quad (2.12)$$

这些结果也可以直接使用微积分来证明。

2.1.1 贝塔分布

我们已经在 (2.8) 中看到，伯努利分布，以及相应的二项分布中参数 (μ) 的最大似然估计是数据集中 ($x = 1$) 的观测比例。正如我们已经指出的，对于较小的数据集，这会导致严重的过拟合。为了对该问题建立一个贝叶斯处理方法，我们需要在参数 (μ) 上引入一个先验分布 ($p(\mu)$)。在这里，我们考虑一种既有清晰解释又具有良好分析性质的先验分布。为说明这种先验的来源，注意到似然函数可以写成形如 $(\mu^x(1-\mu)^{1-x})$ 的多个因子的乘积。如果我们选择的先验在形式上与 (μ) 和 $(1-\mu)$ 的幂成正比，那么后验分布就会与先验具有相同的函数形式，因为后验分布正比于先验与似然函数的乘积。这种性质称为共轭性，我们将在本章后续看到多个类似示例。因此，我们选择一种称为贝塔分布的先验，其形式为

$$\text{Beta}(\mu|a, b) = \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} \mu^{a-1} (1-\mu)^{b-1} \quad (2.13)$$




图 2.2 贝塔分布 ($\text{Beta}(\mu | a, b)$) 的曲线图, 展示了式 (2.13) 所定义分布随参数 (μ) 的变化情况, 其中 (a) 和 (b) 取不同的超参数值。

其中 $\Gamma(x)$ 为伽马函数, 其定义见公式 (1.141)。而式 (2.13) 中的系数保证了贝塔分布是归一化的, 即满足

$$\int_0^1 \text{Beta}(\mu | a, b) d\mu = 1. \quad (2.14)$$

贝塔分布的均值和方差为

$$\mathbb{E}[\mu] = \frac{a}{a+b} \quad (2.15)$$

$$\text{var}[\mu] = \frac{ab}{(a+b)^2(a+b+1)}. \quad (2.16)$$

参数 a 和 b 通常被称为超参数, 因为它们控制着参数 μ 的分布。图 2.2 展示了在不同超参数取值下的贝塔分布形状。

现在, 通过将贝塔先验分布式 (2.13) 与二项分布似然函数式 (2.9) 相乘并进行归一化, 可以得到参数 μ 的后验分布。保留仅依赖于 (μ) 的因子后, 可以看到该后验分布具有如下形式:

$$p(\mu | m, l, a, b) \propto \mu^{m+a-1} (1-\mu)^{l+b-1} \quad (2.17)$$

其中 $l = N - m$, 因此在掷硬币的例子中, l 对应于出现反面的次数。可以看到, 式(2.17)与先验分布在 (μ) 上具有相同的函数形式, 这反映了该先验分布相对于似然函数的共轭性质。事实上, 它依然是一个贝塔分布, 其归一化系数可通过与式(2.13) 对比得

到：

$$p(\mu | m, l, a, b) = \frac{\Gamma(m + a + l + b)}{\Gamma(m + a)\Gamma(l + b)} \mu^{m+a-1} (1 - \mu)^{l+b-1} \quad (2.18)$$

我们看到，观测到一个包含 m 个 $x = 1$ 的样本和 l 个 $x = 0$ 的样本，其效果是：在从先验分布到后验分布的过程中，将参数 a 的值增加了 m ，并将参数 b 的值增加了 l 。这使我们可以对先验分布中的超参数 a 和 b 给出一个简单的解释：它们分别可以看作是对 $x = 1$ 和 $x = 0$ 的“有效观测次数”。需要注意的是， a 和 b 不一定是整数。此外，如果我们随后又观测到了新的数据，那么后验分布还可以作为新的先验分布来使用。为说明这一点，我们可以设想依次逐个地获取观测值，并在每次观测之后，通过将当前的后验分布与新观测值的似然函数相乘，然后进行归一化，从而得到新的修正后验分布。在每一步中，后验分布都是一个 Beta 分布，其参数 a 和 b 分别代表（来自先验和实际观测的） $x = 1$ 和 $x = 0$ 的总观测次数。当加入一个新的 $x = 1$ 的观测时，只需将 a 的值加 1；而当加入一个 $x = 0$ 的观测时，只需将 b 的值加 1。图 2.3 展示了这一过程中的一个步骤。




图 2.3 顺序贝叶斯推断过程中的单步示意图。先验分布由参数 $a = 2$ 、 $b = 2$ 的 Beta 分布给出；似然函数由公式 (2.9) 给出，其中 $N = m = 1$ ，对应于一次 $x = 1$ 的观测，因此后验分布为参数 $a = 3$ 、 $b = 2$ 的 Beta 分布。

我们可以看到，当采用贝叶斯观点时，这种顺序学习的方法自然地出现了。它与先验分布或似然函数的具体形式无关，只依赖于数据独立同分布 (i.i.d.) 的假设。顺序方法一次使用一个或一小批观测数据，然后在使用下一组数据之前丢弃之前的数据。这种方法可以应用于实时学习场景中，例如当数据以连续流的形式不断到来，而必须在尚未获得全部数据之前进行预测的情况。由于顺序方法不需要将整个数据集存储或加载到内存中，因此它们在处理大规模数据集时也非常有用。最大似然方法同样也可以被表述为一种顺序化的框架。

如果我们的目标是尽可能准确地预测下一次试验的结果，那么我们必须给定观测数据集 $\mathcal{D}$ 的条件下，计算 x 的预测分布。根据概率的加法与乘法法则，这个分布可以写成如下形式：

$$p(x = 1 | \mathcal{D}) = \int_0^1 p(x = 1 | \mu) p(\mu | \mathcal{D}) d\mu = \int_0^1 \mu p(\mu | \mathcal{D}) d\mu = \mathbb{E}[\mu | \mathcal{D}]. \quad (2.19)$$

利用关于后验分布 $p(\mu | \mathcal{D})$ 的结果 (2.18)，以及关于 Beta 分布均值的结果 (2.15)，我们得到

$$p(x = 1 | \mathcal{D}) = \frac{m + a}{m + a + l + b} \quad (2.20)$$

这个结果可以作出一个简单的解释：它表示与 $x = 1$ 相对应的观测（包括真实观测和先验中的虚拟观测）所占的总比例。需要注意的是，在数据集无限增大的极限下，即 $m, l \rightarrow \infty$ 时，结果 (2.10) 会退化为最大似然结果 (2.8)。正如我们将看到的那样，这是一个非常普遍的性质：在数据量无限大的情况下，贝叶斯结果与最大似然结果是一致的。对于有限的数据集， μ 的后验均值总是位于先验均值与由 (2.7) 给出的事件相对频率所对应的最大似然估计之间。

从图 2.2 可以看出，随着观测数量的增加，后验分布变得越来越尖锐。这一点也可以从 Beta 分布方差的结果 (2.16) 中看出，因为当 $a \rightarrow \infty$ 或 $b \rightarrow \infty$ 时，方差趋于零。事实上，我们可能会好奇：在贝叶斯学习中，是否普遍存在这样一种性质——当我们不断获取更多数据时，由后验分布所表示的不确定性会持续减小。

为了解答这一问题，我们可以从频率学派的角度来看待贝叶斯学习，并证明这种性质在平均意义下确实成立。考虑一个关于参数 θ 的一般贝叶斯推断问题，我们已经观测到一个数据集 D ，其由联合分布 $p(\theta, D)$ 描述。接下来给出如下结果：

$$\mathbb{E}_{\theta}[\theta] = \mathbb{E}_{\mathcal{D}} [\mathbb{E}_{\theta}[\theta \mid \mathcal{D}]] \quad (2.21)$$

其中

$$\mathbb{E}_{\theta}[\theta] \equiv \int p(\theta) \theta d\theta \quad (2.22)$$

$$\mathbb{E}_{\mathcal{D}} [\mathbb{E}_{\theta}[\theta \mid \mathcal{D}]] \equiv \int \left\{ \int \theta p(\theta \mid \mathcal{D}) d\theta \right\} p(\mathcal{D}) d\mathcal{D} \quad (2.23)$$

该结果表明：在生成数据的分布上取平均后， θ 的后验均值等于 θ 的先验均值。类似地，我们还可以证明

$$\text{var}_{\theta}[\theta] = \mathbb{E}_{\mathcal{D}} [\text{var}_{\theta}[\theta \mid \mathcal{D}]] + \text{var}_{\mathcal{D}} [\mathbb{E}_{\theta}[\theta \mid \mathcal{D}]] \quad (2.24)$$

式 (2.24) 左边的项表示参数 θ 的先验方差。右边的第一项是 θ 的后验方差在数据生成分布上的平均值，第二项则衡量了 θ 的后验均值的方差。由于该方差项为正，这一结果表明：平均而言， θ 的后验方差小于其先验方差。而且，后验均值的方差越大，方差的减少幅度也就越大。但需要注意的是，这个结论只在平均意义下成立；对于某一个特定的观测数据集，后验方差有可能比先验方差更大。

2.2 多项式变量

二值变量用于描述只能取两种可能值的量。然而，在很多情况下，我们会遇到离散变量，它们可以取 K 个互斥的状态之一。虽然有多种方式可以表示这样的变量，但我们将很快看到，一种特别方便的表示方法是 1-of- K 编码。在这种表示中，变量被表示为一个 K 维向量 $\mathbf{x}$ ，其中某一个分量 $x_k = 1$ ，其余所有分量均为 0。例如，若某个变量可以取 $K = 6$ 个状态，并且某次观测对应于第 3 个状态（即 $x_3 = 1$ ），那么该变量可以表示为

$$\mathbf{x} = (0, 0, 1, 0, 0, 0)^T. \quad (2.25)$$

注意, 这样的向量满足 $\sum_{k=1}^K x_k = 1$. 如果我们用参数 μ_k 表示事件 $x_k = 1$ 的概率, 则 $\mathbf{x}$ 的分布可以写为

$$p(\mathbf{x} | \boldsymbol{\mu}) = \prod_{k=1}^K \mu_k^{x_k}, \quad (2.26)$$

其中 $\boldsymbol{\mu} = (\mu_1, \dots, \mu_K)^T$, 并且参数满足约束条件 $\mu_k \geq 0$ 且 $\sum_k \mu_k = 1$, 因为它们表示概率。分布式 (2.26) 可以看作是伯努利分布在多于两种结果时的推广。可以很容易验证该分布是归一化的:

$$\sum_{\mathbf{x}} p(\mathbf{x} | \boldsymbol{\mu}) = \sum_{k=1}^K \mu_k = 1, \quad (2.27)$$

并且有期望

$$\mathbb{E}[\mathbf{x} | \boldsymbol{\mu}] = \sum_{\mathbf{x}} p(\mathbf{x} | \boldsymbol{\mu}) \mathbf{x} = (\mu_1, \dots, \mu_K)^T = \boldsymbol{\mu}. \quad (2.28)$$

现在考虑一个包含 N 个独立观测 $\mathbf{x}_1, \dots, \mathbf{x}_N$ 的数据集 $\mathcal{D}$ 。其对应的似然函数为

$$p(\mathcal{D} | \boldsymbol{\mu}) = \prod_{n=1}^N \prod_{k=1}^K \mu_k^{x_{nk}} = \prod_{k=1}^K \mu_k^{(\sum_n x_{nk})} = \prod_{k=1}^K \mu_k^{m_k}. \quad (2.29)$$

我们可以看到, 似然函数仅通过 K 个量 m_k 与 N 个数据点相关:

$$m_k = \sum_n x_{nk}, \quad (2.30)$$

其中 m_k 表示 $x_k = 1$ 被观测到的次数。这些量称为该分布的充分统计量。

为了求出 $\boldsymbol{\mu}$ 的最大似然解, 我们需要在约束条件 $\sum_{k=1}^K \mu_k = 1$ 下, 最大化 $\ln p(\mathcal{D} | \boldsymbol{\mu})$ 关于 μ_k 的值。为此, 我们可以引入一个拉格朗日乘子 λ , 并最大化以下函数:

$$\sum_{k=1}^K m_k \ln \mu_k + \lambda \left(\sum_{k=1}^K \mu_k - 1 \right). \quad (2.31)$$

对式 (2.31) 关于 μ_k 求导并令其为零, 得到

$$\mu_k = -\frac{m_k}{\lambda}. \quad (2.32)$$

我们可以通过将式 (2.32) 代入约束条件 $\sum_k \mu_k = 1$ 来求解拉格朗日乘子 λ , 从而得到 $\lambda = -N$ 。因此, 最大似然解为

$$\mu_k^{\text{ML}} = \frac{m_k}{N}, \quad (2.33)$$

这表示在 N 个观测中, 事件 $x_k = 1$ 出现的比例。

我们还可以考虑在给定参数 $\boldsymbol{\mu}$ 和总观测数 N 的条件下, $m_1, \dots, m_K$ 的联合分布。根据式 (2.29), 该分布可写为

$$\text{Mult}(m_1, m_2, \dots, m_K | \boldsymbol{\mu}, N) = \binom{N}{m_1 m_2 \dots m_K} \prod_{k=1}^K \mu_k^{m_k}, \quad (2.34)$$

这称为多项式分布 (multinomial distribution)。归一化系数表示将 N 个对象划分为大小分别为 $m_1, \dots, m_K$ 的 K 个组的不同方式的数量, 其形式为

$$\binom{N}{m_1 m_2 \dots m_K} = \frac{N!}{m_1! m_2! \dots m_K!}. \quad (2.35)$$

注意, 变量 m_k 满足约束条件

$$\sum_{k=1}^K m_k = N. \quad (2.36)$$


2.2.1 狄利克雷分布

我们现在为多项式分布 (2.34) 的参数集合 μ_k 引入一族先验分布。根据多项式分布的形式可以看出, 其共轭先验为

$$p(\boldsymbol{\mu} | \boldsymbol{\alpha}) \propto \prod_{k=1}^K \mu_k^{\alpha_k - 1}, \quad (2.37)$$

其中 $0 \leq \mu_k \leq 1$ 且 $\sum_k \mu_k = 1$ 。这里的 $\alpha_1, \dots, \alpha_K$ 是该分布的参数, 记作 $\boldsymbol{\alpha} = (\alpha_1, \dots, \alpha_K)^T$ 。由于存在求和约束, 分布在 μ_k 空间中被限制在一个 $(K - 1)$ 维的单纯形上, 如图 2.4 中 $K = 3$ 的情况所示。

图 2.4 对三个变量 μ_1, μ_2, μ_3 的 Dirichlet 分布被限制在一个如图
所示的单纯形 (有界线性流形) 中, 这是由约束条件 $0 \leq$
 $\mu_k \leq 1$ 和 $\sum_k \mu_k = 1$ 所导致的。



该分布的归一化形式为

$$\text{Dir}(\boldsymbol{\mu} | \boldsymbol{\alpha}) = \frac{\Gamma(\alpha_0)}{\Gamma(\alpha_1)\Gamma(\alpha_2)\dots\Gamma(\alpha_K)} \prod_{k=1}^K \mu_k^{\alpha_k - 1}, \quad (2.38)$$

这被称为狄利克雷分布。其中 $\Gamma(x)$ 是伽马函数, 定义见式 (1.141), 并且

$$\alpha_0 = \sum_{k=1}^K \alpha_k. \quad (2.39)$$

图 2.5 展示了在不同参数 α_k 设置下, 狄利克雷分布在单纯形上的形状。

将先验分布 (2.38) 与似然函数 (2.34) 相乘, 我们得到参数 μ_k 的后验分布:

$$p(\boldsymbol{\mu} | \mathcal{D}, \boldsymbol{\alpha}) \propto p(\mathcal{D} | \boldsymbol{\mu}), p(\boldsymbol{\mu} | \boldsymbol{\alpha}) \propto \prod_{k=1}^K \mu_k^{\alpha_k + m_k - 1}. \quad (2.40)$$




图 2.5 三元 Dirichlet 分布的图示中，两个水平坐标轴位于单纯形平面内，垂直轴表示密度值。左图中 $\{\alpha_k\} = 0.1$ ，中图中 $\{\alpha_k\} = 1$ ，右图中 $\{\alpha_k\} = 10$ 。

可以看出，后验分布仍然是一个狄利克雷分布形式的分布，这验证了狄利克雷分布确实是多项式分布的共轭先验。通过与式 (2.38) 比较，我们可以确定其归一化系数，从而得到：

$$p(\boldsymbol{\mu} \mid \mathcal{D}, \boldsymbol{\alpha}) = \text{Dir}(\boldsymbol{\mu} \mid \boldsymbol{\alpha} + \mathbf{m}) = \frac{\Gamma(\alpha_0 + N)}{\Gamma(\alpha_1 + m_1) \cdots \Gamma(\alpha_K + m_K)} \prod_{k=1}^K \mu_k^{\alpha_k + m_k - 1}, \quad (2.41)$$

其中 $\mathbf{m} = (m_1, \dots, m_K)^T$ 。与 Beta 分布作为二项分布的共轭先验的情形类似，我们可以将狄利克雷先验的参数 α_k 理解为对事件 $x_k = 1$ 的“有效观测次数”。

需要注意的是，二状态变量既可以表示为二值变量，并使用二项分布 (2.9) 建模；也可以表示为 1-of-2 变量，并使用 $K = 2$ 的多项式分布 (2.34) 建模。

2.3 高斯分布

高斯分布，又称正态分布，是一种广泛用于描述连续变量分布的模型。对于单个变量 x ，高斯分布可以写为

$$\mathcal{N}(x \mid \mu, \sigma^2) = \frac{1}{(2\pi\sigma^2)^{1/2}} \exp \left\{ -\frac{1}{2\sigma^2} (x - \mu)^2 \right\}, \quad (2.42)$$

其中， μ 为均值， σ^2 为方差。对于 D 维向量 $\mathbf{x}$ ，多元高斯分布的形式为

$$\mathcal{N}(\mathbf{x} \mid \boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{(2\pi)^{D/2}} \frac{1}{|\boldsymbol{\Sigma}|^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right\}, \quad (2.43)$$

其中， $\boldsymbol{\mu}$ 是 D 维均值向量， $\boldsymbol{\Sigma}$ 是 $D \times D$ 协方差矩阵，而 $|\boldsymbol{\Sigma}|$ 表示其行列式。

高斯分布在许多不同的情境中都会自然出现，可以从多种角度加以理解。例如，对于单个实数变量，能最大化熵的分布就是高斯分布。这一性质同样适用于多元高斯情形。

另一种出现高斯分布的情形是当我们考虑多个随机变量的和时。中心极限定理指出：在某些较弱的条件下，一组随机变量的和（本身也是一个随机变量）的分布会随着求和项数的增加而逐渐趋近于高斯分布（参见 Walker, 1969）。例如，假设有 N 个随机

变量 $x_1, \dots, x_N$, 它们在区间 $[0, 1]$ 上均匀分布, 我们关心它们的平均值 $\frac{x_1+x_2+\dots+x_N}{N}$. 当 N 很大时, 该平均值的分布会趋近于高斯分布, 如图 2.6 所示。实际上, 随着 N 的增大, 向高斯分布的收敛速度非常快。这一结果的一个直接推论是: 二项分布 (2.9), 即由对随机二值变量 x 进行 N 次观测后得到的 m 的分布, 在 $N \rightarrow \infty$ 时也将趋近于高斯分布 (见图 2.1 中 $N = 10$ 的情况)。




图 2.6 对于不同取值的 N , 绘制由 N 个均匀分布数值的均值所构成的直方图。可以观察到, 随着 N 的增大, 该分布趋近于高斯分布。

高斯分布具有许多重要的解析性质, 本节将详细讨论其中的一些。由于涉及较多的矩阵恒等式, 本节的技术细节会比之前的章节更复杂。然而, 掌握这里介绍的高斯分布操作技巧, 将对理解后续章节中的复杂模型非常有帮助。

我们首先从几何角度来考察高斯分布的形式。高斯分布对 x 的函数依赖体现在如下二次型中:

$$\Delta^2 = (\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}), \quad (2.44)$$

其中量 Δ 被称为马氏距离, 表示从 $\boldsymbol{\mu}$ 到 $\mathbf{x}$ 的距离。当协方差矩阵 $\boldsymbol{\Sigma}$ 为单位矩阵时, 马氏距离退化为欧氏距离。因此, 高斯分布在 $\mathbf{x}$ 空间中将保持常数于使该二次型取相同值的曲面上。

首先我们注意到, 矩阵 $\boldsymbol{\Sigma}$ 可以在不失一般性的情况下视为对称矩阵, 因为任何反对称部分在指数中都会消失。考虑协方差矩阵的特征向量方程:

$$\boldsymbol{\Sigma} \mathbf{u}_i = \lambda_i \mathbf{u}_i, \quad (2.45)$$

其中 $i = 1, \dots, D$ 。由于 $\boldsymbol{\Sigma}$ 是实对称矩阵, 其特征值 λ_i 均为实数, 并且其特征向量 $\mathbf{u}_i$ 可以选择为正交归一 (orthonormal) 的一组向量, 因此有

$$\mathbf{u}_i^T \mathbf{u}_j = I_{ij}, \quad (2.46)$$

其中 I_{ij} 是单位矩阵的第 (i, j) 个元素, 满足

$$I_{ij} = \begin{cases} 1, & \text{若 } i = j, \\ 0, & \text{否则.} \end{cases} \quad (2.47)$$

协方差矩阵 $\boldsymbol{\Sigma}$ 可以用其特征向量展开为

$$\boldsymbol{\Sigma} = \sum_{i=1}^D \lambda_i \mathbf{u}_i \mathbf{u}_i^T, \quad (2.48)$$

而其逆矩阵 Σ^{-1} 则可写为

$$\Sigma^{-1} = \sum_{i=1}^D \frac{1}{\lambda_i} \mathbf{u}_i \mathbf{u}_i^T. \quad (2.49)$$

将上述式子代入 (2.44)，可得该二次型为

$$\Delta^2 = \sum_{i=1}^D \frac{y_i^2}{\lambda_i}, \quad (2.50)$$

其中我们定义

$$y_i = \mathbf{u}_i^T (\mathbf{x} - \boldsymbol{\mu}). \quad (2.51)$$


我们可以将 y_i 理解为由正交归一向量 $\mathbf{u}_i$ 定义的新坐标系，它相对于原坐标 x_i 进行了旋转和平移。形成向量 $\mathbf{y} = (y_1, \dots, y_D)^T$ ，则有

$$\mathbf{y} = \mathbf{U}(\mathbf{x} - \boldsymbol{\mu}), \quad (2.52)$$

其中，矩阵 $\mathbf{U}$ 的各行由 $\mathbf{u}_i^T$ 给出。由式 (2.46) 可知， $\mathbf{U}$ 是一个正交矩阵，即它满足 $\mathbf{U}\mathbf{U}^T = \mathbf{I}$ ，因此也有 $\mathbf{U}^T\mathbf{U} = \mathbf{I}$ ，其中 $\mathbf{I}$ 为单位矩阵。

该二次型（以及相应的高斯密度）在式 (2.51) 的值保持不变的曲面上取常数。如果所有特征值 λ_i 都为正数，这些曲面就是椭球面，它们的中心位于 $\boldsymbol{\mu}$ ，主轴方向由特征向量 $\mathbf{u}_i$ 给定，而在每个方向上的伸缩尺度由 $\lambda_i^{1/2}$ 决定，如图 2.7 所示。

图 2.7 红色曲线表示二维空间 $\mathbf{x} = (x_1, x_2)$ 中高斯分布的等概率密度椭圆，其密度为在 $\mathbf{x} = \boldsymbol{\mu}$ 处取值的 $\exp(-1/2)$ 。该椭圆的主轴由协方差矩阵的特征向量 $\mathbf{u}_i$ 定义，且对应的特征值为 λ_i 。



为了保证高斯分布是良好定义的，协方差矩阵的所有特征值 λ_i 必须严格为正，否则分布无法正确归一化。一个所有特征值都为正的矩阵称为正定矩阵。在第 12 章中，我们将遇到一些特征值为零的高斯分布，这种情况下分布是奇异的，仅定义在低维子空间中。如果所有特征值非负（即允许为零），则称协方差矩阵是半正定矩阵。

现在考虑在由 y_i 定义的新坐标系下高斯分布的形式。从 $\mathbf{x}$ 到 $\mathbf{y}$ 坐标系的变换具有一个雅可比矩阵 $\mathbf{J}$ ，其元素为

$$J_{ij} = \frac{\partial x_i}{\partial y_j} = U_{ji}, \quad (2.53)$$

其中 U_{ji} 是矩阵 $\mathbf{U}^T$ 的元素。利用 $\mathbf{U}$ 的正交性，可得雅可比矩阵行列式的平方为

$$|\mathbf{J}|^2 = |\mathbf{U}^T|^2 = |\mathbf{U}^T| |\mathbf{U}| = |\mathbf{U}^T \mathbf{U}| = |\mathbf{I}| = 1, \quad (2.54)$$

因此有 $|\mathbf{J}| = 1$ 。此外，协方差矩阵 Σ 的行列式可以表示为其特征值的乘积，因此有

$$|\Sigma|^{1/2} = \prod_{j=1}^D \lambda_j^{1/2}. \quad (2.55)$$

因此，在 y_j 坐标系下，高斯分布可以写为

$$p(\mathbf{y}) = p(\mathbf{x})|\mathbf{J}| = \prod_{j=1}^D \frac{1}{(2\pi\lambda_j)^{1/2}} \exp\left\{-\frac{y_j^2}{2\lambda_j}\right\}, \quad (2.56)$$

这表示为 D 个相互独立的单变量高斯分布的乘积。由此可见，特征向量 $\mathbf{u}_i$ 定义了一个经过平移与旋转的新坐标系，在该坐标系下，联合概率分布可分解为独立分布的乘积。在 $\mathbf{y}$ 坐标系中，对该分布进行积分得到

$$\int p(\mathbf{y}) d\mathbf{y} = \prod_{j=1}^D \int_{-\infty}^{\infty} \frac{1}{(2\pi\lambda_j)^{1/2}} \exp\left\{-\frac{y_j^2}{2\lambda_j}\right\} dy_j = 1, \quad (2.57)$$

其中使用了单变量高斯分布归一化的结果 (1.48)。这验证了多元高斯分布 (2.43) 确实是归一化的。

接下来我们来看高斯分布的矩，并由此解释参数 $\boldsymbol{\mu}$ 和 Σ 的意义。在高斯分布下， $\mathbf{x}$ 的期望为

$$\begin{aligned} \mathbb{E}[\mathbf{x}] &= \frac{1}{(2\pi)^{D/2}} \frac{1}{|\Sigma|^{1/2}} \int \exp\left\{-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu})\right\} \mathbf{x} d\mathbf{x} \\ &= \frac{1}{(2\pi)^{D/2}} \frac{1}{|\Sigma|^{1/2}} \int \exp\left\{-\frac{1}{2}\mathbf{z}^T \Sigma^{-1}\mathbf{z}\right\} (\mathbf{z} + \boldsymbol{\mu}) d\mathbf{z}, \end{aligned} \quad (2.58)$$

其中我们进行了变量替换 $\mathbf{z} = \mathbf{x} - \boldsymbol{\mu}$ 。注意到指数项是关于 $\mathbf{z}$ 各分量的偶函数，并且积分区间为 $(-\infty, \infty)$ ，因此在 $(\mathbf{z} + \boldsymbol{\mu})$ 中与 $\mathbf{z}$ 线性相关的项由于对称性消失。于是有

$$\mathbb{E}[\mathbf{x}] = \boldsymbol{\mu}, \quad (2.59)$$

因此称 $\boldsymbol{\mu}$ 为高斯分布的均值。

现在考虑高斯分布的二阶矩。在一维情形下，我们研究的是 $\mathbb{E}[x^2]$ ；而在多维情况下，有 D^2 个二阶矩 $\mathbb{E}[x_i x_j]$ ，我们可以将它们组合成一个矩阵 $\mathbb{E}[\mathbf{x}\mathbf{x}^T]$ 。该矩阵可写为

$$\begin{aligned} \mathbb{E}[\mathbf{x}\mathbf{x}^T] &= \frac{1}{(2\pi)^{D/2}} \frac{1}{|\Sigma|^{1/2}} \int \exp\left\{-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu})\right\} \mathbf{x}\mathbf{x}^T d\mathbf{x} \\ &= \frac{1}{(2\pi)^{D/2}} \frac{1}{|\Sigma|^{1/2}} \int \exp\left\{-\frac{1}{2}\mathbf{z}^T \Sigma^{-1}\mathbf{z}\right\} (\mathbf{z} + \boldsymbol{\mu})(\mathbf{z} + \boldsymbol{\mu})^T d\mathbf{z}. \end{aligned}$$

这里我们再次进行了变量替换 $\mathbf{z} = \mathbf{x} - \boldsymbol{\mu}$ 。注意，其中涉及 $\boldsymbol{\mu}\mathbf{z}^T$ 和 $\boldsymbol{\mu}^T\mathbf{z}$ 的交叉项会由于对称性而消失。项 $\boldsymbol{\mu}\boldsymbol{\mu}^T$ 是常数，可以从积分中提出，而该积分本身等于 1，因为高斯分布已经归一化。现在考虑涉及 $\mathbf{z}\mathbf{z}^T$ 的项。我们再次利用协方差矩阵的特征向量展开式 (2.45)，并利用特征向量集合的完备性，有

$$\mathbf{z} = \sum_{j=1}^D y_j \mathbf{u}_j, \quad (2.60)$$

其中 $y_j = \mathbf{u}_j^T \mathbf{z}$ 。因此可得

$$\begin{aligned} & \frac{1}{(2\pi)^{D/2}} \frac{1}{|\Sigma|^{1/2}} \int \exp \left\{ -\frac{1}{2} \mathbf{z}^T \Sigma^{-1} \mathbf{z} \right\} \mathbf{z} \mathbf{z}^T, d\mathbf{z} \\ &= \frac{1}{(2\pi)^{D/2}} \frac{1}{|\Sigma|^{1/2}} \sum_{i=1}^D \sum_{j=1}^D \mathbf{u}_i \mathbf{u}_j^T \int \exp \left\{ -\sum_{k=1}^D \frac{y_k^2}{2\lambda_k} \right\} y_i y_j, d\mathbf{y} \\ &= \sum_{i=1}^D \mathbf{u}_i \mathbf{u}_i^T \lambda_i = \Sigma. \end{aligned} \quad (2.61)$$

在这里我们使用了特征向量方程 (2.45)，并利用了中间行右侧的积分在 $i \neq j$ 时因对称性为零的事实。在最后一步，我们结合结果 (1.50)、(2.55) 以及 (2.48) 得到上式。于是

$$\mathbb{E}[\mathbf{x}\mathbf{x}^T] = \boldsymbol{\mu}\boldsymbol{\mu}^T + \Sigma. \quad (2.62)$$

在单变量情形下，我们通过减去均值再取二阶矩来定义方差。类似地，在多变量情况下，也可以通过减去均值来定义协方差，即

$$\text{cov}[\mathbf{x}] = \mathbb{E}[(\mathbf{x} - \mathbb{E}[\mathbf{x}])(\mathbf{x} - \mathbb{E}[\mathbf{x}])^T]. \quad (2.63)$$

对于高斯分布的特例，结合 $\mathbb{E}[\mathbf{x}] = \boldsymbol{\mu}$ 和上式结果 (2.62)，得到


$$\text{cov}[\mathbf{x}] = \Sigma. \quad (2.64)$$

因此，参数矩阵 Σ 控制了高斯分布下 $\mathbf{x}$ 的协方差，因此称其为协方差矩阵。

虽然高斯分布 (2.43) 被广泛用作密度模型，但它也存在显著的局限性。考虑其自由参数的数量：一般的对称协方差矩阵 Σ 具有 $\frac{D(D+1)}{2}$ 个独立参数，而均值向量 $\boldsymbol{\mu}$ 另有 D 个独立参数，因此总参数数量为 $\frac{D(D+3)}{2}$ 。当维度 D 很大时，参数的总数会随 D 二次增长，从而使得在计算上操作和求逆大型矩阵的代价极高。为应对这一问题，可以使用一些受限形式的协方差矩阵。例如，若我们考虑对角协方差矩阵，即 $\Sigma = \text{diag}(\sigma_i^2)$ ，那么模型中共有 $2D$ 个独立参数。此时的等密度曲线是坐标轴对齐的椭球面。进一步地，我们还可以将协方差矩阵约束为与单位矩阵成比例，即 $\Sigma = \sigma^2 \mathbf{I}$ ，这称为各向同性协方差，此时模型仅包含 $D+1$ 个独立参数，对应的等密度面为球面。一般协方差矩阵、对角协方差矩阵和各向同性协方差矩阵这三种情况如图 2.8 所示。不幸的是，虽然这些简化方法减少了分布的自由度，并使协方差矩阵求逆更加高效，但它们也极大地限制了分布的形状，从而削弱了模型捕捉数据中有趣相关结构的能力。

此外，高斯分布本身存在一个根本限制：它固有地是单峰的，即仅有一个最大值，因此无法很好地逼近多峰分布。由此可见，高斯分布在某种意义上既“过于灵活”——参数太多；又“过于受限”——无法表示足够复杂的概率结构。后续我们将看到，通过引入潜变量，也称为隐变量或未观测变量，这两类问题都能得到解决。特别地，若引入离散潜变量，即可得到一类丰富的多峰分布——即高斯混合模型，这一内容将在第 2.3.9 节中讨论。而若引入连续潜变量（第 12 章将详细介绍），则可以构建一类模型，其自由参数数量可独立于数据空间维度 D 而被控制，同时仍能捕捉数据中的主要相关结构。

图 2.8 二维高斯分布的等概率密度轮廓：(a) 协方差矩阵为一般形式；(b) 协方差矩阵为对角形式，此时椭圆轮廓与坐标轴对齐；(c) 协方差矩阵与单位矩阵成比例，此时轮廓为同心圆。



事实上，这两种方法可以结合，并进一步扩展为一整套层次化模型，可适应各种实际应用场景。例如，高斯马尔可夫随机场（Gaussian Markov Random Field）是一种广泛用于图像建模的概率模型。它在像素强度的联合空间上是一个高斯分布，但由于在模型中引入了反映像素空间结构的约束，从而保持了可计算性。类似地，线性动态系统常用于时间序列建模（如目标跟踪），它也是在观测变量与潜变量的联合空间上的高斯分布，并且由于其结构化形式而保持可解性。描述这些复杂分布形式及其性质的强大框架是概率图模型，这将是第 8 章的主题。

2.3.1 条件高斯分布

高斯分布的一个重要性质是：如果两个变量集合联合服从多元高斯分布，那么其中一个变量在给定另一个变量条件下的条件分布仍然是高斯分布；同时，每个变量集合的边缘分布也都是高斯的。

首先考虑条件分布的情形。假设 $\mathbf{x}$ 是一个维度为 D 的随机向量，服从高斯分布 $\mathcal{N}(\mathbf{x} | \boldsymbol{\mu}, \boldsymbol{\Sigma})$ ，并将其划分为两个互不相交的子向量 $\mathbf{x}_a$ 和 $\mathbf{x}_b$ 。不失一般性地，可以令 $\mathbf{x}_a$ 为 $\mathbf{x}$ 的前 M 个分量，而 $\mathbf{x}_b$ 为剩下的 $D - M$ 个分量，于是有

$$\mathbf{x} = \begin{pmatrix} \mathbf{x}_a \\ \mathbf{x}_b \end{pmatrix}. \quad (2.65)$$

相应地，均值向量 $\boldsymbol{\mu}$ 也被划分为

$$\boldsymbol{\mu} = \begin{pmatrix} \boldsymbol{\mu}_a \\ \boldsymbol{\mu}_b \end{pmatrix}, \quad (2.66)$$

而协方差矩阵 $\boldsymbol{\Sigma}$ 被分块写为

$$\boldsymbol{\Sigma} = \begin{pmatrix} \boldsymbol{\Sigma}_{aa} & \boldsymbol{\Sigma}_{ab} \\ \boldsymbol{\Sigma}_{ba} & \boldsymbol{\Sigma}_{bb} \end{pmatrix}. \quad (2.67)$$

由于协方差矩阵是对称的，即 $\boldsymbol{\Sigma}^T = \boldsymbol{\Sigma}$ ，因此 $\boldsymbol{\Sigma}_{aa}$ 和 $\boldsymbol{\Sigma}_{bb}$ 都是对称矩阵，且有 $\boldsymbol{\Sigma}_{ba} = \boldsymbol{\Sigma}_{ab}^T$ 。在许多情况下，使用协方差矩阵的逆会更加方便，我们定义

$$\boldsymbol{\Lambda} \equiv \boldsymbol{\Sigma}^{-1}, \quad (2.68)$$

称 $\boldsymbol{\Lambda}$ 为精度矩阵。事实上，高斯分布的一些性质用协方差矩阵表达最为自然，而另一些性质在用精度矩阵表示时更为简洁。因此，我们也将精度矩阵写成与 $\mathbf{x}$ 分块形式对应

的结构:

$$\Lambda = \begin{pmatrix} \Lambda_{aa} & \Lambda_{ab} \\ \Lambda_{ba} & \Lambda_{bb} \end{pmatrix}. \quad (2.69)$$

由于对称矩阵的逆仍然是对称的, 因此 Λ_{aa} 和 Λ_{bb} 也是对称矩阵, 并且有 $\Lambda_{ab}^T = \Lambda_{ba}$. 需要强调的是, Λ_{aa} 并不等于 Σ_{aa} 的逆。稍后我们将讨论分块矩阵的逆与其各分块之间的关系。

我们现在来求条件分布 $p(\mathbf{x}_a | \mathbf{x}_b)$ 的表达式。我们可以看到, 条件分布可以直接从联合分布 $p(\mathbf{x}) = p(\mathbf{x}_a, \mathbf{x}_b)$ 中求得, 只需将 $\mathbf{x}_b$ 固定为其观测值, 然后对结果进行归一化, 以得到关于 $\mathbf{x}_a$ 的有效概率分布。与其显式地执行这种归一化操作, 不如更高效地通过考察高斯分布 (2.44) 指数中的二次型来求解, 最后再补上归一化系数。利用分块形式 (2.65)、(2.66) 和 (2.69), 可得

$$\begin{aligned} & -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu}) \\ &= -\frac{1}{2}(\mathbf{x}_a - \boldsymbol{\mu}_a)^T \Lambda_{aa}(\mathbf{x}_a - \boldsymbol{\mu}_a) - \frac{1}{2}(\mathbf{x}_a - \boldsymbol{\mu}_a)^T \Lambda_{ab}(\mathbf{x}_b - \boldsymbol{\mu}_b) \\ & \quad - \frac{1}{2}(\mathbf{x}_b - \boldsymbol{\mu}_b)^T \Lambda_{ba}(\mathbf{x}_a - \boldsymbol{\mu}_a) - \frac{1}{2}(\mathbf{x}_b - \boldsymbol{\mu}_b)^T \Lambda_{bb}(\mathbf{x}_b - \boldsymbol{\mu}_b). \end{aligned} \quad (2.70)$$

可以看到, 这个式子作为 $\mathbf{x}_a$ 的函数时仍然是一个二次型, 因此相应的条件分布 $p(\mathbf{x}_a | \mathbf{x}_b)$ 也是一个高斯分布。由于高斯分布完全由其均值和协方差确定, 我们的目标是通过观察式 (2.70) 来确定 $p(\mathbf{x}_a | \mathbf{x}_b)$ 的均值与协方差的表达式。

这种操作在高斯分布的推导中非常常见, 被称为配方。在这种情况下, 我们已知高斯分布指数中的二次型, 需要从中确定对应的均值和协方差。对于一般高斯分布 $\mathcal{N}(\mathbf{x} | \boldsymbol{\mu}, \Sigma)$, 其指数项可写为

$$-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu}) = -\frac{1}{2}\mathbf{x}^T \Sigma^{-1} \mathbf{x} \mathbf{x}^T \Sigma^{-1} \boldsymbol{\mu} \text{const}, \quad (2.71)$$

其中 “const” 表示与 $\mathbf{x}$ 无关的常数项, 并且利用了 Σ 的对称性。因此, 如果我们把一个给定的二次型写成右侧这种形式, 就可以直接识别出: $\mathbf{x}$ 二次项的系数矩阵即为逆协方差矩阵 Σ^{-1} ; 线性项的系数为 $\Sigma^{-1} \boldsymbol{\mu}$, 从而可以求出 $\boldsymbol{\mu}$ 。

现在将这一方法应用到条件高斯分布 $p(\mathbf{x}_a | \mathbf{x}_b)$ 上。对于式 (2.70) 的指数部分, 设其均值与协方差分别为 $\boldsymbol{\mu}_{a|b}$ 和 $\Sigma_{a|b}$ 。考虑其关于 $\mathbf{x}_a$ 的依赖形式, 并把 $\mathbf{x}_b$ 看作常量。取出其中关于 $\mathbf{x}_a$ 的二次项, 可得

$$-\frac{1}{2}\mathbf{x}_a^T \Lambda_{aa} \mathbf{x}_a. \quad (2.72)$$

由此我们可以直接得到条件分布的协方差 (或逆精度) 为

$$\Sigma_{a|b} = \Lambda_{aa}^{-1}. \quad (2.73)$$

现在考虑式 (2.70) 中所有关于 $\mathbf{x}_a$ 的一次项

$$\mathbf{x}_a^T \{ \Lambda_{aa} \boldsymbol{\mu}_a - \Lambda_{ab}(\mathbf{x}_b - \boldsymbol{\mu}_b) \}, \quad (2.74)$$

其中我们使用了 $\Lambda_{ba}^T = \Lambda_{ab}$ 。根据对一般形式 (2.71) 的讨论，上式中 $\mathbf{x}_a$ 的系数必须等于 $\Sigma_{a|b}^{-1}\boldsymbol{\mu}_{a|b}$ ，因此有

$$\begin{aligned}\boldsymbol{\mu}_{a|b} &= \Sigma_{a|b} \{ \Lambda_{aa}\boldsymbol{\mu}_a - \Lambda_{ab}(\mathbf{x}_b - \boldsymbol{\mu}_b) \} \\ &= \boldsymbol{\mu}_a - \Lambda_{aa}^{-1}\Lambda_{ab}(\mathbf{x}_b - \boldsymbol{\mu}_b)\end{aligned}\quad (2.75)$$

其中我们使用了式 (2.73)。

结果 (2.73) 和 (2.75) 是用原联合分布 $p(\mathbf{x}_a, \mathbf{x}_b)$ 的分块精度矩阵来表示的。我们也可以把这些结果用相应的分块协方差矩阵来表示。为此，使用分块矩阵求逆的如下恒等式

$$\begin{pmatrix} \mathbf{A} & \mathbf{B} \\ \mathbf{C} & \mathbf{D} \end{pmatrix}^{-1} = \begin{pmatrix} \mathbf{M} & -\mathbf{M}\mathbf{B}\mathbf{D}^{-1} \\ -\mathbf{D}^{-1}\mathbf{C}\mathbf{M} & \mathbf{D}^{-1} + \mathbf{D}^{-1}\mathbf{C}\mathbf{M}\mathbf{B}\mathbf{D}^{-1} \end{pmatrix}, \quad (2.76)$$

其中

$$\mathbf{M} = (\mathbf{A} - \mathbf{B}\mathbf{D}^{-1}\mathbf{C})^{-1}. \quad (2.77)$$

量 $\mathbf{M}^{-1}$ 称为左侧矩阵关于子矩阵 $\mathbf{D}$ 的 Schur 补。利用定义

$$\begin{pmatrix} \Sigma_{aa} & \Sigma_{ab} \\ \Sigma_{ba} & \Sigma_{bb} \end{pmatrix}^{-1} = \begin{pmatrix} \Lambda_{aa} & \Lambda_{ab} \\ \Lambda_{ba} & \Lambda_{bb} \end{pmatrix} \quad (2.78)$$

并结合 (2.76)，得到

$$\Lambda_{aa} = (\Sigma_{aa} - \Sigma_{ab}\Sigma_{bb}^{-1}\Sigma_{ba})^{-1}, \quad (2.79)$$

$$\Lambda_{ab} = -(\Sigma_{aa} - \Sigma_{ab}\Sigma_{bb}^{-1}\Sigma_{ba})^{-1}\Sigma_{ab}\Sigma_{bb}^{-1}. \quad (2.80)$$

由此可得条件分布 $p(\mathbf{x}_a | \mathbf{x}_b)$ 的均值与协方差为

$$\boldsymbol{\mu}_{a|b} = \boldsymbol{\mu}_a + \Sigma_{ab}\Sigma_{bb}^{-1}(\mathbf{x}_b - \boldsymbol{\mu}_b), \quad (2.81)$$

$$\Sigma_{a|b} = \Sigma_{aa} - \Sigma_{ab}\Sigma_{bb}^{-1}\Sigma_{ba}. \quad (2.82)$$

对比 (2.73) 与 (2.82) 可以看到，当用分块精度矩阵来表示时，条件分布 $p(\mathbf{x}_a | \mathbf{x}_b)$ 的形式更为简洁。注意，由 (2.81) 给出的条件分布的均值是 $\mathbf{x}_b$ 的线性函数，而由 (2.82) 给出的协方差与 $\mathbf{x}_a$ 无关。这就是线性—高斯模型的一个实例。

2.3.2 边缘高斯分布

我们已经看到，如果联合分布 $p(\mathbf{x}_a, \mathbf{x}_b)$ 是高斯分布，那么条件分布 $p(\mathbf{x}_a | \mathbf{x}_b)$ 仍将是高斯分布。现在我们转向讨论由下式给出的边缘分布：

$$p(\mathbf{x}_a) = \int p(\mathbf{x}_a, \mathbf{x}_b) d\mathbf{x}_b \quad (2.83)$$

正如我们将要看到的，这个边缘分布也是高斯分布。同样，我们有效计算此分布的策略是：关注联合分布指数中的二次型，从而识别边缘分布 $p(\mathbf{x}_a)$ 的均值和协方差。

联合分布的二次型可以使用分块精度矩阵，以 (2.70) 式的形式表示。因为我们的目标是积分消去 $\mathbf{x}_b$ ，最容易的实现方式是：首先考虑涉及 $\mathbf{x}_b$ 的项，然后进行配方，以利于积分。挑出仅涉及 $\mathbf{x}_b$ 的项，我们得到

$$-\frac{1}{2}\mathbf{x}_b^T \Lambda_{bb} \mathbf{x}_b + \mathbf{x}_b^T \mathbf{m} = -\frac{1}{2}(\mathbf{x}_b - \Lambda_{bb}^{-1} \mathbf{m})^T \Lambda_{bb} (\mathbf{x}_b - \Lambda_{bb}^{-1} \mathbf{m}) + \frac{1}{2} \mathbf{m}^T \Lambda_{bb}^{-1} \mathbf{m} \quad (2.84)$$

其中我们定义了

$$\mathbf{m} = \Lambda_{bb} \boldsymbol{\mu}_b - \Lambda_{ba} (\mathbf{x}_a - \boldsymbol{\mu}_a) \quad (2.85)$$

我们看到，对 $\mathbf{x}_b$ 的依赖性已被转化为高斯分布的标准二次型形式（对应于 (2.84) 式右侧的第一项），再加上一个不依赖于 $\mathbf{x}_b$ 的项（但它确实依赖于 $\mathbf{x}_a$ ）。因此，当我们取这个二次型的指数时，我们看到 (2.83) 所要求的对 $\mathbf{x}_b$ 的积分将采取以下形式：

$$\int \exp \left\{ -\frac{1}{2} (\mathbf{x}_b - \Lambda_{bb}^{-1} \mathbf{m})^T \Lambda_{bb} (\mathbf{x}_b - \Lambda_{bb}^{-1} \mathbf{m}) \right\} d\mathbf{x}_b \quad (2.86)$$

通过注意到这是一个对未归一化高斯函数的积分，可以很容易地执行此积分，因此结果将是归一化系数的倒数。我们从 (2.43) 给出的归一化高斯函数形式可知，该系数与均值无关，仅取决于协方差矩阵的行列式。因此，通过对 $\mathbf{x}_b$ 进行配方，我们可以积分消去 $\mathbf{x}_b$ ，而 (2.84) 式左侧贡献中唯一剩余的且依赖于 $\mathbf{x}_a$ 的项是 (2.84) 式右侧的最后一项，其中 $\mathbf{m}$ 由 (2.85) 给出。将这一项与 (2.70) 式中剩余的依赖于 $\mathbf{x}_a$ 的项结合起来，我们得到

$$\begin{aligned} & \frac{1}{2} [\Lambda_{bb} \boldsymbol{\mu}_b - \Lambda_{ba} (\mathbf{x}_a - \boldsymbol{\mu}_a)]^T \Lambda_{bb}^{-1} [\Lambda_{bb} \boldsymbol{\mu}_b - \Lambda_{ba} (\mathbf{x}_a - \boldsymbol{\mu}_a)] \\ & - \frac{1}{2} \mathbf{x}_a^T \Lambda_{aa} \mathbf{x}_a + \mathbf{x}_a^T (\Lambda_{aa} \boldsymbol{\mu}_a + \Lambda_{ab} \boldsymbol{\mu}_b) + \text{const} \\ & = -\frac{1}{2} \mathbf{x}_a^T (\Lambda_{aa} - \Lambda_{ab} \Lambda_{bb}^{-1} \Lambda_{ba}) \mathbf{x}_a \\ & + \mathbf{x}_a^T (\Lambda_{aa} - \Lambda_{ab} \Lambda_{bb}^{-1} \Lambda_{ba})^{-1} \boldsymbol{\mu}_a + \text{const} \end{aligned} \quad (2.87)$$

其中“const”表示与 $\mathbf{x}_a$ 无关的量。同样，通过与 (2.71) 式比较，我们看到边缘分布 $p(\mathbf{x}_a)$ 的协方差由下式给出

$$\Sigma_a = (\Lambda_{aa} - \Lambda_{ab} \Lambda_{bb}^{-1} \Lambda_{ba})^{-1} \quad (2.88)$$

类似地，均值由下式给出

$$\Sigma_a (\Lambda_{aa} - \Lambda_{ab} \Lambda_{bb}^{-1} \Lambda_{ba}) \boldsymbol{\mu}_a = \boldsymbol{\mu}_a \quad (2.89)$$

其中我们使用了 (2.88) 式。(2.88) 式中的协方差是根据 (2.69) 式给出的分块精度矩阵来表达的。我们可以将其改写成 (2.67) 式给出的协方差矩阵的相应分块形式，就像我们对条件分布所做的那样。这些分块矩阵之间的关系是

$$\begin{pmatrix} \Lambda_{aa} & \Lambda_{ab} \\ \Lambda_{ba} & \Lambda_{bb} \end{pmatrix}^{-1} = \begin{pmatrix} \Sigma_{aa} & \Sigma_{ab} \\ \Sigma_{ba} & \Sigma_{bb} \end{pmatrix} \quad (2.90)$$

利用 (2.76) 式，我们得到

$$(\Lambda_{aa} - \Lambda_{ab} \Lambda_{bb}^{-1} \Lambda_{ba})^{-1} = \Sigma_{aa} \quad (2.91)$$

因此我们得到了一个直观上令人满意的结果，即边缘分布 $p(\mathbf{x}_a)$ 的均值和协方差由下式给出

$$\mathbb{E}[\mathbf{x}_a] = \boldsymbol{\mu}_a \quad (2.92)$$

$$\text{cov}[\mathbf{x}_a] = \boldsymbol{\Sigma}_{aa}. \quad (2.93)$$

我们看到，对于边缘分布，均值和协方差用分块协方差矩阵来表达最为简洁，这与条件分布形成了对比，条件分布的分块精度矩阵产生了更简洁的表达式。

我们对分块高斯分布的边缘分布和条件分布的结果总结如下。

分块高斯分布

给定联合高斯分布 $\mathcal{N}(\mathbf{x} | \boldsymbol{\mu}, \boldsymbol{\Sigma})$ ，其中 $\boldsymbol{\Lambda} \equiv \boldsymbol{\Sigma}^{-1}$ 以及

$$\mathbf{x} = \begin{pmatrix} \mathbf{x}_a \\ \mathbf{x}_b \end{pmatrix}, \quad \boldsymbol{\mu} = \begin{pmatrix} \boldsymbol{\mu}_a \\ \boldsymbol{\mu}_b \end{pmatrix}, \quad (2.94)$$

$$\boldsymbol{\Sigma} = \begin{pmatrix} \boldsymbol{\Sigma}_{aa} & \boldsymbol{\Sigma}_{ab} \\ \boldsymbol{\Sigma}_{ba} & \boldsymbol{\Sigma}_{bb} \end{pmatrix}, \quad \boldsymbol{\Lambda} = \begin{pmatrix} \boldsymbol{\Lambda}_{aa} & \boldsymbol{\Lambda}_{ab} \\ \boldsymbol{\Lambda}_{ba} & \boldsymbol{\Lambda}_{bb} \end{pmatrix}. \quad (2.95)$$

条件分布：

$$p(\mathbf{x}_a | \mathbf{x}_b) = \mathcal{N}(\mathbf{x}_a | \boldsymbol{\mu}_{a|b}, \boldsymbol{\Lambda}_{aa}^{-1}), \quad (2.96)$$

$$\boldsymbol{\mu}_{a|b} = \boldsymbol{\mu}_a - \boldsymbol{\Lambda}_{aa}^{-1} \boldsymbol{\Lambda}_{ab} (\mathbf{x}_b - \boldsymbol{\mu}_b). \quad (2.97)$$

边缘分布：

$$p(\mathbf{x}_a) = \mathcal{N}(\mathbf{x}_a | \boldsymbol{\mu}_a, \boldsymbol{\Sigma}_{aa}). \quad (2.98)$$

我们通过一个涉及两个变量的例子（如图 2.9 所示）来说明多元高斯分布中的条件分布与边缘分布的概念。

2.3.3 高斯变量的贝叶斯定理

在 2.3.1 和 2.3.2 节中，我们考虑了一个高斯分布 $p(\mathbf{x})$ ，将向量 $\mathbf{x}$ 分割为两个子向量 $\mathbf{x} = (\mathbf{x}_a, \mathbf{x}_b)$ ，并求出了条件分布 $p(\mathbf{x}_a | \mathbf{x}_b)$ 和边缘分布 $p(\mathbf{x}_a)$ 的表达式。我们注意到，条件分布 $p(\mathbf{x}_a | \mathbf{x}_b)$ 的均值是 $\mathbf{x}_b$ 的线性函数。这里我们假设已知一个高斯边缘分布 $p(\mathbf{x})$ 和一个高斯条件分布 $p(\mathbf{y} | \mathbf{x})$ ，其中 $p(\mathbf{y} | \mathbf{x})$ 的均值是 $\mathbf{x}$ 的线性函数，且协方差与 $\mathbf{x}$ 无关。这是一个线性高斯模型（Roweis and Ghahramani, 1999）的例子，我们将在 8.1.4 节中更一般地研究它。我们希望求出边缘分布 $p(\mathbf{y})$ 和条件分布 $p(\mathbf{x} | \mathbf{y})$ 。这个问题在后续章节中会频繁出现，因此在这里推导出一般结果会很方便。




图 2.9 左图显示了关于两个变量的高斯分布 $p(x_a, x_b)$ 的等高线；右图显示了边缘分布 $p(x_a)$ （蓝色曲线）以及在 $x_b = 0.7$ 时的条件分布 $p(x_a | x_b)$ （红色曲线）。

我们取边缘分布和条件分布分别为

$$p(\mathbf{x}) = \mathcal{N}(\mathbf{x} | \boldsymbol{\mu}, \boldsymbol{\Lambda}^{-1}) \quad (2.99)$$

$$p(\mathbf{y} | \mathbf{x}) = \mathcal{N}(\mathbf{y} | \mathbf{A}\mathbf{x} + \mathbf{b}, \mathbf{L}^{-1}) \quad (2.100)$$

其中 $\boldsymbol{\mu}$ 、 $\mathbf{A}$ 和 $\mathbf{b}$ 是控制均值的参数， $\boldsymbol{\Lambda}$ 和 $\mathbf{L}$ 是精度矩阵。如果 $\mathbf{x}$ 的维数为 M ， $\mathbf{y}$ 的维数为 D ，则矩阵 $\mathbf{A}$ 的尺寸为 $D \times M$ 。

首先我们求 $\mathbf{x}$ 和 $\mathbf{y}$ 的联合分布表达式。为此，定义

$$\mathbf{z} = \begin{pmatrix} \mathbf{x} \\ \mathbf{y} \end{pmatrix} \quad (2.101)$$

然后考虑联合分布的对数

$$\begin{aligned} \ln p(\mathbf{z}) &= \ln p(\mathbf{x}) + \ln p(\mathbf{y} | \mathbf{x}) \\ &= -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Lambda}(\mathbf{x} - \boldsymbol{\mu}) \\ &\quad - \frac{1}{2}(\mathbf{y} - \mathbf{A}\mathbf{x} - \mathbf{b})^T \mathbf{L}(\mathbf{y} - \mathbf{A}\mathbf{x} - \mathbf{b}) + \text{const} \end{aligned} \quad (2.102)$$

其中“const”表示与 $\mathbf{x}$ 和 $\mathbf{y}$ 无关的项。同之前一样，我们看到这是 $\mathbf{z}$ 分量的二次型，因此 $p(\mathbf{z})$ 是高斯分布。为了求这个高斯分布的精度，我们考察（2.102）中的二次项，可写为

$$\begin{aligned} &-\frac{1}{2}\mathbf{x}^T(\boldsymbol{\Lambda} + \mathbf{A}^T\mathbf{L}\mathbf{A})\mathbf{x} - \frac{1}{2}\mathbf{y}^T\mathbf{L}\mathbf{y} + \frac{1}{2}\mathbf{y}^T\mathbf{L}\mathbf{A}\mathbf{x} + \frac{1}{2}\mathbf{x}^T\mathbf{A}^T\mathbf{L}\mathbf{y} \\ &= -\frac{1}{2}\begin{pmatrix} \mathbf{x} \\ \mathbf{y} \end{pmatrix}^T \begin{pmatrix} \boldsymbol{\Lambda} + \mathbf{A}^T\mathbf{L}\mathbf{A} & -\mathbf{A}^T\mathbf{L} \\ -\mathbf{L}\mathbf{A} & \mathbf{L} \end{pmatrix} \begin{pmatrix} \mathbf{x} \\ \mathbf{y} \end{pmatrix} = -\frac{1}{2}\mathbf{z}^T\mathbf{R}\mathbf{z} \end{aligned} \quad (2.103)$$

因此 $\mathbf{z}$ 上的高斯分布的精度（逆协方差）矩阵为

$$\mathbf{R} = \begin{pmatrix} \boldsymbol{\Lambda} + \mathbf{A}^T\mathbf{L}\mathbf{A} & -\mathbf{A}^T\mathbf{L} \\ -\mathbf{L}\mathbf{A} & \mathbf{L} \end{pmatrix}. \quad (2.104)$$

协方差矩阵通过对精度矩阵求逆得到，利用矩阵求逆公式（2.76）可得

$$\text{cov}[\mathbf{z}] = \mathbf{R}^{-1} = \begin{pmatrix} \Lambda^{-1} & \Lambda^{-1}\mathbf{A}^T \\ \mathbf{A}\Lambda^{-1} & \mathbf{L}^{-1} + \mathbf{A}\Lambda^{-1}\mathbf{A}^T \end{pmatrix}. \quad (2.105)$$

同样，我们可以通过识别（2.102）中的线性项来求 $\mathbf{z}$ 上高斯分布的均值，这些线性项为

$$\mathbf{x}^T \Lambda \boldsymbol{\mu} - \mathbf{x}^T \mathbf{A}^T \mathbf{L} \mathbf{b} + \mathbf{y}^T \mathbf{L} \mathbf{b} = \begin{pmatrix} \mathbf{x} \\ \mathbf{y} \end{pmatrix}^T \begin{pmatrix} \Lambda \boldsymbol{\mu} - \mathbf{A}^T \mathbf{L} \mathbf{b} \\ \mathbf{L} \mathbf{b} \end{pmatrix}. \quad (2.106)$$

利用我们之前通过对多元高斯二次型完成平方得到的结论（2.71），可得 $\mathbf{z}$ 的均值为

$$\mathbb{E}[\mathbf{z}] = \mathbf{R}^{-1} \begin{pmatrix} \Lambda \boldsymbol{\mu} - \mathbf{A}^T \mathbf{L} \mathbf{b} \\ \mathbf{L} \mathbf{b} \end{pmatrix}. \quad (2.107)$$

再利用（2.105），得到

$$\mathbb{E}[\mathbf{z}] = \begin{pmatrix} \boldsymbol{\mu} \\ \mathbf{A}\boldsymbol{\mu} + \mathbf{b} \end{pmatrix}. \quad (2.108)$$

接下来我们求对 $\mathbf{x}$ 积分后得到的边缘分布 $p(\mathbf{y})$ 。回忆一下，当用分块协方差矩阵表示时，高斯随机向量部分分量的边缘分布具有特别简单的形式。具体地，其均值和协方差分别由（2.92）和（2.93）给出。利用（2.105）和（2.108），边缘分布 $p(\mathbf{y})$ 的均值和协方差为

$$\mathbb{E}[\mathbf{y}] = \mathbf{A}\boldsymbol{\mu} + \mathbf{b}, \quad (2.109)$$

$$\text{cov}[\mathbf{y}] = \mathbf{L}^{-1} + \mathbf{A}\Lambda^{-1}\mathbf{A}^T. \quad (2.110)$$

这一结果的一个特例是 $\mathbf{A} = \mathbf{I}$ ，此时它退化为两个高斯分布的卷积。我们看到，卷积的均值等于两个高斯均值之和，卷积的协方差等于两个协方差之和。

最后，我们求条件分布 $p(\mathbf{x} | \mathbf{y})$ 的表达式。回忆条件分布的结果用分块精度矩阵表示最为简便，即（2.73）和（2.75）。将这些结果应用于（2.105）和（2.108），得到条件分布 $p(\mathbf{x} | \mathbf{y})$ 的均值和协方差为

$$\mathbb{E}[\mathbf{x} | \mathbf{y}] = (\Lambda + \mathbf{A}^T \mathbf{L} \mathbf{A})^{-1} \{ \mathbf{A}^T \mathbf{L} (\mathbf{y} - \mathbf{b}) + \Lambda \boldsymbol{\mu} \}, \quad (2.111)$$

$$\text{cov}[\mathbf{x} | \mathbf{y}] = (\Lambda + \mathbf{A}^T \mathbf{L} \mathbf{A})^{-1}. \quad (2.112)$$

对该条件分布的求解可以视为贝叶斯定理的一个例子。我们可以将分布 $p(\mathbf{x})$ 解释为 $\mathbf{x}$ 上的先验分布。若变量 $\mathbf{y}$ 被观测到，则条件分布 $p(\mathbf{x} | \mathbf{y})$ 即为 $\mathbf{x}$ 上的相应后验分布。在求得边缘分布和条件分布后，我们实际上已将联合分布 $p(\mathbf{z}) = p(\mathbf{x})p(\mathbf{y} | \mathbf{x})$ 表示成了 $p(\mathbf{x} | \mathbf{y})p(\mathbf{y})$ 的形式。这些结果总结如下。

边缘与条件高斯分布

给定 $\mathbf{x}$ 的边缘高斯分布以及 $\mathbf{y}$ 在给定 $\mathbf{x}$ 下的条件高斯分布如下

$$p(\mathbf{x}) = \mathcal{N}(\mathbf{x} | \boldsymbol{\mu}, \boldsymbol{\Lambda}^{-1}) \quad (2.113)$$

$$p(\mathbf{y} | \mathbf{x}) = \mathcal{N}(\mathbf{y} | \mathbf{A}\mathbf{x} + \mathbf{b}, \mathbf{L}^{-1}) \quad (2.114)$$

则 $\mathbf{y}$ 的边缘分布以及给定 $\mathbf{y}$ 时 $\mathbf{x}$ 的条件分布分别为

$$p(\mathbf{y}) = \mathcal{N}(\mathbf{y} | \mathbf{A}\boldsymbol{\mu} + \mathbf{b}, \mathbf{L}^{-1} + \mathbf{A}\boldsymbol{\Lambda}^{-1}\mathbf{A}^T) \quad (2.115)$$

$$p(\mathbf{x} | \mathbf{y}) = \mathcal{N}(\mathbf{x} | \boldsymbol{\Sigma} \{ \mathbf{A}^T \mathbf{L}(\mathbf{y} - \mathbf{b}) + \boldsymbol{\Lambda} \boldsymbol{\mu} \}, \boldsymbol{\Sigma}) \quad (2.116)$$

其中

$$\boldsymbol{\Sigma} = (\boldsymbol{\Lambda} + \mathbf{A}^T \mathbf{L} \mathbf{A})^{-1} \quad (2.117)$$

2.3.4 高斯分布的最大似然估计

给定数据集 $\mathbf{X} = (\mathbf{x}_1, \dots, \mathbf{x}_N)^T$ ，其中观测值 $\{\mathbf{x}_n\}$ 被假定独立地从多元高斯分布中抽取，我们可以通过最大似然估计分布的参数。对数似然函数为

$$\ln p(\mathbf{X} | \boldsymbol{\mu}, \boldsymbol{\Sigma}) = -\frac{ND}{2} \ln(2\pi) - \frac{N}{2} \ln |\boldsymbol{\Sigma}| - \frac{1}{2} \sum_{n=1}^N (\mathbf{x}_n - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x}_n - \boldsymbol{\mu}). \quad (2.118)$$

通过简单重排可见，似然函数仅通过以下两个量依赖于数据集

$$\sum_{n=1}^N \mathbf{x}_n, \quad \sum_{n=1}^N \mathbf{x}_n \mathbf{x}_n^T. \quad (2.119)$$

这两个量被称为高斯分布的充分统计量。利用 (C.19)，对数似然关于 $\boldsymbol{\mu}$ 的导数为

$$\frac{\partial}{\partial \boldsymbol{\mu}} \ln p(\mathbf{X} | \boldsymbol{\mu}, \boldsymbol{\Sigma}) = \sum_{n=1}^N \boldsymbol{\Sigma}^{-1} (\mathbf{x}_n - \boldsymbol{\mu}), \quad (2.120)$$

将该导数设为零，得到均值的最大似然估计解为

$$\boldsymbol{\mu}_{\text{ML}} = \frac{1}{N} \sum_{n=1}^N \mathbf{x}_n \quad (2.121)$$

这是观测数据点的均值。对 (2.118) 关于 $\boldsymbol{\Sigma}$ 的最大化要复杂得多。最简单的方法是暂时忽略对称性约束，先求解，然后证明结果自然是对称的。关于显式施加对称性和正定约束的其他推导，可参见 Magnus and Neudecker (1999)。结果符合预期，形式为

$$\boldsymbol{\Sigma}_{\text{ML}} = \frac{1}{N} \sum_{n=1}^N (\mathbf{x}_n - \boldsymbol{\mu}_{\text{ML}}) (\mathbf{x}_n - \boldsymbol{\mu}_{\text{ML}})^T, \quad (2.122)$$

这里使用了 $\boldsymbol{\mu}_{\text{ML}}$ ，是因为这是对 $\boldsymbol{\mu}$ 和 $\boldsymbol{\Sigma}$ 的联合最大化。注意， $\boldsymbol{\mu}_{\text{ML}}$ 的解 (2.121) 不依赖于 $\boldsymbol{\Sigma}_{\text{ML}}$ ，因此我们可以先计算 $\boldsymbol{\mu}_{\text{ML}}$ ，再用它计算 $\boldsymbol{\Sigma}_{\text{ML}}$ 。

如果我们在真实分布下对最大似然解取期望，得到

$$\mathbb{E}[\boldsymbol{\mu}_{\text{ML}}] = \boldsymbol{\mu}, \quad (2.123)$$

$$\mathbb{E}[\boldsymbol{\Sigma}_{\text{ML}}] = \frac{N-1}{N} \boldsymbol{\Sigma}. \quad (2.124)$$

可见，均值的最大似然估计的期望等于真实均值。然而，协方差的最大似然估计的期望小于真实值，因此是有偏的。我们可以通过定义一个不同的估计量来消除这种偏倚

$$\tilde{\boldsymbol{\Sigma}} = \frac{1}{N-1} \sum_{n=1}^N (\mathbf{x}_n - \boldsymbol{\mu}_{\text{ML}})(\mathbf{x}_n - \boldsymbol{\mu}_{\text{ML}})^T. \quad (2.125)$$

显然，由 (2.122) 和 (2.124) 可知， $\tilde{\boldsymbol{\Sigma}}$ 的期望等于 $\boldsymbol{\Sigma}$ 。

2.3.5 顺序估计

我们对高斯分布参数最大似然解的讨论，为我们提供了一个绝佳的机会，来更一般地讨论最大似然问题的顺序估计课题。顺序方法允许每次只处理一个数据点，处理完后即可丢弃，这在以下两种情形中尤为重要：在线应用，以及数据量巨大、一次性批量处理所有数据点不可行的情况。

考虑均值的最大似然估计式 (2.121)，当基于 N 个观测时我们记作 $\boldsymbol{\mu}_{\text{ML}}^{(N)}$ 。如果把最后一个数据点 $\mathbf{x}_N$ 的贡献单独拆出来，可得


$$\begin{aligned} \boldsymbol{\mu}_{\text{ML}}^{(N)} &= \frac{1}{N} \sum_{n=1}^N \mathbf{x}_n \\ &= \frac{1}{N} \mathbf{x}_N + \frac{1}{N} \sum_{n=1}^{N-1} \mathbf{x}_n \\ &= \frac{1}{N} \mathbf{x}_N + \frac{N-1}{N} \boldsymbol{\mu}_{\text{ML}}^{(N-1)} \\ &= \boldsymbol{\mu}_{\text{ML}}^{(N-1)} + \frac{1}{N} (\mathbf{x}_N - \boldsymbol{\mu}_{\text{ML}}^{(N-1)}). \end{aligned} \quad (2.126)$$

这个结果有一个很直观的解释：观测了 $N-1$ 个数据点后，我们已用 $\boldsymbol{\mu}_{\text{ML}}^{(N-1)}$ 估计了 $\boldsymbol{\mu}$ 。现在又观测到新数据点 $\mathbf{x}_N$ ，我们就把旧估计值沿着“误差信号” $(\mathbf{x}_N - \boldsymbol{\mu}_{\text{ML}}^{(N-1)})$ 的方向移动一小步（步长为 $1/N$ ），得到新的估计 $\boldsymbol{\mu}_{\text{ML}}^{(N)}$ 。注意，随着 N 增大，后续每个数据点的贡献越来越小。

式 (2.126) 显然与批量方法 (2.121) 给出完全相同的结果，因为两者等价。然而，并非所有问题都能通过这种方式直接导出顺序算法，因此我们需要一种更通用的顺序学习框架，这就引出了 **Robbins-Monro (RM)** 算法。考虑一对随机变量 θ 和 z ，其联合分布为 $p(z, \theta)$ 。给定 θ 时 z 的条件期望定义了一个确定性函数 $f(\theta)$ ：

$$f(\theta) \equiv \mathbb{E}[z | \theta] = \int z p(z | \theta) \mathrm{d}z, \quad (2.127)$$

图 2.10 两个相关随机变量 z 和 θ 的示意图，同时给出了回归函数 $f(\theta)$ ，该函数由条件期望 $E[z | \theta]$ 定义。Robbins-Monro 算法提供了一种通用的序列化方法，用于求解此类函数的根 θ^* 。



如图 2.10 所示。这样定义的函数称为回归函数。

我们的目标是寻找根 θ^* ，使得 $f(\theta^*) = 0$ 。如果拥有大量 z 和 θ 的观测数据，我们可以直接对回归函数建模，再求其根。然而，实际中我们往往是逐个观测到 z 的值，希望找到对应的顺序估计方案来逼近 θ^* 。Robbins 和 Monro (1951) 给出了求解这类问题的通用顺序算法。我们假定 z 的条件方差有限，即

$$\mathbb{E}[(z - f)^2 | \theta] < \infty, \quad (2.128)$$

并且不失一般性地考虑图 2.10 所示的情形：当 $\theta > \theta^*$ 时 $f(\theta) > 0$ ，当 $\theta < \theta^*$ 时 $f(\theta) < 0$ 。Robbins-Monro 算法定义根 θ^* 的逐次估计序列为

$$\theta^{(N)} = \theta^{(N-1)} + a_{N-1} z(\theta^{(N-1)}), \quad (2.129)$$

其中 $z(\theta^{(N)})$ 是 θ 取值为 $\theta^{(N)}$ 时 z 的一个观测值。系数序列 $\{a_N\}$ 为正数，且满足

$$\lim_{N \rightarrow \infty} a_N = 0, \quad (2.130)$$

$$\sum_{N=1}^{\infty} a_N = \infty, \quad (2.131)$$

$$\sum_{N=1}^{\infty} a_N^2 < \infty. \quad (2.132)$$

可以证明 (Robbins and Monro, 1951; Fukunaga, 1990)，由 (2.129) 给出的估计序列几乎必然收敛到根 θ^* 。其中，条件 (2.130) 保证逐次修正幅度逐渐减小，使算法能够收敛到极限值；条件 (2.131) 保证算法不会在到达根之前停滞；条件 (2.132) 保证累积噪声具有有限方差，从而不破坏收敛性。

现在来看如何用 Robbins-Monro 算法顺序求解一般的最大似然问题。按定义，最大似然解 θ_{ML} 是对数似然函数的驻点，因此满足

$$\left. \frac{\partial}{\partial \theta} \left\{ \frac{1}{N} \sum_{n=1}^N \ln p(\mathbf{x}_n | \theta) \right\} \right|_{\theta_{ML}} = 0. \quad (2.133)$$

交换求导与求和顺序并取极限 $N \rightarrow \infty$ ，得到

$$\lim_{N \rightarrow \infty} \frac{1}{N} \sum_{n=1}^N \frac{\partial}{\partial \theta} \ln p(x_n | \theta) = \mathbb{E}_x \left[\frac{\partial}{\partial \theta} \ln p(x | \theta) \right], \quad (2.134)$$

可见求最大似然解等价于求一个回归函数的根。因此我们可以直接应用 Robbins-Monro 算法，此时更新公式为


$$\theta^{(N)} = \theta^{(N-1)} + a_{N-1} \frac{\partial}{\partial \theta^{(N-1)}} \ln p(x_N | \theta^{(N-1)}). \quad (2.135)$$

作为一个具体例子，我们再次考虑高斯分布均值的顺序估计。此时参数 $\theta^{(N)}$ 即为高斯均值的估计 $\mu_{\text{ML}}^{(N)}$ ，随机变量 z 为

$$z = \frac{\partial}{\partial \mu_{\text{ML}}} \ln p(x | \mu_{\text{ML}}, \sigma^2) = \frac{1}{\sigma^2} (x - \mu_{\text{ML}}). \quad (2.136)$$

因此 z 的分布是以 $\mu - \mu_{\text{ML}}$ 为均值的高斯分布，如图 2.11 所示。将 (2.136) 代入 (2.135)，只要选择系数为 $a_N = \sigma^2/N$ ，即可得到 (2.126) 的单变量形式。需要指出，虽然我们讨论的是单变量情形，但同样的技术连同对系数 a_N 的相同限制 (2.130) - (2.132) 同样适用于多元情形 (Blum, 1965)。

图 2.11 在高斯分布的情形下，令 θ 对应均值 μ ，则图 2.10 中所示的回归函数呈现为一条直线（红色所示）。此时随机变量 z 对应于对数似然函数的导数，表示为 $(x - \mu_{\text{ML}})/\sigma^2$ ，其期望（即定义回归函数的量）为 $(\mu - \mu_{\text{ML}})/\sigma^2$ ，同样是一条直线。该回归函数的根对应最大似然估计量 μ_{ML} 。



2.3.6 高斯分布的贝叶斯推断

最大似然框架为参数 μ 和 Σ 提供了点估计。现在我们通过引入这些参数的先验分布来发展贝叶斯处理方法。先从一个简单例子开始：考虑单个高斯随机变量 x 。假设方差 σ^2 已知，我们的任务是根据 N 个观测 $\mathbf{X} = \{x_1, \dots, x_N\}$ 推断均值 μ 。似然函数（即给定 μ 时观测数据的概率，作为 μ 的函数）为

$$p(\mathbf{X} | \mu) = \prod_{n=1}^N p(x_n | \mu) = \frac{1}{(2\pi\sigma^2)^{N/2}} \exp \left\{ -\frac{1}{2\sigma^2} \sum_{n=1}^N (x_n - \mu)^2 \right\}. \quad (2.137)$$

再次强调，似然函数 $p(\mathbf{X} | \mu)$ 并不是关于 μ 的概率分布，也不归一化。

我们看到，似然函数具有指数形式的二次型。因此，如果选择高斯先验 $p(\mu)$ ，它将是该似然函数的共轭先验，因为相应的后验分布将是两个关于 μ 的二次函数指数的乘积，因而也是高斯分布。于是我们取先验分布为

$$p(\mu) = \mathcal{N}(\mu | \mu_0, \sigma_0^2), \quad (2.138)$$

后验分布为

$$p(\mu | \mathbf{X}) \propto p(\mathbf{X} | \mu)p(\mu). \quad (2.139)$$

通过在指数中完成平方，简单推导可得后验分布为

$$p(\mu | \mathbf{X}) = \mathcal{N}(\mu | \mu_N, \sigma_N^2), \quad (2.140)$$

其中

$$\mu_N = \frac{\sigma^2}{N\sigma_0^2 + \sigma^2}\mu_0 + \frac{N\sigma_0^2}{N\sigma_0^2 + \sigma^2}\mu_{\text{ML}}, \quad (2.141)$$

$$\frac{1}{\sigma_N^2} = \frac{1}{\sigma_0^2} + \frac{N}{\sigma^2}, \quad (2.142)$$

这里 μ_{ML} 是样本均值给出的最大似然解

$$\mu_{\text{ML}} = \frac{1}{N} \sum_{n=1}^N x_n. \quad (2.143)$$


值得花一点时间研究后验均值和方差的形式。首先，后验均值（2.141）是先验均值 μ_0 与最大似然解 μ_{ML} 的折中。如果观测数据点数 $N = 0$ ，则（2.141）退化为先验均值，这符合预期。当 $N \rightarrow \infty$ 时，后验均值变为最大似然解。

同样，考察后验方差的表达式（2.142）。我们发现用倒数方差（即精度）表示最为自然。而且精度是可加的：后验精度等于先验精度加上每个观测数据贡献的数据精度。随着观测数据点增多，精度持续增加，对应的后验分布方差持续减小。没有观测数据时，只有先验方差；当 $N \rightarrow \infty$ 时，方差 $\sigma_N^2 \rightarrow 0$ ，后验分布在最大似然解处变得无限尖锐。因此我们看到，当观测数据无限多时，贝叶斯方法精确恢复了最大似然给出的点估计结果（2.143）。

另外注意，对于有限 N ，如果取极限 $\sigma_0^2 \rightarrow \infty$ （先验方差无穷大，即无信息先验），则后验均值（2.141）退化为最大似然结果，而由（2.142）得后验方差为 $\sigma_N^2 = \sigma^2/N$ 。

我们用图 2.12 来说明对高斯均值的贝叶斯推断分析。将此结果推广到已知协方差、未知均值的 D 维高斯随机变量 $\mathbf{x}$ 是直观的。

图 2.12 高斯分布均值 μ 的贝叶斯推断示意图，其中方差假定已知。图中曲线展示了对 μ 的先验分布（标记为 $N = 0$ 的曲线），该先验本身为高斯分布；同时还展示了随着数据点数量 N 增加，由式（2.140）给出的后验分布。数据点来自均值为 0.8、方差为 0.1 的高斯分布，先验均值取为 0。在先验和似然函数中，方差均设为真实值。



我们已经看到，高斯均值的最大似然表达式可以重写为顺序更新公式，其中观测 N 个数据点后的均值用观测 $N - 1$ 个数据点后的均值加上第 N 个数据点 $\mathbf{x}_N$ 的贡献表示。事实上，贝叶斯范式天然导致对推断问题的顺序视角。在高斯均值推断的背景下，我们把最后一个数据点 $\mathbf{x}_N$ 的贡献分离出来，写出后验分布

$$p(\boldsymbol{\mu} | \mathbf{X}) \propto \left[p(\boldsymbol{\mu}) \prod_{n=1}^{N-1} p(\mathbf{x}_n | \boldsymbol{\mu}) \right] p(\mathbf{x}_N | \boldsymbol{\mu}). \quad (2.144)$$

方括号中的项（除归一化常数外）正是观测 $N - 1$ 个数据点后的后验分布。我们看到，它可以被视为先验分布，通过贝叶斯定理与数据点 $\mathbf{x}_N$ 的似然函数结合，得到观测 N 个数据点后的后验分布。这种贝叶斯推断的顺序视角非常普适，适用于所有观测数据被假设为独立同分布的情形。

到目前为止，我们一直假设数据的高斯分布方差已知，目标是推断均值。现在假设均值已知，我们希望推断方差。同样，如果选择共轭先验形式，计算将大大简化。最方便的是对精度 $\lambda \equiv 1/\sigma^2$ 进行操作。精度 λ 的似然函数形式为

$$p(\mathbf{X} | \lambda) = \prod_{n=1}^N \mathcal{N}(x_n | \mu, \lambda^{-1}) \propto \lambda^{N/2} \exp \left\{ -\frac{\lambda}{2} \sum_{n=1}^N (x_n - \mu)^2 \right\}. \quad (2.145)$$

因此，共轭先验应与 λ 的幂次乘积以及 λ 的线性函数指数成正比。这对应于伽马分布 (gamma distribution)，其定义为

$$\text{Gam}(\lambda | a, b) = \frac{1}{\Gamma(a)} b^a \lambda^{a-1} \exp(-b\lambda). \quad (2.146)$$

这里 $\Gamma(a)$ 是伽马函数，由 (1.141) 定义，它保证 (2.146) 被正确归一化。当 $a > 0$ 时伽马分布积分有限，当 $a \geq 1$ 时分布本身有限。图 2.13 画出了不同 a 和 b 取值下的伽马分布。伽马分布的均值和方差为

$$\mathbb{E}[\lambda] = \frac{a}{b}, \quad (2.147)$$

$$\text{var}[\lambda] = \frac{a}{b^2}. \quad (2.148)$$




图 2.13 根据式 (2.146) 定义的伽马分布 $\text{Gam}(\lambda | a, b)$ 在不同参数 a 和 b 取值下的绘图。

考虑先验分布 $\text{Gam}(\lambda | a_0, b_0)$ 。将其与似然函数 (2.145) 相乘，得到后验分布

$$p(\lambda | \mathbf{X}) \propto \lambda^{a_0-1} \lambda^{N/2} \exp \left\{ -b_0 \lambda - \frac{\lambda}{2} \sum_{n=1}^N (x_n - \mu)^2 \right\}, \quad (2.149)$$

这显然是形如 $\text{Gam}(\lambda \mid a_N, b_N)$ 的伽马分布，其中

$$a_N = a_0 + \frac{N}{2}, \quad (2.150)$$

$$b_N = b_0 + \frac{1}{2} \sum_{n=1}^N (x_n - \mu)^2 = b_0 + \frac{N}{2} \sigma_{\text{ML}}^2, \quad (2.151)$$

这里 σ_{ML}^2 是方差的最大似然估计量。注意，在 (2.149) 中无需跟踪先验和似然函数中的归一化常数，因为必要时可最后利用伽马分布的归一化形式 (2.146) 补上正确的系数。

从 (2.150) 可见，观测 N 个数据点使参数 a 增加了 $N/2$ 。因此我们可以将先验中的 a_0 解释为对应于 $2a_0$ 个“有效”先验观测。类似地，由 (2.151) 可见， N 个数据点向参数 b 贡献了 $N\sigma_{\text{ML}}^2/2$ ，其中 σ_{ML}^2 是方差，因此先验中的 b_0 可解释为来自这 $2a_0$ 个“有效”先验观测，其方差为 $2b_0/(2a_0) = b_0/a_0$ 。回想我们在 Dirichlet 先验中也做过类似的解释。这些分布都属于指数族，我们将看到，对指数族分布而言，将共轭先验解释为有效虚构数据点是一种通用的做法。

我们也可以直接对方差本身操作，此时共轭先验称为逆伽马分布，但我们不再进一步讨论，因为对精度操作更方便。

现在假设均值和精度均未知。为找到共轭先验，我们考察似然函数对 μ 和 λ 的依赖关系

$$\begin{aligned} p(\mathbf{X} \mid \mu, \lambda) &= \prod_{n=1}^N \left(\frac{\lambda}{2\pi} \right)^{1/2} \exp \left\{ -\frac{\lambda}{2} (x_n - \mu)^2 \right\} \\ &\propto \left[\lambda^{1/2} \exp \left(-\frac{\lambda \mu^2}{2} \right) \right]^N \exp \left\{ \lambda \mu \sum_{n=1}^N x_n - \frac{\lambda}{2} \sum_{n=1}^N x_n^2 \right\}. \end{aligned} \quad (2.152)$$

我们希望找到一个先验 $p(\mu, \lambda)$ ，其对 μ 和 λ 的函数依赖形式与似然相同，因此应具有形式

$$\begin{aligned} p(\mu, \lambda) &\propto \left[\lambda^{1/2} \exp \left(-\frac{\lambda \mu^2}{2} \right) \right]^\beta \exp \{ c\lambda\mu - d\lambda \} \\ &= \exp \left\{ -\frac{\beta\lambda}{2} \left(\mu - \frac{c}{\beta} \right)^2 \right\} \lambda^{\beta/2} \exp \left\{ -\left(d - \frac{c^2}{2\beta} \right) \lambda \right\}, \end{aligned} \quad (2.153)$$


其中 c 、 d 和 β 为常数。由于总可写成 $p(\mu, \lambda) = p(\mu \mid \lambda)p(\lambda)$ ，我们可直接看出： $p(\mu \mid \lambda)$ 是精度与 λ 成正比的高斯分布， $p(\lambda)$ 是伽马分布，因此归一化的先验为

$$p(\mu, \lambda) = \mathcal{N}(\mu \mid \mu_0, (\beta\lambda)^{-1}) \text{Gam}(\lambda \mid a, b), \quad (2.154)$$

其中新常数定义为 $\mu_0 = c/\beta$ ， $a = 1 + \beta/2$ ， $b = d - c^2/(2\beta)$ 。分布 (2.154) 称为正态-伽马分布 (normal-gamma) 或高斯-伽马分布，如图 2.14 所示。注意这不是 μ 的高斯先验与 λ 的伽马先验的独立乘积，因为 μ 的精度与 λ 成正比。即使我们选择 μ 和 λ 独立的先验，后验分布中 μ 的精度与 λ 的取值仍会耦合。

对于 D 维变量 $\mathbf{x}$ 的多元高斯分布 $\mathcal{N}(\mathbf{x} \mid \boldsymbol{\mu}, \boldsymbol{\Lambda}^{-1})$ ，当精度矩阵 $\boldsymbol{\Lambda}$ 已知时，均值 $\boldsymbol{\mu}$ 的

图 2.14 对参数取值 $\mu_0 = 0$, $\beta = 2$, $a = 5$, $b = 6$ 的正态-伽马分布 (??) 的等高线图。



共轭先验仍是高斯分布。当均值已知而精度矩阵 Λ 未知时，共轭先验为 *Wishart* 分布：

$$\mathcal{W}(\Lambda | \mathbf{W}, \nu) = B|\Lambda|^{(\nu-D-1)/2} \exp\left(-\frac{1}{2} \text{Tr}(\mathbf{W}^{-1}\Lambda)\right), \quad (2.155)$$

其中 ν 称为自由度 (degrees of freedom)， $\mathbf{W}$ 是 $D \times D$ 的尺度矩阵 (scale matrix)， $\text{Tr}(\cdot)$ 表示矩阵的迹。归一化常数 B 为

$$B(\mathbf{W}, \nu) = |\mathbf{W}|^{-\nu/2} \left(2^{\nu D/2} \pi^{D(D-1)/4} \prod_{i=1}^D \Gamma\left(\frac{\nu+1-i}{2}\right) \right)^{-1}. \quad (2.156)$$

同样，也可以对协方差矩阵本身定义共轭先验，得到逆 *Wishart* 分布，但此处不再详述。当均值 μ 和精度矩阵 Λ 均未知时，仿照单变量情形的推导，共轭先验为

$$p(\mu, \Lambda | \mu_0, \beta, \mathbf{W}, \nu) = \mathcal{N}(\mu | \mu_0, (\beta\Lambda)^{-1}) \mathcal{W}(\Lambda | \mathbf{W}, \nu), \quad (2.157)$$

称为正态-*Wishart* 分布或高斯-*Wishart* 分布。

2.3.7 学生氏分布

我们已经看到，高斯分布精度的共轭先验是伽马分布。若有一个单变量高斯分布 $\mathcal{N}(x | \mu, \tau^{-1})$ ，并对精度 τ 赋予伽马先验 $\text{Gam}(\tau | a, b)$ ，将精度 τ 边缘化（积分消掉）后，得到 x 的边缘分布为


$$\begin{aligned} p(x | \mu, a, b) &= \int_0^\infty \mathcal{N}(x | \mu, \tau^{-1}) \text{Gam}(\tau | a, b) d\tau \\ &= \int_0^\infty \frac{b^a e^{-b\tau} \tau^{a-1}}{\Gamma(a)} \left(\frac{\tau}{2\pi}\right)^{1/2} \exp\left\{-\frac{\tau}{2}(x-\mu)^2\right\} d\tau \\ &= \frac{b^a}{\Gamma(a)} \left(\frac{1}{2\pi}\right)^{1/2} \left[b + \frac{(x-\mu)^2}{2}\right]^{-a-1/2} \Gamma\left(a + \frac{1}{2}\right) \end{aligned} \quad (2.158)$$

其中我们做了变量替换 $z = \tau \left[b + \frac{(x-\mu)^2}{2}\right]$ 。按惯例引入新参数 $\nu = 2a$ 和 $\lambda = a/b$ ，于是 $p(x | \mu, a, b)$ 变为

$$\text{St}(x | \mu, \lambda, \nu) = \frac{\Gamma(\nu/2 + 1/2)}{\Gamma(\nu/2)} \left(\frac{\lambda}{\pi\nu}\right)^{1/2} \left[1 + \frac{\lambda(x-\mu)^2}{\nu}\right]^{-\nu/2-1/2} \quad (2.159)$$

这就是 Student's t 分布。参数 λ 有时被称为 t 分布的“精度”，尽管它通常并不等于方差的倒数。参数 ν 称为自由度，其影响见图 2.15。当 $\nu = 1$ 时，t 分布退化为 Cauchy 分布；当 $\nu \rightarrow \infty$ 时， $\text{St}(x | \mu, \lambda, \nu) \rightarrow \mathcal{N}(x | \mu, \lambda^{-1})$ ，即均值为 μ 、精度为 λ 的高斯分布。

图 2.15 对不同的 ν 值绘制 Student's t 分布 (2.159), 其中 $\mu = 0$ 且 $\lambda = 1$ 。当 $\nu \rightarrow \infty$ 时, 该分布趋近于均值为 μ 、精度为 λ 的高斯分布。



从 (2.158) 可见, Student's t 分布相当于对无数个均值相同但精度不同的高斯分布求和。这可以看作高斯分布的无限混合 (高斯混合将在 2.3.9 节详细讨论)。结果是一个比高斯分布具有更长“尾部”的分布, 如图 2.15 所示。这种重尾赋予了 t 分布一个重要性质——鲁棒性, 即对少数离群点远不如高斯分布敏感。t 分布的鲁棒性在图 2.16 中与高斯分布的最大似然解进行了对比 (t 分布的最大似然解可用 EM 算法求得)。可见少数离群点对 t 分布的影响远小于高斯分布。实际应用中离群点可能来自: 数据生成过程本身具有重尾; 数据标注错误。鲁棒性在回归问题中同样重要。最小二乘回归 (对应条件高斯分布的最大似然) 不具备鲁棒性。若将回归模型的噪声换成重尾的 t 分布, 则得到更鲁棒的回归模型。




图 2.16 示例说明了与高斯分布相比, Student's t 分布的鲁棒性。(a) 对从高斯分布抽取的 30 个数据点绘制直方图, 并分别给出基于 t 分布 (红色曲线) 和高斯分布 (绿色曲线, 几乎被红色曲线遮住) 的最大似然拟合。由于 t 分布将高斯分布作为特殊情形, 因此其结果与高斯分布几乎相同。(b) 使用同一数据集, 但额外加入三个离群点, 可以看到高斯分布 (绿色曲线) 受离群点影响严重, 而 t 分布 (红色曲线) 则相对不受影响。

回到 (2.158), 若代入参数 $\nu = 2a$ 、 $\lambda = a/b$ 并令 $\eta = \tau b/a$, 则 t 分布可重写为

$$\text{St}(x \mid \mu, \lambda, \nu) = \int_0^\infty \mathcal{N}(x \mid \mu, (\eta\lambda)^{-1}) \text{Gam}\left(\eta \mid \frac{\nu}{2}, \frac{\nu}{2}\right) d\eta \quad (2.160)$$

将其推广到多元情形 $\mathcal{N}(\mathbf{x} | \boldsymbol{\mu}, \boldsymbol{\Lambda})$ ，即得多元 Student's t 分布

$$\text{St}(\mathbf{x} | \boldsymbol{\mu}, \boldsymbol{\Lambda}, \nu) = \int_0^\infty \mathcal{N}(\mathbf{x} | \boldsymbol{\mu}, (\eta \boldsymbol{\Lambda})^{-1}) \text{Gam}\left(\eta | \frac{\nu}{2}, \frac{\nu}{2}\right) d\eta \quad (2.161)$$

采用与单变量情形相同的技巧，对该积分求值可得

$$\text{St}(\mathbf{x} | \boldsymbol{\mu}, \boldsymbol{\Lambda}, \nu) = \frac{\Gamma\left(\frac{D}{2} + \frac{\nu}{2}\right)}{\Gamma\left(\frac{\nu}{2}\right)} \frac{|\boldsymbol{\Lambda}|^{1/2}}{(\pi\nu)^{D/2}} \left[1 + \frac{\Delta^2}{\nu}\right]^{-\frac{D}{2} - \frac{\nu}{2}} \quad (2.162)$$

其中 D 是 $\mathbf{x}$ 的维数， Δ^2 为平方马氏距离，定义为

$$\Delta^2 = (\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Lambda} (\mathbf{x} - \boldsymbol{\mu}). \quad (2.163)$$

这就是多元 Student's t 分布，它具有以下性质

$$\mathbb{E}[\mathbf{x}] = \boldsymbol{\mu} \quad (\text{当 } \nu > 1 \text{ 时存在}) \quad (2.164)$$

$$\text{cov}[\mathbf{x}] = \frac{\nu}{\nu - 2} \boldsymbol{\Lambda}^{-1} \quad (\text{当 } \nu > 2) \quad (2.165)$$

$$\text{mode}[\mathbf{x}] = \boldsymbol{\mu} \quad (2.166)$$

与单变量情况对应的结果类似。

2.3.8 周期变量

虽然高斯分布具有重要的实际意义，既可独立使用，也可作为构建更复杂概率模型的基本模块，但在某些情况下，它们并不适合作为连续变量的密度模型。一个在实际应用中重要的情形就是周期变量。


周期变量的一个例子是在特定地理位置的风向。例如，我们可能在多天测量风向值，并希望用参数分布来总结这些数据。另一个例子是日历时间，我们可能对那些被认为在 24 小时或年度周期内呈现周期性的量进行建模。这类量可以很方便地用角度（极）坐标 $0 \leq \theta < 2\pi$ 表示。

我们可能会倾向于通过选择某个方向作为原点，然后应用常规分布（如高斯分布）来处理周期变量。然而，这种方法会导致结果强烈依赖于原点的任意选择。例如，假设我们有两个观测值 $\theta_1 = 1^\circ$ 和 $\theta_2 = 359^\circ$ ，并使用标准的单变量高斯分布建模。如果选择原点在 0° ，则该数据集的样本均值为 180° ，标准差为 179° ，而如果选择原点在 180° ，则均值为 0° ，标准差为 1° 。显然，我们需要开发一种特殊的方法来处理周期变量。

让我们考虑对一组周期变量观测值 $\mathcal{D} = \{\theta_1, \dots, \theta_N\}$ 求均值的问题。从现在起，我们假设 θ 以弧度为单位。我们已经看到，简单平均 $(\theta_1 + \dots + \theta_N)/N$ 将强烈依赖于坐标选择。为了找到一个不变的均值度量，我们注意到这些观测值可以看作单位圆上的点，因此可以用二维单位向量 $\mathbf{x}_1, \dots, \mathbf{x}_N$ 来描述，其中 $\|\mathbf{x}_n\| = 1$ ($n = 1, \dots, N$)，如图 2.17 所示。我们可以对向量 $\{\mathbf{x}_n\}$ 取平均，得到

$$\bar{\mathbf{x}} = \frac{1}{N} \sum_{n=1}^N \mathbf{x}_n \quad (2.167)$$

图 2.17 将周期变量的取值 θ_n 表示为位于单位圆上的二维向量 $\mathbf{x}_n$ 的示意图, 同时给出了这些向量的平均值 $\bar{\mathbf{x}}$ 。



然后求出这个平均向量的对应角度 $\bar{\theta}$ 。显然, 这种定义将确保均值的位置与角度坐标的原点选择无关。注意, $\bar{\mathbf{x}}$ 通常位于单位圆内部。观测值的笛卡尔坐标为 $\mathbf{x}_n = (\cos \theta_n, \sin \theta_n)$, 我们可以将样本均值的笛卡尔坐标写成 $\bar{\mathbf{x}} = (\bar{r} \cos \bar{\theta}, \bar{r} \sin \bar{\theta})$ 。代入 (2.167) 并分别对 x_1 和 x_2 分量取等, 得到

$$\bar{r} \cos \bar{\theta} = \frac{1}{N} \sum_{n=1}^N \cos \theta_n, \quad \bar{r} \sin \bar{\theta} = \frac{1}{N} \sum_{n=1}^N \sin \theta_n \quad (2.168)$$

取比值, 并利用恒等式 $\tan \theta = \sin \theta / \cos \theta$, 我们可以解出 $\bar{\theta}$, 得到

$$\bar{\theta} = \tan^{-1} \left\{ \frac{\sum_n \sin \theta_n}{\sum_n \cos \theta_n} \right\} \quad (2.169)$$

稍后, 我们将看到这一结果自然地作为适当定义的周期变量分布的最大似然估计量出现。

现在我们考虑高斯分布的周期推广形式——冯·米塞斯。这里我们仅关注单变量分布, 尽管周期分布也可以在任意维度的超球面上定义。有关周期分布的详细讨论, 请参见 Mardia 和 Jupp (2000)。

按照惯例, 我们考虑周期为 2π 的分布 $p(\theta)$ 。任何定义在 θ 上的概率密度 $p(\theta)$ 不仅必须非负且积分为 1, 还必须具有周期性。因此 $p(\theta)$ 必须满足三个条件:

$$p(\theta) \geq 0 \quad (2.170)$$

$$\int_0^{2\pi} p(\theta) d\theta = 1 \quad (2.171)$$

$$p(\theta + 2\pi) = p(\theta) \quad (2.172)$$


由 (2.172) 可知, 对于任意整数 M , 有 $p(\theta + M2\pi) = p(\theta)$ 。

我们可以很容易地得到一个满足这三个性质的类高斯分布, 方法如下。考虑二维变量 $\mathbf{x} = (x_1, x_2)$ 上的高斯分布, 其均值为 $\boldsymbol{\mu} = (\mu_1, \mu_2)$, 协方差矩阵为 $\boldsymbol{\Sigma} = \sigma^2 \mathbf{I}$, 其中 $\mathbf{I}$ 是 2×2 单位矩阵, 于是

$$p(x_1, x_2) = \frac{1}{2\pi\sigma^2} \exp \left\{ -\frac{(x_1 - \mu_1)^2 + (x_2 - \mu_2)^2}{2\sigma^2} \right\} \quad (2.173)$$

常数 $p(\mathbf{x})$ 的等高线是圆，如图 2.18 所示。现在假设我们考虑该分布在固定半径圆上的取值。由于构造方式，这种分布将是周期的，尽管尚未归一化。我们可以通过从笛卡尔坐标 (x_1, x_2) 变换到极坐标 (r, θ) 来确定该分布的形式，即

图 2.18 von Mises 分布可以通过考虑形如 (2.173) 的二维高斯分布推导而来，其密度等高线如蓝色所示，并对位于红色单位圆上的点进行条件化。



$$x_1 = r \cos \theta, \quad x_2 = r \sin \theta \quad (2.174)$$

我们还将均值 μ 映射到极坐标，写作

$$\mu_1 = r_0 \cos \theta_0, \quad \mu_2 = r_0 \sin \theta_0 \quad (2.175)$$

接下来将这些变换代入二维高斯分布 (2.173)，然后在单位圆 $r = 1$ 上条件化，注意我们只关心对 θ 的依赖。聚焦于高斯分布的指数部分，我们有

$$\begin{aligned} & -\frac{1}{2\sigma^2} \{(r \cos \theta - r_0 \cos \theta_0)^2 + (r \sin \theta - r_0 \sin \theta_0)^2\} \\ &= -\frac{1}{2\sigma^2} \{1 + r_0^2 - 2r_0 \cos \theta \cos \theta_0 - 2r_0 \sin \theta \sin \theta_0\} \\ &= \frac{r_0}{\sigma^2} \cos(\theta - \theta_0) + \text{const} \end{aligned} \quad (2.176)$$

其中“const”表示不依赖于 θ 的项，我们利用了以下三角恒等式

$$\cos^2 A + \sin^2 A = 1 \quad (2.177)$$

$$\cos A \cos B + \sin A \sin B = \cos(A - B) \quad (2.178)$$

如果现在定义 $m = r_0/\sigma^2$ ，我们就得到沿单位圆 $r = 1$ 的分布 $p(\theta)$ 的最终表达式

$$p(\theta | \theta_0, m) = \frac{1}{2\pi I_0(m)} \exp\{m \cos(\theta - \theta_0)\} \quad (2.179)$$

这被称为冯·米塞斯分布，或称圆形正态分布。这里参数 θ_0 对应分布的均值，而 m 被称为集中参数，它类似于高斯分布的逆方差（精度）。(2.179) 中的归一化系数用 $I_0(m)$ 表示，这是第一类零阶贝塞尔函数（Abramowitz and Stegun, 1965），定义为

$$I_0(m) = \frac{1}{2\pi} \int_0^{2\pi} \exp\{m \cos \theta\} d\theta \quad (2.180)$$

当 m 很大时，该分布近似成为高斯分布。冯·米塞斯分布如图 2.19 所示，函数 $I_0(m)$ 如图 2.20 所示。




图 2.19 对两组不同参数取值绘制的 von Mises 分布，左图为笛卡尔坐标表示，右图为对应的极坐标表示。

现在考虑冯·米塞斯分布参数 θ_0 和 m 的最大似然估计量。对数似然函数为

$$\ln p(\mathcal{D} | \theta_0, m) = -N \ln(2\pi) - N \ln I_0(m) + m \sum_{n=1}^N \cos(\theta_n - \theta_0) \quad (2.181)$$

将对 θ_0 的导数设为零，得到

$$\sum_{n=1}^N \sin(\theta_n - \theta_0) = 0 \quad (2.182)$$

为了求解 θ_0 ，我们利用三角恒等式

$$\sin(A - B) = \cos B \sin A - \sin B \cos A \quad (2.183)$$

由此得到

$$\theta_0^{\text{ML}} = \tan^{-1} \left\{ \frac{\sum_n \sin \theta_n}{\sum_n \cos \theta_n} \right\} \quad (2.184)$$

这正是我们先前在二维笛卡尔空间中观察均值时得到的 (2.169)。

类似地，对 (2.181) 关于 m 求最大值，并利用 $I'_0(m) = I_1(m)$ (Abramowitz and Stegun,




图 2.20 绘制由式 (2.180) 定义的贝塞尔函数 $I_0(m)$ ，以及由式 (2.186) 定义的函数 $A(m)$ 。

1965), 得到

$$A(m) = \frac{1}{N} \sum_{n=1}^N \cos(\theta_n - \theta_0^{\text{ML}}) \quad (2.185)$$

其中已代入 θ_0^{ML} 的最大似然解 (记住我们是对 θ_0 和 m 进行联合优化), 并定义

$$A(m) = \frac{I_1(m)}{I_0(m)} \quad (2.186)$$

函数 $A(m)$ 如图 2.20 所示。利用三角恒等式 (2.178), 我们可以将 (2.185) 写成

$$A(m_{\text{ML}}) = \left(\frac{1}{N} \sum_{n=1}^N \cos \theta_n \right) \cos \theta_0^{\text{ML}} - \left(\frac{1}{N} \sum_{n=1}^N \sin \theta_n \right) \sin \theta_0^{\text{ML}} \quad (2.187)$$


(2.187) 的右端很容易计算, 而函数 $A(m)$ 可以数值求反。

为了完整性, 我们简要提及几种构造周期分布的替代方法。最简单的方法是使用观测值的直方图, 将角度坐标划分为固定区间。这种方法简单灵活, 但也存在显著局限性, 我们将在 2.5 节详细讨论直方图方法时看到。另一种方法与冯·米塞斯分布类似, 从欧氏空间上的高斯分布出发, 但现在是对单位圆进行边缘化而非条件化 (Mardia and Jupp, 2000)。然而, 这会导致更复杂的形式, 我们不再进一步讨论。最后, 任何在实轴上的合法分布 (如高斯分布) 都可以通过将宽度为 2π 的连续区间映射到周期变量 $(0, 2\pi)$ 上而转为周期分布, 这相当于将实轴“缠绕”在单位圆上。同样, 所得分布比冯·米塞斯分布更难处理。

冯·米塞斯分布的一个局限性是它是单峰的。通过构造冯·米塞斯分布的混合, 我们得到一个灵活的周期变量建模框架, 能够处理多峰情况。关于使用冯·米塞斯分布的机器学习应用示例, 见 Lawrence et al. (2002); 关于回归问题中条件密度建模的扩展, 见 Bishop 和 Nabney (1996)。

2.3.9 高斯混合


图 2.21 对“老忠实间歇泉”数据的绘图, 其中蓝色曲线表示等概率密度轮廓。左图是使用最大似然拟合得到的单个高斯分布。注意该分布无法捕捉数据中的两个聚集区域, 并且将大部分概率质量放在这两个聚集之间的中间区域, 而该区域的数据相对稀疏。右图为由两个高斯的线性组合构成的分布, 利用第 9 章讨论的方法通过最大似然进行拟合, 能够更好地刻画数据结构。



虽然高斯分布具有重要的解析性质，但在建模真实数据集时存在显著局限性。考虑图 2.21 所示的例子。这就是著名的“老忠实间歇泉”（Old Faithful）数据集，包含美国黄石国家公园老忠实间歇泉的 272 次喷发测量记录。每条记录包括喷发持续时间（分钟，横轴）和下一次喷发间隔时间（分钟，纵轴）。我们看到数据集形成了两个主要簇，单一高斯分布无法捕捉这种结构，而两个高斯的线性叠加则能更好地刻画数据集。

这种通过对更基本分布（如高斯）取线性组合形成的叠加，可以表述为称为混合分布的概率模型（McLachlan and Basford, 1988; McLachlan and Peel, 2000）。在图 2.22 中我们看到，高斯的线性组合可以产生非常复杂的密度。通过使用足够多的高斯，并调整它们的均值、协方差以及线性组合中的系数，几乎任意连续密度都可以以任意精度逼近。

图 2.22 一维高斯混合分布示例，其中三个经过系数缩放的高斯分布以蓝色显示，它们的和以红色显示。



因此，我们考虑 K 个高斯密度的叠加，形式为

$$p(\mathbf{x}) = \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x} | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \quad (2.188)$$

这被称为高斯混合。每一个高斯密度 $\mathcal{N}(\mathbf{x} | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$ 都被称为混合的一个分量，它拥有自己的均值 $\boldsymbol{\mu}_k$ 和协方差 $\boldsymbol{\Sigma}_k$ 。具有 3 个分量的高斯混合的等高线图和表面图如图 2.23 所示。




图 2.23 一维高斯混合分布示例，其中三个经过系数缩放的高斯分布以蓝色显示，它们的和以红色显示。

在本节中，我们以高斯分量为例来说明混合模型的框架。更一般地，混合模型可以由其他分布的线性组合构成。例如，在 9.3.3 节我们将讨论伯努利分布的混合，作为离散变量混合模型的一个例子。

(2.188) 中的参数 π_k 被称为混合系数。如果我们对 (2.188) 两边关于 $\mathbf{x}$ 积分，并注意

到 $p(\mathbf{x})$ 和各个高斯分量都是归一化的，便得到

$$\sum_{k=1}^K \pi_k = 1 \quad (2.189)$$

此外， $p(\mathbf{x}) \geq 0$ 的要求，连同 $\mathcal{N}(\mathbf{x} | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \geq 0$ 意味着 $\pi_k \geq 0$ （对所有 k 成立）。结合条件 (2.189)，我们得到

$$0 \leq \pi_k \leq 1 \quad (2.190)$$

因此我们看到，混合系数满足作为概率的要求。

根据求和法则与乘积法则，边际密度为

$$p(\mathbf{x}) = \sum_{k=1}^K p(k) p(\mathbf{x} | k) \quad (2.191)$$

这等价于 (2.188)，其中我们可以将 $\pi_k = p(k)$ 视为选择第 k 个分量的先验概率，而 $\mathcal{N}(\mathbf{x} | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) = p(\mathbf{x} | k)$ 视为给定 k 时 $\mathbf{x}$ 的条件概率。正如我们在后面章节将看到的，后验概率 $p(k | \mathbf{x})$ （也称为 **responsibilities**）扮演着重要角色。根据贝叶斯定理，它们为

$$\begin{aligned} \gamma_k(\mathbf{x}) &\equiv p(k | \mathbf{x}) \\ &= \frac{p(k) p(\mathbf{x} | k)}{\sum_l p(l) p(\mathbf{x} | l)} \\ &= \frac{\pi_k \mathcal{N}(\mathbf{x} | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_l \pi_l \mathcal{N}(\mathbf{x} | \boldsymbol{\mu}_l, \boldsymbol{\Sigma}_l)} \end{aligned} \quad (2.192)$$

我们将在第 9 章更详细地讨论混合分布的概率解释。

高斯混合分布的形式由参数 $\boldsymbol{\pi}$ 、 $\boldsymbol{\mu}$ 和 $\boldsymbol{\Sigma}$ 决定，这里采用记号 $\boldsymbol{\pi} \equiv \{\pi_1, \dots, \pi_K\}$ 、 $\boldsymbol{\mu} \equiv \{\boldsymbol{\mu}_1, \dots, \boldsymbol{\mu}_K\}$ 以及 $\boldsymbol{\Sigma} \equiv \{\boldsymbol{\Sigma}_1, \dots, \boldsymbol{\Sigma}_K\}$ 。确定这些参数值的一种方法是使用最大似然。从 (2.188) 可得对数似然函数为

$$\ln p(\mathbf{X} | \boldsymbol{\pi}, \boldsymbol{\mu}, \boldsymbol{\Sigma}) = \sum_{n=1}^N \ln \left\{ \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x}_n | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \right\} \quad (2.193)$$

其中 $\mathbf{X} = \{\mathbf{x}_1, \dots, \mathbf{x}_N\}$ 。我们立即看到，由于对数内部出现了对 k 的求和，现在的情况比单一高斯复杂得多。因此，参数的最大似然解不再具有闭合解析形式。最大化似然函数的一种方法是使用迭代数值优化技术（Fletcher, 1987; Nocedal and Wright, 1999; Bishop and Nabney, 2008）。另一种方法是采用一种称为期望最大的强大框架，我们将在第 9 章详细讨论。

2.4 指数家族

本章迄今研究的概率分布（高斯混合除外）都是一个广义分布类——指数家族的具体例子（Duda and Hart, 1973; Bernardo and Smith, 1994）。指数家族的成员具有许多共同的重要性质，用一定的通用性讨论这些性质是很有启发性的。

给定参数 $\boldsymbol{\eta}$ ，关于 $\mathbf{x}$ 的指数家族分布定义为如下形式的分布集合：

$$p(\mathbf{x} | \boldsymbol{\eta}) = h(\mathbf{x}) g(\boldsymbol{\eta}) \exp \{ \boldsymbol{\eta}^T \mathbf{u}(\mathbf{x}) \} \quad (2.194)$$

其中 $\mathbf{x}$ 可以是标量或向量，可以是离散的或连续的。这里的 $\boldsymbol{\eta}$ 被称为分布的自然参数， $\mathbf{u}(\mathbf{x})$ 是 $\mathbf{x}$ 的某个函数。函数 $g(\boldsymbol{\eta})$ 可以解释为确保分布归一化的系数，因此满足

$$g(\boldsymbol{\eta}) \int h(\mathbf{x}) \exp \{ \boldsymbol{\eta}^T \mathbf{u}(\mathbf{x}) \} d\mathbf{x} = 1 \quad (2.195)$$

若 $\mathbf{x}$ 是离散变量，则积分改为求和。

我们先从本章前面介绍的一些分布例子入手，说明它们确实属于指数家族。首先考虑伯努利分布

$$p(x | \mu) = \text{Bern}(x | \mu) = \mu^x (1 - \mu)^{1-x} \quad (2.196)$$

将右端表示为对数的指数形式，得到

$$\begin{aligned} p(x | \mu) &= \exp \{ x \ln \mu + (1 - x) \ln(1 - \mu) \} \\ &= (1 - \mu) \exp \left\{ \ln \left(\frac{\mu}{1 - \mu} \right) x \right\} \end{aligned} \quad (2.197)$$

与 (2.194) 对比，可识别出

$$\eta = \ln \left(\frac{\mu}{1 - \mu} \right) \quad (2.198)$$

我们可以解出 μ 得到 $\mu = \sigma(\eta)$ ，其中

$$\sigma(\eta) = \frac{1}{1 + \exp(-\eta)} \quad (2.199)$$

被称为 logistic sigmoid 函数。于是我们可以用标准形式 (2.194) 将伯努利分布写为

$$p(x | \eta) = \sigma(-\eta) \exp(\eta x) \quad (2.200)$$

这里利用了 $1 - \sigma(\eta) = \sigma(-\eta)$ ，这由 (2.199) 易证。与 (2.194) 对比可得

$$u(x) = x \quad (2.201)$$

$$h(x) = 1 \quad (2.202)$$

$$g(\eta) = \sigma(-\eta) \quad (2.203)$$

接下来考虑多项分布，对于单个观测 $\mathbf{x}$ 它具有形式

$$p(\mathbf{x} | \boldsymbol{\mu}) = \prod_{k=1}^M \mu_k^{x_k} = \exp \left\{ \sum_{k=1}^M x_k \ln \mu_k \right\} \quad (2.204)$$

其中 $\mathbf{x} = (x_1, \dots, x_M)^T$ 。同样，我们可以将它写成标准形式 (2.194)：

$$p(\mathbf{x} | \boldsymbol{\eta}) = \exp(\boldsymbol{\eta}^T \mathbf{x}) \quad (2.205)$$

其中 $\eta_k = \ln \mu_k$ ，并定义 $\boldsymbol{\eta} = (\eta_1, \dots, \eta_M)^T$ 。再与 (2.194) 对比得到

$$\mathbf{u}(\mathbf{x}) = \mathbf{x} \quad (2.206)$$

$$h(\mathbf{x}) = 1 \quad (2.207)$$

$$g(\boldsymbol{\eta}) = 1 \quad (2.208)$$

需要注意的是，参数 η_k 并非相互独立，因为参数 μ_k 受约束

$$\sum_{k=1}^M \mu_k = 1 \quad (2.209)$$

因此，给定任意 $M-1$ 个 μ_k ，剩余一个参数的值就被确定了。在某些情况下，为了消除这一约束，方便地用仅 $M-1$ 个参数表达分布是可取的。这可以通过关系式 (2.209) 将 μ_M 表示为其余 $\{\mu_k\}$ ($k=1, \dots, M-1$) 的函数来实现，从而只剩下 $M-1$ 个参数。注意这些剩余参数仍受约束

$$0 \leq \mu_k \leq 1, \quad \sum_{k=1}^{M-1} \mu_k \leq 1 \quad (2.210)$$

利用约束 (2.209)，多项分布在此表示下变为

$$\begin{aligned} & \exp \left\{ \sum_{k=1}^M x_k \ln \mu_k \right\} \\ &= \exp \left\{ \sum_{k=1}^{M-1} x_k \ln \mu_k + \left(1 - \sum_{k=1}^{M-1} x_k \right) \ln \left(1 - \sum_{k=1}^{M-1} \mu_k \right) \right\} \\ &= \exp \left\{ \sum_{k=1}^{M-1} x_k \ln \left(\frac{\mu_k}{1 - \sum_{j=1}^{M-1} \mu_j} \right) + \ln \left(1 - \sum_{k=1}^{M-1} \mu_k \right) \right\} \end{aligned} \quad (2.211)$$

现在令

$$\ln \left(\frac{\mu_k}{1 - \sum_{j=1}^{M-1} \mu_j} \right) = \eta_k \quad (2.212)$$

对 k 求和后整理并回代，得到

$$\mu_k = \frac{\exp(\eta_k)}{1 + \sum_j \exp(\eta_j)} \quad (2.213)$$

这被称为 softmax 函数，或归一化指数函数。在此表示下，多项分布因此具有形式

$$p(\mathbf{x} | \boldsymbol{\eta}) = \left(1 + \sum_{k=1}^{M-1} \exp(\eta_k) \right)^{-1} \exp(\boldsymbol{\eta}^T \mathbf{x}) \quad (2.214)$$

这是指数家族的标准形式，参数向量为 $\boldsymbol{\eta} = (\eta_1, \dots, \eta_{M-1})^T$ ，其中

$$\mathbf{u}(\mathbf{x}) = \mathbf{x} \quad (2.215)$$

$$h(\mathbf{x}) = 1 \quad (2.216)$$

$$g(\boldsymbol{\eta}) = \left(1 + \sum_{k=1}^{M-1} \exp(\eta_k) \right)^{-1} \quad (2.217)$$

最后，我们考虑高斯分布。对于单变量高斯分布，有

$$p(x | \mu, \sigma^2) = \frac{1}{(2\pi\sigma^2)^{1/2}} \exp \left\{ -\frac{1}{2\sigma^2} (x - \mu)^2 \right\} \quad (2.218)$$

$$= \frac{1}{(2\pi\sigma^2)^{1/2}} \exp \left\{ -\frac{1}{2\sigma^2} x^2 + \frac{\mu}{\sigma^2} x - \frac{1}{2\sigma^2} \mu^2 \right\} \quad (2.219)$$

经过简单整理后, 可将其改写为指数家族标准形式 (2.194), 其中

$$\boldsymbol{\eta} = \begin{pmatrix} \mu/\sigma^2 \\ -1/(2\sigma^2) \end{pmatrix} \quad (2.220)$$

$$\mathbf{u}(x) = \begin{pmatrix} x \\ x^2 \end{pmatrix} \quad (2.221)$$

$$h(x) = (2\pi)^{-1/2} \quad (2.222)$$

$$g(\boldsymbol{\eta}) = (-2\eta_2)^{1/2} \exp\left(\frac{\eta_1^2}{4\eta_2}\right) \quad (2.223)$$

2.4.1 最大似然与充分统计量

现在我们考虑使用最大似然方法估计指数家族分布 (2.194) 中的参数向量 $\boldsymbol{\eta}$ 。对 (2.195) 两边关于 $\boldsymbol{\eta}$ 求梯度, 得到

$$\begin{aligned} & \nabla g(\boldsymbol{\eta}) \int h(\mathbf{x}) \exp\{\boldsymbol{\eta}^T \mathbf{u}(\mathbf{x})\} d\mathbf{x} \\ & + g(\boldsymbol{\eta}) \int h(\mathbf{x}) \exp\{\boldsymbol{\eta}^T \mathbf{u}(\mathbf{x})\} \mathbf{u}(\mathbf{x}) d\mathbf{x} = 0 \end{aligned} \quad (2.224)$$

整理并再次利用 (2.195), 得到

$$-\frac{1}{g(\boldsymbol{\eta})} \nabla g(\boldsymbol{\eta}) = \int h(\mathbf{x}) \exp\{\boldsymbol{\eta}^T \mathbf{u}(\mathbf{x})\} \mathbf{u}(\mathbf{x}) d\mathbf{x} = \mathbb{E}[\mathbf{u}(\mathbf{x})] \quad (2.225)$$

这里用到了 (2.194)。因此得到结果

$$-\nabla \ln g(\boldsymbol{\eta}) = \mathbb{E}[\mathbf{u}(\mathbf{x})] \quad (2.226)$$

需要指出, $\mathbf{u}(\mathbf{x})$ 的协方差可以用 $g(\boldsymbol{\eta})$ 的二阶导数表示, 高阶矩同理。因此, 只要能对指数家族分布进行归一化, 我们总可以通过简单求导得到它的各阶矩。

现在考虑一组独立同分布的数据 $\mathbf{X} = \{\mathbf{x}_1, \dots, \mathbf{x}_N\}$, 其似然函数为

$$p(\mathbf{X} | \boldsymbol{\eta}) = \left(\prod_{n=1}^N h(\mathbf{x}_n) \right) g(\boldsymbol{\eta})^N \exp\left\{ \boldsymbol{\eta}^T \sum_{n=1}^N \mathbf{u}(\mathbf{x}_n) \right\} \quad (2.227)$$

将 $\ln p(\mathbf{X} | \boldsymbol{\eta})$ 关于 $\boldsymbol{\eta}$ 的梯度设为零, 得到最大似然估计 $\boldsymbol{\eta}_{\text{ML}}$ 必须满足的条件

$$-\nabla \ln g(\boldsymbol{\eta}_{\text{ML}}) = \frac{1}{N} \sum_{n=1}^N \mathbf{u}(\mathbf{x}_n) \quad (2.228)$$

原则上可通过求解得到 $\boldsymbol{\eta}_{\text{ML}}$ 。我们看到, 最大似然估计的解仅通过 $\sum_n \mathbf{u}(\mathbf{x}_n)$ 依赖于数据, 因此称其为分布 (2.194) 的充分统计量。我们无需存储整个数据集, 只需保留充分统计量的值即可。例如, 对于伯努利分布, $\mathbf{u}(x) = x$, 因此只需记录数据点 $\{x_n\}$ 的和; 而对于高斯分布, $\mathbf{u}(x) = (x, x^2)^T$, 因此需要保留 $\{x_n\}$ 的和以及 $\{x_n^2\}$ 的和。

如果考虑极限 $N \rightarrow \infty$, 则 (2.228) 右端变为 $\mathbb{E}[\mathbf{u}(\mathbf{x})]$, 与 (2.226) 对比可知, 在此极限下 $\boldsymbol{\eta}_{\text{ML}}$ 将等于真实值 $\boldsymbol{\eta}$ 。

事实上，这种充分性性质在贝叶斯推断中同样成立，不过我们将推迟到第 8 章讨论，那时我们已具备图模型工具，从而能更深入地理解这些重要概念。

2.4.2 共轭先验

我们已多次遇到共轭先验的概念，例如伯努利分布（其共轭先验为 beta 分布）或高斯分布（均值的共轭先验为高斯分布，精度的共轭先验为 Wishart 分布）。一般地，对于给定的概率分布 $p(\mathbf{x} | \boldsymbol{\eta})$ ，我们可以寻找一个与似然函数共轭的先验 $p(\boldsymbol{\eta})$ ，使得后验分布与先验具有相同的函数形式。对于指数家族 (2.194) 的任意成员，都存在可写成如下形式的共轭先验：

$$p(\boldsymbol{\eta} | \boldsymbol{\chi}, \nu) = f(\boldsymbol{\chi}, \nu) g(\boldsymbol{\eta})^\nu \exp \{ \nu \boldsymbol{\eta}^\top \boldsymbol{\chi} \} \quad (2.229)$$

其中 $f(\boldsymbol{\chi}, \nu)$ 为归一化系数， $g(\boldsymbol{\eta})$ 与 (2.194) 中出现的函数相同。为了验证其共轭性，将先验 (2.229) 与似然函数 (2.227) 相乘，得到后验分布（除归一化系数外）形式为

$$p(\boldsymbol{\eta} | \mathbf{X}, \boldsymbol{\chi}, \nu) \propto g(\boldsymbol{\eta})^{\nu+N} \exp \left\{ \boldsymbol{\eta}^\top \left(\sum_{n=1}^N \mathbf{u}(\mathbf{x}_n) + \nu \boldsymbol{\chi} \right) \right\} \quad (2.230)$$

这再次具有与先验 (2.229) 相同的函数形式，证实了共轭性。此外，我们看到参数 ν 可解释为先验中有效伪观测的数量，每个伪观测的充分统计量 $\mathbf{u}(\mathbf{x})$ 值为 $\boldsymbol{\chi}$ 。

2.4.3 无信息先验

在概率推断的某些应用中，我们可能拥有可通过先验分布方便表达的先验知识。例如，若先验对变量的某个值赋予零概率，则无论后续观测到什么数据，后验分布也必然对该值赋予零概率。然而在许多情况下，我们对分布形式几乎一无所知。这时我们会寻找一种称为无信息先验的先验分布，旨在对后验分布的影响尽可能小（Jeffries, 1946; Box and Tiao, 1973; Bernardo and Smith, 1994）。这有时被称为“让数据自己发声”。

如果分布 $p(x | \lambda)$ 由参数 λ 控制，我们可能会倾向于提出先验分布 $p(\lambda) = \text{const}$ 作为合适的先验。如果 λ 是具有 K 个状态的离散变量，这相当于将每个状态的先验概率设为 $1/K$ 。然而对于连续参数，这种做法存在两个潜在困难。

第一个困难是，如果 λ 的定义域无界，这个先验分布就无法正确归一化，因为对 λ 的积分发散。这类先验被称为非正常先验。在实践中，只要相应的后验分布是正常的（即可正确归一化），通常仍可使用非正常先验。例如，若对高斯分布的均值施加均匀先验，只要观测到至少一个数据点，均值的后验分布就是正常的。

第二个困难源于概率密度在非线性变量变换下的变换行为，即 (1.27)。如果函数 $h(\lambda)$ 为常数，而我们换元为 $\lambda = \eta^2$ ，则 $\hat{h}(\eta) = h(\eta^2)$ 也为常数。然而，若我们选择密度 $p_\lambda(\lambda)$ 为常数，则根据 (1.27)， η 的密度为

$$p_\eta(\eta) = p_\lambda(\lambda) \left| \frac{d\lambda}{d\eta} \right| = p_\lambda(\eta^2) \cdot 2\eta \propto \eta \quad (2.231)$$

因此 η 上的密度不再是常数。使用最大似然时不会出现这个问题，因为似然函数 $p(x | \lambda)$ 是 λ 的简单函数，我们可以自由选用任何方便的参数化。然而，如果要选择一个常数先验，就必须谨慎选用参数的适当表示。

这里我们考虑两个无信息先验的简单例子 (Berger, 1985)。首先，如果密度具有形式

$$p(x | \mu) = f(x - \mu) \quad (2.232)$$

则参数 μ 被称为位置参数 (location parameter)。这一密度族具有平移不变性，因为若将 x 平移常数得到 $\hat{x} = x + c$ ，则

$$p(\hat{x} | \hat{\mu}) = f(\hat{x} - \hat{\mu}) \quad (2.233)$$

其中定义了 $\hat{\mu} = \mu + c$ 。于是密度在新变量下具有与原变量相同的形式，因此密度与原点的选择无关。我们希望选择一个能反映这种平移不变性的先验分布，即对区间 $A \leq \mu \leq B$ 赋予与平移后的区间 $A - c \leq \mu \leq B - c$ 相同的概率质量。这意味着

$$\int_A^B p(\mu) d\mu = \int_{A-c}^{B-c} p(\mu) d\mu = \int_A^B p(\mu - c) d\mu \quad (2.234)$$

由于这对任意 A 和 B 都必须成立，故有

$$p(\mu - c) = p(\mu) \quad (2.235)$$

这意味着 $p(\mu)$ 为常数。高斯分布均值 μ 就是一个位置参数的例子。如前所述，此情况下 μ 的共轭先验为高斯分布 $p(\mu | \mu_0, \sigma_0^2) = \mathcal{N}(\mu | \mu_0, \sigma_0^2)$ ，取极限 $\sigma_0^2 \rightarrow \infty$ 即可得到无信息先验。事实上，由 (2.141) 和 (2.142) 可知，这将使后验分布中先验的贡献消失。

第二个例子，考虑形如

$$p(x | \sigma) = \frac{1}{\sigma} f\left(\frac{x}{\sigma}\right) \quad (2.236)$$

的密度，其中 $\sigma > 0$ 。只要 $f(x)$ 正确归一化，这就是一个归一化密度。参数 σ 称为尺度参数，该密度具有尺度不变性，因为若将 x 缩放常数得到 $\hat{x} = cx$ ，则

$$p(\hat{x} | \hat{\sigma}) = \frac{1}{\hat{\sigma}} f\left(\frac{\hat{x}}{\hat{\sigma}}\right) \quad (2.237)$$

其中定义了 $\hat{\sigma} = c\sigma$ 。这种变换对应尺度改变，例如从米变为千米（若 x 是长度），我们希望选择能反映这种尺度不变性的先验分布。若考虑区间 $A \leq \sigma \leq B$ 与缩放后的区间 $A/c \leq \sigma \leq B/c$ ，先验应对这两个区间赋予相等的概率质量。于是

$$\int_A^B p(\sigma) d\sigma = \int_{A/c}^{B/c} p(\sigma) d\sigma = \int_A^B p\left(\frac{\sigma}{c}\right) \frac{1}{c} d\sigma \quad (2.238)$$

由于这对任意 A 和 B 都必须成立，故有

$$p(\sigma) = p\left(\frac{\sigma}{c}\right) \frac{1}{c} \quad (2.239)$$

从而 $p(\sigma) \propto 1/\sigma$ 。这又是一个非正常先验，因为在 $0 \leq \sigma \leq \infty$ 上积分发散。有时用参数对数的密度来考虑尺度参数的先验分布也很方便。利用密度变换规则 (1.27)，得到

$p(\ln \sigma) = \text{const}$ 。因此, 对于该先验, 区间 $1 \leq \sigma \leq 10$ 、 $10 \leq \sigma \leq 100$ 以及 $100 \leq \sigma \leq 1000$ 具有相同的概率质量。

高斯分布的标准差 σ 就是一个尺度参数的例子 (在已考虑位置参数 μ 之后), 因为

$$\mathcal{N}(x | \mu, \sigma^2) \propto \sigma^{-1} \exp \{-(\tilde{x}/\sigma)^2\} \quad (2.240)$$

其中 $\tilde{x} = x - \mu$ 。如前所述, 通常更方便用精度 $\lambda = 1/\sigma^2$ 而非 σ 本身工作。利用密度变换规则, 可见 $p(\sigma) \propto 1/\sigma$ 对应于精度 λ 上的分布 $p(\lambda) \propto 1/\lambda$ 。我们已知 λ 的共轭先验是 gamma 分布 $\text{Gam}(\lambda | a_0, b_0)$, 见 (2.146)。无信息先验对应特例 $a_0 = b_0 = 0$ 。同样, 若考察后验分布 (2.150) 与 (2.151), 当 $a_0 = b_0 = 0$ 时, 后验仅依赖于数据项, 而与先验无关。

2.5 非参数方法

在本章中, 我们一直关注具有特定函数形式、仅由少量参数控制的概率分布, 这些参数的值需从数据集中确定。这被称为密度建模的参数方法。该方法的一个重要局限在于, 所选密度可能无法很好地刻画生成数据的真实分布, 从而导致较差的预测性能。例如, 若生成数据的过程是多峰的, 则高斯分布 (必然单峰) 永远无法捕捉这一特性。

在本节最后部分, 我们将讨论几种非参数密度估计方法, 它们对分布形式几乎不作假设。这里主要聚焦于简单的频数主义方法。但需注意, 非参数贝叶斯方法正日益受到关注 (Walker et al., 1999; Neal, 2000; Müller and Quintana, 2004; Teh et al., 2006)。

我们从直方图密度估计方法开始讨论, 这在我们先前讨论边缘分布与条件分布 (图 1.11) 以及中心极限定理 (图 2.6) 时已遇到。这里将更详细地探讨直方图密度模型的性质, 聚焦于单个连续变量 x 的情形。

标准直方图将 x 简单划分为若干互不重叠的区间, 每个区间宽度为 Δ_i , 然后统计落入第 i 个区间的观测数 n_i 。要将其转化为归一化概率密度, 只需将计数除以总观测数 N 再除以区间宽度 Δ_i , 得到每个区间的概率值为


$$p_i = \frac{n_i}{N\Delta_i} \quad (2.241)$$

易见 $\int p(x) dx = 1$ 。这给出了一个在每个区间内恒定的密度模型 $p(x)$, 通常各区间宽度相等, 即 $\Delta_i = \Delta$ 。

在图 2.24 中, 我们展示了一个直方图密度估计的例子。这里的数据是从对应于绿色曲线的分布中抽取的, 该分布由两个高斯分布的混合构成。图中还展示了三种直方图密度估计的结果, 对应于三种不同的区间宽度 Δ 。我们看到, 当 Δ 非常小时 (最上方的图), 得到的密度模型非常尖锐, 出现了许多生成数据集的底层分布中并不存在的结构。相反, 如果 Δ 过大 (最下方的图), 则得到一个过于平滑的模型, 从而无法捕捉绿色曲线的双峰特性。最佳结果是在某个中间值的 Δ 处获得的 (中间的图)。原则上, 直方图密度模型还依赖于区间边界的选择, 不过这通常远不如 Δ 的值重要。

需要注意的是, 直方图方法具有这样一个性质 (与接下来将要讨论的方法不同): 一旦直方图计算完成, 数据集本身就可以被丢弃, 这在数据集很大时非常有利。此外,

图 2.24 密度估计中直方图方法的示意图，其中 50 个数据点由绿色曲线所示的分布生成。基于式 (2.241) 并采用统一分箱宽度 Δ 的直方图密度估计在不同 Δ 取值下给出。



如果数据点是依次到达的，直方图方法也非常容易应用。

在实践中，直方图技术可以用于在一维或二维中快速可视化数据，但不适合大多数密度估计应用。一个明显的问题是估计得到的密度在区间边界处存在不连续性，而这些不连续性来源于区间的划分，而不是生成数据的底层分布的任何特性。直方图方法的另一个主要局限在于其随维数增加的扩展性。如果我们在 D 维空间中将每个变量划分为 M 个区间，那么总的区间数目将是 M^D 。这种随 D 指数级增长的现象就是维数灾难的一个例子。在高维空间中，要提供有意义的局部概率密度估计所需的数据量将非常庞大。

然而，直方图密度估计方法确实给我们带来了两个重要的经验教训。首先，要估计某个特定位置的概率密度，我们应该考虑落在该点某个局部邻域内的数据点。注意，局部的概念要求我们假设某种距离度量，这里我们一直假设的是欧氏距离。对于直方图，这个邻域性质由区间定义，并且存在一个自然的“平滑”参数来描述局部区域的空间范围，在本例中就是区间宽度。其次，平滑参数的值既不能太大也不能太小，才能得到好的结果。这让人联想到第一章中讨论的多项式曲线拟合中的模型复杂度选择，其中多项式的次数 M ，或者正则化参数 α 的值，在某个既不太大也不太小的中间值时达到最优。带着这些洞察，我们现在转向两种广泛使用的非参数密度估计技术——核估计器和最近邻方法，这两种方法在维数增加时的扩展性都优于简单的直方图模型。

2.5.1 核密度估计器

假设在某个 D 维欧氏空间中，观测样本是从某个未知概率密度 $p(\mathbf{x})$ 中独立抽取的，我们希望估计 $p(\mathbf{x})$ 的值。根据之前的局部性讨论，考虑包含 $\mathbf{x}$ 的某个小区间 $\mathcal{R}$ 。该区域包含的概率质量为

$$P = \int_{\mathcal{R}} p(\mathbf{x}) d\mathbf{x}. \quad (2.242)$$

现在假设我们已经收集了一个包含 N 个样本的数据集，这些样本来自 $p(\mathbf{x})$ 。由于每个数据点落入 $\mathcal{R}$ 的概率为 P ，因此落在 $\mathcal{R}$ 内部的点数 K 服从二项分布

$$\text{Bin}(K | N, P) = \frac{N!}{K!(N-K)!} P^K (1-P)^{N-K} \quad (2.243)$$

根据 (2.11)，落入该区域的点的平均比例为 $\mathbb{E}[K/N] = P$ ；同样根据 (2.12)，该比例围绕均值的方差为 $\text{var}[K/N] = P(1-P)/N$ 。当 N 很大时，该分布将在均值附近急剧

集中, 因此

$$K \simeq NP \quad (2.244)$$

另一方面, 如果我们还假设区域 $\mathcal{R}$ 足够小, 使得概率密度 $p(\mathbf{x})$ 在该区域上近似为常数, 则有

$$P \simeq p(\mathbf{x})V \quad (2.245)$$

其中 V 是 $\mathcal{R}$ 的体积。将 (2.244) 和 (2.245) 合并, 可得到密度估计的形式

$$p(\mathbf{x}) = \frac{K}{NV} \quad (2.246)$$

需要注意的是, (2.246) 的有效性依赖于两个相互矛盾的假设: 一方面区域 $\mathcal{R}$ 要足够小, 以保证密度在区域内近似恒定; 另一方面区域又要足够大 (相对于密度的大小), 以使得落入其中的点数 K 足够多, 从而二项分布能够急剧集中在均值附近。

我们可以以两种不同的方式利用结果 (2.246)。要么固定 K 并从数据中确定 V 的值, 这就产生了即将讨论的 K 近邻技术; 要么固定 V 并从数据中确定 K , 这就产生了核方法。可以证明, 只要 V 随着 N 适当地缩小, 而 K 随着 N 增大, 则 K 近邻密度估计器和核密度估计器在 $N \rightarrow \infty$ 极限下都会收敛到真实的概率密度 (Duda and Hart, 1973)。

我们首先详细讨论核方法, 一开始我们取区域 $\mathcal{R}$ 为以希望确定概率密度的点 $\mathbf{x}$ 为中心的一个小超立方体。为了统计落入该区域内的点数 K , 定义如下函数很方便

$$k(\mathbf{u}) = \begin{cases} 1, & |u_i| \leq 1/2, \quad i = 1, \dots, D \\ 0, & \text{otherwise} \end{cases} \quad (2.247)$$

这个函数表示一个以原点为中心、边长为 1 的单位立方体。函数 $k(\mathbf{u})$ 是一种核函数, 在此背景下也称为 Parzen 窗。根据 (2.247), 若数据点 $\mathbf{x}_n$ 位于以 $\mathbf{x}$ 为中心、边长为 h 的立方体内部, 则 $k((\mathbf{x} - \mathbf{x}_n)/h)$ 取值为 1, 否则为 0。因此, 位于该立方体内部的数据点总数为

$$K = \sum_{n=1}^N k\left(\frac{\mathbf{x} - \mathbf{x}_n}{h}\right). \quad (2.248)$$

将此表达式代入 (2.246), 即可得到点 $\mathbf{x}$ 处的估计密度

$$p(\mathbf{x}) = \frac{1}{N} \sum_{n=1}^N \frac{1}{h^D} k\left(\frac{\mathbf{x} - \mathbf{x}_n}{h}\right) \quad (2.249)$$


其中我们用了 D 维空间中边长为 h 的超立方体的体积 $V = h^D$ 。利用函数 $k(\mathbf{u})$ 的对称性, 我们现在可以将这个方程重新解释为不是以 $\mathbf{x}$ 为中心的一个立方体, 而是对以 N 个数据点 $\mathbf{x}_n$ 为中心的 N 个立方体求和。

就目前的形式而言, 核密度估计器 (2.249) 会遇到与直方图方法相同的缺陷之一, 即在立方体边界处存在人为的不连续性。如果我们选择更平滑的核函数, 就可以得到更平滑的密度模型, 一个常见的选择是高斯核, 从而得到如下核密度模型

$$p(\mathbf{x}) = \frac{1}{N} \sum_{n=1}^N \frac{1}{(2\pi h^2)^{1/2}} \exp\left\{-\frac{\|\mathbf{x} - \mathbf{x}_n\|^2}{2h^2}\right\} \quad (2.250)$$

其中 h 表示高斯分量的标准差。因此，我们的密度模型是通过在每个数据点上放置一个高斯分布，然后对整个数据集的贡献求和，再除以 N 以确保密度正确归一化。在图 2.25 中，我们将模型 (2.250) 应用于之前用来展示直方图技术的数据集。可以看出，正如预期的那样，参数 h 起到了平滑参数的作用：在 h 较小时对噪声过于敏感，而在 h 较大时又会出现过度平滑的现象。因此， h 的优化是一个模型复杂度的权衡问题，类似于直方图密度估计中 bin 宽度的选择，或曲线拟合中多项式阶数的选择。

图 2.25 将核密度模型 (2.250) 应用于与图 2.24 中直方图方法相同的数据集。可以看到， h 起平滑参数作用：若 h 取值过小（上图），得到的密度模型噪声很大；若 h 取值过大（下图），则数据生成的真实分布（绿色曲线所示）本来的双峰结构被抹平。某个中间取值的 h （中图）则给出了最佳密度模型。



我们也可以在 (2.249) 中选择任意其他核函数 $k(\mathbf{u})$ ，只要它满足以下条件：

$$k(\mathbf{u}) \geq 0, \quad (2.251)$$

$$\int k(\mathbf{u}) d\mathbf{u} = 1 \quad (2.252)$$

这些条件保证了得到的概率分布处处非负且积分为 1。由 (2.249) 给出的这一类密度模型被称为核密度估计器（kernel density estimator），或 Parzen 估计器。它有一个很大的优点：在“训练”阶段完全不需要计算，因为这仅仅需要存储训练集。然而，这也是它的一个重大缺陷，因为密度估计的计算代价随着数据集大小线性增长。


2.5.2 最近邻方法

核方法在密度估计中的一个困难在于，控制核宽度的参数 h 对所有核都是固定的。在数据密度高的区域，较大的 h 可能会导致过度平滑，从而抹平原本可以从数据中提取的结构。然而，减小 h 又可能在数据空间中密度较低的其他区域导致噪声估计。因此， h 的最优选择可能依赖于数据空间中的位置。最近邻密度估计方法正是为了解决这一问题而提出的。

我们因此回到局部密度估计的通用结果 (2.246)，不再固定体积 V 并从数据中确定 K 的值，而是固定 K 的值，并利用数据找到合适的 V 。具体做法是：在希望估计密度 $p(\mathbf{x})$ 的点 $\mathbf{x}$ 处放置一个小的球体，让球体的半径逐渐增大，直到正好包含 K 个数据点。此时密度 $p(\mathbf{x})$ 的估计由 (2.246) 给出，其中 V 取为该球体的体积。这种技术被称为 K 最近邻（ K nearest neighbours），如图 2.26 所示，我们对不同的 K 值使用了与图 2.24 和图 2.25 相同的数据集。可以看出， K 的取值现在控制了平滑程度，同样存在一个最优

的 K 值，既不能太大也不能太小。需要注意的是， K 最近邻方法产生的模型并不是真正的概率密度模型，因为其在整个空间上的积分是发散的。

图 2.26 使用与图 2.25 和图 2.24 相同的数据集进行 K 近邻密度估计的示意图。可以看到，参数 K 决定平滑程度： K 较小时（上图），密度模型噪声很大； K 较大时（下图），数据生成的真实分布（绿色曲线所示）的双峰结构被过度平滑。



我们通过展示如何将 K 最近邻密度估计技术扩展到分类问题来结束本章。为此，我们分别对每个类别单独应用 K 最近邻密度估计，然后利用贝叶斯定理。假设我们有一个数据集，其中类别 $\mathcal{C}_k$ 包含 N_k 个点，总共 N 个点，因此 $\sum_k N_k = N$ 。如果我们要对一个新点 $\mathbf{x}$ 进行分类，就以 $\mathbf{x}$ 为中心画一个球体，使其恰好包含 K 个点（不论类别）。假设该球体的体积为 V ，其中来自类别 $\mathcal{C}_k$ 的点有 K_k 个。那么 (2.246) 给出了各个类别的密度估计

$$p(\mathbf{x} | \mathcal{C}_k) = \frac{K_k}{N_k V} \quad (2.253)$$

同样，无条件密度为

$$p(\mathbf{x}) = \frac{K}{NV} \quad (2.254)$$

而类别先验概率为

$$p(\mathcal{C}_k) = \frac{N_k}{N} \quad (2.255)$$

现在我们利用贝叶斯定理合并 (2.253)、(2.254) 和 (2.255)，得到类别后验概率

$$p(\mathcal{C}_k | \mathbf{x}) = \frac{p(\mathbf{x} | \mathcal{C}_k) p(\mathcal{C}_k)}{p(\mathbf{x})} = \frac{K_k}{K} \quad (2.256)$$

如果我们希望最小化误分类概率，只需将测试点 $\mathbf{x}$ 分配给后验概率最大的类别，也就是 K_k/K 最大的那个类别。因此，对一个新点进行分类时，我们从训练集中找出 K 个最近的点，然后将新点分配给这 K 个点中代表数量最多的类别。如果出现平局，可随机打破平局。 $K=1$ 的特殊情况称为最近邻规则，此时测试点直接被分配给训练集中最近点的同一类别。这些概念在图 2.27 中得到了说明。

在图 2.28 中，我们对第 1 章介绍的油流数据应用了 K 最近邻算法，展示了不同 K 值的结果。正如预期， K 控制了平滑程度： K 较小时会产生许多小的类别区域，而 K 较大时则导致更少但更大的区域。

最近邻 ($K=1$) 分类器的一个有趣性质是，当 $N \rightarrow \infty$ 时，其错误率永远不会超过最优分类器（即使用真实类别分布的分类器）最小可达错误率的两倍（Cover and Hart, 1967）。

图 2.27 (a) 在 K 近邻分类器中, 新数据点 (黑色菱形所示) 的类别由其最近的 K 个训练样本中占多数的类别决定, 此处 $K = 3$ 。(b) 在最近邻 ($K = 1$) 分类方法中, 得到的决策边界由一系列超平面组成, 这些超平面是来自不同类别的成对样本之间的垂直平分面。





图 2.28 从油流数据集中抽取的 200 个数据点, 其特征 x_6 与 x_7 的散点图如上所示。其中红色、绿色与蓝色点分别对应“层流 (laminar)”、“环状流 (annular)”和“均匀流 (homogeneous)”三类。图中还展示了 K 近邻算法在不同 K 取值下对输入空间的分类结果。

到目前为止讨论的 K 最近邻方法和核密度估计器都需要存储整个训练数据集, 当数据集很大时会导致计算代价高昂。通过构造基于树的搜索结构, 可以在一次性额外计算的代价下, 高效地找到 (近似的) 最近邻, 而无需对数据集进行穷尽搜索, 从而在一定程度上缓解这一问题。尽管如此, 这些非参数方法仍然受到严重限制。另一方面, 我们已经看到, 简单的参数模型在所能表示的分布形式上非常受限。因此, 我们需要找到非常灵活的密度模型, 同时模型的复杂度能够独立于训练集大小进行控制, 在后续章节中我们将看到如何实现这一点。

3 线性回归模型

本书至今的重点一直是非监督学习，包括密度估计和数据聚类主题。现在我们转向监督学习的讨论，从回归开始。回归的目标是：在给定 D 维输入向量 $\mathbf{x}$ 的值时，预测一个或多个连续目标变量 t 的值。我们在第 1 章讨论多项式曲线拟合时，已经接触过一个回归问题的例子。多变量就是一大类称为线性回归模型的函数中的一个具体例子，这类模型的特点是它们是可调参数的线性函数，本章将以此为重点。最简单的线性回归模型同时也是输入变量的线性函数。然而，通过对一组固定的输入变量非线性函数（称为基函数）取线性组合，我们可以得到一类更加有用的函数。这类模型关于参数是线性的，因而具有简单的解析性质，同时关于输入变量却可以是非线性的。

给定一个包含 N 个观测的训练数据集 $\{\mathbf{x}_n\}$ （其中 $n = 1, \dots, N$ ），以及对应的目标值 $\{t_n\}$ ，我们的目标是预测当输入为新的 $\mathbf{x}$ 时 t 的值。最简单的方法是直接构造一个合适的函数 $y(\mathbf{x})$ ，使其在新输入 x 上的取值构成对相应 t 值的预测。更一般地，从概率的观点来看，我们的目标是建模预测分布 $p(t | \mathbf{x})$ ，因为它表达了对于每一个 $\mathbf{x}$ ，我们对 t 取值的不确定性。利用这个条件分布，我们可以通过最小化适当选择的损失函数的期望值，来对任意新 $\mathbf{x}$ 下的 t 进行预测。正如 1.5.5 节所讨论的，对于实值变量，常用的损失函数是平方损失，其最优解由 t 的条件期望给出。

尽管线性模型作为模式识别的实用技术存在显著局限性，尤其是在高维输入空间问题中，但它们具有良好的解析性质，并且构成了后续章节将要讨论的更复杂模型的基础。

3.1 线性基函数模型

最简单的回归线性模型是对输入变量进行线性组合的形式

$$y(\mathbf{x}, \mathbf{w}) = w_0 + w_1 x_1 + \dots + w_D x_D \quad (3.1)$$

其中 $\mathbf{x} = (x_1, \dots, x_D)^T$ 。这通常被简称为线性回归。该模型的关键性质是它关于参数 $w_0, \dots, w_D$ 是线性的。然而，它同时也关于输入变量 x_i 是线性的，这给模型带来了显著的局限性。因此，我们通过考虑输入变量的固定非线性函数的线性组合来扩展模型类，得到如下形式

$$y(\mathbf{x}, \mathbf{w}) = w_0 + \sum_{j=1}^{M-1} w_j \phi_j(\mathbf{x}) \quad (3.2)$$

其中 $\phi_j(\mathbf{x})$ 被称为基函数。通过令索引 j 的最大值为 $M-1$ ，该模型中的参数总数为 M 。

参数 w_0 用来适应数据中的任何固定偏移，有时被称为偏置参数（不要与统计意义上的“偏差”混淆）。为了方便，通常定义一个额外的哑基函数 $\phi_0(\mathbf{x}) = 1$ ，从而

$$y(\mathbf{x}, \mathbf{w}) = \sum_{j=0}^{M-1} w_j \phi_j(\mathbf{x}) = \mathbf{w}^T \boldsymbol{\phi}(\mathbf{x}) \quad (3.3)$$

其中 $\mathbf{w} = (w_0, \dots, w_{M-1})^T$ ， $\boldsymbol{\phi} = (\phi_0, \dots, \phi_{M-1})^T$ 。在许多模式识别的实际应用中，我们会对原始数据变量施加某种固定的预处理或特征提取。如果原始变量组成向量 $\mathbf{x}$ ，那么

特征就可以用基函数 $\{\phi_j(\mathbf{x})\}$ 来表示。

通过使用非线性基函数，我们允许函数 $y(\mathbf{x}, \mathbf{w})$ 成为输入向量 $\mathbf{x}$ 的非线性函数。然而，形如 (3.2) 的函数仍被称为线性模型，因为该函数关于参数 $\mathbf{w}$ 是线性的。正是这种参数的线性性质极大地简化了这类模型的分析。不过，这也带来了一些重要的局限性，我们将在 3.6 节中讨论。

第 1 章中考虑的多项式回归是这类模型的一个特例，其中只有一个输入变量 x ，基函数采用 x 的幂形式，即 $\phi_j(x) = x^j$ 。多项式基函数的一个局限性在于它们是输入变量的全局函数，因此输入空间某一区域的变化会影响所有其他区域。这一问题可以通过将输入空间划分成多个区域，并在每个区域内拟合不同的多项式来解决，从而得到样条函数 (Hastie et al., 2001)。

基函数还有许多其他选择，例如

$$\phi_j(x) = \exp \left\{ -\frac{(x - \mu_j)^2}{2s^2} \right\} \quad (3.4)$$

其中 μ_j 控制基函数在输入空间中的位置，参数 s 控制其空间尺度。这些通常被称为“高斯”基函数，但需要注意的是，它们并不需要具有概率意义，特别是归一化系数并不重要，因为这些基函数最终会乘以可调参数 w_j 。

另一种可能是采用如下形式的 sigmoid 基函数

$$\phi_j(x) = \sigma \left(\frac{x - \mu_j}{s} \right) \quad (3.5)$$

其中 $\sigma(a)$ 是 logistic sigmoid 函数，定义为

$$\sigma(a) = \frac{1}{1 + \exp(-a)} \quad (3.6)$$

等价地，我们也可以使用 ‘tanh’ 函数，因为它与 logistic sigmoid 的关系为 $\tanh(a) = 2\sigma(a) - 1$ ，因此 logistic sigmoid 函数的一般线性组合等价于 ‘tanh’ 函数的一般线性组合。这些不同的基函数选择在图 3.1 中得到了展示。




图 3.1 基函数示例：左图为多项式基函数，中间为形式如 (3.4) 的高斯基函数，右图为形式如 (3.5) 的 sigmoid 基函数。

另一种可能的基函数选择是傅里叶基，它会导致正弦函数的展开。每个基函数代表一个特定的频率并具有无限的空间范围。相比之下，局限于输入空间有限区域的基函数

必然包含不同空间频率的谱。在许多信号处理应用中，人们感兴趣的是同时在空间和频率上都局部化的基函数，这导致了一类称为小波的函数。这些小波还被定义为相互正交，以简化其应用。小波最适用于输入值位于规则网格上的情况，例如时间序列中的连续时间点或图像中的像素。关于小波的有效参考文献包括 Ogden (1997)、Mallat (1999) 和 Vidakovic (1999)。

本章的大部分讨论并不依赖于基函数集的具体选择，因此在大多数讨论中我们不会指定基函数的具体形式，除非为了数值说明。事实上，我们的许多讨论同样适用于基函数向量 $\phi(\mathbf{x})$ 就是恒等的情形，即 $\phi(\mathbf{x}) = \mathbf{x}$ 。此外，为了保持记号简洁，我们将重点关注单个目标变量 t 的情况。不过，在 3.1.5 节中，我们将简要讨论处理多个目标变量所需的修改。

3.1.1 最大似然与最小二乘

在第 1 章中，我们通过最小化平方和误差函数将多项式函数拟合到数据集。我们还证明了该误差函数可以在假设高斯噪声模型下被解释为最大似然解。现在让我们回到这一讨论，更详细地考察最小二乘方法及其与最大似然的关系。

与之前一样，我们假设目标变量 t 由一个确定性函数 $y(\mathbf{x}, \mathbf{w})$ 加上加性高斯噪声给出，即

$$t = y(\mathbf{x}, \mathbf{w}) + \epsilon \quad (3.7)$$

其中 ϵ 是均值为零、精度（方差的倒数）为 β 的高斯随机变量。因此我们可以写出

$$p(t | \mathbf{x}, \mathbf{w}, \beta) = \mathcal{N}(t | y(\mathbf{x}, \mathbf{w}), \beta^{-1}) \quad (3.8)$$

回忆一下，如果我们采用平方损失函数，那么对于新的 $\mathbf{x}$ ，最优预测将由目标变量的条件均值给出。对于形如 (3.8) 的高斯条件分布，条件均值简化为

$$\mathbb{E}[t | \mathbf{x}] = \int t p(t | \mathbf{x}) dt = y(\mathbf{x}, \mathbf{w}) \quad (3.9)$$

需要注意的是，高斯噪声假设意味着给定 $\mathbf{x}$ 时 t 的条件分布是单峰的，这在某些应用中可能不合适。将条件分布扩展为高斯混合的形式（允许条件分布为多峰）将在 14.5.1 节讨论。

现在考虑输入集合 $\mathbf{X} = \{\mathbf{x}_1, \dots, \mathbf{x}_N\}$ 以及对应的目标值 $t_1, \dots, t_N$ 。我们将目标变量 $\{t_n\}$ 组合成一个列向量，用 $\mathbf{t}$ 表示（采用不同字体以区别于多变量目标的单个观测 $\mathbf{t}$ ）。假设这些数据点独立地从分布 (3.8) 中抽取，可得似然函数关于可调参数 $\mathbf{w}$ 和 β 的表达式为

$$p(\mathbf{t} | \mathbf{X}, \mathbf{w}, \beta) = \prod_{n=1}^N \mathcal{N}(t_n | \mathbf{w}^T \phi(\mathbf{x}_n), \beta^{-1}) \quad (3.10)$$

这里使用了 (3.3)。注意，在回归（以及分类）等监督学习问题中，我们并不试图对输入变量的分布建模。因此 $\mathbf{x}$ 总是出现在条件变量集合中，从现在起我们将省略诸如

$p(\mathbf{t} | \mathbf{x}, \mathbf{w}, \beta)$ 中的显式 $\mathbf{x}$ ，以保持记号简洁。对似然函数取对数，并利用单变量高斯的标准形式 (1.46)，得到

$$\begin{aligned} \ln p(\mathbf{t} | \mathbf{w}, \beta) &= \sum_{n=1}^N \ln \mathcal{N}(t_n | \mathbf{w}^T \phi(\mathbf{x}_n), \beta^{-1}) \\ &= \frac{N}{2} \ln \beta - \frac{N}{2} \ln(2\pi) - \beta E_D(\mathbf{w}) \end{aligned} \quad (3.11)$$

其中平方和误差函数定义为

$$E_D(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N \{t_n - \mathbf{w}^T \phi(\mathbf{x}_n)\}^2 \quad (3.12)$$

写出似然函数后，我们即可使用最大似然法确定 $\mathbf{w}$ 和 β 。首先考虑关于 $\mathbf{w}$ 的最大化。正如 1.2.5 节已指出的，在线性模型的条件高斯噪声分布下，最大化似然函数等价于最小化平方和误差函数 $E_D(\mathbf{w})$ 。对数似然函数 (3.11) 的梯度形式为

$$\nabla \ln p(\mathbf{t} | \mathbf{w}, \beta) = \sum_{n=1}^N \{t_n - \mathbf{w}^T \phi(\mathbf{x}_n)\} \phi(\mathbf{x}_n)^T \quad (3.13)$$

将该梯度设为零得到

$$0 = \sum_{n=1}^N t_n \phi(\mathbf{x}_n)^T - \mathbf{w}^T \left(\sum_{n=1}^N \phi(\mathbf{x}_n) \phi(\mathbf{x}_n)^T \right) \quad (3.14)$$

求解 $\mathbf{w}$ 可得

$$\mathbf{w}_{\text{ML}} = (\Phi^T \Phi)^{-1} \Phi^T \mathbf{t} \quad (3.15)$$

这就是最小二乘问题的正规方程 (normal equations)。其中 Φ 是 $N \times M$ 矩阵，称为设计矩阵 (design matrix)，其元素为 $\Phi_{nj} = \phi_j(\mathbf{x}_n)$ ，因此

$$\Phi = \begin{pmatrix} \phi_0(\mathbf{x}_1) & \phi_1(\mathbf{x}_1) & \cdots & \phi_{M-1}(\mathbf{x}_1) \\ \phi_0(\mathbf{x}_2) & \phi_1(\mathbf{x}_2) & \cdots & \phi_{M-1}(\mathbf{x}_2) \\ \vdots & \vdots & \ddots & \vdots \\ \phi_0(\mathbf{x}_N) & \phi_1(\mathbf{x}_N) & \cdots & \phi_{M-1}(\mathbf{x}_N) \end{pmatrix} \quad (3.16)$$

其中

$$\Phi^\dagger \equiv (\Phi^T \Phi)^{-1} \Phi^T \quad (3.17)$$

称为矩阵 Φ 的 Moore-Penrose 伪逆 (Rao and Mitra, 1971; Golub and Van Loan, 1996)。它可视为矩阵逆概念对非方阵的推广。事实上，如果 Φ 是可逆方阵，利用 $(\mathbf{A}\mathbf{B})^{-1} = \mathbf{B}^{-1}\mathbf{A}^{-1}$ 可知 $\Phi^\dagger = \Phi^{-1}$ 。

此时我们可以深入理解偏置参数 w_0 的作用。如果显式写出偏置参数，误差函数 (3.12) 变为

$$E_D(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N \left\{ t_n - w_0 - \sum_{j=1}^{M-1} w_j \phi_j(\mathbf{x}_n) \right\}^2 \quad (3.18)$$

对 w_0 求导并令其为零，解得

$$w_0 = \bar{t} - \sum_{j=1}^{M-1} w_j \bar{\phi}_j \quad (3.19)$$

其中定义了

$$\bar{t} = \frac{1}{N} \sum_{n=1}^N t_n, \quad \bar{\phi}_j = \frac{1}{N} \sum_{n=1}^N \phi_j(\mathbf{x}_n) \quad (3.20)$$

可见，偏置 w_0 用来补偿目标值平均值与基函数值加权平均值之和之间的差值。

我们还可以对噪声精度参数 β 最大化对数似然函数 (3.11)，得到


$$\frac{1}{\beta_{\text{ML}}} = \frac{1}{N} \sum_{n=1}^N \{t_n - \mathbf{w}_{\text{ML}}^T \boldsymbol{\phi}(\mathbf{x}_n)\}^2 \quad (3.21)$$

因此，噪声精度的倒数正是目标值围绕回归函数的残差方差。

3.1.2 最小二乘的几何解释

此时考察最小二乘解的几何意义是很有启发的。为此，我们考虑一个 N 维空间，其坐标轴由 t_n 给出，从而 $\mathbf{t} = (t_1, \dots, t_N)^T$ 是该空间中的一个向量。每个基函数 $\phi_j(\mathbf{x}_n)$ 在 N 个数据点上的取值也可以表示为同一空间中的向量，记作 $\boldsymbol{\varphi}_j$ ，如图 3.2 所示。注意 $\boldsymbol{\varphi}_j$ 对应于 Φ 的第 j 列，而 $\phi(\mathbf{x}_n)$ 对应于 Φ 的第 n 行。如果基函数数量 M 小于数据点数量 N ，则 M 个向量 $\boldsymbol{\varphi}_j$ 将张成一个维度为 M 的线性子空间 $\mathcal{S}$ 。我们定义 $\mathbf{y}$ 为一个 N 维向量，其第 n 个元素为 $y(\mathbf{x}_n, \mathbf{w})$ ，其中 $n = 1, \dots, N$ 。由于 $\mathbf{y}$ 是向量 $\boldsymbol{\varphi}_j$ 的任意线性组合，它可以位于 M 维子空间中的任意位置。平方和误差 (3.12) 则（除以因子 $1/2$ 外）等于 $\mathbf{y}$ 与 $\mathbf{t}$ 之间的平方欧氏距离。因此， $\mathbf{w}$ 的最小二乘解对应于子空间 $\mathcal{S}$ 中离 $\mathbf{t}$ 最近的那个 $\mathbf{y}$ 。从图 3.2 直观来看，我们预期该解对应于 $\mathbf{t}$ 在子空间 $\mathcal{S}$ 上的正交投影。事实也的确如此，这一点很容易验证：只需注意到 $\mathbf{y}$ 的解为 $\Phi \mathbf{w}_{\text{ML}}$ ，然后确认它正是正交投影的形式。

图 3.2 最小二乘解的几何解释：在一个 N 维空间中，各坐标轴对应 $t_1, \dots, t_N$ 的取值。最小二乘回归函数可以通过将数据向量 $\mathbf{t}$ 正交投影到由基函数 $\phi_j(x)$ 所张成的子空间上得到，其中每个基函数可视为一个长度为 N 的向量 $\boldsymbol{\varphi}_j$ ，其元素为 $\phi_j(x_n)$ 。



在实际中，直接求解正规方程可能在 $\Phi^T \Phi$ 接近奇异时导致数值困难。特别是当两个或多个基向量 $\boldsymbol{\varphi}_j$ 共线或几乎共线时，得到的参数值可能具有很大的幅度。在处理真实数据集时，这种近似退化并不罕见。由此产生的数值困难可以使用奇异值分解 (SVD) 技术来解决 (Press et al., 1992; Bishop and Nabney, 2008)。需要注意的是，加入正则化项可以保证矩阵非奇异，即使存在退化情况。

3.1.3 序贯学习

批处理技术（如最大似然解 (3.15)）需要一次性处理整个训练集，对于大数据集来说计算代价高昂。正如第 1 章所讨论的，如果数据集足够大，使用序贯算法（也称为在线算法）可能是值得的：在这种算法中，数据点逐个考虑，每次呈现一个数据点后就更新模型参数。序贯学习也适用于实时应用场景，此时数据观测以连续流的形式到来，并且必须在看到所有数据点之前就做出预测。

我们可以通过应用随机梯度下降技术（也称为序贯梯度下降）得到一种序贯学习算法，具体如下。如果误差函数是关于数据点的求和 $E = \sum_n E_n$ ，则在呈现第 n 个模式后，随机梯度下降算法使用以下方式更新参数向量 $\mathbf{w}$

$$\mathbf{w}^{(\tau+1)} = \mathbf{w}^{(\tau)} - \eta \nabla E_n \quad (3.22)$$

其中 τ 表示迭代步数， η 是学习率参数。我们稍后将讨论 η 的取值选择。 $\mathbf{w}$ 的值初始化为某个起始向量 $\mathbf{w}^{(0)}$ 。对于平方和误差函数 (3.12)，这给出了

$$\mathbf{w}^{(\tau+1)} = \mathbf{w}^{(\tau)} + \eta (t_n - \mathbf{w}^{(\tau)\top} \phi_n) \phi_n \quad (3.23)$$

其中 $\phi_n = \phi(\mathbf{x}_n)$ 。这被称为最小均方算法（least-mean-squares，简称 LMS）。 η 的取值需要小心选择，以确保算法收敛（Bishop and Nabney, 2008）。

3.1.4 正则化最小二乘

在 1.1 节中，我们介绍了向误差函数中添加正则化项以控制过拟合的思想，从而要求最小化的总误差函数形式为

$$E_D(\mathbf{w}) + \lambda E_W(\mathbf{w}) \quad (3.24)$$

其中 λ 是正则化系数，用于控制数据相关误差 $E_D(\mathbf{w})$ 与正则化项 $E_W(\mathbf{w})$ 的相对重要性。最简单的正则化器之一是权重向量元素的平方和

$$E_W(\mathbf{w}) = \frac{1}{2} \mathbf{w}^\top \mathbf{w} \quad (3.25)$$

若同时考虑平方和误差函数

$$E(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N \{t_n - \mathbf{w}^\top \phi(\mathbf{x}_n)\}^2 \quad (3.26)$$

则总误差函数变为

$$\frac{1}{2} \sum_{n=1}^N \{t_n - \mathbf{w}^\top \phi(\mathbf{x}_n)\}^2 + \frac{\lambda}{2} \mathbf{w}^\top \mathbf{w} \quad (3.27)$$

这种特定的正则化器在机器学习文献中被称为权重衰减（weight decay），因为在序贯学习算法中，它会促使权重值向零衰减，除非得到数据的支持。在统计学中，它是参数收缩（parameter shrinkage）方法的一个例子，因为它使参数值向零收缩。其优点在于误差

函数关于 $\mathbf{w}$ 仍保持为二次函数，因此可以以闭合形式精确求得其极小值。具体地，将 (3.27) 关于 $\mathbf{w}$ 的梯度设为零并求解，得到

$$\mathbf{w} = (\lambda \mathbf{I} + \Phi^T \Phi)^{-1} \Phi^T \mathbf{t} \quad (3.28)$$

这是在最小二乘解 (3.15) 基础上的一个简单扩展。

有时会使用更一般的正则化器，此时正则化误差采取如下形式

$$\frac{1}{2} \sum_{n=1}^N \{t_n - \mathbf{w}^T \phi(\mathbf{x}_n)\}^2 + \frac{\lambda}{2} \sum_{j=1}^M |w_j|^q \quad (3.29)$$

其中 $q = 2$ 对应于二次正则化器 (3.27)。图 3.3 显示了不同 q 值下正则化项的等高线。





图 3.3 式 (3.29) 中正则项在不同参数 q 取值下的等高线。

$q = 1$ 的情形在统计学文献中被称为 lasso (Tibshirani, 1996)。它具有如下性质：当 λ 足够大时，某些系数 w_j 会被压缩到零，从而得到一个稀疏模型，其中对应的基函数不起任何作用。为了看出这一点，我们首先注意到，最小化 (3.29) 等价于在如下约束下最小化未经正则化的平方和误差 (3.12)

$$\sum_{j=1}^M |w_j|^q \leq \eta \quad (3.30)$$

其中 η 是适当的参数值，这两种方法可以通过拉格朗日乘子相互关联。稀疏性的来源可见于图 3.4，该图展示了在约束 (3.30) 下误差函数的最小值。随着 λ 的增大，越来越多的参数被压缩到零。

图 3.4 对无正则项误差函数的等高线（蓝色）与约束区域 (3.30) 的绘图：左图为二次正则项 $q = 2$ ，右图为 lasso 正则项 $q = 1$ 。参数向量的最优值记为 $\mathbf{w}^*$ 。在 lasso 情况下得到稀疏解，其中 $w_1^+ = 0$ 。



正则化允许在有限规模的数据集上训练复杂模型，而不会出现严重的过拟合，其本质是通过限制有效模型复杂度来实现。然而，确定最优模型复杂度的问题也随之从寻找适当的基函数数量转移到确定正则化系数 λ 的合适取值上。我们将在本章后面重新讨论模型复杂度问题。

在本章余下部分，我们将专注于二次正则化器 (3.27)，既因为它在实践中重要，也因为它在数学上易于处理。

3.1.5 多输出

到目前为止，我们一直考虑单个目标变量 t 的情况。在某些应用中，我们可能希望同时预测 $K > 1$ 个目标变量，统称为目标向量 $\mathbf{t}$ 。一种做法是为 $\mathbf{t}$ 的每个分量引入不同的基函数集合，从而得到多个独立的回归问题。然而，更有趣也更常见的方法是使用同一组基函数来对目标向量的所有分量进行建模，即

$$\mathbf{y}(\mathbf{x}, \mathbf{w}) = \mathbf{W}^T \phi(\mathbf{x}) \quad (3.31)$$

其中 $\mathbf{y}$ 是 K 维列向量， $\mathbf{W}$ 是 $M \times K$ 参数矩阵， $\phi(\mathbf{x})$ 是 M 维列向量，其元素为 $\phi_j(\mathbf{x})$ ，且仍令 $\phi_0(\mathbf{x}) = 1$ 。假设目标向量的条件分布为各向同性高斯分布

$$p(\mathbf{t} | \mathbf{x}, \mathbf{W}, \beta) = \mathcal{N}(\mathbf{t} | \mathbf{W}^T \phi(\mathbf{x}), \beta^{-1} \mathbf{I}) \quad (3.32)$$

若有观测 $\mathbf{t}_1, \dots, \mathbf{t}_N$ ，我们可将其组装成 $N \times K$ 矩阵 $\mathbf{T}$ ，其第 n 行为 $\mathbf{t}_n^T$ 。类似地，将输入向量 $\mathbf{x}_1, \dots, \mathbf{x}_N$ 组装成矩阵 $\mathbf{X}$ 。此时对数似然函数为

$$\begin{aligned} \ln p(\mathbf{T} | \mathbf{X}, \mathbf{W}, \beta) &= \sum_{n=1}^N \ln \mathcal{N}(\mathbf{t}_n | \mathbf{W}^T \phi(\mathbf{x}_n), \beta^{-1} \mathbf{I}) \\ &= \frac{NK}{2} \ln \left(\frac{\beta}{2\pi} \right) - \frac{\beta}{2} \sum_{n=1}^N \|\mathbf{t}_n - \mathbf{W}^T \phi(\mathbf{x}_n)\|^2. \end{aligned} \quad (3.33)$$

与之前一样，我们对 $\mathbf{W}$ 最大化该函数，得到

$$\mathbf{W}_{\text{ML}} = (\Phi^T \Phi)^{-1} \Phi^T \mathbf{T}. \quad (3.34)$$

如果我们对每个目标变量 t_k 单独考察，就有

$$\mathbf{w}_k = (\Phi^T \Phi)^{-1} \Phi^T \mathbf{t}_k = \Phi^\dagger \mathbf{t}_k \quad (3.35)$$

其中 $\mathbf{t}_k$ 是 N 维列向量，其分量为 t_{nk} ， $n = 1, \dots, N$ 。因此回归问题的解在不同目标变量之间是解耦的，我们只需计算一次伪逆矩阵 $\Phi^\dagger$ ，它被所有 $\mathbf{w}_k$ 共享。

扩展到具有任意协方差矩阵的一般高斯噪声分布也是直观的，同样会导致 K 个独立的回归问题。这一结果并不令人意外，因为参数 $\mathbf{W}$ 只定义了高斯噪声分布的均值，而我们从 2.3.4 节知道，多变量高斯分布均值的最大似然解与协方差无关。从现在起，为简便起见，我们将只考虑单个目标变量 t 。

3.2 偏差-方差分解

到目前为止，在讨论回归的线性模型时，我们一直假设基函数的形式和数量都是固定的。正如第 1 章所见，如果用数据规模有限的数据集训练复杂模型，最大似然（或等价的最小二乘）会导致严重的过拟合。然而，为了避免过拟合而限制基函数数量的副作用是限制了模型捕捉数据中重要趋势的灵活性。虽然引入正则化项可以对参数较多的模型控制过拟合，但这又引出了如何确定正则化系数 λ 合适值的问题。显然，同时对权重向量 $\mathbf{w}$ 和正则化系数 λ 最小化正则化误差函数并不是正确做法，因为这会导致无正则化的解，即 $\lambda = 0$ 。

正如前几章所见，过拟合本质上是最大似然的一个缺陷，而在贝叶斯框架下对参数边缘化时就不会出现这种现象。在本章中，我们将深入探讨模型复杂度的贝叶斯观点。不过在此之前，先从频度学派的视角考察模型复杂度问题——即偏差-方差权衡（**bias-variance trade-off**）——是很有启发的。虽然我们将在简单易于说明的线性基函数模型背景下引入这一概念，但相关讨论具有更广泛的适用性。

在 1.5.5 节讨论回归问题的决策理论时，我们考虑了多种损失函数，每一种在给定条件分布 $p(t | \mathbf{x})$ 后都会导向相应的最优预测。常用的平方损失函数对应的最优预测是条件期望，我们记作 $h(\mathbf{x})$ ，定义为

$$h(\mathbf{x}) = \mathbb{E}[t | \mathbf{x}] = \int t p(t | \mathbf{x}) dt \quad (3.36)$$

此时有必要区分决策理论中产生的平方损失函数与最大似然参数估计中出现的平方和误差函数。我们可能会采用比最小二乘更复杂的技术（例如正则化或完全贝叶斯方法）来确定条件分布 $p(t | \mathbf{x})$ 。这些方法都可以与平方损失函数结合，用于做出预测。

我们在 1.5.5 节证明，期望平方损失可以写成如下形式

$$\mathbb{E}[L] = \int \{y(\mathbf{x}) - h(\mathbf{x})\}^2 p(\mathbf{x}) d\mathbf{x} + \int \{h(\mathbf{x}) - t\}^2 p(\mathbf{x}, t) d\mathbf{x} dt \quad (3.37)$$

回忆一下，第二项与 $y(\mathbf{x})$ 无关，它源于数据的固有噪声，代表期望损失可达到的最小值。第一项依赖于我们对函数 $y(\mathbf{x})$ 的选择，我们将寻求使该项最小的 $y(\mathbf{x})$ 。由于它非负，我们希望的最好结果是使其为零。如果拥有无限数据（以及无限计算资源），原则上我们可以以任意精度求得回归函数 $h(\mathbf{x})$ ，这将是 $y(\mathbf{x})$ 的最优选择。然而实际中我们只有包含有限 N 个数据点的有限数据集 $\mathcal{D}$ ，因此无法精确知道回归函数 $h(\mathbf{x})$ 。

如果我们使用参数函数 $y(\mathbf{x}, \mathbf{w})$ 来建模 $h(\mathbf{x})$ ，其中由参数向量 $\mathbf{w}$ 控制，那么从贝叶斯视角，模型的不确定性通过 $\mathbf{w}$ 的后验分布表达。而频度学派处理方式则是基于数据集 $\mathcal{D}$ 对 $\mathbf{w}$ 做一个点估计，并通过如下思想实验来解释该估计的不确定性：假设我们有大量大小均为 N 的数据集，每个数据集都独立地从分布 $p(t, \mathbf{x})$ 中抽取。对于任意给定的数据集 $\mathcal{D}$ ，我们运行学习算法得到预测函数 $y(\mathbf{x}; \mathcal{D})$ 。来自集合的不同数据集会给出不同的函数，从而产生不同的平方损失值。特定学习算法的性能通过对这一数据集集合取平均来评估。

考虑 (3.37) 中第一项的被积函数，对于特定数据集 $\mathcal{D}$ 其形式为

$$\{y(\mathbf{x}; \mathcal{D}) - h(\mathbf{x})\}^2 \quad (3.38)$$

由于该量依赖于具体数据集 $\mathcal{D}$ ，我们对其在数据集集合上取平均。如果在大括号内加减 $\mathbb{E}_{\mathcal{D}}[y(\mathbf{x}; \mathcal{D})]$ ，然后展开，可得

$$\begin{aligned} & \{y(\mathbf{x}; \mathcal{D}) - \mathbb{E}_{\mathcal{D}}[y(\mathbf{x}; \mathcal{D})] + \mathbb{E}_{\mathcal{D}}[y(\mathbf{x}; \mathcal{D})] - h(\mathbf{x})\}^2 \\ &= \{y(\mathbf{x}; \mathcal{D}) - \mathbb{E}_{\mathcal{D}}[y(\mathbf{x}; \mathcal{D})]\}^2 + \{\mathbb{E}_{\mathcal{D}}[y(\mathbf{x}; \mathcal{D})] - h(\mathbf{x})\}^2 \\ & \quad + 2 \{y(\mathbf{x}; \mathcal{D}) - \mathbb{E}_{\mathcal{D}}[y(\mathbf{x}; \mathcal{D})]\} \{\mathbb{E}_{\mathcal{D}}[y(\mathbf{x}; \mathcal{D})] - h(\mathbf{x})\} \end{aligned} \quad (3.39)$$

现在我们对 $\mathcal{D}$ 取该表达式的期望，注意到最后一项将消失，得到

$$\begin{aligned} & \mathbb{E}_{\mathcal{D}} [\{y(\mathbf{x}; \mathcal{D}) - h(\mathbf{x})\}^2] \\ &= \underbrace{\{\mathbb{E}_{\mathcal{D}}[y(\mathbf{x}; \mathcal{D})] - h(\mathbf{x})\}^2}_{(\text{bias})^2} + \underbrace{\mathbb{E}_{\mathcal{D}} [\{y(\mathbf{x}; \mathcal{D}) - \mathbb{E}_{\mathcal{D}}[y(\mathbf{x}; \mathcal{D})]\}^2]}_{\text{variance}} \end{aligned} \quad (3.40)$$

可见， $y(\mathbf{x}; \mathcal{D})$ 与回归函数 $h(\mathbf{x})$ 之间期望平方差可以表示为两个项之和。第一项称为平方偏差 (squared bias)，它衡量所有数据集上的平均预测与理想回归函数的差异程度。第二项称为方差 (variance)，它衡量各个数据集的解围绕其平均值的波动程度，从而反映函数 $y(\mathbf{x}; \mathcal{D})$ 对具体数据集选择的敏感程度。我们稍后通过一个简单例子来直观说明这些定义。

到目前为止，我们只考虑单个输入值 $\mathbf{x}$ 。若将此展开式代回 (3.37)，就得到期望平方损失的如下分解

$$\text{expected loss} = (\text{bias})^2 + \text{variance} + \text{noise} \quad (3.41)$$

其中

$$(\text{bias})^2 = \int \{\mathbb{E}_{\mathcal{D}}[y(\mathbf{x}; \mathcal{D})] - h(\mathbf{x})\}^2 p(\mathbf{x}) d\mathbf{x} \quad (3.42)$$

$$\text{variance} = \int \mathbb{E}_{\mathcal{D}} [\{y(\mathbf{x}; \mathcal{D}) - \mathbb{E}_{\mathcal{D}}[y(\mathbf{x}; \mathcal{D})]\}^2] p(\mathbf{x}) d\mathbf{x} \quad (3.43)$$

$$\text{noise} = \int \{h(\mathbf{x}) - t\}^2 p(\mathbf{x}, t) d\mathbf{x} dt \quad (3.44)$$

此时偏差和方差项指代的是积分量。

我们的目标是最小化期望损失，它被分解为（平方）偏差、方差以及一个常数噪声项之和。正如我们将看到的，偏差与方差之间存在权衡：非常灵活的模型偏差低但方差高，相对刚性的模型偏差高但方差低。预测能力最优的模型是在偏差与方差之间取得最佳平衡的模型。这可以通过第 1 章中的正弦数据集来说明。这里我们独立地从正弦曲线 $h(x) = \sin(2\pi x)$ 生成 100 个数据集，每个数据集包含 $N = 25$ 个数据点。数据集编号为 $l = 1, \dots, L$ ，其中 $L = 100$ 。对每个数据集 $\mathcal{D}^{(l)}$ ，我们通过最小化正则化误差函数 (3.27) 拟合 24 个高斯基函数，得到预测函数 $y^{(l)}(x)$ ，如图 3.5 所示。




图 3.5 利用第 1 章中的正弦数据集展示偏差与方差随模型复杂度变化的示意图，模型复杂度由正则化参数 λ 控制。这里共有 $L = 100$ 个数据集，每个数据集包含 $N = 25$ 个数据点，模型中包含 24 个高斯基函数，因此参数总数为 $M = 25$ （包括偏置参数）。左栏展示了在不同 $\ln \lambda$ 取值下将模型拟合到这些数据集的结果（为便于展示，仅绘制了 100 次拟合中的 20 条）。右栏则展示了 100 次拟合结果的平均值（红色），以及生成数据集的真实正弦函数（绿色）。

第一行对应于正则化系数 λ 很大的情况：方差低（左图中红色曲线看起来很相似），但偏差高（右图中平均拟合与真实正弦函数相差很大）。最后一行对应于 λ 很小的情形：方差大（左图中红色曲线之间变化剧烈），但偏差低（右图中平均模型拟合与原始正弦函数吻合良好）。值得注意的是，对复杂模型（ $M = 25$ ）的多个解取平均后，能极好地拟合回归函数，这提示我们平均可能是一种有益的操作。实际上，对多个解进行加权平均正是贝叶斯方法的核心，只不过平均是对参数后验分布进行的，而不是对多个数据集进行的。

我们也可以对该例子进行偏差-方差权衡的定量分析。平均预测通过下式估计

$$\bar{y}(x) = \frac{1}{L} \sum_{l=1}^L y^{(l)}(x) \quad (3.45)$$


积分平方偏差和积分方差则由下式给出

$$(\text{bias})^2 = \frac{1}{N} \sum_{n=1}^N \{\bar{y}(x_n) - h(x_n)\}^2 \quad (3.46)$$

$$\text{variance} = \frac{1}{N} \sum_{n=1}^N \frac{1}{L} \sum_{l=1}^L \{y^{(l)}(x_n) - \bar{y}(x_n)\}^2 \quad (3.47)$$

其中关于 x 加权分布 $p(x)$ 的积分通过从该分布抽取的数据点的有限和来近似。这些量连同它们的和作为 $\ln \lambda$ 的函数绘于图 3.6 中。我们看到, λ 的取值很小时, 模型会精细地拟合每个单独数据集上的噪声, 导致方差很大。相反, λ 取值很大时会把权重参数拉向零, 导致偏差很大。

图 3.6 对应图 3.5 结果的平方偏差与方差及其和的绘图, 同时还展示了大小为 1000 的测试集上的平均测试误差。可以看到, $(\text{偏差})^2 + \text{方差}$ 的最小值出现在 $\ln \lambda = -0.31$ 附近, 该数值与在测试集上得到最小误差的取值非常接近。



尽管偏差-方差分解从频度学派视角为模型复杂度问题提供了一些有趣的洞察, 但其实际价值有限, 因为偏差-方差分解基于对数据集集合的平均, 而实际中我们只有一个观测到的数据集。如果我们有大量给定大小的独立训练集, 最好将它们合并成一个大的训练集, 这当然会降低给定模型复杂度下的过拟合程度。

鉴于这些局限性, 我们将在下一节转向对线性基函数模型的贝叶斯处理, 这不仅为过拟合问题提供了深刻的洞察, 还导向了解决模型复杂度问题的实用技术。

3.3 贝叶斯线性回归

在讨论线性回归模型参数的最大似然设定时, 我们已经看到, 有效模型复杂度 (由基函数数量决定) 必须根据数据集大小进行控制。在对数似然函数中加入正则化项后, 有效模型复杂度就可以通过正则化系数的值来控制, 不过基函数的数量和形式选择当然仍然对模型整体行为至关重要。

这就留下了一个问题: 如何为具体问题确定合适的模型复杂度? 单纯最大化似然函数显然不行, 因为这总是导致过于复杂的模型和过拟合。如 1.3 节所述, 可以使用独立的验证集来确定模型复杂度, 但这样做既计算昂贵, 又浪费宝贵的数据。因此, 我们转向线性回归的贝叶斯处理, 它将避免最大似然带来的过拟合问题, 并仅使用训练数据就

能自动确定模型复杂度。为简单起见，我们仍重点讨论单个目标变量 t 的情况。扩展到多个目标变量是直观的，只需遵循 3.1.5 节的讨论即可。

3.3.1 参数分布

我们从对模型参数 $\mathbf{w}$ 引入先验概率分布开始讨论线性回归的贝叶斯处理。暂时将噪声精度参数 β 视为已知常数。首先注意，由 (3.10) 定义的似然函数 $p(\mathbf{t} | \mathbf{w})$ 是 $\mathbf{w}$ 的二次函数的指数形式。因此对应的共轭先验是高斯分布

$$p(\mathbf{w}) = \mathcal{N}(\mathbf{w} | \mathbf{m}_0, \mathbf{S}_0) \quad (3.48)$$

其中均值为 $\mathbf{m}_0$ ，协方差为 $\mathbf{S}_0$ 。

接下来我们计算后验分布，它正比于似然函数与先验的乘积。由于选择了共轭高斯先验，后验分布也将是高斯的。我们可以通过在指数中完成平方并利用标准高斯归一化结果来求得该分布。不过，我们已经在推导通用结果 (2.116) 时完成了必要工作，因此可以直接写出后验分布的形式

$$p(\mathbf{w} | \mathbf{t}) = \mathcal{N}(\mathbf{w} | \mathbf{m}_N, \mathbf{S}_N) \quad (3.49)$$

其中

$$\mathbf{m}_N = \mathbf{S}_N (\mathbf{S}_0^{-1} \mathbf{m}_0 + \beta \Phi^T \mathbf{t}) \quad (3.50)$$

$$\mathbf{S}_N^{-1} = \mathbf{S}_0^{-1} + \beta \Phi^T \Phi \quad (3.51)$$

需要注意的是，由于后验分布是高斯的，其众数与均值重合。因此最大后验权重向量就是 $\mathbf{w}_{\text{MAP}} = \mathbf{m}_N$ 。如果考虑无限宽的先验 $\mathbf{S}_0 = \alpha^{-1} \mathbf{I}$ 并令 $\alpha \rightarrow 0$ ，则后验均值 $\mathbf{m}_N$ 将退化为最大似然值 $\mathbf{w}_{\text{ML}}$ （由 (3.15) 给出）。类似地，若 $N = 0$ ，后验分布退回到先验。此外，如果数据点逐个到达，则任意阶段的后验分布可作为下一个数据点的先验，新后验分布仍由 (3.49) 给出。

在本章余下部分，我们将考虑一种特殊的高斯先验以简化处理。具体地，我们采用零均值、各向同性的高斯先验，仅由单一精度参数 α 控制，即

$$p(\mathbf{w} | \alpha) = \mathcal{N}(\mathbf{w} | \mathbf{0}, \alpha^{-1} \mathbf{I}) \quad (3.52)$$

此时关于 $\mathbf{w}$ 的后验分布仍由 (3.49) 给出，但参数变为

$$\mathbf{m}_N = \beta \mathbf{S}_N \Phi^T \mathbf{t} \quad (3.53)$$

$$\mathbf{S}_N^{-1} = \alpha \mathbf{I} + \beta \Phi^T \Phi \quad (3.54)$$

后验分布的对数是似然函数对数与先验对数之和，作为 $\mathbf{w}$ 的函数具有如下形式

$$\ln p(\mathbf{w} | \mathbf{t}) = -\frac{\beta}{2} \sum_{n=1}^N \{t_n - \mathbf{w}^T \phi(\mathbf{x}_n)\}^2 - \frac{\alpha}{2} \mathbf{w}^T \mathbf{w} + \text{const.} \quad (3.55)$$

因此，对该后验分布关于 $\mathbf{w}$ 的最大化等价于最小化平方和误差函数加上二次正则化项，即 (3.27) 中 $\lambda = \alpha/\beta$ 的情形。

我们可以通过一个简单的直线拟合例子来说明线性基函数模型中的贝叶斯学习以及后验分布的序贯更新。考虑单个输入变量 x 、单个目标变量 t 和形如 $y(x, \mathbf{w}) = w_0 + w_1 x$ 的线性模型。由于只有两个可调参数，我们可以直接在参数空间中绘制先验和后验分布。我们可以通过一个简单的直线拟合示例，在线性基函数模型中说明贝叶斯学习以及后验分布的序列更新。考虑单一输入变量 x 、单一目标变量 t ，以及形如 $y(x, \mathbf{w}) = w_0 + w_1 x$ 的线性模型。由于该模型只有两个可调参数，我们可以直接在参数空间中绘制先验和后验分布。我们从函数 $f(x, \mathbf{a}) = a_0 + a_1 x$ 生成合成数据，其中参数取值为 $a_0 = -0.3$ 和 $a_1 = 0.5$ 。具体方法是，首先从均匀分布 $U(x | -1, 1)$ 中选取 x_n 的值，然后计算 $f(x_n, \mathbf{a})$ ，最后添加标准差为 0.2 的高斯噪声以得到目标值 t_n 。我们的目标是根据这些数据恢复 a_0 和 a_1 的取值，并将探讨数据集大小的影响。这里假设噪声方差已知，因此将精度参数设为其真实值 $\beta = (1/0.2)^2 = 25$ 类似地，将参数 $\alpha = 2.0$ 固定下来。稍后我们将讨论从训练数据中确定 α 和 β 的策略。图 3.7 展示了在该模型中，随着数据集大小增加的贝叶斯学习结果，并演示了贝叶斯学习的序列特性：当观察到新数据点时，当前后验分布将作为新的先验。值得花时间详细分析该图，因为它说明了贝叶斯推断中的多个重要方面。

图的第一行对应未观察到任何数据点的情况，显示了 $\mathbf{w}$ 空间中的先验分布，以及从先验中采样得到的六条函数 $y(x, \mathbf{w})$ 的曲线。第二行展示了观察到一个数据点后的情况。右侧列用蓝色圆点表示数据点 (x, t) 。左侧列显示了该数据点对应的似然函数 $p(t | x, \mathbf{w})$ 作为 $\mathbf{w}$ 的函数。注意，似然函数提供的是一种“柔性”约束，即直线需要经过数据点附近，而“附近”的程度由噪声精度 β 决定。为了对比，生成数据集时使用的真实参数 $a_0 = -0.3$ 、 $a_1 = 0.5$ 在左侧的图中以白色叉号标出。将该似然函数与第一行的先验相乘并归一化，即得到第二行中间的后验分布。从该后验分布中对 $\mathbf{w}$ 进行采样，得到的回归函数样本显示在右侧的图中。可以看到，这些样本曲线都经过该数据点附近。第三行展示了观察第二个数据点的效果。同样在右侧列以蓝色圆点表示。左侧图显示仅由第二个数据点得到的似然函数。当我们将该似然函数与第二行的后验分布相乘时，得到第三行中间的后验分布。注意，这与直接将原始先验与两个数据点的似然函数相结合所得结果完全相同。此时后验已受到两个数据点的影响，而两个点足以确定一条直线，因此后验已经相对集中。该后验的样本生成的函数以红色显示，可以看到它们同时经过两个数据点附近。第四行展示了观察到总共 20 个数据点的情况。左侧图为第 20 个数据点单独的似然函数，中间图为结合所有 20 个观测后的后验分布。可以注意到此时后验比第三行显著更尖锐。在数据点数趋于无穷时，后验分布将收缩为一个以真实参数值（白色叉号所示）为中心的狄拉克 delta 分布。




图 3.7 对简单线性模型 $y(x, \mathbf{w}) = w_0 + w_1 x$ 的序贯贝叶斯学习示意图。该图的详细说明见正文。

可以考虑参数上的其他形式的先验。例如，我们可以将高斯先验推广为

$$p(\mathbf{w} | \alpha) = \left[\frac{q}{2} \left(\frac{\alpha}{2} \right)^{1/q} \frac{1}{\Gamma(1/q)} \right]^M \exp \left(-\frac{\alpha}{2} \sum_{j=1}^M |w_j|^q \right) \quad (3.56)$$

其中 $q = 2$ 时对应高斯分布，并且只有在这种情况下先验与似然函数 (3.10) 是共轭的。在 w 上对后验分布取最大值等价于最小化正则化误差函数 (3.29)。对于高斯先验，后验分布的众数等于其均值，但如果 $q \neq 2$ ，这一性质将不再成立。

3.3.2 预测分布

在实际中，我们通常并不直接关心 $\mathbf{w}$ 的取值，而是希望对新的 $\mathbf{x}$ 预测 t 。这需要计算定义为

$$p(t | \mathbf{t}, \alpha, \beta) = \int p(t | \mathbf{w}, \beta) p(\mathbf{w} | \mathbf{t}, \alpha, \beta) d\mathbf{w} \quad (3.57)$$

的预测分布，其中 $\mathbf{t}$ 是训练集中的目标值向量，并且为了简化符号，我们在条件语句中省略了对应的输入向量。目标变量的条件分布 $p(t | \mathbf{x}, \mathbf{w}, \beta)$ 由 (3.8) 给出，而权重的后验分布由 (3.49) 给出。注意 (3.57) 涉及两个高斯分布的卷积，因此利用第 8.1.4 节中的结果 (2.115)，可得预测分布为

$$p(t | \mathbf{x}, \mathbf{t}, \alpha, \beta) = \mathcal{N}(t | \mathbf{m}^T \phi(\mathbf{x}), \sigma^2 N^2(\mathbf{x})) \quad (3.58)$$

其中预测分布方差 $\sigma_N^2(\mathbf{x})$ 为

$$\sigma_N^2(\mathbf{x}) = \frac{1}{\beta} + \phi(\mathbf{x})^T \mathbf{S}_N \phi(\mathbf{x}) \quad (3.59)$$

(3.59) 中的第一项表示数据噪声，而第二项反映参数 w 的不确定性。由于噪声和 $\mathbf{w}$ 的分布均为高斯分布，它们的方差可以相加。注意，随着观察到更多的数据点，后验分布会逐渐收缩。因此可以证明 (Qazaz et al., 1997)，有 $\sigma_{N+1}^2(\mathbf{x}) \leq \sigma_N^2(\mathbf{x})$ 。当 $N \rightarrow \infty$ 时，(3.59) 中的第二项趋于 0，此时预测分布的方差仅由噪声参数 β 决定。




图 3.8 对由 9 个形式为 (3.4) 的高斯基函数组成的模型，其预测分布 (3.58) 的示例，使用第 1.1 节中的合成正弦数据集。详细讨论见正文。

为了说明贝叶斯线性回归模型的预测分布，我们回到第 1.1 节中的合成正弦数据集。在图 3.8 中，我们将由高斯基函数线性组合构成的模型拟合到不同规模的数据集上，并观察相应的后验分布。图中绿色曲线表示生成数据点（加高斯噪声）的函数 $\sin(2\pi x)$ 。四幅图中蓝色圆点分别表示规模为 $N = 1$ 、 $N = 2$ 、 $N = 4$ 和 $N = 25$ 的数据集。对于每幅图，红色曲线表示相应高斯预测分布的均值，而红色阴影区域表示均值左右一个标准差的范围。可以看到，预测不确定性依赖于 x ，并且在数据点附近最小。同时注意到，随着观测数据点的数量增加，不确定性逐渐降低。

图 3.8 中的图仅展示了预测方差随 x 变化的点对点形式。为了进一步理解在不同 x 取值下预测之间的协方差关系，我们可以从 $\mathbf{w}$ 的后验分布中进行采样，然后绘制对应的函数 $y(x, \mathbf{w})$ ，如图 3.9 所示。




图 3.9 利用从 w 的后验分布中抽取的样本绘制函数 $y(x, w)$ ，对应于图 3.8 中的结果。

如果使用局部化的基函数（例如高斯函数），那么在远离基函数中心的区域中，(3.59) 中预测方差的第二项贡献将趋于零，只剩下噪声项 β^{-1} 。因此，在超出基函数覆盖范围进行外推时，模型会对自己的预测表现得非常自信，而这通常是一种不理想的行为。这个问题可以通过采用另一种用于回归的贝叶斯方法来避免，该方法称为高斯过程。

注意，如果将 $\mathbf{w}$ 和 β 都视为未知量，那么我们可以为 $p(\mathbf{w}, \beta)$ 引入一个共轭先验分布，根据第 2.3.6 节的讨论，该先验将是高斯-伽马分布（Denison et al., 2002）。在这种情况下，预测分布将是 Student's t 分布。

3.3.3 等价核

线性基函数模型的后验均值解 (3.53) 有一个有趣的解释, 这将为包括高斯过程在内的核方法奠定基础。如果我们将 (3.53) 代入表达式 (3.3), 可以看到预测均值可以写成如下形式

$$y(\mathbf{x}, \mathbf{m}_N) = \mathbf{m}_N^T \phi(\mathbf{x}) = \beta \phi(\mathbf{x})^T \mathbf{S}_N \Phi^T \mathbf{t} = \sum_{n=1}^N \beta \phi(\mathbf{x})^T \mathbf{S}_N \phi(\mathbf{x}_n) t_n \quad (3.60)$$


其中 $\mathbf{S}_N$ 由 (3.51) 定义。因此, 在点 $\mathbf{x}$ 处预测分布的均值可以表示为训练集目标变量 t_n 的线性组合, 从而我们可以写为

$$y(\mathbf{x}, \mathbf{m}_N) = \sum_{n=1}^N k(\mathbf{x}, \mathbf{x}_n) t_n \quad (3.61)$$

其中函数


$$k(\mathbf{x}, \mathbf{x}') = \beta \phi(\mathbf{x})^T \mathbf{S}_N \phi(\mathbf{x}') \quad (3.62)$$

图 3.10 图 3.1 中高斯基函数对应的等效核 $k(x, x')$, 以 x 对 x' 的形式绘制, 并给出了该矩阵在三个不同 x 取值处的三条切片。用于生成该核的数据集由区间 $(-1, 1)$ 上均匀取样的 200 个 x 值组成。



被称为平滑矩阵或等效核。像这样的回归函数通过对训练集目标值进行线性组合来进行预测, 被称为线性平滑器。注意, 等效核依赖于数据集中输入值 $\mathbf{x}_n$, 因为这些值出现在 $\mathbf{S}_N$ 的定义中。图 3.10 展示了高斯基函数情况下的等效核, 其中核函数 $k(x, x')$ 随着 x' 绘制, 并对应三个不同的 x 值。可见这些函数都集中在 x 附近, 因此在 x 处预测分布的均值 $y(x, \mathbf{m}_N)$ 是通过加权组合目标值得到的, 其中靠近 x 的数据点具有更高权重, 而离 x 较远的数据点权重较低。直观地说, 更强地权衡局部证据而非远处证据是合理的。注意, 这种局部化性质不仅出现在局部的高斯基函数中, 也出现在非局部的多项式和 S 形 (sigmoidal) 基函数中, 如图 3.11 所示。

图 3.11 对应于图 3.1 所示的基函数, 给出 $x = 0$ 时的等效核 $k(x, x')$ 随 x' 的函数形式: 左图为多项式基函数情形, 右图为 sigmoid 基函数情形。尽管相应的基函数本身是非局部的, 但这些等效核关于 x' 是局部化的函数。



对等价核作用的进一步理解可以通过考虑 $y(\mathbf{x})$ 与 $y(\mathbf{x}')$ 之间的协方差来获得, 其形

式为

$$\begin{aligned}\text{cov}[y(\mathbf{x}), y(\mathbf{x}')] &= \text{cov}[\phi(\mathbf{x})^T \mathbf{w}, \mathbf{w}^T \phi(\mathbf{x}')] \\ &= \phi(\mathbf{x})^T \mathbf{S}_N \phi(\mathbf{x}') = \beta^{-1} k(\mathbf{x}, \mathbf{x}')\end{aligned}\quad (3.63)$$

这里使用了 (3.49) 和 (3.62)。由等价核的形式可以看出，相邻点处的预测均值具有较强的相关性，而较远点之间的相关性则较弱。

图 3.8 所示的预测分布允许我们通过 (3.59) 观察预测在每一个点上的不确定性。然而，通过从 $\mathbf{w}$ 的后验分布中抽取样本并在图 3.9 中绘制相应的模型函数 $y(\mathbf{x}, \mathbf{w})$ ，我们实际上是在可视化由等价核决定的，在两个（或更多）不同 x 值处的 y 值之间的联合不确定性。

将线性回归表示为核函数形式提示了另一种回归方法。与其引入一组基函数（从而隐式决定等价核），我们可以直接定义一个局部化的核函数，并利用它在给定训练集的情况下对新的输入向量 $\mathbf{x}$ 进行预测。这引出了一个用于回归（和分类）的实用框架，称为高斯过程，我们将在第 6.4 节中详细讨论。

我们已经看到，有效核决定了在对新的 $\mathbf{x}$ 进行预测时，训练集目标值被组合的权重，并且可以证明这些权重之和为 1，即

$$\sum_{n=1}^N k(\mathbf{x}, \mathbf{x}_n) = 1 \quad (3.64)$$

对所有 $\mathbf{x}$ 都成立。这个直观上令人满意的结果可以通过一个非正式推断得到：考虑一个训练集，其中所有目标值 $t_n = 1$ ，则其预测均值记为 $\hat{y}(\mathbf{x})$ 。只要基函数线性无关、数据点数量多于基函数数量，并且包含一个常数基函数（对应偏置参数），那么我们可以精确拟合训练数据，从而预测均值必为 $\hat{y}(x) = 1$ ，由此得到 (3.64)。需要注意的是，核函数的值可以为负也可以为正，因此尽管满足加和约束，预测并不一定是训练集目标值的凸组合。

最后，我们注意到等价核 (3.62) 具有核函数的一项重要通性，即它可以表示为关于一组非线性函数向量 $\psi(x)$ 的内积形式，因此有

$$k(\mathbf{x}, \mathbf{z}) = \psi(\mathbf{x})^T \psi(\mathbf{z}) \quad (3.65)$$

其中 $\psi(\mathbf{x}) = \beta^{1/2} \mathbf{S}_N^{1/2} \phi(\mathbf{x})$ 。

3.4 贝叶斯模型比较

在第 1 章中，我们强调了过拟合的问题，以及使用交叉验证来设定正则化参数取值或在备选模型之间进行选择的方法。在这里，我们从贝叶斯的角度来讨论模型选择的问题。本节将给出一个非常一般性的讨论，并在第 3.5 节中看到如何将这些思想用于线性回归中正则化参数的确定。

正如我们将看到的，通过对模型参数进行边缘化（求和或积分），而不是对其进行点估计，可以避免最大似然引起的过拟合。这样，模型可以直接使用训练数据进行比较，而不需要验证集。这使得可以利用全部可用数据进行训练，也避免了交叉验证中每个模

型都需要多次训练的问题。同时，这还允许在训练过程中同时确定多个复杂度参数。例如，在第7章中我们将介绍相关向量机，它是一个贝叶斯模型，并为每一个训练数据点设置一个复杂度参数。

贝叶斯模型比较的观点非常简单，即使用概率来表示对模型选择的不确定性，并一致地使用概率的和法则和积法则。假设我们希望比较一组模型 $\mathcal{M}_i$ ，其中 $i = 1, \dots, L$ 。这里模型指的是定义在观测数据 $\mathcal{D}$ 上的概率分布。在多项式曲线拟合问题中，该分布定义在目标值向量 $\mathbf{t}$ 上，并假设输入值集合 $\mathbf{X}$ 已知。其他类型的模型会对 $\mathbf{X}$ 和 $\mathbf{t}$ 的联合分布进行建模。我们假设数据由这些模型之一生成，但我们并不确定是哪一个。这种不确定性用先验分布 $p(\mathcal{M}_i)$ 来表达。在给定训练集 $\mathcal{D}$ 的情况下，我们希望计算后验分布

$$p(\mathcal{M}_i | \mathcal{D}) \propto p(\mathcal{M}_i)p(\mathcal{D} | \mathcal{M}_i). \quad (3.66)$$

先验允许我们表达对不同模型的偏好。我们可以简单地假设所有模型具有相同的先验概率。更有趣的项是模型证据 $p(\mathcal{D} | \mathcal{M}_i)$ ，它表示数据对不同模型的偏好，我们将稍后更详细地研究这一项。模型证据有时也称为边缘似然，因为它可以被看作模型空间上的似然函数，其中参数已经被边缘化掉。两个模型的模型证据之比 $p(\mathcal{D} | \mathcal{M}_i)/p(\mathcal{D} | \mathcal{M}_j)$ 被称为贝叶斯因子 (Kass and Raftery, 1995)。

一旦我们知道模型的后验分布，根据和法则与积法则，预测分布可写为

$$p(t | \mathbf{x}, \mathcal{D}) = \sum_{i=1}^L p(t | \mathbf{x}, \mathcal{M}_i, \mathcal{D}) p(\mathcal{M}_i | \mathcal{D}) \quad (3.67)$$

这是一个混合分布的例子，其中整体预测分布由各个模型的预测分布 $p(t | \mathbf{x}, \mathcal{M}_i, \mathcal{D})$ 按照其后验概率 $p(\mathcal{M}_i | \mathcal{D})$ 加权求平均得到。例如，如果存在两个后验上同等可能的模型，一个给出在 $t = a$ 附近的窄分布，另一个给出在 $t = b$ 附近的窄分布，那么整体预测分布将是一个在 $t = a$ 和 $t = b$ 处具有两个峰值的双峰分布，而不是在 $t = (a + b)/2$ 处产生一个单峰分布。

对模型平均的一种简单近似是仅使用后验概率最大的模型来进行预测，这称为模型选择。

对于由参数向量 $\mathbf{w}$ 所决定的模型，根据概率的和法则与积法则，模型证据为

$$p(\mathcal{D} | \mathcal{M}_i) = \int p(\mathcal{D} | \mathbf{w}, \mathcal{M}_i) p(\mathbf{w} | \mathcal{M}_i) d\mathbf{w} \quad (3.68)$$

从采样的角度看，边缘似然可以理解为：从先验中随机采样参数后由模型生成数据集 $\mathcal{D}$ 的概率。还值得注意的是，该模型证据正是贝叶斯公式中用于归一化参数后验分布的分母项，因为

$$p(\mathbf{w} | \mathcal{D}, \mathcal{M}_i) = \frac{p(\mathcal{D} | \mathbf{w}, \mathcal{M}_i) p(\mathbf{w} | \mathcal{M}_i)}{p(\mathcal{D} | \mathcal{M}_i)}. \quad (3.69)$$

我们可以通过对参数积分做一个简单近似来理解模型证据。首先考虑只有一个参数 w 的模型。参数的后验分布与 $p(\mathcal{D} | w)p(w)$ 成正比，这里为了简化符号省略模型 $\mathcal{M}_i$ 的依赖。若假设后验在其最可能值 w_{MAP} 附近非常尖锐，宽度为 $\Delta w_{\text{posterior}}$ ，则可将积

分近似为取被积函数在峰值处的函数值乘以该峰的宽度。进一步地，若先验是宽度为 Δw_{prior} 的平坦先验，即 $p(w) = 1/\Delta w_{\text{prior}}$ ，则有


$$p(\mathcal{D}) = \int p(\mathcal{D} | w)p(w)dw \simeq p(\mathcal{D} | w_{\text{MAP}}) \frac{\Delta w_{\text{posterior}}}{\Delta w_{\text{prior}}} \quad (3.70)$$

取对数后得到

$$\ln p(\mathcal{D}) \simeq \ln p(\mathcal{D} | w_{\text{MAP}}) + \ln \left(\frac{\Delta w_{\text{posterior}}}{\Delta w_{\text{prior}}} \right) \quad (3.71)$$

这一近似在图 3.12 中进行了说明。第一项表示由最可能参数值所给出的对数据的拟合，对于平坦先验来说，这一项就对应数似然。第二项根据模型的复杂度对模型进行惩罚。由于 $\Delta w_{\text{posterior}} < \Delta w_{\text{prior}}$ ，因此该项为负，并且随着 $\Delta w_{\text{posterior}}/\Delta w_{\text{prior}}$ 的比例变小而其绝对值增大。于是，如果参数在后验分布中被精细地调整以拟合数据，那么惩罚项将会很大。

图 3.12 如果我们假设参数的后验分布在其模式 w_{MAP} 附近高度尖峰化，那么可以对模型证据做一个粗略近似。



对于具有 M 个参数的模型，可以对每个参数做类似的近似。假设所有参数具有相同的比值 $\Delta w_{\text{posterior}}/\Delta w_{\text{prior}}$ ，则有


$$\ln p(\mathcal{D}) \simeq \ln p(\mathcal{D} | \mathbf{w}_{\text{MAP}}) + M \ln \left(\frac{\Delta w_{\text{posterior}}}{\Delta w_{\text{prior}}} \right) \quad (3.72)$$

因此，在这一非常简单的近似中，复杂度惩罚的大小随模型中自适应参数数量 M 成线性增长。当增加模型复杂度时，第一项通常会减少，因为更复杂的模型能够更好地拟合数据；而第二项由于依赖于 M 而增加。由最大证据确定的最优模型复杂度正是这两个相互竞争项之间的折中。稍后我们将基于后验分布的高斯近似给出一个更精细的版本。

我们可以通过考察图 3.13 来进一步理解贝叶斯模型比较，并理解为何边缘似然会偏好中等复杂度的模型。这里的横轴是一维地表示所有可能数据集的空间，因此横轴上的每一点对应一个具体的数据集。我们考虑三个复杂度逐渐增加的模型 $\mathcal{M}_1, \mathcal{M}_2, \mathcal{M}_3$ 。设想以生成模式运行这些模型以产生数据集，然后观察其生成的数据集的分布。由于参数由先验分布 $p(\mathbf{w})$ 控制，并且在目标变量中可能会有噪声，因此任何模型都可以生成多种不同的数据集。要从一个模型生成一个数据集，我们先从先验中选取参数 $\mathbf{w}$ ，再根据 $p(\mathcal{D} | \mathbf{w})$ 生成数据。一个简单模型（例如一阶多项式）具有较小的变化能力，因此会生成彼此相似的数据集，其分布 $p(\mathcal{D})$ 集中在横轴上的一个较小区域。相比之下，一个

复杂模型（例如九阶多项式）能够生成种类繁多的数据集，因此其 $p(\mathcal{D})$ 分布覆盖横轴的更大范围。由于分布 $p(\mathcal{D} | \mathcal{M}_i)$ 都归一化，因此对于某个特定数据集 $\mathcal{D}_0$ ，中等复杂度的模型会给出最大的模型证据。直观上来说，简单模型无法很好地拟合数据，而复杂模型则将其预测概率分散到过于广阔的数据集范围中，从而对任何具体数据集都赋予较小的概率。

图 3.13 示意图展示了三个不同复杂度模型的数据集分布，其中 $\mathcal{M}_1$ 最简单， $\mathcal{M}_3$ 最复杂。注意这些分布均已归一化。在该示例中，对于特定观测数据集 $\mathcal{D}_0$ ，中等复杂度的模型 $\mathcal{M}_2$ 具有最高的模型证据。



在贝叶斯模型比较框架中隐含着这样一个假设：生成数据的真实分布包含在所考虑模型集合之中。在此条件下，可以证明贝叶斯模型比较平均而言会偏好正确模型。为说明这一点，考虑两个模型 $\mathcal{M}_1$ 和 $\mathcal{M}_2$ ，其中真实模型为 $\mathcal{M}_1$ 。对于给定的有限数据集，贝叶斯因子有可能会偏向错误的模型。然而，如果对数据集的分布取平均，则得到期望的贝叶斯因子，其形式为

$$\int p(\mathcal{D} | \mathcal{M}_1) \ln \frac{p(\mathcal{D} | \mathcal{M}_1)}{p(\mathcal{D} | \mathcal{M}_2)} d\mathcal{D} \quad (3.73)$$

其中平均是相对于数据的真实分布进行的。该量是 Kullback-Leibler 散度的一个例子，具有总为正的性质，只有当两个分布相等时该式才为零。因此，平均而言，贝叶斯因子总是偏好正确模型。

我们已经看到，贝叶斯框架避免了过拟合问题，并允许仅基于训练数据来比较模型。然而，与任何模式识别方法一样，贝叶斯方法也需要对模型形式作出假设，如果这些假设不正确，结果仍可能产生误导。特别地，从图 3.12 中可以看到，模型证据对先验的多个方面（例如尾部行为）可能非常敏感。实际上，如果先验是不适定的，那么证据将无法定义，因为不适定先验具有任意缩放因子（即归一化系数未定义，因为分布无法归一化）。如果我们考虑一个适定先验，并通过取极限使其成为一个不适定先验（例如令高斯先验的方差趋于无穷大），则证据将趋于零，这可以从 (3.70) 和图 3.12 中看出。然而，可以先计算两个模型之间的证据比值，然后再取极限，以得到有意义的结果。

因此，在实际应用中，明智的做法是保留一份独立的测试数据集，用于评估最终系统的整体性能。

3.5 证据近似

在对线性基函数模型进行完全贝叶斯处理时，我们会为超参数 α 和 β 引入先验分布，并通过对这些超参数以及参数 $\mathbf{w}$ 进行边缘化来进行预测。然而，尽管我们可以对 $\mathbf{w}$ 或对超参数中的任一个进行解析积分，但对所有这些变量的完整边缘化在解析上是不可行的。这里我们讨论一种近似方法，在该方法中，我们将超参数设定为特定值，这

些值通过最大化先对参数 $\mathbf{w}$ 积分后得到的边缘似然函数来确定。该框架在统计文献中称为经验贝叶斯 (Bernardo and Smith, 1994; Gelman et al., 2004), 或类型 2 最大似然 (Berger, 1985), 或广义最大似然 (Wahba, 1975), 而在机器学习文献中也称为证据近似 (Gull, 1989; MacKay, 1992a)。

如果我们为 α 和 β 引入超先验, 则预测分布通过对 $\mathbf{w}, \alpha, \beta$ 进行边缘化得到, 因此

$$p(t | \mathbf{t}) = \iiint p(t | \mathbf{w}, \beta), p(\mathbf{w} | \mathbf{t}, \alpha, \beta), p(\alpha, \beta | \mathbf{t}), d\mathbf{w}, d\alpha, d\beta \quad (3.74)$$

其中 $p(t | \mathbf{w}, \beta)$ 由 (3.8) 给出, 而 $p(\mathbf{w} | \mathbf{t}, \alpha, \beta)$ 由 (3.49) 给出, 其中 $\mathbf{m} * N$ 和 $\mathbf{S} * N$ 分别由 (3.53) 和 (3.54) 定义。这里我们为简化符号省略了对输入变量 $\mathbf{x}$ 的依赖。

如果后验分布 $p(\alpha, \beta | \mathbf{t})$ 在某些值 $\hat{\alpha}$ 和 $\hat{\beta}$ 附近高度尖锐, 则预测分布可以通过仅对 $\mathbf{w}$ 进行边缘化并将 α 和 β 固定为 $\hat{\alpha}$ 和 $\hat{\beta}$ 来获得, 因此

$$p(t | \mathbf{t}) \simeq p(t | \mathbf{t}, \hat{\alpha}, \hat{\beta}) = \int p(t | \mathbf{w}, \hat{\beta}), p(\mathbf{w} | \mathbf{t}, \hat{\alpha}, \hat{\beta}), d\mathbf{w} \quad (3.75)$$

根据贝叶斯定理, α 和 β 的后验分布为

$$p(\alpha, \beta | \mathbf{t}) \propto p(\mathbf{t} | \alpha, \beta), p(\alpha, \beta). \quad (3.76)$$

如果先验相对平坦, 则在证据框架中, $\hat{\alpha}$ 和 $\hat{\beta}$ 的取值通过最大化边缘似然函数 $p(\mathbf{t} | \alpha, \beta)$ 来获得。我们将通过对线性基函数模型的边缘似然进行求值并找到其最大值, 从而仅利用训练数据来确定这些超参数, 而无需进行交叉验证。回忆一下, 比值 α/β 起到了类似正则化参数的作用。

顺便指出, 如果我们为 α 和 β 定义共轭先验 (Gamma 分布), 则在式 (3.74) 中对这些超参数的边缘化可以解析完成, 从而在 $\mathbf{w}$ 上得到一个 Student-t 分布 (见 2.3.7 节)。尽管此时对 $\mathbf{w}$ 的积分不再可解析, 但可能会想到用拉普拉斯近似 (见 4.4 节), 即在后验分布的众数附近用局部高斯近似来逼近该积分 (Buntine and Weigend, 1991)。然而, 积分作为 $\mathbf{w}$ 的函数往往具有强烈偏斜的峰形, 拉普拉斯近似无法捕获大部分概率质量, 从而导致结果反而不如最大化证据的方法 (MacKay, 1999)。

回到证据框架, 我们可以采取两种方法来最大化对数证据。其一是对证据函数进行解析求导, 将其对 α 和 β 的偏导设为零, 从而得到重新估计方程, 这将在 3.5.2 节中讨论。另一种方法是使用期望最大化 (EM) 算法, 将在 9.3.4 节中讨论, 并会展示两种方法收敛到相同的解。

3.5.1 证据函数的求值

边缘似然函数 $p(\mathbf{t} | \alpha, \beta)$ 通过对权重参数 $\mathbf{w}$ 积分得到:

$$p(\mathbf{t} | \alpha, \beta) = \int p(\mathbf{t} | \mathbf{w}, \beta), p(\mathbf{w} | \alpha), d\mathbf{w}. \quad (3.77)$$

一种求解该积分的方法是再次利用线性-高斯模型条件分布的结果 (2.115)。这里我们将改为通过配方 (完成平方) 的方法来整理指数, 并使用高斯分布标准归一化系数的形式来求解。

根据 (3.11)、(3.12) 和 (3.52)，我们可以将证据函数写为

$$p(\mathbf{t} | \alpha, \beta) = \left(\frac{\beta}{2\pi}\right)^{N/2} \left(\frac{\alpha}{2\pi}\right)^{M/2} \int \exp -E(\mathbf{w}), d\mathbf{w} \quad (3.78)$$

其中 M 是 $\mathbf{w}$ 的维度，并定义

$$E(\mathbf{w}) = \beta E_D(\mathbf{w}) + \alpha E_W(\mathbf{w}) = \frac{\beta}{2} |\mathbf{t} - \Phi \mathbf{w}|^2 + \frac{\alpha}{2} \mathbf{w}^T \mathbf{w}. \quad (3.79)$$

我们注意到 (3.79) 与正则化平方和误差函数 (3.27) 等价（差一个比例常数）。现在对 $\mathbf{w}$ 完成平方，得到

$$E(\mathbf{w}) = E(\mathbf{m}_N) + \frac{1}{2} (\mathbf{w} - \mathbf{m}_N)^T \mathbf{A} (\mathbf{w} - \mathbf{m}_N) \quad (3.80)$$

这里我们引入了

$$\mathbf{A} = \alpha \mathbf{I} + \beta \Phi^T \Phi \quad (3.81)$$

以及

$$E(\mathbf{m}_N) = \frac{\beta}{2} |\mathbf{t} - \Phi \mathbf{m}_N|^2 + \frac{\alpha}{2} \mathbf{m}_N^T \mathbf{m}_N. \quad (3.82)$$

注意， $\mathbf{A}$ 对应误差函数的二阶导数矩阵

$$\mathbf{A} = \nabla \nabla E(\mathbf{w}) \quad (3.83)$$

称为 Hessian 矩阵。这里我们还定义了 $\mathbf{m}_N$ ，其为

$$\mathbf{m}_N = \beta \mathbf{A}^{-1} \Phi^T \mathbf{t}. \quad (3.84)$$

利用 (3.54)，我们有 $\mathbf{A} = \mathbf{S}_N^{-1}$ ，因此 (3.84) 与先前定义的 (3.53) 等价，从而表示后验分布的均值。

现在对 $\mathbf{w}$ 的积分可以直接利用多元高斯归一化系数的标准结果来计算，得到

$$\begin{aligned} & \int \exp -E(\mathbf{w}) d\mathbf{w} \\ &= \exp -E(\mathbf{m}_N) \int \exp \left\{ -\frac{1}{2} (\mathbf{w} - \mathbf{m}_N)^T \mathbf{A} (\mathbf{w} - \mathbf{m}_N) \right\} d\mathbf{w} \\ &= \exp -E(\mathbf{m}_N) (2\pi)^{M/2} |\mathbf{A}|^{-1/2}. \end{aligned} \quad (3.85)$$

利用 (3.78)，我们可以将边缘似然的对数写成


$$\ln p(\mathbf{t} | \alpha, \beta) = \frac{M}{2} \ln \alpha + \frac{N}{2} \ln \beta - E(\mathbf{m}_N) - \frac{1}{2} \ln |\mathbf{A}| - \frac{N}{2} \ln(2\pi) \quad (3.86)$$

这就是所需的证据函数表达式。

回到多项式回归问题，我们可以将模型证据随多项式阶数的变化绘制出来，如图 3.14 所示。这里我们假设先验具有 (1.65) 的形式，并将参数 α 固定为 $\alpha = 5 \times 10^{-3}$ 。这一图形的形状非常具有启发性。回顾图 1.4，可以看到 $M = 0$ 的多项式对数据拟合非常差，因此其证据值相对较低。将模型提升到 $M = 1$ 时，数据拟合能力大幅提高，因此证

据显著增大。然而，从 $M = 1$ 增加到 $M = 2$ 时，数据拟合仅得到非常微小的改善，这是因为用于生成数据的底层正弦函数是奇函数，因此在多项式展开中没有偶次项。实际上，从图 1.5 可以看到，从 $M = 1$ 到 $M = 2$ 时残差误差仅略微降低。由于更复杂的模型会带来更高的复杂度惩罚，因此在从 $M = 1$ 到 $M = 2$ 的过程中证据反而下降。当我们增加到 $M = 3$ 时，数据拟合又获得了显著改善，如图 1.4 所示，因此证据再次上升，并在多项式模型中达到最大值。继续增大 M 虽然可以带来微小的拟合改进，但复杂度惩罚增长更快，导致证据整体下降。再看图 1.5，可以发现 $M = 3$ 到 $M = 8$ 之间的泛化误差大致相当，仅凭该图很难在这些模型间做出选择。而证据值则清晰地偏好 $M = 3$ ，因为这是最简单且能够很好解释观测数据的模型。

图 3.14 对于多项式回归模型，绘制模型证据随阶数 M 变化的曲线，可以看到证据偏好于 $M = 3$ 的模型。



3.5.2 证据函数的最大化

首先考虑对 α 最大化 $p(\mathbf{t} | \alpha, \beta)$ 。为此，先定义如下特征向量方程

$$(\beta \Phi^T \Phi) \mathbf{u}_i = \lambda_i \mathbf{u}_i. \quad (3.87)$$

由 (3.81) 可知， $\mathbf{A}$ 的特征值为 $\alpha + \lambda_i$ 。现在考虑 (3.86) 中含有 $\ln |\mathbf{A}|$ 的那一项对 α 的导数。有

$$\frac{d}{d\alpha} \ln |\mathbf{A}| = \frac{d}{d\alpha} \ln \prod_i (\lambda_i + \alpha) = \frac{d}{d\alpha} \sum_i \ln(\lambda_i + \alpha) = \sum_i \frac{1}{\lambda_i + \alpha}. \quad (3.88)$$

因此，(3.86) 关于 α 的驻点满足

$$0 = \frac{M}{2\alpha} - \frac{1}{2} \mathbf{m}_N^T \mathbf{m}_N - \frac{1}{2} \sum_i \frac{1}{\lambda_i + \alpha}. \quad (3.89)$$

两边同乘以 2α 并整理，得到

$$\alpha \mathbf{m}_N^T \mathbf{m}_N = M - \alpha \sum_i \frac{1}{\lambda_i + \alpha} = \gamma. \quad (3.90)$$

由于对 i 的求和有 M 项，量 γ 可写为

$$\gamma = \sum_i \frac{\lambda_i}{\alpha + \lambda_i}. \quad (3.91)$$

关于 γ 的解释将很快讨论。由 (3.90) 可见，使边缘似然达到最大值的 α 满足

$$\alpha = \frac{\gamma}{\mathbf{m}_N^T \mathbf{m}_N}. \quad (3.92)$$

注意，这实际上是关于 α 的隐式解，不仅因为 γ 依赖于 α ，而且因为后验分布的众数 $\mathbf{m}_N$ 本身也依赖于 α 的取值。因此，我们采用一种迭代过程：首先为 α 选择一个初始值，并利用 (3.53) 求得 $\mathbf{m}_N$ ，然后利用 (3.91) 计算 γ 。接着利用 (3.92) 重新估计 α ，并重复这一过程直到收敛。由于矩阵 $\Phi^T \Phi$ 是固定的，我们可以在开始时一次性计算出它的特征值，并通过乘以 β 来得到 λ_i 。

需要强调的是， α 的取值完全由训练数据决定。与最大似然方法不同，这里不需要使用独立的数据集来优化模型复杂度。

类似地，我们也可以对 β 最大化对数边缘似然 (3.86)。为此，注意到由 (3.87) 定义的特征值 λ_i 与 β 成正比，因此 $d\lambda_i/d\beta = \lambda_i/\beta$ ，从而得到

$$\frac{d}{d\beta} \ln |\mathbf{A}| = \frac{d}{d\beta} \sum_i \ln(\lambda_i + \alpha) = \frac{1}{\beta} \sum_i \frac{\lambda_i}{\lambda_i + \alpha} = \frac{\gamma}{\beta}. \quad (3.93)$$

因此，边缘似然的驻点满足

$$0 = \frac{N}{2\beta} - \frac{1}{2} \sum_{n=1}^N t_n - \mathbf{m}_N^T \phi(\mathbf{x}_n)^2 - \frac{\gamma}{2\beta}. \quad (3.94)$$

整理后得到


$$\frac{1}{\beta} = \frac{1}{N - \gamma} \sum_{n=1}^N t_n - \mathbf{m}_N^T \phi(\mathbf{x}_n)^2. \quad (3.95)$$

同样地，这是关于 β 的隐式解，可以通过首先选择 β 的初值，然后利用其计算 $\mathbf{m}_N$ 和 γ ，再通过 (3.95) 重新估计 β ，重复迭代直到收敛。如果要同时从数据中确定 α 和 β ，那么在每次更新 γ 后可以同时重新估计它们。

3.5.3 有效参数个数

结果 (3.92) 有一个优雅的解释 (MacKay, 1992a)，它为理解关于 α 的贝叶斯解提供了洞见。为此，考虑如图 3.15 所示的似然函数和先验的等高线。在这里，我们隐含地将参数空间转换到由 (3.87) 中定义的特征向量 $\mathbf{u}_i$ 对齐的旋转坐标系。在该坐标系中，似然函数的等高线是轴对齐的椭圆。特征值 λ_i 衡量似然函数的曲率，因此在图 3.15 中，特征值 λ_1 相对于 λ_2 较小（因为较小的曲率对应于似然等高线的较大拉伸）。由于 $\beta \Phi^T \Phi$ 是一个正定矩阵，它具有正特征值，因此比值 $\lambda_i/(\lambda_i + \alpha)$ 将位于 0 和 1 之间。于是，由 (3.91) 定义的数量 γ 将服从 $0 \leq \gamma \leq M$ 。对于满足 $\lambda_i \gg \alpha$ 的方向，相应的参数 w_i 将接近其最大似然值，并且比值 $\lambda_i/(\lambda_i + \alpha)$ 将接近 1。这样的参数称为确定良好的参数，因为它们的值被数据严格约束。相反，对于满足 $\lambda_i \ll \alpha$ 的方向，相应的参数 w_i 将接近于零，且比值 $\lambda_i/(\lambda_i + \alpha)$ 也接近零。这些方向对应的是似然函数对参数值相对不敏感的

图 3.15 似然函数的等高线（红色）与先验（绿色），其中参数空间的坐标轴经过旋转以与 Hessian 的特征向量 $\mathbf{u}_i$ 对齐。当 $\alpha = 0$ 时，后验的模式为最大似然解 $\mathbf{w}_{\text{ML}}$ ；而当 α 非零时，模式位于 $\mathbf{w}_{\text{MAP}} = \mathbf{m}_N$ 。在 w_1 方向上，特征值 λ_1 （定义见式 (3.87)）与 α 相比很小，所以 $\lambda_1/(\lambda_1 + \alpha)$ 接近零，相应的 w_1 的 MAP 值也接近零。相比之下，在 w_2 方向上，特征值 λ_2 与 α 相比很大，因此 $\lambda_2/(\lambda_2 + \alpha)$ 接近 1， w_2 的 MAP 值接近其最大似然值。



情况，因此参数值被先验压缩到较小。由此可知，(3.91) 定义的 γ 衡量了有效的、被良好确定的参数个数之和。

我们通过将 (3.95) 与最大似然情况下的结果 (3.21) 进行比较，可以获得对重新估计 β 结果的进一步理解。这两个公式都将方差（或精度的倒数）表示为目标值与模型预测之间平方差的平均。然而，它们的区别在于，最大似然结果分母中的数据点个数 N 在贝叶斯结果中被 $N - \gamma$ 所取代。我们从 (1.56) 回忆，高斯分布下单变量 x 的最大似然方差估计为

$$\sigma_{\text{ML}}^2 = \frac{1}{N} \sum_{n=1}^N (x_n - \mu_{\text{ML}})^2 \quad (3.96)$$

并且该估计是有偏的，因为最大似然解 μ_{ML} 对数据中的噪声进行了拟合。本质上，这相当于在模型中使用了一个自由度。对应的无偏估计由 (1.59) 给出，其形式为

$$\sigma_{\text{MAP}}^2 = \frac{1}{N-1} \sum_{n=1}^N (x_n - \mu_{\text{ML}})^2. \quad (3.97)$$

我们将在第 10.1.3 节中看到，可以通过对未知均值进行边缘化的贝叶斯处理得到这一结果。贝叶斯结果分母中的 $N - 1$ 因子考虑到在拟合均值时使用了一个自由度，从而消除了最大似然的偏差。现在考虑线性回归模型的对应结果。此时目标分布的均值由函数 $\mathbf{w}^T \phi(\mathbf{x})$ 给出，它包含 M 个参数。然而，并不是所有这些参数都被数据所调节。由数据决定的有效参数个数为 γ ，剩余的 $M - \gamma$ 个参数则因为先验而被压缩到较小的值。这体现在贝叶斯的方差结果中，其分母包含 $N - \gamma$ ，从而校正了最大似然结果的偏差。

我们可以使用第 1.1 节中的正弦合成数据集，并采用包含 9 个高斯基函数的模型来说明用于设置超参数的证据框架，因此模型中的参数总数（包括偏置）为 $M = 10$ 。在这里，为了简化说明，我们将 β 固定为其真实值 11.1，然后使用证据框架来确定 α ，如图 3.16 所示。

我们还可以通过绘制各个参数 w_i 随有效参数个数 γ 的变化情况，来看出超参数 α 是如何控制参数大小的，如图 3.17 所示。

如果考虑极限 $N \gg M$ ，即数据点数量远大于参数数量，那么根据 (3.87)，所有参数都会被数据很好地确定，因为 $\Phi^T \Phi$ 中隐含了对数据点的求和，因此特征值 λ_i 会随着





图 3.16 左图展示了对于合成正弦数据集， γ （红色曲线）以及 $2\alpha E_W(\mathbf{m}_N)$ （蓝色曲线）随 $\ln \alpha$ 的变化。两条曲线的交点给出了由证据方法确定的最优 α 值。右图展示了对应的对数证据 $\ln p(\mathbf{t} | \alpha, \beta)$ 随 $\ln \alpha$ 的曲线（红色），可以看到其峰值与左图中两曲线的交点一致。同时绘出了测试集误差（蓝色曲线），显示证据最大值的位置与最佳泛化点非常接近。

图 3.17 对高斯基函数模型中的 10 个参数 w_i 随有效参数数量 γ 变化的绘图，其中超参数 α 在 $0 \leq \alpha \leq \infty$ 范围内变化，从而使 γ 在 $0 \leq \gamma \leq M$ 范围内变化。



数据集的规模增长而变大。在这种情况下，有 $\gamma = M$ ，于是 α 和 β 的重新估计方程变为

$$\alpha = \frac{M}{2E_W(\mathbf{m}_N)} \quad (3.98)$$

$$\beta = \frac{N}{2E_D(\mathbf{m}_N)} \quad (3.99)$$

其中 E_W 和 E_D 分别由 (3.25) 和 (3.26) 定义。由于这一结果不需要计算 Hessian 的特征值谱，因此可以作为完整证据重估公式的易计算近似。

3.6 固定基函数的局限性

在本章中，我们一直关注由固定的非线性基函数的线性组合构成的模型。我们已经看到，对参数的线性假设带来了许多有用的性质，包括最小二乘问题的闭式解以及可处理的贝叶斯推断过程。此外，对于合适选择的基函数，我们可以对输入变量到目标之间的任意非线性映射进行建模。在下一章中，我们将研究用于分类的一类类似模型。

因此，看起来这类线性模型可以构成解决模式识别问题的通用框架。然而，不幸的是，线性模型存在一些显著的缺点，这将导致我们在后续章节中转向更复杂的模型，比如支持向量机和神经网络。

问题出在这样一个假设：基函数 $\phi_j(\mathbf{x})$ 在观察到训练数据之前就是固定的，而这实

际上是第 1.4 节中讨论的维度灾难的一种表现。其结果是，基函数的数量需要随着输入空间维度 D 的增加而迅速增长，通常是指数级增长。

幸运的是，真实数据集具有两个可以利用来缓解该问题的性质。首先，数据向量 $\mathbf{x}_n$ 通常由于输入变量之间存在强相关性，而接近于一个低维的非线性流形，其内在维度小于输入空间的维度。当我们使用局部化基函数时，我们可以将它们仅分布在包含数据的输入空间区域中。这一策略被用于径向基函数网络（RBF networks）、支持向量机（SVM）以及相关向量机（RVM）中。神经网络模型使用具有 S 型非线性的自适应基函数，可以让基函数的作用区域与数据流形相匹配。第二个性质是目标变量可能仅依赖于数据流形中的少数几个方向。神经网络可以通过自动选择基函数响应的输入空间方向来利用这一性质。

4 线性分类模型

在上一章中，我们研究了一类具有特别简单的解析与计算性质的回归模型。现在我们讨论一类用于解决分类问题的类似模型。分类的目标是给定一个输入向量 $\mathbf{x}$ ，将其归入 K 个离散类别 $\mathcal{C}_k$ 中的某一个，其中 $k = 1, \dots, K$ 。最常见的情形中，这些类别是互斥的，因此每个输入只能被分到唯一一个类别。这样输入空间被划分为若干决策区域，其边界称为决策边界或决策面。在本章中，我们考虑线性分类模型，即决策面是输入向量 $\mathbf{x}$ 的线性函数，因此在 D 维输入空间中由 $(D - 1)$ 维超平面所定义。若一个数据集的类别可以被线性决策面完全分开，则称该数据集是线性可分的。

在回归问题中，目标变量 $\mathbf{t}$ 是我们希望预测的一组实数；而在分类问题中，有多种方式可以利用目标值来表示类别标签。对于概率模型，在二分类问题中最方便的方法是使用二元表示，即令单一目标变量 $t \in 0, 1$ ，其中 $t = 1$ 代表类别 $\mathcal{C}_1$ ， $t = 0$ 代表类别 $\mathcal{C}_2$ 。我们可以将 t 的取值解释为属于类别 $\mathcal{C}_1$ 的概率，只不过此时概率只能取 0 或 1 的极值。当 $K > 2$ 时，我们使用 1-of- K 编码，即令 $\mathbf{t}$ 为长度为 K 的向量，如果类别为 $\mathcal{C}_j$ ，则向量中除 $t_j = 1$ 外其余分量 t_k 全部为 0。例如，若 $K = 5$ ，且样本属于类别 2，则其目标向量为

$$\mathbf{t} = (0, 1, 0, 0, 0)^T \quad (4.1)$$

我们同样可以将 t_k 理解为输入属于类别 $\mathcal{C}_k$ 的概率。而对于非概率模型，有时使用不同形式的类别标签表示会更加便利。

在第 1 章中，我们已经识别出三种不同的分类问题求解方法。最简单的一种是构造一个判别函数，它直接将每个向量 $\mathbf{x}$ 分配到一个特定的类别中。然而，更强大的方法是先在推断阶段对条件概率分布 $p(\mathcal{C}_k | \mathbf{x})$ 建模，然后再使用该分布进行最优决策。通过将推断和决策分离，我们可以获得许多好处，正如在 1.5.4 节中所讨论的。对条件概率 $p(\mathcal{C}_k | \mathbf{x})$ 有两种不同的处理方法。其中一种技术是直接对其建模，例如将它们表示为参数模型并使用训练集来优化这些参数。另一种方法是采用生成式方法，在该方法中我们对类条件密度 $p(\mathbf{x} | \mathcal{C}_k)$ 以及类的先验概率 $p(\mathcal{C}_k)$ 建模，然后使用贝叶斯定理计算所需的后验概率：

$$p(\mathcal{C}_k | \mathbf{x}) = \frac{p(\mathbf{x} | \mathcal{C}_k)p(\mathcal{C}_k)}{p(\mathbf{x})}. \quad (4.2)$$

在本章中，我们将讨论这三种方法的例子。

在线性回归模型中（第 3 章中讨论），模型预测 $y(\mathbf{x}, \mathbf{w})$ 由参数 $\mathbf{w}$ 的线性函数给出。在最简单的情况下，模型在输入变量上也是线性的，因此具有形式 $y(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + w_0$ ，于是 y 是一个实数。然而，对于分类问题，我们希望预测的是离散的类别标签，或者更一般地说，是位于区间 $(0, 1)$ 的后验概率。为了实现这一点，我们将线性函数通过一个非线性函数 $f(\cdot)$ 进行变换，因此

$$y(\mathbf{x}) = f(\mathbf{w}^T \mathbf{x} + w_0). \quad (4.3)$$

在机器学习文献中， $f(\cdot)$ 被称为激活函数，而在统计文献中，其逆函数被称为链接函数。决策边界对应于 $y(\mathbf{x}) = \text{constant}$ ，因此 $\mathbf{w}^T \mathbf{x} + w_0 = \text{constant}$ ，于是即使函数 $f(\cdot)$

是非线性的，决策边界仍然是输入 $\mathbf{x}$ 的线性函数。因此，由式 (4.3) 描述的这一类模型被称为广义线性模型 (McCullagh and Nelder, 1989)。然而需要注意的是，与用于回归的模型不同，由于存在非线性函数 $f(\cdot)$ ，这些模型在参数上不再是线性的。这将导致比线性回归模型更复杂的分析和计算性质。然而，与我们将在后续章节中研究的更一般的非线性模型相比，这些模型仍然相对简单。

本章讨论的算法同样适用于我们首先使用一组基函数 $\phi(\mathbf{x})$ 对输入变量进行固定的非线性变换的情况，就像我们在第 3 章回归模型中所做的那样。我们首先直接在原始输入空间 $\mathbf{x}$ 中考虑分类问题，而在第 4.3 节中，为了与后续章节保持一致，我们将发现使用涉及基函数的符号表示会更加方便。

4.1 判别函数

判别函数是一个将输入向量 $\mathbf{x}$ 分配到 K 个类别之一的函数，这些类别记为 $\mathcal{C}_k$ 。在本章中，我们将关注线性判别函数，也就是那些决策面为超平面的判别方法。为了简化讨论，我们首先考虑两类的情形，然后再研究扩展到 $K > 2$ 类的情况。

4.1.1 二分类

最简单的线性判别函数形式是对输入向量取线性函数：


$$y(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + w_0 \quad (4.4)$$

其中 $\mathbf{w}$ 称为权重向量， w_0 称为偏置（不要与统计学意义上的偏差混淆）。偏置的相反数有时也称为阈值。如果对点 $\mathbf{x}$ 有 $y(\mathbf{x}) \geq 0$ ，则将其判为类别 $\mathcal{C}_1$ ；否则判为 $\mathcal{C}_2$ 。因此，决策边界由 $y(\mathbf{x}) = 0$ 定义，对应于 D 维输入空间中的一个 $D - 1$ 维超平面。设有两个点 $\mathbf{x}_A$ 和 $\mathbf{x}_B$ 都位于该决策边界上。由于 $y(\mathbf{x}_A) = y(\mathbf{x}_B) = 0$ 因此 $\mathbf{w}^T(\mathbf{x}_A - \mathbf{x}_B) = 0$ 说明向量 $\mathbf{w}$ 与决策超平面内任何向量都正交，因此 $\mathbf{w}$ 决定了决策面的方向。同样地，如果 $\mathbf{x}$ 是决策面上的点，则 $y(\mathbf{x}) = 0$ ，于是决策面到原点的法向距离为：

$$\frac{\mathbf{w}^T \mathbf{x}}{\|\mathbf{w}\|} = -\frac{w_0}{\|\mathbf{w}\|} \quad (4.5)$$

因此偏置 w_0 决定了决策面的平移位置。在 $D = 2$ 的情形中，这些性质如图 4.1 所示。

图 4.1 二维情况下线性判别函数的几何示意图。决策面（红色）与向量 $\mathbf{w}$ 垂直，其相对于原点的偏移由偏置参数 w_0 控制。另外，任一点 $\mathbf{x}$ 到决策面的带符号正交距离为 $y(\mathbf{x})/\|\mathbf{w}\|$ 。



此外, $y(\mathbf{x})$ 的值还给出了点 $\mathbf{x}$ 到决策面的符号化垂直距离 r 。为看到这一点, 考虑任意一点 $\mathbf{x}$, 并设其在决策面上的正交投影为 $\mathbf{x}_\perp$, 则有:

$$\mathbf{x} = \mathbf{x}_\perp + r \frac{\mathbf{w}}{|\mathbf{w}|} \quad (4.6)$$

将该结果两边同时左乘 $\mathbf{w}^T$ 并加上 w_0 , 并利用 $y(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + w_0$ 以及 $y(\mathbf{x} * \perp) = \mathbf{w}^T \mathbf{x} * \perp + w_0 = 0$, 我们得到

$$r = \frac{y(\mathbf{x})}{|\mathbf{w}|} \quad (4.7)$$

该结果如图 4.1 所示。

如同第 3 章中的线性回归模型一样, 有时使用一种更紧凑的记号会更为方便, 即我们引入一个额外的虚拟“输入”值 $x_0 = 1$, 然后定义 $\tilde{\mathbf{w}} = (w_0, \mathbf{w})$ 和 $\tilde{\mathbf{x}} = (x_0, \mathbf{x})$, 从而

$$y(\mathbf{x}) = \tilde{\mathbf{w}}^T \tilde{\mathbf{x}} \quad (4.8)$$

在这种情况下, 决策面是在扩展输入空间中经过原点的 $D+1$ 维超平面, 对应于原始 D 维空间中的超平面。

4.1.2 多类别情形

现在考虑将线性判别扩展到 $K > 2$ 个类别的情况。我们可能会倾向于通过组合若干个二分类判别函数来构建一个 K 类判别器。然而, 这种做法会导致一些严重的问题 (Duda 和 Hart, 1973), 如下所示。

考虑使用 $K-1$ 个分类器, 每个分类器解决一个将某个特定类别 $\mathcal{C}_k$ 与不属于该类别的点分开的二分类问题。这被称为一对其余 (one-versus-the-rest) 分类器。图 4.2 左侧的例子展示了一个包含三个类别的情况, 在这种方法下输入空间中会出现分类结果不明确区域。

另一种方法是为每一对可能的类别引入 $K(K-1)/2$ 个二元判别函数。这称为一对一 (one-versus-one) 分类器。然后根据这些判别函数的多数投票结果将每个点进行分类。然而, 这种方法同样会出现分类模糊区域的问题, 如图 4.2 右侧图所示。

我们可以通过考虑一个由 K 个线性函数组成的单一 K 类判别来避免这些困难, 其形式为

$$y_k(\mathbf{x}) = \mathbf{w}_k^T \mathbf{x} + w_{k0} \quad (4.9)$$

然后对于点 $\mathbf{x}$, 如果 $y_k(\mathbf{x}) > y_j(\mathbf{x})$ 对所有 $j \neq k$ 都成立, 则将 $\mathbf{x}$ 判为类别 $\mathcal{C}_k$ 。因此, 类别 $\mathcal{C}_k$ 和类别 $\mathcal{C}_j$ 之间的决策边界由 $y_k(\mathbf{x}) = y_j(\mathbf{x})$ 给出, 从而对应如下定义的 $(D-1)$ 维超平面

$$-(\mathbf{w}_k - \mathbf{w}_j)^T \mathbf{x} + (w_{k0} - w_{j0}) = 0 \quad (4.10)$$

这与第 4.1.1 节讨论的二分类情况下的决策边界形式相同, 因此可以得到类似的几何性质。





图 4.2 试图利用多个二类判别函数来构造一个 K 类判别器会产生如绿色区域所示的歧义。左图示例展示了两个判别函数，它们用于区分属于类别 C_k 的点与不属于 C_k 的点。右图示例展示了三个判别函数，每个用于区分一对类别 C_k 与 C_j 。

图 4.3 多类别线性判别的决策区域示意图，决策边界以红色显示。如果两个点 $\mathbf{x}_A$ 和 $\mathbf{x}_B$ 都位于同一决策区域 $\mathcal{R}_k$ 内，那么连接这两点的直线上任意一点 $\mathbf{x}$ 也必然位于 $\mathcal{R}_k$ 。因此，决策区域必须是单连通且凸的。



这种判别器的决策区域总是单连通且凸的。为说明这一点，考虑两个点 $\mathbf{x}_A$ 和 $\mathbf{x}_B$ ，它们都位于决策区域 $\mathcal{R}_k$ 内，如图 4.3 所示。连接 $\mathbf{x}_A$ 与 $\mathbf{x}_B$ 的直线上的任意点 $\hat{\mathbf{x}}$ 都可以表示为

$$\hat{\mathbf{x}} = \lambda \mathbf{x}_A + (1 - \lambda) \mathbf{x}_B \quad (4.11)$$

其中 $0 \leq \lambda \leq 1$ 。由判别函数的线性性质可知，

$$y_k(\hat{\mathbf{x}}) = \lambda y_k(\mathbf{x}_A) + (1 - \lambda) y_k(\mathbf{x}_B) \quad (4.12)$$

由于 $\mathbf{x}_A$ 和 $\mathbf{x}_B$ 都位于 $\mathcal{R}_k$ 内，因此对于所有 $j \neq k$ ，都有 $y_k(\mathbf{x}_A) > y_j(\mathbf{x}_A)$ ，以及 $y_k(\mathbf{x}_B) > y_j(\mathbf{x}_B)$ ，于是可得 $y_k(\hat{\mathbf{x}}) > y_j(\hat{\mathbf{x}})$ ，从而 $\hat{\mathbf{x}}$ 也位于 $\mathcal{R}_k$ 内。因此， $\mathcal{R}_k$ 是单连通且凸的。

注意，对于二分类问题，我们可以使用此处基于两个判别函数 $y_1(\mathbf{x})$ 和 $y_2(\mathbf{x})$ 的形式主义，或者使用第 4.1.1 节中基于单一判别函数 $y(\mathbf{x})$ 的更简单但等价的公式。

接下来我们将讨论三种用于学习线性判别函数参数的方法，分别基于最小二乘、Fisher 线性判别以及感知机算法。

4.1.3 用最小二乘法进行分类

在第3章中，我们讨论了参数的线性函数模型，并看到通过最小化平方和误差函数可以得到参数值的一个简单的闭式解。因此，我们可能会倾向于尝试将同样的形式主义应用于分类问题。考虑一个具有 K 个类别的一般分类问题，采用 1-of- K 的二元编码方案来表示目标向量 $\mathbf{t}$ 。在这种情形下使用最小二乘的一种理由是，它近似了给定输入向量后的目标值的条件期望 $\mathbb{E}[\mathbf{t} | \mathbf{x}]$ 。对于二元编码方案，这个条件期望由后验类别概率向量给出。然而，不幸的是，由于线性模型灵活性有限，这些概率通常被近似得很差，实际上这些近似甚至可能超出区间 $(0, 1)$ ，这一点我们很快就会看到。

每个类别 C_k 都由其自己的线性模型描述，因此

$$y_k(\mathbf{x}) = \mathbf{w}_k^T \mathbf{x} + w_{k0} \quad (4.13)$$

其中 $k = 1, \dots, K$ 。我们可以使用向量表示将它们方便地组合在一起：

$$\mathbf{y}(\mathbf{x}) = \tilde{\mathbf{W}}^T \tilde{\mathbf{x}} \quad (4.14)$$

其中 $\tilde{\mathbf{W}}$ 是一个矩阵，其第 k 列为 $D+1$ 维向量 $\tilde{\mathbf{w}}_k = (w_{k0}, \mathbf{w}_k^T)^T$ ，而 $\tilde{\mathbf{x}}$ 是相应的增广输入向量 $(1, \mathbf{x}^T)^T$ ，其中包含一个虚拟输入 $x_0 = 1$ 。这种表示法已在第3.1节中详细讨论。对新的输入 $\mathbf{x}$ ，我们将其分配给使输出 $y_k = \tilde{\mathbf{w}}_k^T \tilde{\mathbf{x}}$ 最大的类别。

现在我们像第3章回归那样，通过最小化平方和误差函数来确定参数矩阵 $\tilde{\mathbf{W}}$ 。考虑一个训练数据集 $\{\mathbf{x}_n, \mathbf{t}_n\}$ ，其中 $n = 1, \dots, N$ ，并定义矩阵 $\mathbf{T}$ ，其第 n 行为向量 $\mathbf{t}_n^T$ ，以及矩阵 $\tilde{\mathbf{X}}$ ，其第 n 行为 $\tilde{\mathbf{x}}_n^T$ 。则平方和误差函数可写为

$$E_D(\tilde{\mathbf{W}}) = \frac{1}{2} \text{Tr} \left\{ (\tilde{\mathbf{X}}\tilde{\mathbf{W}} - \mathbf{T})^T (\tilde{\mathbf{X}}\tilde{\mathbf{W}} - \mathbf{T}) \right\}. \quad (4.15)$$

将对 $\tilde{\mathbf{W}}$ 的导数设为零并整理后，可得 $\tilde{\mathbf{W}}$ 的解为

$$\tilde{\mathbf{W}} = (\tilde{\mathbf{X}}^T \tilde{\mathbf{X}})^{-1} \tilde{\mathbf{X}}^T \mathbf{T} = \tilde{\mathbf{X}}^\dagger \mathbf{T} \quad (4.16)$$

其中 $\tilde{\mathbf{X}}^\dagger$ 为矩阵 $\tilde{\mathbf{X}}$ 的伪逆，见第3.1.1节。于是可得判别函数为

$$\mathbf{y}(\mathbf{x}) = \tilde{\mathbf{W}}^T \tilde{\mathbf{x}} = \mathbf{T}^T (\tilde{\mathbf{X}}^\dagger)^T \tilde{\mathbf{x}} \quad (4.17)$$

关于具有多个目标变量的最小二乘解，有一个有趣的性质：如果训练集中每个目标向量都满足某个线性约束

$$\mathbf{a}^T \mathbf{t}_n + b = 0 \quad (4.18)$$

其中 $\mathbf{a}$ 和 b 为常数，那么对于任意 $\mathbf{x}$ ，模型的预测同样满足该约束，即

$$\mathbf{a}^T \mathbf{y}(\mathbf{x}) + b = 0. \quad (4.19)$$

因此，如果对 K 个类别使用 1-of- K 的编码方案，那么模型给出的预测将具有这样一个性质：对于任意的 $\mathbf{x}$ ， $\mathbf{y}(\mathbf{x})$ 的各个元素之和都等于 1。然而，仅有这个求和约束还不足以使模型输出能够被解释为概率，因为它们并没有被限制在区间 $(0, 1)$ 内。




图 4.4 左图展示了来自两个类别的数据，分别用红色叉号和蓝色圆点表示，同时给出了最小二乘法得到的决策边界（品红色曲线）以及逻辑回归模型得到的决策边界（绿色曲线，关于该模型的讨论见第 4.3.2 节）。右图展示了在图左下方添加额外数据点后的结果，可以看到最小二乘法对离群点极为敏感，而逻辑回归则不然。

最小二乘法为判别函数参数提供了精确的闭式解。然而，即使将其仅作为判别函数来直接作出分类决策（而不去做概率解释），该方法仍然存在一些严重问题。我们已经看到，最小二乘解对离群点缺乏鲁棒性，这一点在分类应用中同样成立，如图 4.4 所示。从图中可以看到，在右图中额外的数据点使得决策边界发生了显著的变化，尽管这些点在左图中原有的决策边界下本可以被正确分类。平方和误差函数会惩罚“过于正确”的预测，即那些落在决策边界正确一侧且距离较远的点。在第 7.1.2 节中，我们将讨论几种用于分类的替代误差函数，并会看到它们不会出现这种问题。

然而，最小二乘法的问题甚至比缺乏鲁棒性更为严重，如图 4.5 所示。该图展示了一个三类的人工数据集，输入空间为二维 (x_1, x_2) ，并且线性决策边界能够很好地分离各类别。实际上，本章后面介绍的逻辑回归方法就能得到很令人满意的结果，如右图所示。然而，最小二乘解却表现不佳，输入空间中只有很小的区域被判为绿色类别。

最小二乘法的失败并不令人意外，因为我们回忆到它对应于假设条件分布为高斯分布下的最大似然解，而二元目标向量显然具有与高斯分布相差甚远的分布特性。通过采用更合适的概率模型，我们将会得到比最小二乘法性质优良得多的分类技术。然而，目前我们将继续探讨用于为线性分类模型设定参数的其他非概率方法。

4.1.4 Fisher 线性判别

一种理解线性分类模型的方法是将其视为一种降维手段。首先考虑两类的情形，假设我们将 D 维输入向量 $\mathbf{x}$ 投影到一维空间：

$$y = \mathbf{w}^T \mathbf{x}. \quad (4.20)$$

如果我们对 y 设置一个阈值，将 $y \geq -w_0$ 判为类别 C_1 ，否则判为类别 C_2 ，那么就




图 4.5 一个由三个类别组成的合成数据集示例，训练数据点分别用红色 (×)、绿色 (+) 和蓝色 (o) 表示。线条表示决策边界，背景颜色表示各决策区域所属的类别。左图为使用最小二乘判别的结果，可以看到分配给绿色类别的输入空间区域过小，因而该类别的大多数点被误分类。右图为采用第 4.3.2 节所述的逻辑回归方法的结果，训练数据均得到正确分类。

得到了上一节讨论的标准线性分类器。一般而言，将数据投影到一维会导致信息的大量丢失，原本在 D 维空间中分离良好的类别在一维上可能会强烈重叠。然而，通过调整权向量 $\mathbf{w}$ 的分量，我们可以选择一个投影，使得类别间的分离程度最大。

首先考虑一个两类问题，其中类别 C_1 有 N_1 个样本，类别 C_2 有 N_2 个样本，则两个类别的均值向量为

$$\mathbf{m}_1 = \frac{1}{N_1} \sum_{n \in C_1} \mathbf{x}_n, \quad \mathbf{m}_2 = \frac{1}{N_2} \sum_{n \in C_2} \mathbf{x}_n. \quad (4.21)$$

在投影到 $\mathbf{w}$ 后，类别之间最简单的分离度量是投影后的类别均值之差。这提示我们可以选择 $\mathbf{w}$ 来最大化

$$m_2 - m_1 = \mathbf{w}^T (\mathbf{m}_2 - \mathbf{m}_1), \quad (4.22)$$

其中

$$m_k = \mathbf{w}^T \mathbf{m}_k \quad (4.23)$$

是类别 C_k 投影后数据的均值。然而，这个表达式可以通过增大 $\mathbf{w}$ 的长度而任意放大。为解决这个问题，我们可以约束 $\mathbf{w}$ 的长度为 1，即 $\sum_i w_i^2 = 1$ 。使用拉格朗日乘子法进行约束最大化，可得 $\mathbf{w} \propto (\mathbf{m}_2 - \mathbf{m}_1)$ 。

然而，这种方法仍然存在问题，如图 4.6 所示。图中两个类别在二维空间 (x_1, x_2) 中分离良好，但在投影到连接其均值的直线后出现了明显的重叠。这一问题来自类别分布具有强非对角协方差结构。Fisher 提出的思想是最大化一个函数，该函数不仅使投影后的类别均值分离较大，而且使每个类别内部的投影方差较小，从而减少类别间的重叠。

投影公式 (4.20) 将带标签的数据点集合 $\mathbf{x}$ 映射到一维空间 y 中的带标签数据集合。因此，类别 C_k 的投影数据的类内方差为

$$s_k^2 = \sum_{n \in C_k} (y_n - m_k)^2 \quad (4.24)$$




图 4.6 左图展示了来自两个类别的样本（以红色和蓝色表示），以及将数据投影到连接类别均值的直线后得到的直方图。可以看到在投影空间中类别之间存在显著重叠。右图展示了基于 Fisher 线性判别的对应投影，类别分离效果显著提升。

其中 $y_n = \mathbf{w}^T \mathbf{x}_n$ 。我们可以将整个数据集的类内总方差简单地定义为 $s_1^2 + s_2^2$ 。Fisher 判别准则定义为类间方差与类内方差之比，表示为

$$J(\mathbf{w}) = \frac{(m_2 - m_1)^2}{s_1^2 + s_2^2}. \quad (4.25)$$

利用 (4.20)、(4.23) 和 (4.24)，可以将 Fisher 判别准则中对 $\mathbf{w}$ 的依赖显式改写为

$$J(\mathbf{w}) = \frac{\mathbf{w}^T \mathbf{S}_B \mathbf{w}}{\mathbf{w}^T \mathbf{S}_W \mathbf{w}} \quad (4.26)$$

其中 $\mathbf{S}_B$ 是类间协方差矩阵，给出为

$$\mathbf{S}_B = (\mathbf{m}_2 - \mathbf{m}_1)(\mathbf{m}_2 - \mathbf{m}_1)^T \quad (4.27)$$

而 $\mathbf{S}_W$ 是总类内协方差矩阵，给出为

$$\mathbf{S}_W = \sum_{n \in \mathcal{C}_1} (\mathbf{x}_n - \mathbf{m}_1)(\mathbf{x}_n - \mathbf{m}_1)^T + \sum_{n \in \mathcal{C}_2} (\mathbf{x}_n - \mathbf{m}_2)(\mathbf{x}_n - \mathbf{m}_2)^T. \quad (4.28)$$

对 (4.26) 式关于 $\mathbf{w}$ 求导，我们发现当满足以下条件时， $J(\mathbf{w})$ 达到最大值

$$(\mathbf{w}^T \mathbf{S}_B \mathbf{w}) \mathbf{S}_W \mathbf{w} = (\mathbf{w}^T \mathbf{S}_W \mathbf{w}) \mathbf{S}_B \mathbf{w} \quad (4.29)$$

从 (4.27) 式我们看到， $\mathbf{S}_B \mathbf{w}$ 总是沿着 $(\mathbf{m}_2 - \mathbf{m}_1)$ 的方向。此外，我们不关心 $\mathbf{w}$ 的大小，只关心它的方向，因此我们可以去掉标量因子 $(\mathbf{w}^T \mathbf{S}_B \mathbf{w})$ 和 $(\mathbf{w}^T \mathbf{S}_W \mathbf{w})$ 。将 (4.29) 式的两边乘以 $\mathbf{S}_W^{-1}$ ，我们得到

$$\mathbf{w} \propto \mathbf{S}_W^{-1} (\mathbf{m}_2 - \mathbf{m}_1) \quad (4.30)$$

注意，如果类内协方差是各向同性的，即 $\mathbf{S}_W$ 与单位矩阵成比例，我们发现 $\mathbf{w}$ 与类均值之差成比例，这与我们前面讨论的一致。

结果 (4.30) 被称为费舍尔线性判别 (Fisher's linear discriminant)，尽管严格来说它不是一个判别式，而是将数据投影到一维的特定方向的选择。然而，投影后的数据随后可以用于构建一个判别式，方法是选择一个阈值 y_0 ，使得如果 $y(\mathbf{x}) \geq y_0$ ，我们将一个

新点分类为属于 C_1 ，否则分类为属于 C_2 。例如，我们可以使用高斯分布来建模类条件概率密度 $p(y | C_k)$ ，然后使用第 1.2.4 节的技术通过最大似然法来找到高斯分布的参数。在找到投影后的类的高斯近似后，第 1.5.1 节的形式主义随后给出了最优阈值的表达式。对于高斯假设的一些佐证来自于中心极限定理，因为 $y = \mathbf{w}^T \mathbf{x}$ 是一组随机变量的和。

4.1.5 与最小二乘法的关系

确定线性判别函数的最小二乘法基于的目标是使模型预测尽可能接近一组目标值。相比之下，费舍尔准则的推导要求在输出空间中实现最大的类别可分离性。观察这两种方法之间的关系是很有趣的。特别是，我们将证明，对于两类问题，费舍尔准则可以作为最小二乘法的一个特例获得。

到目前为止，我们已经考虑了目标值的 1-of- K 编码。然而，如果我们采用略微不同的目标编码方案，那么权值的最小二乘解就等价于费舍尔解 (Duda and Hart, 1973)。具体来说，我们将 C_1 类的目标值设为 N/N_1 ，其中 N_1 是 C_1 类中的模式数量， N 是模式总数。这个目标值近似于 C_1 类先验概率的倒数。对于 C_2 类，我们将目标值设为 $-N/N_2$ ，其中 N_2 是 C_2 类中的模式数量。

平方误差函数可以写成

$$E = \frac{1}{2} \sum_{n=1}^N (\mathbf{w}^T \mathbf{x}_n + w_0 - t_n)^2 \quad (4.31)$$

将 E 对 w_0 和 $\mathbf{w}$ 的导数设为零，我们分别得到

$$\sum_{n=1}^N (\mathbf{w}^T \mathbf{x}_n + w_0 - t_n) = 0 \quad (4.32)$$

$$\sum_{n=1}^N (\mathbf{w}^T \mathbf{x}_n + w_0 - t_n) \mathbf{x}_n = 0 \quad (4.33)$$

根据 (4.32) 式，并利用我们对 t_n 的目标编码方案的选择，我们得到了偏置项的形式

$$w_0 = -\mathbf{w}^T \mathbf{m} \quad (4.34)$$

其中我们使用了

$$\sum_{n=1}^N t_n = N_1 \frac{N}{N_1} - N_2 \frac{N}{N_2} = 0 \quad (4.35)$$

并且 $\mathbf{m}$ 是总数据集的均值，由下式给出

$$\mathbf{m} = \frac{1}{N} \sum_{n=1}^N \mathbf{x}_n = \frac{1}{N} (N_1 \mathbf{m}_1 + N_2 \mathbf{m}_2) \quad (4.36)$$

经过一些简单的代数运算，并再次利用 t_n 的选择，第二个方程 (4.33) 变为

$$\left(\mathbf{S}_W + \frac{N_1 N_2}{N} \mathbf{S}_B \right) \mathbf{w} = N (\mathbf{m}_1 - \mathbf{m}_2) \quad (4.37)$$

其中 $\mathbf{S}_W$ 由 (4.28) 式定义, $\mathbf{S}_B$ 由 (4.27) 式定义, 并且我们已经用 (4.34) 式代入了偏置项。利用 (4.27) 式, 我们注意到 $\mathbf{S}_B \mathbf{w}$ 总是沿着 $(\mathbf{m}_2 - \mathbf{m}_1)$ 的方向。因此, 我们可以写成

$$\mathbf{w} \propto \mathbf{S}_W^{-1} (\mathbf{m}_2 - \mathbf{m}_1) \quad (4.38)$$

其中我们忽略了不相关的尺度因子。因此, 权向量与从费舍尔准则中发现的结果一致。此外, 我们还找到了由 (4.34) 式给出的偏置值 w_0 的表达式。这告诉我们, 如果 $y(\mathbf{x}) = \mathbf{w}^T(\mathbf{x} - \mathbf{m}) > 0$, 一个新的向量 $\mathbf{x}$ 应该被分类为属于 $\mathcal{C}_1$ 类, 否则属于 $\mathcal{C}_2$ 类。

4.1.6 费舍尔 (Fisher's) 多类判别式

我们现在考虑将费舍尔判别式推广到 $K > 2$ 个类的情形, 并且我们假设输入空间 $\mathbf{x}$ 的维数 D 大于类的数量 K 。接下来, 我们引入 $D' > 1$ 个线性“特征” $y_k = \mathbf{w}_k^T \mathbf{x}$, 其中 $k = 1, \dots, D'$ 。这些特征值可以方便地组合起来形成一个向量 $\mathbf{y}$ 。类似地, 权向量集合 $\{\mathbf{w}_k\}$ 可以被视为矩阵 $\mathbf{W}$ 的列, 因此

$$\mathbf{y} = \mathbf{W}^T \mathbf{x} \quad (4.39)$$

注意, 在 $\mathbf{y}$ 的定义中, 我们再次没有包含任何偏置参数。将类内协方差矩阵推广到 K 个类的情况, 由 (4.28) 式得出

$$\mathbf{S}_W = \sum_{k=1}^K \mathbf{S}_k \quad (4.40)$$

其中

$$\mathbf{S}_k = \sum_{n \in \mathcal{C}_k} (\mathbf{x}_n - \mathbf{m}_k) (\mathbf{x}_n - \mathbf{m}_k)^T \quad (4.41)$$

$$\mathbf{m}_k = \frac{1}{N_k} \sum_{n \in \mathcal{C}_k} \mathbf{x}_n \quad (4.42)$$

N_k 是 $\mathcal{C}_k$ 类中的模式数量。为了找到类间协方差矩阵的推广形式, 我们遵循 Duda 和 Hart (1973) 的做法, 首先考虑总协方差矩阵

$$\mathbf{S}_T = \sum_{n=1}^N (\mathbf{x}_n - \mathbf{m}) (\mathbf{x}_n - \mathbf{m})^T \quad (4.43)$$

其中 $\mathbf{m}$ 是总数据集的均值

$$\mathbf{m} = \frac{1}{N} \sum_{n=1}^N \mathbf{x}_n = \frac{1}{N} \sum_{k=1}^K N_k \mathbf{m}_k \quad (4.44)$$

$N = \sum_k N_k$ 是数据的总点数。总协方差矩阵可以分解为由 (4.40) 和 (4.41) 给出的类内协方差矩阵 $\mathbf{S}_W$ 加上一个附加矩阵 $\mathbf{S}_B$ 的和, 我们将 $\mathbf{S}_B$ 视作类间协方差的度量

$$\mathbf{S}_T = \mathbf{S}_W + \mathbf{S}_B \quad (4.45)$$

其中

$$\mathbf{S}_B = \sum_{k=1}^K N_k (\mathbf{m}_k - \mathbf{m})(\mathbf{m}_k - \mathbf{m})^T \quad (4.46)$$

这些协方差矩阵是在原始的 $\mathbf{x}$ -空间中定义的。我们现在可以在投影后的 D' 维 $\mathbf{y}$ -空间中定义类似的矩阵

$$\mathbf{s}_W = \sum_{k=1}^K \sum_{n \in C_k} (\mathbf{y}_n - \boldsymbol{\mu}_k)(\mathbf{y}_n - \boldsymbol{\mu}_k)^T \quad (4.47)$$

和

$$\mathbf{s}_B = \sum_{k=1}^K N_k (\boldsymbol{\mu}_k - \boldsymbol{\mu})(\boldsymbol{\mu}_k - \boldsymbol{\mu})^T \quad (4.48)$$

其中

$$\boldsymbol{\mu}_k = \frac{1}{N_k} \sum_{n \in C_k} \mathbf{y}_n, \quad \boldsymbol{\mu} = \frac{1}{N} \sum_{k=1}^K N_k \boldsymbol{\mu}_k \quad (4.49)$$

我们再次希望构造一个标量，当类间协方差大而类内协方差小时，该标量也大。现在有许多可能的判别准则可供选择 (Fukunaga, 1990)。其中一个例子是

$$J(\mathbf{W}) = \text{Tr} \{ \mathbf{s}_W^{-1} \mathbf{s}_B \} \quad (4.50)$$

然后，这个判别准则可以重写为投影矩阵 $\mathbf{W}$ 的显式函数，形式为

$$J(\mathbf{W}) = \text{Tr} \left\{ (\mathbf{W} \mathbf{s}_W \mathbf{W}^T)^{-1} (\mathbf{W} \mathbf{s}_B \mathbf{W}^T) \right\}. \quad (4.51)$$

最大化这类准则是直截了当的，尽管涉及一些复杂的步骤，Fukunaga (1990) 对此进行了详细讨论。权值 $\mathbf{W}$ 由 $\mathbf{s}_W^{-1} \mathbf{s}_B$ 的对应于 D' 个最大特征值的特征向量来确定。

所有这类准则都有一个重要的共同结果，值得强调。我们首先从 (4.46) 式注意到， $\mathbf{S}_B$ 由 K 个矩阵的和组成，其中每个矩阵都是两个向量的外积，因此秩为 1。此外，由于约束 (4.44) 的结果，这些矩阵中只有 $(K-1)$ 个是独立的。因此， $\mathbf{S}_B$ 的秩至多等于 $(K-1)$ ，从而至多只有 $(K-1)$ 个非零特征值。这表明，投影到由 $\mathbf{S}_B$ 的特征向量张成的 $(K-1)$ 维子空间上并不会改变 $J(\mathbf{W})$ 的值，因此通过这种方法，我们最多只能找到 $(K-1)$ 个线性“特征” (Fukunaga, 1990)。

4.1.7 感知器算法

线性判别模型的另一个例子是 Rosenblatt (1962) 的感知器 (perceptron)，它在模式识别算法的历史中占有重要地位。它对应于一个两类模型，其中输入向量 $\mathbf{x}$ 首先通过一个固定的非线性变换被转换成特征向量 $\boldsymbol{\phi}(\mathbf{x})$ ，然后用它来构建一个广义线性模型，其形式为

$$y(\mathbf{x}) = f(\mathbf{w}^T \boldsymbol{\phi}(\mathbf{x})) \quad (4.52)$$

其中非线性激活函数 $f(\cdot)$ 由一个阶梯函数给出，其形式为

$$f(a) = \begin{cases} +1, & a \geq 0 \\ -1, & a < 0. \end{cases} \quad (4.53)$$

向量 $\phi(\mathbf{x})$ 通常会包含一个偏置分量 $\phi_0(\mathbf{x}) = 1$ 。在之前关于两类分类问题的讨论中，我们主要关注于目标编码方案 $t \in \{0, 1\}$ ，这在概率模型的背景下是合适的。然而，对于感知器，使用 $\mathcal{C}_1$ 类的目标值 $t = +1$ 和 $\mathcal{C}_2$ 类的目标值 $t = -1$ 更为方便，这与激活函数的选择相匹配。

用于确定感知器参数 $\mathbf{w}$ 的算法可以最容易地通过误差函数的最小化来推导。误差函数的一个自然选择可能是被错误分类的模式总数。然而，这不会导致一个简单的学习算法，因为误差是 $\mathbf{w}$ 的分段常数函数，在 $\mathbf{w}$ 的任何变化导致决策边界穿过某个数据点的地方存在不连续性。因此，不能应用基于使用误差函数梯度来改变 $\mathbf{w}$ 的方法，因为梯度在几乎所有地方都为零。

因此，我们考虑另一种误差函数，称为感知器准则 (perceptron criterion)。为了推导出它，我们注意到我们正在寻找一个权向量 $\mathbf{w}$ ，使得 $\mathcal{C}_1$ 类中的模式 $\mathbf{x}_n$ 满足 $\mathbf{w}^T \phi(\mathbf{x}_n) > 0$ ，而 $\mathcal{C}_2$ 类中的模式 $\mathbf{x}_n$ 满足 $\mathbf{w}^T \phi(\mathbf{x}_n) < 0$ 。使用 $t \in \{-1, +1\}$ 的目标编码方案，这意味着我们希望所有模式都满足 $\mathbf{w}^T \phi(\mathbf{x}_n) t_n > 0$ 。感知器准则将零误差与任何正确分类的模式相关联，而对于一个错误分类的模式 $\mathbf{x}_n$ ，它试图最小化 $-\mathbf{w}^T \phi(\mathbf{x}_n) t_n$ 。因此，感知器准则由下式给出

$$E_P(\mathbf{w}) = - \sum_{n \in \mathcal{M}} \mathbf{w}^T \phi_n t_n \quad (4.54)$$

其中 $\mathcal{M}$ 表示所有被错误分类的模式集合。与特定错误分类模式相关的误差贡献是 $\mathbf{w}$ 的线性函数，在模式被错误分类的 $\mathbf{w}$ 空间区域中如此，而在模式被正确分类的区域中为零。因此，总误差函数是分段线性的。

我们现在将随机梯度下降算法应用于这个误差函数。权向量 $\mathbf{w}$ 的变化由下式给出

$$\mathbf{w}^{(\tau+1)} = \mathbf{w}^{(\tau)} - \eta \nabla E_P(\mathbf{w}) = \mathbf{w}^{(\tau)} + \eta \phi_n t_n \quad (4.55)$$

其中 η 是学习率参数， τ 是算法步数的索引。因为如果我们将 $\mathbf{w}$ 乘以一个常数，感知器函数 $y(\mathbf{x}, \mathbf{w})$ 保持不变，所以我们可以不失一般性的前提下将学习率参数 η 设为 1。请注意，随着权向量在训练过程中演变，被错误分类的模式集合会发生变化。

感知器学习算法有一个简单的解释，如下所述。我们依次循环遍历训练模式，对于每个模式 $\mathbf{x}_n$ ，我们评估感知器函数 (4.52)。如果模式被正确分类，则权向量保持不变；如果它被错误分类，那么对于 $\mathcal{C}_1$ 类，我们将向量 $\phi(\mathbf{x}_n)$ 添加到当前的权向量估计 $\mathbf{w}$ 上，而对于 $\mathcal{C}_2$ 类，我们从 $\mathbf{w}$ 中减去向量 $\phi(\mathbf{x}_n)$ 。图 4.7 说明了感知器学习算法。




图 4.7 感知机学习算法收敛过程的示意图，展示了二维特征空间 (ϕ_1, ϕ_2) 中来自两个类别的样本点（红色与蓝色）。左上图显示了初始参数向量 w （黑色箭头）以及对应的决策边界（黑线），箭头指向被判定为红色类别的区域。绿色圆圈标出的数据点被误分类，因此其特征向量被加到当前权向量上，得到右上图所示的新决策边界。左下图显示下一个被误分类的数据点（绿色圆圈所示），其特征向量再次被加到权向量上，最终得到右下图的决策边界，此时所有数据点均被正确分类。

如果我们考虑感知器学习算法中单次更新的影响，我们会看到一个错误分类模式对误差的贡献将会减少，因为根据 (4.55) 式，我们有

$$-\mathbf{w}^{(\tau+1)\top} \phi_n t_n = -\mathbf{w}^{(\tau)\top} \phi_n t_n - (\phi_n t_n)^\top \phi_n t_n < -\mathbf{w}^{(\tau)\top} \phi_n t_n \quad (4.56)$$

其中我们已设置 $\eta = 1$ ，并使用了 $\|\phi_n t_n\|^2 > 0$ 。当然，这并不意味着其他被错误分类的模式对误差函数的贡献也会减少。此外，权向量的改变可能会导致一些先前正确分类的模式变得错误分类。因此，感知器学习规则并不能保证在每一步都减少总误差函数。

然而，感知器收敛定理表明，如果存在一个精确解（换句话说，如果训练数据集是线性可分的），那么感知器学习算法保证能在有限步数内找到一个精确解。该定理的证明可以在例如 Rosenblatt (1962)、Block (1962)、Nilsson (1965)、Minsky and Papert (1969)、

Hertz et al. (1991) 和 Bishop (1995a) 中找到。但需要注意的是，达到收敛所需的步数可能仍然相当多，而且在实际应用中，在达到收敛之前，我们将无法区分一个不可分问题和一个只是收敛缓慢的问题。

即使数据集是线性可分的，也可能存在许多解，找到哪一个解将取决于参数的初始化以及数据点的呈现顺序。此外，对于非线性可分的数据集，感知器学习算法将永远不会收敛。

除了学习算法上的困难之外，感知器不提供概率输出，也不能轻易地推广到 $K > 2$ 个类别。然而，其最主要的局限性在于（与本章和前一章讨论的所有模型一样），它是基于固定基函数的线性组合。关于感知器局限性的更详细讨论可以在 Minsky and Papert (1969) 和 Bishop (1995a) 中找到。

Rosenblatt 制造了感知器的模拟硬件实现，基于电机驱动的可变电阻器来实现自适应参数 w_j 。这些在图 4.8 中有所展示。输入来自一个基于光电传感器阵列的简单摄像系统，而基函数 ϕ 可以通过各种方式选择，例如基于输入图像中随机选择的像素子集的简单固定函数。典型的应用包括学习区分简单的形状或字符。




图 4.8 Mark 1 感知机硬件示意图。左侧照片展示了输入如何通过一套简单的摄像系统获得：输入场景（此处为打印字符）在强光照明下被成像到一个由硫化镉光电池构成的 20×20 阵列上，从而得到一个原始的 400 像素图像。中间的照片展示了感知机的接线板，它允许尝试不同的输入特征配置；这些连接常常是随机布线，以显示感知机无需精确布线即可学习的特性，这与现代数字计算机形成对比。右侧照片展示了自适应权值的机架之一，每个权值通过旋转可变电阻（即电位器）实现，并由电动机驱动，从而允许学习算法自动调整权值的数值。

在感知器被开发的同时，Widrow 及其同事正在探索一个密切相关的系统，称为 adaline，它是“adaptive linear element”（自适应线性元件）的缩写。该模型的函数形式与感知器相同，但采用了不同的训练方法 (Widrow and Hoff, 1960; Widrow and Lehr, 1990)。

4.2 概率生成模型

接下来，我们转向分类的概率观点，并展示具有线性决策边界的模型是如何从对数据分布的简单假设中产生的。在第 1.5.4 节中，我们讨论了判别式方法和生成式方法在分类上的区别。在这里，我们将采用一种生成式方法，其中我们对类条件概率密度 $p(\mathbf{x} | C_k)$ 和类先验概率 $p(C_k)$ 进行建模，然后使用贝叶斯定理计算后验概率 $p(C_k | \mathbf{x})$ 。

首先考虑两类的情况。 $\mathcal{C}_1$ 类的后验概率可以写成

$$\begin{aligned} p(\mathcal{C}_1 | \mathbf{x}) &= \frac{p(\mathbf{x} | \mathcal{C}_1) p(\mathcal{C}_1)}{p(\mathbf{x} | \mathcal{C}_1) p(\mathcal{C}_1) + p(\mathbf{x} | \mathcal{C}_2) p(\mathcal{C}_2)} \\ &= \frac{1}{1 + \exp(-a)} = \sigma(a) \end{aligned} \quad (4.57)$$

其中我们定义了

$$a = \ln \frac{p(\mathbf{x} | \mathcal{C}_1) p(\mathcal{C}_1)}{p(\mathbf{x} | \mathcal{C}_2) p(\mathcal{C}_2)} \quad (4.58)$$

$\sigma(a)$ 是由下式定义的逻辑 Sigmoid 函数

$$\sigma(a) = \frac{1}{1 + \exp(-a)} \quad (4.59)$$

它绘制在图 4.9 中。术语“Sigmoid”的意思是 S 形。这种类型的函数有时也被称为“挤压函数”(squashing function)，因为它将整个实轴映射到一个有限区间内。逻辑 Sigmoid 在前面章节中已经遇到过，并在许多分类算法中扮演着重要角色。它满足以下对称性


$$\sigma(-a) = 1 - \sigma(a) \quad (4.60)$$

这很容易验证。逻辑 Sigmoid 的逆函数由下式给出

$$a = \ln \left(\frac{\sigma}{1 - \sigma} \right) \quad (4.61)$$

被称为 logit 函数。它表示两类概率比值的对数 $\ln [p(\mathcal{C}_1 | \mathbf{x}) / p(\mathcal{C}_2 | \mathbf{x})]$ ，也称为对数几率 (log odds)。

图 4.9 绘制由式 (4.59) 定义的 logistic sigmoid 函数 $\sigma(a)$ (红色实线)，以及缩放后的 probit 函数 $\Phi(\lambda a)$ (蓝色虚线)，其中 $\lambda^2 = \pi/8$ ， $\Phi(a)$ 由式 (4.114) 定义。缩放因子 $\pi/8$ 的选择使得在 $a = 0$ 处两条曲线的导数相同。



请注意，在 (4.57) 式中，我们只是将后验概率改写成了一种等价的形式，因此逻辑 Sigmoid 的出现可能看起来相当空泛。然而，如果 $a(\mathbf{x})$ 具有简单的函数形式，它将具有重要意义。我们很快会考虑 $a(\mathbf{x})$ 是 $\mathbf{x}$ 的线性函数的情况，在这种情况下，后验概率由一个广义线性模型控制。

对于 $K > 2$ 个类的情况，我们有

$$\begin{aligned} p(\mathcal{C}_k | \mathbf{x}) &= \frac{p(\mathbf{x} | \mathcal{C}_k) p(\mathcal{C}_k)}{\sum_j p(\mathbf{x} | \mathcal{C}_j) p(\mathcal{C}_j)} \\ &= \frac{\exp(a_k)}{\sum_j \exp(a_j)} \end{aligned} \quad (4.62)$$

这被称为归一化指数函数，可以看作是逻辑 Sigmoid 的多类推广。这里，量 a_k 定义为

$$a_k = \ln p(\mathbf{x} | \mathcal{C}_k) p(\mathcal{C}_k) \quad (4.63)$$

归一化指数函数也被称为 softmax 函数，因为它代表了 'max' 函数的一个平滑版本，因为如果对于所有 $j \neq k$ 都有 $a_k \gg a_j$ ，那么 $p(\mathcal{C}_k | \mathbf{x}) \simeq 1$ 且 $p(\mathcal{C}_j | \mathbf{x}) \simeq 0$ 。

我们现在研究选择特定形式的类条件概率密度的后果，首先考察连续输入变量 $\mathbf{x}$ ，然后简要讨论离散输入的情况。

4.2.1 连续输入

让我们假设类条件概率密度是高斯分布，然后探究后验概率的最终形式。首先，我们假设所有类共享相同的协方差矩阵。因此， $\mathcal{C}_k$ 类的密度由下式给出

$$p(\mathbf{x} | \mathcal{C}_k) = \frac{1}{(2\pi)^{D/2}} \frac{1}{|\Sigma|^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_k)^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}_k) \right\} \quad (4.64)$$

我们首先考虑两类的情况。根据 (4.57) 和 (4.58) 式，我们有

$$p(\mathcal{C}_1 | \mathbf{x}) = \sigma(\mathbf{w}^T \mathbf{x} + w_0) \quad (4.65)$$

其中我们定义了

$$\mathbf{w} = \Sigma^{-1} (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2) \quad (4.66)$$

$$w_0 = -\frac{1}{2} \boldsymbol{\mu}_1^T \Sigma^{-1} \boldsymbol{\mu}_1 + \frac{1}{2} \boldsymbol{\mu}_2^T \Sigma^{-1} \boldsymbol{\mu}_2 + \ln \frac{p(\mathcal{C}_1)}{p(\mathcal{C}_2)}. \quad (4.67)$$




图 4.10 左图显示两个类别的类别条件密度，分别以红色和蓝色表示。右图为对应的后验概率 $p(\mathcal{C}_1 | x)$ ，其形式为关于 x 的线性函数再经过 logit sigmoid 变换。右图中的表面通过颜色区分：红色比例为 $p(\mathcal{C}_1 | x)$ ，蓝色比例为 $p(\mathcal{C}_2 | x) = 1 - p(\mathcal{C}_1 | x)$ 。

我们看到，来自高斯密度指数的 $\mathbf{x}$ 的二次项相互抵消了（由于共同协方差矩阵的假设），从而使得逻辑 Sigmoid 函数的自变量成为 $\mathbf{x}$ 的线性函数。对于二维输入空间 $\mathbf{x}$ 的情况，结果如图 4.10 所示。最终的决策边界对应于后验概率 $p(\mathcal{C}_k | \mathbf{x})$ 恒定的曲面，因此将由 $\mathbf{x}$ 的线性函数给出，故决策边界在输入空间中是线性的。先验概率 $p(\mathcal{C}_k)$ 仅通过

偏置参数 w_0 参与进来, 因此先验概率的变化只会导致决策边界和更一般的等后验概率平行等高线的平行平移。

对于一般 K 类的情况, 根据 (4.62) 和 (4.63) 式, 我们有

$$a_k(\mathbf{x}) = \mathbf{w}_k^T \mathbf{x} + w_{k0} \quad (4.68)$$

其中我们定义了

$$\mathbf{w}_k = \Sigma^{-1} \boldsymbol{\mu}_k \quad (4.69)$$

$$w_{k0} = -\frac{1}{2} \boldsymbol{\mu}_k^T \Sigma^{-1} \boldsymbol{\mu}_k + \ln p(\mathcal{C}_k) \quad (4.70)$$

我们看到, 由于共享协方差导致的二次项抵消, $a_k(\mathbf{x})$ 再次是 $\mathbf{x}$ 的线性函数。由此产生的决策边界, 对应于最小错误分类率, 将出现在两个后验概率 (两个最大的概率) 相等的地方, 因此将由 $\mathbf{x}$ 的线性函数定义, 所以我们再次得到了一个广义线性模型。

如果放松共享协方差矩阵的假设, 允许每个类条件概率密度 $p(\mathbf{x} | \mathcal{C}_k)$ 拥有自己的协方差矩阵 Σ_k , 那么之前的抵消将不再发生, 我们将得到 $\mathbf{x}$ 的二次函数, 从而产生一个二次判别式。线性判别边界和二次判别边界如图 4.11 所示。




图 4.11 左图展示了三个类别的类别条件密度, 每个类别均为高斯分布, 分别以红色、绿色和蓝色表示, 其中红色与绿色类别具有相同的协方差矩阵。右图展示了对应的后验概率, 其中 RGB 颜色向量表示三个类别的后验概率。图中同时给出了决策边界。注意, 对具有相同协方差矩阵的红色与绿色类别之间, 决策边界为线性, 而与其他类别之间的边界则为二次形式。

4.2.2 最大似然解

一旦我们为类条件概率密度 $p(\mathbf{x} | \mathcal{C}_k)$ 指定了参数化的函数形式, 我们就可以使用最大似然法来确定参数的值, 以及先验类概率 $p(\mathcal{C}_k)$ 。这需要一个包含 $\mathbf{x}$ 观测值及其相应类标签的数据集。

首先考虑两类的情况, 每类都有一个共享协方差矩阵的高斯类条件概率密度, 假设我们有一个数据集 $\{\mathbf{x}_n, t_n\}$, 其中 $n = 1, \dots, N$ 。这里 $t_n = 1$ 表示 $\mathcal{C}_1$ 类, $t_n = 0$ 表示 $\mathcal{C}_2$

类。我们用 $p(C_1) = \pi$ 来表示先验类概率，因此 $p(C_2) = 1 - \pi$ 。对于来自 C_1 类的数据点 $\mathbf{x}_n$ ，我们有 $t_n = 1$ ，因此

$$p(\mathbf{x}_n, C_1) = p(C_1) p(\mathbf{x}_n | C_1) = \pi \mathcal{N}(\mathbf{x}_n | \boldsymbol{\mu}_1, \boldsymbol{\Sigma})$$

类似地，对于 C_2 类，我们有 $t_n = 0$ ，因此

$$p(\mathbf{x}_n, C_2) = p(C_2) p(\mathbf{x}_n | C_2) = (1 - \pi) \mathcal{N}(\mathbf{x}_n | \boldsymbol{\mu}_2, \boldsymbol{\Sigma})$$

因此，似然函数由下式给出

$$p(\mathbf{t} | \pi, \boldsymbol{\mu}_1, \boldsymbol{\mu}_2, \boldsymbol{\Sigma}) = \prod_{n=1}^N [\pi \mathcal{N}(\mathbf{x}_n | \boldsymbol{\mu}_1, \boldsymbol{\Sigma})]^{t_n} [(1 - \pi) \mathcal{N}(\mathbf{x}_n | \boldsymbol{\mu}_2, \boldsymbol{\Sigma})]^{1-t_n} \quad (4.71)$$

其中 $\mathbf{t} = (t_1, \dots, t_N)^T$ 。像往常一样，最大化似然函数的对数是很方便的。首先考虑关于 π 的最大化。对数似然函数中依赖于 π 的项是

$$\sum_{n=1}^N \{t_n \ln \pi + (1 - t_n) \ln(1 - \pi)\} \quad (4.72)$$

将关于 π 的导数设为零并重新整理，我们得到

$$\pi = \frac{1}{N} \sum_{n=1}^N t_n = \frac{N_1}{N} = \frac{N_1}{N_1 + N_2} \quad (4.73)$$

其中 N_1 表示 C_1 类中数据点的总数， N_2 表示 C_2 类中数据点的总数。因此， π 的最大似然估计正如预期的那样，就是 C_1 类中的点所占的比例。这个结果很容易推广到多类情况，其中 C_k 类先验概率的最大似然估计同样是由分配给该类的训练集点的比例给出。

现在考虑关于 $\boldsymbol{\mu}_1$ 的最大化。同样，我们可以从对数似然函数中挑出依赖于 $\boldsymbol{\mu}_1$ 的项，得到

$$\sum_{n=1}^N t_n \ln \mathcal{N}(\mathbf{x}_n | \boldsymbol{\mu}_1, \boldsymbol{\Sigma}) = -\frac{1}{2} \sum_{n=1}^N t_n (\mathbf{x}_n - \boldsymbol{\mu}_1)^T \boldsymbol{\Sigma}^{-1} (\mathbf{x}_n - \boldsymbol{\mu}_1) + \text{const.} \quad (4.74)$$

将关于 $\boldsymbol{\mu}_1$ 的导数设为零并重新整理，我们得到

$$\boldsymbol{\mu}_1 = \frac{1}{N_1} \sum_{n=1}^N t_n \mathbf{x}_n \quad (4.75)$$

这仅仅是分配给 C_1 类的所有输入向量 $\mathbf{x}_n$ 的均值。通过类似的论证， $\boldsymbol{\mu}_2$ 的相应结果由下式给出

$$\boldsymbol{\mu}_2 = \frac{1}{N_2} \sum_{n=1}^N (1 - t_n) \mathbf{x}_n \quad (4.76)$$

这同样是分配给 C_2 类的所有输入向量 $\mathbf{x}_n$ 的均值。

最后，考虑共享协方差矩阵 Σ 的最大似然解。从对数似然函数中挑出依赖于 Σ 的项，我们有

$$\begin{aligned} & -\frac{1}{2} \sum_{n=1}^N t_n \ln |\Sigma| - \frac{1}{2} \sum_{n=1}^N t_n (\mathbf{x}_n - \boldsymbol{\mu}_1)^T \Sigma^{-1} (\mathbf{x}_n - \boldsymbol{\mu}_1) \\ & -\frac{1}{2} \sum_{n=1}^N (1 - t_n) \ln |\Sigma| - \frac{1}{2} \sum_{n=1}^N (1 - t_n) (\mathbf{x}_n - \boldsymbol{\mu}_2)^T \Sigma^{-1} (\mathbf{x}_n - \boldsymbol{\mu}_2) \\ & = -\frac{N}{2} \ln |\Sigma| - \frac{N}{2} \text{Tr} \{ \Sigma^{-1} \mathbf{S} \} \end{aligned} \quad (4.77)$$

其中我们定义了

$$\mathbf{S} = \frac{N_1}{N} \mathbf{S}_1 + \frac{N_2}{N} \mathbf{S}_2 \quad (4.78)$$

$$\mathbf{S}_1 = \frac{1}{N_1} \sum_{n \in \mathcal{C}_1} (\mathbf{x}_n - \boldsymbol{\mu}_1) (\mathbf{x}_n - \boldsymbol{\mu}_1)^T \quad (4.79)$$

$$\mathbf{S}_2 = \frac{1}{N_2} \sum_{n \in \mathcal{C}_2} (\mathbf{x}_n - \boldsymbol{\mu}_2) (\mathbf{x}_n - \boldsymbol{\mu}_2)^T \quad (4.80)$$

利用高斯分布最大似然解的标准结果，我们看到 $\Sigma = \mathbf{S}$ ，这代表了与两个类分别相关的协方差矩阵的加权平均。

这一结果很容易扩展到 K 类问题，以获得相应参数的最大似然解，其中每个类条件密度都是具有共享协方差矩阵的高斯分布。请注意，用高斯分布拟合类别的方法对异常值不鲁棒，因为高斯分布的最大似然估计本身就不是鲁棒的。

4.2.3 离散特征

现在让我们考虑离散特征值 x_i 的情况。为简单起见，我们首先考察二值特征值 $x_i \in \{0, 1\}$ ，稍后讨论推广到更一般的离散特征。如果有 D 个输入，那么一个一般的分布将对应于每个类的一个 2^D 个数字的表，其中包含 $2^D - 1$ 个独立变量（由于求和约束）。因为这随着特征数量呈指数增长，我们可能会寻求一种限制性更强的表示。这里我们将采用朴素贝叶斯假设，其中特征值在给定类别 $\mathcal{C}_k$ 的条件下被视为独立的。因此，我们有如下形式的类条件分布

$$p(\mathbf{x} | \mathcal{C}_k) = \prod_{i=1}^D \mu_{ki}^{x_i} (1 - \mu_{ki})^{1-x_i} \quad (4.81)$$

其中，对于每个类别，包含 D 个独立参数。将其代入 (4.63) 式，得到

$$a_k(\mathbf{x}) = \sum_{i=1}^D \{x_i \ln \mu_{ki} + (1 - x_i) \ln (1 - \mu_{ki})\} + \ln p(\mathcal{C}_k) \quad (4.82)$$

这再次是输入值 x_i 的线性函数。对于 $K = 2$ 类的情况，我们可以选择考虑由 (4.57) 给出的逻辑 Sigmoid 公式。对于每个可取 $M > 2$ 个状态的离散变量，可以得到类似的结论。

4.2.4 指数族

正如我们所见,对于高斯分布的输入和离散输入,后验类概率都由具有逻辑 Sigmoid ($K = 2$ 类) 或 Softmax ($K \geq 2$ 类) 激活函数的广义线性模型给出。这些是一个更一般结果的特例,该结果通过假设类条件概率密度 $p(\mathbf{x} | C_k)$ 是指数族分布的成员而获得。

使用指数族成员的 (2.194) 形式,我们看到 $\mathbf{x}$ 的分布可以写成如下形式:

$$p(\mathbf{x} | \boldsymbol{\lambda}_k) = h(\mathbf{x})g(\boldsymbol{\lambda}_k) \exp \{ \boldsymbol{\lambda}_k^T \mathbf{u}(\mathbf{x}) \}. \quad (4.83)$$

现在我们将注意力限制在满足 $\mathbf{u}(\mathbf{x}) = \mathbf{x}$ 的这类分布的子类上。然后,我们利用 (2.236) 引入一个尺度参数 s , 从而得到形式受限的指数族类条件概率密度:

$$p(\mathbf{x} | \boldsymbol{\lambda}_k, s) = \frac{1}{s} h\left(\frac{1}{s} \mathbf{x}\right) g(\boldsymbol{\lambda}_k) \exp \left\{ \frac{1}{s} \boldsymbol{\lambda}_k^T \mathbf{x} \right\}. \quad (4.84)$$

请注意,我们允许每个类别拥有自己的参数向量 $\boldsymbol{\lambda}_k$, 但我们假设这些类别共享相同的尺度参数 s 。

对于两类问题,我们将类条件概率密度的此表达式代入 (4.58) 式,可以看到后验类概率再次由作用于线性函数 $a(\mathbf{x})$ 的逻辑 Sigmoid 函数给出,该线性函数为

$$a(\mathbf{x}) = (\boldsymbol{\lambda}_1 - \boldsymbol{\lambda}_2)^T \mathbf{x} + \ln g(\boldsymbol{\lambda}_1) - \ln g(\boldsymbol{\lambda}_2) + \ln p(C_1) - \ln p(C_2). \quad (4.85)$$

类似地,对于 K 类问题,我们将类条件概率密度表达式代入 (4.63) 式,得到

$$a_k(\mathbf{x}) = \boldsymbol{\lambda}_k^T \mathbf{x} + \ln g(\boldsymbol{\lambda}_k) + \ln p(C_k) \quad (4.86)$$

因此,它再次是 $\mathbf{x}$ 的线性函数。

4.3 概率判别模型

对于两类分类问题,我们已经看到,对于广泛选择的类条件分布 $p(\mathbf{x} | C_k)$, C_1 类的后验概率可以写成作用于 $\mathbf{x}$ 的线性函数的逻辑 Sigmoid 函数。类似地,对于多类情况, C_k 类的后验概率由 $\mathbf{x}$ 的线性函数的 softmax 变换给出。对于特定选择的类条件概率密度 $p(\mathbf{x} | C_k)$, 我们使用最大似然法来确定密度的参数以及类先验 $p(C_k)$, 然后使用贝叶斯定理来找到后验类概率。

然而,另一种方法是明确使用广义线性模型的函数形式,并直接通过最大似然法确定其参数。我们将看到,有一个有效算法可以找到这样的解,称为迭代重加权最小二乘法 (iterative reweighted least squares, 或 IRLS)。

通过分别拟合类条件概率密度和类先验,然后应用贝叶斯定理来找到广义线性模型参数的间接方法,是生成式建模的一个例子,因为我们可以利用这样的模型并从边缘分布 $p(\mathbf{x})$ 中抽取 $\mathbf{x}$ 的值来生成合成数据。在直接方法中,我们最大化一个通过条件分布 $p(C_k | \mathbf{x})$ 定义的似然函数,这代表了一种判别式训练形式。判别式方法的一个优点是,通常需要确定的自适应参数会更少,这一点我们很快就会看到。它也可能带来更高的预测性能,特别是当类条件密度假设对真实分布的近似效果较差时。

4.3.1 固定基函数

到目前为止，在本章中我们考虑的分类模型是直接使用原始输入向量 $\mathbf{x}$ 进行工作的。然而，如果我们首先使用基函数向量 $\phi(\mathbf{x})$ 对输入进行一个固定的非线性变换，那么所有这些算法同样适用。由此产生的决策边界在特征空间 ϕ 中是线性的，而这些决策边界在原始 $\mathbf{x}$ 空间中对应于非线性决策边界，如图 4.12 所示。在特征空间 $\phi(\mathbf{x})$ 中线性可分的类，在原始观测空间 $\mathbf{x}$ 中不一定是线性可分的。请注意，正如我们在讨论回归的线性模型时所讨论的，其中一个基函数通常设置为常数，例如 $\phi_0(\mathbf{x}) = 1$ ，因此对应的参数 w_0 扮演着偏置的角色。在本章的其余部分，我们将包含一个固定的基函数变换 $\phi(\mathbf{x})$ ，因为这将突出与第 3 章讨论的回归模型的一些有用相似之处。




图 4.12 说明非线性基函数在线性分类模型中的作用。左图为原始输入空间 (x_1, x_2) ，其中包含红色与蓝色两类数据点。该空间中定义了两个“高斯”基函数 $\phi_1(x)$ 和 $\phi_2(x)$ ，其中心位置以绿色叉号表示，等值线以绿色圆圈表示。右图为对应的特征空间 (ϕ_1, ϕ_2) ，并给出了基于第 4.3.2 节讨论的逻辑回归模型得到的线性决策边界。在原始输入空间中，该线性边界对应于一条非线性决策边界，见左图中的黑色曲线。

对于许多实际感兴趣的问题，类条件概率密度 $p(\mathbf{x} | C_k)$ 之间存在显著的重叠。这对应于后验概率 $p(C_k | \mathbf{x})$ ，对于至少某些 $\mathbf{x}$ 值而言，它们既不是 0 也不是 1。在这种情况下，最优解是通过准确建模后验概率，然后应用标准决策理论获得的，如第 1 章所讨论。请注意，非线性变换 $\phi(\mathbf{x})$ 不能消除这种类别重叠。事实上，它们可能会增加重叠的程度，或者在原始观测空间中不存在重叠的地方创建重叠。然而，适当选择的非线性可以使建模后验概率的过程更容易。

这种固定基函数模型具有重要的局限性，这些局限性将在后面的章节中通过允许基函数本身适应数据来解决。尽管存在这些局限性，带有固定非线性基函数的模型在应用中仍扮演着重要角色，对这些模型的讨论将引入理解其更复杂对应物所需的许多关键概念。

4.3.2 逻辑回归

我们从考虑二分类问题开始，对广义线性模型进行处理。在我们在第 4.2 节中生成方法的讨论中，我们看到在相当一般的假设下，类别 $\mathcal{C}_1$ 的后验概率可以写成作用在特征向量 ϕ 的线性函数上的逻辑 S 形函数，即

$$p(\mathcal{C}_1 | \phi) = y(\phi) = \sigma(\mathbf{w}^T \phi) \quad (4.87)$$

其中 $p(\mathcal{C}_2 | \phi) = 1 - p(\mathcal{C}_1 | \phi)$ 。这里的 $\sigma(\cdot)$ 是由 (4.59) 定义的逻辑 S 形函数。在统计学的术语中，该模型被称为逻辑回归，但需要强调的是，这是一个用于分类而非回归的模型。

对于一个 M 维的特征空间 ϕ ，该模型有 M 个可调参数。相比之下，如果我们使用最大似然法拟合高斯类别条件密度，我们将为均值使用 $2M$ 个参数，为（共享的）协方差矩阵使用 $M(M+1)/2$ 个参数。再加上类别先验 $p(\mathcal{C}_1)$ ，参数总数为 $M(M+5)/2 + 1$ 个，它随 M 二次增长，与逻辑回归中参数数量对 M 的线性依赖形成对比。对于较大的 M 值，直接使用逻辑回归模型具有明显的优势。

我们现在使用最大似然法来确定逻辑回归模型的参数。为此，我们将利用逻辑 S 形函数的导数，它可以方便地用 S 形函数本身来表达

$$\frac{d\sigma}{da} = \sigma(1 - \sigma) \quad (4.88)$$

对于一个数据集 $\{\phi_n, t_n\}$ ，其中 $t_n \in \{0, 1\}$ 且 $\phi_n = \phi(\mathbf{x}_n)$ ， $n = 1, \dots, N$ ，似然函数可以写成

$$p(\mathbf{t} | \mathbf{w}) = \prod_{n=1}^N y_n^{t_n} \{1 - y_n\}^{1-t_n} \quad (4.89)$$

其中 $\mathbf{t} = (t_1, \dots, t_N)^T$ 且 $y_n = p(\mathcal{C}_1 | \phi_n)$ 。像往常一样，我们可以通过取似然的负对数来定义一个误差函数，从而得到以下形式的交叉熵误差函数

$$E(\mathbf{w}) = -\ln p(\mathbf{t} | \mathbf{w}) = -\sum_{n=1}^N \{t_n \ln y_n + (1 - t_n) \ln(1 - y_n)\} \quad (4.90)$$

其中 $y_n = \sigma(a_n)$ 且 $a_n = \mathbf{w}^T \phi_n$ 。对 $E(\mathbf{w})$ 关于 $\mathbf{w}$ 取梯度，我们得到

$$\nabla E(\mathbf{w}) = \sum_{n=1}^N (y_n - t_n) \phi_n \quad (4.91)$$

这里我们使用了 (4.88) 的结果。我们看到，涉及逻辑 S 形函数导数的因子被抵消了，从而使得对数似然的梯度形式得以简化。特别是，数据点 n 对梯度的贡献由目标值与模型预测值之间的“误差” $y_n - t_n$ 乘以基函数向量 ϕ_n 给出。此外，与 (3.13) 比较表明，这与线性回归模型的平方和误差函数的梯度具有完全相同的形式。

如果需要，我们可以利用结果 (4.91) 给出一个序列算法，其中模式被逐个呈现，并使用 (3.22) 更新每个权重向量，其中 ∇E_n 是 (4.91) 中的第 n^{th} 项。

值得注意的是，对于线性可分的数据集，最大似然法可能会表现出严重的过拟合。这是因为最大似然解发生在对应于 $\sigma = 0.5$ （等价于 $\mathbf{w}^T \phi = 0$ ）的超平面将两类分开，并且 $\mathbf{w}$ 的幅值趋于无穷大时。在这种情况下，逻辑 S 形函数在特征空间中变得无限陡峭，对应于一个赫维赛德阶跃函数，从而将来自每个类别 k 的每个训练点都分配给后验概率 $p(C_k | \mathbf{x}) = 1$ 。此外，通常存在一个解的连续体，因为任何分离超平面都会在训练数据点处产生相同的后验概率，正如稍后在图 10.13 中将看到的。最大似然法无法在这些解中偏爱任何一个，实践中找到哪个解将取决于所选的优化算法和参数初始化。请注意，即使数据点的数量相对于模型中参数的数量很大，只要训练数据集是线性可分的，这个问题就会出现。可以通过纳入先验并找到 $\mathbf{w}$ 的 MAP 解，或者等效地通过向误差函数添加正则化项来避免这种奇异性。

4.3.3 迭代重加权最小二乘法

在第 3 章讨论的线性回归模型的情况下，在高斯噪声模型的假设下，最大似然解可得到闭式解。这是因为对数似然函数对参数向量 $\mathbf{w}$ 具有二次依赖性。对于逻辑回归，由于逻辑 S 形函数的非线性，不再存在闭式解。然而，与二次形式的偏离并不大。确切地说，误差函数是凹函数，正如我们稍后将看到的，因此它具有唯一的最小值。此外，可以使用基于牛顿-拉夫逊（Newton-Raphson）迭代优化方案的高效迭代技术来最小化误差函数，该方案使用对数似然函数的局部二次近似。用于最小化函数 $E(\mathbf{w})$ 的牛顿-拉夫逊更新形式为 (Fletcher, 1987; Bishop and Nabney, 2008)

$$\mathbf{w}^{(\text{new})} = \mathbf{w}^{(\text{old})} - \mathbf{H}^{-1} \nabla E(\mathbf{w}) \quad (4.92)$$

其中 $\mathbf{H}$ 是 Hessian 矩阵，其元素包含 $E(\mathbf{w})$ 关于 $\mathbf{w}$ 分量的二阶导数。

让我们首先将牛顿-拉夫逊方法应用于具有平方和误差函数 (3.12) 的线性回归模型 (3.3)。该误差函数的梯度和 Hessian 矩阵由下式给出

$$\nabla E(\mathbf{w}) = \sum_{n=1}^N (\mathbf{w}^T \phi_n - t_n) \phi_n = \Phi^T \Phi \mathbf{w} - \Phi^T \mathbf{t} \quad (4.93)$$

$$\mathbf{H} = \nabla \nabla E(\mathbf{w}) = \sum_{n=1}^N \phi_n \phi_n^T = \Phi^T \Phi \quad (4.94)$$

其中 Φ 是 $N \times M$ 设计矩阵，其第 n^{th} 行由 ϕ_n^T 给出。牛顿-拉夫逊更新然后采用以下形式

$$\begin{aligned} \mathbf{w}^{(\text{new})} &= \mathbf{w}^{(\text{old})} - (\Phi^T \Phi)^{-1} \{ \Phi^T \Phi \mathbf{w}^{(\text{old})} - \Phi^T \mathbf{t} \} \\ &= (\Phi^T \Phi)^{-1} \Phi^T \mathbf{t} \end{aligned} \quad (4.95)$$

我们认识到这就是标准最小二乘解。请注意，在这种情况下，误差函数是二次的，因此牛顿-拉夫逊公式在一步中即可给出精确解。

现在让我们将牛顿-拉夫逊更新应用于逻辑回归模型的交叉熵误差函数 (4.90)。从

(4.91) 我们看到, 该误差函数的梯度和 Hessian 矩阵由下式给出

$$\nabla E(\mathbf{w}) = \sum_{n=1}^N (y_n - t_n) \phi_n = \Phi^T(\mathbf{y} - \mathbf{t}) \quad (4.96)$$

$$\mathbf{H} = \nabla \nabla E(\mathbf{w}) = \sum_{n=1}^N y_n (1 - y_n) \phi_n \phi_n^T = \Phi^T \mathbf{R} \Phi \quad (4.97)$$

其中我们使用了 (4.88)。此外, 我们引入了 $N \times N$ 对角矩阵 $\mathbf{R}$, 其元素为

$$R_{nn} = y_n (1 - y_n) \quad (4.98)$$

我们看到 Hessian 矩阵不再是常数, 而是通过权重矩阵 $\mathbf{R}$ 依赖于 $\mathbf{w}$, 这对应于误差函数不再是二次的这一事实。利用逻辑 S 形函数的形式所带来的性质 $0 < y_n < 1$, 我们看到对于任意向量 $\mathbf{u}$, 有 $\mathbf{u}^T \mathbf{H} \mathbf{u} > 0$, 因此 Hessian 矩阵 $\mathbf{H}$ 是正定的。由此可知, 误差函数是 $\mathbf{w}$ 的凹函数, 因此具有唯一的最小值。

对于逻辑回归模型, 牛顿-拉夫逊更新公式变为

$$\begin{aligned} \mathbf{w}^{(\text{new})} &= \mathbf{w}^{(\text{old})} - (\Phi^T \mathbf{R} \Phi)^{-1} \Phi^T(\mathbf{y} - \mathbf{t}) \\ &= (\Phi^T \mathbf{R} \Phi)^{-1} \{ \Phi^T \mathbf{R} \Phi \mathbf{w}^{(\text{old})} - \Phi^T(\mathbf{y} - \mathbf{t}) \} \\ &= (\Phi^T \mathbf{R} \Phi)^{-1} \Phi^T \mathbf{R} \mathbf{z} \end{aligned} \quad (4.99)$$

其中 $\mathbf{z}$ 是一个 N 维向量, 其元素为

$$\mathbf{z} = \Phi \mathbf{w}^{(\text{old})} - \mathbf{R}^{-1}(\mathbf{y} - \mathbf{t}) \quad (4.100)$$

我们看到, 更新公式 (4.99) 采用了加权最小二乘问题的正规方程组的形式。由于加权矩阵 $\mathbf{R}$ 不是常数, 而是取决于参数向量 $\mathbf{w}$, 我们必须迭代地应用正规方程组, 每次都使用新的权重向量 $\mathbf{w}$ 来计算修正后的加权矩阵 $\mathbf{R}$ 。因此, 该算法被称为迭代重加权最小二乘法 (iterative reweighted least squares), 简称 IRLS (Rubin, 1983)。与加权最小二乘问题中一样, 对角加权矩阵 $\mathbf{R}$ 的元素可以解释为方差, 因为逻辑回归模型中 t 的均值和方差由下式给出

$$\mathbb{E}[t] = \sigma(\mathbf{x}) = y \quad (4.101)$$

$$\text{var}[t] = \mathbb{E}[t^2] - \mathbb{E}[t]^2 = \sigma(\mathbf{x}) - \sigma(\mathbf{x})^2 = y(1 - y) \quad (4.102)$$

其中我们使用了 $t \in \{0, 1\}$ 时 $t^2 = t$ 的性质。实际上, 我们可以将 IRLS 解释为在变量 $a = \mathbf{w}^T \phi$ 空间中线性化问题的解。然后, 对应于 $\mathbf{z}$ 的第 n^{th} 个元素的量 z_n 可以在该空间中被简单地解释为一个有效目标值, 该值是通过在当前工作点 $\mathbf{w}^{(\text{old})}$ 周围对逻辑 S 形函数进行局部线性近似获得的

$$\begin{aligned} a_n(\mathbf{w}) &\simeq a_n(\mathbf{w}^{(\text{old})}) + \left. \frac{da_n}{dy_n} \right|_{\mathbf{w}^{(\text{old})}} (t_n - y_n) \\ &= \phi_n^T \mathbf{w}^{(\text{old})} - \frac{(y_n - t_n)}{y_n(1 - y_n)} = z_n. \end{aligned} \quad (4.103)$$

4.3.4 多类别逻辑回归

在我们关于多类别分类的生成模型的讨论中，我们已经看到，对于一大类分布，后验概率由特征变量的线性函数的 **Softmax** 变换给出，因此

$$p(\mathcal{C}_k | \phi) = y_k(\phi) = \frac{\exp(a_k)}{\sum_j \exp(a_j)} \quad (4.104)$$

其中“激活” a_k 由下式给出

$$a_k = \mathbf{w}_k^T \phi \quad (4.105)$$

在那里，我们使用最大似然法分别确定类别条件密度和类别先验，然后使用贝叶斯定理找到相应的后验概率，从而隐式地确定了参数 $\{\mathbf{w}_k\}$ 。在这里，我们考虑使用最大似然法直接确定该模型的参数 $\{\mathbf{w}_k\}$ 。为此，我们需要 y_k 关于所有激活 a_j 的导数。它们由下式给出

$$\frac{\partial y_k}{\partial a_j} = y_k (I_{kj} - y_j) \quad (4.106)$$

其中 I_{kj} 是单位矩阵的元素。接下来我们写出似然函数。这最容易通过使用 1-of- K 编码方案来完成，在该方案中，属于类别 $\mathcal{C}_k$ 的特征向量 ϕ_n 的目标向量 $\mathbf{t}_n$ 是一个二元向量，除了元素 k 等于一之外，所有元素都为零。则似然函数由下式给出

$$p(\mathbf{T} | \mathbf{w}_1, \dots, \mathbf{w}_K) = \prod_{n=1}^N \prod_{k=1}^K p(\mathcal{C}_k | \phi_n)^{t_{nk}} = \prod_{n=1}^N \prod_{k=1}^K y_{nk}^{t_{nk}} \quad (4.107)$$

其中 $y_{nk} = y_k(\phi_n)$ ，而 $\mathbf{T}$ 是一个 $N \times K$ 目标变量矩阵，其元素为 t_{nk} 。取负对数则得到

$$E(\mathbf{w}_1, \dots, \mathbf{w}_K) = -\ln p(\mathbf{T} | \mathbf{w}_1, \dots, \mathbf{w}_K) = -\sum_{n=1}^N \sum_{k=1}^K t_{nk} \ln y_{nk} \quad (4.108)$$

这被称为多类别分类问题的交叉熵误差函数。

我们现在对误差函数关于其中一个参数向量 $\mathbf{w}_j$ 取梯度。利用 **Softmax** 函数导数的结果 (4.106)，我们得到

$$\nabla_{\mathbf{w}_j} E(\mathbf{w}_1, \dots, \mathbf{w}_K) = \sum_{n=1}^N (y_{nj} - t_{nj}) \phi_n \quad (4.109)$$

其中我们使用了 $\sum_k t_{nk} = 1$ 的性质。我们再次看到与线性模型的平方和误差函数和逻辑回归模型的交叉熵误差所发现的梯度具有相同的形式，即误差 $(y_{nj} - t_{nj})$ 乘以基函数 ϕ_n 的乘积。同样，我们可以使用它来制定一个序列算法，其中模式被逐个呈现，并使用 (3.22) 更新每个权重向量。

我们已经看到，对于数据点 n ，线性回归模型的对数似然函数关于参数向量 $\mathbf{w}$ 的导数采用误差 $y_n - t_n$ 乘以特征向量 ϕ_n 的形式。类似地，对于逻辑 S 形激活函数和交叉熵误差函数 (4.90) 的组合，以及 **Softmax** 激活函数和多类别交叉熵误差函数 (4.108) 的组合，我们再次获得了这种相同的简单形式。正如我们将在第 4.3.6 节中看到的，这是一个更一般结果的例子。

为了找到一个批处理算法，我们再次诉诸牛顿-拉夫逊更新，以获得多类别问题相应的 IRLS 算法。这需要评估 Hessian 矩阵，该矩阵包含大小为 $M \times M$ 的块，其中块 j, k 由下式给出

$$\nabla_{\mathbf{w}_k} \nabla_{\mathbf{w}_j} E(\mathbf{w}_1, \dots, \mathbf{w}_K) = - \sum_{n=1}^N y_{nk} (I_{kj} - y_{nj}) \phi_n \phi_n^T \quad (4.110)$$

与两类别问题一样，多类别逻辑回归模型的 Hessian 矩阵是正定的，因此误差函数再次具有唯一的最小值。多类别情况下 IRLS 的实践细节可以在 Bishop and Nabney (2008) 中找到。

4.3.5 概率单位回归 (Probit Regression)

我们已经看到，对于指数族描述的广泛类别条件分布，所得的后验类别概率由作用在特征变量的线性函数上的逻辑（或 Softmax）变换给出。然而，并非所有类别条件密度的选择都会产生这种简单的后验概率形式（例如，如果类别条件密度是使用高斯混合建模的）。这表明可能值得探索其他类型的判别概率模型。然而，对于本章的目的，我们将回到两类别情况，并仍停留在广义线性模型的框架内，因此

$$p(t = 1 | a) = f(a) \quad (4.111)$$

其中 $a = \mathbf{w}^T \phi$ ，而 $f(\cdot)$ 是激活函数。

激励连接函数（link function）的替代选择的一种方法是考虑一个带噪声的阈值模型，如下所示。对于每个输入 ϕ_n ，我们评估 $a_n = \mathbf{w}^T \phi_n$ ，然后我们根据以下规则设置目标值

$$\begin{cases} t_n = 1 & \text{if } a_n \geq \theta \\ t_n = 0 & \text{otherwise} \end{cases} \quad (4.112)$$

如果 θ 的值是从概率密度 $p(\theta)$ 中抽取的，那么相应的激活函数将由累积分布函数给出

$$f(a) = \int_{-\infty}^a p(\theta) d\theta \quad (4.113)$$

如图 4.13 所示。


作为一个具体的例子，假设密度 $p(\theta)$ 由一个零均值、单位方差的高斯分布给出。相应的累积分布函数由下式给出

$$\Phi(a) = \int_{-\infty}^a \mathcal{N}(\theta | 0, 1) d\theta \quad (4.114)$$

这被称为 Probit 函数（probit function）。它具有 S 形，并与逻辑 S 形函数在图 4.9 中进行了比较。请注意，使用更一般的高斯分布不会改变模型，因为这等效于线性系数 $\mathbf{w}$ 的重新缩放。许多数值软件包提供了对一个密切相关函数的评估，该函数定义为

$$\text{erf}(a) = \frac{2}{\sqrt{\pi}} \int_0^a \exp(-\theta^2/2) d\theta \quad (4.115)$$

图 4.13 示意图展示了概率密度 $p(\theta)$ (蓝色曲线), 该示例中其由两个高斯混合而成, 以及其累积分布函数 $f(a)$ (红色曲线)。注意, 蓝色曲线在任意一点的取值 (如绿色竖线所示位置) 对应红色曲线在同一点的斜率; 反之, 红色曲线在该点的取值对应于蓝色曲线下方绿色阴影区域所代表的面积。在随机阈值模型中, 当 $a = \mathbf{w}^T \phi$ 的值超过某个阈值时类别标签取 $t = 1$, 否则取 $t = 0$ 。这等价于使用累积分布函数 $f(a)$ 作为激活函数。



被称为 **erf** 函数或误差函数 (不要与机器学习模型的误差函数混淆)。它与概率单位函数的关系为

$$\Phi(a) = \frac{1}{2} \left\{ 1 + \frac{1}{\sqrt{2}} \operatorname{erf}(a) \right\}. \quad (4.116)$$

基于 **Probit** 激活函数的广义线性模型被称为 **Probit** 回归。

我们可以使用最大似然法来确定该模型的参数, 只需对前面讨论的思想进行直接扩展即可。实际上, 使用概率单位回归发现的结果往往与逻辑回归的结果相似。然而, 当我们在第 4.5 节讨论逻辑回归的贝叶斯处理时, 我们将发现概率单位模型的另一种用途。

在实际应用中可能出现的一个问题是异常值 (outliers), 它可能例如通过输入向量 $\mathbf{x}$ 的测量误差或目标值 t 的错误标记而产生。由于这些点可能位于理想决策边界的错误一侧很远的地方, 它们会严重扭曲分类器。请注意, 逻辑回归模型和概率单位回归模型在这方面表现不同, 因为对于 $x \rightarrow \infty$, 逻辑 S 形的尾部以 $\exp(-x)$ 的形式渐近衰减, 而对于概率单位激活函数, 它们以 $\exp(-x^2)$ 的形式衰减, 因此概率单位模型可能对异常值显著更敏感。

然而, 逻辑模型和概率单位模型都假设数据被正确标记。错误标记的影响很容易纳入概率模型中, 方法是引入一个概率 ϵ , 表示目标值 t 被翻转到错误值 (Oppen and Winther, 2000a), 从而导致数据点 $\mathbf{x}$ 的目标值分布形式为

$$\begin{aligned} p(t | \mathbf{x}) &= (1 - \epsilon)\sigma(\mathbf{x}) + \epsilon(1 - \sigma(\mathbf{x})) \\ &= \epsilon + (1 - 2\epsilon)\sigma(\mathbf{x}) \end{aligned} \quad (4.117)$$

其中 $\sigma(\mathbf{x})$ 是输入向量 $\mathbf{x}$ 的激活函数。这里的 ϵ 可以预先设定, 也可以被视为一个超参数, 其值从数据中推断出来。

4.3.6 典则连接函数

对于具有高斯噪声分布的线性回归模型, 对应于负对数似然的误差函数由 (3.12) 给出。如果我们对误差函数中来自数据点 n 的贡献关于参数向量 $\mathbf{w}$ 取导数, 它采用误差 $y_n - t_n$ 乘以特征向量 ϕ_n 的形式, 其中 $y_n = \mathbf{w}^T \phi_n$ 。类似地, 对于逻辑 S 形激活函数和

交叉熵误差函数 (4.90) 的组合, 以及 Softmax 激活函数和多类别交叉熵误差函数 (4.108) 的组合, 我们再次获得了这种相同的简单形式。我们现在证明这是一个一般性结果, 即假设目标变量的条件分布来自指数族, 并伴随着激活函数的相应选择, 该选择被称为正则连接函数。

我们再次使用指数族分布的受限形式 (4.84)。请注意, 这里我们将指数族分布的假设应用于目标变量 t , 这与第 4.2.4 节中将其应用于输入向量 $\mathbf{x}$ 形成对比。因此, 我们考虑目标变量的条件分布形式为

$$p(t | \eta, s) = \frac{1}{s} h\left(\frac{t}{s}\right) g(\eta) \exp\left\{\frac{\eta t}{s}\right\}. \quad (4.118)$$

使用导致推导出结果 (2.226) 的相同推理思路, 我们看到 t 的条件均值, 我们将其表示为 y , 由下式给出

$$y \equiv \mathbb{E}[t | \eta] = -s \frac{d}{d\eta} \ln g(\eta) \quad (4.119)$$

因此 y 和 η 必须相关, 我们通过 $\eta = \psi(y)$ 来表示这种关系。

遵循 Nelder 和 Wedderburn (1972) 的定义, 我们广义线性模型定义为 y 是输入 (或特征) 变量的线性组合的非线性函数的模型, 因此

$$y = f(\mathbf{w}^T \boldsymbol{\phi}) \quad (4.120)$$

其中 $f(\cdot)$ 在机器学习文献中被称为激活函数, 而 $f^{-1}(\cdot)$ 在统计学中被称为连接函数 (link function)。

现在考虑该模型的对数似然函数, 它作为 η 的函数, 由下式给出

$$\ln p(\mathbf{t} | \eta, s) = \sum_{n=1}^N \ln p(t_n | \eta, s) = \sum_{n=1}^N \left\{ \ln g(\eta_n) + \frac{\eta_n t_n}{s} \right\} + \text{const} \quad (4.121)$$

其中我们假设所有观测值共享一个共同的尺度参数 (例如, 对于高斯分布, 它对应于噪声方差), 因此 s 独立于 n 。对数似然关于模型参数 $\mathbf{w}$ 的导数然后由下式给出

$$\begin{aligned} \nabla_{\mathbf{w}} \ln p(\mathbf{t} | \eta, s) &= \sum_{n=1}^N \left\{ \frac{d}{d\eta_n} \ln g(\eta_n) + \frac{t_n}{s} \right\} \frac{d\eta_n}{dy_n} \frac{dy_n}{da_n} \nabla a_n \\ &= \sum_{n=1}^N \frac{1}{s} \{t_n - y_n\} \psi'(y_n) f'(a_n) \phi_n \end{aligned} \quad (4.122)$$

其中 $a_n = \mathbf{w}^T \phi_n$, 并且我们使用了 $y_n = f(a_n)$ 以及 $\mathbb{E}[t | \eta]$ 的结果 (4.119)。我们现在看到, 如果我们对连接函数 $f^{-1}(y)$ 选择由下式给出的特定形式, 就会有极大的简化

$$f^{-1}(y) = \psi(y) \quad (4.123)$$

这给出 $f(\psi(y)) = y$, 因此 $f'(\psi)\psi'(y) = 1$ 。此外, 因为 $a = f^{-1}(y)$, 我们有 $a = \psi$, 因此 $f'(a)\psi'(y) = 1$ 。在这种情况下, 误差函数的梯度简化为

$$\nabla \ln E(\mathbf{w}) = \frac{1}{s} \sum_{n=1}^N \{y_n - t_n\} \phi_n \quad (4.124)$$

对于高斯分布 $s = \beta^{-1}$, 而对于逻辑模型 $s = 1$ 。

4.4 拉普拉斯近似

在第 4.5 节中，我们将讨论逻辑回归的贝叶斯处理。正如我们将看到的，这比第 3.3 节和第 3.5 节中讨论的线性回归模型的贝叶斯处理更复杂。特别是，我们无法对参数向量 $\mathbf{w}$ 进行精确积分，因为后验分布不再是高斯分布。因此，有必要引入某种形式的近似。在本书的后面，我们将考虑一系列基于解析近似和数值采样的技术。

这里我们介绍一个简单但广泛使用的框架，称为拉普拉斯近似 (Laplace approximation)，其目的是为定义在一组连续变量上的概率密度找到一个高斯近似。首先考虑单个连续变量 z 的情况，假设分布 $p(z)$ 由下式定义

$$p(z) = \frac{1}{Z} f(z) \quad (4.125)$$

其中 $Z = \int f(z) dz$ 是归一化系数。我们将假设 Z 的值是未知的。在拉普拉斯方法中，目标是找到一个高斯近似 $q(z)$ ，它以分布 $p(z)$ 的众数为中心。第一步是找到 $p(z)$ 的一个众数，换句话说，找到一个点 z_0 ，使得 $p'(z_0) = 0$ ，或者等价地

$$\left. \frac{df(z)}{dz} \right|_{z=z_0} = 0. \quad (4.126)$$

高斯分布具有这样的性质：它的对数是变量的二次函数。因此，我们考虑以众数 z_0 为中心的 $\ln f(z)$ 的泰勒展开，因此

$$\ln f(z) \simeq \ln f(z_0) - \frac{1}{2} A (z - z_0)^2 \quad (4.127)$$

其中

$$A = - \left. \frac{d^2}{dz^2} \ln f(z) \right|_{z=z_0} \quad (4.128)$$

请注意，泰勒展开中的一阶项没有出现，因为 z_0 是分布的局部最大值。取指数，我们得到

$$f(z) \simeq f(z_0) \exp \left\{ -\frac{A}{2} (z - z_0)^2 \right\} \quad (4.129)$$

然后我们可以利用高斯分布归一化的标准结果来获得一个归一化分布 $q(z)$ ，因此

$$q(z) = \left(\frac{A}{2\pi} \right)^{1/2} \exp \left\{ -\frac{A}{2} (z - z_0)^2 \right\}. \quad (4.130)$$

拉普拉斯近似如图 4.14 所示。请注意，高斯近似只有在它的精度 $A > 0$ 时才定义良好，换句话说，驻点 z_0 必须是一个局部最大值，这样 $f(z)$ 在点 z_0 处的二阶导数才是负的。

我们可以将拉普拉斯方法扩展到近似定义在 M 维空间 $\mathbf{z}$ 上的分布 $p(\mathbf{z}) = f(\mathbf{z})/Z$ 。在驻点 $\mathbf{z}_0$ 处，梯度 $\nabla f(\mathbf{z})$ 将消失。围绕该驻点展开，我们有

$$\ln f(\mathbf{z}) \simeq \ln f(\mathbf{z}_0) - \frac{1}{2} (\mathbf{z} - \mathbf{z}_0)^T \mathbf{A} (\mathbf{z} - \mathbf{z}_0) \quad (4.131)$$

其中 $M \times M$ Hessian 矩阵 $\mathbf{A}$ 定义为

$$\mathbf{A} = - \nabla \nabla \ln f(\mathbf{z})|_{\mathbf{z}=\mathbf{z}_0} \quad (4.132)$$




图 4.14 对分布 $p(z) \propto \exp(-z^2/2) \sigma(20z + 4)$ 应用拉普拉斯近似的示意图，其中 $\sigma(z)$ 是由 $\sigma(z) = (1 + e^{-z})^{-1}$ 定义的 logistic sigmoid 函数。左图显示了归一化后的分布 $p(z)$ （黄色），以及以 $p(z)$ 的模态 z_0 为中心的拉普拉斯近似（红色）。右图展示了对应曲线的负对数形式。

而 ∇ 是梯度算子。对两边取指数，我们得到

$$f(\mathbf{z}) \simeq f(\mathbf{z}_0) \exp \left\{ -\frac{1}{2} (\mathbf{z} - \mathbf{z}_0)^T \mathbf{A} (\mathbf{z} - \mathbf{z}_0) \right\}. \quad (4.133)$$

分布 $q(\mathbf{z})$ 与 $f(\mathbf{z})$ 成比例，并且可以使用归一化多元高斯分布的标准结果 (2.43) 通过观察找到适当的归一化系数，给出

$$q(\mathbf{z}) = \frac{|\mathbf{A}|^{1/2}}{(2\pi)^{M/2}} \exp \left\{ -\frac{1}{2} (\mathbf{z} - \mathbf{z}_0)^T \mathbf{A} (\mathbf{z} - \mathbf{z}_0) \right\} = \mathcal{N}(\mathbf{z} | \mathbf{z}_0, \mathbf{A}^{-1}) \quad (4.134)$$

其中 $|\mathbf{A}|$ 表示 $\mathbf{A}$ 的行列式。当其精度矩阵 $\mathbf{A}$ 是正定时，这个高斯分布将定义良好，这意味着驻点 $\mathbf{z}_0$ 必须是局部最大值，而不是最小值或鞍点。

为了应用拉普拉斯近似，我们首先需要找到众数 $\mathbf{z}_0$ ，然后在该众数处评估 Hessian 矩阵。在实践中，众数通常通过运行某种形式的数值优化算法找到 (Bishop and Nabney, 2008)。实践中遇到的许多分布将是多峰的，因此根据考虑的众数，会有不同的拉普拉斯近似。请注意，为了应用拉普拉斯方法，真实分布的归一化常数 Z 不需要是已知的。由于中心极限定理，随着观测数据点数量的增加，模型的后验分布预计将越来越好地被高斯分布近似，因此我们期望拉普拉斯近似在数据点数量相对较大的情况下最有用。

拉普拉斯近似的一个主要弱点是，由于它基于高斯分布，因此它只直接适用于实变量。在其他情况下，可以将拉普拉斯近似应用于变量的变换。例如，如果 $0 \leq \tau < \infty$ ，那么我们可以考虑 $\ln \tau$ 的拉普拉斯近似。然而，拉普拉斯框架最严重的限制是它纯粹基于真实分布在变量的特定值处的方面，因此可能无法捕捉重要的全局属性。在第 10 章中，我们将考虑采用更全局视角的替代方法。

4.4.1 模型对比和贝叶斯信息准则 (BIC)

除了近似分布 $p(\mathbf{z})$ 之外,我们还可以获得归一化常数 Z 的近似值。使用近似 (4.133), 我们有

$$\begin{aligned} Z &= \int f(\mathbf{z}) d\mathbf{z} \\ &\simeq f(\mathbf{z}_0) \int \exp \left\{ -\frac{1}{2} (\mathbf{z} - \mathbf{z}_0)^T \mathbf{A} (\mathbf{z} - \mathbf{z}_0) \right\} d\mathbf{z} \\ &= f(\mathbf{z}_0) \frac{(2\pi)^{M/2}}{|\mathbf{A}|^{1/2}} \end{aligned} \quad (4.135)$$

这里我们注意到被积函数是高斯分布,并使用了归一化高斯分布的标准结果 (2.43)。我们可以使用结果 (4.135) 来获得模型证据的近似值,正如第 3.4 节所讨论的,它在贝叶斯模型比较中起着核心作用。

考虑一个数据集 $\mathcal{D}$ 和一组具有参数 $\{\theta_i\}$ 的模型 $\{\mathcal{M}_i\}$ 。对于每个模型,我们定义一个似然函数 $p(\mathcal{D} | \theta_i, \mathcal{M}_i)$ 。如果我们在参数上引入一个先验 $p(\theta_i | \mathcal{M}_i)$, 那么我们感兴趣的是计算各种模型的模型证据 $p(\mathcal{D} | \mathcal{M}_i)$ 。从现在开始,我们省略对 $\mathcal{M}_i$ 的条件依赖以保持符号简洁。根据贝叶斯定理,模型证据由下式给出

$$p(\mathcal{D}) = \int p(\mathcal{D} | \theta) p(\theta) d\theta \quad (4.136)$$

将 $f(\theta) = p(\mathcal{D} | \theta) p(\theta)$ 和 $Z = p(\mathcal{D})$ 对应起来,并应用结果 (4.135), 我们得到

$$\ln p(\mathcal{D}) \simeq \ln p(\mathcal{D} | \theta_{\text{MAP}}) + \underbrace{\ln p(\theta_{\text{MAP}}) + \frac{M}{2} \ln(2\pi) - \frac{1}{2} \ln |\mathbf{A}|}_{\text{奥卡姆因子}} \quad (4.137)$$

其中 θ_{MAP} 是后验分布众数处的 θ 值,而 $\mathbf{A}$ 是负对数后验的二阶导数的 Hessian 矩阵

$$\mathbf{A} = -\nabla \nabla \ln p(\mathcal{D} | \theta_{\text{MAP}}) p(\theta_{\text{MAP}}) = -\nabla \nabla \ln p(\theta_{\text{MAP}} | \mathcal{D}) \quad (4.138)$$

(4.137) 右侧的第一项表示使用优化后的参数评估的对数似然,而剩余的三项构成了“奥卡姆因子”(Occam factor),它惩罚模型复杂度。

如果我们假设参数上的高斯先验分布是宽泛的,并且 Hessian 矩阵具有满秩,那么我们可以使用以下公式非常粗略地近似 (4.137)

$$\ln p(\mathcal{D}) \simeq \ln p(\mathcal{D} | \theta_{\text{MAP}}) - \frac{1}{2} M \ln N \quad (4.139)$$

其中 N 是数据点的数量, M 是 θ 中的参数数量,我们省略了加性常数。这被称为贝叶斯信息准则 (Bayesian Information Criterion, BIC) 或 Schwarz 准则 (Schwarz, 1978)。请注意,与 (1.73) 给出的 AIC 相比,这更严厉地惩罚了模型复杂度。

复杂性度量,例如 AIC 和 BIC,具有易于评估的优点,但也可能给出误导性的结果。特别是, Hessian 矩阵具有满秩的假设通常是无效的,因为许多参数不是“充分确定的”。我们可以使用结果 (4.137) 从拉普拉斯近似开始获得模型证据的更准确估计,正如我们在第 5.7 节中在神经网络的背景下所说明的那样。

4.5 贝叶斯逻辑回归

我们现在转向逻辑回归的贝叶斯处理。逻辑回归的精确贝叶斯推断是难解的（intractable）。特别是，后验分布的评估需要对先验分布和一个似然函数的乘积进行归一化，而似然函数本身又包含逻辑 S 形函数的乘积，每个数据点一个。预测分布的评估同样难解。在这里，我们考虑将拉普拉斯近似应用于贝叶斯逻辑回归问题 (Spiegelhalter and Lauritzen, 1990; MacKay, 1992b)。

4.5.1 拉普拉斯近似

回想一下第 4.4 节，拉普拉斯近似是通过找到后验分布的众数，然后拟合一个以该众数为中心的高斯分布来获得的。这需要评估对数后验的二阶导数，这等价于找到 Hessian 矩阵。

因为我们寻求后验分布的高斯表示，所以自然地从小高斯先验开始，我们将其写成一般形式

$$p(\mathbf{w}) = \mathcal{N}(\mathbf{w} \mid \mathbf{m}_0, \mathbf{S}_0) \quad (4.140)$$

其中 $\mathbf{m}_0$ 和 $\mathbf{S}_0$ 是固定超参数。关于 $\mathbf{w}$ 的后验分布由下式给出

$$p(\mathbf{w} \mid \mathbf{t}) \propto p(\mathbf{w})p(\mathbf{t} \mid \mathbf{w}) \quad (4.141)$$

其中 $\mathbf{t} = (t_1, \dots, t_N)^T$ 。对两边取对数，并使用 (4.140) 代入先验分布，使用 (4.89) 代入似然函数，我们得到

$$\begin{aligned} \ln p(\mathbf{w} \mid \mathbf{t}) = & -\frac{1}{2}(\mathbf{w} - \mathbf{m}_0)^T \mathbf{S}_0^{-1}(\mathbf{w} - \mathbf{m}_0) \\ & + \sum_{n=1}^N \{t_n \ln y_n + (1 - t_n) \ln (1 - y_n)\} + \text{const} \end{aligned} \quad (4.142)$$

其中 $y_n = \sigma(\mathbf{w}^T \phi_n)$ 。为了获得后验分布的高斯近似，我们首先最大化后验分布以得到 MAP（最大后验）解 $\mathbf{w}_{\text{MAP}}$ ，它定义了高斯分布的均值。协方差然后由负对数似然的二阶导数矩阵的逆给出，其形式为

$$\mathbf{S}_N = -\nabla \nabla \ln p(\mathbf{w} \mid \mathbf{t}) = \mathbf{S}_0^{-1} + \sum_{n=1}^N y_n (1 - y_n) \phi_n \phi_n^T \quad (4.143)$$

因此，后验分布的高斯近似采用以下形式

$$q(\mathbf{w}) = \mathcal{N}(\mathbf{w} \mid \mathbf{w}_{\text{MAP}}, \mathbf{S}_N) \quad (4.144)$$

在获得了后验分布的高斯近似之后，剩下的任务是相对于这个分布进行边缘化以进行预测。

4.5.2 预测分布

给定一个新的特征向量 $\phi(\mathbf{x})$ ，类别 $\mathcal{C}_1$ 的预测分布是通过后验分布 $p(\mathbf{w} | \mathbf{t})$ 进行边缘化获得的，该分布本身被高斯分布 $q(\mathbf{w})$ 所近似，因此

$$p(\mathcal{C}_1 | \phi, \mathbf{t}) = \int p(\mathcal{C}_1 | \phi, \mathbf{w}) p(\mathbf{w} | \mathbf{t}) d\mathbf{w} \simeq \int \sigma(\mathbf{w}^T \phi) q(\mathbf{w}) d\mathbf{w} \quad (4.145)$$

类别 $\mathcal{C}_2$ 的相应概率由 $p(\mathcal{C}_2 | \phi, \mathbf{t}) = 1 - p(\mathcal{C}_1 | \phi, \mathbf{t})$ 给出。为了评估预测分布，我们首先注意到函数 $\sigma(\mathbf{w}^T \phi)$ 仅通过其在 ϕ 上的投影依赖于 $\mathbf{w}$ 。记 $a = \mathbf{w}^T \phi$ ，我们有

$$\sigma(\mathbf{w}^T \phi) = \int \delta(a - \mathbf{w}^T \phi) \sigma(a) da \quad (4.146)$$

其中 $\delta(\cdot)$ 是狄拉克 δ 函数。由此我们得到

$$\int \sigma(\mathbf{w}^T \phi) q(\mathbf{w}) d\mathbf{w} = \int \sigma(a) p(a) da \quad (4.147)$$

其中

$$p(a) = \int \delta(a - \mathbf{w}^T \phi) q(\mathbf{w}) d\mathbf{w} \quad (4.148)$$

我们可以通过注意到 δ 函数对 $\mathbf{w}$ 施加了线性约束，并通过积分排除所有正交于 ϕ 的方向，从而从联合分布 $q(\mathbf{w})$ 中形成一个边缘分布来评估 $p(a)$ 。由于 $q(\mathbf{w})$ 是高斯分布，我们从第 2.3.2 节中知道边缘分布也将是高斯分布。我们可以通过取矩，并交换 a 和 $\mathbf{w}$ 上的积分顺序来评估该分布的均值和协方差，因此

$$\mu_a = \mathbb{E}[a] = \int p(a) a da = \int q(\mathbf{w}) \mathbf{w}^T \phi d\mathbf{w} = \mathbf{w}_{\text{MAP}}^T \phi \quad (4.149)$$

其中我们使用了变分后验分布 $q(\mathbf{w})$ 的结果 (4.144)。类似地

$$\begin{aligned} \sigma_a^2 = \text{var}[a] &= \int p(a) \{a^2 - \mathbb{E}[a]^2\} da \\ &= \int q(\mathbf{w}) \{(\mathbf{w}^T \phi)^2 - (\mathbf{m}_N^T \phi)^2\} d\mathbf{w} = \phi^T \mathbf{S}_N \phi \end{aligned} \quad (4.150)$$

请注意， a 的分布与线性回归模型的预测分布 (3.58) 采用相同的形式，噪声方差设置为零。因此，我们对预测分布的变分近似变为

$$p(\mathcal{C}_1 | \mathbf{t}) = \int \sigma(a) p(a) da = \int \sigma(a) \mathcal{N}(a | \mu_a, \sigma_a^2) da. \quad (4.151)$$

该结果也可以通过利用第 2.3.2 节中给出的高斯分布边缘的结果直接推导出来。

对 a 的积分表示高斯分布与逻辑 S 形函数的卷积，无法解析评估。然而，我们可以通过利用由 (4.59) 定义的逻辑 S 形函数 $\sigma(a)$ 和由 (4.114) 定义的概率单位函数 $\Phi(a)$ 之间的高度相似性来获得一个良好的近似 (Spiegelhalter and Lauritzen, 1990; MacKay, 1992b; Barber and Bishop, 1998a)。为了获得对逻辑函数的最佳近似，我们需要重新缩放水平轴，以便我们用 $\Phi(\lambda a)$ 来近似 $\sigma(a)$ 。我们可以通过要求这两个函数在原点处具有相同的斜率来找到一个合适的 λ 值，这给出 $\lambda^2 = \pi/8$ 。对于这个 λ 的选择，逻辑 S 形函数和概率单位函数的相似性如图 4.9 所示。

使用概率单位函数的优点在于，它与高斯分布的卷积可以解析地用另一个概率单位函数来表示。具体来说，我们可以证明

$$\int \Phi(\lambda a) \mathcal{N}(a | \mu, \sigma^2) da = \Phi\left(\frac{\mu}{(\lambda^{-2} + \sigma^2)^{1/2}}\right). \quad (4.152)$$

我们现在将近似 $\sigma(a) \simeq \Phi(\lambda a)$ 应用于该等式两边出现的概率单位函数，从而得到逻辑 S 形函数与高斯分布的卷积的近似

$$\int \sigma(a) \mathcal{N}(a | \mu, \sigma^2) da \simeq \sigma(\kappa(\sigma^2) \mu) \quad (4.153)$$

其中我们定义了

$$\kappa(\sigma^2) = (1 + \pi\sigma^2/8)^{-1/2} \quad (4.154)$$

将此结果应用于 (4.151)，我们得到以下形式的近似预测分布

$$p(\mathcal{C}_1 | \phi, \mathbf{t}) = \sigma(\kappa(\sigma_a^2) \mu_a) \quad (4.155)$$

其中 μ_a 和 σ_a^2 分别由 (4.149) 和 (4.150) 定义，而 $\kappa(\sigma_a^2)$ 由 (4.154) 定义。

请注意，对应于 $p(\mathcal{C}_1 | \phi, \mathbf{t}) = 0.5$ 的决策边界由 $\mu_a = 0$ 给出，这与使用 $\mathbf{w}$ 的 MAP 值获得的决策边界相同。因此，如果决策标准基于最小化误分类率，并且先验概率相等，那么对 $\mathbf{w}$ 的边缘化没有影响。然而，对于更复杂的决策标准，它将发挥重要作用。在变分推断的背景下，逻辑 sigmoid 模型在后验分布的高斯近似下的边缘化将在图 10.13 中进行说明。

5 神经网络

在第3章和第4章中，我们讨论了由固定基函数的线性组合构成的回归和分类模型。我们看到这类模型具有良好的解析性质和计算性质，但其实际应用受到维度灾难的严重限制。为了将这类模型应用于大规模问题，必须使基函数能够自适应地适应数据

支持向量机（SVM，第7章讨论）通过以下方式解决这一问题：首先定义以训练数据点为中心的基函数，然后在训练过程中只选择其中一个子集。SVM的一个优点在于，虽然训练涉及非线性优化，但目标函数是凸的，因此优化问题的求解相对直接。最终模型中基函数的数量通常远小于训练样本点数，但仍然相对较多，且一般随训练集规模增大而增加。相关向量机（Relevance Vector Machine，7.2节讨论）同样从一组固定的基函数中选择子集，通常能得到稀疏得多的模型。与SVM不同的是，它还能输出概率预测，但代价是在训练阶段需要进行非凸优化。

另一种思路是提前固定基函数的数量，但让基函数本身具备自适应能力，即采用参数化的基函数形式，并在训练过程中调整这些参数。在模式识别领域，这种思路中最成功的模型就是本章要讨论的前馈神经网络（feed-forward neural network），也称为多层感知器（multilayer perceptron）。事实上，“多层感知器”这个名字并不准确，因为该模型实际上是由多层logistic回归（具有连续非线性）堆叠而成，而不是真正的感知器（具有不连续的阈值非线性）。在许多应用中，与具有同等泛化性能的支持向量机相比，训练好的神经网络模型通常要紧凑得多，因此对新数据的预测速度也快得多。与相关向量机类似，为获得这种紧凑性所付出的代价是：用于网络训练的似然函数关于模型参数不再是凸函数。不过在实践中，人们往往愿意在训练阶段投入大量计算资源，以换取一个在预测阶段快速高效的紧凑模型。

“神经网络”这一术语起源于试图为生物系统中的信息处理建立数学表示的努力（McCulloch and Pitts, 1943; Widrow and Hoff, 1960; Rosenblatt, 1962; Rumelhart et al., 1986）。事实上，这个术语被非常宽泛地使用，涵盖了大量不同的模型，其中许多模型曾被夸大其与生物系统的相似性。然而，从模式识别实际应用的视角来看，追求生物真实性只会带来完全不必要的约束。因此，本章的关注点在于神经网络作为高效的统计模式识别模型。特别是，我们将把注意力限制在已被证明具有最大实际价值的那一特定类神经网络上，即多层感知器（multilayer perceptron）。

我们首先考察网络模型的函数形式，包括基函数的具体参数化形式，然后在最大似然框架下讨论网络参数的确定问题，这涉及一个非线性优化问题的求解。这需要计算对数似然函数关于网络参数的导数，我们将看到如何利用误差反向传播（error backpropagation）技术高效地得到这些导数。我们还将展示如何将反向传播框架扩展到计算其他导数，例如雅可比矩阵和海森矩阵。接下来，我们讨论神经网络训练的多种正则化方法及其相互关系。我们还将考虑神经网络模型的一些扩展，特别是介绍一种用于建模条件概率分布的通用框架——混合密度网络（mixture density network）。最后，我们讨论神经网络的贝叶斯处理方法。关于神经网络模型的更多背景资料，可参阅Bishop (1995a)。

5.1 前馈网络函数

第3章和第4章分别讨论的回归和分类线性模型，都是基于固定非线性基函数 $\phi_j(\mathbf{x})$ 的线性组合，形式为

$$y(\mathbf{x}, \mathbf{w}) = f\left(\sum_{j=1}^M w_j \phi_j(\mathbf{x})\right) \quad (5.1)$$

其中分类时 $f(\cdot)$ 是非线性激活函数，回归时 $f(\cdot)$ 为恒等函数。我们的目标是进一步扩展该模型，使基函数 $\phi_j(\mathbf{x})$ 本身也依赖于参数，并在训练过程中与系数 $\{w_j\}$ 一起进行调整。构造参数化的非线性基函数当然有许多方式。神经网络采用的基函数仍遵循与 (5.1) 相同的形式，即每个基函数本身是输入的线性组合的非线性函数，而该线性组合中的系数是可调参数。

这就引出了基本的神经网络模型，可以将其描述为一连串函数变换。首先对输入变量 $x_1, \dots, x_D$ 构造 M 个线性组合

$$a_j = \sum_{i=1}^D w_{ji}^{(1)} x_i + w_{j0}^{(1)} \quad (5.2)$$

其中 $j = 1, \dots, M$ 。上标 (1) 表示这些参数属于网络的第“一层”。沿用第3章的术语，称 $w_{ji}^{(1)}$ 为权重 (weights)， $w_{j0}^{(1)}$ 为偏置 (biases)。这些 a_j 称为激活值 (activations)。接着对每个激活值使用可微的非线性激活函数 $h(\cdot)$ 进行变换，得到

$$z_j = h(a_j) \quad (5.3)$$

这些量对应于 (5.1) 中的基函数输出，在神经网络语境中被称为隐单元 (hidden units)。非线性函数 $h(\cdot)$ 通常选择为 sigmoid 类函数，例如 logistic sigmoid 或 ‘tanh’ 函数。按照 (5.1) 的形式，这些隐单元输出再次进行线性组合，得到输出单元的激活值

$$a_k = \sum_{j=1}^M w_{kj}^{(2)} z_j + w_{k0}^{(2)} \quad (5.4)$$

其中 $k = 1, \dots, K$ ， K 为输出总数。这一变换对应网络的第二层， $w_{k0}^{(2)}$ 仍为偏置参数。最后，输出单元激活值通过适当的激活函数变换，得到网络输出值 y_k 。激活函数的选择取决于数据的性质和目标变量的假设分布，与第3、4章讨论的线性模型遵循相同原则。对于标准回归问题，激活函数取恒等函数，故 $y_k = a_k$ 。对于多标签二分类问题，每个输出单元激活值通过 logistic sigmoid 函数变换

$$y_k = \sigma(a_k) \quad (5.5)$$

其中

$$\sigma(a) = \frac{1}{1 + \exp(-a)} \quad (5.6)$$

对于多分类问题，则采用 (4.62) 形式的 softmax 激活函数。输出单元激活函数的具体选择将在 5.2 节详细讨论。

将上述各阶段合并，对于采用 sigmoid 输出单元激活函数的情形，整体网络函数形式为


$$y_k(\mathbf{x}, \mathbf{w}) = \sigma \left(\sum_{j=1}^M w_{kj}^{(2)} h \left(\sum_{i=1}^D w_{ji}^{(1)} x_i + w_{j0}^{(1)} \right) + w_{k0}^{(2)} \right) \quad (5.7)$$

其中所有权重和偏置参数已统一归入向量 $\mathbf{w}$ 。因此，神经网络模型本质上只是从输入变量集合 $\{x_i\}$ 到输出变量集合 $\{y_k\}$ 的一个由可调参数向量 $\mathbf{w}$ 控制的非线性函数。

该函数可以用图 5.1 所示的网络图来表示。计算 (5.7) 的过程即可解释为信息在网络中的前向传播（forward propagation）。需要强调的是，这些图并不是第 8 章将要讨论的那类概率图模型，因为其中的内部节点表示的是确定性变量而非随机变量。正因如此，我们对这两类模型采用了略有区别的图形记号。稍后我们会看到如何为神经网络赋予概率意义。

图 5.1 对应式 (5.7) 的两层神经网络的网络示意图。

输入层、隐藏层与输出层的变量由节点表示，权重参数由节点之间的连接表示，其中偏置参数通过来自额外输入变量 x_0 和隐藏变量 z_0 的连接来表示。箭头表示前向传播过程中信息在网络中的流动方向。



如 3.1 节所述，(5.2) 中的偏置参数可以通过定义一个固定为 $x_0 = 1$ 的额外输入变量 x_0 来吸收到权重参数集合中，从而使 (5.2) 变为

$$a_j = \sum_{i=0}^D w_{ji}^{(1)} x_i \quad (5.8)$$

类似地，我们也可以将第二层的偏置吸收到第二层权重中，于是整体网络函数变为

$$y_k(\mathbf{x}, \mathbf{w}) = \sigma \left(\sum_{j=0}^M w_{kj}^{(2)} h \left(\sum_{i=0}^D w_{ji}^{(1)} x_i \right) \right) \quad (5.9)$$

从图 5.1 可以看出，神经网络模型包含两个处理阶段，每一阶段都类似于 4.1.7 节中的感知器模型，正因如此，该神经网络也被称为多层感知器（multilayer perceptron，简称 MLP）。然而与感知器的一个关键区别在于：神经网络在隐单元中使用的是连续的 sigmoid 类非线性，而感知器使用的是阶跃函数非线性。这使得神经网络函数关于网络参数是可微的，这一性质将在网络训练中发挥核心作用。

如果网络中所有隐单元的激活函数都取为线性函数，那么无论网络结构如何，总可以找到一个等价的不含隐层的网络。这是因为连续线性变换的复合仍然是线性变换。但是，如果隐单元数量少于输入或输出单元数量，则网络所能实现的从输入到输出的变换就不是最一般的线性变换，因为在隐层发生了降维，信息会有损失。在 12.4.2 节中我

们会看到，线性单元组成的网络会导出主成分分析（PCA）。总体而言，多层线性单元网络几乎没有什么实际意义。

图 5.1 所示的网络结构是实践中用得最多的结构。但它很容易推广，例如增加更多处理层，每一层都由形如 (5.4) 的加权线性组合加上逐元素的非线性激活函数变换构成。需要注意的是，文献中对这类网络“层数”的计数方式存在一定混乱。因此图 5.1 中的网络可能被称作：3 层网络（把输入也算作一层，共三层单元）或者单隐层网络（只数隐层）。我们推荐的说法是称图 5.1 为两层网络，因为真正决定网络性质的是可调权重层的数量。

网络结构的另一种推广是加入跳层连接（skip-layer connections），每条跳层连接也对应一个可调参数。例如在两层网络中，这些连接可以直接从输入连到输出。从原理上讲，带有 sigmoid 隐单元的网络完全可以通过以下方式“模拟”跳层连接：在有界输入范围内把第一层某些权重设得非常小，使对应隐单元在其工作范围内近似线性，再用从该隐单元到输出的极大权重进行补偿。但在实际中，显式加入跳层连接往往更有优势。


此外，网络还可以是稀疏的，即同一层内并非所有可能的连接都存在。我们将在 5.5.6 节讨论卷积神经网络时看到一个典型的稀疏网络结构示例。

由于网络图与其数学函数之间存在直接对应关系，我们可以通过设计更复杂的网络图来得到更一般的网络映射。但必须限制为前馈结构（feed-forward architecture），即不存在闭合的有向环路，以保证输出是输入的确定性函数。图 5.2 用一个简单例子对此进行了说明。在这样的网络中，每个（隐层或输出层）单元计算的函数为

$$z_k = h \left(\sum_j w_{kj} z_j \right) \quad (5.10)$$

其中求和遍历所有向单元 k 发送连接的单元（偏置参数也包含在求和中）。对网络输入施加一组固定值后，依次应用 (5.10) 即可计算出网络中所有单元（包括输出单元）的激活值。

图 5.2 具有一般前馈拓扑结构的神经网络示例。注意，每个隐藏单元和输出单元都带有对应的偏置参数（为简洁未在图中显示）。



前馈网络的逼近能力已被广泛研究（Funahashi, 1989; Cybenko, 1989; Hornik et al., 1989; Stinchcombe and White, 1989; Cotter, 1990; Ito, 1991; Hornik, 1991; Kreinovich, 1991; Ripley, 1996），结果表明其能力非常强大，因此神经网络被称为通用逼近器（universal approximators）。例如，只要隐单元数量足够多，具有线性输出的两层网络就能在紧致输入域上以任意精度一致逼近任何连续函数。这一结论对广泛的隐单元激活函数都成立（多项式除外）。尽管这些定理令人安心，但关键问题在于给定训练数据后如何找到合适

的参数值。本章后续部分将展示，基于最大似然和贝叶斯方法都存在有效的解决方案。

图 5.3 展示了两个隐层网络对多种函数的逼近能力，同时显示了各个隐单元如何协作逼近最终函数。图 5.4 则在附录 A 描述的合成分类数据集上，用一个简单分类问题说明了隐单元的作用。

图 5.3 示例展示了多层感知机对四种不同函数的逼近能力：(a) $f(x) = x^2$ ，(b) $f(x) = \sin(x)$ ，(c) $f(x) = |x|$ ，以及 (d) $f(x) = H(x)$ ，其中 $H(x)$ 为 Heaviside 阶跃函数。在每种情况下，取 $N = 50$ 个数据点（蓝色点），在区间 $(-1, 1)$ 内对 x 均匀采样，并计算对应的 $f(x)$ 值。随后使用这些数据点训练一个具有 3 个隐藏单元的两层网络，隐藏层采用“tanh”激活函数，输出层为线性单元。最终得到的网络函数由红色曲线表示，三个隐藏单元的输出以虚线曲线显示。





图 5.4 一个简单的二分类合成数据问题的示例，使用的神经网络包含两个输入、两个采用“tanh”激活函数的隐藏单元，以及一个采用 logistic sigmoid 激活函数的输出单元。两个隐藏单元各自的 $z = 0.5$ 等值线以蓝色虚线表示，网络的 $y = 0.5$ 决策边界以红线表示。作为对比，用于生成数据的分布给出的最优决策边界以绿色曲线表示。



5.1.1 权重空间对称性

前馈神经网络的一个重要性质（在后面进行贝叶斯模型比较时会起到作用）是：存在多个不同的权重向量 $\mathbf{w}$ ，却能产生完全相同的输入到输出映射函数（Chen et al., 1993）。考虑图 5.1 所示的两层网络，拥有 M 个隐单元，隐单元激活函数为 $\tanh$ ，且两层均为全连接。如果我们把所有进入某个特定隐单元的权重和偏置的符号全部取反，由于 $\tanh$ 是奇函数，满足 $\tanh(-a) = -\tanh(a)$ ，该隐单元的激活值符号也会随之反转。这一变化可以通过将从该隐单元出发的所有权重符号再次取反来完全抵消。因此，通过对一组特定的权重（以及一个偏置）进行符号翻转，网络的输入-输出映射函数保持不变。我们就找到了两个不同的权重向量，却对应完全相同的映射函数。对于 M 个隐单元，存在 M 种这样的“符号翻转”对称性，因此任意给定的权重向量属于一个包含 2^M 个等价权重向量的集合。

类似地，假设我们将所有进入某个隐单元的权重、偏置与另一个隐单元的对应权重、偏置完全互换，同时也将从这两个隐单元出发的权重也相应互换。这显然不会改变

网络的输入-输出映射函数，但对应了不同的权重向量。对于 M 个隐单元，任意权重向量属于一个包含 $M!$ 个等价权重向量的集合，对应 $M!$ 种隐单元的排列方式。因此，网络总的权重空间对称性因子为 $M! \cdot 2^M$ 。对于具有更多权重层的网络，总对称性水平为每个隐层对应因子的乘积。

事实证明，这些因子已经涵盖了权重空间中的所有对称性（除了由于权重具体取值偶然导致的额外对称性外）。而且，这种对称性的存在并非 $\tanh$ 函数的特有性质，而是适用于广泛的激活函数（Kürková and Kainen, 1994）。在大多数情况下，权重空间的这些对称性对实际应用影响不大，但在 5.7 节中我们会遇到一个需要特别考虑这些对称性的情形。

5.2 网络训练

到目前为止，我们一直将神经网络视为从输入向量 $\mathbf{x}$ 到输出向量 $\mathbf{y}$ 的一类通用参数化非线性函数。确定网络参数的一种最直接方法是类比 1.1 节的多项式曲线拟合，直接最小化平方和误差函数。给定训练集包含输入向量 $\{\mathbf{x}_n\}$, $n = 1, \dots, N$ ，以及对应的目标向量 $\{\mathbf{t}_n\}$ ，我们最小化误差函数

$$E(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N \|\mathbf{y}(\mathbf{x}_n, \mathbf{w}) - \mathbf{t}_n\|^2 \quad (5.11)$$

然而，如果先为网络输出赋予概率意义，我们就能得到一个更加普适、也更加清晰的训练框架。我们在 1.5.4 节已经看到概率预测的诸多优势，这里它还将为我们提供：输出层非线性激活函数选择和误差函数选择明确理由

我们先讨论回归问题，暂时考虑单个实值目标变量 t 。沿袭 1.2.5 节和 3.1 节的讨论，假设 t 服从以 $\mathbf{x}$ 为条件的均值高斯分布，而该均值正是神经网络的输出，即

$$p(t | \mathbf{x}, \mathbf{w}) = \mathcal{N}(t | y(\mathbf{x}, \mathbf{w}), \beta^{-1}) \quad (5.12)$$

其中 β 是高斯噪声的精度（方差倒数）。当然这是一个比较强的假设，5.6 节我们会看到如何将其扩展到更一般的条件分布。对于 (5.12) 这种条件分布，只要输出层激活函数取恒等函数就足够了，因为这样的网络已经可以逼近任意从 $\mathbf{x}$ 到 y 的连续函数。给定 N 个独立同分布的观测数据 $\mathbf{X} = \{\mathbf{x}_1, \dots, \mathbf{x}_N\}$ 以及对应的目标值 $\mathbf{t} = \{t_1, \dots, t_N\}$ ，我们可以写出似然函数

$$p(\mathbf{t} | \mathbf{X}, \mathbf{w}, \beta) = \prod_{n=1}^N p(t_n | \mathbf{x}_n, \mathbf{w}, \beta)$$

取负对数后得到误差函数

$$\frac{\beta}{2} \sum_{n=1}^N \{y(\mathbf{x}_n, \mathbf{w}) - t_n\}^2 - \frac{N}{2} \ln \beta + \frac{N}{2} \ln(2\pi) \quad (5.13)$$

该式可用于学习参数 $\mathbf{w}$ 和 β 。5.7 节将讨论神经网络的贝叶斯处理，而这里我们采用最大似然方法。需要注意的是，在神经网络文献中，通常习惯最小化误差函数而非最大化

(对数) 似然, 因此这里沿用这一惯例。首先考虑 $\mathbf{w}$ 的确定。最大化似然函数等价于最小化平方和误差函数

$$E(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N \{y(\mathbf{x}_n, \mathbf{w}) - t_n\}^2 \quad (5.14)$$

其中已丢弃加法和乘法常数。通过最小化 $E(\mathbf{w})$ 得到的 $\mathbf{w}$ 值记为 $\mathbf{w}_{\text{ML}}$, 因为它对应最大似然解。实际上, 由于网络函数 $y(\mathbf{x}_n, \mathbf{w})$ 的非线性, 误差函数 $E(\mathbf{w})$ 通常是非凸的, 因此实际优化中可能只找到局部极大似然解 (对应误差函数的局部极小), 这一点将在 5.2.1 节详细讨论。

在得到 $\mathbf{w}_{\text{ML}}$ 后, 通过最小化负对数似然可求得 β

$$\frac{1}{\beta_{\text{ML}}} = \frac{1}{N} \sum_{n=1}^N \{y(\mathbf{x}_n, \mathbf{w}_{\text{ML}}) - t_n\}^2 \quad (5.15)$$

该式在完成求解 $\mathbf{w}_{\text{ML}}$ 的迭代优化后即可直接计算。如果存在多个目标变量, 并且假设它们在给定 $\mathbf{x}$ 和 $\mathbf{w}$ 的条件下独立且共享同一噪声精度 β , 则目标向量的条件分布为

$$p(\mathbf{t} | \mathbf{x}, \mathbf{w}) = \mathcal{N}(\mathbf{t} | \mathbf{y}(\mathbf{x}, \mathbf{w}), \beta^{-1} \mathbf{I}). \quad (5.16)$$

沿袭单个目标变量的推导, 对于多输出回归, 最大似然权重同样通过最小化平方和误差函数 (5.11) 得到。噪声精度则由下式给出

$$\frac{1}{\beta_{\text{ML}}} = \frac{1}{NK} \sum_{n=1}^N \|\mathbf{y}(\mathbf{x}_n, \mathbf{w}_{\text{ML}}) - \mathbf{t}_n\|^2 \quad (5.17)$$

其中 K 是目标变量个数。如果放弃独立性假设, 优化问题会稍复杂一些, 但原理相同。

回忆 4.3.6 节的结论: 误差函数 (负对数似然) 与输出层激活函数之间存在自然的配对关系。对于回归情形, 输出层激活函数取恒等函数 $y_k = a_k$, 对应的平方和误差函数满足

$$\frac{\partial E}{\partial a_k} = y_k - t_k \quad (5.18)$$

这在 5.3 节讨论误差反向传播时将发挥关键作用。

现在考虑单个二分类目标变量 t , $t = 1$ 表示类 $\mathcal{C}_1$, $t = 0$ 表示类 $\mathcal{C}_2$ 。按照 4.3.6 节关于规范链接函数的讨论, 我们采用单个输出单元, 激活函数为 logistic sigmoid

$$y = \sigma(a) \equiv \frac{1}{1 + \exp(-a)} \quad (5.19)$$

从而 $0 \leq y(\mathbf{x}, \mathbf{w}) \leq 1$ 。我们将 $y(\mathbf{x}, \mathbf{w})$ 解释为条件概率 $p(\mathcal{C}_1 | \mathbf{x})$, 而 $p(\mathcal{C}_2 | \mathbf{x}) = 1 - y(\mathbf{x}, \mathbf{w})$ 。给定输入后目标变量的条件分布为伯努利分布

$$p(t | \mathbf{x}, \mathbf{w}) = y(\mathbf{x}, \mathbf{w})^t \{1 - y(\mathbf{x}, \mathbf{w})\}^{1-t}. \quad (5.20)$$

如果我们考虑由独立观测组成的训练集, 则负对数似然所对应的误差函数就是交叉熵 (cross-entropy) 误差函数, 其具体形式为

$$E(\mathbf{w}) = - \sum_{n=1}^N \{t_n \ln y_n + (1 - t_n) \ln(1 - y_n)\} \quad (5.21)$$

其中 $y_n \equiv y(\mathbf{x}_n, \mathbf{w})$ 。这里没有类似于噪声精度 β 的参数，因为默认类别标签是正确的（模型可轻易扩展以容纳标签错误）。Simard et al. (2003) 发现，在分类问题中使用交叉熵误差函数而非平方和误差，能带来更快的训练速度和更好的泛化性能。

若需同时进行 K 个独立的二分类任务，可使用 K 个输出单元，每个输出均采用 logistic sigmoid 激活函数。对应每个输出的二元标签为 $t_k \in \{0, 1\}$, $k = 1, \dots, K$ 。假设给定输入后各类标签独立，则目标向量的条件分布为

$$p(\mathbf{t} | \mathbf{x}, \mathbf{w}) = \prod_{k=1}^K y_k(\mathbf{x}, \mathbf{w})^{t_k} [1 - y_k(\mathbf{x}, \mathbf{w})]^{1-t_k}. \quad (5.22)$$

对相应的似然函数取负对数后，得到以下误差函数

$$E(\mathbf{w}) = - \sum_{n=1}^N \sum_{k=1}^K \{t_{nk} \ln y_{nk} + (1 - t_{nk}) \ln(1 - y_{nk})\} \quad (5.23)$$

其中 y_{nk} 表示 $y_k(\mathbf{x}_n, \mathbf{w})$ 。同样，误差函数相对于某一特定输出单元的激活值的导数具有与回归情况完全相同的形式 (5.18)。

有趣的是，将神经网络对该问题的求解与第四章讨论的基于线性分类模型的相应方法进行对比。假设我们使用图 5.1 所示的标准两层网络。可以看出，网络第一层的权重参数在各个输出之间是共享的，而在线性模型中，每个分类问题都是独立求解的。网络的第一层可以看作是在执行非线性特征提取，不同输出之间共享特征既可以节省计算量，也能带来更好的泛化性能。

最后，我们考虑标准的多分类问题，其中每个输入被分配到 K 个互斥类别中的一个。二值目标变量 $t_k \in \{0, 1\}$ 采用 1-of- K 编码方式表示类别，网络输出被解释为 $y_k(\mathbf{x}, \mathbf{w}) = p(t_k = 1 | \mathbf{x})$ ，从而得到以下误差函数

$$E(\mathbf{w}) = - \sum_{n=1}^N \sum_{k=1}^K t_{kn} \ln y_k(\mathbf{x}_n, \mathbf{w}). \quad (5.24)$$

按照 4.3.4 节的讨论，与规范链接（canonical link）对应的输出单元激活函数由 softmax 函数给出：

$$y_k(\mathbf{x}, \mathbf{w}) = \frac{\exp(a_k(\mathbf{x}, \mathbf{w}))}{\sum_j \exp(a_j(\mathbf{x}, \mathbf{w}))} \quad (5.25)$$


它满足 $0 \leq y_k \leq 1$ 且 $\sum_k y_k = 1$ 。需要注意，如果对所有的 $a_k(\mathbf{x}, \mathbf{w})$ 同时加上一个常数， $y_k(\mathbf{x}, \mathbf{w})$ 并不会改变，这会导致误差函数在权重空间的某些方向上保持不变。这种退化可以通过向误差函数添加适当的正则化项（5.5 节）来消除。

同样，误差函数相对于某一特定输出单元激活值的导数仍具有熟悉的形式 (5.18)。

总之，根据所解决问题的类型，对输出单元激活函数和与之匹配的误差函数存在自然的选择。对于回归问题，我们使用线性输出和平方和误差；对于（多个独立的）二分类问题，我们使用 logistic sigmoid 输出和交叉熵误差函数；对于多分类问题，我们使用 softmax 输出以及相应的多分类交叉熵误差函数。对于只有两类的情况，既可以使用单个 logistic sigmoid 输出，也可以使用具有 softmax 输出激活函数的双输出网络。

5.2.1 参数优化

图 5.5 从几何角度来看, 误差函数 $E(\mathbf{w})$ 可视为覆盖在权重空间之上的一个曲面。点 $\mathbf{w}_A$ 是局部最小点, 点 $\mathbf{w}_B$ 是全局最小点。在任意点 $\mathbf{w}_C$, 误差曲面的局部梯度由向量 ∇E 给出。



接下来我们要讨论的任务是寻找权重向量 $\mathbf{w}$, 使所选的误差函数 $E(\mathbf{w})$ 达到最小值。此时对误差函数建立一个几何图像很有帮助, 我们可以将其看作是悬在权重空间上方的一个曲面, 如图 5.5 所示。首先注意, 如果在权重空间中从 $\mathbf{w}$ 向 $\mathbf{w} + \delta\mathbf{w}$ 迈出一小步, 则误差函数的变化为 $\delta E \simeq \delta\mathbf{w}^T \nabla E(\mathbf{w})$, 其中向量 $\nabla E(\mathbf{w})$ 指向误差函数增加最快的方向。因为误差 $E(\mathbf{w})$ 是 $\mathbf{w}$ 的光滑连续函数, 它的最小值必然出现在权重空间中梯度为零的点, 即

$$\nabla E(\mathbf{w}) = 0 \quad (5.26)$$

否则我们总可以沿 $-\nabla E(\mathbf{w})$ 方向再迈出一小步来进一步减小误差。梯度消失的点称为驻点 (stationary points), 可进一步分为极小点、极大点和鞍点。

我们的目标是找到使 $E(\mathbf{w})$ 取得最小值的向量 $\mathbf{w}$ 。然而, 误差函数通常对权重和偏置参数具有高度非线性的依赖关系, 因此权重空间中会存在许多梯度消失 (或者数值上非常接近零) 的点。实际上, 从 5.1.1 节的讨论可知, 对于任意一个局部极小点 $\mathbf{w}$, 权重空间中还存在其他等价的极小点。例如, 在图 5.1 所示的具有 M 个隐单元的两层网络中, 权重空间的每一个点都属于一个包含 $M!2^M$ 个等价点的家族。

此外, 通常还存在多个不等价的驻点, 特别是多个不等价的极小点。其中对应误差函数全局最小值的极小点称为全局极小点 (global minimum)。其余对应较高误差函数值的极小点称为局部极小点 (local minima)。对于神经网络的成功应用, 往往并不需要一定找到全局极小点 (通常也无法确定是否已经找到全局极小点), 但通常需要比较多个局部极小点, 以便找到一个足够好的解。

显然不可能找到方程 $\nabla E(\mathbf{w}) = 0$ 的解析解, 因此我们只能求助于迭代数值方法。连续非线性函数的优化是一个被广泛研究的问题, 存在大量关于如何高效求解的文献。大多数方法都包含以下步骤: 先为权重向量选择某个初始值 $\mathbf{w}^{(0)}$, 然后在权重空间中按如下形式连续进行一系列移动

$$\mathbf{w}^{(\tau+1)} = \mathbf{w}^{(\tau)} + \Delta\mathbf{w}^{(\tau)} \quad (5.27)$$

其中 τ 表示迭代步数。不同算法的区别主要在于权重向量更新量 $\Delta \mathbf{w}^{(\tau)}$ 的不同选择方式。许多算法会利用梯度信息，因此需要在每次更新后在新权重向量 $\mathbf{w}^{(\tau+1)}$ 处重新计算 $\nabla E(\mathbf{w})$ 的值。为了理解梯度信息的重要性，有必要考虑基于泰勒展开的误差函数局部近似。

5.2.2 局部二次近似

通过考察误差函数的局部二次近似，可以对优化问题以及各种求解技术获得深入洞察。

考虑误差函数 $E(\mathbf{w})$ 在权重空间某点 $\hat{\mathbf{w}}$ 附近的泰勒展开

$$E(\mathbf{w}) \simeq E(\hat{\mathbf{w}}) + (\mathbf{w} - \hat{\mathbf{w}})^T \mathbf{b} + \frac{1}{2} (\mathbf{w} - \hat{\mathbf{w}})^T \mathbf{H} (\mathbf{w} - \hat{\mathbf{w}}) \quad (5.28)$$

其中省略了三次及更高次项。这里 $\mathbf{b}$ 定义为在 $\hat{\mathbf{w}}$ 处计算的 E 的梯度

$$\mathbf{b} \equiv \nabla E|_{\mathbf{w}=\hat{\mathbf{w}}} \quad (5.29)$$

而黑塞矩阵 $\mathbf{H} = \nabla \nabla E$ 的元素为

$$(\mathbf{H})_{ij} \equiv \left. \frac{\partial^2 E}{\partial w_i \partial w_j} \right|_{\mathbf{w}=\hat{\mathbf{w}}} \quad (5.30)$$

根据 (5.28)，梯度的相应局部近似为

$$\nabla E \simeq \mathbf{b} + \mathbf{H}(\mathbf{w} - \hat{\mathbf{w}}). \quad (5.31)$$

对于足够靠近 $\hat{\mathbf{w}}$ 的点 $\mathbf{w}$ ，这些表达式能对误差及其梯度给出合理的近似。

考虑误差函数极小点 $\mathbf{w}^*$ 附近的局部二次近似这一特殊情形。此时由于在 $\mathbf{w}^*$ 处 $\nabla E = 0$ ，因此不存在线性项，(5.28) 变为

$$E(\mathbf{w}) = E(\mathbf{w}^*) + \frac{1}{2} (\mathbf{w} - \mathbf{w}^*)^T \mathbf{H} (\mathbf{w} - \mathbf{w}^*) \quad (5.32)$$

其中黑塞矩阵 $\mathbf{H}$ 在 $\mathbf{w}^*$ 处取值。为了对其进行几何解释，考虑黑塞矩阵的本征值方程

$$\mathbf{H} \mathbf{u}_i = \lambda_i \mathbf{u}_i \quad (5.33)$$

其中本征向量 $\mathbf{u}_i$ 构成完备的正交归一集（附录 C），满足

$$\mathbf{u}_i^T \mathbf{u}_j = \delta_{ij}. \quad (5.34)$$

现在将 $(\mathbf{w} - \mathbf{w}^*)$ 按本征向量展开

$$\mathbf{w} - \mathbf{w}^* = \sum_i \alpha_i \mathbf{u}_i. \quad (5.35)$$

这可以看作一种坐标变换：原点平移到 $\mathbf{w}^*$ ，坐标轴旋转到与本征向量对齐（旋转矩阵的列为 $\mathbf{u}_i$ ，详见附录 C）。将 (5.35) 代入 (5.32)，并利用 (5.33) 与 (5.34)，误差函数可写为

$$E(\mathbf{w}) = E(\mathbf{w}^*) + \frac{1}{2} \sum_i \lambda_i \alpha_i^2. \quad (5.36)$$

矩阵 $\mathbf{H}$ 被称为正定矩阵，当且仅当对任意 $\mathbf{v}$ 都有

$$\mathbf{v}^T \mathbf{H} \mathbf{v} > 0 \quad \text{for all } \mathbf{v}. \quad (5.37)$$

由于本征向量 $\{\mathbf{u}_i\}$ 构成完备集，任意向量 $\mathbf{v}$ 可写为

$$\mathbf{v} = \sum_i c_i \mathbf{u}_i. \quad (5.38)$$

根据 (5.33) 与 (5.34)，有


$$\mathbf{v}^T \mathbf{H} \mathbf{v} = \sum_i c_i^2 \lambda_i \quad (5.39)$$

因此 $\mathbf{H}$ 正定当且仅当它的所有本征值均为正。在以本征向量 $\{\mathbf{u}_i\}$ 为基的新坐标系中，常数 E 的等高线是以原点为中心的椭圆，如图 5.6 所示。在一维权重空间中，驻点 w^* 为极小点的条件是

$$\left. \frac{\partial^2 E}{\partial w^2} \right|_{w^*} > 0. \quad (5.40)$$

对应的 D 维情形是：在 $\mathbf{w}^*$ 处计算的黑塞矩阵必须是正定的。

图 5.6 在最小点 $\mathbf{w}^*$ 附近，误差函数可以用二次函数近似。此时等误差轮廓为椭圆，其主轴与 Hessian 矩阵的特征向量 $\mathbf{u}_i$ 对齐，且主轴长度与相应特征值 λ_i 的平方根成反比。



5.2.3 梯度信息的使用

在 5.3 节我们将会看到，通过反向传播算法可以高效地计算误差函数的梯度。利用这一梯度信息能够显著加快误差函数极小点的定位速度。我们可以从以下分析看出原因。

在误差函数的二次近似 (5.28) 中，误差曲面由 $\mathbf{b}$ 和 $\mathbf{H}$ 完全确定，这两者一共包含 $W(W+3)/2$ 个独立元素（因为 $\mathbf{H}$ 是对称矩阵），其中 W 是 $\mathbf{w}$ 的维数（即网络中自适应参数的总数）。因此，该二次近似的极小点位置依赖于 $O(W^2)$ 个参数，我们预期在收集到 $O(W^2)$ 个独立信息之前无法定位极小点。如果不使用梯度信息，我们预计需要进行 $O(W^2)$ 次函数值评估，每次评估需要 $O(W)$ 步计算。因此，使用此类方法找到极小点所需的计算量为 $O(W^3)$ 。

现在对比使用梯度信息的算法。由于每次计算 ∇E 能带来 W 项信息，我们有望在 $O(W)$ 次梯度评估后找到函数极小点。正如我们将看到的，通过误差反向传播，每次梯度评估只需 $O(W)$ 步计算，因此现在找到极小点总共只需 $O(W^2)$ 步。正因如此，利用梯度信息构成了实际神经网络训练算法的基础。

5.2.4 梯度下降优化

使用梯度信息的最简单方法是将 (5.27) 中的权重更新选为沿负梯度方向迈出一小步，即

$$\mathbf{w}^{(\tau+1)} = \mathbf{w}^{(\tau)} - \eta \nabla E(\mathbf{w}^{(\tau)}) \quad (5.41)$$

其中参数 $\eta > 0$ 称为学习率 (learning rate)。每次更新后，在新的权重向量处重新计算梯度，并重复该过程。需要注意的是，误差函数是针对整个训练集定义的，因此每一步都需要处理全部训练集才能计算 ∇E 。一次使用全部数据的技术称为批方法 (batch methods)。在每一步中，权重向量都沿着误差函数下降最快的方向移动，因此这种方法被称为梯度下降 (gradient descent) 或最陡下降 (steepest descent)。尽管这种方法直觉上看起来合理，但实际上它是一种很差的算法，原因见 Bishop and Nabney (2008)。

对于批优化，存在更高效的方法，如共轭梯度法 (conjugate gradients) 和拟牛顿法 (quasi-Newton methods)，它们远比简单梯度下降更稳健、速度更快 (Gill et al., 1981; Fletcher, 1987; Nocedal and Wright, 1999)。与梯度下降不同，这些算法具有如下性质：除非权重向量已经到达局部或全局极小点，否则每一次迭代误差函数都会严格下降。

为了找到一个足够好的极小点，可能需要多次运行基于梯度的算法，每次使用不同的随机初始起点，并在独立的验证集上比较最终性能。

然而，梯度下降还有一种在线版本 (on-line version)，在对大规模数据集训练神经网络时已被证明非常实用 (Le Cun et al., 1989)。基于最大似然且观测相互独立的误差函数由各数据点的误差项之和构成

$$E(\mathbf{w}) = \sum_{n=1}^N E_n(\mathbf{w}). \quad (5.42)$$

在线梯度下降，也称为序贯梯度下降 (sequential gradient descent) 或随机梯度下降 (stochastic gradient descent)，每次基于一个数据点对权重向量进行更新，即

$$\mathbf{w}^{(\tau+1)} = \mathbf{w}^{(\tau)} - \eta \nabla E_n(\mathbf{w}^{(\tau)}). \quad (5.43)$$

这种更新通过顺序循环遍历数据或随机有放回地选取数据点反复进行。当然也存在中间方案，即每次更新基于一小批 (mini-batch) 数据点。

在线方法相对于批方法的一个优势是，前者能更高效地处理数据中的冗余。为说明这一点，考虑一个极端例子：将数据集的规模翻倍，方法是把每个数据点都复制一遍。注意，这只不过是把误差函数整体乘以 2，因此与使用原始误差函数完全等价。批方法评估整个批的误差函数梯度所需的计算量会翻倍，而在线方法则完全不受影响。在线梯度下降的另一个特性是，它有可能逃离局部极小点，因为对整个数据集的误差函数而言的驻点，通常并不是对每个单独数据点误差函数的驻点。

非线性优化算法及其在神经网络训练中的实际应用，在 Bishop and Nabney (2008) 中有详细讨论。

5.3 误差反向传播

本节的目标是为前馈神经网络找到一种高效计算误差函数 $E(\mathbf{w})$ 梯度的方法。我们将会看到，这可以通过一种局部消息传递机制实现，即信息在网络中交替地向前和向后传递，这种方法被称为误差反向传播（error backpropagation），有时简称为 backprop。

需要注意的是，在神经计算文献中，“backpropagation”一词被用来指代多种不同的含义。例如，多层感知器结构有时就被称为反向传播网络。“backpropagation”这个术语也常用来描述使用梯度下降最小化平方和误差函数来训练多层感知器。为了澄清术语，有必要更仔细地考察训练过程的本质。大多数训练算法都包含一个迭代过程，用以最小化误差函数，并在连续的步骤中对权重进行调整。在每一步中，我们可以区分两个截然不同的阶段。

第一阶段必须计算误差函数对权重的导数。正如我们将要看到的，反向传播技术的核心贡献在于提供了一种计算高效的方法来评估这些导数。正因为在这一阶段误差被向后传播通过网络，我们将专门使用“backpropagation”一词来描述导数的计算。

第二阶段：利用计算得到的导数来确定对权重的调整。最简单的方法（也是 Rumelhart et al. (1986) 最初考虑的方法）是梯度下降。

重要的是要认识到这两个阶段是相互独立的。因此，第一阶段（即误差在网络中向后传播以计算导数）可以应用于许多其他类型的网络，而不仅仅是多层感知器。它还可以用于除简单平方和之外的其他误差函数，以及计算其他导数（如雅可比矩阵和黑塞矩阵），这一点我们将在本章后面看到。同样，使用计算得到的导数进行权重调整的第二阶段，也可以使用多种优化方案，其中许多远比简单的梯度下降更强大。

5.3.1 误差函数导数的计算

现在我们为具有任意前馈拓扑、任意可微非线性激活函数以及广泛一类误差函数的一般网络推导反向传播算法。然后，我们将以一个简单的分层网络结构（具有单层 sigmoid 隐单元并采用平方和误差）为例来说明所得公式。

许多实际中常用的误差函数，例如由一组独立同分布数据最大似然定义的误差函数，都由训练集中每个数据点对应的项求和构成，因此

$$E(\mathbf{w}) = \sum_{n=1}^N E_n(\mathbf{w}). \quad (5.44)$$

在本节中，我们将考虑对误差函数中的某一项 $E_n(\mathbf{w})$ 计算 $\nabla E_n(\mathbf{w})$ 的问题。这可以直接用于序贯优化，或者在批方法中对整个训练集进行累加。

首先考虑一个简单的线性模型，其中输出 y_k 是输入变量 x_i 的线性组合，即

$$y_k = \sum_i w_{ki} x_i \quad (5.45)$$

并对于某个特定的输入模式 n ，误差函数具有如下形式

$$E_n = \frac{1}{2} \sum_k (y_{nk} - t_{nk})^2 \quad (5.46)$$

其中 $y_{nk} = y_k(\mathbf{x}_n, \mathbf{w})$ 。该误差函数对权重 w_{ji} 的梯度为

$$\frac{\partial E_n}{\partial w_{ji}} = (y_{nj} - t_{nj})x_{ni} \quad (5.47)$$

这可以解释为一种“局部”计算，涉及与连接 w_{ji} 输出端相关的“误差信号” $y_{nj} - t_{nj}$ 和与输入端相关的变量 x_{ni} 的乘积。在 4.3.2 节中，我们看到当使用 logistic sigmoid 激活函数配合交叉熵误差函数时，会出现类似的公式，softmax 激活函数配合其对应的交叉熵误差函数也是如此。我们现在将看到，这一简单结果如何推广到更复杂的前馈多层网络的情形。

在一般的前馈网络中，每个单元计算其输入的加权和，形式为

$$a_j = \sum_i w_{ji} z_i \quad (5.48)$$

其中 z_i 是发送连接到单元 j 的某个单元（或输入）的激活值， w_{ji} 是该连接对应的权重。在 5.1 节中，我们看到可以通过引入一个激活值固定为 +1 的额外单元（或输入）将偏置包含在此求和中。因此我们无需显式处理偏置。(5.48) 中的求和通过一个非线性激活函数 $h(\cdot)$ 变换后，得到单元 j 的激活值

$$z_j = h(a_j). \quad (5.49)$$

需要注意的是，(5.48) 式求和中的变量 z_i 之一可能是输入，同样，(5.49) 式中的单元 j 也可能是输出。

对于训练集中的每一个模式，我们假设已经将对应的输入向量提供给网络，并通过依次应用 (5.48) 和 (5.49) 计算出网络中所有隐单元和输出单元的激活值。这一过程通常称为前向传播（forward propagation），因为它可以看作信息在网络中的向前流动。

现在考虑计算 E_n 对权重 w_{ji} 的导数。各单元的输出将依赖于具体的输入模式 n 。不过，为了保持记号简洁，我们将省略网络变量的下标 n 。首先注意到， E_n 只通过单元 j 的总输入 a_j 依赖于权重 w_{ji} 。因此我们可以应用偏导数的链式法则，得到

$$\frac{\partial E_n}{\partial w_{ji}} = \frac{\partial E_n}{\partial a_j} \frac{\partial a_j}{\partial w_{ji}}. \quad (5.50)$$

现在引入一个有用的记号

$$\delta_j \equiv \frac{\partial E_n}{\partial a_j} \quad (5.51)$$

其中 δ 通常被称为误差（errors），原因我们稍后会看到。利用 (5.48)，有

$$\frac{\partial a_j}{\partial w_{ji}} = z_i. \quad (5.52)$$

将 (5.51) 和 (5.52) 代入 (5.50)，得到

$$\frac{\partial E_n}{\partial w_{ji}} = \delta_j z_i. \quad (5.53)$$

方程 (5.53) 告诉我们，所需的导数只需将权重输出端单元的 δ 值与权重输入端单元的 z 值相乘即可得到（对于偏置的情况， $z = 1$ ）。注意，这与本节开头考虑的简单线性模型的形式完全相同。因此，要计算这些导数，我们只需要计算网络中每个隐单元和输出单元的 δ_j 值，然后应用 (5.53) 即可。

正如我们已经看到的，对于输出单元，如果使用规范链接函数作为输出单元激活函数，则有

$$\delta_k = y_k - t_k \quad (5.54)$$

为了计算隐单元的 δ ，我们再次使用偏导数的链式法则


$$\delta_j \equiv \frac{\partial E_n}{\partial a_j} = \sum_k \frac{\partial E_n}{\partial a_k} \frac{\partial a_k}{\partial a_j} \quad (5.55)$$

其中求和遍历单元 j 所有发送连接的目标单元 k 。单元和权重的连接方式如图 5.7 所示。注意，标记为 k 的单元可以是其他隐单元和/或输出单元。在写下 (5.55) 时，我们利用了这样一个事实： a_j 的变化只会通过 a_k 的变化影响误差函数。现在若将 (5.51) 中 δ 的定义代入 (5.55)，并利用 (5.48) 和 (5.49)，即可得到如下反向传播公式

$$\delta_j = h'(a_j) \sum_k w_{kj} \delta_k \quad (5.56)$$

这表明，某个特定隐单元的 δ 值可以通过将更高层单元的 δ 向后传播得到，如图 5.7 所示。注意，(5.56) 中的求和是对 w_{kj} 的第一个下标进行的（对应信息在网络中的向后传播），而在向前传播方程 (5.10) 中则是对第二个下标求和。由于我们已经知道输出单元的 δ 值，因此通过递归应用 (5.56)，我们就可以在前馈网络中计算所有隐单元的 δ ，而不论其拓扑结构如何。

图 5.7 通过将来自单元 j 向其连接的各单元 k 的 δ 反向传播，示意计算隐藏单元 j 的 δ_j 。蓝色箭头表示前向传播时的信息流方向，红色箭头表示误差信息的反向传播。



因此，反向传播过程可以总结如下。

误差反向传播

1. 将输入向量 $\mathbf{x}_n$ 输入网络，按照 (5.48) 和 (5.49) 前向传播，计算所有隐藏单元和输出单元的激活值。
2. 利用 (5.54) 计算所有输出单元的 δ_k 。
3. 利用 (5.56) 反向传播 δ ，得到网络中每个隐藏单元的 δ_j 。
4. 利用 (5.53) 计算所需的偏导数。

对于批方法，总误差 E 的导数可以通过对训练集中每个模式重复上述步骤，然后对所有模式求和得到：

$$\frac{\partial E}{\partial w_{ji}} = \sum_n \frac{\partial E_n}{\partial w_{ji}}. \quad (5.57)$$

在上面的推导中，我们隐式地假设网络中每个隐单元或输出单元都使用相同的激活函数 $h(\cdot)$ 。然而，这一推导很容易推广到允许不同单元拥有各自激活函数的情况，只需记录每个单元对应哪种形式的 $h(\cdot)$ 即可。

5.3.2 一个简单例子

上面反向传播过程的推导允许误差函数、激活函数和网络拓扑具有一般形式。为了说明该算法的应用，我们考虑一个特定的例子。这个例子既简单又具有实际重要性，因为文献中报告的许多神经网络应用都使用了这种网络。具体地，我们考虑图 5.1 所示的两层网络，配合平方和误差，其中输出单元采用线性激活函数，故 $y_k = a_k$ ，而隐单元采用 logistic sigmoid 激活函数，形式为

$$h(a) \equiv \tanh(a) \quad (5.58)$$

其中

$$\tanh(a) = \frac{e^a - e^{-a}}{e^a + e^{-a}}. \quad (5.59)$$

该函数的一个有用特性是其导数可以表示为特别简单的形式：

$$h'(a) = 1 - h(a)^2. \quad (5.60)$$

我们还采用标准的平方和误差函数，因此对于模式 n ，误差为

$$E_n = \frac{1}{2} \sum_{k=1}^K (y_k - t_k)^2 \quad (5.61)$$

其中 y_k 是输出单元 k 的激活值， t_k 是对应目标值，对于特定的输入模式 $\mathbf{x}_n$ 。

对训练集中的每个模式依次进行如下操作，首先进行前向传播

$$a_j = \sum_{i=0}^D w_{ji}^{(1)} x_i \quad (5.62)$$

$$z_j = \tanh(a_j) \quad (5.63)$$

$$y_k = \sum_{j=0}^M w_{kj}^{(2)} z_j. \quad (5.64)$$

接着对每个输出单元计算 δ

$$\delta_k = y_k - t_k. \quad (5.65)$$

然后反向传播这些 δ ，得到隐单元的 δ

$$\delta_j = (1 - z_j^2) \sum_{k=1}^K w_{kj} \delta_k. \quad (5.66)$$

最后，第一层和第二层权重的导数分别为

$$\frac{\partial E_n}{\partial w_{ji}^{(1)}} = \delta_j x_i, \quad \frac{\partial E_n}{\partial w_{kj}^{(2)}} = \delta_k z_j. \quad (5.67)$$

5.3.3 反向传播的计算效率

反向传播最重要的特性之一就是它的计算效率。为了理解这一点，我们来考察对网络中全部权重和偏置总数 W 而言，计算误差函数导数所需的计算操作次数是如何随 W 变化的。对于足够大的 W ，一次（对给定输入模式）误差函数的计算需要 $O(W)$ 次操作。这是因为，除非网络连接极其稀疏，否则权重的数量通常远大于单元数量，因此前向传播的主要计算量集中在对 (5.48) 中求和的计算上，而激活函数的计算只占很小的额外开销。(5.48) 中求和的每一项都需要一次乘法和一次加法，因此总计算代价为 $O(W)$ 。

另一种计算误差函数导数的方法是使用有限差分。可以依次对每个权重进行扰动，并用下式近似导数

$$\frac{\partial E_n}{\partial w_{ji}} = \frac{E_n(w_{ji} + \epsilon) - E_n(w_{ji})}{\epsilon} + O(\epsilon) \quad (5.68)$$

其中 $\epsilon \ll 1$ 。在软件实现中，可以通过减小 ϵ 来提高导数近似的精度，直到出现数值舍入误差为止。有限差分方法的精度可以通过使用对称中心差分显著提高

$$\frac{\partial E_n}{\partial w_{ji}} = \frac{E_n(w_{ji} + \epsilon) - E_n(w_{ji} - \epsilon)}{2\epsilon} + O(\epsilon^2). \quad (5.69)$$

此时 $O(\epsilon)$ 的误差项被抵消（可通过对 (5.69) 右侧进行泰勒展开验证），剩余误差为 $O(\epsilon^2)$ 。不过相比 (5.68)，计算量大约增加一倍。

数值微分的主要问题是失去了非常理想的 $O(W)$ 计算复杂度。每次前向传播需要 $O(W)$ 步，而网络中有 W 个权重需要分别扰动，因此总复杂度变为 $O(W^2)$ 。

然而，数值微分在实践中仍扮演重要角色，因为将反向传播计算得到的导数与使用中心差分得到的结果进行比较，是检查反向传播算法软件实现正确性的强大手段。在实际训练网络时，应使用反向传播来计算导数，因为它具有最高的精度和数值效率。但在实现完成后，应针对一些测试用例使用 (5.69) 进行数值微分，并与反向传播结果对比，以验证实现的正确性。

5.3.4 雅可比矩阵

我们已经看到，通过将误差反向传播，可以得到误差函数对权重的导数。反向传播技术还可以用来计算其他类型的导数。这里我们考虑雅可比矩阵（Jacobian matrix）的计算，其元素由网络输出对输入的导数给出

$$J_{ki} \equiv \frac{\partial y_k}{\partial x_i} \quad (5.70)$$


其中每个导数在其他所有输入固定的情况下计算。雅可比矩阵在由多个独立模块构成的系统中发挥重要作用，如图 5.8 所示。每个模块可以是固定的或自适应的函数，可以

是线性的或非线性的，只要它是可微的。假设我们希望对图 5.8 中的参数 w 最小化误差函数 E ，则误差函数的导数为

$$\frac{\partial E}{\partial w} = \sum_{k,j} \frac{\partial E}{\partial y_k} \frac{\partial y_k}{\partial z_j} \frac{\partial z_j}{\partial w} \quad (5.71)$$

其中图 5.8 中红色模块的雅可比矩阵出现在中间一项。

图 5.8 模块化模式识别系统示意图，在该系统中，Jacobian 矩阵可用于将误差信号从输出端反向传播至系统中较早的模块。



因为雅可比矩阵度量了输出对每个输入变量变化的局部敏感性，它还允许将已知的输入误差 Δx_i 通过训练好的网络传播，从而估计它们对输出误差 Δy_k 的贡献

$$\Delta y_k \simeq \sum_i \frac{\partial y_k}{\partial x_i} \Delta x_i \quad (5.72)$$

该关系在 $|\Delta x_i|$ 足够小时成立。一般而言，经过训练的神经网络所代表的映射是非线性的，因此雅可比矩阵的元素不是常数，而是依赖于具体的输入向量。因而 (5.72) 只对输入的微小扰动成立，且雅可比矩阵本身必须针对每个新的输入向量重新计算。

雅可比矩阵可以使用与前面推导误差函数对权重导数相似的反向传播过程来计算。我们先将元素 J_{ki} 写成

$$\begin{aligned} J_{ki} &= \frac{\partial y_k}{\partial x_i} = \sum_j \frac{\partial y_k}{\partial a_j} \frac{\partial a_j}{\partial x_i} \\ &= \sum_j w_{ji} \frac{\partial y_k}{\partial a_j} \end{aligned} \quad (5.73)$$

其中利用了 (5.48)。 (5.73) 中的求和遍历输入单元 i 所发送连接的所有单元 j （例如，在前面考虑的分层拓扑中，遍历第一隐层的所有单元）。现在写出递归反向传播公式来计算 $\partial y_k / \partial a_j$

$$\begin{aligned} \frac{\partial y_k}{\partial a_j} &= \sum_l \frac{\partial y_k}{\partial a_l} \frac{\partial a_l}{\partial a_j} \\ &= h'(a_j) \sum_l w_{lj} \frac{\partial y_k}{\partial a_l} \end{aligned} \quad (5.74)$$

其中求和遍历单元 j 发送连接的所有单元 l （对应 w_{lj} 的第一个下标）。这里再次利用了 (5.48) 和 (5.49)。这一反向传播从输出单元开始，此时所需导数可以直接由输出单元激活函数的形式得到。例如，若每个输出单元单独使用 sigmoid 激活函数，则

$$\frac{\partial y_k}{\partial a_j} = \delta_{kj} \sigma'(a_j) \quad (5.75)$$

而对于 softmax 输出，则有

$$\frac{\partial y_k}{\partial a_j} = \delta_{kj} y_k - y_k y_j \quad (5.76)$$

计算雅可比矩阵的过程可以总结如下：将对应于输入空间中需要计算雅可比矩阵点的输入向量施加到网络，按通常方式前向传播，得到网络中所有隐单元和输出单元的激活值。接着，对雅可比矩阵的每一行 k （对应输出单元 k ），使用递归关系 (5.74)，从 (5.75) 或 (5.76) 开始，对网络中所有隐单元进行反向传播。最后，使用 (5.73) 将信息反向传播到输入端。雅可比矩阵也可以使用另一种前向传播形式来计算，其推导方式与这里给出的反向传播方法类似。

同样，此类算法的实现也可以通过数值微分进行检查，形式为

$$\frac{\partial y_k}{\partial x_i} = \frac{y_k(x_i + \epsilon) - y_k(x_i - \epsilon)}{2\epsilon} + O(\epsilon^2) \quad (5.77)$$

对于具有 D 个输入的网络，这需要进行 $2D$ 次前向传播。

5.4 黑塞矩阵

我们已经展示了如何利用反向传播技术获得误差函数对网络中权重的一阶导数。反向传播还可以用来计算误差的二阶导数，即

$$\frac{\partial^2 E}{\partial w_{ji} \partial w_{lk}}. \quad (5.78)$$

有时为了方便，将所有的权重和偏置参数视为单个向量 $\mathbf{w}$ 的元素 w_i ，此时二阶导数组成黑塞矩阵 $\mathbf{H}$ 的元素 H_{ij} ，其中 $i, j \in \{1, \dots, W\}$ ， W 为权重和偏置的总数。黑塞矩阵在神经计算的许多方面都扮演着重要角色，包括：

1. 用于训练神经网络的几种非线性优化算法都基于误差曲面的二阶性质，而这些性质由黑塞矩阵控制（Bishop and Nabney, 2008）。
2. 黑塞矩阵是训练数据发生微小变化后快速重新训练前馈网络的基础（Bishop, 1991）。
3. 黑塞矩阵的逆曾被用于识别网络中重要性最低的权重，作为网络“剪枝”算法的一部分（Le Cun et al., 1990）。
4. 在贝叶斯神经网络的拉普拉斯近似中（见 5.7 节），黑塞矩阵占据核心地位。其逆用于确定训练好网络的预测分布，其特征值决定超参数的取值，其行列式用于评估模型证据（model evidence）。

人们曾使用多种近似方案来计算神经网络的黑塞矩阵。然而，通过对反向传播技术的扩展，也可以精确地计算黑塞矩阵。

对于黑塞矩阵的许多应用，一个重要的考虑因素是计算它的效率。如果网络中有 W 个参数（权重和偏置），则黑塞矩阵的维度为 $W \times W$ ，因此对数据集中的每个模式评估黑塞矩阵所需的计算量将以 $O(W^2)$ 的方式增长。正如我们将要看到的，确实存在效率很高的黑塞矩阵计算方法，其复杂度正是 $O(W^2)$ 。

5.4.1 对角近似

上面提到的黑塞矩阵的若干应用实际上需要的是黑塞矩阵的逆，而不是黑塞矩阵本身。正因如此，人们对使用黑塞矩阵的对角近似（即简单地将所有非对角元素置零）表现出一定兴趣，因为其逆的计算极其简单。我们仍考虑误差函数由数据集每个模式对应的项求和构成，即 $E = \sum_n E_n$ 。此时，黑塞矩阵可以通过逐个模式计算后再对所有模式求和得到。根据 (5.48)，对模式 n ，黑塞矩阵的对角元素可写为

$$\frac{\partial^2 E_n}{\partial w_{ji}^2} = \frac{\partial^2 E_n}{\partial a_j^2} z_i^2. \quad (5.79)$$

利用 (5.48) 和 (5.49)，(5.79) 右侧的二阶导数可通过微分学的链式法则递归求得，从而得到如下形式的反向传播方程

$$\frac{\partial^2 E_n}{\partial a_j^2} = h'(a_j)^2 \sum_k \sum_{k'} w_{kj} w_{k'j} \frac{\partial^2 E_n}{\partial a_k \partial a_{k'}} + h''(a_j) \sum_k w_{kj} \frac{\partial E_n}{\partial a_k}. \quad (5.80)$$

如果现在忽略二阶导数项中的所有非对角元素，就得到 (Becker and Le Cun, 1989; Le Cun et al., 1990)

$$\frac{\partial^2 E_n}{\partial a_j^2} = h'(a_j)^2 \sum_k w_{kj}^2 \frac{\partial^2 E_n}{\partial a_k^2} + h''(a_j) \sum_k w_{kj} \frac{\partial E_n}{\partial a_k}. \quad (5.81)$$

需要注意，计算这一近似所需的计算步数为 $O(W)$ ，其中 W 是网络中权重和偏置参数的总数，而完整黑塞矩阵的计算复杂度为 $O(W^2)$ 。

Ricotti et al. (1988) 同样使用了黑塞矩阵的对角近似，但他们在计算 $\partial^2 E_n / \partial a_j^2$ 时保留了所有项，从而得到了对角元素的精确表达式。需要指出的是，这种做法不再具有 $O(W)$ 的复杂度。然而，对角近似的主要问题是，实际中黑塞矩阵通常表现出强烈的非对角性，因此这些主要出于计算方便考虑的近似必须谨慎对待。

5.4.2 外积近似

当神经网络用于回归问题时，通常采用平方和误差函数，形式为

$$E = \frac{1}{2} \sum_{n=1}^N (y_n - t_n)^2 \quad (5.82)$$

为保持记号简洁，这里考虑单个输出的情形（向多个输出的扩展是直观的）。此时黑塞矩阵可写为

$$\mathbf{H} = \nabla \nabla E = \sum_{n=1}^N \nabla y_n \nabla y_n^T + \sum_{n=1}^N (y_n - t_n) \nabla \nabla y_n. \quad (5.83)$$

如果网络已在数据集上训练完成，且其输出 y_n 已非常接近目标值 t_n ，则 (5.83) 中的第二项将很小，可忽略。更一般地，可通过如下理由忽略该项。回忆 1.5.5 节，使平方和损失最小的最优函数是目标数据的条件均值。此时 $(y_n - t_n)$ 是均值为零的随机变

量。如果假设其值与 (5.83) 右侧二阶导数项的值不相关，则在对 n 求和时整个第二项的平均值为零。

通过忽略 (5.83) 中的第二项，我们得到 Levenberg-Marquardt 近似，或称外积近似 (outer product approximation，因为黑塞矩阵由向量外积之和构成)

$$\mathbf{H} \simeq \sum_{n=1}^N \mathbf{b}_n \mathbf{b}_n^T \quad (5.84)$$

其中 $\mathbf{b}_n = \nabla y_n = \nabla a_n$ ，因为输出单元的激活函数为恒等函数。外积近似黑塞矩阵的计算非常直接，仅涉及误差函数的一阶导数，可通过标准反向传播在 $O(W)$ 步内高效完成。随后通过简单乘法在 $O(W^2)$ 步内得到矩阵元素。必须强调，这一近似仅在网络已适当训练的情况下才可能成立。对于一般的网络映射，(5.83) 右侧的二阶导数项通常不可忽略。

对于采用 logistic sigmoid 输出单元激活函数的交叉熵误差函数，相应的近似为

$$\mathbf{H} \simeq \sum_{n=1}^N y_n(1 - y_n) \mathbf{b}_n \mathbf{b}_n^T. \quad (5.85)$$

对于具有 softmax 输出单元激活函数的多分类网络，可得到类似的结果。

5.4.3 逆黑塞矩阵

我们可以利用外积近似来得到一种计算效率较高的逆黑塞矩阵近似方法 (Hassibi and Stork, 1993)。首先将外积近似写成矩阵形式

$$\mathbf{H}_N = \sum_{n=1}^N \mathbf{b}_n \mathbf{b}_n^T \quad (5.86)$$

其中 $\mathbf{b}_n \equiv \nabla_{\mathbf{w}} a_n$ 是数据点 n 对输出单元激活值梯度的贡献。现在我们推导一种逐个加入数据点、逐步构建黑塞矩阵的序贯方法。假设我们已经利用前 L 个数据点得到了逆黑塞矩阵。将第 $L + 1$ 个数据点的贡献分离出来，可得

$$\mathbf{H}_{L+1} = \mathbf{H}_L + \mathbf{b}_{L+1} \mathbf{b}_{L+1}^T. \quad (5.87)$$

为了计算黑塞矩阵的逆，我们考虑如下矩阵恒等式

$$(\mathbf{M} + \mathbf{v} \mathbf{v}^T)^{-1} = \mathbf{M}^{-1} - \frac{(\mathbf{M}^{-1} \mathbf{v}) (\mathbf{v}^T \mathbf{M}^{-1})}{1 + \mathbf{v}^T \mathbf{M}^{-1} \mathbf{v}} \quad (5.88)$$

其中 $\mathbf{I}$ 为单位矩阵，这只是 Woodbury 恒等式 (C.7) 的特例。此时令 $\mathbf{H}_L$ 对应 $\mathbf{M}$ ， $\mathbf{b}_{L+1}$ 对应 $\mathbf{v}$ ，得到

$$\mathbf{H}_{L+1}^{-1} = \mathbf{H}_L^{-1} - \frac{\mathbf{H}_L^{-1} \mathbf{b}_{L+1} \mathbf{b}_{L+1}^T \mathbf{H}_L^{-1}}{1 + \mathbf{b}_{L+1}^T \mathbf{H}_L^{-1} \mathbf{b}_{L+1}}. \quad (5.89)$$

这样，数据点被逐个吸收，直至 $L + 1 = N$ ，整个数据集处理完毕。该结果因此提供了一种只需单次遍历数据集即可计算黑塞矩阵逆的方法。初始矩阵 $\mathbf{H}_0$ 取为 $\alpha \mathbf{I}$ ，其中

α 为一个很小的数，因此该算法实际求的是 $\mathbf{H} + \alpha\mathbf{I}$ 的逆。结果对 α 的具体取值并不特别敏感。将此算法扩展到具有多个输出的网络是直观的。

这里需要指出，黑塞矩阵有时可以在网络训练过程中作为副产品间接计算得到。特别是拟牛顿（quasi-Newton）非线性优化算法会在训练过程中逐步构建黑塞矩阵逆的近似。这类算法在 Bishop and Nabney (2008) 中有详细讨论。

5.4.4 有限差分

与误差函数一阶导数的情形类似，也可以使用有限差分来计算二阶导数，其精度受数值精度的限制。如果依次对每一对权重进行扰动，可得

$$\frac{\partial^2 E}{\partial w_{ji} \partial w_{lk}} = \frac{1}{4\epsilon^2} \left\{ E(w_{ji} + \epsilon, w_{lk} + \epsilon) - E(w_{ji} + \epsilon, w_{lk} - \epsilon) - E(w_{ji} - \epsilon, w_{lk} + \epsilon) + E(w_{ji} - \epsilon, w_{lk} - \epsilon) \right\} + O(\epsilon^2) \quad (5.90)$$

通过采用对称中心差分形式，确保残差为 $O(\epsilon^2)$ 而不是 $O(\epsilon)$ 。由于黑塞矩阵有 W^2 个元素，而每个元素的计算需要四次前向传播（每次传播对每个模式需要 $O(W)$ 次操作），因此该方法评估完整黑塞矩阵需要 $O(W^3)$ 次操作。它的复杂度扩展性很差，但实际上是检验反向传播方法软件实现是否正确的一种非常有力的手段。

数值微分还有一种更高效的版本，即对使用反向传播计算得到的一阶导数再应用中心差分，从而得到

$$\frac{\partial^2 E}{\partial w_{ji} \partial w_{lk}} = \frac{1}{2\epsilon} \left\{ \frac{\partial E}{\partial w_{ji}}(w_{lk} + \epsilon) - \frac{\partial E}{\partial w_{ji}}(w_{lk} - \epsilon) \right\} + O(\epsilon^2). \quad (5.91)$$

此时只需要对 W 个权重进行扰动，而梯度本身可用 $O(W)$ 步计算，因此该方法以 $O(W^2)$ 次操作得到黑塞矩阵。

5.4.5 黑塞矩阵的精确计算

到目前为止，我们讨论了多种计算黑塞矩阵或其逆的近似方法。实际上，对于任意前馈拓扑的网络，完全可以通过对计算一阶导数的反向传播技术的扩展来精确计算黑塞矩阵，这种方法保留了反向传播的许多优良特性，包括计算效率（Bishop, 1991; Bishop, 1992）。它适用于任何可表示为网络输出函数的可微误差函数，以及具有任意可微激活函数的网络。计算黑塞矩阵所需的计算步数以 $O(W^2)$ 方式增长。Buntine and Weigend (1993) 也考虑过类似的算法。

这里我们具体考虑具有两层权重的网络，这种情况下所需方程很容易推导。我们使用下标 i 和 i' 表示输入， j 和 j' 表示隐单元， k 和 k' 表示输出。首先定义

$$\delta_k = \frac{\partial E_n}{\partial a_k}, \quad M_{kk'} \equiv \frac{\partial^2 E_n}{\partial a_k \partial a_{k'}} \quad (5.92)$$

其中 E_n 是数据点 n 对误差的贡献。此网络的黑塞矩阵可分为以下三个独立的块。

1. 两个权重都在第二层:

$$\frac{\partial^2 E_n}{\partial w_{kj}^{(2)} \partial w_{k'j'}^{(2)}} = z_j z_{j'} M_{kk'} \quad (5.93)$$

2. 两个权重都在第一层:

$$\begin{aligned} \frac{\partial^2 E_n}{\partial w_{ji}^{(1)} \partial w_{j'i'}^{(1)}} &= x_i x_{i'} h''(a_{j'}) I_{jj'} \sum_k w_{kj'}^{(2)} \delta_k \\ &+ x_i x_{i'} h'(a_{j'}) h'(a_j) \sum_k \sum_{k'} w_{k'j'}^{(2)} w_{kj}^{(2)} M_{kk'}. \end{aligned} \quad (5.94)$$

3. 各一层权重:

$$\frac{\partial^2 E_n}{\partial w_{ji}^{(1)} \partial w_{kj'}^{(2)}} = x_i h'(a_{j'}) \left\{ \delta_k I_{jj'} + z_j \sum_{k'} w_{k'j'}^{(2)} M_{kk'} \right\}. \quad (5.95)$$

其中 $I_{jj'}$ 是单位矩阵的 j, j' 元素。如果一个或两个权重是偏置, 只需将相应的激活值设为 1 即可得到对应表达式。加入跳层连接也是直观的。

5.4.6 与黑塞矩阵的快速乘法

在黑塞矩阵的许多应用中, 我们真正关心的并不是黑塞矩阵 $\mathbf{H}$ 本身, 而是 $\mathbf{H}$ 与某个向量 $\mathbf{v}$ 的乘积 $\mathbf{v}^T \mathbf{H}$ 。我们已经知道, 直接计算黑塞矩阵需要 $O(W^2)$ 次操作, 并且需要 $O(W^2)$ 的存储空间。而我们最终想要的 $\mathbf{v}^T \mathbf{H}$ 只有 W 个元素, 因此完全可以绕过显式计算黑塞矩阵这一中间步骤, 直接寻找一种只需 $O(W)$ 次操作就能高效计算 $\mathbf{v}^T \mathbf{H}$ 的方法。

为此, 我们首先注意到

$$\mathbf{v}^T \mathbf{H} = \mathbf{v}^T \nabla (\nabla E) \quad (5.96)$$

其中 ∇ 表示权重空间中的梯度算子。于是我们可以先写出标准的用于计算 ∇E 的前向传播和反向传播方程, 然后对这些方程作用算子 (5.96), 即可得到一组用于计算 $\mathbf{v}^T \mathbf{H}$ 的前向传播和反向传播方程 (Møller, 1993; Pearlmutter, 1994)。这相当于对原始的前向传播和反向传播方程作用微分算子 $\mathbf{v}^T \nabla$ 。Pearlmutter (1994) 用记号 $\mathcal{R}\{\cdot\}$ 表示算子 $\mathbf{v}^T \nabla$, 我们沿用这一记号。分析过程非常直接, 只需使用通常的微分规则以及

$$\mathcal{R}\{\mathbf{w}\} = \mathbf{v}. \quad (5.97)$$

下面通过一个简单例子来说明该技术, 我们再次选用图 5.1 所示的两层网络, 输出单元为线性, 误差函数为平方和。如前所述, 这里只考虑单个模式对误差的贡献, 最终所需向量通过对所有模式分别计算后求和得到。

对于该两层网络，前向传播方程为

$$a_j = \sum_i w_{ji} x_i \quad (5.98)$$

$$z_j = h(a_j) \quad (5.99)$$

$$y_k = \sum_j w_{kj} z_j. \quad (5.100)$$

对这些方程作用 $\mathcal{R}\{\cdot\}$ 算子，得到如下形式的前向传播方程

$$\mathcal{R}\{a_j\} = \sum_i v_{ji} x_i \quad (5.101)$$

$$\mathcal{R}\{z_j\} = h'(a_j) \mathcal{R}\{a_j\} \quad (5.102)$$

$$\mathcal{R}\{y_k\} = \sum_j w_{kj} \mathcal{R}\{z_j\} + \sum_j v_{kj} z_j \quad (5.103)$$

其中 v_{ji} 是向量 $\mathbf{v}$ 中对应权重 w_{ji} 的元素。形如 $\mathcal{R}\{z_j\}$ 、 $\mathcal{R}\{a_j\}$ 和 $\mathcal{R}\{y_k\}$ 的量应视为新的变量，其值由上述方程计算得到。

由于采用平方和误差函数，标准反向传播表达式为

$$\delta_k = y_k - t_k \quad (5.104)$$

$$\delta_j = h'(a_j) \sum_k w_{kj} \delta_k \quad (5.105)$$

再次对这些方程作用 $\mathcal{R}\{\cdot\}$ 算子，得到如下反向传播方程

$$\mathcal{R}\{\delta_k\} = \mathcal{R}\{y_k\} \quad (5.106)$$

$$\begin{aligned} \mathcal{R}\{\delta_j\} &= h''(a_j) \mathcal{R}\{a_j\} \sum_k w_{kj} \delta_k \\ &\quad + h'(a_j) \sum_k v_{kj} \delta_k + h'(a_j) \sum_k w_{kj} \mathcal{R}\{\delta_k\}. \end{aligned} \quad (5.107)$$

最后，误差对权重的一阶导数标准方程为

$$\frac{\partial E}{\partial w_{kj}} = \delta_k z_j \quad (5.108)$$

$$\frac{\partial E}{\partial w_{ji}} = \delta_j x_i \quad (5.109)$$

对它们作用 $\mathcal{R}\{\cdot\}$ 算子，即得到向量 $\mathbf{v}^T \mathbf{H}$ 的各元素

$$\mathcal{R}\left\{\frac{\partial E}{\partial w_{kj}}\right\} = \mathcal{R}\{\delta_k\} z_j + \delta_k \mathcal{R}\{z_j\} \quad (5.110)$$

$$\mathcal{R}\left\{\frac{\partial E}{\partial w_{ji}}\right\} = x_i \mathcal{R}\{\delta_j\} \quad (5.111)$$

该算法的实现需要在隐单元中引入额外的变量 $\mathcal{R}\{a_j\}$ 、 $\mathcal{R}\{z_j\}$ 和 $\mathcal{R}\{\delta_j\}$ ，在输出单元中引入 $\mathcal{R}\{\delta_k\}$ 和 $\mathcal{R}\{y_k\}$ 。对于每一个输入模式，都可以利用上述结果计算这些量的

值, 随后 $\mathbf{v}^T \mathbf{H}$ 的各元素由 (5.110) 和 (5.111) 给出。该技术的一个优雅之处在于, 计算 $\mathbf{v}^T \mathbf{H}$ 的方程与标准的前向传播和反向传播方程非常相似, 因此对现有软件进行扩展以计算该乘积通常非常直接。

如果需要, 也可以利用该技术通过依次取向量 $\mathbf{v}$ 为一系列单位向量 (形式为 $(0, 0, \dots, 1, \dots, 0)$) 来计算完整的黑塞矩阵, 每个单位向量对应取出黑塞矩阵的一列。这将得到一个在解析上等价于 5.4.5 节描述的 Bishop (1992) 反向传播过程的形式化方法, 但由于存在冗余计算, 效率会有一定损失。

5.5 神经网络中的正则化

神经网络中输入单元和输出单元的数量通常由数据集的维数决定, 而隐单元数量 M 是一个可自由调节的超参数, 用来获得最佳预测性能。注意, M 控制着网络中参数 (权重和偏置) 的总数, 因此在最大似然框架下, 我们预期存在一个最优的 M 值, 使泛化性能最佳, 这对应于欠拟合与过拟合之间的最佳平衡。图 5.9 展示了正弦回归问题中不同 M 值的影响示例。





图 5.9 对来自正弦数据集的 10 个数据点训练两层网络的示意图。图中分别展示了具有 $M = 1, 3$ 和 10 个隐藏单元的网络, 采用缩放共轭梯度算法最小化平方误差函数得到的拟合结果。

然而, 由于误差函数存在局部极小值 (如图 5.10 所示), 泛化误差并不是 M 的简单函数。图中显示了对一系列 M 值采用多次随机权重初始化的结果。在该例中, 整体最佳验证集性能出现在某个 $M = 8$ 的特定解。实际操作中, 选择 M 的一种常用方法正是绘制类似图 5.10 的曲线, 然后挑选验证集误差最小的那个具体解。

图 5.10 对多项式数据集的平方和测试误差随网络隐藏单元数变化的示意图, 每个网络规模使用 30 次随机初始化, 以展示局部极小值的影响。每次初始化的权重向量均从均值为 0、方差为 10 的各向同性高斯分布中采样。



除了调整隐单元数量, 还有其他控制神经网络模型复杂度的手段以避免过拟合。从第 1 章多项式曲线拟合的讨论可知, 另一种思路是先选择一个相对较大的 M , 然后通过向误差函数中加入正则化项来控制复杂度。最简单的正则化项是二次形式, 得到如下

正则化误差

$$\tilde{E}(\mathbf{w}) = E(\mathbf{w}) + \frac{\lambda}{2} \mathbf{w}^T \mathbf{w} \quad (5.112)$$

这种正则化项也称为权重衰减 (weight decay)，我们在第 3 章已详细讨论。此时模型的有效复杂度由正则化系数 λ 决定。如前所述，这种正则化项可以解释为权重向量 $\mathbf{w}$ 上的零均值高斯先验分布的负对数。

5.5.1 一致的高斯先验

简单权重衰减形式 (5.112) 的一个局限在于，它与网络映射的某些尺度性质 (scaling properties) 不一致。为了说明这一点，考虑具有两层权重且输出单元为线性的多层感知器网络，该网络实现从输入变量集合 $\{x_i\}$ 到输出变量集合 $\{y_k\}$ 的映射。第一隐层隐单元的激活值为

$$z_j = h \left(\sum_i w_{ji} x_i + w_{j0} \right) \quad (5.113)$$

而输出单元的激活值为

$$y_k = \sum_j w_{kj} z_j + w_{k0}. \quad (5.114)$$

假设我们对输入数据进行如下线性变换

$$x_i \rightarrow \tilde{x}_i = ax_i + b. \quad (5.115)$$

则可以通过对从输入到第一隐层的权重和偏置进行相应的线性变换，使网络实现的映射保持不变：

$$w_{ji} \rightarrow \tilde{w}_{ji} = \frac{1}{a} w_{ji} \quad (5.116)$$

$$w_{j0} \rightarrow \tilde{w}_{j0} = w_{j0} - \frac{b}{a} \sum_i w_{ji}. \quad (5.117)$$

类似地，对网络输出变量进行线性变换

$$y_k \rightarrow \tilde{y}_k = cy_k + d \quad (5.118)$$

可以通过对第二层权重和偏置进行如下变换实现：

$$w_{kj} \rightarrow \tilde{w}_{kj} = cw_{kj} \quad (5.119)$$

$$w_{k0} \rightarrow \tilde{w}_{k0} = cw_{k0} + d. \quad (5.120)$$

如果我们分别使用原始数据和经过上述任一线性变换后的输入/目标数据来训练两个网络，一致性要求我们应该得到等价的网络，它们仅在权重上相差上述线性变换。任何正则化项都应当与这一性质一致，否则它就会武断地偏向某个解而排斥另一个等价解。显然，简单权重衰减 (5.112) 对所有权重和偏置一视同仁，并不满足这一性质。

因此，我们寻找一种在上述线性变换 (5.116)、(5.117)、(5.119) 和 (5.120) 下保持不变的正则化项。这些变换要求正则化项对权重的重新缩放以及偏置的平移保持不变。满足这一要求的正则化项为

$$\frac{\lambda_1}{2} \sum_{w \in \mathcal{W}_1} w^2 + \frac{\lambda_2}{2} \sum_{w \in \mathcal{W}_2} w^2 \quad (5.121)$$

其中 $\mathcal{W}_1$ 表示第一层权重的集合， $\mathcal{W}_2$ 表示第二层权重的集合，求和中不包含偏置。只要对正则化参数进行相应的重新缩放 $\lambda_1 \rightarrow a^{1/2}\lambda_1$ 和 $\lambda_2 \rightarrow c^{-1/2}\lambda_2$ ，该正则化项在上述权重变换下就保持不变。

正则化项 (5.121) 对应于如下形式的先验

$$p(\mathbf{w} \mid \alpha_1, \alpha_2) \propto \exp \left(-\frac{\alpha_1}{2} \sum_{w \in \mathcal{W}_1} w^2 - \frac{\alpha_2}{2} \sum_{w \in \mathcal{W}_2} w^2 \right). \quad (5.122)$$

需要注意，这种形式的先验是不 **proper** 的（无法归一化），因为偏置参数完全没有受到约束。使用不 **proper** 先验在贝叶斯框架下选择正则化系数以及进行模型比较时会带来困难，因为对应的证据（**evidence**）为零。因此，通常的做法是为偏置单独引入先验（这会打破平移不变性），并为其配置独立的超参数。我们可以通过从包含四个超参数的先验中抽样并绘制对应的网络函数来展示其效果，如图 5.11 所示。

更一般地，我们可以考虑将权重划分为任意多个组 $\mathcal{W}_k$ 的先验

$$p(\mathbf{w}) \propto \exp \left(-\frac{1}{2} \sum_k \alpha_k \|\mathbf{w}\|_k^2 \right) \quad (5.123)$$

其中

$$\|\mathbf{w}\|_k^2 = \sum_{j \in \mathcal{W}_k} w_j^2. \quad (5.124)$$

作为该先验的一个特例，如果我们将分组对应于与每个输入单元相连的权重集合，并在对应参数 α_k 上优化边缘似然，就会得到 7.2.2 节讨论的自动相关性判定（**automatic relevance determination**）。

5.5.2 早停法

控制网络有效复杂度的另一种方法（替代正则化）是早停法（**early stopping**）。对非线性网络模型的训练对应于针对训练数据集定义的误差函数的迭代下降。对于许多用于网络训练的优化算法（如共轭梯度），训练误差随迭代步数单调不增。然而，对独立数据（通常称为验证集，**validation set**）测量的误差往往先下降，随后当网络开始过拟合时出现上升。因此，可以在验证集误差最小的时刻停止训练，如图 5.12 所示，从而获得具有良好泛化性能的网络。

这种现象有时会用网络中“有效自由度”的概念进行定性解释：训练初期有效自由度很小，随着训练进行逐渐增加，对应模型有效复杂度的持续增长。在训练误差达到最小值之前提前终止训练，就相当于限制了网络的有效复杂度。




图 5.11 图展示了超参数对两层网络中权重和偏置先验分布的影响。该网络具有单一输入、单一线性输出，以及 12 个采用“tanh”激活函数的隐藏单元。先验由四个超参数 $\alpha_1^b, \alpha_1^w, \alpha_2^b, \alpha_2^w$ 控制，它们分别代表第一层偏置、第一层权重、第二层偏置与第二层权重的高斯分布精度。可以看到，参数 α_2^w 控制函数的纵向尺度（注意上方两幅图的纵轴范围不同）， α_1^w 控制函数值变化的横向尺度，而 α_1^b 控制变化发生的横向区间。参数 α_2^b （此处未示出）则控制函数的整体纵向偏移范围。

对于平方误差函数的情形，我们可以严格验证这一直觉，并证明早停法与使用简单权重衰减的正则化具有相似行为。这一点可从图 5.13 看出，其中权重空间坐标轴已旋转到与黑塞矩阵本征向量平行。在无权重衰减的情况下，权重向量从原点出发，沿局部负梯度方向前进，其轨迹会先基本平行于 w_2 轴，经过一个近似对应 $\tilde{\mathbf{w}}$ 的点，然后才转向误差函数最小点 $\mathbf{w}_{\text{ML}}$ 。这是因为误差曲面形状以及黑塞矩阵特征值差异极大。因此，在靠近 $\tilde{\mathbf{w}}$ 处停止训练与施加权重衰减非常相似。早停法与权重衰减之间的关系可以定量表述，从而表明量 $\tau\eta$ （其中 τ 为迭代步数， η 为学习率参数）起到了正则化参数 λ 倒数的作用。因此，网络中的有效参数数量在训练过程中逐渐增长。

5.5.3 不变性 (Invariances)

在许多模式识别应用中，已知预测结果应当对输入变量的一个或多个变换保持不变或具有不变性。例如，在二维图像中对物体（如手写数字）进行分类时，同一物体无论出现在图像中的哪个位置（平移不变性 **translation invariance**）或大小如何（尺度不变性 **scale invariance**），都应该被分配到相同的类别。这类变换会在原始数据（以图像每个像素的强度表示）上产生显著变化，但分类系统的输出应当保持一致。类似地，在语





图 5.12 图展示了在对正弦数据集进行训练时，训练集误差（左图）与验证集误差（右图）随迭代步数变化的情况。为了获得最佳泛化性能，应在验证集误差达到最小值的位置（由竖直虚线标出）停止训练。

图 5.13 图说明了在误差函数为二次形式时，提前停止训练为何能产生与权重衰减类似的效果。椭圆表示恒定误差的等高线， $\mathbf{w}_{ML}$ 表示误差函数的最小点。如果权重向量从原点出发并沿局部负梯度方向移动，将沿图中曲线前进。通过提前停止训练可得到权重向量 $\tilde{\mathbf{w}}$ ，其性质与使用简单权重衰减正则项并将训练进行到正则化误差最小点所得到的解相似，这一点可与图 3.15 进行比较。



音识别中，沿时间轴的小幅非线性扭曲（warping，只要保持时序顺序）也不应改变对信号的解释。

如果有足够多的训练样本，自适应模型（如神经网络）至少可以近似地学习到这些不变性。这需要训练集中包含足够多的、经过各种变换后的样本。例如，要实现图像的平移不变性，训练集中就应包含物体出现在许多不同位置的样本。

然而，当训练样本数量有限，或存在多个需要的不变性时（因为变换组合的数量随变换种类指数增长），这种方法可能变得不切实际。因此，我们需要寻找其他方法来鼓励自适应模型表现出所需的不变性。这些方法大致可分为四类：

1. 通过对训练样本进行所需不变性对应的变换来扩充训练集。例如，在手写数字识别中，可以对每个样本生成多个副本，其中数字被平移到图像中的不同位置。
2. 在误差函数中加入正则化项，对输入变换后模型输出的变化进行惩罚。这导致了切线传播（tangent propagation）技术，将在 5.5.4 节讨论。
3. 在预处理阶段提取对所需变换具有不变性的特征。随后使用这些特征作为输入的任何回归或分类系统必然也尊重这些不变性。
4. 最后一种选择是将不变性直接构建到神经网络的结构中（或在相关向量机等技术中构建到核函数的定义中）。实现这一目标的一种方式是使用局部感受野（local

receptive fields) 和权重共享 (shared weights), 这将在 5.5.6 节卷积神经网络的讨论中介绍。




图 5.14 手写数字的合成变形示意图。左侧为原始图像。右侧上排展示了三个变形后的数字示例，下排给出了对应的位移场。这些位移场通过在每个像素处随机采样 $\Delta x, \Delta y \in (0, 1)$, 然后分别使用宽度为 0.01, 30, 60 的高斯核进行平滑卷积生成。


方法 1 通常相对容易实现, 并且可以用来鼓励复杂的、如图 5.14 所示的不变性。对于序贯训练算法, 可以在每次将输入模式呈现给模型前对其进行变换 (如果样本被循环使用, 则每次从适当分布中抽取不同的变换)。对于批方法, 可以通过将每个数据点复制多次并对每个副本独立变换来达到类似效果。这种数据增强的使用可以显著提升泛化性能 (Simard et al., 2003), 尽管计算成本也可能较高。

方法 2 不改变数据集本身, 而是通过添加正则化项修改误差函数。我们将在 5.5.5 节中展示, 这种方法与方法 1 密切相关。

方法 3 的一个优点是它能很好地外推到训练集中未包含的变换范围之外。然而, 手工设计既具有所需不变性又不丢弃对区分有用信息的特征往往非常困难。

5.5.4 切线传播

图 5.15 二维输入空间示意图, 展示连续变换对特定输入向量 $\mathbf{x}_n$ 的影响。对 $\mathbf{x}_n$ 施加由连续变量 ξ 参数化的一维变换, 会使其在空间中描绘出一条一维流形 $\mathcal{M}$ 。在局部, 该变换的作用可以由切向量 τ_n 进行近似。



我们可以通过切线传播 (tangent propagation) 技术 (Simard et al., 1992) 利用正则化来鼓励模型对输入变换保持不变。考虑对某个特定输入向量 $\mathbf{x}_n$ 施加变换的影响。只要变换是连续的 (例如平移或旋转, 但不包括镜面反射), 变换后的模式就会在 D 维输入空间中扫出一个流形 $\mathcal{M}$ 。如图 5.15 所示 (为简单起见, 取 $D = 2$)。假设该变换由单

一参数 ξ （例如旋转角度）控制，则 $\mathbf{x}_n$ 扫出的子空间 $\mathcal{M}$ 是一维的，并由 ξ 参数化。记对 $\mathbf{x}_n$ 施加该变换后得到的向量为 $\mathbf{s}(\mathbf{x}_n, \xi)$ ，定义满足 $\mathbf{s}(\mathbf{x}, 0) = \mathbf{x}$ 。则曲线 $\mathcal{M}$ 的切向量为方向导数 $\boldsymbol{\tau} = \partial \mathbf{s} / \partial \xi$ ，在点 $\mathbf{x}_n$ 处的切向量为

$$\boldsymbol{\tau}_n = \left. \frac{\partial \mathbf{s}(\mathbf{x}_n, \xi)}{\partial \xi} \right|_{\xi=0}. \quad (5.125)$$

在输入向量变换下，网络输出向量一般会发生变化。输出 k 对 ξ 的导数为

$$\left. \frac{\partial y_k}{\partial \xi} \right|_{\xi=0} = \sum_{i=1}^D \frac{\partial y_k}{\partial x_i} \left. \frac{\partial x_i}{\partial \xi} \right|_{\xi=0} = \sum_{i=1}^D J_{ki} \tau_i \quad (5.126)$$

其中 J_{ki} 是 5.3.4 节讨论的雅可比矩阵 $\mathbf{J}$ 的第 (k, i) 元素。利用 (5.126)，我们可以通过向原始误差函数 E 加入正则化项 Ω 来鼓励在每个数据点附近具有局部不变性，从而得到总误差函数

$$\tilde{E} = E + \lambda \Omega \quad (5.127)$$


其中 λ 为正则化系数，正则化项为

$$\Omega = \frac{1}{2} \sum_n \sum_k \left(\left. \frac{\partial y_{nk}}{\partial \xi} \right|_{\xi=0} \right)^2 = \frac{1}{2} \sum_n \sum_k \left(\sum_{i=1}^D J_{nki} \tau_{ni} \right)^2. \quad (5.128)$$

当网络映射函数在每个模式向量附近对该变换保持不变时，正则化项为零；参数 λ 的取值决定了拟合训练数据与学习不变性之间的平衡。

在实际实现中，切向量 $\boldsymbol{\tau}_n$ 可以用有限差分近似：对 $\mathbf{x}_n$ 施加小的 ξ 变换后得到的向量减去原向量，再除以 ξ 。如图 5.16 所示。

图 5.16 图展示了：(a) 手写数字的原始图像 $\mathbf{x}$ ；(b) 对应于无穷小顺时针旋转的切向量 $\boldsymbol{\tau}$ ；(c) 将切向量按小幅度加入原始图像得到的 $\mathbf{x} + \epsilon \boldsymbol{\tau}$ ，其中 $\epsilon = 15$ 度；(d) 真实旋转后的图像用于对比。



正则化函数通过雅可比矩阵 $\mathbf{J}$ 依赖于网络权重。对正则化项关于网络权重的导数，可以很容易地通过 5.3 节介绍技术的扩展，用反向传播形式计算得到。

如果变换由 L 个参数控制（例如二维图像中平移结合平面内旋转时 $L = 3$ ），则流形 $\mathcal{M}$ 的维数为 L ，相应的正则化项为 (5.128) 形式的各项之和，每一项对应一个变换参数。如果同时考虑多个变换，并使网络映射对每个变换单独保持不变，则网络将（局部）对这些变换的组合也保持不变（Simard et al., 1992）。

一种相关技术称为切线距离（tangent distance），可用于将不变性引入基于距离的方法，如最近邻分类器（Simard et al., 1993）。

5.5.5 使用变换数据进行训练

我们已经看到，鼓励模型对一组变换保持不变的一种方法是使用原始输入样本的变换版本来扩充训练集。这里我们证明，这种方法与切线传播（tangent propagation）技术密切相关（Bishop, 1995b; Leen, 1995）。

与 5.5.4 节相同，我们考虑由单一参数 ξ 控制的变换，记为函数 $\mathbf{s}(\mathbf{x}, \xi)$ ，满足 $\mathbf{s}(\mathbf{x}, 0) = \mathbf{x}$ 。同时考虑平方和误差函数。在无限数据极限下，未施加变换的误差函数可写为（见 1.5.5 节）

$$E = \frac{1}{2} \iint \{y(\mathbf{x}) - t\}^2 p(t | \mathbf{x}) p(\mathbf{x}) d\mathbf{x} dt \quad (5.129)$$

为保持记号简洁，这里考虑网络只有一个输出。现在假设对每个数据点生成无限多个副本，每个副本的扰动参数 ξ 从分布 $p(\xi)$ 中抽取，则在该扩充数据集上的误差函数为

$$\tilde{E} = \frac{1}{2} \iiint \{y(\mathbf{s}(\mathbf{x}, \xi)) - t\}^2 p(t | \mathbf{x}) p(\mathbf{x}) p(\xi) d\mathbf{x} dt d\xi. \quad (5.130)$$

假设 $p(\xi)$ 均值为零、方差很小（即只考虑对原始输入向量的微小变换），我们可将变换函数对 ξ 进行泰勒展开

$$\begin{aligned} \mathbf{s}(\mathbf{x}, \xi) &= \mathbf{s}(\mathbf{x}, 0) + \xi \left. \frac{\partial}{\partial \xi} \mathbf{s}(\mathbf{x}, \xi) \right|_{\xi=0} + \frac{\xi^2}{2} \left. \frac{\partial^2}{\partial \xi^2} \mathbf{s}(\mathbf{x}, \xi) \right|_{\xi=0} + O(\xi^3) \\ &= \mathbf{x} + \xi \boldsymbol{\tau} + \frac{1}{2} \xi^2 \boldsymbol{\tau}' + O(\xi^3) \end{aligned}$$

其中 $\boldsymbol{\tau}'$ 表示 $\mathbf{s}(\mathbf{x}, \xi)$ 关于 ξ 的二阶导数在 $\xi = 0$ 处的值。这使得我们可以对模型函数进行展开，得到

$$y(\mathbf{s}(\mathbf{x}, \xi)) = y(\mathbf{x}) + \xi \boldsymbol{\tau}^T \nabla y(\mathbf{x}) + \frac{\xi^2}{2} [(\boldsymbol{\tau}')^T \nabla y(\mathbf{x}) + \boldsymbol{\tau}^T \nabla \nabla y(\mathbf{x}) \boldsymbol{\tau}] + O(\xi^3).$$

将上式代入 (5.130) 并展开，得到

$$\begin{aligned} \tilde{E} &= \frac{1}{2} \iint \{y(\mathbf{x}) - t\}^2 p(t | \mathbf{x}) p(\mathbf{x}) d\mathbf{x} dt \\ &\quad + \mathbb{E}[\xi] \iint \{y(\mathbf{x}) - t\} \boldsymbol{\tau}^T \nabla y(\mathbf{x}) p(t | \mathbf{x}) p(\mathbf{x}) d\mathbf{x} dt \\ &\quad + \mathbb{E}[\xi^2] \iint \left[\{y(\mathbf{x}) - t\} \frac{1}{2} \left\{ (\boldsymbol{\tau}')^T \nabla y(\mathbf{x}) + \boldsymbol{\tau}^T \nabla \nabla y(\mathbf{x}) \boldsymbol{\tau} \right\} \right. \\ &\quad \left. + (\boldsymbol{\tau}^T \nabla y(\mathbf{x}))^2 \right] p(t | \mathbf{x}) p(\mathbf{x}) d\mathbf{x} dt + O(\xi^3). \end{aligned}$$

由于变换分布均值为零，有 $\mathbb{E}[\xi] = 0$ 。记 $\mathbb{E}[\xi^2] = \lambda$ 。忽略 $O(\xi^3)$ 项后，平均误差函数变为

$$\tilde{E} = E + \lambda\Omega \quad (5.131)$$

其中 E 为原始平方和误差，正则化项 Ω 为

$$\Omega = \int \left[\{y(\mathbf{x}) - \mathbb{E}[t | \mathbf{x}]\} \frac{1}{2} \{(\boldsymbol{\tau}')^T \nabla y(\mathbf{x}) + \boldsymbol{\tau}^T \nabla \nabla y(\mathbf{x}) \boldsymbol{\tau}\} + (\boldsymbol{\tau}^T \nabla y(\mathbf{x}))^2 \right] p(\mathbf{x}) d\mathbf{x} \quad (5.132)$$

其中我们已经对 t 进行了积分。

我们还可以按如下方式进一步简化该正则化项。在 1.5.5 节中我们看到，最小化平方和误差的函数正是目标值 t 的条件均值 $\mathbb{E}[t | \mathbf{x}]$ 。从 (5.131) 可知，正则化误差等于未正则化的平方和误差加上 $O(\xi)$ 量级的项，因此最小化总误差的网络函数具有形式

$$y(\mathbf{x}) = \mathbb{E}[t | \mathbf{x}] + O(\xi). \quad (5.133)$$

因此，在 ξ 的最低阶，正则化项中的第一项消失，我们得到

$$\Omega = \frac{1}{2} \int (\boldsymbol{\tau}^T \nabla y(\mathbf{x}))^2 p(\mathbf{x}) d\mathbf{x} \quad (5.134)$$

这等价于切线传播正则化项 (5.128)。

如果我们考虑一种特殊情形，即对输入的变换仅为加入随机噪声 $\mathbf{x} \rightarrow \mathbf{x} + \boldsymbol{\xi}$ ，则正则化项取如下形式

$$\Omega = \frac{1}{2} \int \|\nabla y(\mathbf{x})\|^2 p(\mathbf{x}) d\mathbf{x} \quad (5.135)$$

这被称为 Tikhonov 正则化 (Tikhonov and Arsenin, 1977; Bishop, 1995b)。该正则化项对网络权重的导数也可以通过扩展的反向传播算法求得 (Bishop, 1993)。我们看到，当噪声幅度很小时，Tikhonov 正则化等价于在输入中加入随机噪声，而后者在适当情形下已被证明能够改善泛化性能 (Sietsma and Dow, 1991)。

5.5.6 卷积网络

另一种使模型对输入的某些变换具有不变性的方法，是将不变性直接构建到神经网络的结构中。这就是卷积神经网络 (convolutional neural network) 的基础 (Le Cun et al., 1989; LeCun et al., 1998)，它已被广泛应用于图像数据。

考虑手写数字识别这一具体任务。每个输入图像由一组像素强度值组成，期望的输出是对十个数字类别上的后验概率分布。我们知道，数字的身份对平移、缩放以及（小的）旋转是不变的。此外，网络还必须对更细微的变换（如图 5.14 所示的弹性形变）具有不变性。最简单的一种思路是将图像直接作为全连接网络（如图 5.1 所示）的输入。如果训练集足够大，这种网络原则上可以很好地解决这个问题，并通过样本学习到适当的不变性。

然而，这种做法忽略了图像的一个关键特性：相邻像素之间的相关性远强于距离较远的像素。现代计算机视觉的许多方法都利用了这一特性，通过仅依赖图像小区域的局部特征进行提取。随后在处理的后期阶段将这些特征融合，以检测更高阶特征，最终得到关于整幅图像的信息。此外，在图像某个区域有用的局部特征，在图像的其他区域通常也同样有用，例如当感兴趣的对象发生平移时。




图 5.17 图展示了卷积神经网络的一部分，其中一层卷积单元之后接一层子采样单元。这种层对可以连续堆叠多次。

卷积神经网络通过以下三种机制将这些思想融入其中：(i). 局部感受野（local receptive fields），(ii). 权重共享（weight sharing），(iii). 子采样（subsampling）。卷积网络的结构如图 5.17 所示。在卷积层中，单元被组织成若干平面，每个平面称为一个特征图（feature map）。同一特征图中的单元仅从图像的一个小局部区域接收输入，并且该特征图内所有单元被迫共享完全相同的权重值。例如，一个特征图可能包含 100 个单元，排列成 10×10 的网格，每个单元从图像的 5×5 像素块接收输入。这样，整个特征图只有 25 个可调权重参数加上 1 个可调偏置参数。来自局部区域的输入值通过这些权重和偏置进行线性组合，再通过 sigmoid 等非线性（5.1）变换。如果把这些单元看作特征检测器，那么同一个特征图中的所有单元都在检测相同的模式，只是位置不同。由于权重共享，计算这些单元激活值的过程等价于用一个由权重参数构成的“核”（kernel）对图像像素强度进行卷积。如果输入图像发生平移，特征图的激活值也会平移相同距离，但其余保持不变。这为网络输出对输入图像的平移和形变具有（近似）不变性提供了基础。通常为了构建有效的模型，需要检测多种特征，因此卷积层中一般包含多个特征图，每个特征图拥有自己独立的权重和偏置参数。

卷积单元的输出作为网络子采样层的输入。对于卷积层中的每个特征图，子采样层中都有对应的一个单元平面，每个子采样单元从卷积层相应特征图的一个小感受野接收输入。这些单元执行子采样操作。例如，每个子采样单元可能从对应特征图的 2×2 区域接收输入，计算这些输入的平均值，再乘以一个可调权重、加上一个可调偏置，最后通过 **sigmoid** 非线性激活函数变换。感受野设计为连续且不重叠，因此子采样层的行数和列数是卷积层的一半。这样，子采样层中单元的响应对输入空间对应区域的微小平移就相对不敏感。

在实际架构中，通常会堆叠多对卷积层和子采样层。每经过一对这样的层，网络对输入变换（平移、缩放、形变等）的不变性就比前一层显著增强。在每一级卷积层中，针对前一层子采样层的每个单元平面，通常会设置多个特征图。这样，虽然空间分辨率逐步降低，但特征通道数不断增加，从而对信息量进行补偿。网络的最后一层通常是一个全连接、全自适应的层，对于多分类任务，输出端采用 **softmax** 非线性。

整个网络可以通过误差最小化进行训练，使用反向传播计算误差函数的梯度。只需对标准反向传播算法稍作修改，即可保证权重共享约束得到满足。由于采用了局部感受野，网络中的权重总数远少于同等规模的全连接网络。更重要的是，由于大量权重共享约束的存在，需要从数据中实际学习的独立参数数量大幅减少。

5.5.7 软权重共享

减少拥有大量权重网络有效复杂度的一种方法，是强制某些权重组内的权重取值相等。这就是 5.5.6 节讨论的权重共享技术，用于在图像解释任务中构建平移不变性。但它仅适用于可以预先指定约束形式的问题。这里介绍一种软权重共享（**soft weight sharing**）方法（Nowlan and Hinton, 1992），它不再使用权重必须严格相等的硬约束，而是通过正则化鼓励若干权重组内的权重值趋于相近。更重要的是，权重的分组、每个组的中心值以及组内离散程度，都在学习过程中自动确定。

回想最简单的权重衰减正则化项 (5.112) 可以看作权重上的高斯先验的负对数。如果我们希望权重不是聚成一个高斯，而是聚成多个簇，就可以改用高斯混合模型作为先验。混合模型中每个高斯分量的中心 μ_j 、方差 σ_j^2 以及混合系数 π_j 都是可调参数，随训练一起学习。

于是，权重的先验分布为

$$p(\mathbf{w}) = \prod_i p(w_i) \quad (5.136)$$

其中

$$p(w_i) = \sum_{j=1}^M \pi_j \mathcal{N}(w_i | \mu_j, \sigma_j^2) \quad (5.137)$$

取负对数后得到正则化项

$$\Omega(\mathbf{w}) = - \sum_i \ln \left(\sum_{j=1}^M \pi_j \mathcal{N}(w_i | \mu_j, \sigma_j^2) \right). \quad (5.138)$$

总误差函数为

$$\tilde{E}(\mathbf{w}) = E(\mathbf{w}) + \lambda \Omega(\mathbf{w}) \quad (5.139)$$

其中 λ 为正则化系数。该误差函数同时对权重 w_i 和混合模型参数 $\{\pi_j, \mu_j, \sigma_j\}$ 进行最小化。如果权重固定, 可用第 9 章介绍的 EM 算法求解混合模型参数。但这里权重本身也在不断变化, 因此为避免数值不稳定, 通常采用联合优化, 同时对权重和混合模型参数进行迭代优化, 可使用共轭梯度或拟牛顿等标准优化算法实现。

为了最小化总误差函数, 需要计算它对各可调参数的导数。为此, 方便地将 $\{\pi_j\}$ 视为先验概率, 并引入对应的后验概率, 按照贝叶斯定理 (2.192), 后验概率为

$$\gamma_j(w) = \frac{\pi_j \mathcal{N}(w | \mu_j, \sigma_j^2)}{\sum_k \pi_k \mathcal{N}(w | \mu_k, \sigma_k^2)}. \quad (5.140)$$

于是, 总误差函数对权重的导数为

$$\frac{\partial \tilde{E}}{\partial w_i} = \frac{\partial E}{\partial w_i} + \lambda \sum_j \gamma_j(w_i) \frac{(w_i - \mu_j)}{\sigma_j^2}. \quad (5.141)$$

正则化项的作用因此是将每个权重 w_i 向第 j 个高斯中心的 μ_j 拉动, 拉力大小与该权重属于第 j 个高斯分量的后验概率成正比。这正是我们希望得到的软权重共享效果。对高斯中心 μ_j 的导数也很容易计算:

$$\frac{\partial \tilde{E}}{\partial \mu_j} = \lambda \sum_i \gamma_j(w_i) \frac{(\mu_j - w_i)}{\sigma_j^2} \quad (5.142)$$

这具有直观的解释: 它将 μ_j 推向所有权重的加权平均, 权重由各权重属于第 j 个分量的后验概率决定。对高斯方差的导数为

$$\frac{\partial \tilde{E}}{\partial \sigma_j} = \lambda \sum_i \gamma_j(w_i) \left(\frac{1}{\sigma_j} - \frac{(w_i - \mu_j)^2}{\sigma_j^3} \right) \quad (5.143)$$

这将 σ_j 驱动到权重围绕对应中心 μ_j 的平方偏差的加权平均, 权重系数同样是各权重由第 j 个分量生成的后验概率。在实际实现中, 通常引入新变量 η_j , 定义

$$\sigma_j^2 = \exp(\eta_j) \quad (5.144)$$

并对 η_j 进行优化。这样既保证了 σ_j 始终为正, 又有效避免了病态解 (即某个 σ_j 趋于零, 使高斯分量坍缩到某个权重值上)。这类病态解在第 9.2.1 节高斯混合模型的讨论中会更详细说明。

对于混合系数 π_j 的导数, 我们必须考虑其作为先验概率所满足的约束

$$\sum_j \pi_j = 1, \quad 0 \leq \pi_j \leq 1 \quad (5.145)$$

为此, 可通过 softmax 函数将混合系数表示为一组辅助变量 $\{\eta_j\}$ 的函数

$$\pi_j = \frac{\exp(\eta_j)}{\sum_{k=1}^M \exp(\eta_k)}. \quad (5.146)$$

此时，正则化误差函数对 $\{\eta_j\}$ 的导数为

$$\frac{\partial \tilde{E}}{\partial \eta_j} = \sum_i \{\pi_j - \gamma_j(w_i)\}. \quad (5.147)$$


可见， π_j 将被驱动到第 j 个高斯分量在所有权重上的平均后验概率。

5.6 混合密度网络

监督学习的目标是建模条件分布 $p(\mathbf{t} | \mathbf{x})$ 。在许多简单的回归问题中，通常假设其为高斯分布。然而，实际机器学习问题中的条件分布往往显著非高斯。例如在逆问题（inverse problems）中，条件分布可能是多峰的，此时高斯假设会导致极差的预测。

一个简单的逆问题例子是机器人臂运动学，如图 5.18 所示。正向问题（给定关节角度求末端执行器位置）有唯一解；但实际任务通常是让末端执行器到达指定位置，需要求解关节角度，即逆问题，如图所示存在两个解。

图 5.18 左图展示了一个双连杆机械臂，其中末端执行器的笛卡尔坐标 (x_1, x_2) 由两个关节角 θ_1, θ_2 以及臂长 L_1, L_2 （固定不变）唯一决定，这被称为机械臂的正运动学。在实际应用中，我们需要根据目标末端位置求解对应的关节角，如右图所示，逆运动学存在两个解，分别对应“肘部朝上”和“肘部朝下”两种姿态。



正向问题通常对应物理系统中的因果关系，具有唯一解。例如某种疾病会导致特定症状。而在模式识别中，我们通常要解决逆问题：根据症状预测疾病。如果正向映射是多对一的，则逆问题必然存在多个解——多种疾病可能产生相同症状。

在机器人臂例子中，多峰性通过几何方程显而易见。但在许多机器学习问题中，尤其是在高维空间中，多峰性并不明显。为便于教学，我们考虑一个简单的玩具问题：先从区间 $(0,1)$ 均匀采样 x_n ，目标值 $t_n = x_n + 0.3 \sin(2\pi x_n)$ 再加上区间 $(-0.1, 0.1)$ 的均匀噪声。正向问题和逆问题的数据如图 5.19 所示。使用含 6 个隐单元的双层神经网络、线性输出单元并最小化平方和误差（即最大似然下的高斯假设）拟合，结果表明：对高度非高斯的逆问题，模型表现极差。


因此，我们需要一个通用的框架来建模条件概率分布。这可以通过将 $p(\mathbf{t} | \mathbf{x})$ 建模为混合模型实现，其中混合系数和各分量密度均为输入向量 $\mathbf{x}$ 的函数，从而得到混合密度网络（mixture density network）。对于任意给定的 $\mathbf{x}$ ，混合模型提供了一种建模任意条件密度 $p(\mathbf{t} | \mathbf{x})$ 的通用形式。只要网络足够灵活，就具备逼近任意条件分布的能力。

这里我们显式地针对高斯分量展开模型：

$$p(\mathbf{t} | \mathbf{x}) = \sum_{k=1}^K \pi_k(\mathbf{x}) \mathcal{N}(\mathbf{t} | \boldsymbol{\mu}_k(\mathbf{x}), \sigma_k^2(\mathbf{x}) \mathbf{I}) \quad (5.148)$$

这是一个异方差模型（heteroscedastic），因为噪声方差是输入 $\mathbf{x}$ 的函数。若目标变量为二值而非连续，可改用伯努利分布作为分量。当前采用各向同性协方差，但混合密

图 5.19 左图展示了一个简单“正向问题”的数据集，通过最小化平方误差函数拟合两层神经网络得到的结果以红色曲线表示。右图展示了相应的逆问题，通过交换 x 和 t 的角色得到。在这种情况下，使用同样的网络并再次通过最小化平方误差函数进行训练会得到非常糟糕的拟合结果，因为该数据集具有多模态特性。



度网络很容易扩展到一般协方差矩阵（通过 Cholesky 分解表示协方差，Williams, 1996）。即使分量各向同性，由于混合机制的存在，条件分布 $p(\mathbf{t} | \mathbf{x})$ 并不假设在 $\mathbf{t}$ 的各分量上独立（这与标准平方和回归模型不同）。

我们将混合模型的全部参数——混合系数 $\pi_k(\mathbf{x})$ 、均值 $\mu_k(\mathbf{x})$ 、方差 $\sigma_k^2(\mathbf{x})$ ——均设为一个常规神经网络的输出，该网络以 $\mathbf{x}$ 为输入。这种混合密度网络的结构如图 5.20 所示。混合密度网络与 14.5.3 节将介绍的专家混合模型（mixture of experts）密切相关。主要区别在于：混合密度网络中，所有分量密度参数和混合系数均由同一个网络预测，因此非线性隐单元在所有依赖输入的函数之间共享。




图 5.20 混合密度网络可以通过引入关于 t 的参数化混合模型来表示一般的条件概率密度 $p(t | x)$ ，其中混合模型的参数由以 x 为输入向量的神经网络输出决定。

图 5.20 中的神经网络可以是具有 sigmoid ($\tanh$) 隐单元的双层网络。若混合模型 (5.148) 含有 L 个高斯分量，目标变量 $\mathbf{t}$ 有 K 维，则该网络将具有以下输出单元激活值： L 个激活值 a_k^π ，用于决定混合系数 $\pi_k(\mathbf{x})$ ； L 个激活值 a_k^σ ，用于决定核宽度 $\sigma_k(\mathbf{x})$ ； $L \times K$ 个激活值 a_{kj}^μ ，用于决定核中心 $\mu_k(\mathbf{x})$ 的各分量 $\mu_{kj}(\mathbf{x})$ 。网络总输出单元数为 $(K + 2)L$ ，相比普通仅预测条件均值的网络（只有 K 个输出）大幅增加。

混合系数必须满足

$$\sum_{k=1}^L \pi_k(\mathbf{x}) = 1, \quad 0 \leq \pi_k(\mathbf{x}) \leq 1 \quad (5.149)$$

可通过 softmax 输出实现：

$$\pi_k(\mathbf{x}) = \frac{\exp(a_k^\pi)}{\sum_{l=1}^L \exp(a_l^\pi)} \quad (5.150)$$

方差必须非负，故采用指数形式：

$$\sigma_k(\mathbf{x}) = \exp(a_k^\sigma) \quad (5.151)$$

均值 $\mu_k(\mathbf{x})$ 为实数，可直接由网络输出激活值表示：

$$\mu_{kj}(\mathbf{x}) = a_{kj}^\mu \quad (5.152)$$

混合密度网络的可调参数为神经网络中的权重和偏置向量 $\mathbf{w}$ ，通过最大似然设定，或等价地通过最小化负对数似然误差函数实现。对于独立同分布的数据，该误差函数为

$$E(\mathbf{w}) = - \sum_{n=1}^N \ln \left\{ \sum_{k=1}^L \pi_k(\mathbf{x}_n, \mathbf{w}) \mathcal{N}(\mathbf{t}_n | \mu_k(\mathbf{x}_n, \mathbf{w}), \sigma_k^2(\mathbf{x}_n, \mathbf{w})) \right\} \quad (5.153)$$

其中已显式写出对 $\mathbf{w}$ 的依赖。

为最小化误差函数，需要计算 $E(\mathbf{w})$ 对 $\mathbf{w}$ 各分量的导数。这些导数可通过标准反向传播算法求得，只需先得到误差对各输出单元激活值的导数（即每个模式、每个输出单元的误差信号 δ ），然后按常规方式反向传播至隐单元，即可得到误差函数对权重的导数。由于误差函数 (5.153) 是对所有训练样本求和的形式，我们可以先针对单个模式 n 计算导数，再对所有模式求和得到总的 E 的导数。

由于涉及混合分布，方便地将混合系数 $\pi_k(\mathbf{x})$ 视为依赖于 $\mathbf{x}$ 的先验概率，并引入给定目标数据后的后验概率

$$\gamma_k(\mathbf{t} | \mathbf{x}) = \frac{\pi_k \mathcal{N}_{nk}}{\sum_{l=1}^K \pi_l \mathcal{N}_{nl}} \quad (5.154)$$

其中 $\mathcal{N}_{nk} \triangleq \mathcal{N}(\mathbf{t}_n | \mu_k(\mathbf{x}_n), \sigma_k^2(\mathbf{x}_n))$ 。

对控制混合系数的网络输出激活值的导数为

$$\frac{\partial E_n}{\partial a_k^\pi} = \pi_k - \gamma_k \quad (5.155)$$

对控制分量均值的输出激活值的导数为

$$\frac{\partial E_n}{\partial a_{kl}^\mu} = \gamma_k \left\{ \frac{\mu_{kl} - t_l}{\sigma_k^2} \right\} \quad (5.156)$$


对控制分量方差的输出激活值的导数为

$$\frac{\partial E_n}{\partial a_k^\sigma} = -\gamma_k \left\{ \frac{\|\mathbf{t} - \mu_k\|^2}{\sigma_k^3} - \frac{1}{\sigma_k} \right\} \quad (5.157)$$

我们回到图 5.19 所示的逆问题玩具例子来展示混合密度网络的效果。混合系数 $\pi_k(x)$ 、均值 $\mu_k(x)$ 以及条件密度 $p(t | x)$ 的等高线图如图 5.21 所示。神经网络的输出（即混合模型参数）必然是输入变量的连续单值函数。然而从图 5.21(c) 可以看到，通过调节混合系数 $\pi_k(\mathbf{x})$ 的大小，模型能够在某些 x 值处产生单峰的条件密度，而在另一些 x 值处产生三峰的条件密度。

混合密度网络训练完成后，对于任意给定的输入向量 $\mathbf{x}$ ，即可预测目标数据的条件密度函数 $p(\mathbf{t} | \mathbf{x})$ 。这一条件密度完整描述了数据的生成过程（就预测输出向量而言）。

图 5.21 (a) 将图 5.19 所示数据训练得到的混合密度网络中三组核函数的混合系数 $\pi_k(x)$ 绘制为随 x 变化的函数。该模型包含三个高斯成分，并使用一个两层的多层感知机，隐藏层有五个使用“tanh”激活函数的单元，输出层有九个输出（对应三组高斯的均值、三组方差以及三个混合系数）。当 x 取值较小或较大时，目标数据的条件概率密度为单峰，此时只有一个核的先验概率较高；而在中间区域，目标数据的条件概率密度为三峰，三个混合系数取值接近。(b) 三个均值函数 $\mu_k(x)$ 的绘图，颜色编码方式与混合系数相同。(c) 对同一混合密度网络绘制目标数据对应条件概率密度的等高线图。(d) 条件密度的近似条件众数绘图（红点）。



根据具体应用需求，我们可以从中进一步计算感兴趣的量。最简单的是条件均值，即目标数据的条件期望

$$\mathbb{E}[\mathbf{t} | \mathbf{x}] = \int \mathbf{t} p(\mathbf{t} | \mathbf{x}) d\mathbf{t} = \sum_{k=1}^K \pi_k(\mathbf{x}) \boldsymbol{\mu}_k(\mathbf{x}) \quad (5.158)$$

其中用到了 (5.148)。由于传统最小二乘训练的网络实际上是在逼近条件均值，因此混合密度网络在混合系数退化为单一分量时可以完全退化为普通最小二乘结果。当然，正如我们已经指出的，对于多峰分布，条件均值的信息量非常有限。

我们可以类似地计算条件密度围绕条件均值的方差，得到

$$s^2(\mathbf{x}) = \mathbb{E} [\|\mathbf{t} - \mathbb{E}[\mathbf{t} | \mathbf{x}]\|^2 | \mathbf{x}] \quad (5.159)$$

$$= \sum_{k=1}^K \pi_k(\mathbf{x}) \left\{ \sigma_k^2(\mathbf{x}) + \left\| \boldsymbol{\mu}_k(\mathbf{x}) - \sum_{l=1}^K \pi_l(\mathbf{x}) \boldsymbol{\mu}_l(\mathbf{x}) \right\|^2 \right\} \quad (5.160)$$

其中用到了 (5.148) 和 (5.158)。这比普通最小二乘的结果更一般，因为方差本身也是输入 $\mathbf{x}$ 的函数。

我们已经看到，对于多峰分布，条件均值可能给出非常差的表示。例如，在控制图 5.18 所示的简单机器人臂时，为了使末端执行器到达指定位置，我们必须从两个可能的关节角度配置中选择一个，而这两个解的平均值本身并不是一个合法解。在这类情形下，条件众数（conditional mode）往往更有价值。由于混合密度网络的条件众数没有简单的解析解，需要数值迭代求解。一个简单的替代方案是对每个 $\mathbf{x}$ 值取混合系数最大的那个高斯分量的均值。这种做法在玩具数据集上的结果如图 5.21(d) 所示。

5.7 贝叶斯神经网络

到目前为止，我们对神经网络的讨论主要集中于使用最大似然来确定网络参数（权重和偏置）。正则化的最大似然可以解释为 MAP（最大后验）方法，其中正则化项可视为参数先验分布的对数。然而，在完全的贝叶斯处理中，为了进行预测，我们需要对参数分布进行边缘化（即积分）。

在 3.3 节中，我们针对高斯噪声假设下的简单线性回归模型开发了贝叶斯解法。我们看到，后验分布是高斯的，可以精确计算，预测分布也可以得到闭式解。但对于多层神经网络，由于网络函数对参数的高度非线性依赖，精确的贝叶斯处理已不再可能。事实上，后验分布的对数是非凸的，对应误差函数的多个局部极小值。

变分推断技术（将在第 10 章讨论）已被应用于贝叶斯神经网络，例如使用因子化高斯近似后验分布（Hinton and van Camp, 1993），或使用全协方差高斯（Barber and Bishop, 1998a; Barber and Bishop, 1998b）。然而，最完整的处理方式基于拉普拉斯近似（MacKay, 1992c; MacKay, 1992b），这也是本节讨论的基础。我们将用一个以真实后验众数为中心的高斯分布来近似后验分布。此外，我们假设该高斯的协方差很小，使得在后验概率显著不为零的参数空间区域内，网络函数对参数近似线性。在上述两个近似下，我们得到的模型将类似于前面章节讨论的线性回归和分类模型，从而可以直接利用那里的结果。随后，我们可以使用证据框架（evidence framework）为超参数提供点估计，并比较不同模型（例如具有不同隐单元数的网络）。我们首先讨论回归情形，随后再说明解决分类任务所需的修改。

5.7.1 后验参数分布

考虑从输入向量 $\mathbf{x}$ 预测单个连续目标变量 t 的问题（向多个目标的扩展是直观的）。我们假设条件分布 $p(t | \mathbf{x})$ 为高斯分布，其均值由神经网络模型输出 $y(\mathbf{x}, \mathbf{w})$ 给出，精度（方差的倒数）为 β

$$p(t | \mathbf{x}, \mathbf{w}, \beta) = \mathcal{N}(t | y(\mathbf{x}, \mathbf{w}), \beta^{-1}). \quad (5.161)$$

同样，对权重 $\mathbf{w}$ 选择零均值各向同性高斯先验

$$p(\mathbf{w} | \alpha) = \mathcal{N}(\mathbf{w} | \mathbf{0}, \alpha^{-1}\mathbf{I}). \quad (5.162)$$

对于 N 个独立同分布观测数据 $\mathbf{x}_1, \dots, \mathbf{x}_N$ 及其对应目标值 $\mathcal{D} = \{t_1, \dots, t_N\}$ ，似然函数为

$$p(\mathcal{D} | \mathbf{w}, \beta) = \prod_{n=1}^N \mathcal{N}(t_n | y(\mathbf{x}_n, \mathbf{w}), \beta^{-1}) \quad (5.163)$$

于是后验分布为

$$p(\mathbf{w} | \mathcal{D}, \alpha, \beta) \propto p(\mathbf{w} | \alpha) p(\mathcal{D} | \mathbf{w}, \beta). \quad (5.164)$$

由于 $y(\mathbf{x}, \mathbf{w})$ 对 $\mathbf{w}$ 的高度非线性依赖，该后验分布是非高斯的。

我们使用拉普拉斯近似（Laplace approximation）来得到后验的高斯近似。首先需找到后验的一个（局部）众数，这需要通过迭代数值优化实现。通常更方便的是最大化

后验的对数

$$\ln p(\mathbf{w} | \mathcal{D}) = -\frac{\alpha}{2} \mathbf{w}^T \mathbf{w} - \frac{\beta}{2} \sum_{n=1}^N \{y(\mathbf{x}_n, \mathbf{w}) - t_n\}^2 + \text{const} \quad (5.165)$$

这正是带权重衰减的正则化平方和误差函数。暂时固定 α 和 β ，我们可以使用标准非线性优化算法（如共轭梯度）找到后验众数 $\mathbf{w}_{\text{MAP}}$ ，其中所需导数通过反向传播计算。

找到众数 $\mathbf{w}_{\text{MAP}}$ 后，通过计算负对数后验的二阶导数矩阵建立局部高斯近似。由 (5.165) 可得

$$\mathbf{A} = -\nabla \nabla \ln p(\mathbf{w} | \mathcal{D}, \alpha, \beta) = \alpha \mathbf{I} + \beta \mathbf{H} \quad (5.166)$$

其中 $\mathbf{H}$ 是平方和误差函数关于权重 $\mathbf{w}$ 各分量的黑塞矩阵（计算与近似方法见 5.4 节）。相应的后验高斯近似为（见 4.134 式）

$$q(\mathbf{w} | \mathcal{D}) = \mathcal{N}(\mathbf{w} | \mathbf{w}_{\text{MAP}}, \mathbf{A}^{-1}). \quad (5.167)$$

同样，预测分布通过对该后验分布进行边缘化得到

$$p(t | \mathbf{x}, \mathcal{D}) = \int p(t | \mathbf{x}, \mathbf{w}) q(\mathbf{w} | \mathcal{D}) d\mathbf{w} \quad (5.168)$$

即使使用了后验的高斯近似，由于网络函数 $y(\mathbf{x}, \mathbf{w})$ 对 $\mathbf{w}$ 的非线性，这一积分仍然无法解析求解。为取得进展，我们现在假设后验分布的方差很小，相对于 $y(\mathbf{x}, \mathbf{w})$ 显著变化的 $\mathbf{w}$ 特征尺度而言可忽略。这允许我们将网络函数在 $\mathbf{w}_{\text{MAP}}$ 附近进行泰勒展开，仅保留线性项：

$$y(\mathbf{x}, \mathbf{w}) \simeq y(\mathbf{x}, \mathbf{w}_{\text{MAP}}) + \mathbf{g}^T (\mathbf{w} - \mathbf{w}_{\text{MAP}}) \quad (5.169)$$

其中定义了

$$\mathbf{g} = \nabla_{\mathbf{w}} y(\mathbf{x}, \mathbf{w})|_{\mathbf{w}=\mathbf{w}_{\text{MAP}}} . \quad (5.170)$$

在此近似下，我们得到一个线性-高斯模型： $p(\mathbf{w})$ 为高斯， $p(t | \mathbf{w})$ 的均值是 $\mathbf{w}$ 的线性函数

$$p(t | \mathbf{x}, \mathbf{w}, \beta) \simeq \mathcal{N}(t | y(\mathbf{x}, \mathbf{w}_{\text{MAP}}) + \mathbf{g}^T (\mathbf{w} - \mathbf{w}_{\text{MAP}}), \beta^{-1}). \quad (5.171)$$

于是可直接使用线性-高斯模型的通用结果 (2.115)，得到预测分布

$$p(t | \mathbf{x}, \mathcal{D}, \alpha, \beta) = \mathcal{N}(t | y(\mathbf{x}, \mathbf{w}_{\text{MAP}}), \sigma^2(\mathbf{x})) \quad (5.172)$$

其中依赖输入的方差为

$$\sigma^2(\mathbf{x}) = \beta^{-1} + \mathbf{g}^T \mathbf{A}^{-1} \mathbf{g}. \quad (5.173)$$

可见，预测分布是高斯的，其均值正是将参数设为 MAP 值的网络输出 $y(\mathbf{x}, \mathbf{w}_{\text{MAP}})$ 。方差包含两部分：第一项来自目标变量的固有噪声，第二项是依赖 $\mathbf{x}$ 的不确定性，反映了模型参数 $\mathbf{w}$ 的不确定性对插值函数的影响。这与线性回归模型的预测分布 (3.58)-(3.59) 完全对应。

5.7.2 超参数优化

到目前为止，我们假设超参数 α 和 β 是已知固定的。我们可以利用 3.5 节介绍的证据框架，结合拉普拉斯近似得到的高斯后验，获得一个实用的超参数选择方法。

超参数的边缘似然（证据）通过对网络权重积分得到

$$p(\mathcal{D} | \alpha, \beta) = \int p(\mathcal{D} | \mathbf{w}, \beta) p(\mathbf{w} | \alpha) d\mathbf{w} \quad (5.174)$$

利用拉普拉斯近似结果 (4.135) 容易求得，取对数后

$$\ln p(\mathcal{D} | \alpha, \beta) \simeq -E(\mathbf{w}_{\text{MAP}}) - \frac{1}{2} \ln |\mathbf{A}| + \frac{W}{2} \ln \alpha + \frac{N}{2} \ln \beta - \frac{N}{2} \ln(2\pi) \quad (5.175)$$

其中 W 是 $\mathbf{w}$ 的总参数个数，正则化误差函数定义为

$$E(\mathbf{w}_{\text{MAP}}) = \frac{\beta}{2} \sum_{n=1}^N \{y(\mathbf{x}_n, \mathbf{w}_{\text{MAP}}) - t_n\}^2 + \frac{\alpha}{2} \mathbf{w}_{\text{MAP}}^T \mathbf{w}_{\text{MAP}}. \quad (5.176)$$

形式与线性回归模型的对应结果 (3.86) 完全相同。

在边缘似然框架下，通过最大化 $\ln p(\mathcal{D} | \alpha, \beta)$ 对 α, β 进行点估计。先对 α 最大化，仿照 3.5.2 节线性回归情形，首先定义特征值方程

$$\beta \mathbf{H} \mathbf{u}_i = \lambda_i \mathbf{u}_i \quad (5.177)$$

其中 $\mathbf{H}$ 为在 $\mathbf{w} = \mathbf{w}_{\text{MAP}}$ 处计算的平方和误差黑塞矩阵。仿照 (3.92)，得到

$$\alpha = \frac{\gamma}{\mathbf{w}_{\text{MAP}}^T \mathbf{w}_{\text{MAP}}} \quad (5.178)$$

其中有效参数个数 γ 定义为

$$\gamma = \sum_{i=1}^W \frac{\lambda_i}{\alpha + \lambda_i}. \quad (5.179)$$

在线性回归中此式是精确的；但对非线性神经网络，由于改变 α 会导致 $\mathbf{H}$ 变化，从而特征值 λ_i 也变化，这里忽略了 λ_i 对 α 的导数项。

类似地，对 β 最大化证据得到重估计公式（仿 (3.95)）

$$\frac{1}{\beta} = \frac{1}{N - \gamma} \sum_{n=1}^N \{y(\mathbf{x}_n, \mathbf{w}_{\text{MAP}}) - t_n\}^2. \quad (5.180)$$

与线性模型一样，需要在超参数 α, β 的重估计与后验分布更新之间交替进行。但神经网络后验的多峰性使得情况更复杂： $\mathbf{w}_{\text{MAP}}$ 的解依赖于权重初始化。由隐单元的置换和符号翻转对称性导致的等价解对预测完全相同，无关紧要；但也可能存在非等价解，导致优化后的超参数值不同。

为比较不同模型（如不同隐单元数的网络），需评估模型证据 $p(\mathcal{D})$ 。最简单的方法是将迭代优化得到的 α, β 代入 (5.175)。更精确的做法是对 α, β 再做边缘化，也使用高斯近似（MacKay, 1992c; Bishop, 1995a）。两种方法都需要计算黑塞矩阵的行列式 $|\mathbf{A}|$ ，这在实践中较困难，因为行列式对小特征值非常敏感，而小特征值往往难以精确计算。

拉普拉斯近似基于后验权重分布众数附近的局部二次展开。我们在 5.1.1 节已看到，双层网络的任意众数都属于一个包含 $M!2^M$ 个等价众数（ M 为隐单元数）的集合，它们由置换和符号翻转对称性产生。在比较不同隐单元数的网络时，可通过将证据乘以因子 $M!2^M$ 来考虑这种对称性。

5.7.3 贝叶斯神经网络用于分类

到目前为止，我们使用拉普拉斯近似对神经网络回归模型进行了贝叶斯处理。下面讨论将其应用于分类时需要做的修改。这里考虑单 logistic sigmoid 输出的二分类网络，向多类 softmax 输出的扩展是直观的。我们将大量借鉴 4.5 节线性分类模型的对应结果，建议读者先熟悉该节内容。

该模型的对数似然函数为

$$\ln p(\mathcal{D} | \mathbf{w}) = \sum_{n=1}^N \{t_n \ln y_n + (1 - t_n) \ln(1 - y_n)\} \quad (5.181)$$

其中 $t_n \in \{0, 1\}$, $y_n \triangleq y(\mathbf{x}_n, \mathbf{w})$ 。注意这里没有噪声超参数 β ，因为假设标签完全正确。先验仍采用各向同性高斯 (5.162)。

应用拉普拉斯框架的第一步是初始化超参数 α ，然后通过最大化对数后验确定权重向量，等价于最小化正则化误差函数

$$E(\mathbf{w}) = -\ln p(\mathcal{D} | \mathbf{w}) + \frac{\alpha}{2} \mathbf{w}^T \mathbf{w} \quad (5.182)$$

可用反向传播结合标准优化算法实现（见 5.3 节）。

得到权重向量 $\mathbf{w}_{\text{MAP}}$ 后，接下来计算负对数似然函数的二阶导数组成的黑塞矩阵 $\mathbf{H}$ ，可用 5.4.5 节的精确方法或 (5.85) 的外积近似。负对数后验的二阶导数仍可写成 (5.166) 形式，后验的高斯近似仍为 (5.167)。

为优化超参数 α ，再次最大化边缘似然，易证其形式为

$$\ln p(\mathcal{D} | \alpha) \simeq -E(\mathbf{w}_{\text{MAP}}) - \frac{1}{2} \ln |\mathbf{A}| + \frac{W}{2} \ln \alpha + \text{const} \quad (5.183)$$

其中正则化误差函数定义为

$$E(\mathbf{w}_{\text{MAP}}) = -\sum_{n=1}^N \{t_n \ln y_n + (1 - t_n) \ln(1 - y_n)\} + \frac{\alpha}{2} \mathbf{w}_{\text{MAP}}^T \mathbf{w}_{\text{MAP}} \quad (5.184)$$


$y_n \equiv y(\mathbf{x}_n, \mathbf{w}_{\text{MAP}})$ 。对 α 最大化再次得到重估计公式 (5.178)。

使用证据过程确定 α 的例子见图 5.22（附录 A 的合成二维数据）。

最后需要预测分布，仍由 (5.168) 定义。由于网络函数非线性，积分仍不可解。最简单的近似是假设后验很窄，直接取

$$p(t | \mathbf{x}, \mathcal{D}) \simeq p(t | \mathbf{x}, \mathbf{w}_{\text{MAP}}). \quad (5.185)$$

图 5.22 证据框架在一个合成的二分类数据集上的应用示意图。绿色曲线表示最优决策边界，黑色曲线表示使用最大似然方法训练的具有 8 个隐藏单元的两层网络的拟合结果，红色曲线表示在加入正则项并通过证据方法从初始值 $\alpha = 0$ 开始优化 α 后得到的结果。可以看到，证据方法显著减少了网络的过拟合。



为改进此近似，可考虑后验方差。此时若仍像回归情形那样对网络输出做线性近似不合适，因为 logistic sigmoid 输出被限制在 $(0,1)$ 。改为对输出单元的激活值做线性近似

$$a(\mathbf{x}, \mathbf{w}) \simeq a_{\text{MAP}}(\mathbf{x}) + \mathbf{b}^T(\mathbf{w} - \mathbf{w}_{\text{MAP}}) \quad (5.186)$$

其中 $a_{\text{MAP}}(\mathbf{x}) = a(\mathbf{x}, \mathbf{w}_{\text{MAP}})$ ，向量 $\mathbf{b} \equiv \nabla a(\mathbf{x}, \mathbf{w}_{\text{MAP}})$ 可通过反向传播得到。

由于我们现在对权重 $\mathbf{w}$ 的后验分布有了高斯近似，并且激活值 a 是 $\mathbf{w}$ 的线性函数，我们可以直接利用 4.5.2 节的结果。由网络权重分布诱导的输出单元激活值分布为

$$p(a | \mathbf{x}, \mathcal{D}) = \int \delta(a - a_{\text{MAP}}(\mathbf{x}) - \mathbf{b}^T(\mathbf{x})(\mathbf{w} - \mathbf{w}_{\text{MAP}})) q(\mathbf{w} | \mathcal{D}) d\mathbf{w} \quad (5.187)$$

其中 $q(\mathbf{w} | \mathcal{D})$ 是由 (5.167) 给出的后验分布的高斯近似。根据 4.5.2 节，这个分布是高斯分布，其均值为 $a_{\text{MAP}} \equiv a(\mathbf{x}, \mathbf{w}_{\text{MAP}})$ ，方差为

$$\sigma_a^2(\mathbf{x}) = \mathbf{b}^T(\mathbf{x}) \mathbf{A}^{-1} \mathbf{b}(\mathbf{x}). \quad (5.188)$$




图 5.23 一个关于贝叶斯神经网络的拉普拉斯近似示意图，该网络具有 8 个隐藏单元，使用 tanh 激活函数，并包含一个 logistic-sigmoid 输出单元。权重参数是通过缩放共轭梯度方法得到的，超参数 α 则通过证据框架进行优化。左图展示了使用基于参数点估计 w_{map} 的简单近似 (5.185) 的结果，其中绿色曲线表示 $y = 0.5$ 的决策边界，其他等高线分别对应输出概率 $y = 0.1, 0.3, 0.7$ 和 0.9 。右图则展示了使用 (5.190) 得到的相应结果。请注意，积分（边缘化）的效果是将等高线展开，并使预测更加不确定，因此对于每个输入点 x ，后验概率会向 0.5 移动，而 $y = 0.5$ 的等高线本身则不受影响。

最终预测分布需对 a 边缘化

$$p(t = 1 | \mathbf{x}, \mathcal{D}) = \int \sigma(a) p(a | \mathbf{x}, \mathcal{D}) da. \quad (5.189)$$

高斯与 logistic sigmoid 的卷积无解析解，故采用近似 (4.153)，得到

$$p(t = 1 \mid \mathbf{x}, \mathcal{D}) \simeq \sigma \left(\kappa(\sigma_a^2) a_{\text{MAP}}(\mathbf{x}) \right) \quad (5.190)$$

其中 $\kappa(\cdot)$ 由 (4.154) 定义。注意 σ_a^2 和 $\mathbf{b}$ 均依赖于 $\mathbf{x}$ 。

图 5.23 展示了该框架在附录 A 所述合成分类数据集上的应用示例。

6 核方法

在第三章和第四章中，我们考虑了用于回归和分类的线性参数模型，其中从输入 $\mathbf{x}$ 到输出 y 的映射 $y(\mathbf{x}, \mathbf{w})$ 的形式由自适应参数向量 $\mathbf{w}$ 控制。在学习阶段，使用一组训练数据要么得到参数向量的点估计，要么确定该向量的后验分布。随后丢弃训练数据，对新输入的预测完全基于学习得到的参数向量 $\mathbf{w}$ 。这种方法也用于诸如神经网络之类的非线性参数模型。

然而，有一类模式识别技术会保留训练数据点（或其子集），并在预测阶段也使用它们。例如，Parzen 概率密度模型由以每个训练数据点为中心的一组“核”函数的线性组合构成。同样，在 2.5.2 节我们介绍了一种称为最近邻的简单分类技术，它将每个新的测试向量分配与训练集中最近样本相同的标签。这些都是基于记忆的方法，需要存储整个训练集以便对未来数据点进行预测。它们通常需要定义一个度量来衡量输入空间中任意两个向量的相似性，一般“训练”很快，但在对测试数据点进行预测时较慢。

许多线性参数模型可以被重新表述为等价的“对偶表示”（dual representation），在这种表示中，预测同样基于在训练数据点处求值的核函数的线性组合。正如我们将要看到的，对于基于固定非线性特征空间映射 $\phi(\mathbf{x})$ 的模型，核函数由下式给出

$$k(\mathbf{x}, \mathbf{x}') = \phi(\mathbf{x})^T \phi(\mathbf{x}') \quad (6.1)$$

根据这个定义，核是其自变量的对称函数，因此 $k(\mathbf{x}, \mathbf{x}') = k(\mathbf{x}', \mathbf{x})$ 。核概念由 Aizerman 等（1964）在势函数方法（method of potential functions）的背景下引入模式识别领域，该方法因与静电学的类比而得名。尽管多年来被忽视，但它被 Boser 等（1992）在大大间隔分类器（large-margin classifiers）的背景下重新引入机器学习，从而产生了支持向量机技术。此后，这一主题无论在理论还是应用方面都受到了广泛关注。其中最重要的进展之一是将核扩展到处理符号对象，从而极大地扩展了可以解决的问题范围。

最简单的核函数例子是通过考虑特征空间的恒等映射（式 6.1），即 $\phi(\mathbf{x}) = \mathbf{x}$ ，此时 $k(\mathbf{x}, \mathbf{x}') = \mathbf{x}^T \mathbf{x}'$ 。我们将此称为线性核。

将核表述为特征空间内积的概念，使我们能够通过使用核技巧（kernel trick，也称为核替换）来构建许多著名算法的有趣扩展。其基本思想是：如果某个算法被表述为输入向量 $\mathbf{x}$ 仅以标量积的形式出现，那么我们就可以用其他选择的核来替换该标量积。例如，核替换技术可以应用于主成分分析，从而开发出 PCA 的非线性变体（Schölkopf 等，1998）。核替换的其他例子包括最近邻分类器和核 Fisher 判别式（Mika 等，1999；Roth 和 Steinhage，2000；Baudat 和 Anouar，2000）。

常见的核函数形式有很多，我们将在本章遇到几个例子。许多核函数具有仅依赖于自变量之差的性质，即 $k(\mathbf{x}, \mathbf{x}') = k(\mathbf{x} - \mathbf{x}')$ ，这类核被称为平稳核（stationary kernels），因为它们对输入空间中的平移不变。更进一步的特例是齐次核（homogeneous kernels），也称为径向基函数（radial basis functions），它们仅依赖于自变量之间距离（通常为欧氏距离）的模，即 $k(\mathbf{x}, \mathbf{x}') = k(\|\mathbf{x} - \mathbf{x}'\|)$ 。

关于核方法的近期教科书，可参阅 Schölkopf 和 Smola（2002）、Herbrich（2002）以

及 Shawe-Taylor 和 Cristianini (2004)。

6.1 对偶表示

许多用于回归和分类的线性模型都可以重新表述为一种对偶表示，其中核函数会自然出现。当我们在下一章讨论支持向量机时，这一概念将发挥重要作用。这里我们考虑一个线性回归模型，其参数通过最小化一个正则化的平方和误差函数来确定，该函数为

$$J(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N \{\mathbf{w}^T \phi(\mathbf{x}_n) - t_n\}^2 + \frac{\lambda}{2} \mathbf{w}^T \mathbf{w} \quad (6.2)$$

其中 $\lambda \geq 0$ 。如果我们将 $J(\mathbf{w})$ 关于 $\mathbf{w}$ 的梯度设为零，可以看到 $\mathbf{w}$ 的解呈现为向量 $\phi(\mathbf{x}_n)$ 的线性组合，其系数是 $\mathbf{w}$ 的函数，形式为

$$\mathbf{w} = -\frac{1}{\lambda} \sum_{n=1}^N \{\mathbf{w}^T \phi(\mathbf{x}_n) - t_n\} \phi(\mathbf{x}_n) = \sum_{n=1}^N a_n \phi(\mathbf{x}_n) = \Phi^T \mathbf{a} \quad (6.3)$$

其中 Φ 是设计矩阵，其第 n^{th} 行为 $\phi(\mathbf{x}_n)^T$ 。这里向量 $\mathbf{a} = (a_1, \dots, a_N)^T$ ，并且我们定义

$$a_n = -\frac{1}{\lambda} \{\mathbf{w}^T \phi(\mathbf{x}_n) - t_n\}. \quad (6.4)$$

现在，我们不再使用参数向量 $\mathbf{w}$ ，而是可以用参数向量 $\mathbf{a}$ 来重新表述最小二乘算法，从而得到一个对偶表示。如果将 $\mathbf{w} = \Phi^T \mathbf{a}$ 代入 $J(\mathbf{w})$ ，我们得到

$$J(\mathbf{a}) = \frac{1}{2} \mathbf{a}^T \Phi \Phi^T \Phi \Phi^T \mathbf{a} - \mathbf{a}^T \Phi \Phi^T \mathbf{t} + \frac{1}{2} \mathbf{t}^T \mathbf{t} + \frac{\lambda}{2} \mathbf{a}^T \Phi \Phi^T \mathbf{a} \quad (6.5)$$

其中 $\mathbf{t} = (t_1, \dots, t_N)^T$ 。我们现在定义 Gram 矩阵 $\mathbf{K} = \Phi \Phi^T$ ，它是一个 $N \times N$ 的对称矩阵，其元素为

$$K_{nm} = \phi(\mathbf{x}_n)^T \phi(\mathbf{x}_m) = k(\mathbf{x}_n, \mathbf{x}_m) \quad (6.6)$$

其中我们引入了由式 (6.1) 定义的核函数 $k(\mathbf{x}, \mathbf{x}')$ 。用 Gram 矩阵表示时，平方和误差函数可以写为

$$J(\mathbf{a}) = \frac{1}{2} \mathbf{a}^T \mathbf{K} \mathbf{K} \mathbf{a} - \mathbf{a}^T \mathbf{K} \mathbf{t} + \frac{1}{2} \mathbf{t}^T \mathbf{t} + \frac{\lambda}{2} \mathbf{a}^T \mathbf{K} \mathbf{a}. \quad (6.7)$$

将 $J(\mathbf{a})$ 关于 $\mathbf{a}$ 的梯度设为零，我们得到如下解

$$\mathbf{a} = (\mathbf{K} + \lambda \mathbf{I}_N)^{-1} \mathbf{t}. \quad (6.8)$$

如果我们将其代回线性回归模型，对于一个新的输入 $\mathbf{x}$ 可以得到如下预测

$$y(\mathbf{x}) = \mathbf{w}^T \phi(\mathbf{x}) = \mathbf{a}^T \Phi \phi(\mathbf{x}) = \mathbf{k}(\mathbf{x})^T (\mathbf{K} + \lambda \mathbf{I}_N)^{-1} \mathbf{t} \quad (6.9)$$

其中我们将向量 $\mathbf{k}(\mathbf{x})$ 定义为其元素满足 $k_n(\mathbf{x}) = k(\mathbf{x}_n, \mathbf{x})$ 。因此我们看到，对偶形式使得最小二乘问题的解能够完全用核函数 $k(\mathbf{x}, \mathbf{x}')$ 来表示。这被称为对偶形式，因为注意到 $\mathbf{a}$ 的解可以表示为 $\phi(\mathbf{x})$ 的各元素的线性组合，我们便可以恢复原始的参数向量

$\mathbf{w}$ 的表述。注意在 $\mathbf{x}$ 处的预测是由训练集中目标值的线性组合给出的。事实上，在第 3.3.3 节我们已经用稍微不同的符号推导过这个结果。

在对偶表示中，我们通过求一个 $N \times N$ 矩阵的逆来确定参数向量 $\mathbf{a}$ ，而在原始参数空间的表示中，我们需要求一个 $M \times M$ 矩阵的逆来确定 $\mathbf{w}$ 。由于 N 通常远大于 M ，对偶表示看起来似乎并不特别有用。然而，对偶表示的优势在于，它完全以核函数 $k(\mathbf{x}, \mathbf{x}')$ 的形式表达。这样我们就可以直接基于核进行工作，而无需显式引入特征向量 $\phi(\mathbf{x})$ ，这使我们能够隐式地使用高维甚至无限维的特征空间。

基于 Gram 矩阵存在对偶表示是许多线性模型的性质，包括感知机。在第 6.4 节中，我们将建立概率线性回归模型与高斯过程技术之间的对偶性。在第 7 章讨论支持向量机时，对偶性也将发挥重要作用。

6.2 构造核函数




图 6.1 从一组对应的基函数出发构造核函数的示意图。每一列中，下方的图展示根据 (6.10) 定义的核函数 $k(\mathbf{x}, \mathbf{x}')$ ，作为 $\mathbf{x}$ 的函数并取 $\mathbf{x}'=0$ ；上方的图展示相应的基函数，分别由多项式（左列）、“高斯函数”（中列）以及逻辑 Sigmoid 函数（右列）给出。

为了利用核替换，我们需要能够构造有效的核函数。一种方法是选择一个特征空间映射 $\phi(\mathbf{x})$ ，然后用它来找到对应的核函数，如图 6.1 所示。这里针对一维输入空间，核函数被定义为

$$k(\mathbf{x}, \mathbf{x}') = \phi(\mathbf{x})^T \phi(\mathbf{x}') = \sum_{i=1}^M \phi_i(\mathbf{x}) \phi_i(\mathbf{x}') \quad (6.10)$$

其中 $\phi_i(\mathbf{x})$ 是基函数。

另一种方法是直接构造核函数。在这种情况下，我们必须确保所选择的函数是一个有效的核，也就是说，它对应于某个（可能是无限维的）特征空间中的一个标量积。作为一个简单示例，考虑如下给出的核函数

$$k(\mathbf{x}, \mathbf{z}) = (\mathbf{x}^T \mathbf{z})^2. \quad (6.11)$$

如果我们取二维输入空间 $\mathbf{x} = (x_1, x_2)$ 的特殊情况，那么我们可以将各项展开，从而识别出对应的非线性特征映射

$$\begin{aligned}
 k(\mathbf{x}, \mathbf{z}) &= (\mathbf{x}^T \mathbf{z})^2 = (x_1 z_1 + x_2 z_2)^2 \\
 &= x_1^2 z_1^2 + 2x_1 z_1 x_2 z_2 + x_2^2 z_2^2 \\
 &= \begin{pmatrix} x_1^2, \sqrt{2}x_1 x_2, x_2^2 \end{pmatrix} \begin{pmatrix} z_1^2, \sqrt{2}z_1 z_2, z_2^2 \end{pmatrix}^T \\
 &= \phi(\mathbf{x})^T \phi(\mathbf{z})
 \end{aligned} \tag{6.12}$$

我们看到特征映射的形式为 $\phi(\mathbf{x}) = (x_1^2, \sqrt{2}x_1 x_2, x_2^2)^T$ ，因此包含了所有可能的二阶项，并具有特定的加权关系。

更一般地，我们需要一种简单的方法来判断一个函数是否是有效核，而无需显式构造函数 $\phi(x)$ 。一个函数 $k(\mathbf{x}, \mathbf{x}')$ 成为有效核的充要条件（Shawe-Taylor 和 Cristianini, 2004）是，其 Gram 矩阵 $\mathbf{K}$ （其元素为 $k(\mathbf{x}_n, \mathbf{x}_m)$ ）对所有可能的点集 $\{\mathbf{x}_n\}$ 都应为正半定矩阵。注意，正半定矩阵与元素全部非负的矩阵并不是同一回事。

构造新核的一种强大技术是用较简单的核作为构件来组合它们。可以利用以下性质来实现：

构造新核的技巧。给定有效核 $k_1(\mathbf{x}, \mathbf{x}')$ 和 $k_2(\mathbf{x}, \mathbf{x}')$ ，以下新核也都是有效的：

构造新核函数的技术。

$$k(\mathbf{x}, \mathbf{x}') = c k_1(\mathbf{x}, \mathbf{x}') \tag{6.13}$$

$$k(\mathbf{x}, \mathbf{x}') = f(\mathbf{x}) k_1(\mathbf{x}, \mathbf{x}') f(\mathbf{x}') \tag{6.14}$$

$$k(\mathbf{x}, \mathbf{x}') = q(k_1(\mathbf{x}, \mathbf{x}')) \tag{6.15}$$

$$k(\mathbf{x}, \mathbf{x}') = \exp(k_1(\mathbf{x}, \mathbf{x}')) \tag{6.16}$$

$$k(\mathbf{x}, \mathbf{x}') = k_1(\mathbf{x}, \mathbf{x}') + k_2(\mathbf{x}, \mathbf{x}') \tag{6.17}$$

$$k(\mathbf{x}, \mathbf{x}') = k_1(\mathbf{x}, \mathbf{x}') k_2(\mathbf{x}, \mathbf{x}') \tag{6.18}$$

$$k(\mathbf{x}, \mathbf{x}') = k_3(\phi(\mathbf{x}), \phi(\mathbf{x}')) \tag{6.19}$$

$$k(\mathbf{x}, \mathbf{x}') = \mathbf{x}^T \mathbf{A} \mathbf{x}' \tag{6.20}$$

$$k(\mathbf{x}, \mathbf{x}') = k_a(\mathbf{x}_a, \mathbf{x}'_a) + k_b(\mathbf{x}_b, \mathbf{x}'_b) \tag{6.21}$$

$$k(\mathbf{x}, \mathbf{x}') = k_a(\mathbf{x}_a, \mathbf{x}'_a) k_b(\mathbf{x}_b, \mathbf{x}'_b) \tag{6.22}$$

其中 $c > 0$ 是常数， $f(\cdot)$ 是任意函数， $q(\cdot)$ 是非负系数的多项式， $\phi(\mathbf{x})$ 是将 $\mathbf{x}$ 映射到 $\mathbb{R}^M$ 的函数， $k_3(\cdot, \cdot)$ 是 $\mathbb{R}^M$ 上的有效核， $\mathbf{A}$ 是对称正半定矩阵， $\mathbf{x}_a$ 和 $\mathbf{x}_b$ 是（不必互不相交的）变量，且 $\mathbf{x} = (\mathbf{x}_a, \mathbf{x}_b)$ ，并且 k_a 与 k_b 是各自空间上的有效核函数。

借助这些性质，我们可以开始构造适用于特定应用的更复杂核函数。我们要求核 $k(\mathbf{x}, \mathbf{x}')$ 是对称且正半定的，并且它能够根据具体应用表达 $\mathbf{x}$ 与 $\mathbf{x}'$ 之间恰当的相似度。这

里我们讨论一些常见的核函数示例。若想进一步了解“核工程”的内容，可参阅 Shawe-Taylor 和 Cristianini (2004)。

我们看到简单的多项式核 $k(\mathbf{x}, \mathbf{x}') = (\mathbf{x}^T \mathbf{x}')^2$ 只包含二次项。如果我们考虑稍作推广的核 $k(\mathbf{x}, \mathbf{x}') = (\mathbf{x}^T \mathbf{x}' + c)^2$ ，其中 $c > 0$ ，那么对应的特征映射 $\phi(\mathbf{x})$ 将包含常数项、一阶项以及二阶项。类似地， $k(\mathbf{x}, \mathbf{x}') = (\mathbf{x}^T \mathbf{x}')^M$ 包含所有 M 阶单项式。例如，如果 $\mathbf{x}$ 和 $\mathbf{x}'$ 是两幅图像，那么该核表示第一幅图像中任意 M 个像素与第二幅图像中任意 M 个像素所有可能乘积的某种加权和。这同样可以推广为包含所有不超过 M 阶的项，即使用 $k(\mathbf{x}, \mathbf{x}') = (\mathbf{x}^T \mathbf{x}' + c)^M$ 且 $c > 0$ 。利用用于组合核的结果 (6.17) 与 (6.18)，我们看到这些都会是有效的核函数。

另一种常用的核具有下列形式

$$k(\mathbf{x}, \mathbf{x}') = \exp(-\|\mathbf{x} - \mathbf{x}'\|^2 / 2\sigma^2) \quad (6.23)$$

通常被称为“高斯”核。然而注意，在这个背景下它并不作为概率密度来解释，因此省略了归一化系数。我们可以通过展开平方项来验证它是一个有效核：

$$\|\mathbf{x} - \mathbf{x}'\|^2 = \mathbf{x}^T \mathbf{x} + (\mathbf{x}')^T \mathbf{x}' - 2\mathbf{x}^T \mathbf{x}' \quad (6.24)$$

从而得到

$$k(\mathbf{x}, \mathbf{x}') = \exp(-\mathbf{x}^T \mathbf{x} / 2\sigma^2) \exp(\mathbf{x}^T \mathbf{x}' / \sigma^2) \exp(-(\mathbf{x}')^T \mathbf{x}' / 2\sigma^2) \quad (6.25)$$

并利用 (6.14) 和 (6.16)，再加上线性核 $k(\mathbf{x}, \mathbf{x}') = \mathbf{x}^T \mathbf{x}'$ 的有效性。注意，对应于高斯核的特征向量具有无限维度。

高斯核并不限于欧氏距离。如果我们在 (6.24) 中进行核替换，将 $\mathbf{x}^T \mathbf{x}'$ 替换为某个非线性核 $\kappa(\mathbf{x}, \mathbf{x}')$ ，便得到

$$k(\mathbf{x}, \mathbf{x}') = \exp \left\{ -\frac{1}{2\sigma^2} (\kappa(\mathbf{x}, \mathbf{x}) + \kappa(\mathbf{x}', \mathbf{x}') - 2\kappa(\mathbf{x}, \mathbf{x}')) \right\} \quad (6.26)$$

核方法的一个重要贡献是可以扩展到符号输入，而非仅限于实数向量。核函数可以定义在图、集合、字符串以及文本文档等多种对象上。例如，考虑一个固定的集合，并定义由所有该集合的子集组成的非向量空间。如果 A_1 和 A_2 是两个这样的子集，那么一个简单的核可以是

$$k(A_1, A_2) = 2^{|A_1 \cap A_2|} \quad (6.27)$$

其中 $A_1 \cap A_2$ 表示集合 A_1 与 A_2 的交集，而 $|A|$ 表示集合 A 中包含的子集的数量。这个核是有效的，因为可以证明它对应某个特征空间中的内积。

一种强有力的构造核的方法基于概率生成模型 (Haussler, 1999)，它使我们能够在判别式任务中应用生成模型。生成模型可以自然地处理缺失数据，而在隐马尔可夫模型的情形下还可处理长度不同的序列。相反，在判别式任务中，判别模型通常会比生成模型表现更好。因此，将这两种方法结合起来具有一定意义 (Lasserre 等, 2006)。一种结合方式是利用生成模型定义一个核，然后在判别式方法中使用该核。

给定一个生成模型 $p(\mathbf{x})$ ，我们可以通过下面的方式定义一个核：

$$k(\mathbf{x}, \mathbf{x}') = p(\mathbf{x}) p(\mathbf{x}') \quad (6.28)$$

这显然是一个有效的核函数，因为我们可以把它解释为由映射 $p(\mathbf{x})$ 定义的一维特征空间中的内积。它表达的含义是：两个输入 $\mathbf{x}$ 和 $\mathbf{x}'$ 若都具有较高概率，则被视为相似。我们可以利用 (6.13) 与 (6.17) 来扩展这一类核，考虑对不同概率分布的乘积求和，并使用正权重系数 $p(i)$ ，得到

$$k(\mathbf{x}, \mathbf{x}') = \sum_i p(\mathbf{x} | i) p(\mathbf{x}' | i) p(i) \quad (6.29)$$

这相当于一个混合分布（差一个乘法常数），其各成分是可分解的，且索引 i 扮演“潜变量”的角色。若两个输入 $\mathbf{x}$ 和 $\mathbf{x}'$ 在多个成分下都具有显著概率，那么对应的核值就会大，从而被视为相似。取无限求和的极限，我们还可以考虑如下形式的核：

$$k(\mathbf{x}, \mathbf{x}') = \int p(\mathbf{x} | \mathbf{z}) p(\mathbf{x}' | \mathbf{z}) p(\mathbf{z}) d\mathbf{z} \quad (6.30)$$

其中 $\mathbf{z}$ 是一个连续潜变量。

现在假设数据由长度为 L 的有序序列组成，因此一次观测为 $\mathbf{X} = \{\mathbf{x}_1, \dots, \mathbf{x}_L\}$ 。处理序列时，一个常用的生成模型是隐马尔可夫模型，它通过对对应的隐藏状态序列 $\mathbf{Z} = \{\mathbf{z}_1, \dots, \mathbf{z}_L\}$ 的边缘化来表达分布 $p(\mathbf{X})$ 。我们可以利用这种方法定义一个度量两个序列 $\mathbf{X}$ 与 $\mathbf{X}'$ 相似性的核函数，将混合表示 (6.29) 推广为

$$k(\mathbf{X}, \mathbf{X}') = \sum_{\mathbf{Z}} p(\mathbf{X} | \mathbf{Z}) p(\mathbf{X}' | \mathbf{Z}) p(\mathbf{Z}) \quad (6.31)$$

这样两个观测序列都是由同一个隐藏序列 $\mathbf{Z}$ 生成的。该模型可以很容易扩展，使其能够比较不同长度的序列。

使用生成模型定义核函数的另一种技术称为 Fisher 核 (Jaakkola 和 Haussler, 1999)。考虑一个参数化生成模型 $p(\mathbf{x} | \boldsymbol{\theta})$ ，其中 $\boldsymbol{\theta}$ 为参数向量。目标是找到一个由生成模型诱导的、用于衡量两个输入向量 $\mathbf{x}$ 与 $\mathbf{x}'$ 相似性的核。Jaakkola 和 Haussler (1999) 考虑关于 $\boldsymbol{\theta}$ 的梯度，其在“特征”空间中形成一个向量，该空间维度与 $\boldsymbol{\theta}$ 的维度相同。特别地，他们考虑 Fisher 得分

$$\mathbf{g}(\boldsymbol{\theta}, \mathbf{x}) = \nabla_{\boldsymbol{\theta}} \ln p(\mathbf{x} | \boldsymbol{\theta}) \quad (6.32)$$

由此 Fisher 核定义为

$$k(\mathbf{x}, \mathbf{x}') = \mathbf{g}(\boldsymbol{\theta}, \mathbf{x})^T \mathbf{F}^{-1} \mathbf{g}(\boldsymbol{\theta}, \mathbf{x}') \quad (6.33)$$

其中 $\mathbf{F}$ 是 Fisher 信息矩阵，定义为

$$\mathbf{F} = \mathbb{E}_{\mathbf{x}} [\mathbf{g}(\boldsymbol{\theta}, \mathbf{x}) \mathbf{g}(\boldsymbol{\theta}, \mathbf{x})^T] \quad (6.34)$$

期望是关于 $p(\mathbf{x} | \boldsymbol{\theta})$ 取的。该结果可以从信息几何的角度进行理解 (Amari, 1998)，信息几何研究模型参数空间的微分几何结构。此处我们只需注意 Fisher 信息矩阵的存在使得该核在密度模型的非线性再参数化 $\boldsymbol{\theta} \rightarrow \boldsymbol{\psi}(\boldsymbol{\theta})$ 下保持不变。

在实际应用中, 精确计算 Fisher 信息矩阵通常不可行。一种做法是简单地用样本均值替代其定义中的期望, 从而得到

$$\mathbf{F} \simeq \frac{1}{N} \sum_{n=1}^N \mathbf{g}(\boldsymbol{\theta}, \mathbf{x}_n) \mathbf{g}(\boldsymbol{\theta}, \mathbf{x}_n)^T. \quad (6.35)$$

这是 Fisher 得分的协方差矩阵, 因此 Fisher 核对应对这些得分进行白化。更简单的方式是直接省略 Fisher 信息矩阵, 从而使用非不变核

$$k(\mathbf{x}, \mathbf{x}') = \mathbf{g}(\boldsymbol{\theta}, \mathbf{x})^T \mathbf{g}(\boldsymbol{\theta}, \mathbf{x}') \quad (6.36)$$

Fisher 核在文档检索中的一个应用由 Hofmann (2000) 给出。最后一个核函数的示例是 sigmoid 核:

$$k(\mathbf{x}, \mathbf{x}') = \tanh(a \mathbf{x}^T \mathbf{x}' + b) \quad (6.37)$$

其 Gram 矩阵一般不是正半定的。然而这种核在实践中仍然被使用过 (Vapnik, 1995), 可能是因为它使诸如支持向量机的核展开在形式上类似于神经网络模型。我们将看到, 当基函数数量趋于无穷时, 带适当先验的贝叶斯神经网络会收敛为一个高斯过程, 从而在神经网络与核方法之间建立更深的联系。

6.3 径向基函数网络

在第 3 章中, 我们讨论了基于固定基函数线性组合的回归模型, 不过当时并未详细讨论这些基函数的具体形式。一种被广泛使用的选择是径向基函数, 它们的特点是每个基函数只依赖于离某个中心 $\boldsymbol{\mu}_j$ 的径向距离 (通常是欧氏距离), 因此 $\phi_j(\mathbf{x}) = h(\|\mathbf{x} - \boldsymbol{\mu}_j\|)$ 。

从历史上看, 径向基函数是为精确函数插值而提出的 (Powell, 1987)。给定一组输入向量 $\{\mathbf{x}_1, \dots, \mathbf{x}_N\}$ 以及对应的目标值 $\{t_1, \dots, t_N\}$, 目标是找到一个光滑函数 $f(\mathbf{x})$, 它能精确拟合每个目标值, 也就是说 $f(\mathbf{x}_n) = t_n$, 对 $n = 1, \dots, N$ 。这种效果可以通过将 $f(\mathbf{x})$ 表示为径向基函数的线性组合实现, 其中每个基函数以每一个数据点为中心:

$$f(\mathbf{x}) = \sum_{n=1}^N w_n h(\|\mathbf{x} - \mathbf{x}_n\|) \quad (6.38)$$

系数 $\{w_n\}$ 通过最小二乘法求得, 并且因为系数数量与约束数量相同, 所以得到的函数能精确拟合所有目标值。然而在模式识别应用中, 目标值通常带有噪声, 精确插值会导致过拟合, 因此并不理想。

径向基函数展开也来自正则化理论 (Poggio and Girosi, 1990; Bishop, 1995a)。对一个带有基于微分算子的正则项的平方误差函数, 其最优解由该算子的格林函数展开给出 (类似于离散矩阵的特征向量), 同样每个格林函数中心位于每个数据点。如果微分算子是各向同性的, 那么其格林函数只依赖于离对应数据点的径向距离。由于正则化项的存在, 此时的解不再精确插值训练数据。

另一种引出径向基函数的方法来自对插值问题的考虑, 当噪声出现在输入变量 (而不是目标变量) 上时 (Webb, 1994; Bishop, 1995a)。如果输入变量 $\mathbf{x}$ 上的噪声由变量 $\boldsymbol{\xi}$

描述，并服从某个分布 $\nu(\boldsymbol{\xi})$ ，则平方误差函数变为

$$E = \frac{1}{2} \sum_{n=1}^N \int \{y(\mathbf{x}_n + \boldsymbol{\xi}) - t_n\}^2 \nu(\boldsymbol{\xi}) d\boldsymbol{\xi} \quad (6.39)$$

利用变分法，我们可以对函数 $f(\mathbf{x})$ 进行优化，从而得到

$$y(\mathbf{x}) = \sum_{n=1}^N t_n h(\mathbf{x} - \mathbf{x}_n) \quad (6.40)$$

其中基函数给出为

$$h(\mathbf{x} - \mathbf{x}_n) = \frac{\nu(\mathbf{x} - \mathbf{x}_n)}{\sum_{n=1}^N \nu(\mathbf{x} - \mathbf{x}_n)} \quad (6.41)$$

我们看到依然是每个数据点对应一个基函数。这被称为 Nadaraya-Watson 模型，并将在 6.3.1 节中从另一角度再次推导。如果噪声分布 $\nu(\xi)$ 是各向同性的，即仅依赖于 $\|\xi\|$ ，那么基函数将是径向的。




图 6.2 左图为一组高斯基函数的图像，右图为对应的归一化基函数的图像。

注意基函数 (6.41) 是归一化的，因此 $\sum_n h(\mathbf{x} - \mathbf{x}_n) = 1$ 对任意 $\mathbf{x}$ 都成立。归一化的效果如图 6.2 所示。在实践中，归一化常被用于避免输入空间的某些区域出现所有基函数都取很小值的情况，因为那将导致预测结果要么很小，要么完全由偏置参数控制。

另一种产生归一化径向基函数展开的情形出现在将核密度估计应用于回归问题时，我们将在 6.3.1 节讨论。

由于这种模型中每个数据点都对应一个基函数，因此当对新数据点进行预测时计算代价较高。因此出现了许多模型 (Broomhead 和 Lowe, 1988; Moody 和 Darken, 1989; Poggio 和 Girosi, 1990)，它们保留径向基函数展开，但基函数数量 M 小于数据点数量 N 。通常，基函数的数量及其中心位置 μ_i 仅基于输入数据 $\{\mathbf{x}_n\}$ 确定。一旦基函数确定后，系数 $\{w_i\}$ 会通过最小二乘法估计，方法如 3.1.1 节所述。

选择基函数中心最简单的方法之一是从数据点中随机抽取一个子集。一个更系统的方法称为正交最小二乘法 (orthogonal least squares) (Chen et al., 1991)。这是一个序贯选择过程，每一步选出的下一个中心是能最大程度减少平方误差的那个数据点。展开系数会在算法过程里一并得到。聚类算法 (例如 K-means) 也常被用于选择基函数中心，这种方法得到的中心不再与训练数据直接重合。

6.3.1 Nadaraya-Watson 模型

在 3.3.3 节中, 我们看到线性回归模型对一个新输入 $\mathbf{x}$ 的预测可以写为训练集目标值的线性组合, 其系数由“等效核”(3.62) 给出, 并满足求和约束 (3.64)。

我们可以从另一角度来推导核回归模型 (3.61), 从核密度估计开始。假设有一个训练集 $\{\mathbf{x}_n, t_n\}$, 并使用 Parzen 密度估计来建模联合分布 $p(\mathbf{x}, t)$, 于是

$$p(\mathbf{x}, t) = \frac{1}{N} \sum_{n=1}^N f(\mathbf{x} - \mathbf{x}_n, t - t_n) \quad (6.42)$$

其中 $f(\mathbf{x}, t)$ 是分量密度函数, 每个数据点对应一个这样的分量。现在我们要找到回归函数 $y(\mathbf{x})$ 的表达式, 也就是目标变量在给定输入变量条件下的条件均值:

$$\begin{aligned} y(\mathbf{x}) &= \mathbb{E}[t | \mathbf{x}] = \int_{-\infty}^{\infty} t p(t | \mathbf{x}) dt \\ &= \frac{\int t p(\mathbf{x}, t) dt}{\int p(\mathbf{x}, t) dt} \\ &= \frac{\sum_n \int t f(\mathbf{x} - \mathbf{x}_n, t - t_n) dt}{\sum_m \int f(\mathbf{x} - \mathbf{x}_m, t - t_m) dt} \end{aligned} \quad (6.43)$$

现假设分量密度函数均值为零, 即

$$\int_{-\infty}^{\infty} f(\mathbf{x}, t) t dt = 0 \quad (6.44)$$

对所有 $\mathbf{x}$ 成立。用一个简单的变量替换可以得到:

$$\begin{aligned} y(\mathbf{x}) &= \frac{\sum_n g(\mathbf{x} - \mathbf{x}_n) t_n}{\sum_m g(\mathbf{x} - \mathbf{x}_m)} \\ &= \sum_n k(\mathbf{x}, \mathbf{x}_n) t_n \end{aligned} \quad (6.45)$$

其中 $n, m = 1, \dots, N$, 核函数 $k(\mathbf{x}, \mathbf{x}_n)$ 定义为

$$k(\mathbf{x}, \mathbf{x}_n) = \frac{g(\mathbf{x} - \mathbf{x}_n)}{\sum_m g(\mathbf{x} - \mathbf{x}_m)} \quad (6.46)$$

并且我们定义了

$$g(\mathbf{x}) = \int_{-\infty}^{\infty} f(\mathbf{x}, t) dt \quad (6.47)$$

结果 (6.45) 被称为 Nadaraya-Watson 模型或核回归 (Nadaraya, 1964; Watson, 1964)。对于局部化的核函数, 它具有这样的性质: 距离 $\mathbf{x}$ 越近的数据点 $\mathbf{x}_n$ 权重越大。注意核函数 (6.46) 满足求和约束:

$$\sum_{n=1}^N k(\mathbf{x}, \mathbf{x}_n) = 1$$


事实上, 该模型不仅定义了条件均值, 还定义了完整的条件分布:

$$p(t | \mathbf{x}) = \frac{p(t, \mathbf{x})}{\int p(t, \mathbf{x}) dt} = \frac{\sum_n f(\mathbf{x} - \mathbf{x}_n, t - t_n)}{\sum_m \int f(\mathbf{x} - \mathbf{x}_m, t - t_m) dt} \quad (6.48)$$

由此可以求得其他期望。

作为一个例子，我们考虑单一输入变量 x 的情况，以及 $f(x, t)$ 是对变量 $\mathbf{z} = (x, t)$ 的零均值各向同性高斯，方差为 σ^2 。对应的条件分布 (6.48) 将是一个高斯混合，其形状以及条件均值在图 6.3 的正弦合成数据集中给出。

图 6.3 使用各向同性高核对正弦数据集进行 Nadaraya-Watson 核回归模型的示意图。绿色曲线表示原始正弦函数，蓝色点表示数据点，每个数据点都是一个各向同性高斯核的中心。由条件均值给出的回归函数用红色曲线表示，两倍标准差范围由红色阴影表示，对应于条件分布 $p(t | x)$ 。每个数据点周围的蓝色椭圆表示对应核的一倍标准差等高线。由于横轴与纵轴的尺度不同，这些等高线看起来并非圆形。



这个模型一个显而易见的扩展是允许更灵活形式的高斯分量，例如为输入变量和目标变量分别使用不同的方差参数。更一般地，我们可以使用高斯混合模型来对联合分布 $p(t, \mathbf{x})$ 建模，并使用第 9 章讨论的技术进行训练 (Ghahramani 和 Jordan, 1994)，然后求得对应的条件分布 $p(t | \mathbf{x})$ 。在这种情况下，我们不再能将结果表示为在训练数据点上计算得到的核函数形式。然而，混合模型中的分量数量可以小于训练集的数据点数量，从而使模型在对测试数据点进行预测时的计算速度更快。这样，我们在训练阶段接受了更高的计算代价，以换取一个在预测阶段更快速的模型。

6.4 高斯过程

在 6.1 节中，我们通过对偶性的概念应用于一个非概率的回归模型来引入核函数。现在我们将核的作用扩展到概率判别模型，从而得到高斯过程这一框架。这样我们将看到核函数如何在贝叶斯环境中自然出现。

在第 3 章中，我们考虑了形如 $y(\mathbf{x}, \mathbf{w}) = \mathbf{w}^T \phi(\mathbf{x})$ 的线性回归模型，其中 $\mathbf{w}$ 是参数向量，而 $\phi(\mathbf{x})$ 是依赖于输入向量 $\mathbf{x}$ 的固定非线性基函数向量。我们展示了对 $\mathbf{w}$ 的先验分布如何诱导出函数 $y(\mathbf{x}, \mathbf{w})$ 的先验分布。给定训练数据集之后，我们评估了 $\mathbf{w}$ 的后验分布，从而得到了对应的回归函数后验分布，而后者（再加上噪声）进一步对新的输入向量 $\mathbf{x}$ 给出了预测分布 $p(t | \mathbf{x})$ 。

在高斯过程的观点中，我们不再使用参数化模型，而是直接在函数空间上定义一个先验概率分布。乍看之下，在一个不可数的函数空间上定义分布似乎很困难。然而我们将看到，对于有限的训练集，我们只需要考虑函数在训练集和测试集输入点 $\mathbf{x}_n$ 上的取值，因此实际上可以在有限维空间中工作。

与高斯过程等价的模型在许多不同领域中被广泛研究。例如，在地统计学文献中，高斯过程回归称为克里金 (kriging) (Cressie, 1993)。类似地，ARMA (自回归滑动平均) 模型、卡尔曼滤波器以及径向基函数网络都可以视为高斯过程模型的一种形式。关于机

机器学习视角下高斯过程的综述可见 MacKay (1998)、Williams (1999) 和 MacKay (2003), 并且 Rasmussen (1996) 提供了高斯过程与其他方法的比较; Rasmussen 和 Williams (2006) 也提供了关于高斯过程的最新教材。

6.4.1 重新回到线性回归

为了引出高斯过程的观点, 我们重新回到线性回归的例子, 并通过研究关于函数 $y(\mathbf{x}, \mathbf{w})$ 的分布来重新推导预测分布。这将给出一个高斯过程的具体例子。

考虑一个由 M 个固定基函数线性组合定义的模型, 其基函数由向量 $\phi(\mathbf{x})$ 的各个元素给出, 因此

$$y(\mathbf{x}) = \mathbf{w}^T \phi(\mathbf{x}) \quad (6.49)$$

其中 $\mathbf{x}$ 是输入向量, $\mathbf{w}$ 是 M 维权重向量。现在考虑关于 $\mathbf{w}$ 的先验分布, 它是一个各向同性高斯分布:

$$p(\mathbf{w}) = \mathcal{N}(\mathbf{w} \mid \mathbf{0}, \alpha^{-1} \mathbf{I}) \quad (6.50)$$

由超参数 α 控制, 它表示分布的精度 (方差的倒数)。对于任意给定的 $\mathbf{w}$, 定义式 (6.49) 都给出一个关于 $\mathbf{x}$ 的特定函数。因此 (6.50) 中对 $\mathbf{w}$ 的概率分布诱导出了关于函数 $y(\mathbf{x})$ 的概率分布。

在实践中, 我们希望在特定的 $\mathbf{x}$ 值上评估这个函数, 例如训练数据点 $\mathbf{x}_1, \dots, \mathbf{x}_N$ 。因此我们关注函数值的联合分布即 $y(\mathbf{x}_1), \dots, y(\mathbf{x}_N)$, 并将其记为向量 $\mathbf{y}$, 其中 $y_n = y(\mathbf{x}_n)$, $n = 1, \dots, N$ 。根据 (6.49), 该向量可以写为

$$\mathbf{y} = \Phi \mathbf{w} \quad (6.51)$$

其中 Φ 是设计矩阵, 其元素为 $\Phi_{nk} = \phi_k(\mathbf{x}_n)$ 。我们可以如下求出 $\mathbf{y}$ 的概率分布。首先注意 $\mathbf{y}$ 是关于 $\mathbf{w}$ 的线性组合, 而 $\mathbf{w}$ 的各个分量服从高斯分布, 因此 $\mathbf{y}$ 也服从高斯分布。于是我们只要求它的均值和协方差, 根据 (6.50) 可得:

$$\mathbb{E}[\mathbf{y}] = \Phi \mathbb{E}[\mathbf{w}] = \mathbf{0} \quad (6.52)$$

$$\text{cov}[\mathbf{y}] = \mathbb{E}[\mathbf{y}\mathbf{y}^T] = \Phi \mathbb{E}[\mathbf{w}\mathbf{w}^T] \Phi^T = \frac{1}{\alpha} \Phi \Phi^T = \mathbf{K} \quad (6.53)$$

其中 $\mathbf{K}$ 是 Gram 矩阵, 其元素为

$$K_{nm} = k(\mathbf{x}_n, \mathbf{x}_m) = \frac{1}{\alpha} \phi(\mathbf{x}_n)^T \phi(\mathbf{x}_m) \quad (6.54)$$

$k(\mathbf{x}, \mathbf{x}')$ 是核函数。


这一模型给出了一个高斯过程的具体例子。一般来说, 高斯过程被定义为对函数 $y(\mathbf{x})$ 的概率分布, 其性质是: 对任意一组点 $\mathbf{x}_1, \dots, \mathbf{x}_N$, 函数值 $y(\mathbf{x}_1), \dots, y(\mathbf{x}_N)$ 的联合分布都是高斯分布。在输入向量 $\mathbf{x}$ 为二维的情形, 这也称为高斯随机场。更一般地, 一个随机过程 $y(\mathbf{x})$ 由其在任意有限集合点上的值 $y(\mathbf{x}_1), \dots, y(\mathbf{x}_N)$ 的联合概率分布一致地定义。

高斯随机过程的一个关键点在于，关于 N 个变量 $y_1, \dots, y_N$ 的联合分布完全由二阶统计量决定，也就是均值与协方差。在大多数应用中，我们对 $y(\mathbf{x})$ 的均值没有任何先验知识，因此出于对称性的理由，将其设为零。这等价于在基函数视角中，将权重先验 $p(\mathbf{w} | \alpha)$ 的均值选为零。这样，高斯过程的完整指定就通过给出 $y(x)$ 在任意两个位置的协方差来完成，而此协方差由核函数给出：

$$\mathbb{E}[y(\mathbf{x}_n) y(\mathbf{x}_m)] = k(\mathbf{x}_n, \mathbf{x}_m). \quad (6.55)$$

对于由线性回归模型 (6.49) 和权重先验 (6.50) 定义的这一特定高斯过程，其核函数就是 (6.54) 所给出的形式。

图 6.4 来自高斯过程的样本：左图为“高斯”核，右图为指数核。



我们也可以直接定义核函数，而不必通过选择基函数的方式间接获得。图 6.4 给出了从两个不同核函数的高斯过程中采样得到的函数示例。其中第一个是形如 (6.23) 的“高斯”核，第二个是指数核：

$$k(x, x') = \exp(-\theta|x - x'|), \quad (6.56)$$

它对应于 Ornstein-Uhlenbeck 过程，由 Uhlenbeck 和 Ornstein (1930) 最初提出用于描述布朗运动。

6.4.2 用于回归的高斯过程

为了将高斯过程模型用于回归问题，我们需要处理观测目标值中的噪声，其形式为

$$t_n = y_n + \epsilon_n, \quad (6.57)$$

其中 $y_n = y(\mathbf{x}_n)$ ，而 ϵ_n 是一个噪声随机变量，并且对每个样本 n 独立取值。这里我们假设噪声服从高斯分布，因此

$$p(t_n | y_n) = \mathcal{N}(t_n | y_n, \beta^{-1}), \quad (6.58)$$

其中 β 是表示噪声精度的超参数。由于噪声对每个数据点都是独立的，因此在给定 $\mathbf{y} = (y_1, \dots, y_N)^T$ 的情况下，目标向量 $\mathbf{t} = (t_1, \dots, t_N)^T$ 的联合分布是一个各向同性高斯：

$$p(\mathbf{t} | \mathbf{y}) = \mathcal{N}(\mathbf{t} | \mathbf{y}, \beta^{-1} \mathbf{I}_N), \quad (6.59)$$

其中 $\mathbf{I}_N$ 表示 $N \times N$ 的单位矩阵。根据高斯过程的定义, $\mathbf{y}$ 的边缘分布是一个均值为零、协方差由 Gram 矩阵 $\mathbf{K}$ 给出的高斯分布:

$$p(\mathbf{y}) = \mathcal{N}(\mathbf{y} \mid \mathbf{0}, \mathbf{K}). \quad (6.60)$$

核函数决定 $\mathbf{K}$ 的形式, 通常用于表达这样一个性质: 如果两个点 $\mathbf{x}_n$ 与 $\mathbf{x}_m$ 相似, 那么对应的函数值 $y(\mathbf{x}_n)$ 与 $y(\mathbf{x}_m)$ 将比不相似的点更强相关; 而相似性的具体定义依赖于应用场景。

为了找到在输入值 $\mathbf{x}_1, \dots, \mathbf{x}_N$ 条件下的边缘分布 $p(\mathbf{t})$, 我们需要对 $\mathbf{y}$ 积分。利用第 2.3.3 节中线性-高斯模型的结果, 并用上 (2.115), 可得目标向量的边缘分布为

$$p(\mathbf{t}) = \int p(\mathbf{t} \mid \mathbf{y}) p(\mathbf{y}) d\mathbf{y} = \mathcal{N}(\mathbf{t} \mid \mathbf{0}, \mathbf{C}), \quad (6.61)$$

其中协方差矩阵 $\mathbf{C}$ 的元素为

$$C(\mathbf{x}_n, \mathbf{x}_m) = k(\mathbf{x}_n, \mathbf{x}_m) + \beta^{-1} \delta_{nm}. \quad (6.62)$$

这个结果反映了这样一个事实: 由 $y(\mathbf{x})$ 和由 ϵ 产生的两个高斯随机源彼此独立, 因此它们的协方差简单相加。

一种广泛使用的高斯过程回归核函数是带有常数项和线性项的二次指数核:

$$k(\mathbf{x}_n, \mathbf{x}_m) = \theta_0 \exp \left\{ -\frac{\theta_1}{2} \|\mathbf{x}_n - \mathbf{x}_m\|^2 \right\} + \theta_2 + \theta_3 \mathbf{x}_n^T \mathbf{x}_m. \quad (6.63)$$

其中涉及 θ_3 的那一项对应于输入变量的线性参数化模型。图 6.5 展示了不同参数 $\theta_0, \dots, \theta_3$ 下从该先验采样的函数示例, 图 6.6 则展示了从联合分布 (6.60) 采样得到的一组点及由 (6.61) 给出的对应函数值。

到目前为止, 我们已经利用高斯过程的视角构建了关于数据点集合的联合分布模型。然而, 在回归任务中, 我们的目标是: 在给定训练集的情况下, 对新的输入预测其目标变量。设训练集中对应输入为 $\mathbf{x}_1, \dots, \mathbf{x}_N$ 的目标值为 $\mathbf{t}_N = (t_1, \dots, t_N)^T$, 而我们的任务是对新输入向量 $\mathbf{x}_{N+1}$ 的目标值 t_{N+1} 做预测。这要求我们计算预测分布 $p(t_{N+1} \mid \mathbf{t}_N)$ 。注意, 这个分布还以 $\mathbf{x}_1, \dots, \mathbf{x}_N$ 与 $\mathbf{x}_{N+1}$ 为条件, 但为了符号简洁, 这些条件不写出来。

为了求条件分布 $p(t_{N+1} \mid \mathbf{t})$, 我们首先写出 $p(\mathbf{t}_{N+1})$, 其中 $\mathbf{t}_{N+1} = (t_1, \dots, t_N, t_{N+1})^T$ 。然后使用第 2.3.1 节的结果来求所需的条件分布, 如图 6.7 所示。

根据 (6.61), $t_1, \dots, t_{N+1}$ 的联合分布为

$$p(\mathbf{t}_{N+1}) = \mathcal{N}(\mathbf{t}_{N+1} \mid \mathbf{0}, \mathbf{C}_{N+1}), \quad (6.64)$$

其中 $\mathbf{C}_{N+1}$ 是一个 $(N+1) \times (N+1)$ 的协方差矩阵, 其元素由 (6.62) 给出。因为该联合分布是高斯分布, 我们可以使用第 2.3.1 节的条件高斯分布结果。为此, 我们将协方差矩阵分块为

$$\mathbf{C}_{N+1} = \begin{pmatrix} \mathbf{C}_N & \mathbf{k} \\ \mathbf{k}^T & c \end{pmatrix}, \quad (6.65)$$





图 6.5 由协方差函数 (6.63) 定义的高斯过程先验的样本。每个图上方的标题表示 $(\theta_0, \theta_1, \theta_2, \theta_3)$ 。

图 6.6 从高斯过程中采样数据点 $\{t_n\}$ 的示意图。蓝色曲线表示来自该高斯过程函数先验的一个样本函数，红色点表示将该函数在一组输入值 $\{x_n\}$ 处进行求值得到的 y_n 。绿色显示的对应 $\{t_n\}$ 值是通过在每个 y_n 上加入独立的高斯噪声得到的。



其中 $\mathbf{C}_N$ 是 $N \times N$ 的协方差矩阵（元素由 (6.62) 给出， $n, m = 1, \dots, N$ ），向量 $\mathbf{k}$ 的元素是 $k(\mathbf{x}_n, \mathbf{x}_{N+1})$ ，标量 $c = k(\mathbf{x}_{N+1}, \mathbf{x}_{N+1}) + \beta^{-1}$ 。利用 (2.81) 与 (2.82)，条件分布 $p(t_{N+1} | \mathbf{t})$ 为均值与方差如下的高斯分布：

$$m(\mathbf{x}_{N+1}) = \mathbf{k}^T \mathbf{C}_N^{-1} \mathbf{t}, \quad (6.66)$$

$$\sigma^2(\mathbf{x}_{N+1}) = c - \mathbf{k}^T \mathbf{C}_N^{-1} \mathbf{k}. \quad (6.67)$$

这些结果构成了高斯过程回归的核心。由于向量 $\mathbf{k}$ 是测试点输入 $\mathbf{x}_{N+1}$ 的函数，因此预测分布是一个均值与方差均依赖于 $\mathbf{x}_{N+1}$ 的高斯分布。图 6.8 给出了一个高斯过程回归的示例。

对核函数唯一的限制是由 (6.62) 给出的协方差矩阵必须是正定的。若 λ_i 是 $\mathbf{K}$ 的某个特征值，则 $\mathbf{C}$ 的对应特征值为 $\lambda_i + \beta^{-1}$ 。因此，只要核矩阵 $k(\mathbf{x}_n, \mathbf{x}_m)$ 是半正定的（即 $\lambda_i \geq 0$ ），就可以保证 $\mathbf{C}$ 是正定的，因为 $\beta > 0$ ，即使某个 λ_i 为零，对应特征值仍然为正。这与前面讨论的核函数条件一致，因此我们仍然可以使用第 6.2 节中的构造技巧。

图 6.7 展示高斯过程回归机制的示意图，情形为一个训练点和一个测试点，其中红色椭圆表示联合分布 $p(t_1, t_2)$ 的等高线。这里 t_1 是训练数据点，对 t_1 的取值进行条件化（对应于垂直的蓝色直线）后，可得到关于 t_2 的条件分布 $p(t_2 | t_1)$ ，其作为 t_2 的函数由绿色曲线表示。





图 6.8 将高斯过程回归应用于图 A.6 中的正弦数据集的示意图，其中最右侧的三个数据点已被省略。绿色曲线表示生成数据的正弦函数，蓝色点表示通过采样并加入高斯噪声得到的数据点。红色曲线表示高斯过程预测分布的均值，阴影区域对应于正负两个标准差。可以看到，在数据点右侧的区域，不确定性明显增大。



注意，预测均值 (6.66) 可写成关于 $\mathbf{x}_{N+1}$ 的如下形式：

$$m(\mathbf{x}_{N+1}) = \sum_{n=1}^N a_n k(\mathbf{x}_n, \mathbf{x}_{N+1}), \quad (6.68)$$

其中 a_n 是向量 $\mathbf{C}_N^{-1}\mathbf{t}$ 的第 n 个分量。因此，如果核函数 $k(\mathbf{x}_n, \mathbf{x}_m)$ 仅依赖于距离 $\|\mathbf{x}_n - \mathbf{x}_m\|$ ，那么预测均值就是一个径向基函数展开。

(6.66) 与 (6.67) 给出了任意核函数 $k(\mathbf{x}_n, \mathbf{x}_m)$ 下的高斯过程回归预测分布。在核函数由有限组基函数定义的特殊情形下，我们可以从高斯过程视角重新得到第 3.3.2 节中线性回归的结果。

因此，这类模型的预测分布既可以从参数空间（线性回归）视角获得，也可以从函数空间（高斯过程）视角获得。

在实际计算中，高斯过程方法的核心操作是求解大小为 $N \times N$ 的矩阵的逆，标准方法需要 $O(N^3)$ 的计算量。相比之下，在基函数模型中我们求解的是大小为 $M \times M$ 的矩阵 $\mathbf{S}_N$ ，其复杂度为 $O(M^3)$ 。注意，无论哪种方法，矩阵求逆在处理固定训练集时只需执行一次；对于每一个新的测试点，两种方法都需要一次向量-矩阵乘法，其代价在高斯过程下为 $O(N^2)$ ，而在基函数模型下为 $O(M^2)$ 。如果基函数数量 M 小于数据点数量 N ，那么基函数模型的计算效率更高。不过，高斯过程的优势在于我们可以使用只能通过无限多个基函数表达的协方差函数。

然而，对大型训练集直接应用高斯过程方法会变得不可行，因此发展出了许多近似方案，它们在训练集规模上有更好的伸缩性（Gibbs, 1997; Tresp, 2001; Smola and Bartlett, 2001; Williams and Seeger, 2001; Csató and Opper, 2002; Seeger et al., 2003）。关于高斯过

程应用中的实际问题，可参考 Bishop 和 Nabney (2008)。

我们以上讨论的是单一目标变量的高斯过程回归，其推广到多目标变量（称为 co-kriging, Cressie, 1993）是直接的。高斯过程回归还有许多其他扩展，如用于无监督学习的低维流形建模（Bishop et al., 1998a）以及随机微分方程求解（Graepel, 2003）。

6.4.3 学习超参数

高斯过程模型的预测部分取决于协方差函数的选择。在实际应用中，我们通常不会将协方差函数固定不变，而是使用一个带参数的函数族，并根据数据推断这些参数的取值。这些参数控制例如相关性的长度尺度以及噪声的精度，它们在标准的参数模型中对应于超参数。

学习超参数的方法基于似然函数 $p(\mathbf{t} | \boldsymbol{\theta})$ 的计算，其中 $\boldsymbol{\theta}$ 表示高斯过程模型的超参数。最简单的方式是通过最大化对数似然函数来对 $\boldsymbol{\theta}$ 进行点估计。因为 $\boldsymbol{\theta}$ 作为超参数属于回归问题，所以这可以看作类似于在线性回归模型中使用的第二类最大似然过程。对数似然的最大化可以使用诸如共轭梯度法之类的高效梯度优化算法来完成（Fletcher, 1987; Nocedal 和 Wright, 1999; Bishop 和 Nabney, 2008）。

对于高斯过程回归模型，对数似然可以直接利用多元高斯分布的标准形式计算得到：

$$\ln p(\mathbf{t} | \boldsymbol{\theta}) = -\frac{1}{2} \ln |\mathbf{C}_N| - \frac{1}{2} \mathbf{t}^T \mathbf{C}_N^{-1} \mathbf{t} - \frac{N}{2} \ln(2\pi). \quad (6.69)$$

为了进行非线性优化，我们还需要对数似然关于参数向量 $\boldsymbol{\theta}$ 的梯度。我们假设 $\mathbf{C}_N$ 的导数容易计算（对本章讨论的协方差函数而言确实如此）。利用 (C.21) 给出的 $\mathbf{C}_N^{-1}$ 的导数公式以及 (C.22) 中关于 $\ln |\mathbf{C}_N|$ 的导数公式，我们得到

$$\frac{\partial}{\partial \theta_i} \ln p(\mathbf{t} | \boldsymbol{\theta}) = -\frac{1}{2} \text{Tr} \left(\mathbf{C}_N^{-1} \frac{\partial \mathbf{C}_N}{\partial \theta_i} \right) + \frac{1}{2} \mathbf{t}^T \mathbf{C}_N^{-1} \frac{\partial \mathbf{C}_N}{\partial \theta_i} \mathbf{C}_N^{-1} \mathbf{t}. \quad (6.70)$$

由于 $\ln p(\mathbf{t} | \boldsymbol{\theta})$ 通常是非凸的，它可能具有多个局部极大值。

我们可以很容易地在 $\boldsymbol{\theta}$ 上加入先验分布，并通过梯度方法最大化对数后验。在完全贝叶斯的设定下，我们需要对 $\boldsymbol{\theta}$ 做边缘化，并以先验 $p(\boldsymbol{\theta})$ 与似然 $p(\mathbf{t} | \boldsymbol{\theta})$ 的乘积作为权重。然而精确边缘化通常不可行，因此需要依赖近似方法。

高斯过程回归模型给出的预测分布的均值与方差都是输入向量 $\mathbf{x}$ 的函数。然而我们一直假设预测方差中的噪声项是常数，由参数 β 控制。但在一些称为异方差（heteroscedastic）的问题中，噪声方差本身也依赖于 $\mathbf{x}$ 。为建模这种现象，我们可以通过引入第二个高斯过程来表示 β 对输入的依赖关系（Goldberg 等, 1998）。由于 β 是一个方差，因此非负，我们通过对 $\ln \beta(\mathbf{x})$ 建模来保持其合法性。

6.4.4 自动相关性确定

在前一节中，我们看到如何利用最大似然法来确定高斯过程中的相关长度尺度参数。这个方法可以进一步扩展：为每一个输入变量引入单独的参数（Rasmussen 和

Williams, 2006)。我们将会看到，这些参数通过最大似然优化，其结果可以反映不同输入维度的重要性，从而从数据中自动推断出哪些输入变量更相关。这就是自动相关性确定（automatic relevance determination, ARD），最初在神经网络框架中提出（MacKay, 1994; Neal, 1996）。关于模型如何偏好适当的输入变量的机制，将在 7.2.2 节讨论。

考虑一个具有二维输入空间 $\mathbf{x} = (x_1, x_2)$ 的高斯过程，其核函数形式为

$$k(\mathbf{x}, \mathbf{x}') = \theta_0 \exp \left\{ -\frac{1}{2} \sum_{i=1}^2 \eta_i (x_i - x'_i)^2 \right\}. \quad (6.71)$$

图 6.9 来自高斯过程的 ARD

先验的样本，其中核函数由 (6.71) 给出。左图对应 $\eta_1 = \eta_2 = 1$ ，右图对应 $\eta_1 = 1, \eta_2 = 0.01$ 。





图 6.9 展示了在两种不同精度参数 η_i 设置下，从所得的函数先验分布中采样的结果。可以看到，当某个参数 η_i 变小时，函数对相应输入变量 x_i 的敏感性会降低。通过使用最大似然将这些参数适配到数据集上，可以检测出对预测分布影响很小的输入变量，因为其对应的 η_i 会变得很小。这在实践中很有用，因为可以将此类输入丢弃。图 6.10 使用一个具有三个输入 x_1, x_2, x_3 的简单合成数据集（Nabney, 2002）说明了 ARD 的效果。目标变量 t 的生成方式是从高斯分布中采样 100 个 x_1 值，计算函数 $\sin(2\pi x_1)$ ，然后加入高斯噪声。 x_2 的值通过复制对应的 x_1 并添加噪声获得，而 x_3 的值则从一个独立的高斯分布中采样。因此， x_1 是 t 的良好预测变量， x_2 是更噪声的 t 的预测变量，而 x_3 与 t 只有偶然相关性。对具有 ARD 参数 η_1, η_2, η_3 的高斯过程，其边缘似然使用缩放共轭梯度算法进行优化。从图 6.10 可见， η_1 收敛到一个相对较大的值， η_2 收敛到一个更小的值，而 η_3 几乎变得非常小，表明 x_3 与预测 t 无关。

图 6.10 展示在一个具有三个输入 x_1, x_2, x_3 的合成问题中，高斯过程的自动相关性确定机制。图中的曲线分别显示超参数 η_1 （红色）、 η_2 （绿色）和 η_3 （蓝色）在优化边缘似然时随迭代次数变化的取值。细节见正文。注意纵轴为对数刻度。



ARD 框架可以很容易地并入指数二次核 (6.63) 中，从而得到以下形式的核函数，该核函数在将高斯过程应用于各种回归问题时十分有用

$$k(\mathbf{x}_n, \mathbf{x}_m) = \theta_0 \exp \left\{ -\frac{1}{2} \sum_{i=1}^D \eta_i (x_{ni} - x_{mi})^2 \right\} + \theta_2 + \theta_3 \sum_{i=1}^D x_{ni} x_{mi} \quad (6.72)$$

其中 D 为输入空间的维度。

6.4.5 用于分类的高斯过程

在概率分类方法中，我们的目标是建模给定训练数据后，对于一个新的输入向量，目标变量的后验概率。这些概率必须位于区间 $(0, 1)$ 中，而高斯过程模型的预测值位于整个实数轴上。然而，我们可以通过使用适当的非线性激活函数对高斯过程的输出进行变换，从而轻松将高斯过程适配到分类问题。

首先考虑二分类问题，其目标变量为 $t \in \{0, 1\}$ 。如果我们在函数 $a(\mathbf{x})$ 上定义一个高斯过程，然后使用逻辑 sigmoid 函数 $y = \sigma(a)$ （由公式 (4.59) 给出）对该函数进行变换，那么我们将得到关于函数 $y(\mathbf{x})$ 的非高斯随机过程，其中 $y \in (0, 1)$ 。图 6.11 展示了一维输入空间的情况，此时目标变量 t 的概率分布由伯努利分布给出

$$p(t | a) = \sigma(a)^t (1 - \sigma(a))^{1-t}. \quad (6.73)$$




图 6.11 左图展示函数 $a(x)$ 的高斯过程先验的一个样本，右图展示将该样本经过逻辑 sigmoid 函数变换后的结果。

和往常一样，我们将训练集输入记为 $\mathbf{x}_1, \dots, \mathbf{x}_N$ ，其对应的观测目标变量为 $\mathbf{t} = (t_1, \dots, t_N)^T$ 。我们还考虑一个单独的测试点 $\mathbf{x}_{N+1}$ ，其目标值为 t_{N+1} 。我们的目标是确定预测分布 $p(t_{N+1} | \mathbf{t})$ ，其中对输入变量的条件隐式省略。为此，我们在向量 $\mathbf{a}_{N+1}$ 上引入一个高斯过程先验，其分量为 $a(\mathbf{x}_1), \dots, a(\mathbf{x}_{N+1})$ 。这进一步定义了一个关于 $\mathbf{t}_{N+1}$ 的非高斯过程，并通过对训练数据 $\mathbf{t}_N$ 条件化得到所需的预测分布。 $\mathbf{a}_{N+1}$ 的高斯过程先验形式为

$$p(\mathbf{a}_{N+1}) = \mathcal{N}(\mathbf{a}_{N+1} | \mathbf{0}, \mathbf{C}_{N+1}). \quad (6.74)$$

与回归情形不同，协方差矩阵不再包含噪声项，因为我们假设所有训练数据点都被正确标记。然而，出于数值原因，引入一个由参数 ν 控制的类似噪声的项是方便的，它确保协方差矩阵为正定。因此，协方差矩阵 $\mathbf{C}_{N+1}$ 的元素为

$$C(\mathbf{x}_n, \mathbf{x}_m) = k(\mathbf{x}_n, \mathbf{x}_m) + \nu \delta_{nm} \quad (6.75)$$

其中 $k(\mathbf{x}_n, \mathbf{x}_m)$ 为第 6.2 节讨论的任意正半定核函数，而 ν 的取值通常预先固定。我们将假设核函数 $k(\mathbf{x}, \mathbf{x}')$ 由参数向量 $\boldsymbol{\theta}$ 控制，并将在后续讨论如何从训练数据中学习 $\boldsymbol{\theta}$ 。

对于二分类问题，只需预测 $p(t_{N+1} = 1 | \mathbf{t}_N)$ ，因为 $p(t_{N+1} = 0 | \mathbf{t}_N)$ 的值由 $1 - p(t_{N+1} = 1 | \mathbf{t}_N)$ 给出。所需的预测分布为

$$p(t_{N+1} = 1 | \mathbf{t}_N) = \int p(t_{N+1} = 1 | a_{N+1}) p(a_{N+1} | \mathbf{t}_N) da_{N+1} \quad (6.76)$$

其中 $p(t_{N+1} = 1 | a_{N+1}) = \sigma(a_{N+1})$ 。

这个积分在解析上是不可解的，因此可以使用采样方法进行近似 (Neal, 1997)。作为替代，我们可以考虑基于解析近似的技术。在第 4.5.2 节中，我们推导了逻辑 sigmoid 与高斯分布卷积的近似公式 (4.153)。只要我们对后验分布 $p(a_{N+1} | \mathbf{t}_N)$ 有一个高斯近似，就可以利用该结果来计算 (6.76) 中的积分。对后验分布使用高斯近似的常见理由是，随着数据点数量的增加，真实后验会由于中心极限定理而趋于高斯分布。在高斯过程的情况下，变量数量随着数据点的增加而增长，因此这个论点不能直接适用。然而，如果我们考虑在 $\mathbf{x}$ 空间的某一固定区域内增加数据点数量，那么函数 $a(\mathbf{x})$ 的对应不确定性将减小，从而再次在极限下趋向高斯分布 (Williams 和 Barber, 1998)。

已有三种不同的方法用于获得高斯近似。一种技术基于变分推断 (Gibbs 和 MacKay, 2000)，使用对逻辑 sigmoid 的局部变分界 (10.144)。这使得 sigmoid 函数的乘积可以用高斯分布的乘积来近似，从而允许对 $\mathbf{a}_N$ 的边缘化在解析上完成。该方法还给出了似然函数 $p(\mathbf{t}_N | \boldsymbol{\theta})$ 的下界。用于高斯过程分类的变分框架也可以通过对 softmax 函数使用高斯近似扩展到多类别 ($K > 2$) 问题 (Gibbs, 1997)。

第二种方法使用期望传播 (Opper 和 Winther, 2000b; Minka, 2001b; Seeger, 2003)。由于真实后验分布是单峰的，正如我们稍后将看到的，期望传播方法可以给出良好的结果。

6.4.6 拉普拉斯近似

第三种高斯过程分类方法基于拉普拉斯近似，我们现在详细讨论这一方法。为了计算预测分布 (6.76)，我们寻求一个关于 a_{N+1} 的后验分布的高斯近似，根据贝叶斯定理，该分布为

$$\begin{aligned} p(a_{N+1} | \mathbf{t}_N) &= \int p(a_{N+1}, \mathbf{a}_N | \mathbf{t}_N) d\mathbf{a}_N \\ &= \frac{1}{p(\mathbf{t}_N)} \int p(a_{N+1}, \mathbf{a}_N) p(\mathbf{t}_N | a_{N+1}, \mathbf{a}_N) d\mathbf{a}_N \\ &= \frac{1}{p(\mathbf{t}_N)} \int p(a_{N+1} | \mathbf{a}_N) p(\mathbf{a}_N) p(\mathbf{t}_N | \mathbf{a}_N) d\mathbf{a}_N \\ &= \int p(a_{N+1} | \mathbf{a}_N) p(\mathbf{a}_N | \mathbf{t}_N) d\mathbf{a}_N \end{aligned} \quad (6.77)$$

其中我们使用了 $p(\mathbf{t}_N | a_{N+1}, \mathbf{a}_N) = p(\mathbf{t}_N | \mathbf{a}_N)$ 。

条件分布 $p(a_{N+1} | \mathbf{a}_N)$ 可以通过引用高斯过程回归的结果 (6.66) 和 (6.67) 得到

$$p(a_{N+1} | \mathbf{a}_N) = \mathcal{N}(a_{N+1} | \mathbf{k}^T \mathbf{C}_N^{-1} \mathbf{a}_N, c - \mathbf{k}^T \mathbf{C}_N^{-1} \mathbf{k}). \quad (6.78)$$

因此, 通过对后验分布 $p(\mathbf{a}_N | \mathbf{t}_N)$ 进行拉普拉斯近似, 再使用两个高斯分布卷积的标准结果, 我们即可计算 (6.77) 中的积分。

先验 $p(\mathbf{a}_N)$ 由协方差矩阵 $\mathbf{C}_N$ 的零均值高斯过程给出, 而数据项 (假设各数据点独立) 为

$$p(\mathbf{t}_N | \mathbf{a}_N) = \prod_{n=1}^N \sigma(a_n)^{t_n} (1 - \sigma(a_n))^{1-t_n} = \prod_{n=1}^N e^{a_n t_n} \sigma(-a_n). \quad (6.79)$$

然后我们通过对 $p(\mathbf{a}_N | \mathbf{t}_N)$ 的对数进行泰勒展开来得到拉普拉斯近似, 该对数除了一个加性的归一化常数之外, 由下式给出

$$\begin{aligned} \Psi(\mathbf{a}_N) &= \ln p(\mathbf{a}_N) + \ln p(\mathbf{t}_N | \mathbf{a}_N) \\ &= -\frac{1}{2} \mathbf{a}_N^T \mathbf{C}_N^{-1} \mathbf{a}_N - \frac{N}{2} \ln(2\pi) - \frac{1}{2} \ln |\mathbf{C}_N| + \mathbf{t}_N^T \mathbf{a}_N \\ &\quad - \sum_{n=1}^N \ln(1 + e^{a_n}) + \text{const.} \end{aligned} \quad (6.80)$$

首先我们需要找到后验分布的模, 这要求我们计算 $\Psi(\mathbf{a}_N)$ 的梯度, 其形式为

$$\nabla \Psi(\mathbf{a}_N) = \mathbf{t}_N - \sigma_N - \mathbf{C}_N^{-1} \mathbf{a}_N \quad (6.81)$$

其中 σ_N 是一个向量, 其元素为 $\sigma(a_n)$ 。由于 σ_N 非线性地依赖于 $\mathbf{a}_N$, 我们不能简单地通过将梯度设为零来找到模, 因此采用基于牛顿-拉夫森方法的迭代方案, 这引出了迭代重加权最小二乘 (IRLS) 算法。这需要 $\Psi(\mathbf{a}_N)$ 的二阶导数, 而这本身也是进行拉普拉斯近似所需要的, 其形式为

$$\nabla \nabla \Psi(\mathbf{a}_N) = -\mathbf{W}_N - \mathbf{C}_N^{-1} \quad (6.82)$$

其中 $\mathbf{W}_N$ 是一个对角矩阵, 其元素为 $\sigma(a_n)(1 - \sigma(a_n))$, 我们使用了逻辑 sigmoid 函数的导数结果 (4.88)。注意这些对角元素位于区间 $(0, 1/4)$, 因此 $\mathbf{W}_N$ 是正定矩阵。由于 $\mathbf{C}_N$ (以及它的逆) 根据构造是正定的, 而两个正定矩阵之和仍为正定, 因此 Hessian 矩阵 $\mathbf{A} = -\nabla \nabla \Psi(\mathbf{a}_N)$ 为正定, 故后验分布 $p(\mathbf{a}_N | \mathbf{t}_N)$ 的对数是凸的, 因此有唯一的全局最大值。后验分布并不是高斯分布, 因为 Hessian 是 $\mathbf{a}_N$ 的函数。

利用牛顿-拉夫森公式 (4.92), $\mathbf{a}_N$ 的迭代更新方程为

$$\mathbf{a}_N^{\text{new}} = \mathbf{C}_N (\mathbf{I} + \mathbf{W}_N \mathbf{C}_N)^{-1} \{\mathbf{t}_N - \sigma_N + \mathbf{W}_N \mathbf{a}_N\}. \quad (6.83)$$

这些方程被不断迭代, 直到收敛到我们记为 $\mathbf{a}_N^*$ 的模。在模处, 梯度 $\nabla \Psi(\mathbf{a}_N)$ 为零, 因此 $\mathbf{a}_N^*$ 满足

$$\mathbf{a}_N^* = \mathbf{C}_N (\mathbf{t}_N - \sigma_N). \quad (6.84)$$

一旦找到了后验的模 $\mathbf{a}_N^*$, 我们即可计算 Hessian 矩阵

$$\mathbf{H} = -\nabla \nabla \Psi(\mathbf{a}_N) = \mathbf{W}_N + \mathbf{C}_N^{-1} \quad (6.85)$$

其中 $\mathbf{W}_N$ 的元素使用 $\mathbf{a}_N^*$ 来计算。这定义了后验分布 $p(\mathbf{a}_N | \mathbf{t}_N)$ 的高斯近似

$$q(\mathbf{a}_N) = \mathcal{N}(\mathbf{a}_N | \mathbf{a}_N^*, \mathbf{H}^{-1}). \quad (6.86)$$

我们现在可以将此与 (6.78) 结合, 从而计算 (6.77) 中的积分。由于这对应于一个线性-高斯模型, 可以使用一般结果 (2.115), 得到

$$\mathbb{E}[a_{N+1} | \mathbf{t}_N] = \mathbf{k}^T (\mathbf{t}_N - \boldsymbol{\sigma}_N) \quad (6.87)$$

$$\text{var}[a_{N+1} | \mathbf{t}_N] = c - \mathbf{k}^T (\mathbf{W}_N^{-1} + \mathbf{C}_N)^{-1} \mathbf{k}. \quad (6.88)$$

现在我们已经得到了 $p(a_{N+1} | \mathbf{t}_N)$ 的高斯分布, 可以使用结果 (4.153) 来近似计算积分 (6.76)。如同第 4.5 节中的贝叶斯逻辑回归模型一样, 如果我们只关心对应于 $p(\mathbf{t}_{N+1} | \mathbf{t}_N) = 0.5$ 的决策边界, 那么只需考虑均值即可, 可以忽略方差的影响。

我们还需要确定协方差函数的参数 $\boldsymbol{\theta}$ 。一种方法是最大化由 $p(\mathbf{t}_N | \boldsymbol{\theta})$ 给出的似然函数, 为此我们需要对数似然及其梯度的表达式。如果需要, 还可以加入适当的正则化项, 从而得到一个带惩罚项的最大似然解。似然函数定义为

$$p(\mathbf{t}_N | \boldsymbol{\theta}) = \int p(\mathbf{t}_N | \mathbf{a}_N) p(\mathbf{a}_N | \boldsymbol{\theta}) d\mathbf{a}_N. \quad (6.89)$$

该积分在解析上不可解, 因此我们再次使用拉普拉斯近似。利用结果 (4.135), 可以得到似然函数对数的以下近似

$$\ln p(\mathbf{t}_N | \boldsymbol{\theta}) = \Psi(\mathbf{a}_N^*) - \frac{1}{2} \ln |\mathbf{W}_N + \mathbf{C}_N^{-1}| + \frac{N}{2} \ln(2\pi) \quad (6.90)$$

其中 $\Psi(\mathbf{a}_N^*) = \ln p(\mathbf{a}_N^* | \boldsymbol{\theta}) + \ln p(\mathbf{t}_N | \mathbf{a}_N^*)$ 。我们还需要计算 $\ln p(\mathbf{t}_N | \boldsymbol{\theta})$ 对参数向量 $\boldsymbol{\theta}$ 的梯度。注意, $\boldsymbol{\theta}$ 的变化会使 $\mathbf{a}_N^*$ 发生变化, 从而在梯度中引入额外的项。因此, 当我们对 (6.90) 关于 $\boldsymbol{\theta}$ 求导时, 会得到两类项: 一类来自协方差矩阵 $\mathbf{C}_N$ 对 $\boldsymbol{\theta}$ 的显式依赖, 另一类来自 $\mathbf{a}_N^*$ 对 $\boldsymbol{\theta}$ 的依赖。

来自对 $\boldsymbol{\theta}$ 的显式依赖的项可通过使用 (6.80) 以及结果 (C.21) 和 (C.22) 得到, 其形式为

$$\begin{aligned} \frac{\partial \ln p(\mathbf{t}_N | \boldsymbol{\theta})}{\partial \theta_j} &= \frac{1}{2} \mathbf{a}_N^{*T} \mathbf{C}_N^{-1} \frac{\partial \mathbf{C}_N}{\partial \theta_j} \mathbf{C}_N^{-1} \mathbf{a}_N^* \\ &\quad - \frac{1}{2} \text{Tr} \left[(\mathbf{I} + \mathbf{C}_N \mathbf{W}_N)^{-1} \mathbf{W}_N \frac{\partial \mathbf{C}_N}{\partial \theta_j} \right]. \end{aligned} \quad (6.91)$$

为了计算来自 $\mathbf{a}_N^*$ 对 $\boldsymbol{\theta}$ 的依赖所产生的项, 我们注意到拉普拉斯近似构造得使得 $\Psi(\mathbf{a}_N)$ 在 $\mathbf{a}_N = \mathbf{a}_N^*$ 处的梯度为零, 因此 $\Psi(\mathbf{a}_N^*)$ 对梯度没有贡献。剩下的关于 $\boldsymbol{\theta}$ 分量 θ_j 的导数贡献为

$$\begin{aligned} & - \frac{1}{2} \sum_{n=1}^N \frac{\partial \ln |\mathbf{W}_N + \mathbf{C}_N^{-1}|}{\partial a_n^*} \frac{\partial a_n^*}{\partial \theta_j} \\ &= - \frac{1}{2} \sum_{n=1}^N [(\mathbf{I} + \mathbf{C}_N \mathbf{W}_N)^{-1} \mathbf{C}_N]_{nn} \sigma_n^* (1 - \sigma_n^*) (1 - 2\sigma_n^*) \frac{\partial a_n^*}{\partial \theta_j} \end{aligned} \quad (6.92)$$

其中 $\sigma_n^* = \sigma(a_n^*)$, 我们再次使用了结果 (C.22) 和 $\mathbf{W}_N$ 的定义。

我们可以通过对关系式 (6.84) 关于 θ_j 求导来计算 a_N^* 关于 θ_j 的导数, 从而得到

$$\frac{\partial a_n^*}{\partial \theta_j} = \frac{\partial \mathbf{C}_N}{\partial \theta_j} (\mathbf{t}_N - \boldsymbol{\sigma}_N) - \mathbf{C}_N \mathbf{W}_N \frac{\partial a_n^*}{\partial \theta_j} \quad (6.93)$$

整理后得到

$$\frac{\partial a_n^*}{\partial \theta_j} = (\mathbf{I} + \mathbf{W}_N \mathbf{C}_N)^{-1} \frac{\partial \mathbf{C}_N}{\partial \theta_j} (\mathbf{t}_N - \sigma_N). \quad (6.94)$$

结合 (6.91)、(6.92) 和 (6.94)，我们就可以计算对数似然函数的梯度，从而可以利用标准的非线性优化算法来确定 θ 的取值。




图 6.12 展示将高斯过程用于分类的示意图：左侧显示数据，绿色曲线为真实分布给出的最优决策边界，黑色曲线为高斯过程分类器得到的决策边界。右侧显示蓝色类和红色类的预测后验概率，以及高斯过程的决策边界。

我们可以利用图 6.12 中所示的二维合成二分类数据集来说明拉普拉斯近似在高斯过程中的应用。使用 softmax 激活函数，将拉普拉斯近似扩展到涉及 $K > 2$ 类的高斯过程也是直接可行的 (Williams 和 Barber, 1998)。

6.4.7 与神经网络的联系

我们已经看到，神经网络可以表示的函数范围由隐藏单元数量 M 控制，并且当 M 足够大时，双层网络可以以任意精度逼近任何给定函数。在最大似然框架中，隐藏单元的数量需要受到限制（限制程度依赖于训练集的规模），以避免过拟合。然而，从贝叶斯的角度来看，根据训练集规模来限制网络中的参数数量并没有多少意义。

在贝叶斯神经网络中，参数向量 $\mathbf{w}$ 的先验分布与网络函数 $f(\mathbf{x}, \mathbf{w})$ 结合起来，会在函数空间中产生一个关于 $y(\mathbf{x})$ 的先验分布，其中 $\mathbf{y}$ 是网络输出的向量。Neal (1996) 表明，对于一大类关于 $\mathbf{w}$ 的先验分布，当 $M \rightarrow \infty$ 时，由神经网络生成的函数分布会趋向于一个高斯过程。然而，需要注意的是，在这个极限下，神经网络的输出变量会彼此独立。神经网络的一个重要优点是，输出共享隐藏单元，因此它们可以“共享统计力量”，即每个隐藏单元的权重不仅由某一个输出变量影响，而是由所有输出变量同时影响。因此，这一特性在高斯过程的极限中会丢失。

我们已经看到，高斯过程由其协方差（核）函数决定。Williams (1998) 给出了两种特定隐藏单元激活函数（probit 和 Gaussian）情况下的协方差函数的显式形式。这些核函数 $k(\mathbf{x}, \mathbf{x}')$ 是非平稳的，即它们不能表示为差值 $\mathbf{x} - \mathbf{x}'$ 的函数。这是因为高斯权重先验以零为中心，从而破坏了权重空间中的平移不变性。

通过直接处理协方差函数，我们实际上已经对权重分布进行了隐式边缘化。如果权

重先验由超参数控制，那么它们的取值将决定函数分布的长度尺度，这一点可以通过研究图 5.11 中有限个隐藏单元时的例子来理解。需要注意的是，我们无法解析地边缘化这些超参数，因此必须采用第 6.4 节中讨论的技术。

7 稀疏核机

在上一章中，我们探讨了多种基于非线性核的学习算法。许多此类算法的一个重要局限在于，必须对所有可能的训练点对 $\mathbf{x}_n$ 和 $\mathbf{x}_m$ 计算核函数 $k(\mathbf{x}_n, \mathbf{x}_m)$ ，这在训练过程中可能在计算上不可行，并且在对新数据点进行预测时会导致过高的计算成本。本章将研究具有稀疏解的基于核的算法，使得对新输入的预测只依赖于在训练数据点的一个子集上评估的核函数。

我们首先详细讨论支持向量机 (SVM)，它在若干年前因解决分类、回归和新颖性检测等问题而广受欢迎。支持向量机的一个重要特性是模型参数的确定对应于一个凸优化问题，因此任何局部解都是全局最优解。由于对支持向量机的讨论中广泛使用了拉格朗日乘子，读者可回顾附录 E 中涵盖的关键概念。关于支持向量机的更多信息见 Vapnik (1995)、Burges (1998)、Cristianini 和 Shawe-Taylor (2000)、Müller 等 (2001)、Schölkopf 和 Smola (2002) 以及 Herbrich (2002)。

SVM 是一种决策机器，因此不提供后验概率。我们在 1.5.4 节已经讨论了确定概率的一些益处。另一种稀疏核方法称为相关向量机 (RVM)，基于贝叶斯的形式化，不仅能够提供后验概率输出，而且通常具有比 SVM 更稀疏得多的解。

7.1 最大间隔分类器

我们对支持向量机的讨论从重新审视线性模型的二分类问题开始，其形式为

$$y(\mathbf{x}) = \mathbf{w}^T \phi(\mathbf{x}) + b \quad (7.1)$$

其中 $\phi(\mathbf{x})$ 表示一个固定的特征空间变换，并且我们将偏置参数 b 显式写出。注意，我们很快将引入一个基于核函数的对偶表示，从而无需显式在特征空间中工作。训练数据集包含 N 个输入向量 $\mathbf{x}_1, \dots, \mathbf{x}_N$ ，其对应的目标值为 $t_1, \dots, t_N$ ，其中 $t_n \in \{-1, 1\}$ ，并且新数据点 $\mathbf{x}$ 根据 $y(\mathbf{x})$ 的符号进行分类。

我们暂时假设训练数据集在特征空间中是线性可分的，因此根据定义，至少存在某个参数向量 $\mathbf{w}$ 和某个偏置 b ，使得形式为 (7.1) 的函数对所有训练样本满足：对于 $t_n = +1$ 的点有 $y(\mathbf{x}_n) > 0$ ，对于 $t_n = -1$ 的点有 $y(\mathbf{x}_n) < 0$ ，从而对所有训练点都有 $t_n y(\mathbf{x}_n) > 0$ 。当然，这样的解可能有多个都能精确分开两类。在 4.1.7 节中，我们讨论了感知机算法，它可以保证在有限步数内找到一个这样的解。然而，该算法找到的解依赖于（任意）初始化的 $\mathbf{w}$ 和 b ，也依赖于训练样本的呈现顺序。如果存在多个完全正确分类的解，我们应尝试找到其中泛化误差最小的一个。支持向量机通过“间隔” (margin) 的概念来解决这个问题，它被定义为决策边界与任一样本之间的最小距离，如图 7.1 所示。

在支持向量机中，决策边界被选择为间隔最大者。最大间隔的动机可以基于计算学习理论（统计学习理论）来解释。然而，Tong 和 Koller (2000) 给出了一个简单的直觉解释：他们考虑一种结合生成式和判别式方法的分类框架。他们首先使用带有共同参数 σ^2 的高斯核的 Parzen 密度估计器来建模各类的输入向量分布。结合类别先验，这定义了一个最优的错误率最小决策边界。然而，他们并不直接使用这个最优边界，而是寻找




图 7.1 间隔被定义为决策边界与离其最近的数据点之间的垂直距离，如左图所示。最大化间隔会得到特定的决策边界，如右图所示。该决策边界的位置由数据点中的一个子集决定，这些数据点称为支持向量，并用圆圈标出。

使相对学习到的密度模型的误差概率最小的超平面。在极限 $\sigma^2 \rightarrow 0$ 时，可以证明最优超平面就是具有最大间隔的那一个。直觉上，随着 σ^2 的减小，超平面越来越受到附近数据点的影响，而远处的数据点影响减弱。在极限下，超平面完全与非支持向量的数据点无关。

我们将在图 10.13 中看到，在简单的线性可分数据集上，对参数进行贝叶斯边缘化会使决策边界落在分隔数据点的区域正中，而最大间隔解表现出类似行为。

回忆图 4.1，可知点 $\mathbf{x}$ 到由 $y(\mathbf{x}) = 0$ 定义的超平面的垂直距离为 $|y(\mathbf{x})|/\|\mathbf{w}\|$ 。并且我们只考虑所有训练点都被正确分类的解，即对所有 n 有 $t_n y(\mathbf{x}_n) > 0$ 。因此点 $\mathbf{x}_n$ 到决策面的距离为

$$\frac{t_n y(\mathbf{x}_n)}{\|\mathbf{w}\|} = \frac{t_n (\mathbf{w}^T \phi(\mathbf{x}_n) + b)}{\|\mathbf{w}\|}. \quad (7.2)$$

间隔由数据集中距离决策边界最近的点的垂直距离给出，我们希望通过优化 $\mathbf{w}$ 和 b 来最大化该距离。因此最大间隔解由以下问题求得：

$$\arg \max_{\mathbf{w}, b} \left\{ \frac{1}{\|\mathbf{w}\|} \min_n [t_n (\mathbf{w}^T \phi(\mathbf{x}_n) + b)] \right\}. \quad (7.3)$$

其中我们把 $1/\|\mathbf{w}\|$ 从对 n 的最小化中提取出来，因为 $\mathbf{w}$ 与 n 无关。直接求解该优化问题非常复杂，因此我们将其转换为一个等价但更易处理的问题。

为此注意到，如果进行缩放变换 $\mathbf{w} \rightarrow \kappa \mathbf{w}$ 、 $b \rightarrow \kappa b$ ，则任意点 $\mathbf{x}_n$ 到决策面的距离 $t_n y(\mathbf{x}_n)/\|\mathbf{w}\|$ 保持不变。我们可以利用这种自由度将与决策面最近的点设为

$$t_n (\mathbf{w}^T \phi(\mathbf{x}_n) + b) = 1. \quad (7.4)$$

这样，所有数据点都满足约束

$$t_n (\mathbf{w}^T \phi(\mathbf{x}_n) + b) \geq 1, \quad n = 1, \dots, N. \quad (7.5)$$

这称为决策超平面的规范形式。对于满足等式的点，约束称为“活跃的”；其余则“不活跃”。根据定义，总会至少有一个活跃约束，因为总有最近点；并且当间隔最大化

后，将至少有两个活跃约束。优化问题此时只需最大化 $\|\mathbf{w}\|^{-1}$ ，等价于最小化 $\|\mathbf{w}\|^2$ ，因此我们要解决

$$\arg \min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 \quad (7.6)$$

条件是满足 (7.5) 的约束。(7.6) 中的 $1/2$ 是为了之后的方便加入的。

看似偏置 b 在优化中消失了，但其实它通过约束被隐式确定，因为约束要求对 $\|\mathbf{w}\|$ 的改变必须由 b 的改变来补偿。我们很快将看到这是如何运作的。

为了解决这个带约束的优化问题，我们为 (7.5) 中的每个约束引入拉格朗日乘子 $a_n \geq 0$ ，从而得到拉格朗日函数

$$L(\mathbf{w}, b, \mathbf{a}) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{n=1}^N a_n \{t_n (\mathbf{w}^T \phi(\mathbf{x}_n) + b) - 1\} \quad (7.7)$$

其中 $\mathbf{a} = (a_1, \dots, a_N)^T$ 。注意拉格朗日乘子项前的负号，因为我们对 $\mathbf{w}$ 和 b 执行最小化，而对 $\mathbf{a}$ 执行最大化。将 $L(\mathbf{w}, b, \mathbf{a})$ 对 $\mathbf{w}$ 和 b 的导数设为零，可得到以下两个条件

$$\mathbf{w} = \sum_{n=1}^N a_n t_n \phi(\mathbf{x}_n) \quad (7.8)$$

$$0 = \sum_{n=1}^N a_n t_n \quad (7.9)$$

利用这些条件将 $\mathbf{w}$ 和 b 从 $L(\mathbf{w}, b, \mathbf{a})$ 中消去，我们得到最大间隔问题的对偶形式，即最大化

$$\tilde{L}(\mathbf{a}) = \sum_{n=1}^N a_n - \frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N a_n a_m t_n t_m k(\mathbf{x}_n, \mathbf{x}_m) \quad (7.10)$$

满足以下约束

$$a_n \geq 0, \quad n = 1, \dots, N, \quad (7.11)$$

$$\sum_{n=1}^N a_n t_n = 0. \quad (7.12)$$

这里核函数定义为 $k(\mathbf{x}, \mathbf{x}') = \phi(\mathbf{x})^T \phi(\mathbf{x}')$ 。这再次构成一个二次规划问题，即在不等式约束下优化一个关于 $\mathbf{a}$ 的二次函数。我们将在 7.1.1 节讨论求解此类二次规划问题的技术。

一般来说，一个含 M 个变量的二次规划问题具有 $O(M^3)$ 的计算复杂度。在转向对偶形式时，我们把原始问题（需要在 M 个变量上最小化 (7.6)）转化为了具有 N 个变量的对偶问题 (7.10)。如果基函数数量 M 小于数据点数量 N ，这种转化似乎不利。然而，它允许我们使用核方法重构模型，因此最大间隔分类器可以高效地应用于维度远大于数据数量甚至无限维的特征空间。核的形式也清楚地说明了核函数必须是正定的，因为这确保 $\tilde{L}(\mathbf{a})$ 有下界，从而使优化问题良好定义。

在训练好模型后，为了对新数据点进行分类，我们计算 (7.1) 中给出的 $y(\mathbf{x})$ 的符号。利用 (7.8) 代入 $\mathbf{w}$ ，可将其写为：

$$y(\mathbf{x}) = \sum_{n=1}^N a_n t_n k(\mathbf{x}, \mathbf{x}_n) + b \quad (7.13)$$

在附录 E 中，我们展示了这种带约束的优化满足 Karush-Kuhn-Tucker (KKT) 条件，在当前情况下其要求以下三条成立：

$$a_n \geq 0 \quad (7.14)$$

$$t_n y(\mathbf{x}_n) - 1 \geq 0 \quad (7.15)$$

$$a_n \{t_n y(\mathbf{x}_n) - 1\} = 0. \quad (7.16)$$

因此对每个数据点，要么 $a_n = 0$ ，要么 $t_n y(\mathbf{x}_n) = 1$ 。若 $a_n = 0$ ，该数据点不会出现在 (7.13) 的求和中，因此在对新点预测时不起任何作用。剩余的数据点称为支持向量，因为它们满足 $t_n y(\mathbf{x}_n) = 1$ ，对应于位于特征空间中最大间隔超平面上的点，如图 7.1 所示。这一性质对 SVM 的实际应用至关重要：一旦模型训练好，大量数据点都可以丢弃，只保留支持向量。

在求解二次规划问题并得到 $\mathbf{a}$ 后，我们可以确定阈值参数 b 。因为任一支持向量 $\mathbf{x}_n$ 都满足 $t_n y(\mathbf{x}_n) = 1$ 。将 (7.13) 代入得到

$$t_n \left(\sum_{m \in \mathcal{S}} a_m t_m k(\mathbf{x}_n, \mathbf{x}_m) + b \right) = 1 \quad (7.17)$$

其中 $\mathcal{S}$ 表示支持向量的索引集合。虽然选择任一支持向量即可解出 b ，但更稳定的数值方法是先将等式两边乘以 t_n （利用 $t_n^2 = 1$ ），然后对所有支持向量取平均，最终得到：

$$b = \frac{1}{N_{\mathcal{S}}} \sum_{n \in \mathcal{S}} \left(t_n - \sum_{m \in \mathcal{S}} a_m t_m k(\mathbf{x}_n, \mathbf{x}_m) \right) \quad (7.18)$$

其中 $N_{\mathcal{S}}$ 是支持向量的总数。

为了与后续的其他模型进行比较，我们还可以将最大间隔分类器表示为如下的误差函数最小化形式，其中包含一个简单的二次正则项：2


$$\sum_{n=1}^N E_{\infty}(y(\mathbf{x}_n)t_n - 1) + \lambda \|\mathbf{w}\|^2 \quad (7.19)$$

其中 $E_{\infty}(z)$ 在 $z \geq 0$ 时为零，否则为 ∞ ，用于保证满足 (7.5) 中的约束。注意，只要正则化参数满足 $\lambda > 0$ ，其具体数值并不重要。

图 7.2 展示了在一个简单的合成数据集上，以形式 (6.23) 的高斯核训练支持向量机所得到的分类结果。尽管该数据集在二维数据空间 $\mathbf{x}$ 中并不可线性分离，但在由非线性核函数隐式定义的非线性特征空间中却是线性可分的。因此，在原始数据空间中，训练数据点实现了完全分离。

这个例子也从几何角度揭示了 SVM 稀疏性的来源。最大间隔超平面完全由支持向量的位置决定。其他数据点只要保持在间隔区域之外，就可以自由移动，而不会改变决策边界，因此最终的解对这类数据点是无关的。

图 7.2 使用各向同性高核对正弦数据集进行 Nadaraya-Watson 核回归模型的示意图。绿色曲线表示原始正弦函数，蓝色点表示数据点，每个数据点都是一个各向同性高核的中心。由条件均值给出的回归函数用红色曲线表示，两倍标准差范围由红色阴影表示，对应于条件分布 $p(t|x)$ 。每个数据点周围的蓝色椭圆表示对应核的一倍标准差等高线。由于横轴与纵轴的尺度不同，这些等高线看起来并非圆形。



7.1.1 类分布重叠

到目前为止，我们一直假设训练数据在特征空间 $\phi(\mathbf{x})$ 中是线性可分的。由此得到的支持向量机会在原始输入空间 $\mathbf{x}$ 中实现对训练数据的完全分离，尽管对应的决策边界是非线性的。然而在实际应用中，各类别的条件分布往往会重叠，此时对训练数据进行完全分离反而可能导致糟糕的泛化性能。

因此，我们需要一种方法对支持向量机进行修改，使其允许部分训练点被错误分类。从 (7.19) 可以看出，在类别可分的情况下，我们隐式采用了一种误差函数：若一个数据点被误分类，其误差为无穷大；若正确分类则误差为零，然后通过最大化间隔来优化模型参数。现在，我们修改这个方法，使得数据点可以落在间隔边界的“错误一侧”，但需要对偏离边界的距离施加惩罚。为后续的优化方便，我们采用线性惩罚。为此，我们为每个训练数据点 (Bennett, 1992; Cortes 和 Vapnik, 1995) 引入松弛变量 $\xi_n \geq 0$ ，定义为：对位于正确间隔边界之上或之内的点， $\xi_n = 0$ ；其他点取 $\xi_n = |t_n - y(\mathbf{x}_n)|$ 。因此若数据点位于决策边界 $y(\mathbf{x}_n) = 0$ ，则 $\xi_n = 1$ ；若 $\xi_n > 1$ 则该点被误分类。原来的精确分类约束 (7.5) 被替换为

$$t_n y(\mathbf{x}_n) \geq 1 - \xi_n, \quad n = 1, \dots, N \quad (7.20)$$

其中松弛变量满足 $\xi_n \geq 0$ 。若 $\xi_n = 0$ ，则该点被正确分类，并且在间隔之上；若 $0 < \xi_n \leq 1$ ，则该点位于间隔内部但仍在正确一侧；若 $\xi_n > 1$ 则它落在决策面错误一侧并被误分类，如图 7.3 所示。这一过程有时被称为从硬间隔放宽到软间隔，允许部分训练样本被误分类。但需要注意，虽然松弛变量允许类别重叠，这种机制对离群点依然敏感，因为误分类惩罚随 ξ 线性增长。


我们的目标是最大化间隔，同时对落在错误侧的点施加适度惩罚。因此我们最小化

$$C \sum_{n=1}^N \xi_n + \frac{1}{2} \|\mathbf{w}\|^2 \quad (7.21)$$

其中 $C > 0$ 控制松弛惩罚与间隔之间的取舍。由于每个被误分类的点均满足 $\xi_n > 1$ ，因此 $\sum_n \xi_n$ 是误分类点数的一个上界。参数 C 类似于正则化系数的倒数，因为它控制训练误差与模型复杂度之间的折中。若取极限 $C \rightarrow \infty$ ，我们会回到类别可分时的 SVM。

图 7.3 展示松弛变量 $\xi_m \geq 0$ 的示意图。

带圆圈的数据点为支持向量。



现在我们希望最小化 (7.21)，其约束由 (7.20) 和 $\xi_n \geq 0$ 给出。相应的拉格朗日函数为

$$L(\mathbf{w}, b, \mathbf{a}) = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{n=1}^N \xi_n - \sum_{n=1}^N a_n \{t_n y(\mathbf{x}_n) - 1 + \xi_n\} - \sum_{n=1}^N \mu_n \xi_n \quad (7.22)$$

其中 $\{a_n \geq 0\}$ 与 $\{\mu_n \geq 0\}$ 为拉格朗日乘子。对应的 KKT 条件为

$$a_n \geq 0 \quad (7.23)$$

$$t_n y(\mathbf{x}_n) - 1 + \xi_n \geq 0 \quad (7.24)$$

$$a_n (t_n y(\mathbf{x}_n) - 1 + \xi_n) = 0 \quad (7.25)$$

$$\mu_n \geq 0 \quad (7.26)$$

$$\xi_n \geq 0 \quad (7.27)$$

$$\mu_n \xi_n = 0 \quad (7.28)$$

其中 $n = 1, \dots, N$ 。

我们现在利用 $y(\mathbf{x})$ 的定义 (7.1)，对 $\mathbf{w}, b, \xi_n$ 求导并令其为零，得到：

$$\frac{\partial L}{\partial \mathbf{w}} = 0 \Rightarrow \mathbf{w} = \sum_{n=1}^N a_n t_n \phi(\mathbf{x}_n) \quad (7.29)$$

$$\frac{\partial L}{\partial b} = 0 \Rightarrow \sum_{n=1}^N a_n t_n = 0 \quad (7.30)$$

$$\frac{\partial L}{\partial \xi_n} = 0 \Rightarrow a_n = C - \mu_n \quad (7.31)$$

利用这些结果消去 $\mathbf{w}, b, \xi_n$ ，得到对偶拉格朗日函数

$$\tilde{L}(\mathbf{a}) = \sum_{n=1}^N a_n - \frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N a_n a_m t_n t_m k(\mathbf{x}_n, \mathbf{x}_m) \quad (7.32)$$

与可分情况完全相同，只是约束条件不同。由于 $a_n \geq 0$ ，并由 (7.31) 与 $\mu_n \geq 0$ 得

到 $a_n \leq C$ ，因此我们要对 $\{a_n\}$ 最小化 (7.32)，其约束为：

$$0 \leq a_n \leq C \quad (7.33)$$

$$\sum_{n=1}^N a_n t_n = 0 \quad (7.34)$$

其中 (7.33) 被称为盒约束 (box constraints)。这再次构成一个二次规划问题。将 (7.29) 代入 (7.1)，可知对新点的预测仍由 (7.13) 给出。

我们现在可以解释最终得到的解。与之前一样，一部分数据点可能满足 $a_n = 0$ ，此时它们不会出现在预测模型 (7.13) 中。剩余的数据点构成支持向量，它们满足 $a_n > 0$ ，因此根据 (7.25) 必须满足

$$t_n y(\mathbf{x}_n) = 1 - \xi_n. \quad (7.35)$$

若 $a_n < C$ ，则由 (7.31) 可知 $\mu_n > 0$ ，而由 (7.28) 可知 $\xi_n = 0$ ，因此这些点位于间隔上。对于满足 $a_n = C$ 的点，它们可以位于间隔内部，并且若 $\xi_n \leq 1$ 则仍被正确分类，若 $\xi_n > 1$ 则被误分类。

为确定 (7.1) 中的参数 b ，注意到那些满足 $0 < a_n < C$ 的支持向量具有 $\xi_n = 0$ ，从而 $t_n y(\mathbf{x}_n) = 1$ ，并因此满足

$$t_n \left(\sum_{m \in S} a_m t_m k(\mathbf{x}_n, \mathbf{x}_m) + b \right) = 1. \quad (7.36)$$

同样，通过取平均可以获得数值上更稳定的解：

$$b = \frac{1}{N_{\mathcal{M}}} \sum_{n \in \mathcal{M}} \left(t_n - \sum_{m \in S} a_m t_m k(\mathbf{x}_n, \mathbf{x}_m) \right) \quad (7.37)$$

其中 $\mathcal{M}$ 表示满足 $0 < a_n < C$ 的数据点的索引集合。

一种替代且等价的支持向量机形式被称为 ν -SVM，由 Schölkopf 等人 (2000) 提出。它需要最大化

$$\tilde{L}(\mathbf{a}) = -\frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N a_n a_m t_n t_m k(\mathbf{x}_n, \mathbf{x}_m) \quad (7.38)$$

满足如下约束：


$$0 \leq a_n \leq \frac{1}{N} \quad (7.39)$$

$$\sum_{n=1}^N a_n t_n = 0 \quad (7.40)$$

$$\sum_{n=1}^N a_n \geq \nu. \quad (7.41)$$

这种方法的优点是，参数 ν (替代了 C) 可以同时被解释为：一方面，它是间隔误差比例的上界 (即 $\xi_n > 0$ 的点，占据错误一侧间隔边界，可能被误分类或未被误分类)；另

图 7.4 展示将 ν -SVM 应用于二维不可分数据集的示意图。支持向量用圆图标出。



一方面，它是支持向量比例的下界。图 7.4 给出了 ν -SVM 在一个合成数据集上的示例。这里使用了形如 $\exp(-\gamma\|\mathbf{x} - \mathbf{x}'\|^2)$ 的高斯核，取 $\gamma = 0.45$ 。

尽管对新样本的预测只依赖支持向量，但训练阶段（即确定参数 $\mathbf{a}$ 和 b ）却需要使用整个数据集，因此需要有效的算法来求解二次规划问题。首先注意到 (7.10) 或 (7.32) 中的目标函数 $\tilde{L}(\mathbf{a})$ 是二次函数，因此只要约束定义的区域是凸的（本例中由线性约束保证），任何局部最优解也是全局最优解。

直接利用传统技术求解二次规划常常难以实现，因为计算与内存需求非常高，因此需要更实际的方法。Vapnik (1982) 提出的 **chunking** 技术利用了这样一个事实：若我们从核矩阵中移除那些对应 $a_n = 0$ 的行与列，拉格朗日函数的值保持不变。这样可以将完整的二次规划问题分解为一系列较小的问题，其目标是逐步识别所有非零的拉格朗日乘子，并丢弃其他乘子。**Chunking** 可以利用受保护的共轭梯度法实现 (Burges, 1998)。尽管 **chunking** 将矩阵规模从“数据点数的平方”降低到“大约非零拉格朗日乘子数的平方”，但即便如此，对于大规模应用，这个矩阵仍可能过大而无法存放于内存中。

分解方法 (Osuna et al., 1996) 同样将问题拆解为一系列小型的二次规划问题，但每个子问题的规模是固定的，因此可以用于任意大规模数据集。然而这些方法仍然需要数值求解二次规划子问题，可能代价高昂且容易出问题。

其中最受欢迎的 SVM 训练方法之一是序列最小优化 (sequential minimal optimization, SMO) (Platt, 1999)。它将 **chunking** 的思想推到极限：每次仅优化两个拉格朗日乘子。对这两个变量的子问题可以解析求解，从而完全避免数值二次规划。SMO 提供了启发式方法来选择每次要优化的乘子对。在实践中，根据应用场景不同，SMO 的时间复杂度通常介于线性与二次之间。

我们已经看到，核函数对应于特征空间中的内积，而这些特征空间可能具有非常高，甚至无限的维度。由于我们直接使用核函数而不显式地构造特征空间，SVM 似乎能够避免维度灾难。然而事实并非如此，因为特征值之间存在约束，这些约束限制了特征空间的有效维度。为了说明这一点，考虑一个简单的二阶多项式核，我们可以将其展开为

$$\begin{aligned}
k(\mathbf{x}, \mathbf{z}) &= (1 + \mathbf{x}^T \mathbf{z})^2 = (1 + x_1 z_1 + x_2 z_2)^2 \\
&= 1 + 2x_1 z_1 + 2x_2 z_2 + x_1^2 z_1^2 + 2x_1 x_2 z_1 z_2 + x_2^2 z_2^2 \\
&= (1, \sqrt{2}x_1, \sqrt{2}x_2, x_1^2, \sqrt{2}x_1 x_2, x_2^2)(1, \sqrt{2}z_1, \sqrt{2}z_2, z_1^2, \sqrt{2}z_1 z_2, z_2^2)^T \\
&= \phi(\mathbf{x})^T \phi(\mathbf{z})
\end{aligned} \tag{7.42}$$

因此该核函数表示特征空间中的一次内积，该特征空间具有六维，映射由向量函数 $\phi(\mathbf{x})$ 描述。然而，不同特征的系数被严格限制为特定的形式。因此，原始二维空间 $\mathbf{x}$ 中的任意点映射到六维特征空间时，都被限制在一个二维的非线性流形上。

我们已经强调过，SVM 本身并不提供概率输出，而是对新的输入向量给出分类决策。Veropoulos 等人（1999）讨论了对 SVM 进行修改，以便在假阳性与假阴性之间进行权衡。然而，如果我们希望将 SVM 作为更大概率系统中的一个模块，那么就需要对新输入 $\mathbf{x}$ 的类别标签 t 进行概率预测。

为了解决这个问题，Platt（2000）提出在经过训练的 SVM 输出上拟合一个逻辑 sigmoid 函数。具体地，所需的条件概率被假设为

$$p(t = 1 | \mathbf{x}) = \sigma(Ay(\mathbf{x}) + B) \tag{7.43}$$

其中 $y(\mathbf{x})$ 由 (7.1) 给出。参数 A 和 B 通过最小化交叉熵误差来确定，训练集由成对的数据 $(y(\mathbf{x}_n), t_n)$ 组成。用于拟合 sigmoid 的数据必须独立于用于训练原始 SVM 的数据，以避免严重的过拟合。

这种两阶段方法等价于假设 SVM 的输出 $y(\mathbf{x})$ 表示输入 $\mathbf{x}$ 属于类别 $t = 1$ 的对数似然比。然而，SVM 的训练过程并非是为了优化这一点，因此它往往无法很好地逼近后验概率（Tipping, 2001）。

7.1.2 与逻辑回归的关系

与可分情形一样，对于不可分布的情况，我们可以将支持向量机重新表述为一个正则化误差函数的最小化问题。这也使我们能够突出其与逻辑回归模型的相似与不同之处。

我们已经看到，对于处在间隔边界正确一侧的数据点，因此满足 $y_n t_n \geq 1$ 的情形，有 $\xi_n = 0$ ；而对于其余的点，有 $\xi_n = 1 - y_n t_n$ 。因此，目标函数 (7.21) 可以写成（忽略一个整体的乘法常数）下面的形式：


$$\sum_{n=1}^N E_{SV}(y_n t_n) + \lambda \|\mathbf{w}\|^2 \tag{7.44}$$

其中 $\lambda = (2C)^{-1}$ ，并且 $E_{SV}(\cdot)$ 为铰链损失函数，定义为

$$E_{SV}(y_n t_n) = [1 - y_n t_n]_+ \tag{7.45}$$

其中 $[\cdot]_+$ 表示取正部分。铰链误差函数之所以得名，是因为其形状类似铰链，其图像绘于图 7.5 中。它可以被看作对误分类误差的近似，即我们理想情况下希望最小化的误差函数，图 7.5 中也给出了该误差。

图 7.5 支持向量机中使用的“铰链”误差函数以蓝色显示，同时给出了逻辑回归的误差函数（缩放了 $1/\ln(2)$ 的因子以使其通过点 $(0, 1)$ ），以红色显示。误分类误差以黑色显示，平方误差以绿色显示。



当我们在第 4.3.2 节讨论逻辑回归模型时，发现使用目标变量 $t \in \{0, 1\}$ 会更方便。为了与支持向量机比较，我们首先将最大似然逻辑回归改写为使用目标变量 $t \in \{-1, 1\}$ 。为此，注意到 $p(t = 1 | y) = \sigma(y)$ ，其中 $y(\mathbf{x})$ 由 (7.1) 给出，而 $\sigma(y)$ 是由 (4.59) 定义的逻辑 sigmoid 函数。由此可得 $p(t = -1 | y) = 1 - \sigma(y) = \sigma(-y)$ ，这里使用了 sigmoid 函数的性质，因此我们可以写成

$$p(t | y) = \sigma(yt) \quad (7.46)$$

由此，通过对似然函数取负对数并加入二次正则项，我们可以构造一个误差函数，其形式为

$$\sum_{n=1}^N E_{\text{LR}}(y_n t_n) + \lambda \|\mathbf{w}\|^2 \quad (7.47)$$

其中

$$E_{\text{LR}}(yt) = \ln(1 + \exp(-yt)). \quad (7.48)$$

为了与其他误差函数比较，我们可以除以 $\ln(2)$ ，使得误差函数经过点 $(0, 1)$ 。该重新缩放后的误差函数也绘于图 7.5 中，可以看到它的形式与支持向量误差函数相似。主要区别在于 $E_{\text{SV}}(yt)$ 中的平坦区域会导致稀疏解。

逻辑误差和铰链损失都可以看作对误分类误差的连续逼近。另一个用于解决分类问题的连续误差函数是平方误差，其图像也在图 7.5 中给出。然而，它具有这样一种性质：对于那些被正确分类且远离决策边界的数据点会赋予越来越大的权重。这些点会被强烈强调，而误分类的点反而被削弱。因此，如果目标是最小化误分类率，那么一个单调递减的误差函数会是更好的选择。

7.1.3 多类支持向量机

支持向量机本质上是一个二分类模型。然而在实际应用中，我们经常需要解决包含 $K > 2$ 个类别的问题。因此，人们提出了多种将多个二类 SVM 组合起来以构建多类分类器的方法。

一种常用的方法 (Vapnik, 1998) 是构建 K 个独立的 SVM, 其中第 k 个模型 $y_k(\mathbf{x})$ 使用来自类别 C_k 的数据作为正样本, 来自其余 $K - 1$ 个类别的数据作为负样本进行训练。这被称为“一对其余”(one-versus-the-rest) 方法。然而, 在图 4.2 中我们看到, 直接使用这些分类器的决策可能导致不一致的结果, 即同一个输入可能被同时判为多个类别。为此有时会使用如下方式来对新的输入 $\mathbf{x}$ 做预测:

$$y(\mathbf{x}) = \max_k y_k(\mathbf{x}). \quad (7.49)$$

然而, 这种启发式方法存在一个问题: 不同的分类器是基于不同的任务训练出来的, 无法保证来自不同分类器的实值输出 $y_k(\mathbf{x})$ 具有可比的尺度。

“一对其余”方法的另一个问题是训练集不平衡。例如, 如果有十个类别且每个类别的训练数据量相同, 那么每个分类器将基于 90

Weston 和 Watkins (1999) 提出了一种单一的目标函数, 用于同时训练全部 K 个 SVM, 使每个分类器与其余类别之间的间隔最大化。但是这会导致训练速度显著下降, 因为需要解决一个规模为 $(K - 1)N$ 的优化问题, 总成本为 $O(K^2 N^2)$, 而不是解决 K 个每个包含 N 个数据点的优化问题 (总体成本为 $O(KN^2)$)。

另一种方法是对所有类别的成对组合训练 $K(K - 1)/2$ 个二分类 SVM, 然后根据测试点在这些分类器中的“投票”结果来决定其类别, 即所谓的“一对一”(one-versus-one) 方法。图 4.2 中我们也看到, 这可能导致分类结果的歧义。此外, 当 K 很大时, 该方法的训练时间比“一对其余”方法显著增加。在测试阶段, 它也需要更多的计算。

后一种问题可以通过将成对分类器组织成一个有向无环图 (不要与概率图模型混淆) 来缓解, 这就是 DAGSVM (Platt et al., 2000)。对于 K 个类别, DAGSVM 总共需要 $K(K - 1)/2$ 个分类器, 而在对一个新测试点分类时, 只需评估 $K - 1$ 个成对分类器, 具体使用哪些分类器取决于在图中所走的路径。

另一种多类分类方法基于纠错输出码 (error-correcting output codes), 由 Dietterich 和 Bakiri (1995) 提出, 并由 Allwein 等人 (2000) 应用于支持向量机。这可以看作“一对一”投票机制的推广, 通过使用更一般的类别划分来训练单个分类器。 K 个类别被表示为由选择的二类分类器给出的特定响应模式, 并借助适当的解码策略, 这种方法能够增强对错误的鲁棒性并减少分类器输出的歧义。尽管将 SVM 应用于多类分类问题仍然是一个未完全解决的课题, 但在实际中, “一对其余”方法仍然最为常用, 尽管它具有一定的启发式性质和实际局限。

也存在单类支持向量机, 它们解决的是与概率密度估计相关的无监督学习问题。然而, 这些方法并不是对数据的密度进行建模, 而是试图找到一个光滑的边界, 用来包围一个高密度区域。该边界被选择为密度的一个分位点, 即从分布中抽取的数据点落在该区域内的概率是一个事先指定的介于 0 与 1 之间的固定数值。这比估计完整的密度要受限得多, 但在某些特定应用中可能已足够。

针对这一问题, 有两种利用支持向量机的方法被提出。Schölkopf 等人 (2001) 的方法试图找到一个超平面, 使其能够将除固定比例 ν 的训练数据外的所有数据点与原

点分开，同时最大化该超平面与原点之间的距离（间隔）。而 Tax 和 Duin（1999）的方法则是在特征空间中寻找包含除比例 ν 的数据点之外所有数据点的最小球体。

对于核函数 $k(\mathbf{x}, \mathbf{x}')$ 仅依赖于 $\mathbf{x} - \mathbf{x}'$ 的情况，这两种算法是等价的。

7.1.4 回归支持向量机

现在我们将支持向量机扩展到回归问题，同时保持其稀疏性的特性。在简单线性回归中，我们最小化的正则化误差函数为


$$\frac{1}{2} \sum_{n=1}^N \{y_n - t_n\}^2 + \frac{\lambda}{2} \|\mathbf{w}\|^2. \quad (7.50)$$

为了得到稀疏解，需要将这个二次误差函数替换为一个 ϵ -不敏感误差函数（Vapnik, 1995）。它的特点是：如果预测 $y(\mathbf{x})$ 与目标 t 的绝对误差小于 ϵ （其中 $\epsilon > 0$ ），则误差为零。一个简单的 ϵ -不敏感误差函数示例如下，它在不敏感区外具有线性代价：

$$E_e(y(\mathbf{x}) - t) = \begin{cases} 0, & \text{if } |y(\mathbf{x}) - t| < \epsilon; \\ |y(\mathbf{x}) - t| - \epsilon, & \text{otherwise} \end{cases} \quad (7.51)$$

其示意图见图 7.6。

图 7.6 ϵ -不敏感误差函数的图（红色），在不敏感区域之外误差随距离线性增加。作为对比，还显示了二次误差函数（绿色）。



因此，我们最小化的正则化误差函数为

$$C \sum_{n=1}^N E_e(y(\mathbf{x}_n) - t_n) + \frac{1}{2} \|\mathbf{w}\|^2 \quad (7.52)$$

其中 $y(\mathbf{x})$ 由 (7.1) 给出。按照惯例，逆正则化参数 C 位于误差项前。


与之前类似，我们通过引入松弛变量来重写优化问题。对每个数据点 $\mathbf{x}_n$ ，现在需要两个满足 $\xi_n \geq 0$ 和 $\hat{\xi}_n \geq 0$ 的松弛变量，其中若 $t_n > y(\mathbf{x}_n) + \epsilon$ 则 $\xi_n > 0$ ；若 $t_n < y(\mathbf{x}_n) - \epsilon$ 则 $\hat{\xi}_n > 0$ 。示意图见图 7.7。

目标点落在 ϵ -管内的条件是 $y_n - \epsilon \leq t_n \leq y_n + \epsilon$ ，其中 $y_n = y(\mathbf{x}_n)$ 。引入松弛变量允许点落在管外，只要松弛变量非零，对应的条件变为

$$t_n \leq y(\mathbf{x}_n) + \epsilon + \xi_n \quad (7.53)$$

$$t_n \geq y(\mathbf{x}_n) - \epsilon - \hat{\xi}_n. \quad (7.54)$$

图 7.7 SVM 回归的示意图，显示了回归曲线以及 ϵ 不敏感“管道”。图中还展示了松弛变量 ξ 和 $\hat{\xi}$ 的示例。位于 ϵ 管道上方的点满足 $\xi > 0$ 且 $\hat{\xi} = 0$ ，位于 ϵ 管道下方的点满足 $\xi = 0$ 且 $\hat{\xi} > 0$ ，而位于 ϵ 管道内部的点满足 $\xi = \hat{\xi} = 0$ 。



支持向量回归的误差函数因此写成

$$C \sum_{n=1}^N (\xi_n + \hat{\xi}_n) + \frac{1}{2} \|\mathbf{w}\|^2 \quad (7.55)$$

其需要在约束 $\xi_n \geq 0$ 、 $\hat{\xi}_n \geq 0$ 以及 (7.53) 和 (7.54) 下最小化。为此，引入拉格朗日乘子 $a_n \geq 0$ 、 $\hat{a}_n \geq 0$ 、 $\mu_n \geq 0$ 、 $\hat{\mu}_n \geq 0$ ，并优化以下拉格朗日函数

$$L = C \sum_{n=1}^N (\xi_n + \hat{\xi}_n) + \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{n=1}^N (\mu_n \xi_n + \hat{\mu}_n \hat{\xi}_n) - \sum_{n=1}^N a_n (\epsilon + \xi_n + y_n - t_n) - \sum_{n=1}^N \hat{a}_n (\epsilon + \hat{\xi}_n - y_n + t_n). \quad (7.56)$$

现在利用 (7.1) 代入 $y(\mathbf{x})$ ，并令 L 对 $\mathbf{w}$ 、 b 、 ξ_n 、 $\hat{\xi}_n$ 的偏导等于零，可得

$$\frac{\partial L}{\partial \mathbf{w}} = 0 \Rightarrow \mathbf{w} = \sum_{n=1}^N (a_n - \hat{a}_n) \phi(\mathbf{x}_n) \quad (7.57)$$

$$\frac{\partial L}{\partial b} = 0 \Rightarrow \sum_{n=1}^N (a_n - \hat{a}_n) = 0 \quad (7.58)$$

$$\frac{\partial L}{\partial \xi_n} = 0 \Rightarrow a_n + \mu_n = C \quad (7.59)$$

$$\frac{\partial L}{\partial \hat{\xi}_n} = 0 \Rightarrow \hat{a}_n + \hat{\mu}_n = C \quad (7.60)$$

利用这些结果将相应变量从拉格朗日函数中消去，我们看到对偶问题需要最大化

$$\begin{aligned} \tilde{L}(\mathbf{a}, \hat{\mathbf{a}}) = & -\frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N (a_n - \hat{a}_n)(a_m - \hat{a}_m) k(\mathbf{x}_n, \mathbf{x}_m) \\ & - \epsilon \sum_{n=1}^N (a_n + \hat{a}_n) + \sum_{n=1}^N (a_n - \hat{a}_n) t_n \end{aligned} \quad (7.61)$$

关于变量 $\{a_n\}$ 和 $\{\hat{a}_n\}$ 的最大化，其中核函数定义为 $k(\mathbf{x}, \mathbf{x}') = \phi(\mathbf{x})^T \phi(\mathbf{x}')$ 。这仍然是一个带约束的最大化问题。由于 $a_n \geq 0$ 和 $\hat{a}_n \geq 0$ 是拉格朗日乘子，而 $\mu_n \geq 0$ 和 $\hat{\mu}_n \geq 0$ 联合 (7.59) 和 (7.60) 又要求 $a_n \leq C$ 、 $\hat{a}_n \leq C$ ，因此得到盒型约束：

$$0 \leq a_n \leq C \quad (7.62)$$

$$0 \leq \hat{a}_n \leq C \quad (7.63)$$

以及条件 (7.58)。

将 (7.57) 代入 (7.1)，我们得到对新输入的预测为

$$y(\mathbf{x}) = \sum_{n=1}^N (a_n - \hat{a}_n) k(\mathbf{x}, \mathbf{x}_n) + b \quad (7.64)$$

这再次以核函数的形式表达。

对应的 KKT 条件 (Karush-Kuhn-Tucker)，即在最优解处对偶变量与相应约束的乘积必须为零，可写为

$$a_n(\epsilon + \xi_n + y_n - t_n) = 0 \quad (7.65)$$

$$\hat{a}_n(\epsilon + \hat{\xi}_n - y_n + t_n) = 0 \quad (7.66)$$

$$(C - a_n)\xi_n = 0 \quad (7.67)$$

$$(C - \hat{a}_n)\hat{\xi}_n = 0. \quad (7.68)$$

由此可得几个重要结果。首先，若 $a_n \neq 0$ ，则必须有 $\epsilon + \xi_n + y_n - t_n = 0$ ，这意味着该点要么位于 ϵ -管的边界上（此时 $\xi_n = 0$ ），要么在边界之外（此时 $\xi_n > 0$ ）。类似地，若 $\hat{a}_n \neq 0$ ，则有 $\epsilon + \hat{\xi}_n - y_n + t_n = 0$ ，说明该点位于或低于 ϵ -管的下边界。

进一步地，上述两个条件不可能同时成立，因为它们相加会导致与 $\xi_n, \hat{\xi}_n \geq 0$ 且 $\epsilon > 0$ 相矛盾。因此，对于每个数据点，要么 a_n 为零，要么 $\hat{a}_n$ 为零，或者两者都为零。

支持向量由满足 $a_n \neq 0$ 或 $\hat{a}_n \neq 0$ 的点构成，也就是在式 (7.64) 中实际参与预测的点。这些点要么正好落在 ϵ -管的边界上，要么位于管外。所有管内的点都有 $a_n = \hat{a}_n = 0$ 。因此解是稀疏的，预测模型 (7.64) 中只需考虑支持向量对应的项。

参数 b 可以通过找到满足 $0 < a_n < C$ 的点来求得。根据 (7.67)，这类点必须满足 $\xi_n = 0$ ，并根据 (7.65) 满足 $\epsilon + y_n - t_n = 0$ 。将 (7.1) 代入并求解 b ：

$$\begin{aligned} b &= t_n - \epsilon - \mathbf{w}^T \phi(\mathbf{x}_n) \\ &= t_n - \epsilon - \sum_{m=1}^N (a_m - \hat{a}_m) k(\mathbf{x}_n, \mathbf{x}_m) \end{aligned} \quad (7.69)$$

其中用到了 (7.57)。对于满足 $0 < \hat{a}_n < C$ 的点也可以得到类似表达，实践中通常对所有可用的估计求平均。

与分类情况类似，回归 SVM 也有另一种形式，其中用于控制模型复杂度的参数更加直观 (Schölkopf et al., 2000)。此时不再固定不敏感区宽度 ϵ ，而是固定一个参数 ν ，它约束落在管外的点的比例。需要最大化

$$\begin{aligned} \tilde{L}(\mathbf{a}, \hat{\mathbf{a}}) &= -\frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N (a_n - \hat{a}_n)(a_m - \hat{a}_m) k(\mathbf{x}_n, \mathbf{x}_m) \\ &\quad + \sum_{n=1}^N (a_n - \hat{a}_n) t_n \end{aligned} \quad (7.70)$$

满足以下约束：

$$0 \leq a_n \leq C/N \quad (7.71)$$

$$0 \leq \hat{a}_n \leq C/N \quad (7.72)$$


$$\sum_{n=1}^N (a_n - \hat{a}_n) = 0 \quad (7.73)$$

$$\sum_{n=1}^N (a_n + \hat{a}_n) \leq \nu C. \quad (7.74)$$

可以证明，最多有 νN 个数据点落在不敏感区之外，而至少有 νN 个数据点是支持向量，因此位于管上或管外。

图 7.8 给出了利用支持向量机求解回归问题的示例，这里使用了一个正弦数据集。参数 ν 和 C 是手工选择的，实际应用中通常通过交叉验证来确定。

图 7.8 将 ν -SVM 回归应用于使用高斯核的正弦合成数据集的示意图。红色曲线为预测的回归曲线， ϵ 不敏感管道对应于阴影区域。绿色点表示数据点，其中作为支持向量的点用蓝色圆圈标出。



7.1.5 计算学习理论

从历史上看，支持向量机在很大程度上是基于一种称为计算学习理论的理论框架进行动机阐述和分析的，该理论有时也被称为统计学习理论（Anthony and Biggs, 1992; Kearns and Vazirani, 1994; Vapnik, 1995; Vapnik, 1998）。它起源于 Valiant (1984) 提出的“可能近似正确”（probably approximately correct, PAC）学习框架。PAC 框架的目标是理解为了获得良好的泛化能力，数据集需要多大规模。它还给出了学习过程计算代价的界限，不过这里我们不对此进行讨论。

设大小为 N 的数据集 $\mathcal{D}$ 来自某个联合分布 $p(\mathbf{x}, \mathbf{t})$ ，其中 $\mathbf{x}$ 表示输入变量， $\mathbf{t}$ 表示类别标签。我们将注意力限制在“无噪声”的情形，即类别标签由某个（未知的）确定性函数 $\mathbf{t} = \mathbf{g}(\mathbf{x})$ 所决定。在 PAC 学习中，我们称从函数空间 $\mathcal{F}$ 中选取、并基于训练集 $\mathcal{D}$ 得到的函数 $\mathbf{f}(\mathbf{x}; \mathcal{D})$ 具有良好泛化能力，如果其期望错误率低于某个预先指定的阈值 ϵ ，即满足

$$\mathbb{E}_{\mathbf{x}, \mathbf{t}}[I(\mathbf{f}(\mathbf{x}; \mathcal{D}) \neq \mathbf{t})] < \epsilon \quad (7.75)$$

其中 $I(\cdot)$ 为指示函数，期望是相对于分布 $p(\mathbf{x}, \mathbf{t})$ 计算的。左侧的量是一个随机变量，因为它依赖于训练集 $\mathcal{D}$ ，而 PAC 框架要求，当数据集 $\mathcal{D}$ 从分布 $p(\mathbf{x}, \mathbf{t})$ 中随机抽取时，上

式以大于 $1 - \delta$ 的概率成立。这里 δ 是另一个预先指定的参数，“可能近似正确”这一术语来源于这样一个要求：以高概率（大于 $1 - \delta$ ），错误率是小的（小于 ϵ ）。对于给定的模型空间 $\mathcal{F}$ 以及给定的参数 ϵ 和 δ ，PAC 学习旨在给出满足该准则所需的最小数据集规模 N 的界限。PAC 学习中的一个关键量是 Vapnik-Chervonenkis 维（VC 维），它用于度量函数空间的复杂度，并使得 PAC 框架能够扩展到包含无限多个函数的空间。

在 PAC 框架中推导得到的界通常被描述为最坏情况的界，因为它们适用于分布 $p(\mathbf{x}, \mathbf{t})$ 的任意选择，只要训练样本和测试样本（相互独立地）来自同一分布，并且适用于函数 $\mathbf{f}(\mathbf{x})$ 的任意选择，只要该函数属于 $\mathcal{F}$ 。在现实世界的机器学习应用中，我们所处理的分布往往具有显著的规律性，例如输入空间中的大区域对应相同的类别标签。由于对分布形式未作任何假设，PAC 界往往非常保守，也就是说，它们严重高估了为达到给定泛化性能所需的数据集规模。正因如此，PAC 界在实际应用中几乎没有得到使用。

为改进 PAC 界的紧致性，有人提出了 PAC-Bayesian 框架（McAllester, 2003），该框架在函数空间 $\mathcal{F}$ 上考虑一个分布，在某种程度上类似于贝叶斯方法中的先验分布。该方法仍然允许对 $p(\mathbf{x}, \mathbf{t})$ 作任意选择，因此尽管界更加紧致，但依然相当保守。

7.2 相关向量机

支持向量机已经被广泛用于分类和回归任务。然而，它们存在一些局限性，其中一些已经在本章中提到。特别是，SVM 的输出是决策结果而非后验概率；此外，SVM 最初是为二分类设计的，当扩展到 $K > 2$ 个类别时会变得麻烦。模型还包含一个复杂度参数 C 或 ν （回归情况下还包括参数 ϵ ），需要通过交叉验证等保留法来选择。最后，预测表达式是基于以训练样本为中心的核函数的线性组合，并且这些核必须是正定的。

相关向量机（RVM）（Tipping, 2001）是一个用于回归和分类的贝叶斯稀疏核方法，既具有许多与 SVM 相同的优点，同时又避免了其主要缺陷。此外，它通常能得到更加稀疏的模型，因此在保持相当泛化能力的同时，对测试数据的计算速度显著更快。

与 SVM 不同，我们首先介绍 RVM 的回归形式，然后再扩展到分类任务。

7.2.1 回归相关向量机

用于回归的相关向量机是第三章讨论的线性模型的一种具体形式，但使用了不同的先验以得到稀疏解。模型对实值目标变量 t 给出如下条件分布：

$$p(t \mid \mathbf{x}, \mathbf{w}, \beta) = \mathcal{N}(t \mid y(\mathbf{x}), \beta^{-1}) \quad (7.76)$$

其中 $\beta = \sigma^{-2}$ 为噪声精度（噪声方差的倒数），均值由线性模型给出

$$y(\mathbf{x}) = \sum_{i=1}^M w_i \phi_i(\mathbf{x}) = \mathbf{w}^T \boldsymbol{\phi}(\mathbf{x}) \quad (7.77)$$

其中 $\phi_i(\mathbf{x})$ 是固定的非线性基函数，通常包含一个常数项，使对应的权重代表“偏置”。

RVM 的具体构造旨在模仿 SVM 的结构。特别地，基函数由核函数给出，每个训练样本对应一个核。因此，式 (7.77) 变为类似 SVM 的形式

$$y(\mathbf{x}) = \sum_{n=1}^N w_n k(\mathbf{x}, \mathbf{x}_n) + b \quad (7.78)$$

其中 b 为偏置项。这种情况下参数数量为 $M = N + 1$ ，而 $y(\mathbf{x})$ 的形式与 SVM 的预测式 (7.64) 相同，只是其中的系数 a_n 被记作 w_n 。需要强调的是，后续分析对任意基函数均适用，为一般性我们继续使用 (7.77) 的形式。与 SVM 不同，核函数不要求正定，基函数也不必与训练样本在数量或位置上对应。

假设我们有 N 个输入向量的观测值 $\mathbf{x}$ ，将它们组成数据矩阵 $\mathbf{X}$ ，其中第 n 行为 $\mathbf{x}_n^T$ ；对应的目标值为 $\mathbf{t} = (t_1, \dots, t_N)^T$ 。因此似然函数为

$$p(\mathbf{t} | \mathbf{X}, \mathbf{w}, \beta) = \prod_{n=1}^N p(t_n | \mathbf{x}_n, \mathbf{w}, \beta^{-1}). \quad (7.79)$$

接着为参数向量 $\mathbf{w}$ 引入先验，如第三章一样使用零均值高斯先验。RVM 的关键区别在于为每个权重 w_i 引入独立的超参数 α_i 而不是使用共享超参数。于是权重先验为

$$p(\mathbf{w} | \boldsymbol{\alpha}) = \prod_{i=1}^M \mathcal{N}(w_i | 0, \alpha_i^{-1}) \quad (7.80)$$

其中 α_i 是对应权重的精度， $\boldsymbol{\alpha} = (\alpha_1, \dots, \alpha_M)^T$ 。我们将看到，当最大化证据时，许多 α_i 会趋于无穷大，使对应的权重后验集中在零附近，从而基函数被剪枝，得到稀疏模型。

利用 (3.49) 中的线性回归结果，权重的后验分布仍为高斯分布：

$$p(\mathbf{w} | \mathbf{t}, \mathbf{X}, \boldsymbol{\alpha}, \beta) = \mathcal{N}(\mathbf{w} | \mathbf{m}, \boldsymbol{\Sigma}) \quad (7.81)$$

其中均值和协方差为

$$\mathbf{m} = \beta \boldsymbol{\Sigma} \boldsymbol{\Phi}^T \mathbf{t} \quad (7.82)$$

$$\boldsymbol{\Sigma} = (\mathbf{A} + \beta \boldsymbol{\Phi}^T \boldsymbol{\Phi})^{-1} \quad (7.83)$$

这里 $\boldsymbol{\Phi}$ 是 $N \times M$ 的设计矩阵， $\Phi_{ni} = \phi_i(\mathbf{x}_n)$ ， $\mathbf{A} = \text{diag}(\alpha_i)$ 。在 (7.78) 这种特例中， $\boldsymbol{\Phi} = \mathbf{K}$ ，其中 $\mathbf{K}$ 是大小为 $(N + 1) \times (N + 1)$ 的核矩阵，元素为 $k(\mathbf{x}_n, \mathbf{x}_m)$ 。

超参数 $\boldsymbol{\alpha}$ 和 β 的估计基于 2 型最大似然（证据近似），即对权重积分得到边缘似然：

$$p(\mathbf{t} | \mathbf{X}, \boldsymbol{\alpha}, \beta) = \int p(\mathbf{t} | \mathbf{X}, \mathbf{w}, \beta) p(\mathbf{w} | \boldsymbol{\alpha}) d\mathbf{w}. \quad (7.84)$$

由于是两个高斯的卷积，可以直接得到对数边缘似然：

$$\begin{aligned} \ln p(\mathbf{t} | \mathbf{X}, \boldsymbol{\alpha}, \beta) &= \ln \mathcal{N}(\mathbf{t} | \mathbf{0}, \mathbf{C}) \\ &= -\frac{1}{2} \{N \ln(2\pi) + \ln |\mathbf{C}| + \mathbf{t}^T \mathbf{C}^{-1} \mathbf{t}\} \end{aligned} \quad (7.85)$$

其中

$$\mathbf{C} = \beta^{-1} \mathbf{I} + \boldsymbol{\Phi} \mathbf{A}^{-1} \boldsymbol{\Phi}^T. \quad (7.86)$$

目标是最大化 (7.85) 关于超参数 α 与 β 。结果几乎与第三章线性模型的证据近似相同。通过令对数边缘似然的导数为零，可得重估公式：

$$\alpha_i^{\text{new}} = \frac{\gamma_i}{m_i^2} \quad (7.87)$$

$$(\beta^{\text{new}})^{-1} = \frac{\|\mathbf{t} - \Phi \mathbf{m}\|^2}{N - \sum_i \gamma_i} \quad (7.88)$$

其中 m_i 为 posterior 均值 $\mathbf{m}$ 的第 i 个分量。量 γ_i 衡量参数 w_i 由数据确定的程度，定义为

$$\gamma_i = 1 - \alpha_i \Sigma_{ii}, \quad (7.89)$$

其中 Σ_{ii} 为 posterior 协方差矩阵 Σ 的对角元。

学习过程因此如下：选择初始的 α 和 β ，利用 (7.82) 和 (7.83) 计算后验均值与协方差，再利用 (7.87)、(7.88) 更新超参数，然后再次计算后验分布，如此交替进行直到收敛。

第二种方法是使用 EM 算法，相关内容见 9.3.4 节。这两种最大化证据的方法在形式上是等价的。然而在数值计算中发现，与 (7.87) 和 (7.88) 对应的直接优化方法收敛速度更快一些 (Tipping, 2001)。

经过优化后，会有一部分超参数 $\{\alpha_i\}$ 被推到很大的值（原则上趋于无穷大），因此对应的权重参数 w_i 的后验分布的均值和方差都为零。于是这些参数以及对应的基函数 $\phi_i(x)$ 会被从模型中“移除”，不再参与对新输入的预测。在 (7.78) 形式的模型中，剩余的非零权重所对应的输入 $\mathbf{x}_n$ 被称为相关向量 (relevance vectors)，它们是通过自动相关性确定机制识别出来的，与 SVM 的支持向量相类似。不过需要强调的是，这种通过自动相关性确定机制在概率模型中实现稀疏性的方式具有普适性，可以用于任何基于自适应线性组合的模型。

在找到使边缘似然最大化的超参数 α^* 和 β^* 后，我们可以对新的输入 $\mathbf{x}$ 计算关于 t 的预测分布。利用 (7.76) 和 (7.81)，预测分布为

$$\begin{aligned} p(t | \mathbf{x}, \mathbf{X}, \mathbf{t}, \alpha^*, \beta^*) &= \int p(t | \mathbf{x}, \mathbf{w}, \beta^*) p(\mathbf{w} | \mathbf{X}, \mathbf{t}, \alpha^*, \beta^*) d\mathbf{w} \\ &= \mathcal{N}(t | \mathbf{m}^T \phi(\mathbf{x}), \sigma^2(\mathbf{x})) \end{aligned} \quad (7.90)$$


因此预测均值由 (7.76) 给出，其中 $\mathbf{w}$ 取为后验均值 $\mathbf{m}$ ，预测分布的方差为

$$\sigma^2(\mathbf{x}) = (\beta^*)^{-1} + \phi(\mathbf{x})^T \Sigma \phi(\mathbf{x}) \quad (7.91)$$

其中 Σ 由 (7.83) 给出，并将 α 和 β 替换为相应的优化值 α^* 和 β^* 。这正是在线性回归情境中得到的熟悉结果 (3.59)。需要回忆的是，对于局部基函数，在输入空间中缺乏基函数的区域，线性回归模型的预测方差会变得很小。在 RVM 中，由于基函数以数据点为中心，因此在数据域之外进行外推时模型会越来越自信 (Rasmussen 和 Quiñero-Candela, 2005)，这当然是不理想的。高斯过程回归的预测分布不存在这个问题。然而，高斯过程的预测开销通常远高于 RVM。

图 7.9 给出了 RVM 在正弦回归数据集上的示例。这里噪声精度参数 β 也是通过证据最大化确定的。可以看到 RVM 的相关向量数量显著少于 SVM 的支持向量。对于大量的回归和分类任务，RVM 通常得到比 SVM 稀疏一个数量级的模型，因此在测试阶段显著提升处理速度。令人意外的是，这种更强的稀疏性几乎不会降低泛化能力，相比 SVM 常常没有性能损失。

图 7.9 使用与图 7.8 中 ν -SVM 回归模型相同的数据集和相同的高斯核函数进行 RVM 回归的示意图。RVM 的预测分布均值由红色曲线表示，一倍标准差的预测分布由阴影区域表示。绿色点为数据点，蓝色圆圈标出了相关向量。注意，相比图 7.8 中 ν -SVM 的 7 个支持向量，这里只有 3 个相关向量。



RVM 相比 SVM 的主要劣势在于训练需要优化一个非凸函数，因此训练时间可能比对应的 SVM 更长。对于含有 M 个基函数的模型，RVM 需要求解一个 $M \times M$ 矩阵的逆，计算复杂度一般为 $O(M^3)$ 。在类 SVM 的模型 (7.78) 中， $M = N + 1$ 。而 SVM 可以使用二次规模（关于 N ）的高效训练方法。当然，对于 RVM，我们可以从远小于 $N + 1$ 的基函数数量开始训练。更重要的是，在 RVM 中，控制模型复杂度和噪声的参数会在一次训练中自动确定，而在 SVM 中，参数 C 和 ϵ （或 ν ）通常通过交叉验证确定，这需要多次训练。此外，在下一节中，我们将推导一种能显著加快 RVM 训练速度的替代方法。

7.2.2 稀疏性的分析

前面我们已经指出，自动相关性确定（ARD）的机制会把一部分参数推到零。现在我们在相关向量机的背景下，更详细地分析这种稀疏性产生的机制。在这个过程中，我们将得到一种比前面直接优化方法更快的超参数优化过程。

在进入数学分析之前，先从直观层面理解一下贝叶斯线性模型中稀疏性的起源。考虑一个仅包含 $N = 2$ 个观测值 t_1 和 t_2 的数据集，并假设模型只有一个基函数 $\phi(\mathbf{x})$ ，配有超参数 α ，同时噪声为各向同性且精度为 β 。根据 (7.85)，边缘似然为 $p(\mathbf{t} | \alpha, \beta) = \mathcal{N}(\mathbf{t} | 0, \mathbf{C})$ ，其中协方差矩阵为

$$\mathbf{C} = \frac{1}{\beta} \mathbf{I} + \frac{1}{\alpha} \boldsymbol{\varphi} \boldsymbol{\varphi}^T \quad (7.92)$$

这里 $\boldsymbol{\varphi}$ 是 N 维向量 $(\phi(\mathbf{x}_1), \phi(\mathbf{x}_2))^T$ ， $\mathbf{t} = (t_1, t_2)^T$ 。注意，这实际上是一个关于 $\mathbf{t}$ 的零均值高斯过程模型，其协方差为 $\mathbf{C}$ 。给定一个具体观测 $\mathbf{t}$ ，我们的目标是通过最大化边缘似然找到 α^* 和 β^* 。从图 7.10 可以看出，如果 $\boldsymbol{\varphi}$ 的方向与训练数据向量 $\mathbf{t}$ 的方向严重不对齐，那么对应的超参数 α 将被推到 ∞ ，该基函数就会被从模型中剪枝。这是

因为在 β 取最优值的前提下，任何有限的 α 都会降低数据的概率，从而降低 $\mathbf{t}$ 处密度的数值。直观地说，有限的 α 会让分布在远离数据的方向上被拉长，增加数据未观测区域的概率质量，从而降低目标数据向量本身处的密度值。对含有 M 个基向量 $\varphi_1, \dots, \varphi_M$ 的更一般情形来说，直觉是类似的：如果某个基向量与数据向量 $\mathbf{t}$ 对齐得很差，就很可能被剪枝。




图 7.10 展示贝叶斯线性回归模型中稀疏性机制的示意图。训练集的目标向量为 $\mathbf{t} = (t_1, t_2)^T$ ，以叉号表示；模型只有一个基向量 $\varphi = (\phi(x_1), \phi(x_2))^T$ ，且它与目标数据向量 $\mathbf{t}$ 的方向对齐较差。左图展示的是仅具有各向同性噪声的模型，此时 $\mathbf{C} = \beta^{-1}\mathbf{I}$ ，对应 $\alpha = \infty$ ，并将 β 设为其最可能值。右图则展示相同的模型，但取有限的 α 。在每种情况下，红色椭圆表示单位马氏距离，并且两幅图中 $|\mathbf{C}|$ 取相同的值；虚线绿色圆表示噪声项 β^{-1} 的贡献。可以看到，任何有限的 α 都会降低观测数据的概率，因此在最可能的解中，该基向量会被移除。

下面我们在一般含 M 个基函数的情形下，从更数学的角度研究稀疏性机制。作为动机，先注意到在重估公式 (7.87) 中，用来更新 α_i 的右端各项本身也依赖于 α_i 。因此这些只是隐式解，即便在其他 α_j ($j \neq i$) 固定时，要解出单个 α_i 也需要迭代。

这提示我们可以换一种方法来求解 RVM 的优化问题：显式写出边缘似然 (7.85) 对某个特定 α_i 的全部依赖，然后直接求其驻点 (Faul and Tipping, 2002; Tipping and Faul, 2003)。为此，我们首先把 (7.86) 中矩阵 $\mathbf{C}$ 里与 α_i 有关的部分单独提取出来：

$$\begin{aligned}\mathbf{C} &= \beta^{-1}\mathbf{I} + \sum_{j \neq i} \alpha_j^{-1} \varphi_j \varphi_j^T + \alpha_i^{-1} \varphi_i \varphi_i^T \\ &= \mathbf{C}_{-i} + \alpha_i^{-1} \varphi_i \varphi_i^T\end{aligned}\quad (7.93)$$

其中 φ_i 表示 Φ 的第 i 列，是一个 N 维向量，元素为 $(\phi_i(\mathbf{x}_1), \dots, \phi_i(\mathbf{x}_N))$ ；而 φ_n 则表示 Φ 的第 n 行。矩阵 $\mathbf{C}_{-i}$ 表示从 $\mathbf{C}$ 中去掉第 i 个基函数贡献后得到的矩阵。利用矩阵恒等式 (C.7) 和 (C.15)，可以把 $\mathbf{C}$ 的行列式与逆写为

$$|\mathbf{C}| = |\mathbf{C}_{-i}| \left| 1 + \alpha_i^{-1} \varphi_i^T \mathbf{C}_{-i}^{-1} \varphi_i \right| \quad (7.94)$$

$$\mathbf{C}^{-1} = \mathbf{C}_{-i}^{-1} - \frac{\mathbf{C}_{-i}^{-1} \varphi_i \varphi_i^T \mathbf{C}_{-i}^{-1}}{\alpha_i + \varphi_i^T \mathbf{C}_{-i}^{-1} \varphi_i} \quad (7.95)$$

使用这些结果，可以将对数边缘似然（7.85）写成

$$L(\boldsymbol{\alpha}) = L(\boldsymbol{\alpha}_{-i}) + \lambda(\alpha_i) \quad (7.96)$$

其中 $L(\boldsymbol{\alpha}_{-i})$ 表示去掉基函数 φ_i 后的对数边缘似然，而

$$\lambda(\alpha_i) = \frac{1}{2} \left[\ln \alpha_i - \ln(\alpha_i + s_i) + \frac{q_i^2}{\alpha_i + s_i} \right] \quad (7.97)$$

包含了全部关于 α_i 的依赖。这里我们引入了

$$s_i = \boldsymbol{\varphi}_i^T \mathbf{C}_{-i}^{-1} \boldsymbol{\varphi}_i \quad (7.98)$$

$$q_i = \boldsymbol{\varphi}_i^T \mathbf{C}_{-i}^{-1} \mathbf{t} \quad (7.99)$$

其中 s_i 称为稀疏度（sparsity）， q_i 称为 $\boldsymbol{\varphi}_i$ 的质量（quality）。如我们将看到的，当 s_i 相对 q_i 的值较大时，对应基函数 $\boldsymbol{\varphi}_i$ 越可能从模型中被剪枝。“稀疏度”刻画基函数 $\boldsymbol{\varphi}_i$ 与模型中其他基向量的重叠程度，而“质量”则度量基向量 $\boldsymbol{\varphi}_i$ 与训练集目标 $\mathbf{t} = (t_1, \dots, t_N)^T$ 与不含 $\boldsymbol{\varphi}_i$ 的模型预测向量 $\mathbf{y}_{-i}$ 之间误差的对齐程度（Tipping and Faul, 2003）。

边缘似然对 α_i 的驻点由导数


$$\frac{d\lambda(\alpha_i)}{d\alpha_i} = \frac{\alpha_i^{-1} s_i^2 - (q_i^2 - s_i)}{2(\alpha_i + s_i)^2} \quad (7.100)$$

为零给出。解有两种可能形式。注意 $\alpha_i \geq 0$ ，如果 $q_i^2 < s_i$ ，则 $\alpha_i \rightarrow \infty$ 是一个解；反之，如果 $q_i^2 > s_i$ ，则可以解出

$$\alpha_i = \frac{s_i^2}{q_i^2 - s_i}. \quad (7.101)$$

这两类解在图 7.11 中有所示意。可以看到，质量项与稀疏度项的相对大小决定了对应基向量是否会被剪枝。基于对边缘似然二阶导数的更完整分析（Faul and Tipping, 2002）可以证明，这些解确实是 $\lambda(\alpha_i)$ 的唯一极大值。

图 7.11 对数边缘似然 $\lambda(\alpha_i)$ 关于 $\ln \alpha_i$ 的示意图。左图在 $q_i^2 = 4$ 且 $s_i = 1$ （因此 $q_i^2 > s_i$ ）的情况下，在有限的 α_i 处具有单个最大值；右图在 $q_i^2 = 1$ 且 $s_i = 2$ （因此 $q_i^2 < s_i$ ）的情况下，其最大值出现在 $\alpha_i = \infty$ 。



需要注意的是，这种方法在给定其他超参数的情况下，给出了 α_i 的闭式解。除了帮助理解 RVM 中稀疏性的起源之外，这一分析还导出了一个在实践中非常有效的超参数优化算法。该算法使用一组固定的候选基向量，依次遍历它们并决定每个是否应包含在模型中。由此得到的序列式稀疏贝叶斯学习算法描述如下。

顺序稀疏贝叶斯学习算法

1. 若是回归问题，初始化 β 。
2. 使用一个基函数 φ_1 初始化模型，将其超参数 α_1 用 (7.101) 设定，其余 α_j ($j \neq 1$) 初始化为无穷大，这样初始模型中只包含 φ_1 。
3. 计算 Σ 和 $\mathbf{m}$ ，并对所有基函数计算 q_i 和 s_i 。
4. 选取一个候选基函数 φ_i 。
5. 若 $q_i^2 > s_i$ 且 $\alpha_i < \infty$ ，即 φ_i 已在模型中，则用 (7.101) 更新 α_i 。
6. 若 $q_i^2 > s_i$ 且 $\alpha_i = \infty$ ，则将 φ_i 加入模型，并用 (7.101) 计算 α_i 。
7. 若 $q_i^2 \leq s_i$ 且 $\alpha_i < \infty$ ，则从模型中移除基函数 φ_i ，并令 $\alpha_i = \infty$ 。
8. 若是回归问题，更新 β 。
9. 若已收敛则结束，否则回到步骤 3。

注意，当 $q_i^2 \leq s_i$ 且 $\alpha_i = \infty$ 时，基函数 φ_i 已经被排除在模型之外，因此无需操作。在实际计算中，引入以下量会更方便：

$$Q_i = \varphi_i^T \mathbf{C}^{-1} \mathbf{t} \quad (7.102)$$

$$S_i = \varphi_i^T \mathbf{C}^{-1} \varphi_i \quad (7.103)$$

此时质量与稀疏度变量可以写成

$$q_i = \frac{\alpha_i Q_i}{\alpha_i - S_i} \quad (7.104)$$

$$s_i = \frac{\alpha_i S_i}{\alpha_i - S_i} \quad (7.105)$$

注意，当 $\alpha_i = \infty$ 时，有 $q_i = Q_i$ 且 $s_i = S_i$ 。利用 (C.7)，可以写出

$$Q_i = \beta \varphi_i^T \mathbf{t} - \beta^2 \varphi_i^T \Phi \Sigma \Phi^T \mathbf{t} \quad (7.106)$$

$$S_i = \beta \varphi_i^T \varphi_i - \beta^2 \varphi_i^T \Phi \Sigma \Phi^T \varphi_i \quad (7.107)$$

其中 Φ 与 Σ 只包含对应有限超参数 α_i 的基向量。在每一步中，相关计算的复杂度约为 $O(M^3)$ ，这里的 M 是模型中当前处于激活状态的基函数个数，通常远小于训练样本数 N 。

7.2.3 分类中的 RVM

我们可以通过对概率线性分类模型（第四章已讨论）施加 ARD 先验，将相关向量机框架扩展到分类问题。先考虑二分类问题，目标变量 $t \in \{0, 1\}$ 。此时模型为一组基

函数线性组合后，再通过 logistic sigmoid 函数变换：

$$y(\mathbf{x}, \mathbf{w}) = \sigma(\mathbf{w}^T \phi(\mathbf{x})) \quad (7.108)$$

其中 $\sigma(\cdot)$ 是 (4.59) 中定义的 logistic sigmoid 函数。若对权重向量 $\mathbf{w}$ 引入高斯先验，就得到第四章中讨论过的模型。不同之处在于 RVM 使用的是 ARD 先验 (7.80)，即每个权重都配有自己独立的精度超参数。

与回归模型不同，这里我们无法对参数向量 $\mathbf{w}$ 进行解析积分。按照 Tipping (2001) 的做法，我们使用 Laplace 近似，这在 4.5.1 节中已应用于贝叶斯逻辑回归。

我们先初始化超参数向量 α 。在给定这一 α 的情况下，构造关于后验分布的高斯近似，从而得到对边缘似然的近似；最大化该近似边缘似然得到更新的 α ，并重复这一过程直到收敛。

下面更详细地看 Laplace 近似。对于固定 α ，需要通过最大化

$$\begin{aligned} \ln p(\mathbf{w} | \mathbf{t}, \alpha) &= \ln \{p(\mathbf{t} | \mathbf{w})p(\mathbf{w} | \alpha)\} - \ln p(\mathbf{t} | \alpha) \\ &= \sum_{n=1}^N [t_n \ln y_n + (1 - t_n) \ln(1 - y_n)] - \frac{1}{2} \mathbf{w}^T \mathbf{A} \mathbf{w} + \text{const} \end{aligned} \quad (7.109)$$

来找到后验分布的众数，这里 $\mathbf{A} = \text{diag}(\alpha_i)$ 。这一最大化可以通过迭代加权最小二乘 (IRLS) 完成，如 4.3.3 节所述。此时对数后验的梯度与 Hessian 为

$$\nabla \ln p(\mathbf{w} | \mathbf{t}, \alpha) = \Phi^T (\mathbf{t} - \mathbf{y}) - \mathbf{A} \mathbf{w} \quad (7.110)$$

$$\nabla \nabla \ln p(\mathbf{w} | \mathbf{t}, \alpha) = -(\Phi^T \mathbf{B} \Phi + \mathbf{A}) \quad (7.111)$$

其中 $\mathbf{B}$ 是对角矩阵，元素 $b_n = y_n(1 - y_n)$ ，向量 $\mathbf{y} = (y_1, \dots, y_N)^T$ ， Φ 为设计矩阵，元素 $\Phi_{ni} = \phi_i(\mathbf{x}_n)$ 。这里用到了 sigmoid 函数导数的性质 (4.88)。在 IRLS 收敛时，负 Hessian 即为高斯近似后验的协方差矩阵的逆。

将 (7.110) 置零，可以得到 Laplace 近似的均值和协方差：

$$\mathbf{w}^* = \mathbf{A}^{-1} \Phi^T (\mathbf{t} - \mathbf{y}) \quad (7.112)$$

$$\Sigma = (\Phi^T \mathbf{B} \Phi + \mathbf{A})^{-1} \quad (7.113)$$

现在可以用 Laplace 近似计算边缘似然。根据一般公式 (4.135)：

$$\begin{aligned} p(\mathbf{t} | \alpha) &= \int p(\mathbf{t} | \mathbf{w}) p(\mathbf{w} | \alpha) d\mathbf{w} \\ &\simeq p(\mathbf{t} | \mathbf{w}^*) p(\mathbf{w}^* | \alpha) (2\pi)^{M/2} |\Sigma|^{1/2} \end{aligned} \quad (7.114)$$

将 $p(\mathbf{t} | \mathbf{w}^*)$ 和 $p(\mathbf{w}^* | \alpha)$ 代入，并令边缘似然对 α_i 的导数为零，得到

$$-\frac{1}{2} (w_i^*)^2 + \frac{1}{2\alpha_i} - \frac{1}{2} \Sigma_{ii} = 0. \quad (7.115)$$

令 $\gamma_i = 1 - \alpha_i \Sigma_{ii}$ ，整理可得

$$\alpha_i^{\text{new}} = \frac{\gamma_i}{(w_i^*)^2} \quad (7.116)$$

这与回归 RVM 的重估公式 (7.87) 完全一致。

若定义

$$\hat{\mathbf{t}} = \Phi \mathbf{w}^* + \mathbf{B}^{-1}(\mathbf{t} - \mathbf{y}) \quad (7.117)$$

则对数边缘似然的近似形式为

$$\ln p(\mathbf{t} | \boldsymbol{\alpha}, \beta) = -\frac{1}{2} \{ N \ln(2\pi) + \ln |\mathbf{C}| + \hat{\mathbf{t}}^T \mathbf{C}^{-1} \hat{\mathbf{t}} \} \quad (7.118)$$

其中

$$\mathbf{C} = \mathbf{B} + \Phi \mathbf{A} \Phi^T. \quad (7.119)$$

这与回归情形下的 (7.85) 具有相同形式，因此我们可以对稀疏性做同样的分析，并得到同样的快速学习算法：每一步完全优化单个超参数 α_i 。

图 7.12 展示了将 RVM 应用于一个合成分类数据集的结果。可以看到，与 SVM 不同，RVM 的相关向量往往不集中在决策边界附近。这与前面对稀疏性的讨论是一致的：对于位于边界附近的数据点，其对应的基函数 $\phi_i(\mathbf{x})$ 所产生的向量 $\boldsymbol{\varphi}_i$ 往往与训练数据向量 $\mathbf{t}$ 对齐得较差。




图 7.12 将相关向量机应用于一个合成数据集的示例。左图显示决策边界和数据点，其中相关向量用圆圈标出。与图 7.4 中对应的支持向量机结果相比，可以看到 RVM 得到的模型更加稀疏。右图显示由 RVM 输出给出的后验概率，其中红色（蓝色）墨迹的比例表示该点属于红色（蓝色）类别的概率。

相关向量机相较 SVM 的一个潜在优势，是它能给出概率预测。例如，它可以用来构造非线性线性动态系统中观测方程的发射密度，用于视频序列中人脸跟踪（Williams 等人，2005）。

到目前为止，我们只考虑了二分类问题下的 RVM。对于 $K > 2$ 的情形，我们可以再次使用 4.3.4 节中的概率多类模型，其中有 K 个线性模型

$$a_k = \mathbf{w}_k^T \mathbf{x} \quad (7.120)$$

并通过 softmax 函数组合成输出

$$y_k(\mathbf{x}) = \frac{\exp(a_k)}{\sum_j \exp(a_j)}. \quad (7.121)$$

对数似然函数为

$$\ln p(\mathbf{T} \mid \mathbf{w}_1, \dots, \mathbf{w}_K) = \prod_{n=1}^N \prod_{k=1}^K y_{nk}^{t_{nk}} \quad (7.122)$$

其中目标 t_{nk} 对每个样本 n 使用 1-of- K 编码， $\mathbf{T}$ 为元素为 t_{nk} 的矩阵。通过 Laplace 近似可以优化超参数 (Tipping, 2001)，模型与其 Hessian 通过 IRLS 得到。这比 SVM 使用的两两分类方式更为严格，并能为新数据点提供概率预测。然而其主要缺点是 Hessian 的维度为 $MK \times MK$ ，其中 M 是激活基函数的个数，因此训练复杂度相比二分类 RVM 多了一个 K^3 的因子。

总的来说，相关向量机的主要缺点是训练时间相对 SVM 较长；但这在一定程度上被以下优势抵消了：它避免了通过交叉验证来选择模型复杂度参数；并且由于模型更稀疏，在测试点上的计算开销——通常是实践中更关键的部分——往往要小得多。

8 图模型

概率在现代模式识别中扮演着核心角色。我们在第 1 章中看到，概率论可以用两个简单的等式来表达，它们分别对应加法规则和乘法规则。本书中讨论的所有概率推断与学习操作，无论看起来多么复杂，本质上都不过是对这两个等式的反复应用。因此，我们完全可以通过纯代数操作来构建并求解复杂的概率模型。然而，我们会发现，用被称为概率图模型的分布图示表示来辅助分析具有巨大的优势。它们提供了以下几个有用的特性：1. 它们提供了一种简单方式来可视化概率模型的结构，并可用于设计和启发新的模型。2. 可以通过观察图来获得关于模型性质（包括条件独立性性质）的洞见。3. 用于在复杂模型中执行推断与学习的复杂计算，可以表示为图上的操作，而底层的数学表达式则被隐式地携带着。

一个图由节点（也称为顶点）以及连接节点的连线（也称为边或弧）构成。在概率图模型中，每个节点表示一个随机变量（或一组随机变量），而连线表达这些变量之间的概率关系。图捕捉了所有随机变量的联合分布如何分解为一组因子，而每个因子仅依赖于变量的某个子集。我们首先讨论贝叶斯网络，也称为有向图模型，其中图的连线具有特定方向，用箭头表示。另一大类图模型是马尔可夫随机场，也称为无向图模型，其中连线不带箭头，也没有方向意义。有向图适合表达随机变量之间的因果关系，而无向图更适合表达变量之间的软约束。为了便于求解推断问题，将有向图和无向图转换为称为因子图的另一种表示方式通常很有用。

在本章中，我们将专注于图模型在模式识别与机器学习应用中所需的关键方面。关于图模型的更全面论述可参见 Whittaker (1990)、Lauritzen (1996)、Jensen (1996)、Castillo 等 (1997)、Jordan (1999)、Cowell 等 (1999) 以及 Jordan (2007) 等著作。

8.1 贝叶斯网络

为了说明使用有向图来描述概率分布的动机，首先考虑三个变量 a 、 b 和 c 上的任意联合分布 $p(a, b, c)$ 。注意在这个阶段，我们并不需要进一步说明这些变量的任何性质，例如它们是离散的还是连续的。事实上，图模型的一个重要特点是，一个特定的图可以对一大类分布作出概率陈述。根据概率的乘法法则 (1.11)，我们可以将联合分布写为

$$p(a, b, c) = p(c \mid a, b)p(a, b). \quad (8.1)$$


第二次应用乘法法则，这次作用于 (8.1) 右边的第二项，得到

$$p(a, b, c) = p(c \mid a, b)p(b \mid a)p(a). \quad (8.2)$$

注意，这个分解对任意选择的联合分布都成立。现在我们将 (8.2) 右侧用一个简单的图模型表示如下。首先，为随机变量 a 、 b 和 c 中的每一个引入一个节点，并将每个节点与 (8.2) 右侧对应的条件分布关联起来。然后，对于每个条件分布，我们在图中从对应于其条件变量的节点添加有向边（箭头）。因此，对于因子 $p(c \mid a, b)$ ，会有从节点 a 和节点 b 指向节点 c 的边，而对于因子 $p(a)$ 则没有指向它的边。最终得到图 8.1 所示

的图。如果从节点 a 指向节点 b ，则称节点 a 是节点 b 的父节点，而节点 b 是节点 a 的子节点。注意我们不对节点与其对应的变量作正式区分，而是用相同的符号指代二者。

图 8.1 一个有向图模型，用来表示三个变量 a, b, c 的联合概率分布，对应于 (8.2) 右侧的分解形式。



关于 (8.2) 有一点值得注意：左侧在变量 a, b 和 c 之间是对称的，而右侧不是。事实上，在进行 (8.2) 中的分解时，我们隐含地选择了一个特定顺序，即 a, b, c ，如果我们选择不同的顺序，就会得到不同的分解，从而得到不同的图表示。我们将在后面回到这一点。


现在让我们扩展图 8.1 的例子，考虑由 $p(x_1, \dots, x_K)$ 给出的 K 个变量的联合分布。通过反复应用概率的乘法法则，这个联合分布可以写成一个由条件分布构成的乘积，每个变量对应一个条件分布：

$$p(x_1, \dots, x_K) = p(x_K | x_1, \dots, x_{K-1}) \dots p(x_2 | x_1) p(x_1). \quad (8.3)$$

对于给定的 K ，我们同样可以将其表示为一个有 K 个节点的有向图，每个节点对应 (8.3) 右侧的一个条件分布，并且每个节点从所有编号比它小的节点接收有向边。我们称这个图是完全连接的，因为任意一对节点之间都有一条边。

到目前为止，我们处理的是完全一般的联合分布，因此这些分解及其作为完全连接图的表示适用于任意分布的选择。正如我们将很快看到的，图中边的缺失揭示了该图所代表的分布族的有趣性质。考虑图 8.2 所示的图，这不是一个完全连接图，因为例如不存在从 x_1 到 x_2 的边，也不存在从 x_3 到 x_7 的边。

图 8.2 一个有向无环图的示例，用来描述变量 $x_1, \dots, x_7$ 的联合分布。对应的联合分布分解由 (8.4) 给出。



现在我们从这个图出发，写出对应的联合概率分布，用一组条件分布的乘积表示，每个节点对应一个条件分布。每个条件分布仅依赖于图中该节点的父节点。例如， x_5 将依赖于 x_1 和 x_3 。因此，七个变量的联合分布为

$$p(x_1)p(x_2)p(x_3)p(x_4 | x_1, x_2, x_3)p(x_5 | x_1, x_3)p(x_6 | x_4)p(x_7 | x_4, x_5). \quad (8.4)$$

读者应当花一些时间仔细研究 (8.4) 与图 8.2 之间的对应关系。

现在我们可以用一般形式陈述给定有向图与其对应变量分布之间的关系。由一个图定义的联合分布等于图中所有节点对应的条件分布的乘积，每个条件分布依赖于图

中该节点的父节点。因此，对于一个有 K 个节点的图，联合分布为

$$p(\mathbf{x}) = \prod_{k=1}^K p(x_k \mid \mathbf{pa}_k) \quad (8.5)$$

其中 $\mathbf{pa}_k$ 表示 x_k 的父节点集合，而 $\mathbf{x} = \{x_1, \dots, x_K\}$ 。这个关键方程表达了有向图模型中联合分布的因子分解性质。尽管我们假设每个节点对应一个单变量，但同样可以将变量集合或向量值变量与图的节点关联起来。可以很容易证明，只要各个条件分布都是归一化的，则 (8.5) 右侧的表示总是正确归一化的。

我们所考虑的有向图受到一个重要限制，即图中不能存在有向环。换句话说，图中不存在这样一条封闭路径：沿着箭头方向从某个节点出发，经过若干节点后能回到起始节点。这样的图也称为有向无环图，或 DAG。这等价于说，存在一种对节点的排序，使得没有边从某个节点指向编号更小的节点。


8.1.1 示例：多项式回归

为了说明如何使用有向图来描述概率分布，我们考虑在 1.2.6 节中介绍的贝叶斯多项式回归模型。该模型的随机变量包括多项式系数向量 $\mathbf{w}$ 和观测数据 $\mathbf{t} = (t_1, \dots, t_N)^T$ 。此外，该模型还包含输入数据 $\mathbf{x} = (x_1, \dots, x_N)^T$ 、噪声方差 σ^2 以及表示 $\mathbf{w}$ 高斯先验精度的超参数 α ，这些量都是模型的参数而不是随机变量。只关注随机变量，我们看到联合分布等于先验 $p(\mathbf{w})$ 与 N 个条件分布 $p(t_n \mid \mathbf{w})$ 的乘积，其中 $n = 1, \dots, N$ ，因此

$$p(\mathbf{t}, \mathbf{w}) = p(\mathbf{w}) \prod_{n=1}^N p(t_n \mid \mathbf{w}). \quad (8.6)$$


这个联合分布可以用图 8.3 所示的图模型来表示。

图 8.3 表示联合分布 (8.6) 的有向图模型，对应于第 1.2.6 节中介绍的贝叶斯多项式回归模型。



在本书后面对更复杂模型进行处理时，如果像图 8.3 那样显式写出 $t_1, \dots, t_N$ 这些多个节点会显得不便。因此，我们引入一种图形符号，使得多个节点可以更紧凑地表达，即绘制一个单独的代表性节点 t_n ，并用一个称为叠加框 (plate) 的方框将其圈起，并标注 N ，表示有 N 个这样的节点。将图 8.3 以这种方式重写，就得到图 8.4。

图 8.4 对图 8.3 中图形的一种更紧凑的替代表示，其中引入了一个表示 N 个节点的板 (标记为 N 的方框)，只显式展示了其中一个示例 t_n 。




有时，将模型的参数与随机变量都在图中显式表示会很有帮助。在这种情况下，(8.6) 变为

$$p(\mathbf{t}, \mathbf{w} \mid \mathbf{x}, \alpha, \sigma^2) = p(\mathbf{w} \mid \alpha) \prod_{n=1}^N p(t_n \mid \mathbf{w}, x_n, \sigma^2).$$


相应地，我们可以在图模型中显式加入 $\mathbf{x}$ 和 α 。为此，我们采纳一个约定：随机变量用空心圆表示，确定性参数用较小的实心圆表示。将图 8.4 中加入这些确定性参数，我们得到图 8.5。

图 8.5 这展示了与图 8.4 相同的模型，但其中的确定性参数以较小的实心节点形式被显式表示出来。



当我们将图模型应用到机器学习或模式识别问题时，通常会将某些随机变量设定为已观测的特定值，例如在多项式曲线拟合中训练集中给出的 $\{t_n\}$ 。在图模型中，我们用给对应节点着色来表示观测到的变量。因此，如果图 8.5 中变量 $\{t_n\}$ 已被观测，表示它们的图如图 8.6 所示。注意 $\mathbf{w}$ 的值并未观测，因此 w 是一个潜变量，也称为隐藏变量。这类变量在许多概率模型中具有关键作用，并将在第 9 章与第 12 章成为主要讨论对象。

图 8.6 与图 8.5 相同，但将节点 $\{t_n\}$ 阴影化，以表示相应的随机变量已被设定为其观测到的（训练集）取值。



在观测到 $\{t_n\}$ 之后，我们可以根据需求出多项式系数 w 的后验分布，如 1.2.5 节所述。此时可直接应用贝叶斯定理：

$$p(\mathbf{w} \mid \mathbf{T}) \propto p(\mathbf{w}) \prod_{n=1}^N p(t_n \mid \mathbf{w}) \quad (8.7)$$

其中再次省略了确定性参数以保持符号简洁。

一般而言，模型参数（例如 $\mathbf{w}$ ）本身通常并不直接引起兴趣，因为我们的最终目标是对新的输入值进行预测。假设给定一个新的输入 $\hat{x}$ ，我们希望找到对应的 $\hat{t}$ 的概率分布，条件是已观测的数据。描述该问题的图模型如图 8.7 所示，对应的在确定性参数条件下的所有随机变量的联合分布为


$$p(\hat{t}, \mathbf{t}, \mathbf{w} \mid \hat{x}, \mathbf{x}, \alpha, \sigma^2) = \left[\prod_{n=1}^N p(t_n \mid x_n, \mathbf{w}, \sigma^2) \right] p(\mathbf{w} \mid \alpha) p(\hat{t} \mid \hat{x}, \mathbf{w}, \sigma^2). \quad (8.8)$$

然后，通过概率的求和规则，将参数 $\mathbf{w}$ 积分消去即可得到所需的 $\hat{t}$ 的预测分布：

$$p(\hat{t} \mid \hat{x}, \mathbf{x}, \mathbf{t}, \alpha, \sigma^2) \propto \int p(\hat{t}, \mathbf{t}, \mathbf{w} \mid \hat{x}, \mathbf{x}, \alpha, \sigma^2) d\mathbf{w}$$

其中我们隐含地将随机变量 $\mathbf{t}$ 设定为数据集中观测到的具体数值。该计算的细节在第 3 章已讨论。

图 8.7 对应于图 8.6 的多项式回归模型，同时展示了一个新的输入值 $\hat{x}$ 及其对应的模型预测 $\hat{t}$ 。



8.1.2 生成模型


在许多情形中，我们希望从给定的概率分布中抽取样本。尽管第 11 章将专门讨论采样方法，但我们在这里先介绍一种与图模型特别相关的技术，称为祖先采样。考虑一个在 K 个变量上的联合分布 $p(x_1, \dots, x_K)$ ，它可按 (8.5) 在一个有向无环图中进行因子分解。我们假定变量的排序已经选定，使得没有边从某节点指向编号更小的节点，换句话说，每个节点的编号都大于其父节点编号。我们的目标是从该联合分布中抽取样本 $\hat{x}_1, \dots, \hat{x}_K$ 。

为此，从编号最小的节点开始，从分布 $p(x_1)$ 抽取样本，记为 $\hat{x}_1$ 。然后按顺序依次处理各节点，对于第 n 个节点，从条件分布 $p(x_n | \mathbf{pa}_n)$ 抽取样本，其中父节点变量已被设定为它们之前抽到的样本值。注意在每一步，父节点值总是可用的，因为它们对应的节点编号更小，已经完成采样。有关如何从具体分布中采样的技术将在第 11 章详细讨论。当我们完成对最后一个变量 x_K 的采样后，就得到了来自该联合分布的一个样本。若希望从某个边缘分布采样，例如 $p(x_2, x_4)$ ，只需从完整联合分布采样一次，然后保留 $\hat{x}_2$ 和 $\hat{x}_4$ ，丢弃其余 $\{\hat{x}_{j \neq 2,4}\}$ 。

在概率模型的实际应用中，通常图中编号较大的节点（也就是末端节点）表示观测变量，而编号较小的节点表示潜变量。潜变量的主要作用在于允许用较简单的（通常是指数族）条件分布构造出对观测变量的复杂分布。

我们可以将这样的模型解释为描述观测数据生成过程的机制。例如，在物体识别任务中，每个观测数据点对应于某个物体的一幅图像（由像素强度向量组成）。此时潜变量可能表示物体的位置和朝向。给定某个具体观测图像，我们希望找到关于物体的后验分布，即对所有可能的位置和朝向积分。我们可以用图 8.8 所示的图模型来表示这个问题。

图 8.8 一个表示物体图像生成过程的图模型，其中物体的身份（离散变量）以及该物体的位置和朝向（连续变量）具有相互独立的先验概率。图像（像素强度向量）的概率分布依赖于物体的身份，以及它的位置和朝向。



图模型刻画了观测数据生成的因果过程 (Pearl, 1988)。因此，这类模型通常称为生成模型。相比之下，图 8.5 所描述的多项式回归模型不是生成的，因为输入变量 x 不

带有概率分布，因此无法由模型生成新的合成数据点。如果我们为 x 引入一个合适的先验分布 $p(x)$ ，则可以使其成为生成模型，但代价是更复杂的结构。

然而，概率模型中的隐藏变量并不一定需要具备任何明确的物理含义，它们也可以仅仅作为构建更复杂联合分布的工具，将其分解为更简单的成分。不论是哪种情况，将生成模型进行祖先采样的过程模拟了观测数据的生成，因此会产生所谓的“幻想”数据，其概率分布（如果模型完美地代表现实）将与观测数据相同。在实践中，从生成模型中生成合成观测有助于理解模型所表示的概率分布的形状。

8.1.3 离散变量

我们已经讨论过属于指数族的概率分布的重要性，并且看到该族包含许多众所周知的分布作为特例。虽然这些分布本身相对简单，但它们是构造更复杂概率分布的有用构件，而图模型框架在表达这些构件之间如何连接时非常有用。

如果我们在有向图中对每一对父-子节点之间的关系都选取共轭形式，这类模型会具有特别好的性质，我们很快就会通过若干例子来探讨这一点。两种情况尤其值得注意：一种是父节点和子节点都对应离散变量，另一种是它们都对应高斯变量，因为在这两种情形下，这种关系都可以层次化地扩展，从而构造任意复杂的有向无环图。我们先从离散情形开始。

对于一个具有 K 个可能状态（使用 1-of- K 表示）的单个离散变量 $\mathbf{x}$ ，其概率分布 $p(\mathbf{x} | \boldsymbol{\mu})$ 为

$$p(\mathbf{x} | \boldsymbol{\mu}) = \prod_{k=1}^K \mu_k^{x_k} \quad (8.9)$$


它由参数 $\boldsymbol{\mu} = (\mu_1, \dots, \mu_K)^T$ 所控制。由于存在约束 $\sum_k \mu_k = 1$ ，为了刻画该分布，只需给定 μ_k 的 $K - 1$ 个取值即可。

现在假设我们有两个离散变量 $\mathbf{x}_1$ 与 $\mathbf{x}_2$ ，它们各自都有 K 个状态，并且我们希望对它们的联合分布建模。我们用参数 μ_{kl} 表示同时观察到 $x_{1k} = 1$ 和 $x_{2l} = 1$ 的概率，其中 x_{1k} 表示 $\mathbf{x}_1$ 的第 k 个分量， x_{2l} 同理。联合分布可以写为

$$p(\mathbf{x}_1, \mathbf{x}_2 | \boldsymbol{\mu}) = \prod_{k=1}^K \prod_{l=1}^K \mu_{kl}^{x_{1k} x_{2l}}$$

由于参数 μ_{kl} 需满足约束 $\sum_k \sum_l \mu_{kl} = 1$ ，因此该分布由 $K^2 - 1$ 个参数刻画。很容易看出，对于 M 个变量上的任意联合分布，其需要给定的参数总数为 $K^M - 1$ ，因此会随变量个数 M 呈指数增长。

图 8.9 (a) 这个全连接图描述了两个取 K 个状态的离散变量的一个一般分布，共有 $K^2 - 1$ 个参数。(b) 通过移除节点之间的连接，参数数量减少为 $2(K - 1)$ 。



利用乘法法则，我们可以将联合分布 $p(\mathbf{x}_1, \mathbf{x}_2)$ 分解为 $p(\mathbf{x}_2 | \mathbf{x}_1)p(\mathbf{x}_1)$ 的形式，这对应于图 8.9(a) 所示的双节点图，其中连线从 $\mathbf{x}_1$ 节点指向 $\mathbf{x}_2$ 节点。边缘分布 $p(\mathbf{x}_1)$ 由

$K - 1$ 个参数控制，如之前一样。同样，条件分布 $p(\mathbf{x}_2 | \mathbf{x}_1)$ 需要在 $\mathbf{x}_1$ 的 K 种可能取值中的每一种下，各指定 $K - 1$ 个参数。因此联合分布总共需要指定的参数个数为 $(K - 1) + K(K - 1) = K^2 - 1$ ，与之前相同。

现在假设变量 $\mathbf{x}_1$ 和 $\mathbf{x}_2$ 相互独立，对应于图 8.9(b) 所示的图模型。此时每个变量都由一个单独的多项分布刻画，总参数数目为 $2(K - 1)$ 。对于 M 个相互独立的离散变量组成的分布，每个变量有 K 个状态，总参数数目为 $M(K - 1)$ ，因此随变量个数线性增长。从图的角度看，我们通过从图上移除若干连线来减少参数数量，代价是只允许一类受限的分布。


更一般地，如果我们有 M 个离散变量 $\mathbf{x}_1, \dots, \mathbf{x}_M$ ，可以用一个有向图来建模其联合分布，每个变量对应图中的一个节点。每个节点的条件分布由一组非负参数给定，并满足通常的归一化约束。如果图是完全连接的，那么我们得到的是一个完全一般的分布，需要 $K^M - 1$ 个参数；而如果图中没有任何连线，则联合分布分解为各边缘分布的乘积，总参数数目为 $M(K - 1)$ 。具有中等连通度的图则允许比完全因子化模型更一般的分布，同时所需参数又少于最一般的联合分布。作为一个例子，考虑图 8.10 所示的链式节点结构。边缘分布 $p(\mathbf{x}_1)$ 需要 $K - 1$ 个参数，而 $M - 1$ 个条件分布 $p(\mathbf{x}_i | \mathbf{x}_{i-1})$ （其中 $i = 2, \dots, M$ ）中的每一个都需要 $K(K - 1)$ 个参数。总参数数目为 $K - 1 + (M - 1)K(K - 1)$ ，它关于 K 是二次的，同时随链长 M 线性（而非指数）增长。

图 8.10 这一由 M 个离散节点构成的链式结构中，每个节点具有 K 个状态，需要指定 $K - 1 + (M - 1)K(K - 1)$ 个参数，其规模随链的长度 M 线性增长。相比之下，一个包含 M 个节点的全连接图将具有 $K^{MP} - 1$ 个参数，其规模随 M 指数式增长。



另一种减少模型中独立参数数量的方法是进行参数共享（也称参数绑定）。例如，在图 8.10 的链式示例中，我们可以让所有条件分布 $p(\mathbf{x}_i | \mathbf{x}_{i-1})$ （ $i = 2, \dots, M$ ）都由同一组 $K(K - 1)$ 个参数控制。再加上刻画 $\mathbf{x}_1$ 分布的 $K - 1$ 个参数，总共只需 $K^2 - 1$ 个参数即可刻画整个联合分布。

图 8.11 图 8.10 中模型的扩展，其中加入了控制离散分布参数的 Dirichlet 先验。



通过为参数引入 Dirichlet 先验，我们可以将一个离散变量图转化为一个贝叶斯模型。从图的角度看，每个节点都会额外获得一个父节点，该父节点表示与该离散节点相关的参数上的 Dirichlet 分布。链式模型的这一形式如图 8.11 所示。而在图 8.12 中，则展示了将条件分布 $p(\mathbf{x}_i | \mathbf{x}_{i-1})$ （ $i = 2, \dots, M$ ）所依赖的参数进行绑定后的对应模型。

控制离散变量模型中参数指数增长的另一种方法，是对条件分布使用参数化模型，

图 8.12 与图 8.11 相同，但所有条件分布 $p(\mathbf{x}_i | \mu_1, \dots, \mu_{i-1})$ 共用一组参数 μ 。





图 8.13 一个由 M 个父节点 $x_1, \dots, x_M$ 和一个单一子节点 y 构成的图，用于说明离散变量的参数化条件分布这一概念。



而不是完整的条件概率表。为了说明这一想法，考虑图 8.13 所示的图，其中所有节点都表示二值变量。每个父节点变量 x_i 都由单个参数 μ_i 控制，它表示概率 $p(x_i = 1)$ ，因此父节点总共有 M 个参数。然而，条件分布 $p(y | x_1, \dots, x_M)$ 则需要 2^M 个参数，用来表示在父变量 2^M 种可能设定下的每一个 $p(y = 1)$ 。因此，一般来说，用于刻画该条件分布的参数数目会随 M 指数增长。我们可以通过采用作用在父变量线性组合上的逻辑 sigmoid 函数，得到一个更为简洁的条件分布形式：

$$p(y = 1 | x_1, \dots, x_M) = \sigma \left(w_0 + \sum_{i=1}^M w_i x_i \right) = \sigma(\mathbf{w}^T \mathbf{x}) \quad (8.10)$$

其中 $\sigma(a) = (1 + \exp(-a))^{-1}$ 为逻辑 sigmoid 函数， $\mathbf{x} = (x_0, x_1, \dots, x_M)^T$ 是一个 $(M+1)$ 维的父节点状态向量，并增加了一个额外变量 x_0 ，其取值固定为 1； $\mathbf{w} = (w_0, w_1, \dots, w_M)^T$ 是一个含有 $M+1$ 个参数的向量。这是比一般形式更受限的一种条件分布形式，但其参数数目只随 M 线性增长。从这个意义上讲，它类似于在多元高斯分布中选取一种受限形式的协方差矩阵（例如对角矩阵）。关于逻辑 sigmoid 表示的动机在 4.2 节中进行了讨论。

8.1.4 线性-高斯模型

在上一节中，我们看到如何通过将变量表示为有向无环图中的节点来构造离散变量集合上的联合概率分布。这里我们将展示，多元高斯分布可以表示为一个有向图，它对应于各分量变量上的线性-高斯模型。这样就可以在分布上施加有趣的结构，而一般高斯分布与对角协方差高斯分布则分别代表两个极端。若干广泛使用的技术都是线性-高斯模型的例子，例如概率主成分分析、因子分析以及线性动力系统（Roweis 和 Ghahramani, 1999）。在后续章节中，当我们具体讨论这些技术时，将广泛用到本节的结果。

考虑一个关于 D 个变量的任意有向无环图，其中第 i 个节点表示单个连续随机变量 x_i ，并服从高斯分布。该分布的均值被设定为该节点父节点 pa_i 状态的线性组合：

$$p(x_i | \text{pa}_i) = \mathcal{N} \left(x_i \mid \sum_{j \in \text{pa}_i} w_{ij} x_j + b_i, v_i \right) \quad (8.11)$$

其中 w_{ij} 和 b_i 是控制均值的参数, v_i 是 x_i 条件分布的方差。联合分布的对数即为图中所有节点条件分布的对数之和, 因此具有如下形式:

$$\ln p(\mathbf{x}) = \sum_{i=1}^D \ln p(x_i | \text{pa}_i) \quad (8.12)$$

$$= - \sum_{i=1}^D \frac{1}{2v_i} \left(x_i - \sum_{j \in \text{pa}_i} w_{ij} x_j - b_i \right)^2 + \text{const} \quad (8.13)$$

其中 $\mathbf{x} = (x_1, \dots, x_D)^T$, 而 “const” 表示与 $\mathbf{x}$ 无关的项。我们可以看到, 这是一个关于 $\mathbf{x}$ 各分量的二次函数, 因此联合分布 $p(\mathbf{x})$ 是一个多元高斯分布。

我们可以如下递归地求出该联合分布的均值与协方差。每个变量 x_i 在其父节点状态给定的条件下, 都具有形如 (8.11) 的高斯分布, 因此有

$$x_i = \sum_{j \in \text{pa}_i} w_{ij} x_j + b_i + \sqrt{v_i} \epsilon_i \quad (8.14)$$

其中 ϵ_i 是一个零均值、单位方差的高斯随机变量, 满足 $\mathbb{E}[\epsilon_i] = 0$ 且 $\mathbb{E}[\epsilon_i \epsilon_j] = I_{ij}$, I_{ij} 为单位矩阵的第 i, j 个元素。对 (8.14) 取期望, 得到

$$\mathbb{E}[x_i] = \sum_{j \in \text{pa}_i} w_{ij} \mathbb{E}[x_j] + b_i. \quad (8.15)$$

因此, 我们可以从编号最小的节点开始, 递归地在图中向前推进, 从而求出 $\mathbb{E}[\mathbf{x}] = (\mathbb{E}[x_1], \dots, \mathbb{E}[x_D])^T$ 的各个分量 (这里我们再次假设节点编号方式满足: 每个节点的编号都大于其任一父节点的编号)。类似地, 我们可以使用 (8.14) 与 (8.15) 得到 $p(\mathbf{x})$ 的协方差矩阵的第 i, j 个元素, 形式为如下递推关系:


$$\begin{aligned} \text{cov}[x_i, x_j] &= \mathbb{E}[(x_i - \mathbb{E}[x_i])(x_j - \mathbb{E}[x_j])] \\ &= \mathbb{E}\left[(x_i - \mathbb{E}[x_i]) \left\{ \sum_{k \in \text{pa}_j} w_{jk} (x_k - \mathbb{E}[x_k]) + \sqrt{v_j} \epsilon_j \right\}\right] \\ &= \sum_{k \in \text{pa}_j} w_{jk} \text{cov}[x_i, x_k] + I_{ij} v_j \end{aligned} \quad (8.16)$$

因此, 协方差同样可以从编号最小的节点开始递归计算。

下面我们考虑两个极端情形。首先, 假设图中没有任何连线, 因此该图由 D 个孤立节点组成。在这种情况下, 没有参数 w_{ij} , 只有 D 个参数 b_i 与 D 个参数 v_i 。从递推关系式 (8.15) 与 (8.16) 可知, $p(\mathbf{x})$ 的均值为 $(b_1, \dots, b_D)^T$, 协方差矩阵则是对角形式 $\text{diag}(v_1, \dots, v_D)$ 。该联合分布一共包含 $2D$ 个参数, 表示 D 个相互独立的一元高斯分布。

再考虑另一种极端情形: 图是完全连接的, 其中每个节点都将所有编号比它小的节点作为父节点。此时矩阵 w_{ij} 的第 i 行上有 $i-1$ 个非零元素, 因此它是一个下三角矩阵 (主对角线上没有元素)。参数 w_{ij} 的总数可通过以下方式得到: 从一个 $D \times D$ 矩阵的 D^2 个元素开始, 减去 D 个主对角线元素, 再除以 2, 因为只有对角线下方的元素

图 8.14 一个关于三个高斯变量的有向图，其中缺少一条连接。



存在，得到总数为 $D(D-1)/2$ 。因此，协方差矩阵中独立参数 $\{w_{ij}\}$ 与 $\{v_i\}$ 的总数为 $D(D+1)/2$ ，这正对应一个一般的对称协方差矩阵。

具有中等复杂度的图则对应于协方差矩阵部分受约束的联合高斯分布。举例来说，考虑图 8.14 所示的图，其中在 x_1 与 x_3 之间缺少一条连线。利用递推关系 (8.15) 与 (8.16)，可以看到该联合分布的均值与协方差分别为

$$\boldsymbol{\mu} = (b_1, b_2 + w_{21}b_1, b_3 + w_{32}b_2 + w_{32}w_{21}b_1)^T \quad (8.17)$$

$$\boldsymbol{\Sigma} = \begin{pmatrix} v_1 & w_{21}v_1 & w_{32}w_{21}v_1 \\ w_{21}v_1 & v_2 + w_{21}^2v_1 & w_{32}(v_2 + w_{21}^2v_1) \\ w_{32}w_{21}v_1 & w_{32}(v_2 + w_{21}^2v_1) & v_3 + w_{32}^2(v_2 + w_{21}^2v_1) \end{pmatrix}. \quad (8.18)$$

我们可以很容易地将线性-高斯图模型扩展到图的节点表示多元高斯变量的情形。在这种情况下，可以将第 i 个节点的条件分布写为

$$p(\mathbf{x}_i | \text{pa}_i) = \mathcal{N}(\mathbf{x}_i | \sum_{j \in \text{pa}_i} \mathbf{W}_{ij}\mathbf{x}_j + \mathbf{b}_i, \boldsymbol{\Sigma}_i) \quad (8.19)$$

此时 $\mathbf{W}_{ij}$ 为一个矩阵（当 $\mathbf{x}_i$ 与 $\mathbf{x}_j$ 维度不同的时候，该矩阵为非方阵）。同样可以很容易地验证，所有变量的联合分布仍然是高斯分布。

注意，我们之前已经遇到过线性-高斯关系的一个具体例子，即高斯变量 $\mathbf{x}$ 的均值 $\boldsymbol{\mu}$ 的共轭先验本身也是关于 $\boldsymbol{\mu}$ 的高斯分布。因此， $\mathbf{x}$ 与 $\boldsymbol{\mu}$ 的联合分布是高斯分布。这对应于一个简单的双节点图，其中表示 $\boldsymbol{\mu}$ 的节点是表示 $\mathbf{x}$ 的节点的父节点。关于 $\boldsymbol{\mu}$ 的分布的均值是控制先验的一个参数，因此可以将其视为一个超参数。由于该超参数的取值本身也可能未知，我们可以再次从贝叶斯的角度出发，为该超参数引入一个先验（有时称为超先验），它同样由高斯分布给出。这类构造原则上可以推广到任意层级，是分层贝叶斯模型的一个例子，我们将在后续章节中看到更多类似的例子。

8.2 条件独立

在多变量概率分布中，一个重要的概念是条件独立（Dawid, 1980）。考虑三个变量 a, b, c ，并假设在给定 b 和 c 的条件下， a 的条件分布不依赖于 b 的取值，即

$$p(a | b, c) = p(a | c) \quad (8.20)$$

我们说 a 在给定 c 的条件下与 b 条件独立。若我们考虑在 c 条件下 a 和 b 的联合分布，则可以写成

$$\begin{aligned} p(a, b | c) &= p(a | b, c)p(b | c) \\ &= p(a | c)p(b | c) \end{aligned} \quad (8.21)$$

其中使用了概率的乘法规则以及 (8.20)。因此我们看到，在给定 c 的条件下， a 与 b 的联合分布可以分解成各自的边缘分布（均再条件化于 c ）的乘积。这表示变量 a 与

b 在给定 c 的情况下统计独立。注意，条件独立的定义要求 (8.20) 或等价的 (8.21) 对所有 c 的取值都成立，而不仅仅是某些取值。

有时我们用简写符号 (Dawid, 1979) 表示条件独立：

$$a \perp\!\!\!\perp b \mid c \quad (8.22)$$

表示 a 在给定 c 的条件下与 b 条件独立，与 (8.20) 等价。


条件独立在模式识别的概率模型中非常重要，因为它能简化模型结构以及模型推断与学习中的计算。我们稍后将看到具体例子。

如果给定一个联合分布以条件分布乘积（即对应某个有向图的数学形式）的方式表达，我们原则上可以用概率的加法规则和乘法规则反复检验潜在的条件独立是否成立。然而在实践中，这种方法会非常耗时。图模型的一大优雅之处在于：我们可以直接从图结构读取条件独立关系，而无需代数运算。实现这一点的通用方法叫做 **d-分离** (d-separation)，其中“d”指的是“directed”（有向）(Pearl, 1988)。本节我们将动机化并给出 d-分离准则的总体描述；形式证明可见 Lauritzen (1996)。

8.2.1 三个示例图

我们从三个仅包含三个节点的简单有向图出发，讨论其条件独立性质。这三个例子共同构成理解 d-分离概念的基础。

图 8.15 用于讨论有向图模型条件独立性质的三个示例之一，其包含三个变量 a, b, c 。



第一个例子如图 8.15 所示，对应的联合分布根据 (8.5) 为

$$p(a, b, c) = p(a \mid c)p(b \mid c)p(c) \quad (8.23)$$

若三个变量均未观测，我们可通过对 c 求和来检查 a 和 b 是否独立：

$$p(a, b) = \sum_c p(a \mid c)p(b \mid c)p(c) \quad (8.24)$$

一般而言，它并不能分解为 $p(a)p(b)$ ，因此有


$$a \not\perp\!\!\!\perp b \mid \emptyset \quad (8.25)$$

这里 $\emptyset$ 表示空集， $\not\perp\!\!\!\perp$ 表示条件独立一般不成立。某些具体参数配置下条件独立可能成立，但这不是由图结构本身保证的。

现在假设我们条件化 c ，如图 8.16 所示。根据 (8.23)，给定 c 后 a 与 b 的条件分布为

$$\begin{aligned} p(a, b \mid c) &= \frac{p(a, b, c)}{p(c)} \\ &= p(a \mid c)p(b \mid c) \end{aligned}$$

图 8.16 与图 8.15 相同，但我们对变量 c 的取值进行了条件化。




因此得到条件独立性质：

$$a \perp\!\!\!\perp b \mid c$$

从图的角度看，从 a 到 b 的路径经由 c ，且 c 是 **tail-to-tail** 连接（都接在箭尾）。未观测时，该路径使 a 与 b 相关；但一旦对 c 条件化，该路径被“阻断”，导致 a 与 b 条件独立。

图 8.17 我们的三个用于阐述有向图模型条件独立框架的三节点图示例中的第二个。



接下来考虑图 8.17，对应的联合分布同样由 (8.5) 得到：

$$p(a, b, c) = p(a)p(c \mid a)p(b \mid c) \quad (8.26)$$


首先假设无变量被观测，通过对 c 求和：

$$p(a, b) = p(a) \sum_c p(c \mid a)p(b \mid c) = p(a)p(b \mid a)$$

一般不等于 $p(a)p(b)$ ，因此：

$$a \not\perp\!\!\!\perp b \mid \emptyset \quad (8.27)$$

图 8.18 与图 8.17 相同，但现在对节点 c 进行条件化。



现在假设我们条件化 c ，如图 8.18 所示。使用贝叶斯公式并结合 (8.26)：

$$\begin{aligned} p(a, b \mid c) &= \frac{p(a, b, c)}{p(c)} \\ &= \frac{p(a)p(c \mid a)p(b \mid c)}{p(c)} \\ &= p(a \mid c)p(b \mid c) \end{aligned}$$


因而再次得到条件独立关系：

$$a \perp\!\!\!\perp b \mid c$$

与之前一样，我们可以对这些结果进行图形化解释。在从节点 a 到节点 b 的路径上，节点 c 被称为 **head-to-tail**，因为箭头一端指向它、另一端从它指出。这样的路径连接了 a 和 b ，使它们产生相关性。当我们观察到 c 时，如图 8.18 所示，这个观测会“阻断”从 a 到 b 的路径，因此得到条件独立 $a \perp\!\!\!\perp b \mid c$ 。

最后，我们来看第三个三节点示例，如图 8.19 所示。正如我们将看到的，它的行为比前两个更微妙。

图 8.19 这是我们用于探讨图模型中条件独立性质的三个三节点图示例中的最后一个。该图的性质与前两个示例明显不同。



该图对应的联合分布同样可由公式 (8.5) 写出：

$$p(a, b, c) = p(a)p(b)p(c | a, b) \quad (8.28)$$


首先考虑没有任何变量被观测的情况。对 (8.28) 的两侧对 c 求和，得到

$$p(a, b) = p(a)p(b)$$

因此在未观测任何变量时， a 和 b 是独立的，这与前两个示例不同。可写为

$$a \perp\!\!\!\perp b \mid \emptyset \quad (8.29)$$

图 8.20 与图 8.19 相同，但对节点 c 的取值进行了条件化。在这个图中，条件化会在 a 和 b 之间引入依赖关系。



接下来假设我们对 c 条件化，如图 8.20 所示。此时 a 和 b 的条件分布为

$$\begin{aligned} p(a, b \mid c) &= \frac{p(a, b, c)}{p(c)} \\ &= \frac{p(a)p(b)p(c \mid a, b)}{p(c)} \end{aligned}$$

一般无法分解成 $p(a)p(b)$ ，因此

$$a \not\perp\!\!\!\perp b \mid c$$

也就是说，这第三个示例与前两个呈现相反的行为。从图结构上讲，节点 c 相对于从 a 到 b 的路径是 head-to-head，因为两条箭头都指向它。当 c 未被观测时，它“阻断”了 a 与 b 之间的路径，使它们独立。然而，一旦对 c 条件化，该路径就被“解锁”，使得 a 与 b 变得相关。

此外，这个例子还有一个重要的细微点。我们先引入一点术语：如果存在一条路径从 x 到 y ，并且路径的每一步都沿箭头方向前进，则称 y 是 x 的后代。接着可以证明：一个 head-to-head 路径不仅在该节点本身被观测时会被“解锁”，而且只要其任意一个后代被观测，该路径也会被“解锁”。

总结而言：尾-尾（tail-to-tail）或头-尾（head-to-tail）的节点会使路径保持“未阻断”，除非该节点被观测，一旦观测到便“阻断”路径。头-头（head-to-head）的节点在未观测时会“阻断”路径，但当该节点或其任意后代被观测时，会“解锁”路径。




图 8.21 图 8.21 是一个用于说明“互相排斥解释”现象的三节点图示例。三个节点分别表示电池状态 (B)、油箱状态 (F) 以及电动油表读数 (G)。细节见正文。

值得花点时间理解图 8.20 这种不寻常现象。图 8.21 展示了一个包含三个二元随机变量的具体示例，涉及汽车燃油系统的情况。三个变量分别是： B ：电池状态，充电 ($B = 1$) 或没电 ($B = 0$)。 F ：油箱状态，满油 ($F = 1$) 或空 ($F = 0$)。 G ：电动油量计的读数，显示满 ($G = 1$) 或空 ($G = 0$)。电池和油箱各自独立地可能为空或有电，其先验概率为

$$p(B = 1) = 0.9$$

$$p(F = 1) = 0.9$$

给定油箱与电池状态时，油量表读满的概率如下：

$$p(G = 1 \mid B = 1, F = 1) = 0.8$$

$$p(G = 1 \mid B = 1, F = 0) = 0.2$$

$$p(G = 1 \mid B = 0, F = 1) = 0.2$$

$$p(G = 1 \mid B = 0, F = 0) = 0.1$$

因此，这实际上是一个相当不可靠的“燃油表”！其余的概率由概率总和为一这一约束条件所确定，因此我们便得到了该概率模型的完整定义。

在未观测任何数据前，油箱为空的先验概率为 $p(F = 0) = 0.1$ 。现在假设我们观察到油量表，发现它显示为空，即 $G = 0$ （图 8.21 中间图）。可以用贝叶斯公式求空油箱的后验概率。首先计算贝叶斯公式分母：

$$p(G = 0) = \sum_{B \in \{0,1\}} \sum_{F \in \{0,1\}} p(G = 0 \mid B, F) p(B) p(F) = 0.315 \quad (8.30)$$

接着计算

$$p(G = 0 \mid F = 0) = \sum_{B \in \{0,1\}} p(G = 0 \mid B, F = 0) p(B) = 0.81 \quad (8.31)$$

因此

$$p(F = 0 \mid G = 0) = \frac{p(G = 0 \mid F = 0) p(F = 0)}{p(G = 0)} \simeq 0.257 \quad (8.32)$$

所以 $p(F = 0 \mid G = 0) > p(F = 0)$ 。油量表显示“空”提高了油箱为空的可能性，这是直觉上合理的。接下来我们再观察电池状态，发现电池没电 ($B = 0$)。此时我们观测了油量表和电池，如图 8.21 右图。此时油箱为空的后续概率为：

$$p(F = 0 \mid G = 0, B = 0) = \frac{p(G = 0 \mid B = 0, F = 0) p(F = 0)}{\sum_{F \in \{0,1\}} p(G = 0 \mid B = 0, F) p(F)} \simeq 0.111 \quad (8.33)$$

注意分子与分母中的 $p(B = 0)$ 相互抵消。结果显示油箱为空的概率从 0.257 降至 0.111。这符合直觉：电池没电可以部分解释为何油量表读“空”。因此油箱状态与电池状态确实因为油量表读数（或其任意后代的观测）而变得相关。注意 $p(F = 0 \mid G = 0, B = 0) \simeq 0.111$ 仍略大于先验 $p(F = 0) = 0.1$ ，因为油量表读“空”依然提供了一些支持油箱为空的证据。

8.2.2 d-分离

现在我们给出有向图的 d-分离性质的一般表述（Pearl, 1988）。考虑一个一般的有向图，其中 A, B, C 是任意互不相交的点集（它们的并集可以小于图中全部节点集合）。我们希望判断某个特定的条件独立陈述 $A \perp\!\!\!\perp B \mid C$ 是否由给定的有向无环图所蕴含。为此，我们考虑从 A 中任意一个节点到 B 中任意一个节点的所有可能路径。如果一条路径上存在某个节点，使得满足如下任一条件，则称该路径被“阻断”（blocked）：

- (a) 路径上的箭头在该节点处以 head-to-tail 或 tail-to-tail 方式相接，并且该节点属于集合 C ；
- (b) 路径上的箭头在该节点处以 head-to-head 方式相接，并且该节点及其所有后代都不属于 C 。

如果从 A 到 B 的所有路径都被阻断，则称 A 被 C 所 d-分离，记为 A 被 C d-separated from B ，此时图中所有变量的联合分布将满足 $A \perp\!\!\!\perp B \mid C$ 。

图 8.22 图 8.22 对 d-分离概念的示意说明。细节见正文。





图 8.22 对 d-分离的概念进行了说明。在图 (a) 中，从 a 到 b 的路径并没有被节点 f 阻断，因为对于这条路径而言， f 是一个 tail-to-tail 节点且未被观测；该路径也没有被节点 e 阻断，因为虽然 e 是 head-to-head 节点，但它有一个后代 c 属于条件集合中。因此，条件独立陈述 $a \perp\!\!\!\perp b \mid c$ 并不能从该图中推出。在图 (b) 中，从 a 到 b 的路径被节点 f 阻断，因为 f 是一个已观测到的 tail-to-tail 节点，因此任何根据该图进行因子分解的分布都会满足条件独立性质 $a \perp\!\!\!\perp b \mid f$ 。注意这条路径同样也被节点 e 阻断，因为 e 是 head-to-head 节点，且它及其后代都不在条件集合中。

在 d-分离的语境中，类似于图 8.5 中用小实心圆表示的参数（如 α 和 σ^2 ）的行为与观测节点相同。然而，这些节点本身并不对应任何边缘分布。因此参数节点从不具有父节点，所有经过这些节点的路径在这里都将是 tail-to-tail 的，因此总是被阻断。故而参数节点在 d-分离中不起任何作用。

另一个关于条件独立和 d-分离的例子来自 1.2.4 节中引入的 i.i.d.（独立同分布）数据概念。考虑求一元高斯分布均值的后验分布问题。该问题可由图 8.23 所示的有向图

图 8.23 (a) 对应于从观测值 $x_1, \dots, x_N$ 推断单变量高斯分布的均值 μ 的有向图。(b) 使用板式记号绘制的相同图形。



表示，其中联合分布由先验 $p(\mu)$ 以及一组条件分布 $p(x_n | \mu)$ ($n = 1, \dots, N$) 定义。在实际中，我们观测到 $\mathcal{D} = \{x_1, \dots, x_N\}$ ，目标是推断 μ 。先假设我们对 μ 条件化，并考虑观测值的联合分布。利用 **d**-分离，我们注意到，从任一 x_i 到任一 $x_{j \neq i}$ 存在唯一一条路径，这条路径在观测节点 μ 处是 **tail-to-tail**，因此被阻断。于是观测集 $\mathcal{D} = \{x_1, \dots, x_N\}$ 在给定 μ 的条件下是独立的，因此

$$p(\mathcal{D} | \mu) = \prod_{n=1}^N p(x_n | \mu). \quad (8.34)$$

然而，如果我们对 μ 积分，则观测值一般不再独立：

$$p(\mathcal{D}) = \int_0^\infty p(\mathcal{D} | \mu) p(\mu) d\mu \neq \prod_{n=1}^N p(x_n). \quad (8.35)$$


此处 μ 是一个潜变量，因为它的取值未被观测到。

另一个表示 i.i.d. 数据的模型例子是图 8.7，对应贝叶斯多项式回归。在那里，随机节点为 $\{t_n\}$ 、 $\mathbf{w}$ 与 $\hat{t}$ 。可以看到，对于从 $\hat{t}$ 到任一 t_n 的路径，节点 $\mathbf{w}$ 是 **tail-to-tail** 的，因此有如下条件独立性质：

$$\hat{t} \perp\!\!\!\perp t_n | \mathbf{w}. \quad (8.36)$$

也就是说，在给定多项式系数 $\mathbf{w}$ 的条件下， $\hat{t}$ 的预测分布与训练数据 $\{t_1, \dots, t_N\}$ 独立。因此，我们可以先用训练数据求出系数 $\mathbf{w}$ 的后验分布，然后丢弃训练数据，再用 $\mathbf{w}$ 的后验分布对新输入 $\hat{x}$ 的输出 $\hat{t}$ 进行预测。

图 8.24 用于分类的“朴素贝叶斯”模型的图形表示。给定类别标签 z 后，观测向量 $\mathbf{x} = (x_1, \dots, x_D)^T$ 的各个分量被假设为相互独立。



与此相关的一种图结构出现在分类方法中，称为朴素贝叶斯模型 (naive Bayes model)，它通过条件独立假设简化模型结构。假设观测变量为一个 D 维向量 $\mathbf{x} = (x_1, \dots, x_D)^T$ ，我们希望将 $\mathbf{x}$ 的观测值划分到 K 个类别之一。采用 1-of- K 编码，我们可以用一个 K 维二值向量 $\mathbf{z}$ 表示类别。然后通过引入一个关于类别标签的多项先验 $p(\mathbf{z} | \mu)$ 来定义生成模型，其中 μ 的第 k 个分量 μ_k 是类别 $\mathcal{C}_k$ 的先验概率，同时再给出观测向量 $\mathbf{x}$ 的条件分布 $p(\mathbf{x} | \mathbf{z})$ 。朴素贝叶斯模型的关键假设是：在给定类别 $\mathbf{z}$ 的条件下，各输入变量 $x_1, \dots, x_D$ 相互独立。该模型的图表示如图 8.24 所示。可以看到，观测到 $\mathbf{z}$ 会阻断 x_i 与 x_j ($j \neq i$) 之间的路径（因为这些路径在节点 $\mathbf{z}$ 处是 **tail-to-tail**），因此 x_i 与 x_j 在给定 $\mathbf{z}$ 的条件下是条件独立的。然而，如果将 $\mathbf{z}$ 积分掉（即 $\mathbf{z}$ 未被观测），则 x_i 到 x_j 的 **tail-to-tail** 路径不再被阻断，这表明一般情况下边缘分布 $p(\mathbf{x})$ 不会在 $\mathbf{x}$ 的各个分量之间

因子化。我们在 1.5 节中曾看到朴素贝叶斯模型在多源医疗诊断数据融合中的一个简单应用。

如果有一个带标签的训练集，由输入 $\{\mathbf{x}_1, \dots, \mathbf{x}_N\}$ 及其类别标签组成，那么在假设数据是从模型独立抽样的前提下，可以用最大似然法对朴素贝叶斯模型进行拟合。其解可以通过对每一类分别拟合各自的模型，并只使用带有相应标签的数据来获得。举例来说，假设每一类内部的概率密度选为高斯分布，那么朴素贝叶斯假设就意味着每个高斯分布的协方差矩阵是对角的，因此各类内部的等密度曲线都是坐标轴对齐的椭球。然而，整体的边缘密度是多个对角高斯的叠加（权重由类别先验给出），因此不再在各分量之间因子化。

当输入空间维度 D 较高时，朴素贝叶斯假设是有益的，因为在完整的 D 维空间中进行密度估计会更加困难。若输入向量同时包含离散与连续变量，该假设也很有用，因为它允许针对不同类型变量分别选择合适的模型（例如，对二值观测使用 **Bernoulli** 分布，对实值变量使用高斯分布）。显然，这种条件独立假设相当强，可能导致对类别条件密度的刻画较为粗糙。尽管如此，即便该假设并非严格满足，朴素贝叶斯模型在实际分类任务中仍然可能表现良好，因为分类决策边界对类别条件密度的某些细节可能并不敏感，如图 1.27 所示。

我们已经看到，一个特定的有向图对应于某个联合概率分布被分解为条件概率乘积的特定方式。该图同时还通过 **d-分离** 准则隐含了一组条件独立陈述，而 **d-分离定理** 实质上表达了这两种性质的等价性。为了更清楚地理解这一点，将有向图看成一个“过滤器”是很有帮助的。假设我们考虑一个关于变量 $\mathbf{x}$ 的联合分布 $p(\mathbf{x})$ ，其中 $\mathbf{x}$ 对应于图中所有（未观测的）节点。如果且仅如果 $p(\mathbf{x})$ 可以按图所蕴含的因子分解式 (8.5) 表示，该分布就能“通过”过滤器。若我们把所有可能的 $p(\mathbf{x})$ 都送入这个过滤器，则被通过的分布子集记为 $\mathcal{DF}$ ，表示 **directed factorization**，如图 8.25 所示。




图 8.25 我们可以将图模型（此处为有向图）看作一种过滤器：一个概率分布 $p(x)$ 只有在满足有向分解性质 (8.5) 时才能通过该过滤器。所有能够通过该过滤器的概率分布集合记为 $\mathcal{DF}$ 。我们也可以根据图所隐含的所有由 **d-分离** 性质得到的条件独立性，将图用作另一种过滤器来筛选分布。**d-分离定理** 表明，能够通过这种第二类过滤器的分布集合与 $\mathcal{DF}$ 相同。

换一种方式，我们也能用该图作为另一种“过滤器”：首先列出通过 **d-分离** 准则从图中得到的所有条件独立性质，然后只保留那些满足所有这些条件独立性质的分布。如果我们将所有可能的 $p(\mathbf{x})$ 送入这种“条件独立过滤器”，**d-分离定理** 告诉我们，能通过过滤的分布集合恰好就是 $\mathcal{DF}$ 。

需要强调的是，通过 **d-分离** 得到的条件独立性质适用于任何由该有向图描述的概率模型。例如，无论变量是离散的、连续的，还是两者的组合，这一点都成立。再次可

以看到，一个特定的图描述的是一整个概率分布族。

在一个极端情况下，我们有完全连接图，它不展示任何条件独立性质，因而可以表示给定变量上的任意联合概率分布。此时集合 $\mathcal{DF}$ 包含所有可能的 $p(\mathbf{x})$ 。在另一个极端，我们有完全断开的图，也就是没有任何连线的图。这对应于联合分布可以分解为图中节点所对应变量的边缘分布的乘积的情况。


注意，对于任一给定图，集合 $\mathcal{DF}$ 中都会包含那些具有比图结构本身所蕴含的独立性更强的分布。例如，任何完全因子化的分布必然可以通过任意一个给定变量集上的图所定义过滤器。

我们在有关条件独立性质的讨论最后，引入马尔可夫毯（Markov blanket）或马尔可夫边界（Markov boundary）的概念。考虑一个联合分布 $p(\mathbf{x}_1, \dots, \mathbf{x}_D)$ ，它由一个具有 D 个节点的有向图表示。我们关心某个特定节点 $\mathbf{x}_i$ 的条件分布，在给定其他所有变量 $\mathbf{x}_{j \neq i}$ 的条件下：

$$\begin{aligned} p(\mathbf{x}_i | \mathbf{x}_{\{j \neq i\}}) &= \frac{p(\mathbf{x}_1, \dots, \mathbf{x}_D)}{\int p(\mathbf{x}_1, \dots, \mathbf{x}_D) d\mathbf{x}_i} \\ &= \frac{\prod_k p(\mathbf{x}_k | \mathbf{pa}_k)}{\int \prod_k p(\mathbf{x}_k | \mathbf{pa}_k) d\mathbf{x}_i} \end{aligned}$$

在离散变量的情形中，积分要用求和取代。我们注意到，任何一个条件因子 $p(\mathbf{x}_k | \mathbf{pa}_k)$ ，若其不依赖于 $\mathbf{x}_i$ ，都可以从对 $\mathbf{x}_i$ 的积分中提出去，并在分子与分母中相互抵消。于是只剩下两类因子：一类是 $\mathbf{x}_i$ 自身的条件分布 $p(\mathbf{x}_i | \mathbf{pa}_i)$ ；另一类是那些以 $\mathbf{x}_i$ 作为父节点的节点 $\mathbf{x}_k$ 的条件分布 $p(\mathbf{x}_k | \mathbf{pa}_k)$ 。其中 $p(\mathbf{x}_i | \mathbf{pa}_i)$ 依赖于 $\mathbf{x}_i$ 的父节点，而 $p(\mathbf{x}_k | \mathbf{pa}_k)$ 则依赖于 $\mathbf{x}_i$ 的子节点以及它们的“共同父节点”（co-parents），也就是那些与 $\mathbf{x}_i$ 一同作为 $\mathbf{x}_k$ 父节点的变量。由 $\mathbf{x}_i$ 的父节点、子节点及其共同父节点组成的节点集合称为 $\mathbf{x}_i$ 的马尔可夫毯，如图 8.26 所示。可以把节点 $\mathbf{x}_i$ 的马尔可夫毯看成是将 $\mathbf{x}_i$ 与图中其他部分隔离开的最小节点集合。注意，只包含节点 $\mathbf{x}_i$ 的父节点与子节点是不够的，因为“解释消除”（explaining away）现象意味着：观测子节点并不能阻断到共同父节点的路径，因此我们也必须将共同父节点纳入观测之中。

图 8.26 节点 $\mathbf{x}_i$ 的马尔可夫毯由该节点的父节点、子节点以及共同父节点组成。它具有这样的性质：在给定图中所有其他变量的条件下， $\mathbf{x}_i$ 的条件分布只依赖于马尔可夫毯中的那些变量。



8.3 马尔可夫随机场

我们已经看到，有向图模型通过将联合分布分解为局部条件分布的乘积来刻画一组变量上的联合概率分布。它们同时也给出了任何按照该图进行因子分解的分布所必须满足的一组条件独立性质。现在我们转向第二大类图模型——由无向图描述的模型，它们同样刻画分解形式并给出一组条件独立关系。

马尔可夫随机场（Markov random field），也称为马尔可夫网络（Markov network）

或无向图模型（undirected graphical model）（Kindermann and Snell, 1980），由一组节点和一组连线构成，每个节点对应一个变量或一组变量，每条连线连接一对节点。连线是无向的，即它们不带箭头。对于无向图，我们从条件独立性质入手会更加方便。

8.3.1 条件独立性质


在有向图的情形中，我们看到可以通过一种称为 d-分离的图形化检验来判断某个条件独立性质是否成立。这一检验涉及检查连接两组节点的路径是否被“阻断”。不过，由于存在 head-to-head 的路径结构，阻断的定义略显微妙。于是我们可以问，是否存在另一种图形语义，使得条件独立可以通过更简单的图分离（graph separation）来判定？答案是肯定的，对应的就是无向图模型。通过从图的连线上移除方向性，父节点与子节点之间的非对称性被消除，因此与 head-to-head 结构相关的微妙问题也不再出现。

设在一个无向图中选出三组节点 A, B, C ，并考虑条件独立性质

$$A \perp\!\!\!\perp B \mid C. \quad (8.37)$$

要检验一个由该图定义的概率分布是否满足这个条件独立性质，我们考察所有从 A 中任意节点到 B 中任意节点的路径。如果所有这样的路径都要经过集合 C 中的一个或多个节点，那么所有这些路径都被“阻断”，条件独立性质成立。相反，如果至少存在一条路径不经过集合 C 的任何节点，那么这个性质就不一定成立，更精确地说，至少存在一些与该图对应的分布不满足这一条件独立关系。图 8.27 给出了一个例子。注意，这与 d-分离准则的形式完全相同，只是这里不存在“解释消除”（explaining away）现象。相较有向图，在无向图中检验条件独立要更为简单。

图 8.27 一个无向图的示例，其中从集合 A 中任一节点到集合 B 中任一节点的所有路径都至少经过集合 C 中的一个节点。因此，对于由该图表示的任意概率分布，都有条件独立性质 $A \perp\!\!\!\perp B \mid C$ 成立。




另一种理解条件独立检验的方法是，设想将集合 C 中所有节点及其相关的连线从图中移除。然后检查是否仍存在从 A 中任一节点到 B 中任一节点的路径。如果不存在这样的路径，则条件独立关系必然成立。

在无向图中，马尔可夫毯（Markov blanket）的形式尤其简单，因为对一个节点而言，在给定其所有邻居的条件下，它与图中其他所有节点条件独立，如图 8.28 所示。

8.3.2 因子分解性质

现在我们希望为无向图找到一个因子分解规则，使其与上述条件独立检验相对应。同样地，这会涉及将联合分布 $p(\mathbf{x})$ 表示为一组局部函数的乘积，这些函数仅依赖于图

图 8.28 对于无向图，节点 x_i 的马尔可夫毯由与其相邻的节点组成。它具有这样的性质：在给定图中所有其他变量的条件下， x_i 的条件分布只依赖于马尔可夫毯中的变量。



中的局部变量集合。因此我们需要确定在无向图中什么样的结构算作“局部”。


如果图中两个节点 x_i 和 x_j 之间没有连线，那么在给定图中所有其他节点的条件，这两个变量应当条件独立。原因是它们之间没有直接路径连接，而所有从一个到另一个的路径都必须经过其它节点；一旦这些其它节点被观测，这些路径就会被阻断。该条件独立性质可以写为

$$p(x_i, x_j \mid \mathbf{x}_{\setminus\{i,j\}}) = p(x_i \mid \mathbf{x}_{\setminus\{i,j\}}) p(x_j \mid \mathbf{x}_{\setminus\{i,j\}}) \quad (8.38)$$

其中 $\mathbf{x}_{\setminus\{i,j\}}$ 表示从变量集合 $\mathbf{x}$ 中去掉 x_i 和 x_j 后的剩余变量。为了让这个条件独立对所有属于该图的分布都成立，联合分布的因子分解中必须保证 x_i 与 x_j 不出现在同一个因子中。

这把我们引向一个图论概念：团（clique）。一个团被定义为图中某个节点子集，使得该子集中的任意两节点之间都存在连线。换句话说，团中的节点集合是完全连接的。进一步地，如果一个团不能再加入图中其他节点而仍保持为团，则称其为极大团（maximal clique）。图 8.29 展示了一个关于四个变量的无向图。它有五个由两个节点组成的团： $\{x_1, x_2\}$ 、 $\{x_2, x_3\}$ 、 $\{x_3, x_4\}$ 、 $\{x_4, x_2\}$ 和 $\{x_1, x_3\}$ ，以及两个极大团： $\{x_1, x_2, x_3\}$ 和 $\{x_2, x_3, x_4\}$ 。集合 $\{x_1, x_2, x_3, x_4\}$ 不是一个团，因为缺少从 x_1 到 x_4 的连线。

图 8.29 一个包含四个节点的无向图，其中绿色轮廓表示一个团，蓝色轮廓表示一个极大团。



因此，我们可以将联合分布分解中的因子定义为这些团中变量的函数。事实上，只考虑极大团就足够了，因为任何非极大团一定是某个极大团的子集。比如，如果 $\{x_1, x_2, x_3\}$ 是一个极大团，我们已在此团上定义了一个任意函数，那么再加上一个只依赖于它的子集变量的因子就是冗余的。

设一个团记为 C ，该团中的变量集合记为 $\mathbf{x}_C$ 。则联合分布可以写成图中各极大团上势函数（potential function） $\psi_C(\mathbf{x}_C)$ 的乘积形式：

$$p(\mathbf{x}) = \frac{1}{Z} \prod_C \psi_C(\mathbf{x}_C) \quad (8.39)$$

其中 Z 称为归一化常数（有时也称配分函数，partition function），定义为

$$Z = \sum_{\mathbf{x}} \prod_C \psi_C(\mathbf{x}_C) \quad (8.40)$$

它保证由 (8.39) 给出的分布 $p(\mathbf{x})$ 正确归一化。只要势函数满足 $\psi_C(\mathbf{x}_C) \geq 0$ ，就可以保证 $p(\mathbf{x}) \geq 0$ 。在 (8.40) 中我们假定 $\mathbf{x}$ 由离散变量组成，但这一框架同样适用于连续变量或二者的组合，只需将求和替换为适当的求和与积分的组合即可。

注意，我们并不要求这些势函数具有特定的概率学解释（比如边缘分布或条件分布）。这与有向图的情况不同，在有向图中，每个因子都被解释为一个变量在其父节点给定条件下的条件分布。不过，在一些特殊情形下，例如无向图是从某个有向图出发构造而来时，势函数的确可以具有这样的概率解释，我们稍后会看到例子。

势函数 $\psi_C(\mathbf{x}_C)$ 的选择具有高度的自由度，因此它们的乘积一般并不会自动归一化，所以必须显式引入 (8.40) 中的归一化因子。回忆在有向图中，联合分布之所以自动归一化，是因为因子分解中的每个条件分布自身已经归一化。

归一化常数的存在是无向图的一大主要局限。如果一个模型有 M 个离散节点，每个节点有 K 个可能状态，那么计算归一化常数就需要对 K^M 个状态求和，因此在最坏情况下计算量会随模型大小指数增长。由于配分函数依赖于势函数 $\psi_C(\mathbf{x}_C)$ 的参数，因此在进行参数学习时必须计算该配分函数。然而，在计算局部条件分布时，配分函数并不需要显式出现，因为条件概率是两个边缘概率的比值，在这个比值中配分函数会在分子与分母之间相互抵消。类似地，在计算局部边缘概率时，我们可以先使用未归一化的联合分布，然后在最后对边缘概率显式归一化。只要这些边缘概率只涉及少量变量，就可以有效地计算它们的归一化系数。

到目前为止，我们已经讨论了基于简单图分离的条件独立概念，并提出了一个旨在对应这种条件独立结构的联合分布因式分解。然而，对于无向图，我们尚未在条件独立与因式分解之间建立形式化的联系。为此，我们需要将注意力限制在严格为正的势函数 $\psi_C(\mathbf{x}_C)$ 上（即对于任何 $\mathbf{x}_C$ 都不为零或负）。在这一限制下，我们便能够在因式分解与条件独立之间建立精确的关系。

为此，我们再次回到将图模型视为滤波器的概念，对应于图 8.25。考虑定义在某个特定无向图节点所对应的固定变量集合上的所有可能分布。我们可以将 $\mathcal{UI}$ 定义为那些与从图中利用图分离可读出的条件独立陈述一致的分布集合。类似地，我们可以将 $\mathcal{UF}$ 定义为那些可以根据图的最大团按式 (8.39) 进行因式分解的分布集合。Hammersley-Clifford 定理 (Clifford, 1990) 说明集合 $\mathcal{UI}$ 与 $\mathcal{UF}$ 是相同的。

因为我们将势函数限制为严格为正，将它们表示为指数形式是方便的，即

$$\psi_C(\mathbf{x}_C) = \exp\{-E(\mathbf{x}_C)\} \quad (8.41)$$

其中 $E(\mathbf{x}_C)$ 被称为能量函数，而这种指数表示称为玻尔兹曼分布。联合分布定义为势函数的乘积，因此总能量通过对每个最大团的能量求和而得。

与有向图中联合分布的因子相比，无向图中的势函数并没有特定的概率解释。尽管这由于没有归一化约束而在选择势函数时提供了更大的灵活性，但也引出了一个问题，

即如何为某一特定应用选择势函数。这可以通过将势函数视为表达局部变量的哪些配置比其他配置更受偏好来实现。具有相对较高概率的全局配置是那些在满足各团势函数的（可能互相冲突的）影响之间找到良好平衡的配置。下面我们给出一个具体例子来说明无向图的使用。

8.3.3 示例：图像去噪

我们可以通过一个从二值图像中去除噪声的示例来说明无向图的应用 (Besag, 1974; Geman and Geman, 1984; Besag, 1986)。尽管这是一个非常简单的例子，但却是更复杂应用的典型代表。令观测到的含噪图像由二值像素 $y_i \in \{-1, +1\}$ 构成，其中索引 $i = 1, \dots, D$ 遍历所有像素。我们假设该图像是通过对一个未知的无噪声图像（其像素为二值 $x_i \in \{-1, +1\}$ ）以某个较小的概率随机翻转像素符号而得到的。一个二值图像样例以及将像素以 10% 概率翻转符号而得到的噪声图像如图 8.30 所示。给定噪声图像，我们的目标是恢复原始的无噪声图像。





图 8.30 使用马尔可夫随机场进行图像去噪的示意图。上排左图为原始二值图像，右图为随机改变 10% 像素后的受损图像。下排左图为使用迭代条件模式 (ICM) 得到的恢复图像，右图为使用图割算法得到的恢复图像。ICM 得到的图像中有 96% 的像素与原始图像一致，而图割算法对应的比例为 99%。

因为噪声较小，我们知道 x_i 与 y_i 之间会存在很强的相关性。我们也知道图像中相邻像素 x_i 与 x_j 之间也有很强相关性。这些先验知识可以通过图 8.31 所示的马尔可夫随机场模型捕捉。该图包含两种类型的团，每种团都包含两个变量。形如 $\{x_i, y_i\}$ 的团具有表达这些变量之间相关性的能量函数。我们为这些团选择一个非常简单的能量函数 $-\eta x_i y_i$ ，其中 η 为正常数。这样，当 x_i 与 y_i 符号相同时能量较低（从而概率更

高), 符号相反时能量较高。

图 8.31 一个用于图像去噪的马尔可夫随机场的无向图模型, 其中 x_i 是一个二值变量, 表示未知无噪声图像中像素 i 的状态, 而 y_i 表示观测到的含噪声图像中像素 i 的对应取值。



剩下的团由相邻像素索引 i 和 j 的成对变量 $\{x_i, x_j\}$ 组成。同样, 我们希望当它们符号相同时能量更低, 因此我们选择能量为 $-\beta x_i x_j$, 其中 β 为正数。

由于势函数是定义在最大团上的任意非负函数, 我们可以将其与任何关于该团子集变量的非负函数相乘, 或者等价地, 我们可以为能量添加对应的项。在这个例子中, 这允许我们为噪声自由图像中的每个像素 i 添加额外项 $h x_i$ 。这样的项会使模型偏向于某一特定符号的像素值。

该模型的完整能量函数具有如下形式

$$E(\mathbf{x}, \mathbf{y}) = h \sum_i x_i - \beta \sum_{\{i,j\}} x_i x_j - \eta \sum_i x_i y_i \quad (8.42)$$

它定义了关于 $\mathbf{x}$ 和 $\mathbf{y}$ 的联合分布:

$$p(\mathbf{x}, \mathbf{y}) = \frac{1}{Z} \exp\{-E(\mathbf{x}, \mathbf{y})\} \quad (8.43)$$

我们现在将 $\mathbf{y}$ 的各个元素固定为噪声图像像素的观测值, 从而隐式地定义了关于无噪声图像的条件分布 $p(\mathbf{x} | \mathbf{y})$ 。这是伊辛模型 (Ising model) 的一个例子, 该模型在统计物理中被广泛研究。为了进行图像恢复, 我们希望找到一个具有高概率的图像 $\mathbf{x}$ (理想情况下应为最大概率)。为此, 我们将使用一种称为迭代条件模式 (iterated conditional modes, ICM) 的简单迭代技术 (Kittler and Föglein, 1984), 它实际上就是坐标方向上的梯度上升法。其思想是首先初始化变量集合 $\{x_i\}$, 我们直接对所有 i 令 $x_i = y_i$ 。然后我们依次取一个节点 x_j , 计算当 $x_j = +1$ 和 $x_j = -1$ 时的总能量 (保持所有其他变量不变), 并将 x_j 设置为能量较低的状态。若 x_j 未改变则概率保持不变, 否则概率将提高。由于每次只改变一个变量, 这是一个简单的局部计算, 可以高效完成。接着我们在另一个位置重复更新, 依此类推, 直到满足某个停止条件为止。节点可以按系统方式更新, 例如不断按扫描线顺序遍历整幅图像, 或随机选择节点。

如果在一系列更新中, 每个位置都至少访问一次, 并且在此期间变量不再发生变化, 那么根据定义, 算法已收敛到一个概率的局部最大值。然而, 这个局部最大值未必就是全局最大值。


在这个简单的例子中, 我们将参数固定为 $\beta = 1.0$ 、 $\eta = 2.1$ 和 $h = 0$ 。注意若令 $h = 0$, 意味着 x_i 的两种状态具有相同的先验概率。以观测到的噪声图像作为初始配置, 我们运行 ICM 直到收敛, 得到图 8.30 左下图所示的去噪图像。需要注意的是, 如

果令 $\beta = 0$ ，这实际上移除了相邻像素之间的连接，此时全局最可能解为对所有 i 都有 $x_i = y_i$ ，即直接得到观测的噪声图像。

稍后我们将讨论一种更有效的寻找高概率解的算法，称为最大乘积（max-product）算法，它通常能得到更好的解，但仍不保证找到后验分布的全局最大值。然而，对于某些模型类别（包括式 (8.42) 给出的模型），存在基于图割（graph cuts）的高效算法，可以保证找到全局最大值（Greig et al., 1989; Boykov et al., 2001; Kolmogorov and Zabih, 2004）。图 8.30 右下图展示了将图割算法应用于该去噪问题的结果。

8.3.4 与有向图的关系

图 8.32 (a) 为一个有向图示例。(b) 为其等价的无向图。



我们已经介绍了两种用于表示概率分布的图模型框架，分别对应有向图和无向图，讨论它们之间的关系是很有启发性的。首先考虑这样一个问题：给定一个用有向图表示的模型，如何将其转换为无向图。在某些情况下，这非常简单，例如图 8.32 中的例子。此处，有向图的联合分布以条件概率的乘积形式给出：

$$p(\mathbf{x}) = p(x_1) p(x_2 | x_1) p(x_3 | x_2) \cdots p(x_N | x_{N-1}) \quad (8.44)$$

现在将其转换为图 8.32 所示的无向图表示。在无向图中，最大团就是相邻节点对，因此根据式 (8.39)，我们希望将联合分布写成如下形式：

$$p(\mathbf{x}) = \frac{1}{Z} \psi_{1,2}(x_1, x_2) \psi_{2,3}(x_2, x_3) \cdots \psi_{N-1,N}(x_{N-1}, x_N) \quad (8.45)$$


这可以很容易地通过如下方式实现：

$$\begin{aligned} \psi_{1,2}(x_1, x_2) &= p(x_1) p(x_2 | x_1) \\ \psi_{2,3}(x_2, x_3) &= p(x_3 | x_2) \\ &\vdots \\ \psi_{N-1,N}(x_{N-1}, x_N) &= p(x_N | x_{N-1}) \end{aligned}$$

其中第一项的边缘分布 $p(x_1)$ 被吸收到第一个势函数中。注意在本例中分区函数 $Z = 1$ 。

下面考虑如何推广这一构造，使得任何由有向图因式分解定义分布都可以转换为无向图因式分解的形式。这在无向图的团势函数由有向图的条件分布给出时是可行的。为了使其有效，必须确保每个条件分布中出现的变量集合至少属于无向图的某个团。对于仅有一个父节点的有向图节点，这只需将有向边替换为无向边即可。然而，对

图 8.33 一个简单有向图的示例 (a)
及其对应的道德图 (b)。



于具有多个父节点的节点，这还远远不够。这些节点具有我们在讨论条件独立时遇到的“头对头”(head-to-head)路径。考虑图 8.33 所示的一个具有 4 个节点的简单有向图，其联合分布为：

$$p(\mathbf{x}) = p(x_1)p(x_2)p(x_3)p(x_4 | x_1, x_2, x_3) \quad (8.46)$$

我们看到因子 $p(x_4 | x_1, x_2, x_3)$ 涉及四个变量 x_1, x_2, x_3 和 x_4 ，因此如果要将这一条件分布吸收到某个团势函数中，它们必须属于同一个团。为了实现这一点，我们在节点 x_4 的所有父节点之间添加额外的连边。带有趣味性的历史称，这一过程被称为“使父母成婚”(moralization)，而将方向去掉后的无向图被称为道德图(moral graph)。重要的是注意到，在此例中，道德图是完全连通的，因此不再具有原始有向图所具有的任何条件独立性质。

因此，一般地，将有向图转换为无向图的步骤是：对于图中的每个节点，首先在其所有父节点之间加入额外的无向连边，然后去掉原有连边上的方向，从而得到道德图。接着，将道德图中所有团势函数初始化为 1。然后我们将有向图中的每个条件分布因子乘入某个团势函数中。由于道德化步骤的作用，总能找到至少一个最大团包含该因子中的所有变量。注意在所有情况下，分区函数都为 $Z = 1$ 。

将有向图转换为无向图的过程在一些精确推断技术中扮演着关键角色，例如交叉树(junction tree)算法。而从无向表示转为有向表示则要少得多，并且由于归一化约束的存在通常会带来困难。

我们看到，在从有向表示转为无向表示时必须丢弃图中的某些条件独立性质。当然，我们总可以采取平凡方式：直接使用一个完全连通的无向图，把任意有向图上的分布转为无向图上的分布。然而这样会丢弃所有条件独立结构，因此是无意义的。道德化过程添加的额外连边最少，因而保留的独立性质最多。

我们还看到，确定条件独立性质的程序在有向图与无向图中是不同的。事实证明，这两类图能够表达的条件独立性质也不同，这一点值得进一步探索。为此，我们再次将特定(有向或无向)图视为一种滤波器，即所有可能分布中的一部分会被过滤出来，从而只剩下那些满足图所隐含条件独立性的分布。


若一个分布满足的每条条件独立陈述都体现在图中，则称该图是该分布的 D 图(dependency map)。因此，一个完全断开的图(没有任何连边)对任何分布都将是一个平凡的 D 图。

另一种角度是：给定一个具体的分布，我们可以询问哪些图具有恰当的条件独立

性质。如果图所隐含的每条条件独立陈述都被该分布满足，则称该图为该分布的 I 图 (independence map)。显然，一个完全连通的图对任何分布都是平凡的 I 图。

如果分布的每条条件独立性质都反映在图中，同时图所表达的每条条件独立性质也都被分布满足，则称该图为该分布的完美图 (perfect map)。完美图同时是 I 图和 D 图。

图 8.34 维恩图示意了在给定变量集合上的所有分布 P ，其中 D 表示能够用有向图作为完美映射表示的分布集合， U 表示能够用无向图作为完美映射表示的分布集合。



考虑这样一类分布：对于其中的每个分布，都存在一个有向图是它的完美图。这个集合与另一类分布不同：其中每个分布都存在一个无向图是它的完美图。此外，还有一些分布既无法用有向图也无法用无向图完美表示。这在图 8.34 的维恩图中示意。

图 8.35 一个有向图，其条件独立性质无法通过在相同三个变量上的无向图来表达。





图 8.35 展示了一个有向图，它是某一分布的完美图，该分布满足的条件独立性质为 $A \perp\!\!\!\perp B \mid \emptyset$ 和 $A \perp\!\!\!\perp B \mid C$ 。在三个变量的情况下，没有任何无向图能够作为该分布的完美图。

图 8.36 一个无向图，其条件独立性质无法通过在相同变量上的有向图来表达。




反过来，考虑图 8.36 所示的四个变量的无向图。该图具有以下性质： $A \perp\!\!\!\perp B \mid \emptyset$ ， $C \perp\!\!\!\perp D \mid A \cup B$ ，以及 $A \perp\!\!\!\perp B \mid C \cup D$ 。不存在任何四个变量的有向图能隐含完全相同的条件独立结构。

图模型框架可以一致地扩展到既含有有向连边又含有无向连边的图中。这类图称为链图 (chain graphs) (Lauritzen and Wermuth, 1989; Frydenberg, 1990)，其中有向图和无向图都是特殊情况。尽管链图能表示比单纯的有向或无向图更广泛的分布类，但仍有一些分布即使链图也无法给出完美图。本书不再继续讨论链图。

8.4 图模型中的推断

现在我们转向图模型中的推断问题，其中图中的某些节点被固定为观测值，而我们的目标是计算一个或多个其他节点子集的后验分布。正如我们将看到的，我们可以利用图结构既找到高效的推断算法，又让这些算法的结构变得直观清晰。具体来说，我们会看到许多算法都可以表达成在图上局部信息传播的形式。本节中，我们将主要关注精确推断的方法，而在第 10 章中，我们将讨论若干近似推断算法。

图 8.37 贝叶斯定理的图形表示。细节见正文。



首先，让我们来看贝叶斯定理的图形化解释。假设我们将两个变量 x 和 y 上的联合分布 $p(x, y)$ 分解为因子乘积 $p(x, y) = p(x) p(y | x)$ 。这可以用图 8.37(a) 所示的有向图来表示。现在假设我们观测到 y 的值，如图 8.37(b) 中被涂阴影的节点所示。我们可以把边缘分布 $p(x)$ 看作潜在变量 x 的先验分布，而我们的目标是推断 x 的后验分布。利用概率的加和与乘法规则，我们可以计算

$$p(y) = \sum_{x'} p(y | x') p(x') \quad (8.47)$$

然后在贝叶斯定理中使用它来得到

$$p(x | y) = \frac{p(y | x) p(x)}{p(y)} \quad (8.48)$$

因此，联合分布现在用 $p(y)$ 和 $p(x | y)$ 来表示。从图的角度看，联合分布 $p(x, y)$ 现在由图 8.37(c) 所示的图来表示，其中箭头的方向被反转了。这是图模型推断问题中最简单的一个例子。

8.4.1 链上的推断

接下来考虑一个更复杂的问题，它涉及图 8.32 所示形式的链式节点。这个例子将为后面关于更一般图中精确推断的讨论打下基础。

具体来说，我们将考虑图 8.32(b) 中的无向图。我们已经看到，有向链可以转化为等价的无向链。因为该有向图中不存在拥有多个父节点的节点，所以这一转换不需要添加任何额外的连边，因此有向和无向版本的图表达的是完全相同的一组条件独立关系。

该图上的联合分布具有如下形式：

$$p(\mathbf{x}) = \frac{1}{Z} \psi_{1,2}(x_1, x_2) \psi_{2,3}(x_2, x_3) \cdots \psi_{N-1,N}(x_{N-1}, x_N) \quad (8.49)$$

我们将考虑一个具体情形： N 个节点分别表示具有 K 个状态的离散变量。在这种情况下，每个势函数 $\psi_{n-1,n}(x_{n-1}, x_n)$ 构成一个 $K \times K$ 的表，因此该联合分布一共包含 $(N-1)K^2$ 个参数。

现在来考虑推断问题：对链中某个中间节点 x_n ，求它的边缘分布 $p(x_n)$ 。注意此时还不存在任何观测节点。根据定义，所需的边缘分布是通过除 x_n 以外的所有变量求和来得到的，因此

$$p(x_n) = \sum_{x_1} \cdots \sum_{x_{n-1}} \sum_{x_{n+1}} \cdots \sum_{x_N} p(\mathbf{x}) \quad (8.50)$$

在一个朴素实现中，我们会先计算联合分布，然后再显式地执行这些求和。联合分布可以表示为一组数，每个 $\mathbf{x}$ 的可能取值对应一个数。由于有 N 个变量，每个有 K 个状态，因此 $\mathbf{x}$ 有 K^N 种取值；于是联合分布的计算与存储，以及为了得到 $p(x_n)$ 而进行的边缘化，其存储与计算量都会随链的长度 N 指数级增长。

然而，我们可以通过利用图模型中的条件独立性质得到一个高效得多的算法。如果我们将联合分布的因式分解形式 (8.49) 代入式 (8.50)，就可以重新排列求和与乘法运算的顺序，从而大大提高计算所需边缘分布的效率。以对 x_N 的求和为例，势函数 $\psi_{N-1,N}(x_{N-1}, x_N)$ 是唯一依赖于 x_N 的部分，因此我们可以先执行

$$\sum_{x_N} \psi_{N-1,N}(x_{N-1}, x_N) \quad (8.51)$$

得到一个关于 x_{N-1} 的函数。然后我们可以利用这个函数对 x_{N-1} 进行求和，此时只涉及这个新函数以及势函数 $\psi_{N-2,N-1}(x_{N-2}, x_{N-1})$ ，因为这是 x_{N-1} 出现的唯一另一个位置。类似地，对 x_1 的求和只涉及势函数 $\psi_{1,2}(x_1, x_2)$ ，因此可以单独执行以得到一个关于 x_2 的函数，依此类推。由于每次求和实际上会从分布中消去一个变量，这可以理解为由图中删去一个节点。

如果我们以这种方式将势函数和求和运算组合在一起，就可以把所需的边缘分布表示为

$$p(x_n) = \frac{1}{Z} \underbrace{\left[\sum_{x_{n-1}} \psi_{n-1,n}(x_{n-1}, x_n) \cdots \left[\sum_{x_2} \psi_{2,3}(x_2, x_3) \left[\sum_{x_1} \psi_{1,2}(x_1, x_2) \right] \right] \cdots \right]}_{\mu_\alpha(x_n)} \underbrace{\left[\sum_{x_{n+1}} \psi_{n,n+1}(x_n, x_{n+1}) \cdots \left[\sum_{x_N} \psi_{N-1,N}(x_{N-1}, x_N) \right] \cdots \right]}_{\mu_\beta(x_n)} \quad (8.52)$$

读者应当仔细研究这一重排过程，因为其基本思想构成了后面讨论一般和积 (sum-product) 算法的基础。这里我们所利用的核心概念是：乘法对加法是可分配的，也就是说

$$ab + ac = a(b + c) \quad (8.53)$$

在等式左边需要进行三次算术运算，而右边将其减少为两次。

让我们用这种重新排列后的表达式来推算计算所需边缘分布的代价。我们需要进行 $N - 1$ 次求和，每次求和都在 K 个状态上进行，并且每次都涉及一个关于两个变量

的函数。例如，对 x_1 的求和只涉及函数 $\psi_{1,2}(x_1, x_2)$ ，它是一个 $K \times K$ 的数表。我们需要对每个 x_2 的取值，将这个表在 x_1 上求和，因此代价为 $O(K^2)$ 。得到的包含 K 个数的向量再与数表 $\psi_{2,3}(x_2, x_3)$ 相乘，因此同样是 $O(K^2)$ 。由于总共有 $N - 1$ 次这样的求和与乘法运算，计算边缘分布 $p(x_n)$ 的总代价为 $O(NK^2)$ 。这在链长 N 上是线性的，而朴素方法的代价则是指数级的。因此，我们成功利用了这个简单图的众多条件独立性质，从而获得了高效的计算方式。若图是完全连通的，就不存在任何条件独立性质，我们就只能直接处理完整的联合分布。

现在，我们给出对该计算的一个强有力的解释：它可以看作是在图上进行局部信息传递。从式 (8.52) 可以看到，边缘分布 $p(x_n)$ 的表达式分解为两个因子的乘积再乘以归一化常数：

$$p(x_n) = \frac{1}{Z} \mu_\alpha(x_n) \mu_\beta(x_n) \quad (8.54)$$

我们可以把 $\mu_\alpha(x_n)$ 解释为沿链从节点 x_{n-1} 传向节点 x_n 的前向信息。同样， $\mu_\beta(x_n)$ 可以看作从节点 x_{n+1} 传回到节点 x_n 的后向信息。注意，每条信息都包含 K 个数，对应于 x_n 的每一种取值，因此两条信息的乘积应理解为对相应分量的逐点相乘，从而得到另一组 K 个数。

信息 $\mu_\alpha(x_n)$ 可以递归地计算，因为

$$\begin{aligned} \mu_\alpha(x_n) &= \sum_{x_{n-1}} \psi_{n-1,n}(x_{n-1}, x_n) \left[\sum_{x_{n-2}} \cdots \right] \\ &= \sum_{x_{n-1}} \psi_{n-1,n}(x_{n-1}, x_n) \mu_\alpha(x_{n-1}) \end{aligned} \quad (8.55)$$

因此，我们首先计算

$$\mu_\alpha(x_2) = \sum_{x_1} \psi_{1,2}(x_1, x_2) \quad (8.56)$$

然后不断应用式 (8.55)，直到到达所需节点。务必注意信息传递方程的结构：在式 (8.55) 中，输出信息 $\mu_\alpha(x_n)$ 是通过将输入信息 $\mu_\alpha(x_{n-1})$ 与包含“当前节点变量”和“输出变量”的局部势函数相乘，然后对当前节点变量求和得到的。

同样，信息 $\mu_\beta(x_n)$ 也可以递归计算，我们从节点 x_N 开始并使用

$$\begin{aligned} \mu_\beta(x_n) &= \sum_{x_{n+1}} \psi_{n+1,n}(x_{n+1}, x_n) \left[\sum_{x_{n+2}} \cdots \right] \\ &= \sum_{x_{n+1}} \psi_{n+1,n}(x_{n+1}, x_n) \mu_\beta(x_{n+1}) \end{aligned} \quad (8.57)$$


这种递归的信息传递在图 8.38 中有所示意。归一化常数 Z 可以通过对式 (8.54) 右侧关于 x_n 的所有状态求和来轻松计算，这一操作只需要 $O(K)$ 的计算量。

图 8.38 所示形式的图称为马尔可夫链，而相应的信息传递方程是马尔可夫过程的 Chapman-Kolmogorov 方程的一个实例 (Papoulis, 1984)。

现在假设我们希望计算链中所有节点 $n \in \{1, \dots, N\}$ 的边缘分布 $p(x_n)$ 。若对每个节点分别独立应用前述过程，则计算代价将是 $O(N^2 K^2)$ 。然而，这样的做法会造成巨

图 8.38 链中节点 x_n 的边缘

分布 $p(x_n)$ 可通过将
两个消息 $\mu_\alpha(x_n)$ 与
 $\mu_\beta(x_n)$ 相乘并归一化
得到。这些消息本身
可以通过从链的两端
向节点 x_n 传递消息而
递归计算。



大浪费。例如，为了求 $p(x_1)$ ，我们需要将一个从节点 x_N 开始的后向信息 $\mu_\beta(\cdot)$ 传递回节点 x_2 。同样，为了求 $p(x_2)$ ，我们必须将一个后向信息从 x_N 传回 x_3 。两者之间的大部分计算完全重复。

更高效的方法是：先从节点 x_N 发出信息 $\mu_\beta(x_{N-1})$ ，将相应信息一路向后传播到 x_1 ；同时，从节点 x_1 发出信息 $\mu_\alpha(x_2)$ ，将相应信息一路向前传播到 x_N 。如果我们在传播过程中存下所有中间信息，那么每个节点只需应用式 (8.54) 即可直接求得自己的边缘分布。整个过程的计算代价仅为求单个节点边缘分布的两倍，而不是 N 倍。也就是说，每条边仅被信息在两个方向各通过一次。此外，归一化常数 Z 只需在任意方便的一个节点上求一次即可。

如果图中某些节点带有观测值，那么相应变量被固定为观测值，不再参与求和。要理解这一点，可以注意：将变量 x_n 固定为观测值 $\hat{x}_n$ 的效果，可以通过将联合分布乘上额外函数 $I(x_n, \hat{x}_n)$ 来实现。该函数在 $x_n = \hat{x}_n$ 时取值为 1，其他情况下取值为 0。然后我们可以把这样一个函数吸收到包含变量 x_n 的每个势函数中。此时，对 x_n 的求和只剩一个项： $x_n = \hat{x}_n$ 。

现在假设我们希望计算链中两个相邻节点的联合分布 $p(x_{n-1}, x_n)$ 。这与求单个节点的边缘分布非常类似，只不过现在有两个变量不被求和。稍加思考即可得到所需的联合分布形式：

$$p(x_{n-1}, x_n) = \frac{1}{Z} \mu_\alpha(x_{n-1}) \psi_{n-1,n}(x_{n-1}, x_n) \mu_\beta(x_n) \quad (8.58)$$

因此，一旦为了计算边缘分布而完成了信息传递，我们就可以直接得到所有势函数对应变量集合的联合分布。

这个结果非常有用，因为在实际应用中，我们往往会为团势函数采用参数化形式；如果是从有向图开始，也可以等价地认为是对条件分布进行参数化。在部分变量不可见的情况下，我们可以使用 EM 算法来学习这些势函数的参数，而在 E 步中恰恰需要的就是给定观测数据后团的局部联合分布。对此我们将在第 13 章中给出一些详细示例。


8.4.2 树

我们已经看到，对于由链状节点组成的图，可以在线性时间内进行精确推断，并且这些推断算法可以解释为沿链进行的信息传递。更一般地，对于一类更广的图——树结构图 (trees)，也可以通过局部信息传递来高效地进行推断。很快我们将把前面为链推

导的信息传递形式加以推广，得到和积（sum-product）算法，它为树状图中的精确推断提供了高效框架。

图 8.39 树结构图的示例：

(a) 无向树, (b) 有向树, (c) 有向多树。



对于无向图，树被定义为：在任意两个节点之间恰有一条路径的图。因此这种图中不存在环。对于有向图，树被定义为：存在一个没有父节点的特殊节点（称为根 root），并且所有其他节点都恰好有一个父节点。如果将一个有向树转化为无向图，则由于所有节点最多只有一个父亲，因此道德化步骤不会添加额外连边，从而对应的道德图是无向树。图 8.39(a) 和图 8.39(b) 分别给出了无向树和有向树的例子。一个用有向树表示的分布可以轻易地转换成用无向树表示，反之亦然。

如果一个有向图中存在有多个父节点的节点，但（忽略方向）任意两个节点之间仍仅有一条路径，那么该图称为多重树（polytree），如图 8.39(c) 所示。这样的图会有多个无父节点，并且其对应的道德化无向图将包含环。

8.4.3 因子图

下一节将推导的和积算法可以用于无向树、有向树以及多重树。若我们首先引入一种称为因子图（factor graph）的新图结构，则这种算法可以以一种特别简单且一般化的形式呈现（Frey, 1998；Kschischang et al., 2001）。

无论是有向图还是无向图，都能把若干变量上的全局函数分解为一些因子在变量子集上的乘积。因子图将这种分解显式化：除了表示变量的节点外，还引入表示因子的节点。因子图也让因式分解的细节呈现得更明确，如我们将看到的。

设联合分布写成如下因式分解形式：

$$p(\mathbf{x}) = \prod_s f_s(\mathbf{x}_s) \quad (8.59)$$

其中 $\mathbf{x}_s$ 表示变量的某个子集。方便起见，我们将单个变量记为 x_i ，但如前所述，它们也可以是变量组（如向量或矩阵）。每个因子 f_s 是其对应变量子集 $\mathbf{x}_s$ 的函数。


有向图的因式分解如式 (8.5) 所定义，是式 (8.59) 的特殊情形，此时因子 $f_s(\mathbf{x}_s)$ 就是局部条件分布。类似地，无向图如式 (8.39) 所示，也是式 (8.59) 的特殊情形，此时因子是最大团上的势函数（归一化系数 $1/Z$ 可视为定义在空变量集上的因子）。

在因子图中，正如在有向图和无向图中一样，分布中的每个变量都有一个节点（圆形）；另外还引入因子节点（小方块），对应联合分布中的每个因子 $f_s(\mathbf{x}_s)$ ；最后，在因子节点与其依赖的所有变量节点之间添加无向连边。举例来说，考虑如下因式分解：

$$p(\mathbf{x}) = f_a(x_1, x_2) f_b(x_1, x_2) f_c(x_2, x_3) f_d(x_3) \quad (8.60)$$

这可由图 8.40 所示的因子图表示。注意其中有两个因子 $f_a(x_1, x_2)$ 与 $f_b(x_1, x_2)$ 作用于同一组变量。在无向图中，这两个因子的乘积会被合并成同一个团势。同样， $f_c(x_2, x_3)$ 和 $f_d(x_3)$ 也可以合并为定义在 x_2 和 x_3 上的单个势函数。然而因子图将所有因子明确地保留下来，因此可以提供更详细的因式分解信息。

图 8.40 与分解式 (8.60) 相对应的因子图示例。



因子图被称为二分图 (bipartite graph)，因为它包含两类不同的节点，并且所有连边都连接不同类型的节点。一般来说，因子图总是可以绘制成两排节点（上排是变量节点，下排是因子节点），并且连边连接两排节点，如图 8.40 所示。不过在某些情况下，其他布局方式可能更直观，例如当因子图来自有向图或无向图时，这一点稍后会看到。

若我们有一个用无向图表示的分布，则可以很容易地将其转换为因子图。方法是：为原无向图的每个节点创建一个变量节点，然后为每个最大团 $\mathbf{x}_s$ 创建因子节点，并将因子 $f_s(\mathbf{x}_s)$ 设为对应的团势函数。注意，可能存在多个不同的因子图对应于同一个无向图。图 8.41 展示了这些概念。




图 8.41 (a) 一个无向图，包含单一团势函数 $\psi(x_1, x_2, x_3)$ 。(b) 一个因子图，包含因子 $f(x_1, x_2, x_3) = \psi(x_1, x_2, x_3)$ ，表示与该无向图相同的分布。(c) 一个不同的因子图，也表示相同的分布，其中因子满足 $f_a(x_1, x_2, x_3) f_b(x_1, x_2) = \psi(x_1, x_2, x_3)$ 。

类似地，将有向图转换为因子图的步骤是：首先创建对应于有向图节点的变量节点，然后为每个条件分布创建因子节点，最后添加相应连边。同样，多个因子图都可以对应于同一个有向图。图 8.42 展示了这一转换过程。

我们已经指出：树状图结构对于高效推断至关重要。如果从一个有向树或无向树生成因子图，那么得到的因子图仍然是树（即其中不存在任何环，并且任意两节点之间仅有一条路径）。对于有向多重树，将其转换为无向图会因道德化出现环，而转换为因子图却仍得到树，如图 8.43 所示。事实上，由于父节点之间的连边产生的有向图局部环，可以在转换为因子图时通过合适定义因子函数来去除，如图 8.44 所示。

我们已经看到：用于表示同一个有向图或无向图的因子图并不唯一。这使因子图可以更明确刻画因式分解的精确形式。图 8.45 给出一个完全连通的无向图及两个不同的




图 8.42 (a) 一个有向图，其分解为 $p(x_1)p(x_2)p(x_3 | x_1, x_2)$ 。(b) 一个因子图，表示与该有向图相同的分布，其因子满足 $f(x_1, x_2, x_3) = p(x_1)p(x_2)p(x_3 | x_1, x_2)$ 。(c) 一个不同的因子图，也表示相同的分布，其中因子为 $f_a(x_1) = p(x_1)$ ， $f_b(x_2) = p(x_2)$ ，以及 $f_c(x_1, x_2, x_3) = p(x_3 | x_1, x_2)$ 。




图 8.43 (a) 一个有向多树。(b) 将该多树转换为无向图后的结果，显示了环的产生。(c) 将该多树转换为因子图后的结果，因子图保留了树结构。

因子图。在 (b) 中，联合分布给出为一般形式 $p(\mathbf{x}) = f(x_1, x_2, x_3)$ ；而在 (c) 中，则给出更具体的因式分解： $p(\mathbf{x}) = f_a(x_1, x_2) f_b(x_1, x_3) f_c(x_2, x_3)$ 。需要强调的是，(c) 中的因式分解并不对应任何条件独立性质。

8.4.4 和积算法

我们现在利用因子图框架，推导一类强大的高效精确推断算法，它适用于树结构图。在本节中，我们关注求解节点或节点子集的局部边缘分布，这将引出和积（sum-product）算法。随后我们会对技术进行修改，使其能够找到最可能的状态，得到最大和（max-sum）算法。

这里先假设模型中的所有变量都是离散的，因此边缘化对应求和。不过同样的框架也适用于线性高斯模型，此时边缘化变成积分。在讨论线性动态系统时，我们会详细说明这一点。

针对无环的有向图，存在一种精确推断方法称为信念传播（belief propagation）（Pearl, 1988; Lauritzen and Spiegelhalter, 1988），它是和积算法的一个特例。我们只考虑和积算




图 8.44 (a) 一个具有局部环的有向图片段。(b) 转换为树结构的因子图片段，其中 $f(x_1, x_2, x_3) = p(x_1)p(x_2 | x_1)p(x_3 | x_1, x_2)$ 。




图 8.45 (a) 一个完全连接的无向图。(b) 和 (c) 为两个因子图，它们都对应于 (a) 中的无向图。

法，因为它推导更简单、应用更方便，也更一般。


我们假设原始图是无向树、有向树或重树，因此对应的因子图具有树结构。我们首先将原始图转换为因子图，以便使用统一框架处理有向与无向模型。我们的目标是利用图的结构实现两件事：(i) 获得一种高效、精确的边缘分布推断方法；(ii) 在需要多个边缘分布时，使计算能够被高效共享。

从求某一变量节点 x 的边缘分布 $p(x)$ 的问题开始。暂时假设所有变量都是隐藏变量。稍后我们将看到如何把具有观测值的变量也纳入算法。根据定义，边缘分布通过对除了 x 以外的所有变量求和得到：

$$p(x) = \sum_{\mathbf{x} \setminus x} p(\mathbf{x}) \quad (8.61)$$

其中 $\mathbf{x} \setminus x$ 表示变量集合 $\mathbf{x}$ 中去掉变量 x 之后的所有变量。

图 8.46 一个因子图片段，用于说明边缘分布 $p(x)$ 的计算过程。



我们要做的是，将 $p(\mathbf{x})$ 的因子图形式 (8.59) 代入上式，然后交换求和和乘积的顺序，从而得到一个高效算法。考虑图 8.46 所示的图结构片段，可以看到由于图具有树结构，我们可以将联合分布中的因子划分成若干组，每组与变量节点 x 的邻居因子节点之一对应。于是联合分布可写为：

$$p(\mathbf{x}) = \prod_{s \in \text{ne}(x)} F_s(x, X_s) \quad (8.62)$$

其中 $\text{ne}(x)$ 表示变量 x 的所有邻居因子节点的集合， X_s 表示通过因子节点 f_s 与变量 x 相连的子树中的所有变量， $F_s(x, X_s)$ 表示因子 f_s 所对应组中所有因子的乘积。

将式 (8.62) 代入式 (8.61)，并交换求和与乘积顺序，可得：

$$\begin{aligned} p(x) &= \prod_{s \in \text{ne}(x)} \left[\sum_{X_s} F_s(x, X_s) \right] \\ &= \prod_{s \in \text{ne}(x)} \mu_{f_s \rightarrow x}(x). \end{aligned} \quad (8.63)$$

这里我们引入了一组函数 $\mu_{f_s \rightarrow x}(x)$ ，定义为

$$\mu_{f_s \rightarrow x}(x) \equiv \sum_{X_s} F_s(x, X_s) \quad (8.64)$$


它们可以视为从因子节点 f_s 发往变量节点 x 的信息。于是可见，所需的边缘分布 $p(x)$ 就是所有进入 x 的信息的乘积。

为了能够计算这些信息，我们再次参考图 8.46，并注意到每个因子 $F_s(x, X_s)$ 本身对应一个因子（子）图，因此它自身也可以进一步被因式分解。具体来说，可以写成

$$F_s(x, X_s) = f_s(x, x_1, \dots, x_M) G_1(x_1, X_{s1}) \cdots G_M(x_M, X_{sM}) \quad (8.65)$$

其中，为了方便，我们将因子 f_s 所依赖的、除 x 之外的变量记为 $x_1, \dots, x_M$ 。这种因式分解如图 8.47 所示。需要注意的是，变量集合 $\{x, x_1, \dots, x_M\}$ 正是因子 f_s 所依赖的全部变量，因此也可写成 $\mathbf{x}_s$ ，即式 (8.59) 中的记号。

图 8.47 展示与因子节点 f_x 相关的子图的分解示意图。



将式 (8.65) 代入式 (8.64)，得到

$$\begin{aligned} \mu_{f_s \rightarrow x}(x) &= \sum_{x_1} \cdots \sum_{x_M} f_s(x, x_1, \dots, x_M) \prod_{m \in \text{ne}(f_s) \setminus x} \left[\sum_{X_{sm}} G_m(x_m, X_{sm}) \right] \\ &= \sum_{x_1} \cdots \sum_{x_M} f_s(x, x_1, \dots, x_M) \prod_{m \in \text{ne}(f_s) \setminus x} \mu_{x_m \rightarrow f_s}(x_m) \end{aligned} \quad (8.66)$$


其中， $\text{ne}(f_s)$ 表示与因子节点 f_s 相邻的变量节点集合，而 $\text{ne}(f_s) \setminus x$ 表示其中除去变量 x 后的节点集合。这里我们定义了从变量节点到因子节点的信息：

$$\mu_{x_m \rightarrow f_s}(x_m) \equiv \sum_{X_{sm}} G_m(x_m, X_{sm}) \quad (8.67)$$

因此，我们引入了两种不同类型的信息：从因子节点到变量节点的信息 $\mu_{f \rightarrow x}(x)$ ，以及从变量节点到因子节点的信息 $\mu_{x \rightarrow f}(x)$ 。无论是哪一类信息，信息总是作为变量节点对应变量的函数而传递。

式 (8.66) 的含义是：为了计算因子节点沿连接它和变量节点的连边发送的信息，需要将该因子节点从其他邻居变量节点收到的所有信息相乘，再乘以该因子自身，然后对所有与进入信息相关的变量求和。图 8.47 展示了这一过程。重要的是：只有当一个因子节点已经从所有其他相邻变量节点收到信息后，它才能向某个变量节点发送信息。

图 8.48 展示变量节点向相邻因子节点发送消息的计算过程示意图。



接下来我们推导从变量节点到因子节点的信息表达式，这再次利用了图的子结构因式分解。根据图 8.48，可以看到与变量 x_m 相关的项 $G_m(x_m, X_{sm})$ 可以写成所有与 x_m 相邻的因子节点（排除 f_s ）对应项 $F_l(x_m, X_{ml})$ 的乘积：

$$G_m(x_m, X_{sm}) = \prod_{l \in \text{ne}(x_m) \setminus f_s} F_l(x_m, X_{ml}) \quad (8.68)$$

将式 (8.68) 代入式 (8.67)，可得

$$\begin{aligned} \mu_{x_m \rightarrow f_s}(x_m) &= \prod_{l \in \text{ne}(x_m) \setminus f_s} \left[\sum_{X_{ml}} F_l(x_m, X_{ml}) \right] \\ &= \prod_{l \in \text{ne}(x_m) \setminus f_s} \mu_{f_l \rightarrow x_m}(x_m) \end{aligned} \quad (8.69)$$

其中使用了式 (8.64) 中从因子节点到变量节点的信息定义。因此，为了计算一个变量节点沿其连边向某个因子节点发送的信息，我们只需将从所有其他相邻因子节点收到的信息相乘。注意：若一个变量节点只有两个邻居，它不进行任何计算，而是简单地原样传递信息。此外，一个变量节点只有在从所有其他邻居因子节点收到信息后才能向某个因子节点发送信息。

回忆一下我们的目标是求变量节点 x 的边缘分布，而该边缘分布等于沿所有连向 x 的连边传来的信息的乘积。每一条信息都可以递归地用其他信息计算出来。为了启动递归，可以把节点 x 视为树的根，从叶节点开始。由式 (8.69) 可见，如果叶节点是变量节点，那么它沿唯一一条连边发送的信息为：

$$\mu_{x \rightarrow f}(x) = 1 \quad (8.70)$$


如图 8.49(a) 所示。同样，如果叶节点是因子节点，那么根据式 (8.66)，其发送的信

息为：

$$\mu_{f \rightarrow x}(x) = f(x) \quad (8.71)$$

如图 8.49(b) 所示。

图 8.49 和积算法从叶节点发送消息开始，具体取决于叶节点是 (a) 变量节点，还是 (b) 因子节点。



此时值得总结一下目前为止我们得到的用于计算边缘分布 $p(x)$ 的和积算法。我们将变量节点 x 视为因子图的根节点，并使用式 (8.70) 和 (8.71) 在叶节点初始化信息。然后递归地应用信息传递步骤 (8.66) 和 (8.69)，直到所有连边上都传播过信息，并且根节点从其全部邻居处收到信息。当根节点收到所有邻居的信息后，就可以通过式 (8.63) 计算所需的边缘分布。我们很快会给出这一过程的示例。

为了说明每个节点总能收到足够的信息以便能够发送出自己的信息，可以用一个简单的归纳论证如下。显然，对于一个由变量根节点直接连接若干因子叶节点构成的图，算法仅仅涉及将形如 (8.71) 的信息直接从叶节点发送到根节点。现在设想我们通过一次添加一个节点的方式逐步构建一般的图，并且假设对于某个中间图我们已经有了一个有效的算法。当再添加一个（变量或因子）节点时，因为整个图必须保持树结构，它只能通过一条连边连接到已有图中，因此该新节点必然是一个叶节点。于是它会向与之相连的节点发送一条信息，而后者因此将收到所有它需要的信息来向根方向发送信息，于是我们再次得到一个有效的算法，从而完成证明。

现在假设我们希望求图中每个变量节点的边缘分布。可以通过对每个节点重新执行上述算法来实现，但这会非常低效，因为许多必需的计算会被重复。通过将这些多重信息传递过程“叠加”起来，可以得到一个更高效的通用和积算法：任意选取一个变量节点或因子节点，将其指定为根节点。像之前一样，将信息从叶节点传向根节点。此时根节点已经从所有邻居收到信息，因此它可以向所有邻居发送信息。随后这些邻居也已经从所有邻居收到信息，因而可以沿远离根的方向发送信息，以此类推。通过这种方式，信息从根节点向外层层传递直到叶节点。此时，每一条连边上已经有信息双向通过，并且每个节点都已从所有邻居处收到信息。再次可以通过简单的归纳证明此信息传递方案的正确性。因为每个变量节点都已收到来自所有邻居的信息，我们就能轻松计算所有变量的边缘分布。需要计算的信息数量等于图中连边数量的两倍，因此所需计算量只是求一个单一边缘分布的两倍。相比之下，如果为每个节点分别运行一次和积算法，则计算量会随图规模平方增长。值得注意的是，该算法实际上与选择哪个节点作为根无关，根节点的特殊地位只是为了更便于讲解信息传递过程。

接下来假设我们希望求与每个因子对应的变量集合的边缘分布 $p(\mathbf{x}_s)$ 。可以用与上面类似的论证看到，因子节点的边缘分布由到达该因子节点的所有信息与其局部因子


函数的乘积给出：

$$p(\mathbf{x}_s) = f_s(\mathbf{x}_s) \prod_{i \in \text{ne}(f_s)} \mu_{x_i \rightarrow f_s}(x_i) \quad (8.72)$$

这与变量节点的边缘分布完全类似。如果因子是带参数的函数，而我们希望用 EM 算法来学习参数，那么这些边缘分布正是在 E 步中需要计算的量，我们将在第 13 章讨论隐马尔可夫模型时详细看到这一点。


正如之前看到的，变量节点向因子节点发送的信息只是其他连边上传入信息的乘积。如果愿意，可以换一种方式理解和积算法，即消去从变量节点到因子节点的信息，而只考虑因子节点发出的信息。通过观察图 8.50 的例子可以最容易地看到这一点。

图 8.50 和积算法也可以仅从因子节点向其他因子节点发送消息的角度来看待。在此示例中，由蓝色箭头表示的输出消息，是通过对所有由绿色箭头表示的输入消息求积，再乘以因子 f_x ，并对变量 x_1 和 x_2 进行边缘化而得到的。



到目前为止，我们忽略了归一化问题。如果因子图源自一个有向图，则联合分布本身已经正确归一化，因此和积算法得到的边缘分布也自动是归一化的。然而，如果从无向图开始，那么联合分布一般会带有未知的归一化系数 $1/Z$ 。如同图 8.38 中的简单链式示例，可以通过使用未归一化版本 $\tilde{p}(\mathbf{x})$ 来处理，其中 $p(\mathbf{x}) = \tilde{p}(\mathbf{x})/Z$ 。我们首先运行和积算法得到未归一化的边缘分布 $\tilde{p}(x_i)$ 。然后可以通过对任意一个这样的边缘分布归一化来求得系数 $1/Z$ ，这非常高效，因为归一化只在单个变量上进行，而不像直接归一化 $\tilde{p}(\mathbf{x})$ 那样需要在整个变量集合上求和。

图 8.51 一个用于说明和积算法的简单因子图。



此时，考虑一个简单的示例来说明和积算法的运作会很有帮助。图 8.51 展示了一个包含 4 个节点的因子图，其未归一化的联合分布为

$$\tilde{p}(\mathbf{x}) = f_a(x_1, x_2) f_b(x_2, x_3) f_c(x_2, x_4) \quad (8.73)$$

。

为了在该图上应用和积算法，我们将节点 x_3 指定为根节点，此时叶节点为 x_1 与

x_4 。从叶节点出发，我们得到以下六条信息的顺序：

$$\mu_{x_1 \rightarrow f_a}(x_1) = 1 \quad (8.74)$$

$$\mu_{f_a \rightarrow x_2}(x_2) = \sum_{x_1} f_a(x_1, x_2) \quad (8.75)$$

$$\mu_{x_4 \rightarrow f_c}(x_4) = 1 \quad (8.76)$$

$$\mu_{f_c \rightarrow x_2}(x_2) = \sum_{x_4} f_c(x_2, x_4) \quad (8.77)$$

$$\mu_{x_2 \rightarrow f_b}(x_2) = \mu_{f_a \rightarrow x_2}(x_2) \mu_{f_c \rightarrow x_2}(x_2) \quad (8.78)$$

$$\mu_{f_b \rightarrow x_3}(x_3) = \sum_{x_2} f_b(x_2, x_3) \mu_{x_2 \rightarrow f_b}(x_2) \quad (8.79)$$




图 8.52 和积算法在图 8.51 示例图中的消息传递过程。(a) 从叶节点 x_1 和 x_4 向根节点 x_3 传递消息。
(b) 再从根节点向叶节点传递消息。

这些信息传播的方向如图 8.52 所示。完成这一轮信息传播后，我们再从根节点向外传播信息到叶节点，其表达式如下：

$$\mu_{x_3 \rightarrow f_b}(x_3) = 1 \quad (8.80)$$

$$\mu_{f_b \rightarrow x_2}(x_2) = \sum_{x_3} f_b(x_2, x_3) \quad (8.81)$$

$$\mu_{x_2 \rightarrow f_a}(x_2) = \mu_{f_b \rightarrow x_2}(x_2) \mu_{f_c \rightarrow x_2}(x_2) \quad (8.82)$$

$$\mu_{f_a \rightarrow x_1}(x_1) = \sum_{x_2} f_a(x_1, x_2) \mu_{x_2 \rightarrow f_a}(x_2) \quad (8.83)$$

$$\mu_{x_2 \rightarrow f_c}(x_2) = \mu_{f_a \rightarrow x_2}(x_2) \mu_{f_b \rightarrow x_2}(x_2) \quad (8.84)$$

$$\mu_{f_c \rightarrow x_4}(x_4) = \sum_{x_2} f_c(x_2, x_4) \mu_{x_2 \rightarrow f_c}(x_2). \quad (8.85)$$

此时，每条连边都已实现了双向信息传递，因此可以开始计算边缘分布。作为一个简单检验，让我们验证边缘分布 $p(x_2)$ 是否具有正确形式。根据 (8.63) 并代入前述信息，

有

$$\begin{aligned}
 \tilde{p}(x_2) &= \mu_{f_a \rightarrow x_2}(x_2) \mu_{f_b \rightarrow x_2}(x_2) \mu_{f_c \rightarrow x_2}(x_2) \\
 &= \left[\sum_{x_1} f_a(x_1, x_2) \right] \left[\sum_{x_3} f_b(x_2, x_3) \right] \left[\sum_{x_4} f_c(x_2, x_4) \right] \\
 &= \sum_{x_1} \sum_{x_3} \sum_{x_4} f_a(x_1, x_2) f_b(x_2, x_3) f_c(x_2, x_4) \\
 &= \sum_{x_1} \sum_{x_3} \sum_{x_4} \tilde{p}(\mathbf{x})
 \end{aligned} \tag{8.86}$$

这确实是正确的结果。

到目前为止，我们一直假设图中所有变量都是隐藏的。在大多数实际应用中，一部分变量是观测到的，而我们希望计算在这些观测条件下的后验分布。观测节点在和积算法中很容易处理。假设我们把 $\mathbf{x}$ 划分为隐藏变量 $\mathbf{h}$ 和观测变量 $\mathbf{v}$ ，其观测值记为 $\hat{\mathbf{v}}$ 。我们只需将联合分布 $p(\mathbf{x})$ 乘以 $\prod_i I(v_i, \hat{v}_i)$ ，其中 $I(v, \hat{v}) = 1$ 当 $v = \hat{v}$ ，否则为 0。这个乘积对应于 $p(\mathbf{h}, \mathbf{v} = \hat{\mathbf{v}})$ ，因此是 $p(\mathbf{h} | \mathbf{v} = \hat{\mathbf{v}})$ 的未归一化版本。通过运行和积算法，可以高效地计算后验边缘分布 $p(h_i | \mathbf{v} = \hat{\mathbf{v}})$ ，其归一化系数可通过局部计算轻松得到。任意关于 $\mathbf{v}$ 的求和都会因为指示函数而简化为单项。

本节始终假设变量是离散的，但无论图结构还是和积算法的概率形式，都不特定依赖离散性。若变量为连续型，只需将求和换为积分即可。在线性高斯模型中我们会给出一个和积算法的示例，并在讨论线性动态系统时详细说明。

8.4.5 最大-求和算法

和-积算法允许我们将联合分布 $p(\mathbf{x})$ 表示为因子图，并有效地求出各个变量的边缘分布。另两个常见任务是找到使概率最大的变量取值，以及求出该最大概率的数值。这些可以通过一个密切相关的算法——最大-求和（max-sum）算法来解决，它可以看作图模型中动态规划的一个应用（Cormen 等，2001）。

一个简单的方法是先运行和-积算法以获得每个变量的边缘分布 $p(x_i)$ ，然后依次找到使每个边缘分布最大的取值 x_i^* 。然而，这样得到的是各变量“各自最可能”的取值。在实践中，我们通常希望找到“联合概率”最大的变量取值集合，即找到使联合分布最大的向量 $\mathbf{x}^{\max}$ ，从而有

$$\mathbf{x}^{\max} = \arg \max_{\mathbf{x}} p(\mathbf{x}) \tag{8.87}$$

其对应的最大联合概率为

$$p(\mathbf{x}^{\max}) = \max_{\mathbf{x}} p(\mathbf{x}) \tag{8.88}$$

一般来说， $\mathbf{x}^{\max}$ 与各自最大化边缘分布得到的 x_i^* 并不相同，这一点可以用一个简单的例子说明。考虑表 8.1 中给出的两个二值变量 $x, y \in \{0, 1\}$ 的联合分布 $p(x, y)$ 。联合分布在 $x = 1, y = 0$ 时取得最大值 0.4。然而，对 y 的两种取值求和得到的边缘分布为 $p(x = 0) = 0.6, p(x = 1) = 0.4$ ；对 x 求和得到 $p(y = 0) = 0.7, p(y = 1) = 0.3$ 。因此

边缘分布分别在 $x = 0$ 和 $y = 0$ 处最大，这对应的联合分布值为 0.3。事实上，不难构造出某些联合分布，使得“各自最可能”的变量取值组合在联合分布下的概率为零。

表 8.1 一个关于两个二值变量的联合分布示例，其中联合分布的最大值对应的变量取值与两个边缘分布的最大值所对应的变量取值不同。

	$x = 0$	$x = 1$
$y = 0$	0.3	0.4
$y = 1$	0.3	0.0

因此，我们希望找到一种高效算法来直接求解使联合分布 $p(\mathbf{x})$ 最大的 $\mathbf{x}$ ，并能够得到该最大联合概率的数值。为解决第二个问题，我们写出最大运算在分量上的展开：

$$\max_{\mathbf{x}} p(\mathbf{x}) = \max_{x_1} \cdots \max_{x_M} p(\mathbf{x}) \quad (8.89)$$

其中 M 为变量总数，然后将 $p(\mathbf{x})$ 替换为因子乘积形式。推导和-积算法时我们用了乘法的分配律 (8.53)。这里我们使用最大运算的对应性质：

$$\max(ab, ac) = a \max(b, c) \quad (8.90)$$

只要 $a \geq 0$ （图模型中的因子始终满足这一点）。这使我们能够交换乘法和最大化运算。

先考虑式 (8.49) 描述的链式结构节点的简单例子。最大概率的计算可写为

$$\begin{aligned} \max_{\mathbf{x}} p(\mathbf{x}) &= \frac{1}{Z} \max_{x_1} \cdots \max_{x_N} [\psi_{1,2}(x_1, x_2) \cdots \psi_{N-1,N}(x_{N-1}, x_N)] \\ &= \frac{1}{Z} \max_{x_1} \left[\psi_{1,2}(x_1, x_2) \left[\cdots \max_{x_N} \psi_{N-1,N}(x_{N-1}, x_N) \right] \right] \end{aligned}$$

与计算边缘分布一样，将最大化和乘积顺序交换能够极大提升计算效率，并且可以解释为从节点 x_N 向链起点 x_1 回传信息。

我们可以将此结果推广到任意树结构因子图：将因子图展开式 (8.59) 代入 (8.89)，并再次交换最大化与乘积。其计算结构与和-积算法完全相同，因此可以直接“翻译”得到相应结果。具体而言，选择某个变量节点作为“根”，从树的叶节点向根节点开始传递信息，每个节点在收到来自除目标方向外所有邻居的信息后向根发送自己的信息。最终在根节点对收到的全部信息的乘积执行最大化，得到 $p(\mathbf{x})$ 的最大值。这就是最大-乘积算法，它与和-积算法完全相同，只是将求和替换为最大化。注意此时信息只从叶子传到根，没有反向传播。

实际应用中，多次相乘小概率数会产生数值下溢，因此通常对联合分布取对数。对数函数是单调的，如果 $a > b$ 则 $\ln a > \ln b$ ，因此最大运算与对数可以交换：

$$\ln \left(\max_{\mathbf{x}} p(\mathbf{x}) \right) = \max_{\mathbf{x}} \ln p(\mathbf{x}) \quad (8.91)$$

分配律依然保持：

$$\max(a + b, a + c) = a + \max(b, c) \quad (8.92)$$

因此最大-乘积算法在取对数后, 将所有乘法变为加法, 得到最大-求和 (max-sum) 算法。利用之前和-积算法的结果 (8.66) 和 (8.69), 只需将“求和”替换为“最大化”, 将乘法替换为对数的加法, 即可得到信息传递形式:

$$\mu_{f \rightarrow x}(x) = \max_{x_1, \dots, x_M} \left[\ln f(x, x_1, \dots, x_M) + \sum_{m \in \text{ne}(f_x) \setminus x} \mu_{x_m \rightarrow f}(x_m) \right] \quad (8.93)$$

$$\mu_{x \rightarrow f}(x) = \sum_{l \in \text{ne}(x) \setminus f} \mu_{f_l \rightarrow x}(x) \quad (8.94)$$

叶节点发出的初始信息按与 (8.70) 和 (8.71) 相同的方式类比得到:

$$\mu_{x \rightarrow f}(x) = 0 \quad (8.95)$$

$$\mu_{f \rightarrow x}(x) = \ln f(x) \quad (8.96)$$

根节点处的最大概率可类似式 (8.63) 计算:

$$p^{\max} = \max_x \left[\sum_{s \in \text{ne}(x)} \mu_{f_s \rightarrow x}(x) \right]. \quad (8.97)$$

到目前为止, 我们已经看到如何从叶节点向任意选择的根节点传递信息来找到联合分布的最大值。无论选择哪个节点作为根, 得到的结果都是相同的。现在我们转向第二个问题: 寻找联合分布取得该最大值时变量的具体配置。到目前为止, 我们只进行了从叶到根的信息传递。计算式 (8.97) 的过程会同时给出根节点变量的最可能取值 $x^{\max}$, 它由下式定义:

$$x^{\max} = \arg \max_x \left[\sum_{s \in \text{ne}(x)} \mu_{f_s \rightarrow x}(x) \right]. \quad (8.98)$$

此时我们可能会倾向于继续沿用信息传递的做法, 让信息从根节点向外传回叶节点, 使用 (8.93) 和 (8.94), 然后对所有剩余变量节点应用 (8.98)。然而, 由于此时我们执行的是最大化而非求和, 可能出现多个变量配置都能使 $p(\mathbf{x})$ 达到最大值的情况。在这种情况下, 该策略可能会失败, 因为对每个节点单独最大化信息乘积得到的变量取值可能分别来自不同的最大化配置, 从而组合成一个并不对应于全局最优的整体配置。

为解决此问题, 我们需要采用一种不同类型的“从根到叶的信息传递”。为了理解其工作方式, 我们再次回到简单的链式例子: N 个变量 $x_1, \dots, x_N$, 每个变量有 K 个状态, 如图 8.38 所示。假设取节点 x_N 作为根节点。那么在第一阶段, 我们从叶节点 x_1 开始向根节点传播信息, 使用:

$$\begin{aligned} \mu_{x_n \rightarrow f_{n,n+1}}(x_n) &= \mu_{f_{n-1,n} \rightarrow x_n}(x_n), \\ \mu_{f_{n-1,n} \rightarrow x_n}(x_n) &= \max_{x_{n-1}} \left[\ln f_{n-1,n}(x_{n-1}, x_n) + \mu_{x_{n-1} \rightarrow f_{n-1,n}}(x_{n-1}) \right], \end{aligned}$$

这正是将 (8.94) 和 (8.93) 应用于该特定图得到的结果。叶节点发出的初始信息是:

$$\mu_{x_1 \rightarrow f_{1,2}}(x_1) = 0. \quad (8.99)$$


随后, x_N 的最可能取值为:

$$x_N^{\max} = \arg \max_{x_N} [\mu_{f_{N-1}, N \rightarrow x_N}(x_N)]. \quad (8.100)$$

现在我们需要找出对应于同一最大化配置的前面各变量的状态。我们可以通过记录哪些变量取值导致了最大化, 从而实现这一点, 即保存如下量:

$$\phi(x_n) = \arg \max_{x_{n-1}} [\ln f_{n-1, n}(x_{n-1}, x_n) + \mu_{x_{n-1} \rightarrow f_{n-1, n}}(x_{n-1})]. \quad (8.101)$$

图 8.53 一个格状(或称网格)图, 明确显示链式模型中每个变量 x_n 的 K 个可能状态(图中每一行对应一个状态)。在此示例中 $K = 3$ 。箭头表示在最大积算法中的消息传递方向。对于每个变量 x_n 的每个状态 k (对应图中第 n 列), 函数 $\phi(x_n)$ 会在前一个变量处确定一个唯一的的状态, 并以黑线标出。图中两条穿过网格的路径对应使联合概率分布达到全局最大值的配置, 沿着黑线按与箭头相反的方向回溯即可找到其中任意一条路径。



为了更好地理解发生了什么, 把链式变量表示成一个格状或“栅栏”图(如图 8.53)是有帮助的。注意, 这并不是一个概率图模型, 因为节点表示变量的具体状态, 每个变量对应图中一整列状态。对于给定变量的每个状态, 总有某个唯一的上一个变量状态使概率最大(若有并列则系统性或随机地选择一个), 这正对应式(8.101)给出的函数 $\phi(x_n)$, 并在图中以连线标出。一旦我们知道最终节点 x_N 的最可能值, 就可以沿着连线向后追踪, 找到 x_{N-1} 的最可能状态, 依此类推直至 x_1 。这对应于沿链回传如下信息:

$$x_{n-1}^{\max} = \phi(x_n^{\max}), \quad (8.102)$$

这称为回溯(back-tracking)。注意, 在(8.101)中可能有多个 x_{n-1} 都能取得最大值。只要在回溯时选择其中任意一个, 我们最终得到的配置就保证是一致的全局最大化结果。

在图 8.53 中, 我们标出了两条路径, 并假设它们都对应联合分布的全局最大值。如果 $k = 2$ 和 $k = 3$ 都代表 $x_N^{\max}$ 的可能取值, 那么从任一状态出发, 沿着黑色连线回溯(即反复应用(8.102)), 都能得到一个有效的全局最大化配置。注意, 如果我们运行一次前向的最大-求和信息传递, 然后反向传递, 再对每个节点分别应用(8.98), 则可能从某条路径选取部分状态、从另一条路径选取部分状态, 从而形成一个并非全局最优的整体配置。由此可见, 我们必须在向前传播过程中保留最大化时的状态记录, 即使用 $\phi(x_n)$, 然后通过回溯找到一致的解。

对一般树结构因子图的扩展现在已经很清楚了。如果一条信息从因子节点 f 发送到变量节点 x ，则需要对与该因子节点相邻的其他变量节点 $x_1, \dots, x_M$ 执行最大化运算，使用式 (8.93)。在执行该最大化时，我们需要记录哪些变量取值 $x_1, \dots, x_M$ 导致了最大值。随后在回溯步骤中，在已经求得 $x^{\max}$ 之后，可以利用这些存储的取值来给出一致的最大化状态 $x_1^{\max}, \dots, x_M^{\max}$ 。对树状因子图而言，带回溯的最大-求和算法能够给出变量的精确最大化配置。该技术的一个重要应用是在隐马尔可夫模型中寻找最可能的隐状态序列，在该情况下它被称为维特比 (Viterbi) 算法。

与和-积算法类似，以观测变量的形式加入“证据”非常直接。观测变量被固定在其观测值上，最大化仅对剩余的隐变量进行。形式化来看，只需像和-积算法那样，将观测变量对应的恒等函数并入因子函数即可。

将最大-求和算法与第 389 页所述的迭代条件模式 (ICM) 算法进行比较是很有趣的。在 ICM 中，每一步的计算更简单，因为在节点之间传递的“信息”只有一个值，它表示在最大化条件分布后节点所更新到的新状态。而最大-求和算法更复杂，因为信息是关于节点变量 x 的函数，因此对每个可能的状态都需要一组包含 K 个值的信息。然而，与最大-求和算法不同，ICM 即使在树结构的图上也不能保证找到全局最大值。

8.4.6 一般图中的精确推断

和-积算法与最大-求和算法为树结构图中的推断问题提供了高效而精确的解。然而，在许多实际应用中，我们必须处理包含环的图。

信息传递框架可以推广到任意图结构，从而得到一种精确推断方法，称为“结点树 (junction tree) 算法” (Lauritzen 和 Spiegelhalter, 1988; Jordan, 2007)。这里我们简要概述其主要步骤。这并非旨在提供对该算法的深入理解，而是为了展示其中涉及的关键阶段。如果起点是有向图，则首先需要通过“道德化 (moralization)”将其转化为无向图；如果起点是无向图，则无需此步骤。接下来对图进行“三角化”，即找到所有包含四个或更多节点的无弦环 (chord-less cycle)，并添加额外链接以消除这些无弦环。例如，在图 8.36 中，环 A-C-B-D-A 是无弦的，因此可以在 A 和 B 之间添加一条边，或者在 C 和 D 之间添加一条边。注意：三角化后的图的联合分布仍由相同的势函数乘积定义，只不过这些势函数现在被视为定义在扩展变量集合上的函数。

然后利用三角化后的图构造一个新的树结构无向图，称为“连接树 (join tree)”，其节点对应三角化图的极大团 (maximal cliques)，链接则连接具有公共变量的团。选择哪些团对相连是一个关键步骤，它通过最大生成树 (maximum spanning tree) 来确定：在所有可能连接这些团的树中，选出总权重最大的那棵树，其中链接的权重为其连接的两个团所共享的变量数，树的权重为所有链接权重之和。如果对树进行压缩，使得任何被包含在更大团中的团都被吸收到更大团中，则得到“结点树 (junction tree)”。由于三角化步骤的缘故，该树满足“运行交叉 (running intersection)”性质，即如果某个变量在两个团中出现，则在连接这两个团的路径上的所有团中也必须出现该变量。这保证了图中变量推断的一致性。最后，在该结点树上可使用两阶段信息传递算法（本质上等同于

和-积算法) 来求解边缘分布与条件分布。

尽管结点树算法听起来复杂, 其核心思想非常简单: 利用联合分布的因子化性质, 使得和与积可以交换顺序, 从而执行部分求和, 避免直接处理完整的联合分布。结点树的作用是在结构上提供一种精确而高效的组织方式。值得强调的是, 这完全是通过图操作实现的!

结点树方法对任意图都是精确的, 而且在给定图的条件下通常不存在更便宜的精确推断方法。然而, 该算法必须在每个结点(对应于三角化后图的团)内处理联合分布, 因此其计算成本由最大团中的变量数量决定; 在离散变量情况下, 这种成本随最大团大小呈指数增长。一个重要的概念是图的树宽(treewidth)(Bodlaender, 1993), 其定义基于最大团中变量数量(更具体地说, 树宽等于最大团大小减一, 以使树的树宽为1)。由于从给定的图出发可能构造多个不同的结点树, 因此树宽取决于其中最大团最小的那棵树的团大小。如果原始图的树宽很大, 结点树算法将变得不可行。

8.4.7 含环的信念传播(loopy belief propagation)

对于许多实际问题, 精确推断是不可行的, 因此需要使用有效的近似方法。属于这一类的重要方法——变分方法(variational methods)——将在第10章详细讨论。另外还包括大量基于随机采样的蒙特卡罗方法(Monte Carlo methods), 将在第11章介绍。

这里我们讨论一种简单的近似推断方法, 用于含环的图, 它直接基于之前在树结构图上的精确推断思想。其思路十分直接: 即便图中存在环, 也直接应用和-积算法, 尽管不能保证结果是好的。这种方法称为“含环信念传播”(loopy belief propagation)(Frey 和 MacKay, 1998), 之所以可行, 是因为和-积算法的信息传递规则(8.66)与(8.69)完全是局部的。然而, 由于图中存在环, 信息可能会在图中流转多次。对某些模型, 该算法会收敛, 而对另一些则不会。

为了应用该方法, 需要定义一套信息传递计划。假设每次在任意给定链接上、任意方向上只发送一条信息。每条信息都会替换之前该方向上的信息, 并且只依赖于该节点在前几次迭代中最近收到的信息。

我们已经看到, 只有当节点在其它链接上已经收到所有信息时, 它才能向某条链接发送信息。含环的图中, 这带来了一个问题: 如何开始信息传递? 为解决这一问题, 我们假设最初在每条连接上、双向都发送一个单位函数信息。这样每个节点都具备了发送信息的条件。

此后, 信息传递计划有许多可能。例如, “洪泛式(flooding)”调度在每个时间步中同时在所有连接的两个方向上传递信息; 而一次只传一条信息的调度称为“串行调度(serial schedule)”。

按照 Kschischang 等(2001)的定义, 如果节点 a 在自上次向节点 b 发送信息之后, 在自身其他链接上收到过任何信息, 那么节点 a 对 b 就有一条“待发送信息(pending message)”。因此, 一个节点在某条链接上收到信息, 会对其所有其他链接产生待发送信息。只有这些待发送信息需要传递, 否则会重复之前的信息。

在树结构图中，任何仅传递待发送信息的调度方式最终都会终止，因为一旦每条链接在两个方向上都已传递过信息，将不再有待发送信息，此时变量节点收到的信息的乘积给出精确边缘分布。然而在含环的图中，算法可能永远无法终止，因为可能始终存在待发送信息。不过在实际应用中，这种方法一般会在合理时间内收敛。当算法收敛（或在未收敛时被停止）后，可使用各变量节点或因子节点最近接收到的信息的乘积来计算（近似的）局部边缘分布。

在某些应用中，含环信念传播可能效果不佳，而在另一些应用中却非常有效。特别是，一些先进的纠错码解码算法与含环信念传播是等价的（Gallager, 1963; Berrou 等, 1993; McEliece 等, 1998; MacKay 和 Neal, 1999; Frey, 1998）。

8.4.8 学习图结构

在前面对图模型推断的讨论中，我们一直假设图的结构是已知且固定的。然而，人们也对超越推断问题、直接从数据中学习图结构本身感兴趣（Friedman 和 Koller, 2003）。这需要我们为可能的结构定义一个空间，并定义一个用于对每个结构进行评分的度量。

从贝叶斯的角度来看，我们理想的做法是计算图结构的后验分布，并通过对该分布求平均来进行预测。如果我们对以 m 为索引的图定义了一个先验 $p(m)$ ，那么后验分布为

$$p(m \mid \mathcal{D}) \propto p(m) p(\mathcal{D} \mid m) \quad (8.103)$$

其中 $\mathcal{D}$ 为观测到的数据集。模型证据 $p(\mathcal{D} \mid m)$ 为每个模型提供了评分。然而，证据的计算涉及对潜在变量的边缘化，这对许多模型来说都是非常具有挑战性的计算问题。

探索结构空间同样困难。由于图结构的数量随着节点数量呈指数增长，通常必须依赖启发式方法来寻找较好的候选结构。

9 混合模型和 EM 算法

如果我们对观测变量和潜在变量定义一个联合分布，那么仅关于观测变量的分布可以通过对潜在变量边缘化得到。这样，观测变量上较为复杂的边缘分布就能够用在扩展的观测-潜在变量空间中的更易处理的联合分布来表达。通过引入潜在变量，我们就能用更简单的组成部分构建出复杂的分布。在本章中，我们将看到混合分布（例如第 2.3.9 节讨论的高斯混合分布）可以用离散潜在变量来解释。连续潜在变量将是第 12 章的主题。

除了提供构建更复杂概率分布的框架之外，混合模型还可以用于聚类数据。因此，我们将从讨论混合分布开始，首先考虑如何在—组数据点中找到聚类，这里我们采用一种非概率的方法——K 均值算法（Lloyd, 1982）。随后我们介绍混合分布的潜在变量视角，其中离散潜在变量可解释为将数据点分配给混合模型中具体成分的标记。在潜在变量模型中，用于求最大似然估计的一般方法是 EM（期望最大化）算法。我们首先以高斯混合分布为例，用一种较为非正式的方式引入 EM 算法，然后基于潜在变量视角给出更严谨的处理。我们将看到，K 均值算法对应于应用于高斯混合的 EM 在某个非概率极限下的特例。最后，我们将更一般性地讨论 EM。

高斯混合模型在数据挖掘、模式识别、机器学习和统计分析中被广泛应用。在许多应用中，其参数通常通过最大似然估计求得，典型地使用 EM 算法。然而正如我们将看到的，最大似然方法存在一些重要的局限；在第 10 章中，我们将展示一种优雅的贝叶斯处理方式——基于变分推断的框架。与 EM 相比，它只需要极少的额外计算，同时解决了最大似然的主要问题，并且能够自动地从数据中推断出混合模型的成分数量。

9.1 K 均值聚类

我们首先考虑在多维空间中识别数据点的群组（或簇）的问题。假设我们有一个数据集 $\{\mathbf{x}_1, \dots, \mathbf{x}_N\}$ ，由一个 D 维欧几里得随机变量 $\mathbf{x}$ 的 N 个观测组成。我们的目标是将该数据集划分为若干个簇，数量为 K ，其中 K 在这里被视为已知。直观来看，我们可以将一个簇理解为这样—组数据点：簇内点之间的距离相对较小，而它们与簇外点之间的距离较大。我们可以将这一概念形式化，方法是首先定义—组 D 维向量 $\boldsymbol{\mu}_k$ ，其中 $k = 1, \dots, K$ ，并令 $\boldsymbol{\mu}_k$ 为第 k 个簇的原型。我们将看到， $\boldsymbol{\mu}_k$ 可以被视为簇的中心。我们的目标是找到数据点到簇的分配方式，以及向量集合 $\{\boldsymbol{\mu}_k\}$ ，使每个数据点到其最近向量 $\boldsymbol{\mu}_k$ 的平方距离和最小。

此时，引入—些符号来描述数据点到簇的分配会很方便。对每个数据点 $\mathbf{x}_n$ ，我们引入对应的一组二元指示变量 $r_{nk} \in \{0, 1\}$ ，其中 $k = 1, \dots, K$ ，用来描述数据点 $\mathbf{x}_n$ 被分配到哪个簇。如果 $\mathbf{x}_n$ 被分配到簇 k ，则令 $r_{nk} = 1$ ，而对于 $j \neq k$ 的所有 j ，令 $r_{nj} = 0$ 。这称为 1-of- K 编码方式。然后我们定义—个目标函数（有时称为失真度量）：

$$J = \sum_{n=1}^N \sum_{k=1}^K r_{nk} \|\mathbf{x}_n - \boldsymbol{\mu}_k\|^2 \quad (9.1)$$

它表示每个数据点到其被分配的向量 $\boldsymbol{\mu}_k$ 的平方距离之和。我们的目标是在 $\{r_{nk}\}$

和 $\{\mu_k\}$ 上找到使 J 最小的取值。可以通过迭代过程来实现，这个迭代由两个连续步骤组成，对 r_{nk} 和 μ_k 依次进行优化。首先选择一些初始的 μ_k 。然后在第一阶段，将 μ_k 固定并对 r_{nk} 最小化 J ；在第二阶段，令 r_{nk} 固定并对 μ_k 最小化 J 。两个步骤交替执行，直至收敛。我们将看到这两个更新步骤分别对应 EM 算法的 E 步（期望步）和 M 步（最大化步），为强调这一点，我们在 K 均值算法的语境中也将使用 E 步和 M 步的术语。

首先考虑对 r_{nk} 的确定。由于式 (9.1) 中的 J 对 r_{nk} 是线性的，因此该优化可以轻易地获得闭式解。不同的 n 之间是独立的，因此我们可以对每个 n 单独优化：选择使 $\|\mathbf{x}_n - \mu_k\|^2$ 最小的 k ，并令该 $r_{nk} = 1$ 。换句话说，将第 n 个数据点分配给最近的簇中心。形式化地：

$$r_{nk} = \begin{cases} 1, & \text{若 } k = \arg \min_j \|\mathbf{x}_n - \mu_j\|^2 \\ 0, & \text{否则} \end{cases} \quad (9.2)$$

现在考虑在固定 r_{nk} 的条件下对 μ_k 的优化。目标函数 J 对 μ_k 是二次函数，通过将其对 μ_k 的导数设为零可得：

$$2 \sum_{n=1}^N r_{nk} (\mathbf{x}_n - \mu_k) = 0 \quad (9.3)$$

我们可以直接解得：

$$\mu_k = \frac{\sum_n r_{nk} \mathbf{x}_n}{\sum_n r_{nk}} \quad (9.4)$$

该式的分母是被分配到簇 k 的点的数量，因此该结果有一个非常直观的解释：令 μ_k 等于所有被分配到簇 k 的数据点 $\mathbf{x}_n$ 的均值。因此该方法被称为 K 均值算法。

重新分配数据点到簇、重新计算簇中心这两个阶段交替进行，直到分配不再变化（或达到最大迭代次数）。由于每个阶段都会降低目标函数 J 的值，算法保证收敛。然而，它可能会收敛到 J 的局部最小值，而非全局最小值。关于 K 均值算法的收敛性，MacQueen（1967）进行了研究。

图 9.1 使用 Old Faithful 数据集说明了 K-means 算法。在这个示例中，我们对数据进行了线性重新缩放（称为标准化），使得每个变量都具有零均值和单位标准差。在此示例中，我们选择了 $K=2$ ，因此对每个数据点分配到最近簇中心的操作等价于根据数据点位于两个簇中心的垂直平分线哪一侧来对其进行分类。Old Faithful 示例中由 (9.1) 给出的代价函数 J 的图示于图 9.2 中展示。

我们特意为簇中心选择了较差的初始值，从而使得算法在收敛之前需要进行多个步骤。实际操作中，更好的初始化方法是将簇中心 μ_k 设置为 K 个随机选择的数据点的子集。同样值得注意的是，K-means 算法本身经常用于在应用 EM 算法之前初始化高斯混合模型的参数。

如这里所讨论的那样，直接实现 K-means 算法可能会相对较慢，因为在每次 E 步骤中，都需要计算每个原型向量与每个数据点之间的欧氏距离。已有多种方案被提出用于加速 K-means 算法，其中一些方案基于预先构建数据结构（例如树结构），使得相邻的




图 9.1 使用重新缩放的 Old Faithful 数据集对 K-means 算法的示意图。(a) 绿色点表示位于二维欧几里得空间中的数据点。中心 μ_1 和 μ_2 的初始选择分别由红色和蓝色的叉号表示。(b) 在初始的 E 步中，根据每个数据点更接近哪个簇中心，将其分配到红色簇或蓝色簇。这等同于根据点位于两个簇中心的垂直平分线（由品红色线表示）的哪一侧来对其进行分类。(c) 在随后的 M 步中，每个簇中心被重新计算为分配到相应簇中的点的均值。(d)-(i) 展示了连续的 E 步和 M 步，直到算法最终收敛。

数据点位于同一子树中 (Ramasubramanian 和 Paliwal, 1990; Moore, 2000)。其他方法利用距离的三角不等式，从而避免不必要的距离计算 (Hodgson, 1998; Elkan, 2003)。


到目前为止，我们考虑的是批量版本的 K-means，其中使用整个数据集来共同更新原型向量。我们也可以通过将 Robbins-Monro 方法应用于寻找由 (9.1) 中对 μ_k 的偏导数给出的回归函数的根，从而导出一种在线随机算法 (MacQueen, 1967)。这会导致一个顺序更新：对每个数据点 x_n ，依次更新最近的原型 μ_k ，使用

$$\mu_k^{\text{new}} = \mu_k^{\text{old}} + \eta_n (\mathbf{x}_n - \mu_k^{\text{old}}) \quad (9.5)$$

其中 η_n 是学习率参数，通常随着更多数据点被处理而单调递减。

K-means 算法基于平方欧氏距离来衡量数据点与原型向量之间的不相似度。这不仅限制了可处理的数据变量类型（例如当变量表示类别标签时该度量就不合适），而且还会使得簇均值的确定对离群点不够稳健。我们可以通过引入一个更一般的不相似度量

图 9.2 图示为在图 9.1 所示示例中，K-means 算法在每一次 E 步（蓝点）和 M 步（红点）之后，由式 (9.1) 给出的代价函数 J 的变化情况。算法在第三次 M 步之后已经收敛，最终的 EM 循环在样本分配和原型向量两方面都不再发生变化。



$\mathcal{V}(\mathbf{x}, \mathbf{x}')$ 来将 K-means 进行推广，然后最小化下式的失真度量：

$$\tilde{J} = \sum_{n=1}^N \sum_{k=1}^K r_{nk} \mathcal{V}(\mathbf{x}_n, \boldsymbol{\mu}_k) \quad (9.6)$$

从而得到 K-medoids 算法。在给定簇原型 k 的情况下，其 E 步骤仍然是将每个数据点分配给使其不相似度最小的簇。其计算成本为 $O(KN)$ ，与标准 K-means 算法相同。对于一般选择的不相似度量，M 步骤可能比 K-means 更复杂，因此通常会将每个簇的原型限制为分配到该簇的数据点之一，因为这样只要不相似度量 $\mathcal{V}(\cdot, \cdot)$ 可计算，就可以实现该算法。因此，M 步骤需要对每个簇 k ，在分配到该簇的 N_k 个点上进行离散搜索，这需要 $O(N_k^2)$ 次对 $\mathcal{V}(\cdot, \cdot)$ 的计算。

K-means 算法的一个显著特征是，在每次迭代中，每个数据点都会被唯一地分配给一个簇，且仅一个簇。虽然有些数据点会比其他簇中心更接近某个特定中心 k ，但也有些数据点可能大致位于多个簇中心的中间位置。在后者情况下，硬性地将其分配给最近簇未必是最合理的。我们将在下一节看到，通过采用概率的方法，可以得到数据点对簇的“软”分配，从而反映最合理分配上的不确定程度。这种概率形式带来了许多优点。

9.1.1 图像分割与压缩

作为 K-means 算法应用的示例，我们来讨论图像分割与图像压缩这两个相关问题。分割的目标是将图像划分成若干区域，每个区域在视觉上具有相对一致的外观，或对应于物体或物体的一部分（Forsyth 和 Ponce, 2003）。图像中的每个像素在三维空间中表示为红、蓝、绿三个通道强度的组合，而我们的分割算法只需将图像中的每个像素视为一个独立的数据点。需要指出的是，这个空间严格来说不是欧氏空间，因为通道强度被限制在区间 $[0,1]$ 内。然而，我们仍然可以直接应用 K-means 算法而不会遇到困难。为了说明 K-means 在给定某个 K 值时收敛后的效果，我们重新绘制图像，将每个像素向量替换为该像素被分配到的中心 μ_k 所给出的 R, G, B 强度三元组。图 9.3 展示了不同 K 值下的结果。可以看到，对于给定的 K ，算法实际上用 K 种颜色的调色板来表示图像。

必须强调的是，这种使用 **K-means** 的方式并不是一种特别复杂的图像分割方法，尤其是因为它没有考虑像素之间的空间邻近关系。图像分割问题一般非常困难，并且仍是活跃研究的主题，这里只是用它来说明 **K-means** 算法的行为。




图 9.3 **K-means** 聚类算法在图像分割中的两个应用示例，展示了原始图像以及在不同 K 值下得到的 **K-means** 分割结果。这也说明了向量量化在数据压缩中的应用，其中较小的 K 值可以获得更高的压缩率，但代价是图像质量较差。

我们还可以利用聚类算法的结果来执行数据压缩。必须区分无损压缩与有损压缩：无损压缩的目标是能够从压缩表示中精确重建原始数据，而有损压缩则接受重建中的一些误差，以换取比无损压缩更高的压缩率。我们可以如下将 **K-means** 算法应用于有损压缩问题。对于每个 N 个数据点，我们只存储它被分配到的簇标号 k 。同时我们也存储 K 个簇中心 μ_k 的值，如果我们选择的 K 远小于 N ，则通常需要显著更少的数据。然后每个数据点就用其最近的中心 μ_k 来近似。新数据点也可通过先找到最近的 μ_k ，然后存储标签 k ，而不是原始向量来进行压缩。这个框架通常称为向量量化，而向量 μ_k 则称为码本向量。

上面讨论的图像分割问题也可以作为使用聚类进行数据压缩的一个例子。假设原始图像有 N 个像素，每个像素具有 R, G, B 值，每个通道用 8 位精度存储。则直接传输整幅图像需要 $24N$ 位。现在假设我们首先对图像数据运行 **K-means**，然后不传输原始像素强度向量，而是传输最近向量 μ_k 的标号。因为共有 K 个这样的向量，这需要每个像素 $\log_2 K$ 位。我们还必须传输 K 个码本向量 μ_k ，这需要 $24K$ 位，因此传输图像所需的总位数为 $24K + N \log_2 K$ （向上取整为最近的整数）。图 9.3 所示的原始图像有 $240 \times 180 = 43,200$ 个像素，因此直接传输需要 $24 \times 43,200 = 1,036,800$ 位。相比之下，压缩后的图像在 $K=2$ 、 $K=3$ 和 $K=10$ 时分别需要 43,248 位、86,472 位和 173,040 位来传输。它们相对于原图的压缩率分别为 4.2%、8.3% 和 16.7%。可以看到，压缩程度与图像质量之间存在权衡。需要注意的是，我们此例的目的是说明 **K-means** 算法。如果

目标是构建一个优秀的图像压缩器，那么更富成效的做法是考虑小块的相邻像素，例如 5×5 ，从而利用自然图像中相邻像素间的相关性。


9.2 高斯混合模型

在第 2.3.9 节中，我们将高斯混合模型动机化为多个高斯分量的简单线性叠加，用以提供比单个高斯更丰富的密度模型类别。现在我们将离散隐变量的角度来表述高斯混合模型。这样不仅能让我们对这一重要分布获得更深入的理解，还将为期望最大化 (EM) 算法提供动机。

回忆式 (2.188)，高斯混合分布可以写成如下高斯的线性叠加形式：

$$p(\mathbf{x}) = \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x} \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \quad (9.7)$$

图 9.4 混合模型的图形化表示，其中联合分布表示为 $p(\mathbf{x}, \mathbf{z}) = p(\mathbf{z}) p(\mathbf{x} \mid \mathbf{z})$.



现在引入一个 K 维二值随机变量 $\mathbf{z}$ ，它采用 1-of- K 的表示方式，其中某个元素 z_k 等于 1，而所有其他元素都等于 0。因而 z_k 满足 $z_k \in \{0, 1\}$ 并且 $\sum_k z_k = 1$ ，并且根据哪个元素为 1，向量 $\mathbf{z}$ 有 K 种可能的状态。我们将联合分布 $p(\mathbf{x}, \mathbf{z})$ 用边缘分布 $p(\mathbf{z})$ 和条件分布 $p(\mathbf{x} \mid \mathbf{z})$ 来定义，对应图 9.4 中的图模型。对 $\mathbf{z}$ 的边缘分布用混合系数 π_k 定义为

$$p(z_k = 1) = \pi_k$$

其中参数 $\{\pi_k\}$ 必须满足

$$0 \leq \pi_k \leq 1 \quad (9.8)$$

以及

$$\sum_{k=1}^K \pi_k = 1 \quad (9.9)$$

以保证其为合法概率分布。由于 $\mathbf{z}$ 采用 1-of- K 表示，我们也可以将其写成

$$p(\mathbf{z}) = \prod_{k=1}^K \pi_k^{z_k} \quad (9.10)$$

类似地，给定 $\mathbf{z}$ 的某个值后， $\mathbf{x}$ 的条件分布为高斯分布：

$$p(\mathbf{x} \mid z_k = 1) = \mathcal{N}(\mathbf{x} \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$$

这同样可以写成

$$p(\mathbf{x} \mid \mathbf{z}) = \prod_{k=1}^K \mathcal{N}(\mathbf{x} \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)^{z_k}. \quad (9.11)$$

联合分布由 $p(\mathbf{z})p(\mathbf{x} | \mathbf{z})$ 给出，而对 $\mathbf{x}$ 的边缘分布通过对所有可能的 $\mathbf{z}$ 状态求和获得：

$$p(\mathbf{x}) = \sum_{\mathbf{z}} p(\mathbf{z})p(\mathbf{x} | \mathbf{z}) = \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x} | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \quad (9.12)$$

在此我们使用了 (9.10) 和 (9.11)。因此， $\mathbf{x}$ 的边缘分布就是形如 (9.7) 的高斯混合。如果我们有多个观测 $\mathbf{x}_1, \dots, \mathbf{x}_N$ ，由于我们将边缘分布写成 $p(\mathbf{x}) = \sum_{\mathbf{z}} p(\mathbf{x}, \mathbf{z})$ 的形式，便可知每个观测数据点 $\mathbf{x}_n$ 都对应一个隐变量 $\mathbf{z}_n$ 。

因此，我们得到了一个包含显式隐变量的高斯混合模型的等价表述。乍看之下，这样做似乎没有带来太多收益。然而，现在我们可以处理联合分布 $p(\mathbf{x}, \mathbf{z})$ 而非边缘分布 $p(\mathbf{x})$ ，这将带来显著的简化，尤其是通过引入期望最大化 (EM) 算法。

另一个将起重要作用的量是给定 $\mathbf{x}$ 后 $\mathbf{z}$ 的条件概率。我们将使用 $\gamma(z_k)$ 表示 $p(z_k = 1 | \mathbf{x})$ ，其数值可以通过贝叶斯定理求得：

$$\begin{aligned} \gamma(z_k) \equiv p(z_k = 1 | \mathbf{x}) &= \frac{p(z_k = 1) p(\mathbf{x} | z_k = 1)}{\sum_{j=1}^K p(z_j = 1) p(\mathbf{x} | z_j = 1)} \\ &= \frac{\pi_k \mathcal{N}(\mathbf{x} | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(\mathbf{x} | \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)}. \end{aligned} \quad (9.13)$$

我们将 π_k 看作先验概率，即 $z_k = 1$ 的概率，而将 $\gamma(z_k)$ 看作在观测到 $\mathbf{x}$ 之后对应的后验概率。正如我们稍后将看到的， $\gamma(z_k)$ 也可以被视为第 k 个分量对“解释”观测 $\mathbf{x}$ 所承担的责任。





图 9.5 从图 2.23 所示的由 3 个高斯分布组成的混合模型中抽取的 500 个点的示例。(a) 来自联合分布 $p(\mathbf{z})p(\mathbf{x} | \mathbf{z})$ 的样本，其中变量 $\mathbf{z}$ 的三个状态（对应于混合模型的分量）分别用红色、绿色和蓝色表示；(b) 来自边缘分布 $p(\mathbf{x})$ 的相应样本，该分布是通过简单地忽略 $\mathbf{z}$ 的取值、仅绘制 $\mathbf{x}$ 的取值而得到的。(a) 中的数据集被称为“完整的”，而 (b) 中的数据集则是“不完整的”。(c) 相同的一组样本，其中颜色表示与数据点 $\mathbf{x}_n$ 相关的责任度 $\gamma(z_{nk})$ 的取值，通过按比例使用红色、蓝色和绿色墨水来绘制对应的数据点，这些比例分别由 $k = 1, 2, 3$ 时的 $\gamma(z_{nk})$ 给出。

我们可以使用“祖先采样”技术来生成符合高斯混合模型分布的随机样本。方法是：首先从边缘分布 $p(\mathbf{z})$ 中生成一个值 $\hat{\mathbf{z}}$ ，然后从条件分布 $p(\mathbf{x} | \hat{\mathbf{z}})$ 中生成 $\mathbf{x}$ 的值。标准分布的采样技巧将在第 11 章讨论。我们可以通过在对应的 $\mathbf{x}$ 位置作点，并根据 $\mathbf{z}$ 的取值进行着色（也就是说，按照生成该点的高斯分量着色），来展示来自联合分布 $p(\mathbf{x}, \mathbf{z})$ 的样本，如图 9.5(a) 所示。同样地，通过忽略 $\mathbf{z}$ 的值，就可以得到来自边缘分布 $p(\mathbf{x})$ 的样本。这些样本在图 9.5(b) 中展示，即仅绘制 $\mathbf{x}$ 值而不作着色标签。

我们还可以使用这个合成数据集来展示“责任”的概念：对每个数据点，计算其在生成此数据集的混合分布中每个分量的后验概率。具体地，我们可以通过为每个数据点 $\mathbf{x}_n$ 按照 $\gamma(z_{nk})$ （对于 $k = 1, 2, 3$ 分别对应红、蓝、绿三种颜色）所占比例来着色，从而表示其责任 $\gamma(z_{nk})$ ，如图 9.5(c) 所示。例如，当 $\gamma(z_{n1}) = 1$ 时，该点将呈现红色；而当 $\gamma(z_{n2}) = \gamma(z_{n3}) = 0.5$ 时，该点将同时以相同比例的蓝色与绿色着色，因此呈现青色。应将其与图 9.5(a) 对比，后者的数据点是按照生成它们的真实分量身份进行标记的。

9.2.1 最大似然

图 9.6 针对一组 N 个 i.i.d. 数据点 $\{\mathbf{x}_n\}$ 的高斯混合模型的图形化表示，其对应的潜在变量为 $\{\mathbf{z}_n\}$ ，其中 $n = 1, \dots, N$ 。



假设我们有一个观测数据集 $\{\mathbf{x}_1, \dots, \mathbf{x}_N\}$ ，并希望使用高斯混合模型来对这些数据进行建模。我们可以将该数据集表示为一个 $N \times D$ 的矩阵 $\mathbf{X}$ ，其中第 n 行为 $\mathbf{x}_n^T$ 。类似地，相应的隐变量可以用 $N \times K$ 的矩阵 $\mathbf{Z}$ 表示，其第 n 行为 $\mathbf{z}_n^T$ 。如果我们假设数据点是从该分布中独立采样得到的，则可以用图 9.6 中的图模型来表示该 i.i.d. 数据集的高斯混合模型。由式 (9.7)，其对数似然函数可写为

$$\ln p(\mathbf{X} | \boldsymbol{\pi}, \boldsymbol{\mu}, \boldsymbol{\Sigma}) = \sum_{n=1}^N \ln \left\{ \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x}_n | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \right\}. \quad (9.14)$$

在讨论如何最大化该函数之前，值得强调的是，将最大似然方法应用于高斯混合模型时会遇到一个严重问题，那就是奇异性（singularity）。为简单起见，考虑一个高斯混合模型，其分量具有协方差矩阵 $\boldsymbol{\Sigma}_k = \sigma_k^2 \mathbf{I}$ ，其中 $\mathbf{I}$ 为单位矩阵，尽管结论对一般协方差同样成立。假设混合模型的某个分量（设为第 j 个）其均值 $\boldsymbol{\mu}_j$ 恰好等于某个数据点，即 $\boldsymbol{\mu}_j = \mathbf{x}_n$ 。那么该数据点对似然函数贡献的项将为


$$\mathcal{N}(\mathbf{x}_n | \mathbf{x}_n, \sigma_j^2 \mathbf{I}) = \frac{1}{(2\pi)^{1/2} \sigma_j}. \quad (9.15)$$

如果我们考虑极限 $\sigma_j \rightarrow 0$ ，就会看到该项趋于无穷大，因此对数似然也趋于无穷大。于是最大化对数似然的问题是不适定的（ill posed），因为这样的奇异性总会出现，也就是说，当某个高斯分量“塌缩”到某个具体数据点上时就会发生。回忆一下，单一高斯分布的情况下并不会出现这种问题。为了理解差异，注意如果一个单高斯塌缩到一个数据点，它对似然函数会贡献来自其他数据点的因子，而这些因子会指数级趋于零，从而整体似然趋于零而不是趋于无穷大。然而，一旦混合模型中至少有两个分量，其中一个分量可以保持有限方差，从而对所有数据点分配有限概率，而另一个分量可以塌缩到一个特定数据点，从而对对数似然贡献无限增大的值，如图 9.7 所示。这些奇异性提

供了一个最大似然方法会发生严重过拟合的例子。我们将看到，采用贝叶斯方法时这一困难将不会出现。不过，目前只需注意，在把最大似然应用于高斯混合模型时，必须采取措施避免找到这类病态解，而应寻求表现良好的似然局部极大值。我们可以通过一些启发式策略来避免奇异性，例如检测某个高斯分量是否正在塌缩，并将其均值重置为随机选择的值，同时将其协方差重置为较大的值，然后继续优化。

图 9.7 高斯混合模型中似然函数出现奇异性的示意图。

这应与图 1.14 中所示的单个高斯分布情形进行比较，在该情形下不会出现奇异性。



在寻找最大似然解时的另一个问题来自这样一个事实：对于任意最大似然解，一个 K 分量的混合模型有总计 $K!$ 个等价解，它们对应于将 K 组参数分配给 K 个分量的 $K!$ 种方式。换句话说，在参数空间的任意（非退化）一点，都存在另外 $K! - 1$ 个点，它们给出的分布完全相同。这一问题称为可辨识性（identifiability）（Casella and Berger, 2002），在我们希望解释模型找到的参数值时非常重要。当我们讨论具有连续隐变量的模型（第 12 章）时也会遇到可辨识性问题。然而，就寻找一个良好的密度模型而言，可辨识性并不重要，因为所有等价解都同样有效。

对于高斯混合模型而言，最大化对数似然函数 (9.14) 要比单高斯的情况复杂得多。困难来自于 (9.14) 中出现在对数内部的对 k 的求和，因此对数不再直接作用于高斯函数。如果我们令对数似然的导数为零，将不再得到封闭形式的解，稍后我们将看到这一点。

一种方法是采用基于梯度的优化技术（Fletcher, 1987; Nocedal 和 Wright, 1999; Bishop 和 Nabney, 2008）。虽然基于梯度的方法是可行的，并且在第 5 章讨论混合密度网络时将发挥重要作用，但我们现在转向另一种称为 EM 算法的方法。EM 算法具有广泛的适用性，并将为第 10 章中的变分推断技术讨论奠定基础。

9.2.2 高斯混合的 EM 算法

一种优雅且强大的方法，可以用于求解含有隐变量模型的最大似然解，这就是期望最大化算法（EM 算法）（Dempster 等, 1977; McLachlan 和 Krishnan, 1997）。稍后我们将给出 EM 的一般形式，并展示如何将其推广以得到变分推断框架。这里我们先在高斯混合模型的背景下，以一种相对非正式的方式来动机化 EM 算法。不过需要强调的是，EM 的适用范围非常广，本书中将会在多个不同模型的场景中再次遇到它。

让我们先写出似然函数在最大值处必须满足的条件。将式 (9.14) 中的对数似然对

高斯分量的均值 μ_k 求导，并令其为零，可得

$$0 = - \sum_{n=1}^N \underbrace{\frac{\pi_k \mathcal{N}(\mathbf{x}_n | \mu_k, \Sigma_k)}{\sum_j \pi_j \mathcal{N}(\mathbf{x}_n | \mu_j, \Sigma_j)}}_{\gamma(z_{nk})} \Sigma_k^{-1} (\mathbf{x}_n - \mu_k) \quad (9.16)$$

这里我们使用了高斯分布的形式 (2.43)。注意后验概率（或称为“责任”） $\gamma(z_{nk})$ （由式 (9.13) 给出）自然地出现在右侧。将上式乘以 Σ_k 的逆（假设其非奇异）并整理，得到

$$\mu_k = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) \mathbf{x}_n, \quad (9.17)$$

其中

$$N_k = \sum_{n=1}^N \gamma(z_{nk}). \quad (9.18)$$

我们可以将 N_k 理解为被有效分配到第 k 个簇的样本数量。务必注意该解的形式：第 k 个高斯分量的均值是所有数据点的加权平均，而每个数据点的权重由后验概率 $\gamma(z_{nk})$ 给出，也就是该分量对生成该数据点所承担的责任。

如果将对数似然 $\ln p(\mathbf{X} | \pi, \mu, \Sigma)$ 对协方差矩阵 Σ_k 的导数设为零，并作类似推导，同时利用单高斯的极大似然协方差公式，则得到

$$\Sigma_k = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) (\mathbf{x}_n - \mu_k)(\mathbf{x}_n - \mu_k)^T, \quad (9.19)$$

其形式与单高斯模型的结果相同，只是这里每个数据点都带有后验概率权重，且分母为对应分量的有效样本数。

最后，我们对混合系数 π_k 最大化对数似然 $\ln p(\mathbf{X} | \pi, \mu, \Sigma)$ 。此时必须考虑约束条件 (9.9)，即混合系数之和必须为 1。可通过拉格朗日乘子实现，对以下表达式最大化：

$$\ln p(\mathbf{X} | \pi, \mu, \Sigma) + \lambda \left(\sum_{k=1}^K \pi_k - 1 \right), \quad (9.20)$$

从而得到

$$0 = \sum_{n=1}^N \frac{\mathcal{N}(\mathbf{x}_n | \mu_k, \Sigma_k)}{\sum_j \pi_j \mathcal{N}(\mathbf{x}_n | \mu_j, \Sigma_j)} + \lambda, \quad (9.21)$$

这里再次出现了责任项。如果我们将上式两边乘以 π_k 并对 k 求和，同时利用约束条件 (9.9)，则可得到 $\lambda = -N$ 。将其代入并整理得到

$$\pi_k = \frac{N_k}{N}, \quad (9.22)$$

因此第 k 个分量的混合系数就是该分量对所有数据点的平均责任。

值得强调的是，结果 (9.17)、(9.19) 和 (9.22) 并不构成混合模型参数的封闭形式解，因为责任项 $\gamma(z_{nk})$ 会通过式 (9.13) 以复杂方式依赖这些参数。然而，这些结果确实暗示了一个简单的迭代方案来求解最大似然问题，而正如我们将看到的，对于高斯混合模型

而言，这正是 EM 算法的一个特例。我们首先为均值、协方差和混合系数选择一些初始值。然后在以下两个更新之间交替进行，这两个步骤分别称为 E 步和 M 步，原因稍后会变得清晰。

在“期望步骤”，即 E 步中，我们使用当前的参数值，通过式 (9.13) 计算后验概率或责任。随后在“最大化步骤”，即 M 步中，利用这些概率通过式 (9.17)、(9.19) 和 (9.22) 重新估计均值、协方差和混合系数。注意，在这个过程中我们首先使用式 (9.17) 计算新的均值，然后使用这些新的均值通过式 (9.19) 计算协方差，这与单高斯分布的对应结果一致。

我们将展示，每一次由 E 步与 M 步组成的参数更新，都保证会提升对数似然函数的值。实际应用中，当对数似然函数（或参数）的变化低于某个阈值时，算法被视为已经收敛。图 9.8 展示了 EM 算法对重新缩放后的 Old Faithful 数据进行两成分高斯混合拟合的示例。这里使用两个高斯分量，其中心采用与图 9.1 的 K-means 算法相同的初始化方式，精度矩阵初始化为与单位矩阵成比例。




图 9.8 使用 Old Faithful 数据集对 EM 算法的示意图，该数据集与图 9.1 中用于说明 K-means 算法的示例相同。具体细节参见正文说明。

图 (a) 中绿色为数据点，蓝色与红色圆圈分别表示两个高斯分量的一标准差轮廓，构成混合模型的初始状态。图 (b) 展示了初始 E 步的结果，每个数据点以蓝色墨水的比例表示其由蓝色分量生成的后验概率，以红色墨水的比例表示其由红色分量生成的概率。因此，对两个簇都有显著概率的数据点呈现紫色。

图 (c) 展示了第一次 M 步之后的情况，其中蓝色高斯的均值移动到了数据点的加权均值位置（权重为该点属于蓝色簇的概率），也就是说，均值移动到了“蓝色墨水”的质心。同理，蓝色高斯的协方差被设为蓝色墨水的协方差。红色分量也有完全对应的更新方式。

图 (d)、(e) 和 (f) 分别展示了 EM 算法经过 2 次、5 次和 20 次完整迭代后的结果。在图 (f) 中算法已接近收敛。

需要注意的是，与 K-means 算法相比，EM 算法需要更多迭代才能达到近似收敛，并且每次完整循环都需要显著更多的计算。因此，通常会先运行 K-means 算法以找到高斯混合模型的合适初始化，然后再使用 EM 进行进一步调整。协方差矩阵可以方便地初始化为 K-means 得到的簇的样本协方差，而混合系数可以设置为分配给各簇的数据点比例。

与基于梯度的方法相同，为避免似然函数出现奇异性（例如某个高斯分量塌缩到单个数据点），必须采用一些技术手段。此外，对数似然函数通常具有多个局部极大值，而 EM 并不能保证找到其中最大的一个。由于高斯混合的 EM 算法具有极其重要的作用，我们在下面对其进行总结。

高斯混合模型的 EM 算法

给定一个高斯混合模型，我们的目标是对参数（包括各分量的均值、协方差以及混合系数）进行最大似然估计。

1. 初始化均值 μ_k 、协方差 Σ_k 和混合系数 π_k ，并计算对数似然的初始值。
2. E step. 使用当前的参数值计算责任：

$$\gamma(z_{nk}) = \frac{\pi_k \mathcal{N}(\mathbf{x}_n | \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(\mathbf{x}_n | \mu_j, \Sigma_j)} \quad (9.23)$$

3. M step. 使用当前的责任重新估计参数：

$$\mu_k^{\text{new}} = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) \mathbf{x}_n \quad (9.24)$$

$$\Sigma_k^{\text{new}} = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) (\mathbf{x}_n - \mu_k^{\text{new}})(\mathbf{x}_n - \mu_k^{\text{new}})^T \quad (9.25)$$

$$\pi_k^{\text{new}} = \frac{N_k}{N} \quad (9.26)$$

其中

$$N_k = \sum_{n=1}^N \gamma(z_{nk}) \quad (9.27)$$

4. 计算对数似然：

$$\ln p(\mathbf{X} | \mu, \Sigma, \pi) = \sum_{n=1}^N \ln \left\{ \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x}_n | \mu_k, \Sigma_k) \right\} \quad (9.28)$$

并检查参数或对数似然是否收敛。如果未满足收敛条件，则回到步骤 2

。

9.3 EM 的另一种视角

本节给出 EM 算法的一种互补视角，强调隐变量所起的关键作用。我们首先在一个抽象的框架下讨论这种方法，然后再以高斯混合模型为例说明。

EM 算法的目标是为含有隐变量的模型寻找最大似然解。我们用 $\mathbf{X}$ 表示所有观测数据的集合，其中第 n 行为 $\mathbf{x}_n^T$ ；类似地，用 $\mathbf{Z}$ 表示所有隐变量的集合，其对应的第 n 行为 $\mathbf{z}_n^T$ 。所有模型参数的集合记为 θ ，因此对数似然函数为

$$\ln p(\mathbf{X} | \theta) = \ln \left\{ \sum_{\mathbf{Z}} p(\mathbf{X}, \mathbf{Z} | \theta) \right\}. \quad (9.29)$$

注意，通过将求和替换为积分，该讨论同样适用于连续隐变量。

一个关键发现是，隐变量上的求和出现在对数内部。即使联合分布 $p(\mathbf{X}, \mathbf{Z} | \theta)$ 属于指数族分布，由于这层求和，边缘分布 $p(\mathbf{X} | \theta)$ 通常并不再属于指数族。求和的存在阻止了对数直接作用在联合分布上，使得最大似然解的表达式变得复杂。

现在假设对于 $\mathbf{X}$ 中的每一个观测，我们都知道对应的隐变量 $\mathbf{Z}$ 的值。我们将 $\{\mathbf{X}, \mathbf{Z}\}$ 称为完整数据集，而将实际观测到的数据 $\mathbf{X}$ 称为不完整数据，如图 9.5 所示。完整数据集的对数似然为 $\ln p(\mathbf{X}, \mathbf{Z} | \theta)$ ，我们假定对这一完整数据集的对数似然进行最大化是容易的。

然而在实际情况中，我们并不知道完整数据集 $\{\mathbf{X}, \mathbf{Z}\}$ ，而只知道不完整数据集 $\mathbf{X}$ 。我们对于 $\mathbf{Z}$ 的了解仅来自后验分布 $p(\mathbf{Z} | \mathbf{X}, \theta)$ 。由于不能直接使用完整数据集的对数似然，我们考虑它在隐变量后验分布下的期望值，这一步对应于 EM 算法的 E 步。随后在 M 步中最大化这一期望。如果当前的参数估计值记为 θ^{old} ，那么一对 E 步与 M 步将产生新的参数估计 θ^{new} 。算法通过选择某个初始参数值 θ_0 来开始。使用期望值似乎显得有些随意，但在第 9.4 节中我们将看到这一选择的更深动机。

在 E 步中，我们使用当前参数 θ^{old} 来计算隐变量的后验分布 $p(\mathbf{Z} | \mathbf{X}, \theta^{\text{old}})$ 。然后利用该后验分布求完整数据集对数似然在某个一般参数值 θ 下的期望。这个期望记为 $Q(\theta, \theta^{\text{old}})$ ，定义为

$$Q(\theta, \theta^{\text{old}}) = \sum_{\mathbf{Z}} p(\mathbf{Z} | \mathbf{X}, \theta^{\text{old}}) \ln p(\mathbf{X}, \mathbf{Z} | \theta). \quad (9.30)$$

在 M 步中，我们通过最大化该函数来确定更新后的参数估计：

$$\theta^{\text{new}} = \arg \max_{\theta} Q(\theta, \theta^{\text{old}}). \quad (9.31)$$

注意，在 $Q(\theta, \theta^{\text{old}})$ 的定义中，对数直接作用在联合分布 $p(\mathbf{X}, \mathbf{Z} | \theta)$ 上，因此对应的 M 步最大化根据假设是易于处理的。

一般 EM 算法总结如下。正如我们稍后将要展示的，EM 的每一次迭代都会提高不完整数据集的对数似然（除非算法已经到达某个局部最大值）。

一般 EM 算法

给定观测变量 $\mathbf{X}$ 与隐变量 $\mathbf{Z}$ 的联合分布 $p(\mathbf{X}, \mathbf{Z} | \boldsymbol{\theta})$ ，其由参数 $\boldsymbol{\theta}$ 控制，目标是最大化似然函数 $p(\mathbf{X} | \boldsymbol{\theta})$ 。

1. 选择参数的初始设置 $\boldsymbol{\theta}^{\text{old}}$ 。
2. **E-step**(期望步) 计算 $p(\mathbf{Z} | \mathbf{X}, \boldsymbol{\theta}^{\text{old}})$ 。
3. **M-step**(最大化步) 计算参数更新 $\boldsymbol{\theta}^{\text{new}}$ ，其定义为

$$\boldsymbol{\theta}^{\text{new}} = \arg \max_{\boldsymbol{\theta}} \mathcal{Q}(\boldsymbol{\theta}, \boldsymbol{\theta}^{\text{old}}) \quad (9.32)$$

其中

$$\mathcal{Q}(\boldsymbol{\theta}, \boldsymbol{\theta}^{\text{old}}) = \sum_{\mathbf{Z}} p(\mathbf{Z} | \mathbf{X}, \boldsymbol{\theta}^{\text{old}}) \ln p(\mathbf{X}, \mathbf{Z} | \boldsymbol{\theta}) \quad (9.33)$$

4. 检查对数似然或参数值是否收敛。如果未满足收敛标准，则令

$$\boldsymbol{\theta}^{\text{old}} \leftarrow \boldsymbol{\theta}^{\text{new}} \quad (9.34)$$

并返回步骤 2。

EM 算法也可以用于寻找具有参数先验 $p(\boldsymbol{\theta})$ 的模型的 MAP (最大后验) 解。在这种情况下，E-step 与最大似然情形相同，而 M-step 需要最大化的量变为 $\mathcal{Q}(\boldsymbol{\theta}, \boldsymbol{\theta}^{\text{old}}) + \ln p(\boldsymbol{\theta})$ 。适当选择先验可以消除图 9.7 中展示的那类奇异性。


在以上讨论中，我们将 EM 算法用于具有离散隐变量的似然最大化。但它同样适用于数据集中存在缺失值的情形。观测数据的分布可由所有变量的联合分布对缺失变量进行边缘化得到。EM 随后可以最大化相应的似然函数。我们将在图 12.11 的主成分分析背景中展示这一技术的一个示例。如果数据是随机缺失的，即缺失机制不依赖于未观测值，那么该过程是有效的。然而在许多实际情境中条件并不如此，例如一个传感器当被测量的量超过某个阈值时就无法返回值。

9.3.1 再访高斯混合模型

现在我们将 EM 的隐变量视角应用到高斯混合模型这一具体情形。回忆我们的目标是最大化对数似然函数 (9.14)，它仅使用观测数据集 $\mathbf{X}$ 来计算。然而，由于对数内部存在关于 k 的求和，这一问题比单高斯分布的情况要困难得多。设想除了观测数据 $\mathbf{X}$ 之外，我们还得到了对应的离散变量 $\mathbf{Z}$ 的取值。回忆图 9.5(a) 显示的是“完整”数据集 (即包含每个数据点由哪个分量生成的标签)，而图 9.5(b) 则显示了对应的“不完整”数据。完整数据的图模型如图 9.9 所示。

现在考虑为完整数据集 $\{\mathbf{X}, \mathbf{Z}\}$ 最大化似然的问题。由式 (9.10) 和 (9.11) 可知，该

图 9.9 该图与图 9.6 所示的图形相同，不同之处在于这里假设离散变量 $\mathbf{z}_n$ 与数据变量 $\mathbf{x}_n$ 一样都是可观测的。



似然函数的形式为

$$p(\mathbf{X}, \mathbf{Z} \mid \boldsymbol{\mu}, \boldsymbol{\Sigma}, \boldsymbol{\pi}) = \prod_{n=1}^N \prod_{k=1}^K \pi_k^{z_{nk}} \mathcal{N}(\mathbf{x}_n \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)^{z_{nk}} \quad (9.35)$$

其中 z_{nk} 表示向量 $\mathbf{z}_n$ 的第 k 个分量。取对数后得到

$$\ln p(\mathbf{X}, \mathbf{Z} \mid \boldsymbol{\mu}, \boldsymbol{\Sigma}, \boldsymbol{\pi}) = \sum_{n=1}^N \sum_{k=1}^K z_{nk} \{ \ln \pi_k + \ln \mathcal{N}(\mathbf{x}_n \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \}. \quad (9.36)$$

与不完整数据的对数似然 (9.14) 对比可以发现，求和与对数的位置已经对调；现在对数直接作用在高斯分布上，而高斯是指数族分布成员。因此，不出意料，这显著简化了最大似然问题的求解。我们来看如何做到这一点。

首先考虑对均值和协方差的最大化。由于 $\mathbf{z}_n$ 是一个 K 维向量，除一个元素为 1 外其余均为 0，所以完整数据的对数似然就是 K 项独立和，每一项对应一个混合分量。因此，对某个均值或协方差的最大化与单一高斯分布完全一致，只不过只需要使用被“指派”给该分量的数据点。而对于混合系数的最大化，由于存在约束 (9.9)，不同 k 的混合系数彼此耦合。像之前一样可以使用拉格朗日乘子，最终得到

$$\pi_k = \frac{1}{N} \sum_{n=1}^N z_{nk} \quad (9.37)$$

即混合系数等于分配给对应分量的数据点的比例。

因此，完整数据对数似然可以轻松地闭式最大化。然而在实际中，我们并不知道隐变量的值，因此如前所述，我们需要在隐变量后验分布下取完整数据对数似然的期望。利用式 (9.10)、(9.11) 以及贝叶斯定理可知，该后验分布为：

$$p(\mathbf{Z} \mid \mathbf{X}, \boldsymbol{\mu}, \boldsymbol{\Sigma}, \boldsymbol{\pi}) \propto \prod_{n=1}^N \prod_{k=1}^K [\pi_k \mathcal{N}(\mathbf{x}_n \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)]^{z_{nk}}, \quad (9.38)$$

因此在后验中 $\{\mathbf{z}_n\}$ 在 n 上是独立的。这一点可以从图 9.6 的有向图结构及 d-分离准则轻松验证。在此后验下，指标变量 z_{nk} 的期望为：

$$\begin{aligned} \mathbb{E}[z_{nk}] &= \frac{\sum_{z_{nk}} z_{nk} [\pi_k \mathcal{N}(\mathbf{x}_n \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)]^{z_{nk}}}{\sum_{z_{nj}} [\pi_j \mathcal{N}(\mathbf{x}_n \mid \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)]^{z_{nj}}} \\ &= \frac{\pi_k \mathcal{N}(\mathbf{x}_n \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(\mathbf{x}_n \mid \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)} = \gamma(\mathbf{x}_n, k), \end{aligned} \quad (9.39)$$

即第 k 个分量对数据点 $\mathbf{x}_n$ 的贡献。因此，完整数据对数似然的期望为：

$$\mathbb{E}_{\mathbf{Z}}[\ln p(\mathbf{X}, \mathbf{Z} \mid \boldsymbol{\mu}, \boldsymbol{\Sigma}, \boldsymbol{\pi})] = \sum_{n=1}^N \sum_{k=1}^K \gamma(z_{nk}) \{\ln \pi_k + \ln \mathcal{N}(\mathbf{x}_n \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)\}. \quad (9.40)$$

我们现在可以按如下方式继续进行。首先，我们为参数 $\boldsymbol{\mu}^{\text{old}}$ 、 $\boldsymbol{\Sigma}^{\text{old}}$ 和 $\boldsymbol{\pi}^{\text{old}}$ 选择一些初始值，并使用这些值计算期望（E-step）。然后保持责任不变，对式 (9.40) 关于 $\boldsymbol{\mu}_k$ 、 $\boldsymbol{\Sigma}_k$ 和 π_k 进行最大化（M-step）。这将像之前一样得到 $\boldsymbol{\mu}^{\text{new}}$ 、 $\boldsymbol{\Sigma}^{\text{new}}$ 和 $\boldsymbol{\pi}^{\text{new}}$ 的闭式解，对应式 (9.17)、(9.19) 和 (9.22)。这正是我们先前推导出的高斯混合模型的 EM 算法。在第 9.4 节给出 EM 算法的收敛性证明时，我们将进一步理解期望完整数据对数似然函数所起的作用。

9.3.2 与 K-means 的关系

将 K-means 算法与高斯混合模型的 EM 算法进行比较，可以发现二者之间有紧密的相似性。K-means 对数据点进行硬分配，也就是说，每个数据点被唯一地归入某个簇；而 EM 则基于后验概率进行软分配。事实上，我们可以通过下面的方法，把 K-means 推导为高斯混合模型 EM 的一个极限情况。

考虑一个高斯混合模型，其中各混合成分的协方差矩阵都等于 $\epsilon \mathbf{I}$ ，其中 ϵ 是所有成分共享的方差参数，而 $\mathbf{I}$ 是单位矩阵，因此

$$p(\mathbf{x} \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) = \frac{1}{(2\pi\epsilon)^{1/2}} \exp \left\{ -\frac{1}{2\epsilon} \|\mathbf{x} - \boldsymbol{\mu}_k\|^2 \right\}. \quad (9.41)$$

我们现在考虑在该模型下的 EM 算法，其中 ϵ 被视为固定常数，而不是需要重新估计的参数。根据式 (9.13)，某个数据点 $\mathbf{x}_n$ 的后验概率（责任）为

$$\gamma(z_{nk}) = \frac{\pi_k \exp \left\{ -\|\mathbf{x}_n - \boldsymbol{\mu}_k\|^2 / 2\epsilon \right\}}{\sum_j \pi_j \exp \left\{ -\|\mathbf{x}_n - \boldsymbol{\mu}_j\|^2 / 2\epsilon \right\}}. \quad (9.42)$$

如果考虑极限 $\epsilon \rightarrow 0$ ，可以看到在分母中，距离 $\|\mathbf{x}_n - \boldsymbol{\mu}_j\|^2$ 最小的那一项衰减得最慢，因此除了该项之外其他项对应的责任都趋于零，而该项对应的责任会趋于 1。值得注意的是，只要所有 π_k 都非零，这一结果与它们的具体取值无关。因此在该极限下，我们得到的是类似 K-means 的硬分配，即 $\gamma(z_{nk}) \rightarrow r_{nk}$ ，其中 r_{nk} 由式 (9.2) 定义。于是，每个数据点都被分配给与其均值最近的簇。

EM 的均值更新公式 (9.17) 在此极限下就变为 K-means 的更新结果 (9.4)。需要注意的是，混合系数的更新公式 (9.22) 此时只是将 π_k 重设为第 k 个簇中数据点的占比，但这些参数不再对算法起实际作用。

最后，在 $\epsilon \rightarrow 0$ 的极限下，期望的完整数据对数似然 (9.40) 变为

$$\mathbb{E}_{\mathbf{Z}}[\ln p(\mathbf{X}, \mathbf{Z} \mid \boldsymbol{\mu}, \boldsymbol{\Sigma}, \boldsymbol{\pi})] \rightarrow -\frac{1}{2} \sum_{n=1}^N \sum_{k=1}^K r_{nk} \|\mathbf{x}_n - \boldsymbol{\mu}_k\|^2 + \text{const.} \quad (9.43)$$

因此,在这一极限下,最大化期望的完整数据对数似然与最小化 K-means 的失真度量 J (见式 (9.1)) 是等价的。

需要注意的是, K-means 并不会估计簇的协方差,只会估计簇的均值。Sung 和 Poggio (1994) 提出了一种高斯混合模型的硬分配版本,允许一般的协方差矩阵,被称为椭圆 K-means 算法。

9.3.3 伯努利分布的混合

到目前为止,本章一直关注由高斯混合描述的连续变量分布。作为混合建模的另一个例子,并为了展示 EM 算法在不同情境下的应用,这里讨论由伯努利分布描述的离散二值变量的混合模型。该模型也称为潜类分析 (Lazarsfeld 和 Henry, 1968; McLachlan 和 Peel, 2000)。除了本身具有实践意义外,对伯努利混合的讨论也为之后研究离散变量的隐马尔可夫模型奠定基础。

考虑一组 D 个二值变量 x_i , 其中 $i = 1, \dots, D$, 每个变量都服从参数为 μ_i 的伯努利分布, 因此

$$p(\mathbf{x} | \boldsymbol{\mu}) = \prod_{i=1}^D \mu_i^{x_i} (1 - \mu_i)^{(1-x_i)} \quad (9.44)$$

其中 $\mathbf{x} = (x_1, \dots, x_D)^T$, $\boldsymbol{\mu} = (\mu_1, \dots, \mu_D)^T$ 。可以看到, 给定 $\boldsymbol{\mu}$ 时, 各变量 x_i 相互独立。该分布的均值和协方差容易得到:

$$\mathbb{E}[\mathbf{x}] = \boldsymbol{\mu} \quad (9.45)$$

$$\text{cov}[\mathbf{x}] = \text{diag}\{\mu_i(1 - \mu_i)\} \quad (9.46)$$

现在考虑这些分布的一个有限混合:

$$p(\mathbf{x} | \boldsymbol{\mu}, \boldsymbol{\pi}) = \sum_{k=1}^K \pi_k p(\mathbf{x} | \boldsymbol{\mu}_k) \quad (9.47)$$

其中 $\boldsymbol{\mu} = \{\boldsymbol{\mu}_1, \dots, \boldsymbol{\mu}_K\}$, $\boldsymbol{\pi} = \{\pi_1, \dots, \pi_K\}$, 并且

$$p(\mathbf{x} | \boldsymbol{\mu}_k) = \prod_{i=1}^D \mu_{ki}^{x_i} (1 - \mu_{ki})^{(1-x_i)} \quad (9.48)$$

该混合分布的均值和协方差为:

$$\mathbb{E}[\mathbf{x}] = \sum_{k=1}^K \pi_k \boldsymbol{\mu}_k \quad (9.49)$$

$$\text{cov}[\mathbf{x}] = \sum_{k=1}^K \pi_k \{\boldsymbol{\Sigma}_k + \boldsymbol{\mu}_k \boldsymbol{\mu}_k^T\} - \mathbb{E}[\mathbf{x}] \mathbb{E}[\mathbf{x}]^T \quad (9.50)$$

其中 $\boldsymbol{\Sigma}_k = \text{diag}\{\mu_{ki}(1 - \mu_{ki})\}$ 。因为协方差矩阵 $\text{cov}[\mathbf{x}]$ 不再是对角矩阵, 因此该混合分布可以刻画变量间的相关性, 而单个伯努利分布无法做到这一点。

若给定数据集 $\mathbf{X} = \{\mathbf{x}_1, \dots, \mathbf{x}_N\}$, 则该模型的对数似然函数为:

$$\ln p(\mathbf{X} | \boldsymbol{\mu}, \boldsymbol{\pi}) = \sum_{n=1}^N \ln \left\{ \sum_{k=1}^K \pi_k p(\mathbf{x}_n | \boldsymbol{\mu}_k) \right\} \quad (9.51)$$

可以再次看到对数内部出现求和, 因此最大似然解不再具有闭式形式。

我们现在推导用于最大化伯努利混合模型似然函数的 EM 算法。为此, 先为每个 $\mathbf{x}$ 的实例引入一个显式的潜变量 $\mathbf{z}$ 。与高斯混合的情形相同, $\mathbf{z} = (z_1, \dots, z_K)^T$ 是一个 K 维二值变量, 其中只有一个分量为 1, 其余分量均为 0。于是可将给定潜变量下的条件分布写为:

$$p(\mathbf{x} | \mathbf{z}, \boldsymbol{\mu}) = \prod_{k=1}^K p(\mathbf{x} | \boldsymbol{\mu}_k)^{z_k} \quad (9.52)$$

而潜变量的先验分布与高斯混合模型一致, 因此

$$p(\mathbf{z} | \boldsymbol{\pi}) = \prod_{k=1}^K \pi_k^{z_k} \quad (9.53)$$

若将 $p(\mathbf{x} | \mathbf{z}, \boldsymbol{\mu})$ 和 $p(\mathbf{z} | \boldsymbol{\pi})$ 相乘后对 $\mathbf{z}$ 做边缘化, 便可恢复式 (9.47)。

为了推导 EM 算法, 先写出完整数据对数似然函数, 其形式为

$$\ln p(\mathbf{X}, \mathbf{Z} | \boldsymbol{\mu}, \boldsymbol{\pi}) = \sum_{n=1}^N \sum_{k=1}^K z_{nk} \left\{ \ln \pi_k + \sum_{i=1}^D [x_{ni} \ln \mu_{ki} + (1 - x_{ni}) \ln (1 - \mu_{ki})] \right\} \quad (9.54)$$

其中 $\mathbf{X} = \{\mathbf{x}_n\}$, $\mathbf{Z} = \{\mathbf{z}_n\}$ 。接着, 对潜变量的后验分布求完整数据对数似然的期望得到

$$\mathbb{E}_{\mathbf{Z}}[\ln p(\mathbf{X}, \mathbf{Z} | \boldsymbol{\mu}, \boldsymbol{\pi})] = \sum_{n=1}^N \sum_{k=1}^K \gamma(z_{nk}) \left\{ \ln \pi_k + \sum_{i=1}^D [x_{ni} \ln \mu_{ki} + (1 - x_{ni}) \ln (1 - \mu_{ki})] \right\} \quad (9.55)$$

其中 $\gamma(z_{nk}) = \mathbb{E}[z_{nk}]$ 是给定数据点 $\mathbf{x}_n$ 时分量 k 的后验概率或责任。在 E-step, 利用贝叶斯定理计算这些责任, 其形式为

$$\begin{aligned} \gamma(z_{nk}) = \mathbb{E}[z_{nk}] &= \frac{\sum_{z_{nk}} z_{nk} [\pi_k p(\mathbf{x}_n | \boldsymbol{\mu}_k)]^{z_{nk}}}{\sum_{z_{nj}} [\pi_j p(\mathbf{x}_n | \boldsymbol{\mu}_j)]^{z_{nj}}} \\ &= \frac{\pi_k p(\mathbf{x}_n | \boldsymbol{\mu}_k)}{\sum_{j=1}^K \pi_j p(\mathbf{x}_n | \boldsymbol{\mu}_j)} \end{aligned} \quad (9.56)$$

若考察式 (9.55) 中对 n 的求和, 可以看到责任仅通过两个量参与:

$$N_k = \sum_{n=1}^N \gamma(z_{nk}) \quad (9.57)$$

$$\bar{\mathbf{x}}_k = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) \mathbf{x}_n \quad (9.58)$$

其中 N_k 是与分量 k 相关的有效数据点数。在 M-step 中，对参数 μ_k 和 π 最大化完整数据对数似然的期望。将 (9.55) 对 μ_k 求导并令其为零、整理后得到

$$\mu_k = \bar{\mathbf{x}}_k \quad (9.59)$$

这说明分量 k 的均值被设为数据的加权均值，加权系数由该分量对数据点承担的责任给出。对于对 π_k 的最大化，需要加入拉格朗日乘子来满足约束 $\sum_k \pi_k = 1$ 。按照与高斯混合相同的步骤，可得到

$$\pi_k = \frac{N_k}{N} \quad (9.60)$$

这正是直观的结果：分量 k 的混合系数等于数据集中由该分量解释的数据比例。

需要注意，与高斯混合不同的是，这个模型没有使似然趋于无穷大的奇异性。这一点可由以下事实看出： $0 \leq p(\mathbf{x}_n | \mu_k) \leq 1$ ，因此似然函数有上界。存在使似然趋于零的奇异点，但只要 EM 不从病态的初始点开始，就不会到达这些奇异点，因为 EM 算法总是使似然增加直到达到局部最大值。图 9.10 通过手写数字示例展示了伯努利混合模型。这里将数字图像转成二值向量：所有超过 0.5 的像素设为 1，其余设为 0。随后对 $N = 600$ 个数字（包括数字“2”“3”“4”）运行 $K = 3$ 个伯努利分布的混合模型，并进行 10 次 EM 迭代。混合系数初始化为 $\pi_k = 1/K$ ，参数 μ_{kj} 设为区间 (0.25, 0.75) 上的随机值，并作归一化以满足 $\sum_j \mu_{kj} = 1$ 。可以看到，3 个伯努利分布的混合能够找到数据集中对应不同数字的三个簇。




图 9.10 伯努利混合模型的示意图，其中顶行展示了将数字数据集中的像素值通过阈值 0.5 从灰度转换为二值后的样本示例。底行中的前三幅图像展示了混合模型中三个分量各自对应的参数 μ_{ki} 。作为对比，我们还使用单一的多变量伯努利分布对同一数据集进行了拟合，同样采用最大似然方法。这等价于对每个像素的计数取平均，其结果由底行最右侧的图像所示。

伯努利分布参数的共轭先验是 Beta 分布，我们已经看到，Beta 先验等价于在 $\mathbf{x}$ 上引入额外的有效观测。同样，可以在伯努利混合模型中加入先验，并使用 EM 来最大化后验概率分布。

将伯努利混合的分析扩展到具有 $M > 2$ 个状态的多项式离散变量是直接的，可利用离散分布 (2.26)。同样，如果需要，还可以在模型参数上引入 Dirichlet 先验。

9.3.4 基于贝叶斯线性回归的 EM 算法

作为 EM 应用的第三个例子，我们回到贝叶斯线性回归的证据近似。在 3.5.2 节中，我们通过计算证据并令所得表达式的导数为零，得到了关于超参数 α 和 β 的重新估计方程。现在来看另一种基于 EM 的方法来求 α 和 β 。回顾我们的目标是最大化关于 α 和 β 的证据函数 $p(\mathbf{t} | \alpha, \beta)$ (式 3.77)。由于对参数向量 $\mathbf{w}$ 已经做了边缘化，可以把它视为潜变量，因此我们可以使用 EM 来优化这个边缘似然函数。

在 E 步中，利用当前的 α 和 β 计算 $\mathbf{w}$ 的后验分布，并据此求完整数据对数似然的期望。在 M 步中，对该期望关于 α 和 β 最大化。我们已经知道 $\mathbf{w}$ 的后验分布，由 (3.49) 给出。于是完整数据对数似然为：

$$\ln p(\mathbf{t}, \mathbf{w} | \alpha, \beta) = \ln p(\mathbf{t} | \mathbf{w}, \beta) + \ln p(\mathbf{w} | \alpha) \quad (9.61)$$

其中似然 $p(\mathbf{t} | \mathbf{w}, \beta)$ 和先验 $p(\mathbf{w} | \alpha)$ 分别由 (3.10) 与 (3.52) 给出，而 $y(\mathbf{x}, \mathbf{w})$ 由 (3.3) 定义。对 $\mathbf{w}$ 的后验分布取期望得到：

$$\begin{aligned} \mathbb{E}[\ln p(\mathbf{t}, \mathbf{w} | \alpha, \beta)] &= \frac{M}{2} \ln \left(\frac{\alpha}{2\pi} \right) - \frac{\alpha}{2} \mathbb{E}[\mathbf{w}^T \mathbf{w}] + \frac{N}{2} \ln \left(\frac{\beta}{2\pi} \right) \\ &\quad - \frac{\beta}{2} \sum_{n=1}^N \mathbb{E}[(t_n - \mathbf{w}^T \phi_n)^2]. \end{aligned} \quad (9.62)$$

对 α 求导并令其为零，得到 M 步的重新估计方程：

$$\alpha = \frac{M}{\mathbb{E}[\mathbf{w}^T \mathbf{w}]} = \frac{M}{\mathbf{m}_N^T \mathbf{m}_N + \text{Tr}(\mathbf{S}_N)}. \quad (9.63)$$

关于 β 也可以得到类似的结果。

注意这个重新估计方程的形式与直接通过证据最大化得到的式 (3.92) 略有不同。然而，这两种方法都需要计算并求逆（或特征分解）一个 $M \times M$ 的矩阵，因此单次迭代的计算代价是相当的。

当然，这两种确定 α 的方法应当收敛到同一结果（假设它们找到证据函数的同一局部最大值）。验证该点的方法是注意量 γ 定义为：

$$\gamma = M - \alpha \sum_{i=1}^M \frac{1}{\lambda_i + \alpha} = M - \alpha \text{Tr}(\mathbf{S}_N) \quad (9.64)$$

在证据函数的驻点处，重新估计方程 (3.92) 将自洽成立，因此可以代入 γ 得：

$$\alpha \mathbf{m}_N^T \mathbf{m}_N = \gamma = M - \alpha \text{Tr}(\mathbf{S}_N) \quad (9.65)$$

解出 α 即得到 (9.63)，正是 EM 的重新估计方程。

最后再看一个密切相关的模型，即第 7.2.1 节讨论的回归问题中的相关向量机 (RVM)。那里我们通过直接最大化边缘似然来推导超参数 α 和 β 的重新估计方程。这里采用另一种方法，将权向量 $\mathbf{w}$ 视为潜变量并应用 EM。E-step 是求权重的后验分布，由 (7.81) 给出。M-step 是最大化完整数据对数似然的期望：

$$\mathbb{E}_{\mathbf{w}}[\ln p(\mathbf{t} | \mathbf{X}, \mathbf{w}, \beta) p(\mathbf{w} | \alpha)] \quad (9.66)$$

其中期望是使用旧参数值的后验分布计算的。对 α 和 β 最大化得到新的参数更新：

$$\alpha_i^{\text{new}} = \frac{1}{m_i^2 + \Sigma_{ii}} \quad (9.67)$$

$$(\beta^{\text{new}})^{-1} = \frac{\|\mathbf{t} - \Phi \mathbf{m}_N\|^2 + \beta^{-1} \sum_i \gamma_i}{N} \quad (9.68)$$

这些重新估计方程在形式上与直接最大化方法得到的结果等价。

9.4 一般形式的 EM 算法

期望最大化算法（EM algorithm）是一种适用于含有潜在变量的概率模型的最大似然求解通用技术（Dempster et al., 1977; McLachlan and Krishnan, 1997）。下面给出 EM 的一个非常一般的处理方式，并顺便证明在 9.2 和 9.3 节中对高斯混合模型给出的启发式 EM 算法确实能最大化似然函数（Csiszár and Tusnády, 1984; Hathaway, 1986; Neal and Hinton, 1999）。这些讨论也为之后的变分推断框架的推导奠定基础。

考虑一个概率模型，将所有观测变量统称为 $\mathbf{X}$ ，所有隐藏变量统称为 $\mathbf{Z}$ ，其联合分布为 $p(\mathbf{X}, \mathbf{Z} | \boldsymbol{\theta})$ ，受参数向量 $\boldsymbol{\theta}$ 控制。我们的目标是最大化如下的似然函数：

$$p(\mathbf{X} | \boldsymbol{\theta}) = \sum_{\mathbf{Z}} p(\mathbf{X}, \mathbf{Z} | \boldsymbol{\theta}). \quad (9.69)$$

这里假设 $\mathbf{Z}$ 是离散变量，不过若是连续或离散与连续的组合，讨论方式完全相同，只需将求和换为积分即可。

我们假定直接对 $p(\mathbf{X} | \boldsymbol{\theta})$ 最大化是困难的，而对完整数据似然 $p(\mathbf{X}, \mathbf{Z} | \boldsymbol{\theta})$ 的最大化要容易得多。接着引入一个定义在潜变量上的分布 $q(\mathbf{Z})$ ，可以观察到，对于任何 $q(\mathbf{Z})$ ，都成立以下分解：

$$\ln p(\mathbf{X} | \boldsymbol{\theta}) = \mathcal{L}(q, \boldsymbol{\theta}) + \text{KL}(q || p) \quad (9.70)$$

其中

$$\mathcal{L}(q, \boldsymbol{\theta}) = \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \left\{ \frac{p(\mathbf{X}, \mathbf{Z} | \boldsymbol{\theta})}{q(\mathbf{Z})} \right\} \quad (9.71)$$

$$\text{KL}(q || p) = - \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \left\{ \frac{p(\mathbf{Z} | \mathbf{X}, \boldsymbol{\theta})}{q(\mathbf{Z})} \right\}. \quad (9.72)$$


注意 $\mathcal{L}(q, \boldsymbol{\theta})$ 对于 $q(\mathbf{Z})$ 是泛函（参见附录 D），而对 $\boldsymbol{\theta}$ 是函数。式（9.71）与（9.72）的形式值得细读，它们符号相反，而且 $\mathcal{L}(q, \boldsymbol{\theta})$ 包含 $(\mathbf{X}, \mathbf{Z})$ 的联合分布，而 $\text{KL}(q || p)$ 则包含给定 $\mathbf{X}$ 后 $\mathbf{Z}$ 的条件分布。验证分解式（9.70）的方法是先利用概率乘法规则：

$$\ln p(\mathbf{X}, \mathbf{Z} | \boldsymbol{\theta}) = \ln p(\mathbf{Z} | \mathbf{X}, \boldsymbol{\theta}) + \ln p(\mathbf{X} | \boldsymbol{\theta}) \quad (9.73)$$

然后将其代入 $\mathcal{L}(q, \boldsymbol{\theta})$ ，从而得到两个项，其中一个抵消 KL 项，另一个在注意 $q(\mathbf{Z})$ 归一化后给出所需的 $\ln p(\mathbf{X} | \boldsymbol{\theta})$ 。

由（9.72）可知， $\text{KL}(q || p)$ 是 $q(\mathbf{Z})$ 与后验分布 $p(\mathbf{Z} | \mathbf{X}, \boldsymbol{\theta})$ 的 KL 散度。回顾 KL 散度满足 $\text{KL}(q || p) \geq 0$ ，且当且仅当 $q(\mathbf{Z}) = p(\mathbf{Z} | \mathbf{X}, \boldsymbol{\theta})$ 时取等号。因此由（9.70）立即得


图 9.11 对式 (9.70) 所给分解的示意图, 该分解对任意分布 $q(\mathbf{Z})$ 的选择都成立。由于 Kullback - Leibler 散度满足 $KL(q||p) \geq 0$, 因此可以看出, 量 $\mathcal{L}(q, \theta)$ 是对对数似然函数 $\ln p(\mathbf{X} | \theta)$ 的一个下界。



到 $\mathcal{L}(q, \theta) \leq \ln p(\mathbf{X} | \theta)$, 也就是说 $\mathcal{L}(q, \theta)$ 是对数似然的下界。图 9.11 给出了这种分解的示意。


EM 算法是一个两阶段的迭代优化过程, 用来寻找最大似然解。可以利用分解式 (9.70) 来定义 EM 并证明它确实能增加似然。假设当前参数为 θ^{old} 。在 E-step 中, 通过对 $q(\mathbf{Z})$ 最大化下界 $\mathcal{L}(q, \theta^{\text{old}})$ (保持 θ^{old} 不变), 最优解显然是令 KL 项为零, 即 $q(\mathbf{Z}) = p(\mathbf{Z} | \mathbf{X}, \theta^{\text{old}})$ 。此时下界与对数似然相等, 如图 9.12 所示。

图 9.12 EM 算法中 E-step 的示意图。将分布 q 设为在当前参数取值 θ^{old} 下的后验分布, 从而使下界上移并与对数似然函数达到相同的数值, 此时 KL 散度消失。



在随后的 M-step 中, 固定 $q(\mathbf{Z})$, 最大化 $\mathcal{L}(q, \theta)$ 得到新的参数 θ^{new} 。这会使下界增加 (如果不在最大值处), 从而必然导致似然的增加。由于 q 仍使用旧参数而非新参数, 因此此时 q 并不等于新的后验分布 $p(\mathbf{Z} | \mathbf{X}, \theta^{\text{new}})$, KL 项不为零。对数似然的增加量因此大于下界的增加, 如图 9.13 所示。

图 9.13 EM 算法中 M-step 的示意图。保持分布 $q(\mathbf{Z})$ 不变, 并对参数向量 θ 最大化下界 $\mathcal{L}(q, \theta)$, 从而得到更新后的参数值 θ^{new} 。由于 KL 散度是非负的, 这 will 使对数似然 $\ln p(\mathbf{X} | \theta)$ 的增幅至少不小于下界的增幅。




将 $q(\mathbf{Z}) = p(\mathbf{Z} | \mathbf{X}, \boldsymbol{\theta}^{\text{old}})$ 代入 (9.71)，可见在 E-step 之后，下界变为：

$$\begin{aligned}\mathcal{L}(q, \boldsymbol{\theta}) &= \sum_{\mathbf{Z}} p(\mathbf{Z} | \mathbf{X}, \boldsymbol{\theta}^{\text{old}}) \ln p(\mathbf{X}, \mathbf{Z} | \boldsymbol{\theta}) - \sum_{\mathbf{Z}} p(\mathbf{Z} | \mathbf{X}, \boldsymbol{\theta}^{\text{old}}) \ln p(\mathbf{Z} | \mathbf{X}, \boldsymbol{\theta}^{\text{old}}) \\ &= \mathcal{Q}(\boldsymbol{\theta}, \boldsymbol{\theta}^{\text{old}}) + \text{const}\end{aligned}\quad (9.74)$$

其中常数是 q 的负熵，因此与 $\boldsymbol{\theta}$ 无关。因此在 M-step 中被最大化的量正是完整数据对数似然的期望，正如我们在高斯混合模型时所看到的。注意需要优化的参数 $\boldsymbol{\theta}$ 只出现在对数内部。如果联合分布 $p(\mathbf{Z}, \mathbf{X} | \boldsymbol{\theta})$ 属于指数族或这些分布的乘积，那么对数将抵消指数，使得 M-step 的优化远比直接最大化不完整数据似然 $p(\mathbf{X} | \boldsymbol{\theta})$ 简单得多。

图 9.14 EM 算法通过交替地在当前参数取值下计算对数似然的一个下界，并随后对该下界进行最大化以获得新的参数取值。完整讨论请参见正文。



EM 算法的运行方式也可以在参数空间中进行理解，如图 9.14 所示。图中红色曲线表示我们希望最大化的（不完整数据）对数似然函数。以某个初始参数 $\boldsymbol{\theta}^{\text{old}}$ 为起点，在第一次 E-step 中我们计算潜变量的后验分布，并据此得到一个下界 $\mathcal{L}(\boldsymbol{\theta}, \boldsymbol{\theta}^{\text{old}})$ ，它在 $\boldsymbol{\theta}^{\text{old}}$ 处的取值等于对数似然本身，如蓝色曲线所示。注意下界在 $\boldsymbol{\theta}^{\text{old}}$ 点与对数似然函数相切，因此两者的梯度相同。该下界对 $\boldsymbol{\theta}$ 是一个凸函数，有唯一极大值（对指数族混合成分而言）。在 M-step 中最大化该下界得到新的参数 $\boldsymbol{\theta}^{\text{new}}$ ，其对应的对数似然值比 $\boldsymbol{\theta}^{\text{old}}$ 更大。下一次 E-step 会在 $\boldsymbol{\theta}^{\text{new}}$ 处构造新的相切下界，如绿色曲线所示。

在独立同分布的数据情形下， $\mathbf{X}$ 包含 N 个数据点 $\{\mathbf{x}_n\}$ ，而 $\mathbf{Z}$ 则包含对应的潜变量 $\{\mathbf{z}_n\}$ ，其中 $n = 1, \dots, N$ 。根据独立性假设我们有 $p(\mathbf{X}, \mathbf{Z}) = \prod_n p(\mathbf{x}_n, \mathbf{z}_n)$ ，对 $\{\mathbf{z}_n\}$ 做边缘化得到 $p(\mathbf{X}) = \prod_n p(\mathbf{x}_n)$ 。利用求和与乘积规则可看到 E-step 中要计算的后验概率满足

$$p(\mathbf{Z} | \mathbf{X}, \boldsymbol{\theta}) = \frac{p(\mathbf{X}, \mathbf{Z} | \boldsymbol{\theta})}{\sum_{\mathbf{Z}} p(\mathbf{X}, \mathbf{Z} | \boldsymbol{\theta})} = \frac{\prod_{n=1}^N p(\mathbf{x}_n, \mathbf{z}_n | \boldsymbol{\theta})}{\sum_{\mathbf{Z}} \prod_{n=1}^N p(\mathbf{x}_n, \mathbf{z}_n | \boldsymbol{\theta})} = \prod_{n=1}^N p(\mathbf{z}_n | \mathbf{x}_n, \boldsymbol{\theta}). \quad (9.75)$$

因此后验分布也按 n 分解。对高斯混合模型而言，这表明每个分量对数据点 $\mathbf{x}_n$ 所承担的责任只依赖于 $\mathbf{x}_n$ 自身以及模型参数 $\boldsymbol{\theta}$ ，而不依赖于其他数据点。

我们已经看到，EM 算法的 E-step 与 M-step 都在提高对数似然函数的一个明确的下界，而完整的 EM 循环会改变模型参数使得对数似然增加（除非已经到达最大值处，此时参数不再变化）。

EM 还可以用来最大化后验分布 $p(\boldsymbol{\theta} | \mathbf{X})$ ，适用于那些参数本身具有先验 $p(\boldsymbol{\theta})$ 的模

型。为说明这一点，注意作为 θ 的函数， $p(\theta | \mathbf{X}) = \frac{p(\theta, \mathbf{X})}{p(\mathbf{X})}$ ，因此

$$\ln p(\theta | \mathbf{X}) = \ln p(\theta, \mathbf{X}) - \ln p(\mathbf{X}). \quad (9.76)$$

利用分解式 (9.70)，得到

$$\begin{aligned} \ln p(\theta | \mathbf{X}) &= \mathcal{L}(q, \theta) + \text{KL}(q||p) + \ln p(\theta) - \ln p(\mathbf{X}) \\ &\geq \mathcal{L}(q, \theta) + \ln p(\theta) - \ln p(\mathbf{X}). \end{aligned} \quad (9.77)$$

其中 $\ln p(\mathbf{X})$ 是常数。于是可以再次交替优化右侧表达式，先对 q 最大化，再对 θ 最大化。关于 q 的优化与标准 EM 的 E-step 相同，因为 q 仅出现于 $\mathcal{L}(q, \theta)$ 。而 M-step 方程则会因先验项 $\ln p(\theta)$ 的出现而被修正，但通常只需对最大似然形式的 M-step 做很小的改动。

EM 算法把可能十分困难的似然最大化问题拆分成两个步骤：E-step 与 M-step，这两步通常都比较容易实现。然而，对复杂模型来说，E-step 或 M-step，甚至两者，都可能依然是不可 tractable 的。这就引出了 EM 的两种扩展方式。

广义 EM (generalized EM, GEM) 用于解决 M-step 难以精确最大化的问题。它不再要求对 θ 完全最大化 $\mathcal{L}(q, \theta)$ ，而只要求找到能提升该下界的参数更新。由于 $\mathcal{L}(q, \theta)$ 是对数似然的下界，因此每次 GEM 的完整迭代都会提升对数似然（除非已经处于局部最大点）。在 M-step 中，可以例如使用非线性优化方法，如共轭梯度，以提高下界值。另一种 GEM 形式称为 ECM (expectation conditional maximization) 算法 (Meng and Rubin, 1993)，它将 M-step 拆分成多个约束优化步骤，比如把参数分组，对每组分别做最大化，其他组保持固定。

我们也可以以类似方式推广 E-step，只进行部分而非完全关于 $q(\mathbf{Z})$ 的优化 (Neal and Hinton, 1999)。如前所述，对任意固定的 θ ，在 $q(\mathbf{Z})$ 上 $\mathcal{L}(q, \theta)$ 的唯一最大值对应于后验分布 $q_\theta(\mathbf{Z}) = p(\mathbf{Z} | \mathbf{X}, \theta)$ ，并且在该值处，下界 $\mathcal{L}(q, \theta)$ 恰好等于对数似然 $\ln p(\mathbf{X} | \theta)$ 。因此，只要算法能收敛到 $\mathcal{L}(q, \theta)$ 的全局最大点，它得到的参数 θ 也将是 $\ln p(\mathbf{X} | \theta)$ 的全局最大点。若 $p(\mathbf{X}, \mathbf{Z} | \theta)$ 关于 θ 连续，则由连续性可知， $\mathcal{L}(q, \theta)$ 的任意局部最大点也对应于 $\ln p(\mathbf{X} | \theta)$ 的局部最大点。

接下来考虑 N 个独立数据点 $\mathbf{x}_1, \dots, \mathbf{x}_N$ 及其对应的潜变量 $\mathbf{z}_1, \dots, \mathbf{z}_N$ 。联合分布 $p(\mathbf{X}, \mathbf{Z} | \theta)$ 在数据点之间可以分解，这一点可以被用于一种增量式的 EM：在每次 EM 循环中只处理一个数据点。在 E-step 中，我们不必重新计算所有数据点的责任值，只需更新一个数据点的责任。看起来 M-step 需要用到所有数据点的更新责任值；但若混合成分属于指数族，责任只通过简单的充分统计量进入，而这些统计量可以被高效地增量更新。例如以高斯混合为例，当更新第 m 个数据点时，其旧责任和新责任分别为 $\gamma^{\text{old}}(z_{mk})$ 与 $\gamma^{\text{new}}(z_{mk})$ 。在 M-step 中，充分统计量可按增量方式更新。以均值为例，其充分统计量由 (9.17) 和 (9.18) 定义，可得：

$$\mu_k^{\text{new}} = \mu_k^{\text{old}} + \left(\frac{\gamma^{\text{new}}(z_{mk}) - \gamma^{\text{old}}(z_{mk})}{N_k^{\text{new}}} \right) (\mathbf{x}_m - \mu_k^{\text{old}}) \quad (9.78)$$

以及：

$$N_k^{\text{new}} = N_k^{\text{old}} + \gamma^{\text{new}}(z_{mk}) - \gamma^{\text{old}}(z_{mk}). \quad (9.79)$$

协方差与混合系数的更新方式完全类似。

因此 E-step 与 M-step 的复杂度都与数据点总数无关，是固定的。由于参数在每处理完一个数据点后就立即更新，而不是等所有数据处理完才更新，这种增量方法常常比批处理版本收敛更快。增量算法中的每个 E-step 或 M-step 都会提升 $\mathcal{L}(q, \theta)$ 的值，而如前所示，只要算法收敛到 $\mathcal{L}$ 的局部（或全局）最大点，它也就收敛到了对数似然 $\ln p(\mathbf{X} | \theta)$ 的局部（或全局）最大点。

10 近似推断

在概率模型的应用中，一个核心任务是评估潜在变量 $\mathbf{Z}$ 在给定可观测（可见）数据 $\mathbf{X}$ 下的后验分布 $p(\mathbf{Z} | \mathbf{X})$ ，以及计算相应的期望值。模型中可能还包含一些确定性的参数（这里先不显式写出），或者模型也可能是完全贝叶斯的，此时所有未知参数都带有先验分布，并被吸收进潜变量向量 $\mathbf{Z}$ 中。

例如，在 EM 算法中，我们需要利用潜变量的后验分布来计算完整数据对数似然的期望。对许多实际模型来说，直接求后验分布或者对其进行期望计算都是不可行的。这可能是因为潜变量空间的维度太高，难以直接处理；也可能是因为后验分布形式复杂，导致期望难以解析求解。若潜变量是连续的，所需的积分可能没有解析形式，而积分空间的维度和被积函数的复杂性往往使数值积分也难以实现。若潜变量是离散的，求边缘分布涉及对所有可能配置求和，虽然理论上总是可行，但在实践中隐藏状态通常呈指数级增长，使得精确计算极其昂贵。

在这种情况下，我们必须采用近似方案，它们大致可以分为两类：基于随机方法的近似与基于确定性方法的近似。随机方法如第 11 章介绍的马尔可夫链蒙特卡罗 (MCMC)，在许多领域中促进了贝叶斯方法的广泛应用。若计算资源无限，它们可以产生精确结果，而近似来自有限运行时间的限制。然而在实践中，采样方法往往计算量大，使它们通常只能用于较小规模的问题。此外，判断采样过程是否真正产生了来自目标分布的独立样本也并不容易。

本章将介绍一系列确定性的近似方法，其中一些方法能够很好地扩展到大规模应用。这类方法通常基于对后验分布的解析近似，例如假设某种因子分解结构，或假设后验具有某种参数化形式，如高斯分布。因为它们依赖于特定的假设，所以永远无法得到完全精确的结果，因此它们的优缺点与采样方法互为补充。

在 4.4 节中，我们讨论了拉普拉斯近似，它是基于对分布某个模态（即最大值附近）的局部高斯近似。这里将讨论一类称为变分推断 (variational inference 或 variational Bayes) 的近似技术，它们基于更全局的准则，并已得到广泛应用。最后，我们将简要介绍另一种变分框架：期望传播 (expectation propa

10.1 变分推断

变分方法起源于 18 世纪，源自 Euler、Lagrange 等人对变分法的研究。标准微积分关注的是求函数的导数。我们可以把函数看成一种映射：输入变量的值，输出函数的值；导数描述了当输入发生无穷小变化时，输出如何变化。类似地，一个泛函可以被视为一种映射：输入是一个函数，输出是该泛函的值。一个例子是熵 $H[p]$ ，它把概率分布 $p(x)$ 作为输入，输出：

$$H[p] = \int p(x) \ln p(x) dx \quad (10.1)$$

我们可以引入“泛函导数”，表示当输入函数发生无穷小变化时，泛函的值如何变化 (Feynman et al., 1964)。变分法的规则与标准微积分类似，附录 D 中有进一步讨论。许多问题可以写成关于泛函的优化问题，即通过探索所有可能的输入函数，找到使泛函

最大或最小的那个函数。变分方法有广泛应用，比如有限元方法（Kapur, 1989）和最大熵方法（Schwarz, 1988）。

虽然变分方法本身并非近似方法，但它们非常自然地用于寻找近似解。方法是限制可优化的函数空间，例如只考虑二次函数，或考虑由固定基函数线性组合而成的函数，并只允许线性组合的系数变化。在概率推断中，这种限制通常体现为分解假设（Jordan et al., 1999; Jaakkola, 2001）等。

现在更深入地讨论如何将变分优化思想用于推断问题。假设我们有一个完全贝叶斯模型，其中所有参数都带有先验分布。模型也可能包含潜变量，我们用 $\mathbf{Z}$ 表示所有潜变量与参数，用 $\mathbf{X}$ 表示所有观测变量。例如，如果有 N 个独立同分布的数据点，那么 $\mathbf{X} = \{\mathbf{x}_1, \dots, \mathbf{x}_N\}$ ，而 $\mathbf{Z} = \{\mathbf{z}_1, \dots, \mathbf{z}_N\}$ 。概率模型给出联合分布 $p(\mathbf{X}, \mathbf{Z})$ ，我们的目标是为后验 $p(\mathbf{Z} | \mathbf{X})$ 以及模型证据 $p(\mathbf{X})$ 找到近似。如同在 EM 的讨论中，我们可以写出边缘概率的分解：

$$\ln p(\mathbf{X}) = \mathcal{L}(q) + \text{KL}(q||p) \quad (10.2)$$

其中

$$\mathcal{L}(q) = \int q(\mathbf{Z}) \ln \left\{ \frac{p(\mathbf{X}, \mathbf{Z})}{q(\mathbf{Z})} \right\} d\mathbf{Z} \quad (10.3)$$

$$\text{KL}(q||p) = - \int q(\mathbf{Z}) \ln \left\{ \frac{p(\mathbf{Z} | \mathbf{X})}{q(\mathbf{Z})} \right\} d\mathbf{Z}. \quad (10.4)$$

与 EM 的不同之处在于，参数向量 θ 已经不再出现，因为参数现在也是随机变量，被吸收到 $\mathbf{Z}$ 中。本章主要关注连续变量，因此使用了积分而非求和；如果部分变量是离散的，则只需把积分换成求和即可，其余推导不受影响。

与之前一样，我们可以通过最大化 $\mathcal{L}(q)$ 来优化近似，也就是最小化 KL 散度。如果 $q(\mathbf{Z})$ 可以任意选择，则下界的最大值在 KL 散度为零时取得，即 $q(\mathbf{Z}) = p(\mathbf{Z} | \mathbf{X})$ 。然而，由于模型复杂，使用真实后验往往不可行。

因此我们考虑一个受限的分布族 $q(\mathbf{Z})$ ，并在其中寻找使 KL 散度最小的成员。目标是在确保可 tractable 的同时，让该分布族足够灵活，以便很好地逼近真实后验。必须强调，这种限制仅仅为了可 tractable 性；在此条件下，我们应尽可能选择丰富的近似分布族。特别地，更灵活的分布族不会造成“过拟合”，只会让我们更接近真实后验。

限制近似分布族的一种方式，是使用带参数的分布 $q(\mathbf{Z} | \omega)$ ，其中 ω 是一组待优化的参数。此时下界 $\mathcal{L}(q)$ 就变成了关于 ω 的函数，我们可以使用标准的非线性优化技术来求出这些参数的最优值。一个例子如图 10.1 所示：变分分布取为高斯分布，并对其均值和方差进行优化。

10.1.1 因子化分布

这里我们讨论一种对分布 $q(\mathbf{Z})$ 的族进行限制的替代方式。假设我们将 $\mathbf{Z}$ 的元素划分为互不相交的若干组，记为 $\mathbf{Z}_i$ ，其中 $i = 1, \dots, M$ 。然后我们假设 q 分布在这些组之




图 10.1 对图 4.14 中先前所考虑示例的变分近似的示意图。左图显示了原始分布（黄色）以及 Laplace 近似（红色）和变分近似（绿色），右图显示了对应曲线的负对数。

间因子化，因此有

$$q(\mathbf{Z}) = \prod_{i=1}^M q_i(\mathbf{Z}_i) \quad (10.5)$$

需要强调的是，我们对分布不做进一步假设。特别地，我们不对各个因子 $q_i(\mathbf{Z}_i)$ 的函数形式施加任何限制。这样的因子化变分推断形式对应于物理中称为平均场理论的近似框架（Parisi, 1988）。

在所有具有形式 (10.5) 的分布 $q(\mathbf{Z})$ 中，我们希望找到使下界 $\mathcal{L}(q)$ 最大的那个。因此我们希望对所有分布 $q_i(\mathbf{Z}_i)$ 进行自由形式（变分）优化，这可以通过依次对每个因子进行优化来完成。为此，我们首先将 (10.5) 代入 (10.3)，然后分离出对某个因子 $q_j(\mathbf{Z}_j)$ 的依赖。为了使符号简洁，我们把 $q_j(\mathbf{Z}_j)$ 记为 q_j ，于是得到

$$\begin{aligned} \mathcal{L}(q) &= \int \prod_i q_i \left\{ \ln p(\mathbf{X}, \mathbf{Z}) - \sum_i \ln q_i \right\} d\mathbf{Z} \\ &= \int q_j \left\{ \int \ln p(\mathbf{X}, \mathbf{Z}) \prod_{i \neq j} q_i d\mathbf{Z}_i \right\} d\mathbf{Z}_j - \int q_j \ln q_j d\mathbf{Z}_j + \text{const} \\ &= \int q_j \ln \tilde{p}(\mathbf{X}, \mathbf{Z}_j) d\mathbf{Z}_j - \int q_j \ln q_j d\mathbf{Z}_j + \text{const} \end{aligned} \quad (10.6)$$

其中我们通过下式定义了一个新的分布 $\tilde{p}(\mathbf{X}, \mathbf{Z}_j)$ ：

$$\ln \tilde{p}(\mathbf{X}, \mathbf{Z}_j) = \mathbb{E}_{i \neq j} [\ln p(\mathbf{X}, \mathbf{Z})] + \text{const}. \quad (10.7)$$

这里符号 $\mathbb{E}_{i \neq j}[\cdot]$ 表示对所有 $i \neq j$ 的变量 $\mathbf{z}_i$ 的 q 分布求期望，因此有

$$\mathbb{E}_{i \neq j} [\ln p(\mathbf{X}, \mathbf{Z})] = \int \ln p(\mathbf{X}, \mathbf{Z}) \prod_{i \neq j} q_i d\mathbf{Z}_i \quad (10.8)$$

现在假设我们固定所有 $\{q_{i \neq j}\}$ ，然后对所有可能形式的 $q_j(\mathbf{Z}_j)$ 最大化 (10.6) 中的 $\mathcal{L}(q)$ 。这可以通过注意到 (10.6) 是 $q_j(\mathbf{Z}_j)$ 与 $\tilde{p}(\mathbf{X}, \mathbf{Z}_j)$ 之间的负 KL 散度来轻松完成。因此最大化 (10.6) 等价于最小化 KL 散度，而其最小值发生在 $q_j(\mathbf{Z}_j) = \tilde{p}(\mathbf{X}, \mathbf{Z}_j)$ 时。因此我们得到因子 $q_j^*(\mathbf{Z}_j)$ 的一般最优形式：

$$\ln q_j^*(\mathbf{Z}_j) = \mathbb{E}_{i \neq j} [\ln p(\mathbf{X}, \mathbf{Z})] + \text{const}. \quad (10.9)$$

值得花一点时间研究这个解的形式，因为它构成了变分方法应用的基础。它表明：因子 q_j 的最优对数形式，就是取整个隐藏与可见变量的联合分布的对数，并对所有其他因子 $\{q_i\}$ ($i \neq j$) 做期望得到的。

(10.9) 中的加性常数由对分布 $q_j^*(\mathbf{Z}_j)$ 的归一化来确定。因此，如果我们对等式两边取指数并进行归一化，就有

$$q_j^*(\mathbf{Z}_j) = \frac{\exp(\mathbb{E}_{i \neq j}[\ln p(\mathbf{X}, \mathbf{Z})])}{\int \exp(\mathbb{E}_{i \neq j}[\ln p(\mathbf{X}, \mathbf{Z})]) d\mathbf{Z}_j}$$

在实际应用中，我们会发现使用形式 (10.9) 更为方便，并在需要时通过直观判断来恢复归一化常数。接下来的例子会使这一点变得清楚。

由 (10.9) 给出的对所有 $j = 1, \dots, M$ 的方程构成了一组一致性条件，用于在因子化约束下最大化下界。然而，它们并不构成一个显式解，因为 (10.9) 右侧给出的最优 $q_j^*(\mathbf{Z}_j)$ 依赖于对所有 $i \neq j$ 的因子 $q_i(\mathbf{Z}_i)$ 的期望。因此，我们将通过以下方式寻求一致解：首先对所有因子 $q_i(\mathbf{Z}_i)$ 进行适当初始化，然后在因子之间循环，每次将某个因子替换为根据 (10.9) 右侧表达式计算得到的更新版本，而该表达式使用了对其他所有因子当前估计的期望值。收敛性是有保证的，因为该下界对每个因子 $q_i(\mathbf{Z}_i)$ 都是凸的 (Boyd and Vandenberghe, 2004)。

10.1.2 因子化近似的性质

我们的变分推断方法基于对真实后验分布的因子化近似。为了更好地理解因子化近似会引入哪些类型的不准确性，我们先考虑一个简单情形：用一个因子化高斯来近似一个一般高斯分布。具体地，考虑一个二维相关变量 $\mathbf{z} = (z_1, z_2)$ 的高斯分布 $p(\mathbf{z}) = \mathcal{N}(\mathbf{z} | \boldsymbol{\mu}, \boldsymbol{\Lambda}^{-1})$ ，其中均值和精度矩阵为

$$\boldsymbol{\mu} = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \quad \boldsymbol{\Lambda} = \begin{pmatrix} \Lambda_{11} & \Lambda_{12} \\ \Lambda_{21} & \Lambda_{22} \end{pmatrix} \quad (10.10)$$

并且由于精度矩阵的对称性有 $\Lambda_{21} = \Lambda_{12}$ 。现在假设我们希望用一个因子化高斯 $q(\mathbf{z}) = q_1(z_1)q_2(z_2)$ 来近似该分布。我们首先应用一般结果 (10.9)，求解最优因子 $q_1^*(z_1)$ 。为此，注意到右侧只需保留对 z_1 有函数依赖的项，因为其余各项都可吸收到归一化常数中。这样得到

$$\begin{aligned} \ln q_1^*(z_1) &= \mathbb{E}_{z_2}[\ln p(\mathbf{z})] + \text{const} \\ &= \mathbb{E}_{z_2} \left[-\frac{1}{2}(z_1 - \mu_1)^2 \Lambda_{11} - (z_1 - \mu_1) \Lambda_{12} (z_2 - \mu_2) \right] + \text{const} \\ &= -\frac{1}{2} z_1^2 \Lambda_{11} + z_1 \mu_1 \Lambda_{11} - z_1 \Lambda_{12} (\mathbb{E}[z_2] - \mu_2) + \text{const}. \end{aligned} \quad (10.11)$$

我们看到，上式右侧关于 z_1 是一个二次函数，因此 $q_1^*(z_1)$ 必然是一个高斯分布。这里值得强调的是，我们并未预设 $q(z_i)$ 为高斯；这个结论是通过对所有可能分布 $q(z_i)$ 的 KL 散度进行变分优化得到的。此外，加性常数无需显式处理，它对应的只是之后可由

观察确定的归一化常数。通过配方法，我们可以识别该高斯分布的均值和精度，从而得到

$$q_1^*(z_1) = \mathcal{N}(z_1 \mid m_1, \Lambda_{11}^{-1}) \quad (10.12)$$

其中

$$m_1 = \mu_1 - \Lambda_{11}^{-1} \Lambda_{12} (\mathbb{E}[z_2] - \mu_2). \quad (10.13)$$

由于对称性， $q_2^*(z_2)$ 也将是高斯分布，可写为


$$q_2^*(z_2) = \mathcal{N}(z_2 \mid m_2, \Lambda_{22}^{-1}) \quad (10.14)$$

其中

$$m_2 = \mu_2 - \Lambda_{22}^{-1} \Lambda_{21} (\mathbb{E}[z_1] - \mu_1). \quad (10.15)$$

注意，这些解是耦合的： $q_1^*(z_1)$ 的均值依赖于对 $q_2^*(z_2)$ 的期望，反之亦然。通常我们将这些变分解视为重新估计方程，轮流更新各个变量，直到满足收敛准则。稍后我们会看到一个例子。不过，在当前这个简单问题中，可以找到一个闭式解。由于 $\mathbb{E}[z_1] = m_1$ 、 $\mathbb{E}[z_2] = m_2$ ，我们发现若取 $\mathbb{E}[z_1] = \mu_1$ 且 $\mathbb{E}[z_2] = \mu_2$ ，两条方程即可满足，并且若分布非奇异，可证明这是唯一解。图 10.2(a) 展示了该结果：虽然均值被准确捕获，但近似分布 $q(\mathbf{z})$ 的方差由 $p(\mathbf{z})$ 中最小方差方向主导，而在其正交方向上的方差被显著低估。一般来说，因子化变分近似会给出过于集中的后验分布。

图 10.2 两种 Kullback-Leibler 散度不同形式的比较。绿色等高线表示定义在两个变量 z_1 和 z_2 上的相关高斯分布 $p(\mathbf{z})$ 在 1、2 和 3 个标准差处的等值线；红色等高线表示在相同变量上近似分布 $q(\mathbf{z})$ 的对应水平，其中 $q(\mathbf{z})$ 被设为两个相互独立的一维高斯分布的乘积，其参数通过最小化 (a) Kullback-Leibler 散度 $\text{KL}(q\|p)$ ，以及 (b) 反向的 Kullback-Leibler 散度 $\text{KL}(p\|q)$ 得到。



作为比较，假设我们现在最小化反向的 Kullback-Leibler 散度 $\text{KL}(p\|q)$ 。我们将看到，这种形式的 KL 散度被用于一种称为期望传播的替代近似推断框架中。因此，我们考虑在 $q(\mathbf{Z})$ 是形如 (10.5) 的因子化近似时最小化 $\text{KL}(p\|q)$ 的一般问题。KL 散度可写成如下形式：

$$\text{KL}(p\|q) = - \int p(\mathbf{Z}) \left[\sum_{i=1}^M \ln q_i(\mathbf{Z}_i) \right] d\mathbf{Z} + \text{const} \quad (10.16)$$

其中常数项只是 $p(\mathbf{Z})$ 的熵，因此不依赖于 $q(\mathbf{Z})$ 。现在我们可以对每一个因子 $q_j(\mathbf{Z}_j)$ 进行优化，利用拉格朗日乘子可以轻松得到

$$q_j^*(\mathbf{Z}_j) = \int p(\mathbf{Z}) \prod_{i \neq j} d\mathbf{Z}_i = p(\mathbf{Z}_j) \quad (10.17)$$

在这种情况下，我们发现 $q_j(\mathbf{Z}_j)$ 的最优解正是 $p(\mathbf{Z})$ 的对应边缘分布。注意这是一个闭式解，因此不需要迭代。

为了将这一结果应用到示例中关于定义在向量 $\mathbf{z}$ 上的高斯分布 $p(\mathbf{z})$ ，我们可以使用 (2.98)，从而得到图 10.2(b) 所示的结果。我们看到，近似的均值依然是正确的，但它在变量空间中概率很低的区域放置了大量概率质量。

这两个结果之间的差异可以通过注意到在下式中的 Kullback-Leibler 散度

$$\text{KL}(q\|p) = - \int q(\mathbf{Z}) \ln \left\{ \frac{p(\mathbf{Z})}{q(\mathbf{Z})} \right\} d\mathbf{Z} \quad (10.18)$$

，来自 $\mathbf{Z}$ 空间中 $p(\mathbf{Z})$ 接近零而 $q(\mathbf{Z})$ 不接近零的区域会带来很大的正贡献。因此，最小化这种形式的 KL 散度会使得 $q(\mathbf{Z})$ 避开 $p(\mathbf{Z})$ 很小的区域。相反，最小化 Kullback-Leibler 散度 $\text{KL}(p\|q)$ 会使得 $q(\mathbf{Z})$ 在 $p(\mathbf{Z})$ 非零的区域也非零。




图 10.3 对 Kullback-Leibler 散度两种不同形式的另一种比较。(a) 蓝色等高线表示由两个高斯分布混合而成的双峰分布 $p(\mathbf{Z})$ ，红色等高线表示在最小化 Kullback-Leibler 散度 $\text{KL}(p\|q)$ 意义下对 $p(\mathbf{Z})$ 进行最佳近似的单个高斯分布 $q(\mathbf{Z})$ 。(b) 与 (a) 类似，但此时红色等高线对应的是通过数值方式最小化 Kullback-Leibler 散度 $\text{KL}(q\|p)$ 所得到的的高斯分布 $q(\mathbf{Z})$ 。(c) 与 (b) 类似，但展示的是 Kullback-Leibler 散度的另一个不同的局部最小值。

如果考虑使用单峰分布去近似多峰分布（如图 10.3 所示），我们可以进一步理解两种 KL 散度的不同行为。在实际应用中，真实后验分布往往是多峰的，大部分后验质量集中在参数空间中若干相对较小的区域中。这些多峰性可能来自潜变量空间中的不可识别性，或来自参数的复杂非线性依赖。这两类多峰性都曾在第 9 章的高斯混合模型中出现过，它们表现为似然函数的多个极大值，而基于最小化 $\text{KL}(q\|p)$ 的变分处理通常会找到这些模式中的一个。相比之下，如果我们最小化 $\text{KL}(p\|q)$ ，得到的近似会对所有模式求平均，而在混合模型的背景下，这会导致较差的预测分布（因为两个好参数值的平均通常本身不是一个好参数值）。可以利用 $\text{KL}(p\|q)$ 定义一个有用的推断过程，但这需要与这里讨论的方式截然不同的方法，我们将在讨论期望传播时详细介绍。

这两种 Kullback-Leibler 散度都属于 alpha 散度族 (Ali and Silvey, 1966; Amari, 1985; Minka, 2005)，其定义为

$$D_\alpha(p\|q) = \frac{4}{1-\alpha^2} \left(1 - \int p(x)^{(1+\alpha)/2} q(x)^{(1-\alpha)/2} dx \right) \quad (10.19)$$

其中 $-\infty < \alpha < \infty$ 是连续参数。Kullback-Leibler 散度 $\text{KL}(p\|q)$ 对应极限 $\alpha \rightarrow 1$ ，而 $\text{KL}(q\|p)$ 对应极限 $\alpha \rightarrow -1$ 。对于所有 α 都有 $D_\alpha(p\|q) \geq 0$ ，且当且仅当 $p(x) = q(x)$ 时

取等号。假设 $p(x)$ 是固定分布，我们对某组分布 $q(x)$ 最小化 $D_\alpha(p\|q)$ 。当 $\alpha \leq -1$ 时，这种散度是“零强迫”的，也就是说凡是 $p(x) = 0$ 的 x ，都必须使 $q(x) = 0$ ，并且通常 $q(x)$ 会低估 $p(x)$ 的支撑，并倾向于选择具有最大质量的模式。相反，当 $\alpha \geq 1$ 时，散度是“零回避”的，也就是只要 $p(x) > 0$ 就会使 $q(x) > 0$ ，并且通常 $q(x)$ 会扩张覆盖 $p(x)$ 的整个支撑，进而高估 $p(x)$ 的支撑。当 $\alpha = 0$ 时，我们得到一种对称散度，它与 Hellinger 距离线性相关，其形式为

$$D_H(p\|q) = \int (p(x)^{1/2} - q(x)^{1/2})^2 dx \quad (10.20)$$

Hellinger 距离的平方根是一个有效的距离度量。

10.1.3 示例：单变量高斯分布

现在我们用一个关于单变量 x 的高斯分布示例 (MacKay, 2003) 来说明因子化变分近似。我们的目标是在给定数据集 $\mathcal{D} = \{x_1, \dots, x_N\}$ 的情况下推断均值 μ 和精度 τ 的后验分布，这些观测值被认为是独立地从该高斯分布中抽取的。其似然函数为

$$p(\mathcal{D} | \mu, \tau) = \left(\frac{\tau}{2\pi}\right)^{N/2} \exp \left\{ -\frac{\tau}{2} \sum_{n=1}^N (x_n - \mu)^2 \right\}. \quad (10.21)$$

接下来我们为 μ 和 τ 引入共轭先验分布：

$$p(\mu | \tau) = \mathcal{N}(\mu | \mu_0, (\lambda_0 \tau)^{-1}) \quad (10.22)$$

$$p(\tau) = \text{Gam}(\tau | a_0, b_0) \quad (10.23)$$

其中 $\text{Gam}(\tau | a_0, b_0)$ 是由 (2.146) 定义的 Gamma 分布。它们一起构成一个高斯-Gamma 共轭先验分布。

对于这个简单问题，后验分布是可以精确求得的，并且依然是一个高斯-Gamma 分布。然而，为了教学目的，我们将使用一个因子化变分近似，即

$$q(\mu, \tau) = q_\mu(\mu) q_\tau(\tau). \quad (10.24)$$

注意真实后验分布并不会以这种方式因子化。最优因子 $q_\mu(\mu)$ 和 $q_\tau(\tau)$ 可以通过一般结果 (10.9) 得到。对 $q_\mu(\mu)$ 有

$$\begin{aligned} \ln q_\mu^*(\mu) &= \mathbb{E}_\tau [\ln p(\mathcal{D} | \mu, \tau) + \ln p(\mu | \tau)] + \text{const} \\ &= -\frac{\mathbb{E}[\tau]}{2} \left\{ \lambda_0 (\mu - \mu_0)^2 + \sum_{n=1}^N (x_n - \mu)^2 \right\} + \text{const}. \end{aligned} \quad (10.25)$$

对 μ 完全平方可见 $q_\mu(\mu)$ 是一个高斯分布 $\mathcal{N}(\mu | \mu_N, \lambda_N^{-1})$ ，其均值与精度为

$$\mu_N = \frac{\lambda_0 \mu_0 + N \bar{x}}{\lambda_0 + N} \quad (10.26)$$

$$\lambda_N = (\lambda_0 + N) \mathbb{E}[\tau]. \quad (10.27)$$

注意当 $N \rightarrow \infty$ 时, 该结果给出最大似然解, 此时 $\mu_N = \bar{x}$ 且精度趋于无穷大。

类似地, 因子 $q_\tau(\tau)$ 的最优解为

$$\begin{aligned} \ln q_\tau^*(\tau) &= \mathbb{E}_\mu[\ln p(\mathcal{D} \mid \mu, \tau) + \ln p(\mu \mid \tau)] + \ln p(\tau) + \text{const} \\ &= (a_0 - 1) \ln \tau - b_0 \tau + \frac{N}{2} \ln \tau \\ &\quad - \frac{\tau}{2} \mathbb{E}_\mu \left[\sum_{n=1}^N (x_n - \mu)^2 + \lambda_0 (\mu - \mu_0)^2 \right] + \text{const} \end{aligned} \quad (10.28)$$

因此 $q_\tau(\tau)$ 是一个 **Gamma** 分布 $\text{Gam}(\tau \mid a_N, b_N)$, 其参数为

$$a_N = a_0 + \frac{N}{2} \quad (10.29)$$

$$b_N = b_0 + \frac{1}{2} \mathbb{E}_\mu \left[\sum_{n=1}^N (x_n - \mu)^2 + \lambda_0 (\mu - \mu_0)^2 \right]. \quad (10.30)$$

当 $N \rightarrow \infty$ 时, 该结果也体现了预期行为。需要强调的是, 我们并未假设最优分布 $q_\mu(\mu)$ 和 $q_\tau(\tau)$ 拥有这些特定的函数形式, 它们是由似然函数结构及其共轭先验自然产生的。

由此我们得到了最优分布 $q_\mu(\mu)$ 和 $q_\tau(\tau)$ 的表达式, 它们都依赖于由对方分布计算得到的矩。求解的一种方式首先是首先对例如 $\mathbb{E}[\tau]$ 给出一个初始猜测, 并据此重新计算分布 $q_\mu(\mu)$ 。得到修正后的分布后, 可以提取所需的矩 $\mathbb{E}[\mu]$ 和 $\mathbb{E}[\mu^2]$, 并用它们重新计算分布 $q_\tau(\tau)$, 如此往复。由于本例中的隐变量空间仅为二维, 我们可以通过绘制真实后验和因子化近似的等高线来展示变分近似, 如图 10.4 所示。

一般来说, 我们需要使用类似这样的迭代方法来求解最优的因子化后验分布。然而, 对于我们这里讨论的这个非常简单的例子, 可以通过求解关于最优因子 $q_\mu(\mu)$ 和 $q_\tau(\tau)$ 的联立方程来找到显式解。在此之前, 我们可以通过考虑宽泛的、非信息性的先验来简化这些表达式, 此时取 $\mu_0 = a_0 = b_0 = \lambda_0 = 0$ 。虽然这些设置对应于不适定先验, 但我们看到后验分布依然是良好定义的。利用 **Gamma** 分布均值的标准结果 $\mathbb{E}[\tau] = a_N/b_N$, 并结合 (10.29) 和 (10.30), 可得

$$\frac{1}{\mathbb{E}[\tau]} = \mathbb{E} \left[\frac{1}{N} \sum_{n=1}^N (x_n - \mu)^2 \right] = \overline{x^2} - 2\bar{x} \mathbb{E}[\mu] + \mathbb{E}[\mu^2]. \quad (10.31)$$

然后使用 (10.26) 和 (10.27), 可得到 $q_\mu(\mu)$ 的一阶与二阶矩:

$$\mathbb{E}[\mu] = \bar{x}, \quad \mathbb{E}[\mu^2] = \bar{x}^2 + \frac{1}{N \mathbb{E}[\tau]}. \quad (10.32)$$

我们现在可以将这些矩代入 (10.31), 并解得关于 $\mathbb{E}[\tau]$ 的表达式:

$$\begin{aligned} \frac{1}{\mathbb{E}[\tau]} &= \frac{1}{N-1} (\overline{x^2} - \bar{x}^2) \\ &= \frac{1}{N-1} \sum_{n=1}^N (x_n - \bar{x})^2. \end{aligned} \quad (10.33)$$




图 10.4 对单变量高斯分布的均值 μ 和精度 τ 进行变分推断的示意图。真实后验分布 $p(\mu, \tau | D)$ 的等高线以绿色表示。(a) 初始的因子化近似 $q_\mu(\mu)q_\tau(\tau)$ 的等高线以蓝色表示。(b) 重新估计因子 $q_\mu(\mu)$ 之后的结果。(c) 重新估计因子 $q_\tau(\tau)$ 之后的结果。(d) 迭代过程最终收敛到的最优因子化近似，其等高线以红色表示。

我们识别出右侧即为单变量高斯分布方差的常见无偏估计。因此可见，使用贝叶斯方法避免了最大似然解的偏差。

10.1.4 模型比较

除了对隐藏变量 $\mathbf{Z}$ 进行推断之外，我们还可能希望比较一组候选模型，这些模型用索引 m 标记，并具有先验概率 $p(m)$ 。我们的目标是对观测数据 $\mathbf{X}$ 给出的后验概率 $p(m | \mathbf{X})$ 进行近似。这比前面讨论的情况稍微复杂一些，因为不同模型可能具有不同的结构，并且隐藏变量 $\mathbf{Z}$ 的维度也可能不同。因此我们不能简单地考虑一个因子化近似 $q(\mathbf{Z})q(m)$ ，而必须意识到 $\mathbf{Z}$ 的后验必须以 m 为条件，因此应考虑 $q(\mathbf{Z}, m) = q(\mathbf{Z} | m)q(m)$ 。基于此变分分布，我们可以直接验证如下分解：

$$\ln p(\mathbf{X}) = \mathcal{L}_m - \sum_m \sum_{\mathbf{Z}} q(\mathbf{Z} | m)q(m) \ln \left\{ \frac{p(\mathbf{Z}, m | \mathbf{X})}{q(\mathbf{Z} | m)q(m)} \right\}, \quad (10.34)$$

其中 $\mathcal{L}_m$ 是对 $\ln p(\mathbf{X})$ 的下界，其形式为

$$\mathcal{L}_m = \sum_m \sum_{\mathbf{Z}} q(\mathbf{Z} | m)q(m) \ln \left\{ \frac{p(\mathbf{Z}, \mathbf{X}, m)}{q(\mathbf{Z} | m)q(m)} \right\}. \quad (10.35)$$

这里我们假设 $\mathbf{Z}$ 是离散变量，但如果是连续变量，同样的分析依然成立，只需将求和替换为积分即可。我们可以通过拉格朗日乘子对 $q(m)$ 最大化 $\mathcal{L}_m$ ，结果为

$$q(m) \propto p(m) \exp\{\mathcal{L}_m\}. \quad (10.36)$$

然而, 如果我们对 $q(\mathbf{Z} | m)$ 最大化 $\mathcal{L}_m$, 会发现不同的 m 的解是耦合的, 这是符合预期的, 因为它们都是以 m 为条件的。我们因此采取另一种方式: 先分别对每个 $q(\mathbf{Z} | m)$ 优化 (10.35), 随后再用 (10.36) 来确定 $q(m)$ 。在归一化之后, 所得的 $q(m)$ 便可以以通常的方式用于模型选择或模型平均。

10.2 高斯混合的变分推断

我们现在回到对高斯混合模型的讨论, 并应用上一节中发展的变分推断机制。这将很好地展示变分方法的应用, 同时也会说明贝叶斯处理如何优雅地解决与最大似然方法相关的许多困难 (Attias, 1999b)。强烈建议读者详细推导这个例子, 因为它能对变分方法的实际使用提供许多洞见。许多更复杂分布形式的贝叶斯模型, 都可以通过对这里分析的直接扩展或推广而求解。

我们的起点是高斯混合模型的似然函数, 如图 9.6 的图模型所示。对每个观测 $\mathbf{x}_n$, 我们有一个对应的隐藏变量 $\mathbf{z}_n$, 它是一个 1-of- K 的二元向量, 其元素为 z_{nk} , 其中 $k = 1, \dots, K$ 。像以前一样, 我们用 $\mathbf{X} = \{\mathbf{x}_1, \dots, \mathbf{x}_N\}$ 表示观测数据集, 用 $\mathbf{Z} = \{\mathbf{z}_1, \dots, \mathbf{z}_N\}$ 表示隐藏变量。由 (9.10) 可写出给定混合系数 π 的条件分布为

$$p(\mathbf{Z} | \pi) = \prod_{n=1}^N \prod_{k=1}^K \pi_k^{z_{nk}}. \quad (10.37)$$

类似地, 由 (9.11), 给定隐藏变量和各分量参数时观测数据向量的条件分布为

$$p(\mathbf{X} | \mathbf{Z}, \boldsymbol{\mu}, \boldsymbol{\Lambda}) = \prod_{n=1}^N \prod_{k=1}^K \mathcal{N}(\mathbf{x}_n | \boldsymbol{\mu}_k, \boldsymbol{\Lambda}_k^{-1})^{z_{nk}}, \quad (10.38)$$

其中 $\boldsymbol{\mu} = \{\boldsymbol{\mu}_k\}$, $\boldsymbol{\Lambda} = \{\boldsymbol{\Lambda}_k\}$ 。注意我们使用精度矩阵而不是协方差矩阵, 因为这样在数学上更为便利。

接下来我们为参数 $\boldsymbol{\mu}, \boldsymbol{\Lambda}$ 和 $\boldsymbol{\pi}$ 引入先验分布。若选择共轭先验, 分析将大大简化。因此我们为混合系数 $\boldsymbol{\pi}$ 选择一个 Dirichlet 分布:

$$p(\boldsymbol{\pi}) = \text{Dir}(\boldsymbol{\pi} | \alpha_0) = C(\alpha_0) \prod_{k=1}^K \pi_k^{\alpha_0 - 1}, \quad (10.39)$$

其中由于对称性, 每个分量都使用相同的参数 α_0 , 而 $C(\alpha_0)$ 是由 (B.23) 定义的 Dirichlet 分布的归一化常数。如前所述, 参数 α_0 可以看作与混合中每个分量相关的有效先验样本数。如果 α_0 很小, 则后验分布主要受数据影响。


类似地, 我们引入独立的 Gaussian-Wishart 先验来控制每个高斯分量的均值和精度:

$$p(\boldsymbol{\mu}, \boldsymbol{\Lambda}) = p(\boldsymbol{\mu} | \boldsymbol{\Lambda}) p(\boldsymbol{\Lambda}) = \prod_{k=1}^K \mathcal{N}(\boldsymbol{\mu}_k | \mathbf{m}_0, (\beta_0 \boldsymbol{\Lambda}_k)^{-1}) \mathcal{W}(\boldsymbol{\Lambda}_k | \mathbf{W}_0, \nu_0), \quad (10.40)$$

因为当均值和精度均未知时, 这就是共轭先验分布。通常我们会因为对称性选取 $\mathbf{m}_0 = \mathbf{0}$ 。

该模型可以表示为图 10.5 中所示的有向图。注意存在从 $\boldsymbol{\Lambda}$ 指向 $\boldsymbol{\mu}$ 的连线, 因为在 (10.40) 中, $\boldsymbol{\mu}$ 的分布方差是 $\boldsymbol{\Lambda}$ 的函数。

图 10.5 表示贝叶斯高斯混合模型的有向无环图，其中方框 (plate) π 表示一组 N 个 i.i.d. 观测。这里 μ 表示 $\{\mu_k\}$ ，而 Λ 表示 $\{\Lambda_k\}$ 。



这个例子很好地说明了隐藏变量与参数之间的区别。像 $\mathbf{z}_n$ 这类出现在 plate 内的变量被视为隐藏变量，因为它们的数量会随着数据集大小增长。相反，像 μ 这类出现在 plate 外的变量，其数量不随数据集大小而变化，因此被视为参数。然而，从图模型的角度看，两者之间并无根本差别。

10.2.1 变分分布

为了对该模型进行变分处理，我们首先写出所有随机变量的联合分布，其形式为

$$p(\mathbf{X}, \mathbf{Z}, \boldsymbol{\pi}, \boldsymbol{\mu}, \boldsymbol{\Lambda}) = p(\mathbf{X} | \mathbf{Z}, \boldsymbol{\mu}, \boldsymbol{\Lambda}) p(\mathbf{Z} | \boldsymbol{\pi}) p(\boldsymbol{\pi}) p(\boldsymbol{\mu} | \boldsymbol{\Lambda}) p(\boldsymbol{\Lambda}). \quad (10.41)$$

上述各项的定义已在前面给出。读者可以验证，这一分解确实对应图 10.5 所示的概率图模型。注意只有变量 $\mathbf{X} = \{\mathbf{x}_1, \dots, \mathbf{x}_N\}$ 被观测到。

现在我们考虑一个在隐藏变量与参数之间因式分解的变分分布：

$$q(\mathbf{Z}, \boldsymbol{\pi}, \boldsymbol{\mu}, \boldsymbol{\Lambda}) = q(\mathbf{Z}) q(\boldsymbol{\pi}, \boldsymbol{\mu}, \boldsymbol{\Lambda}). \quad (10.42)$$

令人惊讶的是，这就是我们需要做出的唯一假设，即可得到对贝叶斯混合模型的一个可处理且实用的解。特别地， $q(\mathbf{Z})$ 与 $q(\boldsymbol{\pi}, \boldsymbol{\mu}, \boldsymbol{\Lambda})$ 的函数形式都会通过优化变分分布自动得到。注意我们省略了 q 分布的下标，类似于在 (10.41) 中对 p 分布的处理，并依靠自变量来区分不同的分布。

这些因子的顺序更新方程可以直接利用一般结果 (10.9) 推导。我们先推导因子 $q(\mathbf{Z})$ 的更新方程。优化后该因子的对数为

$$\ln q^*(\mathbf{Z}) = \mathbb{E}_{\boldsymbol{\pi}, \boldsymbol{\mu}, \boldsymbol{\Lambda}} [\ln p(\mathbf{X}, \mathbf{Z}, \boldsymbol{\pi}, \boldsymbol{\mu}, \boldsymbol{\Lambda})] + \text{const}. \quad (10.43)$$

我们使用分解式 (10.41)。由于我们只关心右侧中依赖于 $\mathbf{Z}$ 的部分，所有独立于 $\mathbf{Z}$ 的项都可以吸收入加法常数中，因此得到

$$\ln q^*(\mathbf{Z}) = \mathbb{E}_{\boldsymbol{\pi}} [\ln p(\mathbf{Z} | \boldsymbol{\pi})] + \mathbb{E}_{\boldsymbol{\mu}, \boldsymbol{\Lambda}} [\ln p(\mathbf{X} | \mathbf{Z}, \boldsymbol{\mu}, \boldsymbol{\Lambda})] + \text{const}. \quad (10.44)$$

将右侧两个条件分布代入，并将再次独立于 $\mathbf{Z}$ 的项吸入常数项，得到

$$\ln q^*(\mathbf{Z}) = \sum_{n=1}^N \sum_{k=1}^K z_{nk} \ln \rho_{nk} + \text{const} \quad (10.45)$$

其中

$$\begin{aligned} \ln \rho_{nk} = & \mathbb{E}[\ln \pi_k] + \frac{1}{2} \mathbb{E}[\ln |\boldsymbol{\Lambda}_k|] - \frac{D}{2} \ln(2\pi) \\ & - \frac{1}{2} \mathbb{E}_{\boldsymbol{\mu}_k, \boldsymbol{\Lambda}_k} [(\mathbf{x}_n - \boldsymbol{\mu}_k)^T \boldsymbol{\Lambda}_k (\mathbf{x}_n - \boldsymbol{\mu}_k)], \end{aligned} \quad (10.46)$$

其中 D 是 $\mathbf{x}$ 的维度。对 (10.45) 两侧取指数得到

$$q^*(\mathbf{Z}) \propto \prod_{n=1}^N \prod_{k=1}^K \rho_{nk}^{z_{nk}}. \quad (10.47)$$

由于该分布必须归一化，并且对每个 n ， z_{nk} 为二元变量并在所有 k 上求和为 1，因此最终得到

$$q^*(\mathbf{Z}) = \prod_{n=1}^N \prod_{k=1}^K r_{nk}^{z_{nk}}, \quad (10.48)$$

其中

$$r_{nk} = \frac{\rho_{nk}}{\sum_{j=1}^K \rho_{nj}}. \quad (10.49)$$

可见因子 $q(\mathbf{Z})$ 的最优形式与先验 $p(\mathbf{Z} | \pi)$ 相同。注意由于 ρ_{nk} 是实数指数函数的输出，因此 r_{nk} 非负且在所有 k 上求和为 1，满足概率分布要求。

对于离散分布 $q^*(\mathbf{Z})$ ，我们有标准结果

$$\mathbb{E}[z_{nk}] = r_{nk} \quad (10.50)$$

由此可见， r_{nk} 的作用类似于责任度。注意 $q^*(\mathbf{Z})$ 的最优解依赖于其它变量分布的矩，因此变分更新方程依然是耦合的，必须通过迭代求解。

此时，我们引入三个对观测数据集的统计量，使用责任度加权定义如下：

$$N_k = \sum_{n=1}^N r_{nk} \quad (10.51)$$

$$\bar{\mathbf{x}}_k = \frac{1}{N_k} \sum_{n=1}^N r_{nk} \mathbf{x}_n \quad (10.52)$$

$$\mathbf{S}_k = \frac{1}{N_k} \sum_{n=1}^N r_{nk} (\mathbf{x}_n - \bar{\mathbf{x}}_k) (\mathbf{x}_n - \bar{\mathbf{x}}_k)^T \quad (10.53)$$

这些量与最大似然 EM 算法中出现的量完全类似。

现在考虑变分后验分布中的因子 $q(\boldsymbol{\pi}, \boldsymbol{\mu}, \boldsymbol{\Lambda})$ 。再次利用一般结果 (10.9)，得到

$$\begin{aligned} \ln q^*(\boldsymbol{\pi}, \boldsymbol{\mu}, \boldsymbol{\Lambda}) &= \ln p(\boldsymbol{\pi}) + \sum_{k=1}^K \ln p(\boldsymbol{\mu}_k, \boldsymbol{\Lambda}_k) + \mathbb{E}_{\mathbf{Z}}[\ln p(\mathbf{Z} | \boldsymbol{\pi})] \\ &+ \sum_{k=1}^K \sum_{n=1}^N \mathbb{E}[z_{nk}] \ln \mathcal{N}(\mathbf{x}_n | \boldsymbol{\mu}_k, \boldsymbol{\Lambda}_k^{-1}) + \text{const.} \end{aligned} \quad (10.54)$$

观察右侧可见，它由仅涉及 $\boldsymbol{\pi}$ 的部分和仅涉及 $\boldsymbol{\mu}$ 、 $\boldsymbol{\Lambda}$ 的部分组成，因此变分后验分布因式分解为 $q(\boldsymbol{\pi}, \boldsymbol{\mu}, \boldsymbol{\Lambda}) = q(\boldsymbol{\pi}) q(\boldsymbol{\mu}, \boldsymbol{\Lambda})$ 。进一步地，涉及 $\boldsymbol{\mu}$ 与 $\boldsymbol{\Lambda}$ 的项又在 k 上求和，且每一项只依赖于对应的 $\boldsymbol{\mu}_k$ 与 $\boldsymbol{\Lambda}_k$ ，从而得到进一步的因式分解

$$q(\boldsymbol{\pi}, \boldsymbol{\mu}, \boldsymbol{\Lambda}) = q(\boldsymbol{\pi}) \prod_{k=1}^K q(\boldsymbol{\mu}_k, \boldsymbol{\Lambda}_k). \quad (10.55)$$

观察 (10.54) 中依赖于 π 的项得

$$\ln q^*(\pi) = (\alpha_0 - 1) \sum_{k=1}^K \ln \pi_k + \sum_{k=1}^K \sum_{n=1}^N r_{nk} \ln \pi_k + \text{const} \quad (10.56)$$

其中使用了 (10.50)。对两边取指数，可识别出

$$q^*(\pi) = \text{Dir}(\pi \mid \alpha), \quad (10.57)$$

其中

$$\alpha_k = \alpha_0 + N_k. \quad (10.58)$$

最后，变分后验 $q^*(\mu_k, \Lambda_k)$ 无法进一步分解为边缘分布之积，但我们可以使用乘积法则写成 $q^*(\mu_k, \Lambda_k) = q^*(\mu_k \mid \Lambda_k) q^*(\Lambda_k)$ 。

在 (10.54) 中识别涉及 μ_k 与 Λ_k 的项，可得到预期的高斯-Wishart 分布：

$$q^*(\mu_k, \Lambda_k) = \mathcal{N}(\mu_k \mid \mathbf{m}_k, (\beta_k \Lambda_k)^{-1}) \mathcal{W}(\Lambda_k \mid \mathbf{W}_k, \nu_k), \quad (10.59)$$

其中

$$\beta_k = \beta_0 + N_k \quad (10.60)$$

$$\mathbf{m}_k = \frac{1}{\beta_k} (\beta_0 \mathbf{m}_0 + N_k \bar{\mathbf{x}}_k) \quad (10.61)$$

$$\mathbf{W}_k^{-1} = \mathbf{W}_0^{-1} + N_k \mathbf{S}_k + \frac{\beta_0 N_k}{\beta_0 + N_k} (\bar{\mathbf{x}}_k - \mathbf{m}_0) (\bar{\mathbf{x}}_k - \mathbf{m}_0)^T \quad (10.62)$$

$$\nu_k = \nu_0 + N_k \quad (10.63)$$

这些更新方程与用于最大似然高斯混合模型的 EM 算法中的 M 步完全类比。我们看到：更新模型参数的变分后验分布所需的计算涉及对整个数据集求和，而这种求和与最大似然处理中的计算相同。

为了执行这个变分版的 M 步，我们需要期望值 $\mathbb{E}[z_{nk}] = r_{nk}$ ，即责任度。这些通过对 (10.46) 中给出的 ρ_{nk} 进行归一化得到。可以看到，该表达式包含对参数的变分分布取期望，而这些期望可以直接计算，得到

$$\mathbb{E}_{\mu_k, \Lambda_k} [(\mathbf{x}_n - \mu_k)^T \Lambda_k (\mathbf{x}_n - \mu_k)] = D \beta_k^{-1} + \nu_k (\mathbf{x}_n - \mathbf{m}_k)^T \mathbf{W}_k (\mathbf{x}_n - \mathbf{m}_k) \quad (10.64)$$

$$\ln \tilde{\Lambda}_k \equiv \mathbb{E}[\ln |\Lambda_k|] = \sum_{i=1}^D \psi\left(\frac{\nu_k + 1 - i}{2}\right) + D \ln 2 + \ln |\mathbf{W}_k| \quad (10.65)$$

$$\ln \tilde{\pi}_k \equiv \mathbb{E}[\ln \pi_k] = \psi(\alpha_k) - \psi(\hat{\alpha}) \quad (10.66)$$

这里我们引入了 $\tilde{\Lambda}_k$ 和 $\tilde{\pi}_k$ 的定义， $\psi(\cdot)$ 是所定义的 digamma 函数，而 $\hat{\alpha} = \sum_k \alpha_k$ 。结果 (10.65) 和 (10.66) 来自 Wishart 与 Dirichlet 分布的标准性质。

将 (10.64)、(10.65) 和 (10.66) 代入 (10.46)，并使用 (10.49)，可以得到责任度的表达式

$$r_{nk} \propto \tilde{\pi}_k \tilde{\Lambda}_k^{1/2} \exp\left\{-\frac{D}{2\beta_k} - \frac{\nu_k}{2} (\mathbf{x}_n - \mathbf{m}_k)^T \mathbf{W}_k (\mathbf{x}_n - \mathbf{m}_k)\right\} \quad (10.67)$$

可注意该结果与最大似然 EM 的责任度公式相似，后者由 (9.13) 可写为

$$r_{nk} \propto \pi_k |\Lambda_k|^{1/2} \exp \left\{ -\frac{1}{2} (\mathbf{x}_n - \boldsymbol{\mu}_k)^T \Lambda_k (\mathbf{x}_n - \boldsymbol{\mu}_k) \right\} \quad (10.68)$$

其中使用精度矩阵代替协方差以突出其与 (10.67) 的对应关系。

因此，变分后验分布的优化过程在形式上与最大似然 EM 算法的 E 步和 M 步完全类似。在变分版 E 步中，我们使用当前参数分布计算 (10.64)、(10.65)、(10.66) 中的期望，从而得到 $\mathbb{E}[z_{nk}] = r_{nk}$ 。然后在随后的变分版 M 步中，保持这些责任度不变，并利用它们通过 (10.57) 和 (10.59) 重新计算参数的变分分布。可以看到，变分后验分布总是具有与联合分布 (10.41) 中对应因子的相同函数形式。这是使用共轭分布的一个普遍特性。

图 10.6 将 $K = 6$ 的变分贝叶斯高斯混合模型应用于 Old Faithful 数据集的结果示意图，其中椭圆表示各个分量的一标准差密度等高线，而每个椭圆内部红色墨水的密度对应于该分量混合系数的均值。每幅图左上角的数字表示变分推断的迭代次数。期望混合系数在数值上与零不可区分的分量未被绘制。




图 10.6 展示了将这一方法应用于重缩放后的 Old Faithful 数据集、并采用 $K = 6$ 的高斯混合模型时的结果。我们看到在收敛后，只有两个混合系数的期望值明显偏离其先验值。这个现象可以从贝叶斯模型中数据拟合与模型复杂度之间的自动折中角度进行解释，其中复杂度惩罚来自那些其参数被推离先验值的成分。对数据点几乎不承担解释责任的成分具有 $r_{nk} \simeq 0$ ，因此 $N_k \simeq 0$ 。由 (10.58) 可见 $\alpha_k \simeq \alpha_0$ ，由 (10.60)-(10.63) 可见其他参数也回到先验值。原则上这些成分会被数据稍微影响，但如果先验足够宽，其影响小到无法在数值上看到。

对于变分高斯混合模型，后验分布中混合系数的期望为

$$\mathbb{E}[\pi_k] = \frac{\alpha_k + N_k}{K\alpha_0 + N}. \quad (10.69)$$

考虑一个满足 $N_k \simeq 0$ 且 $\alpha_k \simeq \alpha_0$ 的成分。如果先验很宽，即 $\alpha_0 \rightarrow 0$ ，则 $\mathbb{E}[\pi_k] \rightarrow 0$ ，该成分在模型中不发挥作用；如果先验对混合系数施加强约束，即 $\alpha_0 \rightarrow \infty$ ，则 $\mathbb{E}[\pi_k] \rightarrow 1/K$ 。

在图 10.6 中，混合系数的先验为 Dirichlet 分布 (10.39)。回忆图 2.5 可知当 $\alpha_0 < 1$ 时，先验偏好某些混合系数为零的稀疏解。图 10.6 使用 $\alpha_0 = 10^{-3}$ 得到，因此最终只有两个成分具有非零混合系数。如果改用 $\alpha_0 = 1$ ，则有三个成分的混合系数为非零；若使用 $\alpha_0 = 10$ ，则六个成分全部具有非零混合系数。

正如我们所看到的，在高斯混合模型的贝叶斯变分解与最大似然 EM 算法之间存在紧密的相似性。事实上，如果考虑极限 $N \rightarrow \infty$ ，那么贝叶斯处理会收敛到最大似然 EM 算法。对于不是非常小的数据集来说，高斯混合的变分算法的主要计算开销来自对责任度的计算，以及对加权数据协方差矩阵的计算与求逆。这些计算与最大似然 EM 算法中出现的计算完全对应，因此相较于传统的最大似然方法，采用这种贝叶斯方法几乎不会带来额外的计算开销。

然而，它却带来了一些重要优势。首先，在最大似然方法中，当某个高斯分量“塌陷”到某个具体数据点时会出现奇异性，而在贝叶斯处理中这种奇异性是不存在的。实际上，只要引入先验并使用 MAP 估计替代最大似然，这些奇异性就会消失。此外，当我们在混合模型中选择较大的分量数 K 时，不会出现过拟合，正如我们在图 10.6 中看到的那样。最后，变分处理还开启了在无需借助交叉验证等技术的情况下确定混合模型最优分量数的可能性。

10.2.2 变分下界

对于该模型，我们也可以直接计算下界 (10.3)。在实际应用中，能在重估过程中监控这个下界非常有用，因为可以用它来判断算法是否收敛。同时，它也能对求解表达式以及其软件实现提供有价值的检验，因为在迭代重估的每一步，这个下界的值都不应下降。我们还可以更进一步，利用有限差分来检查每一次更新确实在给定约束下最大化了该下界，从而更深入地验证重估方程推导及其实现的正确性 (Svensén and Bishop, 2004)。

对于高斯混合的变分形式，下界 (10.3) 为

$$\begin{aligned}
 \mathcal{L} &= \sum_{\mathbf{Z}} \iiint q(\mathbf{Z}, \boldsymbol{\pi}, \boldsymbol{\mu}, \boldsymbol{\Lambda}) \ln \left\{ \frac{p(\mathbf{X}, \mathbf{Z}, \boldsymbol{\pi}, \boldsymbol{\mu}, \boldsymbol{\Lambda})}{q(\mathbf{Z}, \boldsymbol{\pi}, \boldsymbol{\mu}, \boldsymbol{\Lambda})} \right\} d\boldsymbol{\pi} d\boldsymbol{\mu} d\boldsymbol{\Lambda} \\
 &= \mathbb{E}[\ln p(\mathbf{X}, \mathbf{Z}, \boldsymbol{\pi}, \boldsymbol{\mu}, \boldsymbol{\Lambda})] - \mathbb{E}[\ln q(\mathbf{Z}, \boldsymbol{\pi}, \boldsymbol{\mu}, \boldsymbol{\Lambda})] \\
 &= \mathbb{E}[\ln p(\mathbf{X} \mid \mathbf{Z}, \boldsymbol{\mu}, \boldsymbol{\Lambda})] + \mathbb{E}[\ln p(\mathbf{Z} \mid \boldsymbol{\pi})] + \mathbb{E}[\ln p(\boldsymbol{\pi})] + \mathbb{E}[\ln p(\boldsymbol{\mu}, \boldsymbol{\Lambda})] \\
 &\quad - \mathbb{E}[\ln q(\mathbf{Z})] - \mathbb{E}[\ln q(\boldsymbol{\pi})] - \mathbb{E}[\ln q(\boldsymbol{\mu}, \boldsymbol{\Lambda})]
 \end{aligned} \tag{10.70}$$

为了使记号简洁，我们在 q 分布上省略了星号上标，也省略了期望符号上的下标，因为每个期望都是对其参数中的所有随机变量取的。

下界中的各个项都可以很容易地计算，得到如下结果：

$$\mathbb{E}[\ln p(\mathbf{X} | \mathbf{Z}, \boldsymbol{\mu}, \boldsymbol{\Lambda})] = \frac{1}{2} \sum_{k=1}^K N_k \left\{ \ln \tilde{\Lambda}_k - D \beta_k^{-1} - \nu_k \text{Tr}(\mathbf{S}_k \mathbf{W}_k) - \nu_k (\bar{\mathbf{x}}_k - \mathbf{m}_k)^T \mathbf{W}_k (\bar{\mathbf{x}}_k - \mathbf{m}_k) - D \ln(2\pi) \right\} \quad (10.71)$$

$$\mathbb{E}[\ln p(\mathbf{Z} | \boldsymbol{\pi})] = \sum_{n=1}^N \sum_{k=1}^K r_{nk} \ln \tilde{\pi}_k \quad (10.72)$$

$$\mathbb{E}[\ln p(\boldsymbol{\pi})] = \ln C(\boldsymbol{\alpha}_0) + (\alpha_0 - 1) \sum_{k=1}^K \ln \tilde{\pi}_k \quad (10.73)$$

$$\begin{aligned} \mathbb{E}[\ln p(\boldsymbol{\mu}, \boldsymbol{\Lambda})] &= \frac{1}{2} \sum_{k=1}^K \left\{ D \ln(\beta_0/2\pi) + \ln \tilde{\Lambda}_k - \frac{D\beta_0}{\beta_k} \right. \\ &\quad \left. - \beta_0 \nu_k (\mathbf{m}_k - \mathbf{m}_0)^T \mathbf{W}_k (\mathbf{m}_k - \mathbf{m}_0) \right\} + K \ln B(\mathbf{W}_0, \nu_0) \\ &\quad + \frac{(\nu_0 - D - 1)}{2} \sum_{k=1}^K \ln \tilde{\Lambda}_k - \frac{1}{2} \sum_{k=1}^K \nu_k \text{Tr}(\mathbf{W}_0^{-1} \mathbf{W}_k) \end{aligned} \quad (10.74)$$

$$\mathbb{E}[\ln q(\mathbf{Z})] = \sum_{n=1}^N \sum_{k=1}^K r_{nk} \ln r_{nk} \quad (10.75)$$

$$\mathbb{E}[\ln q(\boldsymbol{\pi})] = \sum_{k=1}^K (\alpha_k - 1) \ln \tilde{\pi}_k + \ln C(\boldsymbol{\alpha}) \mathbb{E}[\ln q(\boldsymbol{\mu}, \boldsymbol{\Lambda})] \quad (10.76)$$

$$\boldsymbol{\Lambda})] = \sum_{k=1}^K \left\{ \frac{1}{2} \ln \tilde{\Lambda}_k + \frac{D}{2} \ln \left(\frac{\beta_k}{2\pi} \right) - \frac{D}{2} - H[q(\boldsymbol{\Lambda}_k)] \right\} \quad (10.77)$$

其中 D 是 $\mathbf{x}$ 的维度， $H[q(\boldsymbol{\Lambda}_k)]$ 是 Wishart 分布的熵，其形式由 (B.82) 给出，而系数 $C(\boldsymbol{\alpha})$ 与 $B(\mathbf{W}, \nu)$ 分别由 (B.23) 和 (B.79) 定义。注意，涉及 q 分布对数期望的项，恰好就是这些分布的负熵。在将这些表达式相加得到下界时，可以进行一些化简与合并，但这里我们将它们分开写出以便理解。

最后值得注意的是，下界还提供了一种推导第 10.2.1 节中变分重估方程的替代方法。为此，我们利用以下事实：由于模型采用了共轭先验，变分后验分布中各因子的函数形式是已知的，即对 $\mathbf{Z}$ 为离散分布，对 $\boldsymbol{\pi}$ 为 Dirichlet 分布，对 $(\boldsymbol{\mu}_k, \boldsymbol{\Lambda}_k)$ 为高斯-Wishart 分布。通过为这些分布取一般的参数化形式，我们可以将下界写成这些参数的函数。然后对这些参数最大化该下界，就可以得到所需的重估方程。

10.2.3 预测密度

在贝叶斯高斯混合模型的应用中，我们通常会对观测变量的新取值 $\hat{\mathbf{x}}$ 的预测密度感兴趣。与这条观测对应的将是相应的潜在变量 $\hat{\mathbf{z}}$ ，预测密度由下式给出：

$$p(\hat{\mathbf{x}} | \mathbf{X}) = \sum_{\hat{\mathbf{z}}} \iiint p(\hat{\mathbf{x}} | \hat{\mathbf{z}}, \boldsymbol{\mu}, \boldsymbol{\Lambda}) p(\hat{\mathbf{z}} | \boldsymbol{\pi}) p(\boldsymbol{\pi}, \boldsymbol{\mu}, \boldsymbol{\Lambda} | \mathbf{X}) d\boldsymbol{\pi} d\boldsymbol{\mu} d\boldsymbol{\Lambda} \quad (10.78)$$

其中 $p(\boldsymbol{\pi}, \boldsymbol{\mu}, \boldsymbol{\Lambda} \mid \mathbf{X})$ 是参数的（未知）真实后验分布。利用 (10.37) 与 (10.38)，我们可以首先对 $\hat{\mathbf{z}}$ 求和，从而得到

$$p(\hat{\mathbf{x}} \mid \mathbf{X}) = \sum_{k=1}^K \iiint \pi_k \mathcal{N}(\hat{\mathbf{x}} \mid \boldsymbol{\mu}_k, \boldsymbol{\Lambda}_k^{-1}) p(\boldsymbol{\pi}, \boldsymbol{\mu}, \boldsymbol{\Lambda} \mid \mathbf{X}) d\boldsymbol{\pi} d\boldsymbol{\mu} d\boldsymbol{\Lambda}. \quad (10.79)$$

由于剩余的积分不可 tractable，我们采用变分近似，将真实后验 $p(\boldsymbol{\pi}, \boldsymbol{\mu}, \boldsymbol{\Lambda} \mid \mathbf{X})$ 用其变分近似 $q(\boldsymbol{\pi})q(\boldsymbol{\mu}, \boldsymbol{\Lambda})$ 替换，得到

$$p(\hat{\mathbf{x}} \mid \mathbf{X}) = \sum_{k=1}^K \iiint \pi_k \mathcal{N}(\hat{\mathbf{x}} \mid \boldsymbol{\mu}_k, \boldsymbol{\Lambda}_k^{-1}) q(\boldsymbol{\pi}) q(\boldsymbol{\mu}_k, \boldsymbol{\Lambda}_k) d\boldsymbol{\pi} d\boldsymbol{\mu}_k d\boldsymbol{\Lambda}_k. \quad (10.80)$$

这里我们使用了分解式 (10.55)，并且在每一项中隐式地将所有 $j \neq k$ 的变量 $\{\boldsymbol{\mu}_j, \boldsymbol{\Lambda}_j\}$ 积分掉。此时剩余的积分都可解析求解，最终得到一个 Student's t 分布的混合形式：

$$p(\hat{\mathbf{x}} \mid \mathbf{X}) = \frac{1}{\alpha} \sum_{k=1}^K \alpha_k \text{St}(\hat{\mathbf{x}} \mid \mathbf{m}_k, \mathbf{L}_k, \nu_k + 1 - D), \quad (10.81)$$

其中第 k 个分量的均值为 $\mathbf{m}_k$ ，精度矩阵为

$$\mathbf{L}_k = \frac{(\nu_k + 1 - D) \beta_k}{1 + \beta_k} \mathbf{W}_k, \quad (10.82)$$

其中 ν_k 由 (10.63) 给出。当数据集规模 N 足够大时，预测分布 (10.81) 会趋近于一个高斯混合分布。


10.2.4 确定组件数量

我们已经看到，变分下界可以用于确定混合模型中组件数量 K 的后验分布。然而，这里有一个必须处理的微妙问题。对一个高斯混合模型的任意参数设置（除非是某些特定的退化情况），总存在其他参数设置，它们在观测变量上的概率密度完全相同。这些参数仅仅通过对组件的重新标号而不同。举例来说，考虑一个由两个高斯组成、只有一个观测变量 x 的混合模型，其参数取值为 $\pi_1 = a, \pi_2 = b, \mu_1 = c, \mu_2 = d, \sigma_1 = e, \sigma_2 = f$ 。那么另一组参数 $\pi_1 = b, \pi_2 = a, \mu_1 = d, \mu_2 = c, \sigma_1 = f, \sigma_2 = e$ 只是交换了两个组件，按对称性将给出相同的 $p(x)$ 。如果一个混合模型有 K 个组件，那么每个参数设置都对应着一个 $K!$ 个等价设置的家族。

在最大似然的语境下，这种冗余并不重要，因为参数优化算法（如 EM）将根据初始化找到某一个具体解，而其他等价解不会被考虑。但在贝叶斯推断中，我们会对所有可能的参数进行积分。我们在图 10.2 中已经看到，如果真实后验是多峰的，基于最小化 $\text{KL}(q||p)$ 的变分推断会倾向于逼近其中一个峰附近的分布而忽略其它峰。若模型的组件数 K 固定，这并不会影响预测，因为等价的多个模式给出相同的预测密度。然而，如果我们想比较不同的 K ，就必须考虑这种多模态性。一个简单的近似方法是：在用于模型比较的下界中加上一项 $\ln K!$ 。

图 10.7 展示了包含这一多模态校正项后的下界随组件数 K 变化的曲线（Old Faithful 数据集）。值得再次强调的是，最大似然会随 K 的增加而使似然值单调上升（假设

图 10.7 针对 Old Faithful 数据集，绘制变分下界 $\mathcal{L}$ 随高斯混合模型分量数 K 变化的曲线，显示在 $K = 2$ 个分量处存在一个明显的峰值。对于每一个 K 值，模型均从 100 个不同的随机初始点进行训练，结果以带有轻微随机水平扰动的“+”符号表示，以便彼此区分。需要注意的是，部分解会落在次优的局部极大值处，但这种情况发生得并不频繁。



避免了奇异解并忽略局部极值)，因此不能用于选择合适的模型复杂度；而贝叶斯推断会自动在模型复杂度与数据拟合之间做权衡。

这种确定 K 的方法需要训练一系列不同 K 的模型并相互比较。另一种方法是将混合系数 π 视为参数，通过最大化下界（Corduneanu 和 Bishop, 2001）来求点估计，而不是在完全贝叶斯方法中保持一个对它们的分布。由此得到的重估式为

$$\pi_k = \frac{1}{N} \sum_{n=1}^N r_{nk} \quad (10.83)$$

并且该最大化与其他参数的变分 q 分布的更新交替进行。在优化过程中，那些对解释数据贡献不足的组件的混合系数会被压缩至零，从而通过自动相关性确定机制被有效移除。因此，我们可以在一次训练中从较大的初始 K 开始，让多余的组件自动被删减掉。在超参数优化中产生稀疏性的机理，在相关向量机的讨论中有详细分析。

10.2.5 诱导因子分解

在推导高斯混合模型的变分更新方程时，我们假设了变分后验分布的特定因子分解形式 (10.42)。然而，对应各个因子的最优解本身展现出额外的因子分解结构。特别地， $q^*(\boldsymbol{\mu}, \boldsymbol{\Lambda})$ 的最优形式是对混合模型中每个组件 k 的独立分布 $q^*(\boldsymbol{\mu}_k, \boldsymbol{\Lambda}_k)$ 的乘积；而对潜在变量的变分后验 $q^*(\mathbf{Z})$ （式 (10.48)）则分解成每个观测 n 的独立分布 $q^*(\mathbf{z}_n)$ （注意它并不能进一步对 k 分解，因为对每个 n ， z_{nk} 的取值需满足对 k 求和为 1 的约束）。这些额外的因子分解是由变分分解假设与真实分布的条件独立性质（由图 10.5 的有向图所刻画）共同作用产生的。

我们将这些额外出现的因子分解称为诱导因子分解，因为它们是由变分后验分布的分解假设与真实联合分布的条件独立性质之间的相互作用引起的。在变分方法的数值实现中，考虑这些额外分解是很重要的。例如，如果某个高斯分布的最优形式始终具有对角精度矩阵（对应于关于各变量的因子化），那么维护完整的精度矩阵将是极其低效的。

这种诱导因子分解可以通过一个基于 $\mathbf{d}$ -分离的简单图测试来检测。我们将潜在变量划分为三组两两不交的子集 $\mathbf{A}, \mathbf{B}, \mathbf{C}$ ，并假设我们在变分后验中令 $\mathbf{C}$ 与其它潜在变量

因子化，即

$$q(\mathbf{A}, \mathbf{B}, \mathbf{C}) = q(\mathbf{A}, \mathbf{B}) q(\mathbf{C}). \quad (10.84)$$

利用一般结果 (10.9) 以及概率的乘法规则，我们得到 $q(\mathbf{A}, \mathbf{B})$ 的最优解为

$$\begin{aligned} \ln q^*(\mathbf{A}, \mathbf{B}) &= \mathbb{E}_{\mathbf{C}}[\ln p(\mathbf{X}, \mathbf{A}, \mathbf{B}, \mathbf{C})] + \text{const} \\ &= \mathbb{E}_{\mathbf{C}}[\ln p(\mathbf{A}, \mathbf{B} \mid \mathbf{X}, \mathbf{C})] + \text{const}. \end{aligned} \quad (10.85)$$

现在我们要判断这个最优解是否会进一步在 $\mathbf{A}$ 和 $\mathbf{B}$ 之间因子化，也就是说判断是否有 $q^*(\mathbf{A}, \mathbf{B}) = q^*(\mathbf{A}) q^*(\mathbf{B})$ 。这成立当且仅当 $\ln p(\mathbf{A}, \mathbf{B} \mid \mathbf{X}, \mathbf{C}) = \ln p(\mathbf{A} \mid \mathbf{X}, \mathbf{C}) + \ln p(\mathbf{B} \mid \mathbf{X}, \mathbf{C})$ ，即条件独立关系

$$\mathbf{A} \perp\!\!\!\perp \mathbf{B} \mid \mathbf{X}, \mathbf{C} \quad (10.86)$$

成立。为了判断该关系是否成立，可使用 d- 分离准则。

为说明这一点，再次考虑图 10.5 中的贝叶斯高斯混合模型，并假设变分分解为式 (10.42)。我们可以立刻看出参数 π 与其他参数 μ 和 Λ 的变分后验必然因子化，因为连接 π 与 μ 或 Λ 的任何路径都必须经过某个 $\mathbf{z}_n$ ，而这些节点都属于条件集合，并且在这些路径上均为“头-尾”结构，因此它们阻断了这些路径。

10.3 变分线性回归

作为变分推断的第二个示例，我们回到第 3.3 节中的贝叶斯线性回归模型。在证据框架中，我们通过最大化对数边缘似然来对 α 和 β 的积分进行点估计逼近。完全贝叶斯的方法会对超参数以及参数进行积分。尽管精确积分是不可行的，我们可以使用变分方法找到一个可处理的近似。为了简化讨论，我们将假设噪声精度参数 β 是已知的，并固定在其真实值上，虽然该框架可以轻松扩展以包含对 β 的分布。对于线性回归模型，变分处理将等价于证据框架。然而，它为使用变分方法提供了一个很好的练习，并且也为第 10.6 节中的贝叶斯逻辑回归的变分处理奠定基础。

回忆 $\mathbf{w}$ 的似然函数和先验为

$$p(\mathbf{t} \mid \mathbf{w}) = \prod_{n=1}^N \mathcal{N}(t_n \mid \mathbf{w}^T \phi_n, \beta^{-1}) \quad (10.87)$$

$$p(\mathbf{w} \mid \alpha) = \mathcal{N}(\mathbf{w} \mid \mathbf{0}, \alpha^{-1} \mathbf{I}) \quad (10.88)$$

其中 $\phi_n = \phi(\mathbf{x}_n)$ 。我们现在在 α 上引入一个先验分布。根据第 2.3.6 节的讨论，我们知道高斯精度的共轭先验是 gamma 分布，因此我们选择


$$p(\alpha) = \text{Gam}(\alpha \mid a_0, b_0) \quad (10.89)$$

其中 $\text{Gam}(\cdot, \cdot)$ 的定义见式 (B.26)。因此，所有变量的联合分布为

$$p(\mathbf{t}, \mathbf{w}, \alpha) = p(\mathbf{t} \mid \mathbf{w}) p(\mathbf{w} \mid \alpha) p(\alpha) \quad (10.90)$$

其可以表示为图 10.8 所示的有向图模型。

图 10.8 表示贝叶斯线性回归模型中联合分布 (10.90) 的概率图模型。



10.3.1 变分分布

我们的首要目标是找到后验分布 $p(\mathbf{w}, \alpha | \mathbf{t})$ 的一个近似。为此，我们采用第 10.1 节的变分框架，使用如下分解形式的变分后验分布

$$q(\mathbf{w}, \alpha) = q(\mathbf{w}) q(\alpha) \quad (10.91)$$

我们可以利用一般结果 (10.9) 来得到该分布中各因子的重估计方程。回忆，对于每一个因子，我们对所有变量的联合分布取对数，并对该因子之外的变量取期望。首先考虑关于 α 的分布。只保留与 α 函数相关的项，有

$$\begin{aligned} \ln q^*(\alpha) &= \ln p(\alpha) + \mathbb{E}_{\mathbf{w}}[\ln p(\mathbf{w} | \alpha)] + \text{const} \\ &= (a_0 - 1) \ln \alpha - b_0 \alpha + \frac{M}{2} \ln \alpha - \frac{\alpha}{2} \mathbb{E}[\mathbf{w}^T \mathbf{w}] + \text{const}. \end{aligned} \quad (10.92)$$

这可以识别为一个 gamma 分布的对数形式，因此通过匹配 α 和 $\ln \alpha$ 的系数，我们得到

$$q^*(\alpha) = \text{Gam}(\alpha | a_N, b_N) \quad (10.93)$$

其中

$$a_N = a_0 + \frac{M}{2} \quad (10.94)$$

$$b_N = b_0 + \frac{1}{2} \mathbb{E}[\mathbf{w}^T \mathbf{w}]. \quad (10.95)$$

类似地，我们可以找到关于 $\mathbf{w}$ 的后验分布的变分重估计方程。同样使用一般结果 (10.9)，并只保留与 $\mathbf{w}$ 函数相关的项，有

$$\ln q^*(\mathbf{w}) = \ln p(\mathbf{t} | \mathbf{w}) + \mathbb{E}_{\alpha}[\ln p(\mathbf{w} | \alpha)] + \text{const} \quad (10.96)$$

$$= -\frac{\beta}{2} \sum_{n=1}^N \{\mathbf{w}^T \phi_n - t_n\}^2 - \frac{1}{2} \mathbb{E}[\alpha] \mathbf{w}^T \mathbf{w} + \text{const} \quad (10.97)$$

$$= -\frac{1}{2} \mathbf{w}^T (\mathbb{E}[\alpha] \mathbf{I} + \beta \Phi^T \Phi) \mathbf{w} + \beta \mathbf{w}^T \Phi^T \mathbf{t} + \text{const}. \quad (10.98)$$

由于这是一个二次型，因此 $q^*(\mathbf{w})$ 是高斯分布，于是我们可以按通常方式配方，得到其均值和协方差：

$$q^*(\mathbf{w}) = \mathcal{N}(\mathbf{w} | \mathbf{m}_N, \mathbf{S}_N) \quad (10.99)$$

其中

$$\mathbf{m}_N = \beta \mathbf{S}_N \Phi^T \mathbf{t} \quad (10.100)$$

$$\mathbf{S}_N = (\mathbb{E}[\alpha] \mathbf{I} + \beta \Phi^T \Phi)^{-1}. \quad (10.101)$$

注意其与式 (3.52) 中在将 α 当作固定参数时得到的后验分布非常相似。不同之处在于，这里 α 被其在变分分布下的期望值 $\mathbb{E}[\alpha]$ 所取代。事实上，我们在两种情况下都使用相同的符号 $\mathbf{S}_N$ 表示协方差矩阵。

利用标准结果 (B.27)、(B.38) 与 (B.39)，我们可以得到所需的矩如下：

$$\mathbb{E}[\alpha] = a_N/b_N \quad (10.102)$$

$$\mathbb{E}[\mathbf{w}\mathbf{w}^T] = \mathbf{m}_N\mathbf{m}_N^T + \mathbf{S}_N. \quad (10.103)$$

变分后验分布的求解从初始化分布 $q(\mathbf{w})$ 或 $q(\alpha)$ 的某一组参数开始，随后交替重估这两个因子，直到满足适当的收敛条件（通常以稍后讨论的下界为标准）。

将变分解与第 3.5 节中使用证据框架得到的解进行比较是有启发意义的。为此，我们考虑 $a_0 = b_0 = 0$ 的情形，这对应于对 α 的无限宽先验。在此情况下，变分后验分布 $q(\alpha)$ 的均值为

$$\mathbb{E}[\alpha] = \frac{a_N}{b_N} = \frac{M/2}{\mathbb{E}[\mathbf{w}^T\mathbf{w}]/2} = \frac{M}{\mathbf{m}_N^T\mathbf{m}_N + \text{Tr}(\mathbf{S}_N)}. \quad (10.104)$$

与式 (9.63) 对比可以发现，在这个特别简单的模型中，变分方法给出的表达式与使用 EM 最大化证据函数得到的表达式完全一致，只是将对 α 的点估计替换为其期望值。由于分布 $q(\mathbf{w})$ 对 $q(\alpha)$ 的依赖只通过期望值 $\mathbb{E}[\alpha]$ ，我们看到在无限宽先验的情况下，两种方法将给出相同的结果。

10.3.2 预测分布

对于给定新输入 $\mathbf{x}$ 的 t 的预测分布，可以利用参数的高斯变分后验轻松求得：

$$\begin{aligned} p(t | \mathbf{x}, \mathbf{t}) &= \int p(t | \mathbf{x}, \mathbf{w}) p(\mathbf{w} | \mathbf{t}) d\mathbf{w} \\ &\simeq \int p(t | \mathbf{x}, \mathbf{w}) q(\mathbf{w}) d\mathbf{w} \\ &= \int \mathcal{N}(t | \mathbf{w}^T\phi(\mathbf{x}), \beta^{-1}) \mathcal{N}(\mathbf{w} | \mathbf{m}_N, \mathbf{S}_N) d\mathbf{w} \\ &= \mathcal{N}(t | \mathbf{m}_N^T\phi(\mathbf{x}), \sigma^2(\mathbf{x})). \end{aligned} \quad (10.105)$$

其中该积分利用线性-高斯模型的结果 (2.115) 求得。这里输入相关的方差为

$$\sigma^2(\mathbf{x}) = \frac{1}{\beta} + \phi(\mathbf{x})^T \mathbf{S}_N \phi(\mathbf{x}). \quad (10.106)$$

注意其形式与固定 α 时得到的结果 (3.59) 相同，只是现在 $\mathbb{E}[\alpha]$ 出现在 $\mathbf{S}_N$ 的定义中。

10.3.3 下界

另一个重要量是如下定义的下界 $\mathcal{L}$:

$$\begin{aligned}\mathcal{L}(q) &= \mathbb{E}[\ln p(\mathbf{w}, \alpha, \mathbf{t})] - \mathbb{E}[\ln q(\mathbf{w}, \alpha)] \\ &= \mathbb{E}_{\mathbf{w}}[\ln p(\mathbf{t} | \mathbf{w})] + \mathbb{E}_{\mathbf{w}, \alpha}[\ln p(\mathbf{w} | \alpha)] + \mathbb{E}_{\alpha}[\ln p(\alpha)] \\ &\quad - \mathbb{E}_{\mathbf{w}}[\ln q(\mathbf{w})] - \mathbb{E}_{\alpha}[\ln q(\alpha)].\end{aligned}\quad (10.107)$$

利用前几章得到的结果, 各项可直接求得:

$$\begin{aligned}\mathbb{E}[\ln p(\mathbf{t} | \mathbf{w})]_{\mathbf{w}} &= \frac{N}{2} \ln \left(\frac{\beta}{2\pi} \right) - \frac{\beta}{2} \mathbf{t}^T \mathbf{t} + \beta \mathbf{m}_N^T \Phi^T \mathbf{t} \\ &\quad - \frac{\beta}{2} \text{Tr}[\Phi^T \Phi (\mathbf{m}_N \mathbf{m}_N^T + \mathbf{S}_N)],\end{aligned}\quad (10.108)$$

$$\begin{aligned}\mathbb{E}[\ln p(\mathbf{w} | \alpha)]_{\mathbf{w}, \alpha} &= -\frac{M}{2} \ln(2\pi) + \frac{M}{2} (\psi(a_N) - \ln b_N) \\ &\quad - \frac{a_N}{2b_N} [\mathbf{m}_N^T \mathbf{m}_N + \text{Tr}(\mathbf{S}_N)],\end{aligned}\quad (10.109)$$

$$\begin{aligned}\mathbb{E}[\ln p(\alpha)]_{\alpha} &= a_0 \ln b_0 + (a_0 - 1) [\psi(a_N) - \ln b_N] \\ &\quad - b_0 \frac{a_N}{b_N} - \ln \Gamma(a_N),\end{aligned}\quad (10.110)$$

$$-\mathbb{E}[\ln q(\mathbf{w})]_{\mathbf{w}} = \frac{1}{2} \ln |\mathbf{S}_N| + \frac{M}{2} [1 + \ln(2\pi)],\quad (10.111)$$

$$-\mathbb{E}[\ln q(\alpha)]_{\alpha} = \ln \Gamma(a_N) - (a_N - 1) \psi(a_N) - \ln b_N + a_N.\quad (10.112)$$

图 10.9 对于多项式模型, 绘制下界 $\mathcal{L}$ 随多项式阶数 M 变化的曲线, 其中一组包含 10 个数据点的数是由阶数为 $M = 3$ 的多项式在区间 $(-5, 5)$ 上采样并叠加方差为 0.09 的高斯噪声生成的。该下界的数值给出了模型的对数概率, 可以看到下界在 $M = 3$ 处达到峰值, 这对应于生成该数据集的真实模型。




图 10.9 显示了对于一个由三次多项式生成的合成数据集, 当模型多项式阶数变化时, 下界 $\mathcal{L}(q)$ 的变化曲线。这里的先验参数设置为 $a_0 = b_0 = 0$, 对应于无信息先验 $p(\alpha) \propto 1/\alpha$, 它在 $\ln \alpha$ 上是均匀分布, 如 2.3.6 节讨论的那样。正如 10.1 节所示, 量 $\mathcal{L}$ 是模型对数边缘似然 $p(\mathbf{t} | M)$ 的下界。如果我们对不同的 M 指派相同的先验概率 $p(M)$, 那么可以将 $\mathcal{L}$ 视为后验模型概率 $p(M | \mathbf{t})$ 的近似。因此, 变分框架给出最高概率的模型是 $M = 3$ 。这一结果应与最大似然的表现形成对比: 最大似然会随着模型复杂度的增加使残差误差不断减小, 直到残差误差被驱到零, 从而偏好严重过拟合的模型。

10.4 指数族分布

在第 2 章中，我们讨论了指数族分布及其共轭先验的重要作用。本书中的许多模型，其完整数据似然属于指数族。然而，对观测数据的边缘似然通常并非如此。例如，在高斯混合模型中，观测值 $\mathbf{x}_n$ 与对应的隐藏变量 $\mathbf{z}_n$ 的联合分布属于指数族，而 $\mathbf{x}_n$ 的边缘分布是高斯混合，因此不是指数族分布。

到目前为止，我们将模型中的变量区分为观测变量和隐藏变量。现在进一步区分潜在变量（记为 $\mathbf{Z}$ ）和参数（记为 $\boldsymbol{\theta}$ ），其中参数是强度量（其数量不随数据集大小变化），而潜在变量是广延量（数量随数据集规模线性增长）。例如，在高斯混合模型中，指示变量 z_{kn} （表示哪一个分量 k 生成了数据点 $\mathbf{x}_n$ ）是潜在变量，而均值 $\boldsymbol{\mu}_k$ 、精度矩阵 $\boldsymbol{\Lambda}_k$ 和混合系数 π_k 则属于参数。

考虑独立同分布数据的情形。我们记数据为 $\mathbf{X} = \{\mathbf{x}_n\}$ ($n = 1, \dots, N$)，对应的潜在变量为 $\mathbf{Z} = \{\mathbf{z}_n\}$ 。假设观测变量与潜在变量的联合分布属于指数族，其自然参数为 $\boldsymbol{\eta}$ ，即

$$p(\mathbf{X}, \mathbf{Z} | \boldsymbol{\eta}) = \prod_{n=1}^N h(\mathbf{x}_n, \mathbf{z}_n) g(\boldsymbol{\eta}) \exp\{\boldsymbol{\eta}^T \mathbf{u}(\mathbf{x}_n, \mathbf{z}_n)\}. \quad (10.113)$$

我们同时使用 $\boldsymbol{\eta}$ 的共轭先验，其形式为

$$p(\boldsymbol{\eta} | \nu_0, \chi_0) = f(\nu_0, \chi_0) g(\boldsymbol{\eta})^{\nu_0} \exp\{\nu_0 \boldsymbol{\eta}^T \chi_0\}. \quad (10.114)$$

回忆，共轭先验可以解释为有 ν_0 个先验伪样本，其充分统计量向量均取值为 χ_0 。现在考虑一个变分分布，其在潜在变量与参数之间解耦，即 $q(\mathbf{Z}, \boldsymbol{\eta}) = q(\mathbf{Z}) q(\boldsymbol{\eta})$ 。利用一般结果 (10.9)，我们可以分别求得两个因子：

$$\begin{aligned} \ln q^*(\mathbf{Z}) &= \mathbb{E}_{\boldsymbol{\eta}}[\ln p(\mathbf{X}, \mathbf{Z} | \boldsymbol{\eta})] + \text{const} \\ &= \sum_{n=1}^N \{\ln h(\mathbf{x}_n, \mathbf{z}_n) + \mathbb{E}[\boldsymbol{\eta}^T] \mathbf{u}(\mathbf{x}_n, \mathbf{z}_n)\} + \text{const}. \end{aligned} \quad (10.115)$$

可见，这形式分解为关于 n 的独立项之和，因此 $q^*(\mathbf{Z})$ 关于 n 将进一步因子化 $q^*(\mathbf{Z}) = \prod_n q^*(\mathbf{z}_n)$ 。这是一个诱导因子化的例子。对上式取指数并按指数族的标准形式恢复归一化项得：

$$q^*(\mathbf{z}_n) = h(\mathbf{x}_n, \mathbf{z}_n) g(\mathbb{E}[\boldsymbol{\eta}]) \exp\{\mathbb{E}[\boldsymbol{\eta}^T] \mathbf{u}(\mathbf{x}_n, \mathbf{z}_n)\}. \quad (10.116)$$

类似地，对于参数的变分分布有

$$\ln q^*(\boldsymbol{\eta}) = \ln p(\boldsymbol{\eta} | \nu_0, \chi_0) + \mathbb{E}_{\mathbf{Z}}[\ln p(\mathbf{X}, \mathbf{Z} | \boldsymbol{\eta})] + \text{const} \quad (10.117)$$

$$= \nu_0 \ln g(\boldsymbol{\eta}) + \boldsymbol{\eta}^T \chi_0 + \sum_{n=1}^N \{\ln g(\boldsymbol{\eta}) + \boldsymbol{\eta}^T \mathbb{E}_{\mathbf{z}_n}[\mathbf{u}(\mathbf{x}_n, \mathbf{z}_n)]\} + \text{const}. \quad (10.118)$$

同样对两边取指数，并按指数族形式恢复归一化项得

$$q^*(\boldsymbol{\eta}) = f(\nu_N, \chi_N) g(\boldsymbol{\eta})^{\nu_N} \exp\{\boldsymbol{\eta}^T \chi_N\}, \quad (10.119)$$

其中

$$\nu_N = \nu_0 + N, \quad (10.120)$$

$$\chi_N = \chi_0 + \sum_{n=1}^N \mathbb{E}_{\mathbf{z}_n} [\mathbf{u}(\mathbf{x}_n, \mathbf{z}_n)]. \quad (10.121)$$

注意 $q^*(\mathbf{z}_n)$ 与 $q^*(\boldsymbol{\eta})$ 是耦合的，因此需要以两阶段迭代方式求解。在变分 E 步中，我们利用当前的潜在变量后验 $q(\mathbf{z}_n)$ 来计算期望充分统计量 $\mathbb{E}[\mathbf{u}(\mathbf{x}_n, \mathbf{z}_n)]$ ，并据此更新参数的后验分布 $q(\boldsymbol{\eta})$ 。随后在变分 M 步中，我们利用更新后的参数后验来计算期望自然参数 $\mathbb{E}[\boldsymbol{\eta}^\top]$ ，从而获得更新后的潜在变量变分分布。

10.4.1 变分消息传递

我们之前通过一个具体模型——贝叶斯高斯混合模型——详细说明了变分方法的应用。该模型可以由图 10.5 所示的有向图描述。现在我们更一般地讨论如何将变分方法用于由有向图描述的模型，并推导一些具有广泛适用性的结果。

对于一个有向图，其对应的联合分布可以写成

$$p(\mathbf{x}) = \prod_i p(\mathbf{x}_i \mid \mathbf{pa}_i), \quad (10.122)$$

其中 $\mathbf{x}_i$ 表示与节点 i 对应的变量，而 $\mathbf{pa}_i$ 表示节点 i 的父节点集合。注意， $\mathbf{x}_i$ 可以是潜在变量，也可以属于观测变量集合。现在考虑一个变分近似，其中分布 $q(\mathbf{x})$ 假设按 $\mathbf{x}_i$ 因子化，即

$$q(\mathbf{x}) = \prod_i q_i(\mathbf{x}_i). \quad (10.123)$$

注意，对于观测节点，在变分分布中不会出现 $q(\mathbf{x}_i)$ 这样的因子。将式 (10.122) 代入一般结果 (10.9)，得到

$$\ln q_j^*(\mathbf{x}_j) = \mathbb{E}_{i \neq j} \left[\sum_i \ln p(\mathbf{x}_i \mid \mathbf{pa}_i) \right] + \text{const}. \quad (10.124)$$

右侧任何不依赖于 $\mathbf{x}_j$ 的项都可以吸收入常数项中。实际上，唯一依赖 $\mathbf{x}_j$ 的项是条件分布 $p(\mathbf{x}_j \mid \mathbf{pa}_j)$ ，以及所有在其条件集中包含 $\mathbf{x}_j$ 的其他条件分布。按定义，这些条件分布对应于节点 j 的子节点，因此它们也依赖于子节点的共父节点，也就是除 $\mathbf{x}_j$ 以外的其他父节点。由此可见， $q^*(\mathbf{x}_j)$ 所依赖的所有节点组成了节点 $\mathbf{x}_j$ 的马尔科夫毯（如图 8.26 所示）。因此，变分后验的各因子的更新对应于图中的局部计算。这使得可以构建无需提前指定模型结构的通用变分推断软件（Bishop et al., 2003）。


如果进一步将模型限制为所有条件分布都具有共轭-指数族结构，那么变分更新过程就可以表述为一个局部消息传递算法（Winn and Bishop, 2005）。具体来说，某个节点的分布可以在接收到来自其所有父节点和所有子节点的消息后进行更新。而子节点要向父节点发送消息，则需要先从其共父节点接收到消息。下界评估也可以被简化，因为许多需要的量在消息传递过程中已经被计算过。这种分布式的消息传递形式具有良好的可扩展性，非常适合大型网络。

10.5 局部变分方法

第 10.1 节和第 10.2 节讨论的变分框架可以看作一种“全局”方法，因为它直接寻求对所有随机变量的完整后验分布的近似。另一种“局部”方法则是在模型中针对单个变量或变量组上的函数寻找界。例如，我们可以寻找条件分布 $p(y|x)$ 的一个界，而它本身只是由一个有向图所定义的更大概率模型中的一个因子。引入界的目的当然是为了简化由此得到的分布。这种局部近似可以依次应用于多个变量，直到获得一个可处理的近似；在第 10.6.1 节中，我们将在逻辑回归的背景下给出这种方法的一个实际示例。这里我们主要关注这些界本身的推导。

在讨论 Kullback-Leibler 散度时，我们已经看到对数函数的凸性在全局变分方法构建下界时起到了关键作用。我们把一个（严格）凸函数定义为其任意一条弦都位于函数之上的函数。凸性在局部变分框架中同样起着核心作用。注意，我们的讨论同样适用于凹函数，只不过将“min”和“max”互换，并将下界替换为上界。

图 10.10 在左图中，红色曲线表示函数 $\exp(-x)$ ，蓝色直线表示在 $x = \xi$ 处由式 (10.125) 定义、取 $\xi = 1$ 时的切线。该直线的斜率为 $\lambda = f'(\xi) = -\exp(-\xi)$ 。注意，任何其他切线（例如图中以绿色表示的那些）在 $x = \xi$ 处的 y 值都会更小。右图给出了当 $\xi = 1$ 时，函数 $\lambda\xi - g(\lambda)$ 关于 λ 的对应曲线，其中 $g(\lambda)$ 由式 (10.131) 给出，其最大值对应于 $\lambda = -\exp(-\xi) = -1/e$ 。



让我们从一个简单的例子开始：函数 $f(x) = \exp(-x)$ ，这是 x 的一个凸函数，如图 10.10 左图所示。我们的目标是用更简单的函数来近似 $f(x)$ ，特别是一条关于 x 的线性函数。从图 10.10 中可以看到，如果这条线性函数对应于一条切线，那么它就是 $f(x)$ 的一个下界。我们可以通过在某个特定值（例如 $x = \xi$ ）处做一阶泰勒展开来得到切线 $y(x)$ ：

$$y(x) = f(\xi) + f'(\xi)(x - \xi) \quad (10.125)$$

这样就有 $y(x) \leq f(x)$ ，并且在 $x = \xi$ 时两者相等。对我们的例子 $f(x) = \exp(-x)$ ，切线因此为

$$y(x) = \exp(-\xi) - \exp(-\xi)(x - \xi), \quad (10.126)$$

这是一个由 ξ 参数化的线性函数。为了与后续讨论保持一致，我们定义 $\lambda = -\exp(-\xi)$ ，于是得到

$$y(x, \lambda) = \lambda x - \lambda + \lambda \ln(-\lambda). \quad (10.127)$$

不同的 λ 值对应不同的切线，并且由于所有这些切线都是函数的下界，因此有

$f(x) \geq y(x, \lambda)$ 。因此我们可以将该函数写成

$$f(x) = \max_{\lambda} \{ \lambda x - \lambda + \lambda \ln(-\lambda) \}. \quad (10.128)$$

我们已经成功地用更简单的线性函数 $y(x, \lambda)$ 来近似凸函数 $f(x)$ 。代价是我们引入了一个变分参数 λ ，为了得到最紧的下界，我们必须对 λ 进行优化。




图 10.11 在左图中，红色曲线表示一个凸函数 $f(x)$ ，蓝色直线表示线性函数 λx ，由于对所有 x 都有 $f(x) > \lambda x$ ，因此它是 $f(x)$ 的一个下界。对于给定的斜率 λ ，具有相同斜率的切线的接触点可通过对 x 最小化差值（由绿色虚线表示） $f(x) - \lambda x$ 来找到。这定义了对偶函数 $g(\lambda)$ ，它对应于斜率为 λ 的切线的截距（取负号）。

我们可以用凸对偶的框架（Rockafellar, 1972; Jordan et al., 1999）更一般地表达这种方法。考虑图 10.11 左图所示的凸函数 $f(x)$ 。在该例中，函数 λx 是 $f(x)$ 的一个下界，但它不是具有斜率 λ 的线性函数所能达到的最紧下界，因为最紧的下界由切线给出。设这条切线的方程为 $\lambda x - g(\lambda)$ ，其中（负的）截距 $g(\lambda)$ 显然依赖于切线的斜率 λ 。为了确定这个截距，我们注意到直线必须沿竖直方向移动，使其恰好达到与函数之间的最小竖直距离，如图 10.11 所示。于是

$$\begin{aligned} g(\lambda) &= -\min_x \{ f(x) - \lambda x \} \\ &= \max_x \{ \lambda x - f(x) \}. \end{aligned} \quad (10.129)$$

现在，不是固定 λ 并改变 x ，而是考虑某个给定的 x ，然后调整 λ ，直到切平面（此处是一条切线）在该特定 x 处与函数相切。因为切线在某个 x 的数值在它与函数接触时取得最大，因此有

$$f(x) = \max_{\lambda} \{ \lambda x - g(\lambda) \}. \quad (10.130)$$

可见函数 $f(x)$ 和 $g(\lambda)$ 扮演着对偶的角色，并由 (10.129) 与 (10.130) 关联。

现在将这些对偶关系应用到简单例子 $f(x) = \exp(-x)$ 。由式 (10.129) 可知，使表达式达到最大值的 x 为 $\xi = -\ln(-\lambda)$ ，代回即可得到共轭函数 $g(\lambda)$ ：

$$g(\lambda) = \lambda - \lambda \ln(-\lambda), \quad (10.131)$$

与之前得到的结果一致。函数 $\lambda \xi - g(\lambda)$ 在 $\xi = 1$ 的情形下如图 10.10 右图所示。作为验证，我们可以将式 (10.131) 代入 (10.130)，可得最优 $\lambda = -\exp(-x)$ ，再代回即可恢复原函数 $f(x) = \exp(-x)$ 。

若函数是凹的，可以采用类似的推导得到上界，将“max”换成“min”，于是有

$$f(x) = \min_{\lambda} \{\lambda x - g(\lambda)\}, \quad (10.132)$$

$$g(\lambda) = \min_x \{\lambda x - f(x)\}. \quad (10.133)$$

如果所关心的函数既非凸也非凹，则上述方法不能直接应用。然而，我们可以先寻找可逆变换（作用于函数或自变量），使其变为凸函数；然后计算其共轭函数，再转换回原变量。

一个重要的例子在模式识别中经常出现，即 **logistic sigmoid** 函数：

$$\sigma(x) = \frac{1}{1 + e^{-x}}. \quad (10.134)$$

该函数本身既不是凸的，也不是凹的。然而，如果对其取对数，就得到一个凹函数，通过求二阶导数即可轻松验证。由式 (10.133)，对应的共轭函数为

$$g(\lambda) = \min_x \{\lambda x - f(x)\} = -\lambda \ln \lambda - (1 - \lambda) \ln(1 - \lambda), \quad (10.135)$$

可以识别为一个二元变量的熵函数，其中该变量取值为 1 的概率是 λ 。利用式 (10.132)，我们得到对数 sigmoid 的上界：

$$\ln \sigma(x) \leq \lambda x - g(\lambda), \quad (10.136)$$

取指数后，就得到 sigmoid 本身的上界：

$$\sigma(x) \leq \exp(\lambda x - g(\lambda)), \quad (10.137)$$

如图 10.12 左图对两个不同的 λ 所示。




图 10.12 左图中红色曲线表示由式 (10.134) 定义的逻辑 sigmoid 函数 $\sigma(x)$ ，蓝色曲线给出了指数型上界 (10.137) 的两个示例。右图再次以红色显示逻辑 sigmoid 函数，并以蓝色显示高斯下界 (10.144)。这里参数 $\xi = 2.5$ ，且该下界在 $x = \xi$ 和 $x = -\xi$ 处是精确的，这两个位置由绿色虚线标出。

我们也可以得到一个具有高斯形式的 sigmoid 下界。为此，我们遵循 Jaakkola 和 Jordan (2000)，同时对输入变量及函数本身进行变换。首先对 logistic 函数取对数，并将其改写为

$$\begin{aligned} \ln \sigma(x) &= -\ln(1 + e^{-x}) = -\ln\{e^{-x/2}(e^{x/2} + e^{-x/2})\} \\ &= x/2 - \ln(e^{x/2} + e^{-x/2}). \end{aligned} \quad (10.138)$$

注意，函数 $f(x) = -\ln(e^{x/2} + e^{-x/2})$ 是关于变量 x^2 的凸函数，通过求二阶导数可再次验证。因此，它有一个关于 x^2 的线性下界，其共轭函数为

$$g(\lambda) = \max_{x^2} \{\lambda x^2 - f(\sqrt{x^2})\}. \quad (10.139)$$

驻点条件为

$$0 = \lambda - \frac{dx}{dx^2} \frac{d}{dx} f(x) = \lambda + \frac{1}{4x} \tanh\left(\frac{x}{2}\right). \quad (10.140)$$

如果我们将与该特定 λ 值的切线接触点相对应的 x 值记作 ξ ，那么我们有

$$\lambda(\xi) = -\frac{1}{4\xi} \tanh\left(\frac{\xi}{2}\right) = -\frac{1}{2\xi} \left[\sigma(\xi) - \frac{1}{2}\right]. \quad (10.141)$$

将 ξ 作为变分参数会得到更简单的表达式，此时共轭函数为

$$g(\lambda) = \lambda(\xi)\xi^2 - f(\xi) = \lambda(\xi)\xi^2 + \ln(e^{\xi/2} + e^{-\xi/2}). \quad (10.142)$$

因此，关于 $f(x)$ 的下界为

$$f(x) \geq \lambda x^2 - g(\lambda) = \lambda x^2 - \lambda \xi^2 - \ln(e^{\xi/2} + e^{-\xi/2}). \quad (10.143)$$

对应的 sigmoid 下界为

$$\sigma(x) \geq \sigma(\xi) \exp\left\{\frac{x - \xi}{2} - \lambda(\xi)(x^2 - \xi^2)\right\}, \quad (10.144)$$

其中 $\lambda(\xi)$ 的定义见式 (10.141)。该下界如图 10.12 右图所示。可以看到，下界呈指数形式，其中指数是 x 的二次函数，这将在通过 sigmoid 函数定义的后验分布中构造高斯近似时非常有用。

logistic sigmoid 在二元变量的概率模型中频繁出现，因为它是对数几率比映射为后验概率的函数。多类情形的对应变换是 softmax 函数。不幸的是，这里得到的 sigmoid 下界无法直接推广到 softmax。Gibbs (1997) 提出了一种构造高斯分布的方法，被猜测为 softmax 的一个界（虽然没有严格证明），可用于将局部变分方法扩展到多类问题。

我们将在 10.6.1 节看到局部变分界在实际中的使用案例。不过现在，从一般角度来看这些界是如何使用的是很有启发性的。假设我们希望计算如下形式的积分：

$$I = \int \sigma(a) p(a) da \quad (10.145)$$

其中 $\sigma(a)$ 是 logistic sigmoid，而 $p(a)$ 是高斯概率密度。这类积分在贝叶斯模型中经常出现，例如在求预测分布时， $p(a)$ 就代表某个参数的后验分布。但由于积分是不可解的，我们使用变分界 (10.144)，记作 $\sigma(a) \geq f(a, \xi)$ ，其中 ξ 为变分参数。这样积分变成两个指数-二次函数的乘积，从而可以解析计算，得到对 I 的下界：

$$I \geq \int f(a, \xi) p(a) da = F(\xi). \quad (10.146)$$

此时我们有自由选择变分参数 ξ ，方法是找到使 $F(\xi)$ 最大的 ξ^* 。最终的 $F(\xi^*)$ 是该族变分界中最紧的一个，可以作为 I 的近似。然而，这个优化后的界通常仍然不是精确的。

尽管 sigmoid 的下界 $\sigma(a) \geq f(a, \xi)$ 可以严格求得，但最优的 ξ 依赖于具体的 a ，因此该界只在某个特定 a 上是精确的。而 $F(\xi)$ 是在所有 a 上积分后得到的，因此 ξ^* 是一种折衷，其权重由分布 $p(a)$ 决定。

10.6 变分逻辑回归

接下来我们通过回到第 4.5 节中的贝叶斯逻辑回归模型，来说明如何使用局部变分方法。在第 4.5 节中，我们重点讨论了拉普拉斯近似，而这里则采用 Jaakkola 和 Jordan (2000) 的变分方法。与拉普拉斯方法一样，这种方法同样会得到对后验分布的高斯近似。然而，由于变分近似具有更高的灵活性，因此它通常比拉普拉斯方法更加精确。此外（不同于拉普拉斯方法），变分方法优化的是一个严格下界所定义的明确目标函数，即模型证据的有理下界。使用蒙特卡洛采样技术的贝叶斯逻辑回归分析也可见于 Dybowski 和 Roberts (2005)。

10.6.1 变分后验分布

这里我们将使用基于第 10.5 节提出的局部界的变分近似。这使得逻辑回归的似然函数（由 logistic sigmoid 控制）可以用指数形式的二次函数来近似。因此，再次选用共轭高斯先验（式 (4.140)）是方便的。暂时我们把超参数 $\mathbf{m}_0$ 和 $\mathbf{S}_0$ 视为固定常数。在 10.6.3 节，我们将展示如何把变分形式主义扩展到包含未知超参数的情况，以便从数据中推断它们的值。

在变分框架下，我们希望最大化边缘似然的下界。对贝叶斯逻辑回归模型而言，边缘似然为

$$p(\mathbf{t}) = \int p(\mathbf{t} | \mathbf{w}) p(\mathbf{w}) d\mathbf{w} = \int \left[\prod_{n=1}^N p(t_n | \mathbf{w}) \right] p(\mathbf{w}) d\mathbf{w}. \quad (10.147)$$

首先注意到变量 t 的条件分布可写为

$$\begin{aligned} p(t | \mathbf{w}) &= \sigma(a)^t \{1 - \sigma(a)\}^{1-t} \\ &= \left(\frac{1}{1 + e^{-a}} \right)^t \left(1 - \frac{1}{1 + e^{-a}} \right)^{1-t} \\ &= e^{at} \frac{e^{-a}}{1 + e^{-a}} = e^{at} \sigma(-a), \end{aligned} \quad (10.148)$$

其中 $a = \mathbf{w}^T \phi$ 。为了给 $p(\mathbf{t})$ 找到一个下界，我们使用式 (10.144) 给出的 logistic sigmoid 的变分下界，这里再次列出以便参考：

$$\sigma(z) \geq \sigma(\xi) \exp \left\{ (z - \xi)/2 - \lambda(\xi)(z^2 - \xi^2) \right\}, \quad (10.149)$$

其中

$$\lambda(\xi) = \frac{1}{2\xi} \left[\sigma(\xi) - \frac{1}{2} \right]. \quad (10.150)$$

因此，

$$p(t | \mathbf{w}) = e^{at} \sigma(-a) \geq e^{at} \sigma(\xi) \exp \left\{ \frac{-(a + \xi)}{2} - \lambda(\xi)(a^2 - \xi^2) \right\}. \quad (10.151)$$

需要注意的是，由于这个下界是分别应用于似然函数的每个项，因此对于训练集中的每个观测 (ϕ_n, t_n) ，都有一个对应的变分参数 ξ_n 。使用 $a = \mathbf{w}^T \phi$ ，并乘以前验分布，我们得到关于 $\mathbf{t}$ 和 $\mathbf{w}$ 的联合分布的下界如下：

$$p(\mathbf{t}, \mathbf{w}) = p(\mathbf{t} | \mathbf{w})p(\mathbf{w}) \geq h(\mathbf{w}, \boldsymbol{\xi})p(\mathbf{w}) \quad (10.152)$$

其中 $\boldsymbol{\xi}$ 表示变分参数集合 $\{\xi_n\}$ ，并且

$$h(\mathbf{w}, \boldsymbol{\xi}) = \prod_{n=1}^N \sigma(\xi_n) \exp \left\{ \mathbf{w}^T \phi_n t_n - (\mathbf{w}^T \phi_n + \xi_n) / 2 - \lambda(\xi_n) \left([\mathbf{w}^T \phi_n]^2 - \xi_n^2 \right) \right\}. \quad (10.153)$$

精确后验分布的计算需要对该不等式的左边进行归一化。由于这难以处理，我们转而处理右边。需要注意的是，右边的函数不能被解释为概率密度，因为它没有归一化。然而，一旦对其归一化得到变分后验分布 $q(\mathbf{w})$ ，它就不再是一个下界。

由于对数函数是单调递增的，不等式 $A \geq B$ 蕴含 $\ln A \geq \ln B$ 。这给出了关于 $\mathbf{t}$ 和 $\mathbf{w}$ 联合分布对数的下界，形式为

$$\begin{aligned} \ln\{p(\mathbf{t} | \mathbf{w})p(\mathbf{w})\} &\geq \ln p(\mathbf{w}) + \sum_{n=1}^N \left\{ \ln \sigma(\xi_n) + \mathbf{w}^T \phi_n t_n \right. \\ &\quad \left. - (\mathbf{w}^T \phi_n + \xi_n) / 2 - \lambda(\xi_n) \left([\mathbf{w}^T \phi_n]^2 - \xi_n^2 \right) \right\} \end{aligned} \quad (10.154)$$

将先验 $p(\mathbf{w})$ 代入，该不等式的右边作为 $\mathbf{w}$ 的函数变为

$$\begin{aligned} &-\frac{1}{2} (\mathbf{w} - \mathbf{m}_0)^T \mathbf{S}_0^{-1} (\mathbf{w} - \mathbf{m}_0) \\ &+ \sum_{n=1}^N \left\{ \mathbf{w}^T \phi_n (t_n - 1/2) - \lambda(\xi_n) \mathbf{w}^T (\phi_n \phi_n^T) \mathbf{w} \right\} + \text{const.} \end{aligned} \quad (10.155)$$

这是一个关于 $\mathbf{w}$ 的二次函数，因此我们可以通过识别 $\mathbf{w}$ 的线性项和二次项来得到相应的变分后验分布近似，从而得到高斯变分后验分布形式

$$q(\mathbf{w}) = \mathcal{N}(\mathbf{w} | \mathbf{m}_N, \mathbf{S}_N) \quad (10.156)$$

其中

$$\mathbf{m}_N = \mathbf{S}_N \left(\mathbf{S}_0^{-1} \mathbf{m}_0 + \sum_{n=1}^N (t_n - 1/2) \phi_n \right) \quad (10.157)$$

$$\mathbf{S}_N^{-1} = \mathbf{S}_0^{-1} + 2 \sum_{n=1}^N \lambda(\xi_n) \phi_n \phi_n^T \quad (10.158)$$

与 Laplace 框架一样，我们再次得到了后验分布的高斯近似。然而，变分参数 $\{\xi_n\}$ 提供的额外灵活性使得近似精度得到提升 (Jaakkola and Jordan, 2000)。

这里我们考虑的是批学习的情形，即所有训练数据同时可用。然而，贝叶斯方法本质上非常适合序列学习，即数据点逐个处理并随后丢弃。这种变分方法的序列情形表述是直接的。

需要注意的是, (10.149) 给出的界仅适用于二分类问题, 因此该方法不能直接推广到 $K > 2$ 的多分类问题。对于多分类情形的替代界已被 Gibbs (1997) 研究。

10.6.2 优化变分参数

现在我们已经得到了归一化的高斯后验分布近似, 稍后将用它来计算新数据点的预测分布。但首先, 需要通过最大化边缘似然的下界来确定变分参数 $\{\xi_n\}$ 。

为此, 我们将不等式 (10.152) 代回边缘似然, 得到

$$\ln p(\mathbf{t}) = \ln \int p(\mathbf{t} | \mathbf{w}) p(\mathbf{w}) d\mathbf{w} \geq \ln \int h(\mathbf{w}, \boldsymbol{\xi}) p(\mathbf{w}) d\mathbf{w} = \mathcal{L}(\boldsymbol{\xi}) \quad (10.159)$$

与 3.5 节线性回归模型中优化超参数 α 类似, 确定 ξ_n 有两种方法。第一种方法认识到 $\mathcal{L}(\boldsymbol{\xi})$ 的定义包含对 $\mathbf{w}$ 的积分, 因此可以将 $\mathbf{w}$ 视为潜在变量并使用 EM 算法。第二种方法先对 $\mathbf{w}$ 进行解析积分, 然后直接对 $\boldsymbol{\xi}$ 进行最大化。我们先讨论 EM 方法。

EM 算法首先为参数 $\{\xi_n\}$ (整体记为 $\boldsymbol{\xi}^{\text{old}}$) 选择初始值。在 E 步中, 使用这些参数值计算 $\mathbf{w}$ 的后验分布, 即 (10.156)。在 M 步中, 最大化期望完全数据对数似然

$$Q(\boldsymbol{\xi}, \boldsymbol{\xi}^{\text{old}}) = \mathbb{E}[\ln h(\mathbf{w}, \boldsymbol{\xi}) p(\mathbf{w})] \quad (10.160)$$

其中期望是相对于使用 $\boldsymbol{\xi}^{\text{old}}$ 计算得到的后验分布 $q(\mathbf{w})$ 取的。由于 $p(\mathbf{w})$ 不依赖于 $\boldsymbol{\xi}$, 代入 $h(\mathbf{w}, \boldsymbol{\xi})$ 后得到

$$Q(\boldsymbol{\xi}, \boldsymbol{\xi}^{\text{old}}) = \sum_{n=1}^N \{ \ln \sigma(\xi_n) - \xi_n/2 - \lambda(\xi_n) (\phi_n^T \mathbb{E}[\mathbf{w}\mathbf{w}^T] \phi_n - \xi_n^2) \} + \text{const} \quad (10.161)$$

其中 const 表示不依赖于 $\boldsymbol{\xi}$ 的项。现在对 ξ_n 求导并令其为零, 利用 $\sigma(\xi)$ 和 $\lambda(\xi)$ 的定义, 经过几步代数运算得到

$$0 = \lambda'(\xi_n) (\phi_n^T \mathbb{E}[\mathbf{w}\mathbf{w}^T] \phi_n - \xi_n^2) \quad (10.162)$$

注意到 $\lambda'(\xi)$ 在 $\xi \geq 0$ 时是 ξ 的单调函数, 且由于下界在 $\xi = 0$ 附近是对称的, 我们可以无损一般性地只考虑非负 ξ 。因此 $\lambda'(\xi) \neq 0$, 从而得到如下重估方程

$$(\xi_n^{\text{new}})^2 = \phi_n^T \mathbb{E}[\mathbf{w}\mathbf{w}^T] \phi_n = \phi_n^T (\mathbf{S}_N + \mathbf{m}_N \mathbf{m}_N^T) \phi_n \quad (10.163)$$

其中用到了 (10.156)。

下面总结求解变分后验分布的 EM 算法。首先初始化变分参数 $\boldsymbol{\xi}^{\text{old}}$ 。在 E 步中, 根据 (10.156) 计算 $\mathbf{w}$ 的后验分布, 其中均值和协方差由 (10.157) 和 (10.158) 给出。在 M 步中, 利用该变分后验计算 ξ 的新值, 即 (10.163)。重复 E 步和 M 步直至满足收敛条件, 实际中通常只需几次迭代即可。

另一种得到 ξ 重估方程的方法是注意到下界 $\mathcal{L}(\boldsymbol{\xi})$ 定义 (10.159) 中对 $\mathbf{w}$ 的积分, 其被积函数具有类高斯形式, 因此积分可以解析求解。求得积分后, 再对 ξ_n 求导, 结果与 EM 方法得到的 (10.163) 完全相同。

正如我们已经强调过的，在变分方法的应用中，能够对 (10.159) 给出的下界 $\mathcal{L}(\xi)$ 进行求值是非常有用的。对 $\mathbf{w}$ 的积分可以通过解析方式完成，因为 $p(\mathbf{w})$ 是高斯分布，而 $h(\mathbf{w}, \xi)$ 是 $\mathbf{w}$ 的二次函数的指数形式。因此，通过配方并利用高斯分布归一化系数的标准结果，我们可以得到闭合形式的解，其形式为

$$\begin{aligned} \mathcal{L}(\xi) = & \frac{1}{2} \ln \frac{|\mathbf{S}_N|}{|\mathbf{S}_0|} - \frac{1}{2} \mathbf{m}_N^T \mathbf{S}_N^{-1} \mathbf{m}_N + \frac{1}{2} \mathbf{m}_0^T \mathbf{S}_0^{-1} \mathbf{m}_0 \\ & + \sum_{n=1}^N \left\{ \ln \sigma(\xi_n) - \frac{1}{2} \xi_n - \lambda(\xi_n) \xi_n^2 \right\} \end{aligned} \quad (10.164)$$

这种变分框架也可以应用于数据逐个到达的序列情形 (Jaakkola and Jordan, 2000)。在这种情况下，我们维持一个关于 $\mathbf{w}$ 的高斯后验分布，该分布使用先验 $p(\mathbf{w})$ 进行初始化。每当一个新数据点到达时，利用界 (10.151) 更新后验，然后进行归一化得到更新后的后验分布。




图 10.13 对简单线性可分数据集进行贝叶斯逻辑回归的方法示意图。左图显示了使用变分推断得到的预测分布。可以看到，决策边界大致位于数据点簇之间的中间位置，并且预测分布的等高线在远离数据的区域逐渐张开，反映了这些区域分类不确定性的增加。右图显示了从后验分布 $p(\mathbf{w} | \mathbf{t})$ 中抽取的参数向量 $\mathbf{w}$ 的五个样本所对应的决策边界。

预测分布通过对后验分布进行边缘化得到，其形式与 4.5.2 节讨论的 Laplace 近似相同。图 10.13 显示了一个在合成数据集上的变分预测分布。这个例子为“大间隔” (large margin) 概念提供了有趣的洞见，该概念在 7.1 节中讨论过，其行为与贝叶斯解在定性上相似。

10.6.3 超参数的推断

到目前为止，我们一直将先验分布中的超参数 α 视为已知的常数。现在我们扩展贝叶斯逻辑回归模型，使该参数的值可以从数据集中推断出来。这可以通过将全局变分近似和局部变分近似结合到一个统一的框架中来实现，从而在每个阶段都保持对边缘似然的下界。这种组合方法曾在 Bishop 和 Svensén (2003) 对层次专家混合模型 (hierarchical mixture of experts) 的贝叶斯处理中被采用。

具体来说，我们再次考虑形式简单的各向同性高斯先验

$$p(\mathbf{w} | \alpha) = \mathcal{N}(\mathbf{w} | 0, \alpha^{-1} \mathbf{I}). \quad (10.165)$$

我们的分析很容易扩展到更一般的高斯先验，例如当我们希望为参数 $\mathbf{w}_j$ 的不同子集关联不同的超参数时。通常，我们对 α 采用共轭超先验，即 **Gamma** 分布

$$p(\alpha) = \text{Gam}(\alpha \mid a_0, b_0) \quad (10.166)$$

由常数 a_0 和 b_0 控制。

该模型的边缘似然现在具有如下形式

$$p(\mathbf{t}) = \iint p(\mathbf{w}, \alpha, \mathbf{t}) d\mathbf{w} d\alpha \quad (10.167)$$

其中联合分布为

$$p(\mathbf{w}, \alpha, \mathbf{t}) = p(\mathbf{t} \mid \mathbf{w})p(\mathbf{w} \mid \alpha)p(\alpha) \quad (10.168)$$

现在我们面临对 $\mathbf{w}$ 和 α 的解析上不可处理的积分，我们将通过在同一模型中同时使用局部变分方法和全局变分方法来解决。

首先，我们引入变分分布 $q(\mathbf{w}, \alpha)$ ，然后应用分解 (10.2)，在本例中形式为

$$\ln p(\mathbf{t}) = \mathcal{L}(q) + \text{KL}(q \parallel p) \quad (10.169)$$

其中下界 $\mathcal{L}(q)$ 和 Kullback-Leibler 散度 $\text{KL}(q \parallel p)$ 定义为

$$\mathcal{L}(q) = \iint q(\mathbf{w}, \alpha) \ln \left\{ \frac{p(\mathbf{w}, \alpha, \mathbf{t})}{q(\mathbf{w}, \alpha)} \right\} d\mathbf{w} d\alpha \quad (10.170)$$

$$\text{KL}(q \parallel p) = - \iint q(\mathbf{w}, \alpha) \ln \left\{ \frac{p(\mathbf{w}, \alpha \mid \mathbf{t})}{q(\mathbf{w}, \alpha)} \right\} d\mathbf{w} d\alpha \quad (10.171)$$

此时，由于似然因子 $p(\mathbf{t} \mid \mathbf{w})$ 的形式，下界 $\mathcal{L}(q)$ 仍然是不可处理的。因此，我们像之前一样对每个 logistic sigmoid 因子应用局部变分界，从而利用不等式 (10.152) 对 $\mathcal{L}(q)$ 给出下界，这也将是对对数边缘似然的下界

$$\begin{aligned} \ln p(\mathbf{t}) &\geq \mathcal{L}(q) \geq \tilde{\mathcal{L}}(q, \boldsymbol{\xi}) \\ &= \iint q(\mathbf{w}, \alpha) \ln \left\{ \frac{h(\mathbf{w}, \boldsymbol{\xi})p(\mathbf{w} \mid \alpha)p(\alpha)}{q(\mathbf{w}, \alpha)} \right\} d\mathbf{w} d\alpha. \end{aligned} \quad (10.172)$$

接下来我们假设变分分布在参数和超参数之间因子化，即

$$q(\mathbf{w}, \alpha) = q(\mathbf{w})q(\alpha) \quad (10.173)$$

有了这种因子化，我们可以利用一般结果 (10.9) 来求得最优因子。首先考虑分布 $q(\mathbf{w})$ 。丢弃与 $\mathbf{w}$ 无关的项，有

$$\begin{aligned} \ln q(\mathbf{w}) &= \mathbb{E}_\alpha [\ln \{h(\mathbf{w}, \boldsymbol{\xi})p(\mathbf{w} \mid \alpha)p(\alpha)\}] + \text{const} \\ &= \ln h(\mathbf{w}, \boldsymbol{\xi}) + \mathbb{E}_\alpha [\ln p(\mathbf{w} \mid \alpha)] + \text{const}. \end{aligned}$$

现在利用 (10.153) 代入 $\ln h(\mathbf{w}, \boldsymbol{\xi})$ ，利用 (10.165) 代入 $\ln p(\mathbf{w} \mid \alpha)$ ，得到

$$\ln q(\mathbf{w}) = -\frac{\mathbb{E}[\alpha]}{2} \mathbf{w}^T \mathbf{w} + \sum_{n=1}^N \left\{ (t_n - 1/2) \mathbf{w}^T \boldsymbol{\phi}_n - \lambda(\xi_n) \mathbf{w}^T \boldsymbol{\phi}_n \boldsymbol{\phi}_n^T \mathbf{w} \right\} + \text{const}.$$

我们看到，这是一个关于 $\mathbf{w}$ 的二次函数，因此 $q(\mathbf{w})$ 的解将是高斯分布。按照通常的配方方法，我们得到

$$q(\mathbf{w}) = \mathcal{N}(\mathbf{w} \mid \boldsymbol{\mu}_N, \boldsymbol{\Sigma}_N) \quad (10.174)$$

其中定义了

$$\boldsymbol{\Sigma}_N^{-1} \boldsymbol{\mu}_N = \sum_{n=1}^N (t_n - 1/2) \phi_n \quad (10.175)$$

$$\boldsymbol{\Sigma}_N^{-1} = \mathbb{E}[\alpha] \mathbf{I} + 2 \sum_{n=1}^N \lambda(\xi_n) \phi_n \phi_n^T \quad (10.176)$$

类似地，最优因子 $q(\alpha)$ 的解由下式得到

$$\ln q(\alpha) = \mathbb{E}_{\mathbf{w}}[\ln p(\mathbf{w} \mid \alpha)] + \ln p(\alpha) + \text{const.}$$

利用 (10.165) 代入 $\ln p(\mathbf{w} \mid \alpha)$ ，利用 (10.166) 代入 $\ln p(\alpha)$ ，得到

$$\ln q(\alpha) = \frac{M}{2} \ln \alpha - \frac{\alpha}{2} \mathbb{E}[\mathbf{w}^T \mathbf{w}] + (a_0 - 1) \ln \alpha - b_0 \alpha + \text{const.}$$

我们识别出这是 Gamma 分布的对数形式，因此得到

$$q(\alpha) = \text{Gam}(\alpha \mid a_N, b_N) \quad (10.177)$$

其中

$$a_N = a_0 + \frac{M}{2} \quad (10.178)$$

$$b_N = b_0 + \frac{1}{2} \mathbb{E}_{\mathbf{w}}[\mathbf{w}^T \mathbf{w}] \quad (10.179)$$

我们还需要优化变分参数 ξ_n ，这也是通过最大化下界 $\tilde{\mathcal{L}}(q, \boldsymbol{\xi})$ 来实现。省略与 $\boldsymbol{\xi}$ 无关的项，并对 α 积分后，有

$$\tilde{\mathcal{L}}(q, \boldsymbol{\xi}) = \int q(\mathbf{w}) \ln h(\mathbf{w}, \boldsymbol{\xi}) d\mathbf{w} + \text{const.} \quad (10.180)$$

注意这与 (10.159) 具有完全相同的形式，因此我们可以再次利用之前的结果 (10.163)，该结果可通过直接优化边缘似然函数得到，从而得到重估方程

$$(\xi_n^{\text{new}})^2 = \phi_n^T (\boldsymbol{\Sigma}_N + \boldsymbol{\mu}_N \boldsymbol{\mu}_N^T) \phi_n \quad (10.181)$$

我们已经得到了三个量 $q(\mathbf{w})$ 、 $q(\alpha)$ 和 $\boldsymbol{\xi}$ 的重估方程，因此在进行适当初始化后，可以循环更新这三个量，依次对每个量进行更新。所需的矩为

$$\mathbb{E}[\alpha] = \frac{a_N}{b_N} \quad (10.182)$$

$$\mathbb{E}[\mathbf{w}^T \mathbf{w}] = \boldsymbol{\Sigma}_N + \boldsymbol{\mu}_N \boldsymbol{\mu}_N^T. \quad (10.183)$$

10.7 期望传播

我们以讨论另一种形式的确定性近似推断方法来结束本章,即期望传播(expectation propagation, 或 EP) (Minka, 2001a; Minka, 2001b)。与目前讨论的变分贝叶斯方法一样,它也是基于最小化一个 Kullback-Leibler 散度,但现在采用的是逆向形式,这使得该近似具有相当不同的性质。

暂时考虑最小化 $\text{KL}(p||q)$ 关于 $q(\mathbf{z})$ 的问题,其中 $p(\mathbf{z})$ 是一个固定的分布,而 $q(\mathbf{z})$ 是指数族的一个成员,因此根据 (2.194),可以写成如下形式

$$q(\mathbf{z}) = h(\mathbf{z})g(\boldsymbol{\eta}) \exp \{ \boldsymbol{\eta}^T \mathbf{u}(\mathbf{z}) \}. \quad (10.184)$$

作为 $\boldsymbol{\eta}$ 的函数, Kullback-Leibler 散度变为

$$\text{KL}(p||q) = -\ln g(\boldsymbol{\eta}) - \boldsymbol{\eta}^T \mathbb{E}_{p(\mathbf{z})}[\mathbf{u}(\mathbf{z})] + \text{const} \quad (10.185)$$

其中常数项与自然参数 $\boldsymbol{\eta}$ 无关。我们可以通过将对 $\boldsymbol{\eta}$ 的梯度设为零,在这个分布族内最小化 $\text{KL}(p||q)$, 得到

$$-\nabla \ln g(\boldsymbol{\eta}) = \mathbb{E}_{p(\mathbf{z})}[\mathbf{u}(\mathbf{z})]. \quad (10.186)$$

然而,我们已经在 (2.226) 中看到 $\ln g(\boldsymbol{\eta})$ 的负梯度是由分布 $q(\mathbf{z})$ 下 $\mathbf{u}(\mathbf{z})$ 的期望给出的。将这两个结果等同起来,我们得到

$$\mathbb{E}_{q(\mathbf{z})}[\mathbf{u}(\mathbf{z})] = \mathbb{E}_{p(\mathbf{z})}[\mathbf{u}(\mathbf{z})]. \quad (10.187)$$

我们看到最优解仅仅对应于匹配期望的充分统计量。因此,例如,如果 $q(\mathbf{z})$ 是一个高斯分布 $\mathcal{N}(\mathbf{z} | \boldsymbol{\mu}, \boldsymbol{\Sigma})$, 那么我们通过设置 $q(\mathbf{z})$ 的均值 $\boldsymbol{\mu}$ 等于分布 $p(\mathbf{z})$ 的均值,并将协方差 $\boldsymbol{\Sigma}$ 等于 $p(\mathbf{z})$ 的协方差来最小化 Kullback-Leibler 散度。这有时被称为矩匹配(moment matching)。图 10.3(a) 中就有例子。

现在让我们利用这个结果来获得一个实用的近似推断算法。对于许多概率模型,数据 $\mathcal{D}$ 和隐变量(包括参数) $\boldsymbol{\theta}$ 的联合分布包含一个以下形式的因子乘积

$$p(\mathcal{D}, \boldsymbol{\theta}) = \prod_i f_i(\boldsymbol{\theta}). \quad (10.188)$$

例如,这会出现在独立同分布数据的模型中,其中每个数据点 $\mathbf{x}_n$ 都有一个因子 $f_n(\boldsymbol{\theta}) = p(\mathbf{x}_n | \boldsymbol{\theta})$, 同时还有一个对应于先验的因子 $f_0(\boldsymbol{\theta}) = p(\boldsymbol{\theta})$ 。更一般地,它也适用于由有向概率图定义的任何模型,其中每个因子是对应于其中一个节点的条件分布,或者是由无向图定义的任何模型,其中每个因子是团势。我们感兴趣的是评估后验分布 $p(\boldsymbol{\theta} | \mathcal{D})$ 以进行预测,以及评估模型证据 $p(\mathcal{D})$ 以进行模型比较。根据 (10.188), 后验分布由下式给出

$$p(\boldsymbol{\theta} | \mathcal{D}) = \frac{1}{p(\mathcal{D})} \prod_i f_i(\boldsymbol{\theta}) \quad (10.189)$$

模型证据由下式给出

$$p(\mathcal{D}) = \int \prod_i f_i(\boldsymbol{\theta}) d\boldsymbol{\theta}. \quad (10.190)$$

这里我们考虑的是连续变量，但下面的讨论同样适用于离散变量，只需将积分替换为求和。我们将假设对 θ 的边缘化以及进行预测所需的关于后验分布的边缘化是难以处理的 (intractable)，因此需要某种形式的近似。

期望传播是基于对后验分布的一种近似，该近似同样由若干因子乘积给出

$$q(\theta) = \frac{1}{Z} \prod_i \tilde{f}_i(\theta) \quad (10.191)$$

在这种近似中，每个因子 $\tilde{f}_i(\theta)$ 都对应于真实后验中 (10.189) 式的某个因子 $f_i(\theta)$ ，而因子 $1/Z$ 是归一化常数，用来保证 (10.191) 左侧对 θ 积分为 1。为了得到一个可行的算法，我们需要以某种方式约束这些因子 $\tilde{f}_i(\theta)$ ，特别地，我们将假设它们来自指数族。于是这些因子的乘积也将属于指数族，因此可以用有限个充分统计量来刻画。例如，如果每个 $\tilde{f}_i(\theta)$ 都是高斯分布，那么整体近似 $q(\theta)$ 也将是高斯分布。

理想情况下，我们希望通过最小化真实后验与近似分布之间的 Kullback-Leibler 散度来确定 $\tilde{f}_i(\theta)$ ，该散度为

$$\text{KL}(p\|q) = \text{KL} \left(\frac{1}{p(\mathcal{D})} \prod_i f_i(\theta) \parallel \frac{1}{Z} \prod_i \tilde{f}_i(\theta) \right). \quad (10.192)$$

注意，这与变分推断中使用的 KL 散度方向正好相反。一般来说，这个最小化问题是难以处理的，因为 KL 散度涉及对真实分布的平均。作为一个粗略的近似，我们可以改为最小化对应因子对 $f_i(\theta)$ 和 $\tilde{f}_i(\theta)$ 之间的 KL 散度。这样的问题要简单得多，而且算法是非迭代的，这是它的一个优点。然而，由于每个因子是独立近似的，这些因子的乘积可能会给出一个很差的整体近似。

期望传播通过在其它因子的背景下逐个优化每个因子，从而给出一个好得多的近似。它首先对因子 $\tilde{f}_i(\theta)$ 进行初始化，然后在所有因子之间循环，每次细化一个因子。这在精神上类似于前面讨论的变分贝叶斯框架中的因子更新。假设我们现在要细化因子 $\tilde{f}_j(\theta)$ 。我们先将该因子从乘积中移除，从而得到 $\prod_{i \neq j} \tilde{f}_i(\theta)$ 。从概念上讲，我们现在将通过保证乘积

$$q^{\text{new}}(\theta) \propto \tilde{f}_j(\theta) \prod_{i \neq j} \tilde{f}_i(\theta) \quad (10.193)$$

尽可能接近

$$f_j(\theta) \prod_{i \neq j} \tilde{f}_i(\theta) \quad (10.194)$$

来确定因子 $\tilde{f}_j(\theta)$ 的修正形式，其中对 $i \neq j$ 的所有因子 $\tilde{f}_i(\theta)$ 保持不变。这样就保证了在由其余因子所定义的高后验概率区域中，该近似最为精确。当我们将 EP 应用于“杂波问题”时，将会看到这一效应的例子。为此，我们首先从当前的后验近似中移除因子 $\tilde{f}_j(\theta)$ ，通过定义非归一化分布

$$q^{\setminus j}(\theta) = \frac{q(\theta)}{\tilde{f}_j(\theta)}. \quad (10.195)$$

注意, 我们也可以通过对其余所有因子乘积来得到 $q^{\setminus j}(\boldsymbol{\theta})$, 尽管在实践中通常用除法更为简单。接下来, 我们将其与因子 $f_j(\boldsymbol{\theta})$ 结合, 得到分布

$$\frac{1}{Z_j} f_j(\boldsymbol{\theta}) q^{\setminus j}(\boldsymbol{\theta}) \quad (10.196)$$

其中 Z_j 是归一化常数, 给出为

$$Z_j = \int f_j(\boldsymbol{\theta}) q^{\setminus j}(\boldsymbol{\theta}) d\boldsymbol{\theta}. \quad (10.197)$$

我们现在通过最小化以下 Kullback-Leibler 散度来确定修正后的因子 $\tilde{f}_j(\boldsymbol{\theta})$

$$\text{KL} \left(\frac{f_j(\boldsymbol{\theta}) q^{\setminus j}(\boldsymbol{\theta})}{Z_j} \parallel q^{\text{new}}(\boldsymbol{\theta}) \right). \quad (10.198)$$




图 10.14 对期望传播 (EP) 近似的示意图, 采用高斯分布来处理先前在图 4.14 和图 10.1 中考虑的示例。左图显示了原始分布 (黄色), 以及 Laplace 近似 (红色)、全局变分近似 (绿色) 和 EP 近似 (蓝色); 右图显示了这些分布对应的负对数。需要注意的是, 由于所采用的 KL 散度形式不同, EP 分布相比变分推断得到的分布更加宽广。

这个问题很容易求解, 因为近似分布 $q^{\text{new}}(\boldsymbol{\theta})$ 来自指数族, 因此我们可以利用 (10.187) 式的结果: 该结果告诉我们, $q^{\text{new}}(\boldsymbol{\theta})$ 的参数可以通过将其期望充分统计量与 (10.196) 的相应矩匹配来获得。我们将在此假设这一步是可行的。例如, 如果我们选择 $q(\boldsymbol{\theta})$ 为高斯分布 $\mathcal{N}(\boldsymbol{\theta} \mid \boldsymbol{\mu}, \boldsymbol{\Sigma})$, 那么 $\boldsymbol{\mu}$ 被设为 (未归一化) 分布 $f_j(\boldsymbol{\theta}) q^{\setminus j}(\boldsymbol{\theta})$ 的均值, 而 $\boldsymbol{\Sigma}$ 被设为其协方差。更一般地说, 只要指数族分布可以被归一化, 我们就可以容易地得到所需的期望, 因为这些期望统计量可以通过归一化系数的导数来表示, 如 (2.226) 式所示。EP 近似示意于图 10.14。

由 (10.193) 可知, 可以通过取 $q^{\text{new}}(\boldsymbol{\theta})$ 并将剩余因子除去来得到修正后的因子 $\tilde{f}_j(\boldsymbol{\theta})$, 从而有

$$\tilde{f}_j(\boldsymbol{\theta}) = K \frac{q^{\text{new}}(\boldsymbol{\theta})}{q^{\setminus j}(\boldsymbol{\theta})} \quad (10.199)$$

这里我们使用了 (10.195)。系数 K 可通过将 (10.199) 两边同乘以 $q^{\setminus j}(\boldsymbol{\theta})$ 并积分得到

$$K = \int \tilde{f}_j(\boldsymbol{\theta}) q^{\setminus j}(\boldsymbol{\theta}) d\boldsymbol{\theta} \quad (10.200)$$

其中使用了 $q^{\text{new}}(\boldsymbol{\theta})$ 已经归一化这一事实。因此, K 的取值可以通过匹配零阶矩来求得

$$\int \tilde{f}_j(\boldsymbol{\theta}) q^{\setminus j}(\boldsymbol{\theta}) d\boldsymbol{\theta} = \int f_j(\boldsymbol{\theta}) q^{\setminus j}(\boldsymbol{\theta}) d\boldsymbol{\theta} \quad (10.201)$$

将其与 (10.197) 结合，我们便可看出 $K = Z_j$ ，因此可以通过计算 (10.197) 中的积分来求得。

在实践中，会对所有因子进行多次遍历，依次修正每一个因子。然后利用 (10.191) 来近似后验分布 $p(\boldsymbol{\theta} | \mathcal{D})$ ，并通过在 (10.190) 中将因子 $f_i(\boldsymbol{\theta})$ 替换为其近似 $\tilde{f}_i(\boldsymbol{\theta})$ 来近似模型证据 $p(\mathcal{D})$ 。

期望传播

我们给定关于观测数据 $\mathcal{D}$ 与随机变量 $\boldsymbol{\theta}$ 的联合分布，其形式为因子乘积

$$p(\mathcal{D}, \boldsymbol{\theta}) = \prod_i f_i(\boldsymbol{\theta}) \quad (10.202)$$

我们希望用如下形式的分布来近似后验分布 $p(\boldsymbol{\theta} | \mathcal{D})$

$$q(\boldsymbol{\theta}) = \frac{1}{Z} \prod_i \tilde{f}_i(\boldsymbol{\theta}) \quad (10.203)$$

我们还希望对模型证据 $p(\mathcal{D})$ 作近似。

1. 初始化所有近似因子 $\tilde{f}_i(\boldsymbol{\theta})$ 。
2. 通过设定

$$q(\boldsymbol{\theta}) \propto \prod_i \tilde{f}_i(\boldsymbol{\theta}) \quad (10.204)$$

来初始化后验近似。

3. 重复以下步骤直到收敛：

- (a) 选择一个要细化的因子 $\tilde{f}_j(\boldsymbol{\theta})$ 。
- (b) 通过除法将 $\tilde{f}_j(\boldsymbol{\theta})$ 从后验中移除

$$q^{\setminus j}(\boldsymbol{\theta}) = \frac{q(\boldsymbol{\theta})}{\tilde{f}_j(\boldsymbol{\theta})} \quad (10.205)$$

- (c) 通过将 $q^{\text{new}}(\boldsymbol{\theta})$ 的充分统计量（矩）设为 $q^{\setminus j}(\boldsymbol{\theta})f_j(\boldsymbol{\theta})$ 的对应矩来计算新的后验，包括归一化常数的计算

$$Z_j = \int q^{\setminus j}(\boldsymbol{\theta}) f_j(\boldsymbol{\theta}) d\boldsymbol{\theta} \quad (10.206)$$

- (d) 计算并存储新的因子

$$\tilde{f}_j(\boldsymbol{\theta}) = Z_j \frac{q^{\text{new}}(\boldsymbol{\theta})}{q^{\setminus j}(\boldsymbol{\theta})}. \quad (10.207)$$

4. 计算对模型证据的近似

$$p(\mathcal{D}) \simeq \int \prod_i \tilde{f}_i(\boldsymbol{\theta}) d\boldsymbol{\theta} \quad (10.208)$$


EP 的一个特例称为假设密度滤波 (assumed density filtering, ADF) 或矩匹配 (moment matching) (Maybeck, 1982; Lauritzen, 1992; Boyen and Koller, 1998; Oppor and Winther, 1999)。通过将除第一个近似因子之外的所有近似因子初始化为 1, 然后对所有因子进行一次遍历并各自更新一次, 就可以得到这一特例。假设密度滤波适用于在线学习的情形: 数据点按顺序到达, 我们需要从每个数据点中学习, 然后在考虑下一个数据点之前丢弃它。然而, 在批量 (batch) 环境中, 我们可以多次重复利用数据点以获得更高的精度, 而期望传播正是利用了这一思想。此外, 如果将 ADF 应用于批量数据, 结果将会不希望地依赖于数据点被处理的 (任意的) 顺序, 而 EP 则可以克服这个问题。

期望传播的一个缺点是迭代不一定收敛。然而, 对于指数族中的近似 $q(\theta)$, 如果迭代确实收敛, 则所得解将是某个特定能量函数的驻点 (Minka, 2001a), 尽管 EP 的每次迭代并不一定会减小该能量函数的值。这一点与变分贝叶斯形成对比: 变分贝叶斯通过迭代最大化对数边缘似然的下界, 从而保证每次迭代都不会降低该下界。可以直接对 EP 的代价函数进行优化, 在这种情况下可以保证收敛, 不过由此得到的算法往往更慢, 也更难实现。

变分贝叶斯与 EP 之间的另一差别源于二者所最小化的 KL 散度形式不同, 因为前者最小化的是 $KL(q||p)$, 而后者最小化的是 $KL(p||q)$ 。正如我们在图 10.3 中所见, 对于多峰分布 $p(\theta)$, 最小化 $KL(p||q)$ 可能会导致较差的近似。特别地, 如果将 EP 应用于混合模型, 其结果并不合理, 因为近似会试图同时捕捉后验分布的所有模式。相反, 在逻辑回归类模型中, EP 通常优于局部变分方法和拉普拉斯近似 (Kuss and Rasmussen, 2006)。

10.7.1 示例: 杂波问题

图 10.15 在数据空间维度为 $D = 1$ 的情况下, 对杂波问题的示意图。用叉号表示的训练数据点是从由两个高斯分量组成的混合分布中抽取的, 其中各分量分别以红色和绿色表示。目标是根据观测到的数据推断绿色高斯分布的均值。



参考 Minka (2001b), 我们用一个简单示例来说明 EP 算法。在该示例中, 我们的目标是: 在给定一组由某个多元高斯分布生成的观测值的情况下, 推断该分布的均值 θ , 分布作用在变量 $\mathbf{x}$ 上。为了使问题更有趣, 这些观测值被嵌在背景杂波中, 而杂波本身也是高斯分布的, 如图 10.15 所示。因此, 观测值 $\mathbf{x}$ 的分布是一个高斯混合分布, 我们令其为如下形式

$$p(\mathbf{x} | \theta) = (1 - w)\mathcal{N}(\mathbf{x} | \theta, \mathbf{I}) + w\mathcal{N}(\mathbf{x} | \mathbf{0}, a\mathbf{I}) \quad (10.209)$$

其中 w 是背景杂波所占比例，并假设其已知。对 $\boldsymbol{\theta}$ 的先验取为高斯分布

$$p(\boldsymbol{\theta}) = \mathcal{N}(\boldsymbol{\theta} \mid \mathbf{0}, b\mathbf{I}) \quad (10.210)$$

而 Minka (2001a) 选择的参数值为 $a = 10, b = 100$ 且 $w = 0.5$ 。 N 个观测值 $\mathcal{D} = \{\mathbf{x}_1, \dots, \mathbf{x}_N\}$ 与 $\boldsymbol{\theta}$ 的联合分布为

$$p(\mathcal{D}, \boldsymbol{\theta}) = p(\boldsymbol{\theta}) \prod_{n=1}^N p(\mathbf{x}_n \mid \boldsymbol{\theta}) \quad (10.211)$$

因此，后验分布由 2^N 个高斯分布的混合构成。于是，精确求解该问题的计算代价会随着数据集大小呈指数级增长，因此对中等规模的 N 来说，精确解是不可行的。

要将 EP 应用于杂波问题，首先我们识别因子 $f_0(\boldsymbol{\theta}) = p(\boldsymbol{\theta})$ 与 $f_n(\boldsymbol{\theta}) = p(\mathbf{x}_n \mid \boldsymbol{\theta})$ 。接着我们从指数族中选取一个近似分布，在本例中方便起见选用一个球对称高斯分布

$$q(\boldsymbol{\theta}) = \mathcal{N}(\boldsymbol{\theta} \mid \mathbf{m}, v\mathbf{I}) \quad (10.212)$$

因此，各因子的近似将取指数二次函数的形式

$$\tilde{f}_n(\boldsymbol{\theta}) = s_n \mathcal{N}(\boldsymbol{\theta} \mid \mathbf{m}_n, v_n \mathbf{I}) \quad (10.213)$$

其中 $n = 1, \dots, N$ ，并令 $\tilde{f}_0(\boldsymbol{\theta})$ 等于先验 $p(\boldsymbol{\theta})$ 。注意，使用记号 $\mathcal{N}(\boldsymbol{\theta} \mid \cdot, \cdot)$ 并不意味着右侧一定是一个良好定义的高斯密度（事实上，如我们将看到的，方差参数 v_n 可能为负），该写法仅仅是一个方便的简写。对于 $n = 1, \dots, N$ ，近似因子 $\tilde{f}_n(\boldsymbol{\theta})$ 可以初始化为 1，这对应于 $s_n = (2\pi v_n)^{D/2}, v_n \rightarrow \infty$ 且 $\mathbf{m}_n = \mathbf{0}$ ，其中 D 是 $\mathbf{x}$ 的维度，因此也是 $\boldsymbol{\theta}$ 的维度。由 (10.191) 定义的初始 $q(\boldsymbol{\theta})$ 因而等于先验。

然后通过迭代来细化这些因子，每次取一个因子 $f_n(\boldsymbol{\theta})$ ，并应用 (10.205)、(10.206) 和 (10.207)。注意我们不需要修正项 $f_0(\boldsymbol{\theta})$ ，因为一次 EP 更新会使该项保持不变。这里我们给出结果，细节留给读者自行推导。

首先，利用 (10.205) 通过除法将当前估计的 $\tilde{f}_n(\boldsymbol{\theta})$ 从 $q(\boldsymbol{\theta})$ 中移除，得到 $q^{\setminus n}(\boldsymbol{\theta})$ ，其均值与逆方差为

$$\mathbf{m}^{\setminus n} = \mathbf{m} + v^{\setminus n} v_n^{-1} (\mathbf{m} - \mathbf{m}_n) \quad (10.214)$$

$$(v^{\setminus n})^{-1} = v^{-1} - v_n^{-1} \quad (10.215)$$

接着我们利用 (10.206) 计算归一化常数 Z_n ，得到

$$Z_n = (1 - w) \mathcal{N}(\mathbf{x}_n \mid \mathbf{m}^{\setminus n}, (v^{\setminus n} + 1) \mathbf{I}) + w \mathcal{N}(\mathbf{x}_n \mid \mathbf{0}, a\mathbf{I}). \quad (10.216)$$

类似地，我们通过求出 $q^{\setminus n}(\boldsymbol{\theta}) f_n(\boldsymbol{\theta})$ 的均值和方差来计算 $q^{\text{new}}(\boldsymbol{\theta})$ 的均值和方差，从而得到

$$\mathbf{m} = \mathbf{m}^{\setminus n} + \rho_n \frac{v^{\setminus n}}{v^{\setminus n} + 1} (\mathbf{x}_n - \mathbf{m}^{\setminus n}) \quad (10.217)$$

$$v = v^{\setminus n} - \rho_n \frac{(v^{\setminus n})^2}{v^{\setminus n} + 1} + \rho_n (1 - \rho_n) \frac{(v^{\setminus n})^2 \|\mathbf{x}_n - \mathbf{m}^{\setminus n}\|^2}{D (v^{\setminus n} + 1)^2} \quad (10.218)$$

其中量

$$\rho_n = 1 - \frac{w}{Z_n} \mathcal{N}(\mathbf{x}_n | \mathbf{0}, a\mathbf{I}) \quad (10.219)$$

有一个简单的解释，即点 $\mathbf{x}_n$ 不是杂波的概率。然后我们使用 (10.207) 来计算精化后的因子 $\tilde{f}_n(\boldsymbol{\theta})$ ，其参数为

$$v_n^{-1} = (v^{\text{new}})^{-1} - (v^{\setminus n})^{-1} \quad (10.220)$$

$$\mathbf{m}_n = \mathbf{m}^{\setminus n} + (v_n + v^{\setminus n}) (v^{\setminus n})^{-1} (\mathbf{m}^{\text{new}} - \mathbf{m}^{\setminus n}) \quad (10.221)$$

$$s_n = \frac{Z_n}{(2\pi v_n)^{D/2} \mathcal{N}(\mathbf{m}_n | \mathbf{m}^{\setminus n}, (v_n + v^{\setminus n}) \mathbf{I})}. \quad (10.222)$$

这一细化过程不断重复，直到满足合适的终止准则，例如，在对所有因子完成一次遍历后，参数值的最大变化小于某个阈值。最后，我们使用 (10.208) 来计算对模型证据的近似：

$$p(\mathcal{D}) \simeq (2\pi v^{\text{new}})^{D/2} \exp(B/2) \prod_{n=1}^N \left\{ s_n (2\pi v_n)^{-D/2} \right\} \quad (10.223)$$

其中

$$B = \frac{(\mathbf{m}^{\text{new}})^T \mathbf{m}^{\text{new}}}{v} - \sum_{n=1}^N \frac{\mathbf{m}_n^T \mathbf{m}_n}{v_n}. \quad (10.224)$$




图 10.16 在杂波问题上对期望传播、变分推断以及 Laplace 近似的比较。左图显示了预测后验均值的误差随浮点运算次数变化的关系，右图显示了模型证据对应的结果。

对于一维参数空间 $\boldsymbol{\theta}$ 的杂波问题，其因子近似的示例如图 10.16 所示。注意，因子近似中的“方差”参数 v_n 可以是无穷大，甚至可以为负。这仅仅对应于那些向上弯曲而非向下弯曲的近似，只要整体近似后验 $q(\boldsymbol{\theta})$ 具有正方差，就不一定会造成问题。图 10.17 比较了 EP、变分贝叶斯（平均场理论）以及拉普拉斯近似在杂波问题上的表现。

10.7.2 图上的期望传播

到目前为止，在对 EP 的一般讨论中，我们都允许分布 $p(\boldsymbol{\theta})$ 中的因子 $f_i(\boldsymbol{\theta})$ 可以是关于 $\boldsymbol{\theta}$ 所有分量的函数，近似分布 $q(\boldsymbol{\theta})$ 中的近似因子 $\tilde{f}_i(\boldsymbol{\theta})$ 也类似。现在我们考虑这样一种情形：这些因子只依赖于变量的子集。利用第 8 章讨论过的概率图模型框架，可以




图 10.17 针对一维杂波问题中各个特定因子的近似示例，其中 $f_n(\theta)$ 以蓝色表示， $\bar{f}_n(\theta)$ 以红色表示，而 $q^\lambda(\theta)$ 以绿色表示。可以注意到， $q^\lambda(\theta)$ 的当前形式控制了 $\bar{f}_n(\theta)$ 能够良好近似 $f_n(\theta)$ 的 θ 取值范围。

很方便地表达这种约束。在这里我们使用因子图表示，因为它同时涵盖了有向图和无向图。

我们将重点讨论近似分布是完全因子化的情形，并将说明在这种情况下，期望传播会退化为 **loopy belief propagation** (Minka, 2001a)。一开始，我们先在一个简单示例的背景下展示这一点，然后再讨论一般情形。

首先，回忆式 (10.17) 的结论：如果我们在一个因子化分布 q 上最小化 $\text{KL}(p||q)$ ，那么每个因子的最优解就是 p 的对应边缘分布。




图 10.18 左侧是图 8.51 中的一个简单因子图，这里为方便起见再次给出。右侧是与之对应的因子化近似。

现在考虑图 10.18 左侧所示的因子图，它之前是在和求和-乘积算法相关的背景下引入的。其联合分布为

$$p(\mathbf{x}) = f_a(x_1, x_2) f_b(x_2, x_3) f_c(x_2, x_4). \quad (10.225)$$

我们希望寻找一个具有相同因子分解形式的近似 $q(\mathbf{x})$ ，即

$$q(\mathbf{x}) \propto \tilde{f}_a(x_1, x_2) \tilde{f}_b(x_2, x_3) \tilde{f}_c(x_2, x_4). \quad (10.226)$$

注意，这里省略了归一化常数，它们可以在最后通过局部归一化重新加上，这在信念传播中是普遍做法。现在假设我们把注意力限制在这样的近似上：其中这些因子本身再对各个单独变量进行因子化，即

$$q(\mathbf{x}) \propto \tilde{f}_{a1}(x_1) \tilde{f}_{a2}(x_2) \tilde{f}_{b2}(x_2) \tilde{f}_{b3}(x_3) \tilde{f}_{c2}(x_2) \tilde{f}_{c4}(x_4) \quad (10.227)$$

这就对应于图 10.18 右侧所示的因子图。由于各个因子本身已经因子化，整体分布 $q(\mathbf{x})$ 便是完全因子化的。

现在我们在这个完全因子化的近似下应用 EP 算法。假设我们已经对所有因子完成了初始化，并且我们选择精化因子 $\tilde{f}_b(x_2, x_3) = \tilde{f}_{b2}(x_2) \tilde{f}_{b3}(x_3)$ 。首先，我们从近似分布中移除这个因子，得到

$$q^{\setminus b}(\mathbf{x}) = \tilde{f}_{a1}(x_1) \tilde{f}_{a2}(x_2) \tilde{f}_{c2}(x_2) \tilde{f}_{c4}(x_4) \quad (10.228)$$

然后将其与精确因子 $f_b(x_2, x_3)$ 相乘，得到

$$\hat{p}(\mathbf{x}) = q^{\setminus b}(\mathbf{x}) f_b(x_2, x_3) = \tilde{f}_{a1}(x_1) \tilde{f}_{a2}(x_2) \tilde{f}_{c2}(x_2) \tilde{f}_{c4}(x_4) f_b(x_2, x_3). \quad (10.229)$$

接下来，我们通过最小化 Kullback-Leibler 散度 $\text{KL}(\hat{p}||q^{\text{new}})$ 来求得 $q^{\text{new}}(\mathbf{x})$ 。如前面所述，结果是： $q^{\text{new}}(\mathbf{x})$ 由每个变量 x_i 对应的一个因子乘积构成，而每个因子都等于 $\hat{p}(\mathbf{x})$ 关于该变量的边缘分布。这四个边缘分布为

$$\hat{p}(x_1) \propto \tilde{f}_{a1}(x_1) \quad (10.230)$$

$$\hat{p}(x_2) \propto \tilde{f}_{a2}(x_2) \tilde{f}_{c2}(x_2) \sum_{x_3} f_b(x_2, x_3) \quad (10.231)$$

$$\hat{p}(x_3) \propto \sum_{x_2} \left\{ f_b(x_2, x_3) \tilde{f}_{a2}(x_2) \tilde{f}_{c2}(x_2) \right\} \quad (10.232)$$

$$\hat{p}(x_4) \propto \tilde{f}_{c4}(x_4) \quad (10.233)$$

而 $q^{\text{new}}(\mathbf{x})$ 则通过将这些边缘分布相乘而得到。我们看到，当我们更新 $f_b(x_2, x_3)$ 时， $q(\mathbf{x})$ 中唯一发生改变的因子就是那些涉及 f_b 中变量的因子，即 x_2 和 x_3 。为了得到精化后的因子 $\tilde{f}_b(x_2, x_3) = \tilde{f}_{b2}(x_2) \tilde{f}_{b3}(x_3)$ ，我们只需用 $q^{\text{new}}(\mathbf{x})$ 除以 $q^{\setminus b}(\mathbf{x})$ ，由此得到

$$\tilde{f}_{b2}(x_2) \propto \sum_{x_3} f_b(x_2, x_3) \quad (10.234)$$

$$\tilde{f}_{b3}(x_3) \propto \sum_{x_2} \left\{ f_b(x_2, x_3) \tilde{f}_{a2}(x_2) \tilde{f}_{c2}(x_2) \right\}. \quad (10.235)$$

这正是使用信念传播得到的消息形式，其中变量结点到因子结点的消息已经被折叠进了因子结点到变量结点的消息中。特别地， $\tilde{f}_{b2}(x_2)$ 对应于因子结点 f_b 发送给变量结点 x_2 的消息 $\mu_{f_b \rightarrow x_2}(x_2)$ ，其形式由 (8.81) 给出。类似地，如果我们将 (8.78) 代入 (8.79)，就得到 (10.235)，其中 $\tilde{f}_{a2}(x_2)$ 对应于 $\mu_{f_a \rightarrow x_2}(x_2)$ ，而 $\tilde{f}_{c2}(x_2)$ 对应于 $\mu_{f_c \rightarrow x_2}(x_2)$ ，从而得到消息 $\tilde{f}_{b3}(x_3)$ ，它对应于 $\mu_{f_b \rightarrow x_3}(x_3)$ 。

这个结果与标准信念传播略有不同，因为这里消息是同时两个方向上传递的。我们可以很容易地修改 EP 过程，将其变为求和-乘积算法的标准形式：只在每一步更新一个因子，例如如果我们只精化 $\tilde{f}_{b3}(x_3)$ ，那么 $\tilde{f}_{b2}(x_2)$ 在定义上保持不变，而精化后的 $\tilde{f}_{b3}(x_3)$ 仍然由 (10.235) 给出。如果我们一次只精化一个项，那么就可以按任意顺序选择这些精化的执行次序。特别地，对于一棵树结构的图，我们可以采用两次遍历的更新

方案，对应于标准的信念传播调度，从而精确推断出变量和因子的边缘分布。在这种情况下，近似因子的初始化并不重要。

现在考虑一个对应于分布

$$p(\boldsymbol{\theta}) = \prod_i f_i(\boldsymbol{\theta}_i) \quad (10.236)$$

的一般因子图，其中 $\boldsymbol{\theta}_i$ 表示与因子 f_i 相关联的那一部分变量子集。我们用一个完全因子化的分布来近似它：

$$q(\boldsymbol{\theta}) \propto \prod_i \prod_k \tilde{f}_{ik}(\theta_k) \quad (10.237)$$

这里 θ_k 对应于单个变量结点。假设我们希望在保持其他所有项不变的前提下，精化某个特定项 $\tilde{f}_{jl}(\theta_l)$ 。首先，我们从 $q(\boldsymbol{\theta})$ 中移除项 $\tilde{f}_j(\boldsymbol{\theta}_j)$ ，得到

$$q^{\setminus j}(\boldsymbol{\theta}) \propto \prod_{i \neq j} \prod_k \tilde{f}_{ik}(\theta_k) \quad (10.238)$$

然后再乘上精确因子 $f_j(\boldsymbol{\theta}_j)$ 。为了确定精化后的项 $\tilde{f}_{jl}(\theta_l)$ ，我们只需考虑关于 θ_l 的函数依赖，因此只需求出如下分布的对应边缘：

$$q^{\setminus j}(\boldsymbol{\theta}) f_j(\boldsymbol{\theta}_j). \quad (10.239)$$

在一个乘法常数之内，这就等价于对 $f_j(\boldsymbol{\theta}_j)$ 与 $q^{\setminus j}(\boldsymbol{\theta})$ 中所有关于 $\boldsymbol{\theta}_j$ 中任意变量的项的乘积求边缘分布。对于 $i \neq j$ 的其他因子 $\tilde{f}_i(\boldsymbol{\theta}_i)$ 所对应的项，在之后我们用 $q^{\setminus j}(\boldsymbol{\theta})$ 来做除法时，会在分子与分母之间相互抵消。因此，我们得到

$$\tilde{f}_{jl}(\theta_l) \propto \sum_{\theta_m \neq l \in \boldsymbol{\theta}_j} f_j(\boldsymbol{\theta}_j) \prod_k \prod_{m \neq l} \tilde{f}_{km}(\theta_m). \quad (10.240)$$

我们可以将其识别为求和-乘积规则的一种形式，其中变量结点到因子结点的消息被消去，如图 8.50 所示示例中所展示的那样。量 $\tilde{f}_{jm}(\theta_m)$ 对应于因子结点 j 发送给变量结点 m 的消息 $\mu_{f_j \rightarrow \theta_m}(\theta_m)$ ，而式 (10.240) 中对 k 的乘积则遍及所有依赖于变量 θ_m 的因子——这些因子与 $f_j(\boldsymbol{\theta}_j)$ 共享除变量 θ_l 以外的某些变量。换句话说，为了计算某个因子结点的输出消息，我们取该因子结点从其他因子结点接收的所有输入消息的乘积，与本地因子相乘，然后再进行边缘化。

因此，如果我们采用一个完全因子化的近似分布，那么求和-乘积算法就会作为期望传播的一个特例出现。这提示我们可以使用更灵活的近似分布——对应于部分断开的图结构——来获得更高的精度。另一种推广方式是将若干因子 $f_i(\boldsymbol{\theta}_i)$ 归为一组，在每次迭代中同时精化同一组中的所有因子。这两种方法都可以提高精度 (Minka, 2001b)。总体而言，如何选择最佳的分组方式与断开方式这一问题仍然是一个开放的研究课题。

我们已经看到，变分消息传递与期望传播分别优化了两种不同形式的 Kullback-Leibler 散度。Minka (2005) 表明，可以从一个共同的框架出发，利用对一族 α -散度 (见式 (10.19)) 成员的最小化来推导出广泛的消息传递算法。这些算法包括变分消息传递、loopy belief propagation 和期望传播，以及一系列我们在此没有空间详细讨论的其他

算法，比如树重加权消息传递（tree-reweighted message passing, Wainwright et al., 2005）、分数信念传播（fractional belief propagation, Wierginck and Heskes, 2003）以及 power EP（Minka, 2004）。

11 采样方法


对于大多数具有实际意义的概率模型来说，精确推断是难以实现的，因此我们不得不采用某种形式的近似。在第 10 章中，我们讨论了基于确定性近似的推断算法，其中包括变分贝叶斯和期望传播等方法。本章我们将讨论基于数值采样的近似推断方法，也称为蒙特卡罗技术。

虽然在某些应用中，未观测变量的后验分布本身就是我们直接感兴趣的对象，但在大多数情形下，我们需要后验分布主要是为了计算期望，例如用于做预测。因此，本章要解决的基本问题是：在给定概率分布 $p(\mathbf{z})$ 的前提下，求某个函数 $f(\mathbf{z})$ 的期望。这里， $\mathbf{z}$ 的各个分量可以是离散变量或连续变量，或者二者的某种组合。于是，在连续变量的情况下，我们希望计算的期望为

$$\mathbb{E}[f] = \int f(\mathbf{z})p(\mathbf{z})d\mathbf{z} \quad (11.1)$$

在离散变量的情形中，该积分应替换为求和。对于单个连续变量，这在图 11.1 中做了示意性说明。我们将假设，这样的期望难以通过解析技术精确计算。

图 11.1 对函数 $f(z)$ 的示意图，其期望值需要相对于分布 $p(z)$ 来进行计算。



采样方法的一般思想是，从分布 $p(\mathbf{z})$ 中独立抽取一组样本 $\mathbf{z}^{(l)}$ （其中 $l = 1, \dots, L$ ）。这使得可以用有限和来近似 (11.1) 中的期望：

$$\hat{f} = \frac{1}{L} \sum_{l=1}^L f(\mathbf{z}^{(l)}) \quad (11.2)$$

只要样本 $\mathbf{z}^{(l)}$ 的抽取服从分布 $p(\mathbf{z})$ ，就有 $\mathbb{E}[\hat{f}] = \mathbb{E}[f]$ ，于是估计量 $\hat{f}$ 的均值是正确的。该估计量的方差为

$$\text{var}[\hat{f}] = \frac{1}{L} \mathbb{E}[(f - \mathbb{E}[f])^2] \quad (11.3)$$

其中 $\mathbb{E}[(f - \mathbb{E}[f])^2]$ 是函数 $f(\mathbf{z})$ 在分布 $p(\mathbf{z})$ 下的方差。值得强调的是：因此估计量的精度并不依赖于 $\mathbf{z}$ 的维度，从原则上讲，用相对较少的样本 $\mathbf{z}^{(l)}$ 就可以获得较高精度。在实际中，十到二十个独立样本就可能足以以足够精度估计一个期望。

然而，问题在于样本集合 $\{\mathbf{z}^{(l)}\}$ 可能不是独立的，因此有效样本数可能远小于表面上的样本数。此外，回到图 11.1，如果 $f(\mathbf{z})$ 在 $p(\mathbf{z})$ 较大的区域取值较小，而在 $p(\mathbf{z})$ 较小的区域取值较大，那么期望可能主要由小概率区域贡献，这就意味着需要相对较大的样本规模才能达到足够精度。

对于很多模型，联合分布 $p(\mathbf{z})$ 可以方便地用图模型表示。对于没有观测变量的有向图，如果在每个结点都能从其条件分布中采样，那么从联合分布中采样是直接的，可

以使用在第 8.1.2 节中略微讨论过的祖先采样方法。联合分布由下式给出：

$$p(\mathbf{z}) = \prod_{i=1}^M p(\mathbf{z}_i | \mathbf{pa}_i) \quad (11.4)$$

这里 $\mathbf{z}_i$ 是与结点 i 相关联的变量集合，而 $\mathbf{pa}_i$ 表示与结点 i 的父结点相关联的变量集合。为从联合分布中获得一个样本，我们按顺序 $\mathbf{z}_1, \dots, \mathbf{z}_M$ 对变量做一次遍历，从各自的条件分布 $p(\mathbf{z}_i | \mathbf{pa}_i)$ 中采样。由于在每一步，其父结点的取值都已经被实例化，因此这是总可以做到的。在对图做完一次遍历后，我们就得到了一组来自该联合分布的样本。

接下来考虑有向图中部分结点被观测为已知的情形。原则上，至少对于离散变量结点，可以将上述过程推广成所谓的逻辑采样（logic sampling）（Henrion, 1988），这可以看作第 11.1.4 节中将要讨论的重要性采样的一种特例。在每一步，当我们为某个已观测变量 z_i 采样出一个值时，将该样本值与观测值进行比较；若二者一致，则保留该样本值，算法继续对下一个变量进行采样；而若二者不一致，则丢弃迄今为止的整条样本，并从图中的第一个结点重新开始。这一算法可以从后验分布中正确采样，因为它等价于先从隐藏变量与数据变量的联合分布中采样，然后丢弃那些与观测数据不一致的样本（略有节省的是，一旦发现一个矛盾值，就不再继续完成整条联合采样）。然而，从后验中接受一个样本的总体概率会随着观测变量数目以及这些变量可能状态数的增加而迅速下降，因此这种方法在实践中很少使用。

在由无向图定义的概率分布的情形中，即使没有观测变量，也不存在一种单次遍历的采样策略可以从先验分布中采样。此时必须采用计算代价更高的方法，例如吉布斯采样，将在第 11.3 节讨论。

除了从条件分布中采样，我们有时还需要从边缘分布中采样。如果我们已经有一种方式可以从联合分布 $p(\mathbf{u}, \mathbf{v})$ 中采样，那么只需在每个样本中忽略掉 $\mathbf{v}$ 的取值，就可以得到来自边缘分布 $p(\mathbf{u})$ 的样本。

关于蒙特卡罗方法已有大量著作。从统计推断的角度看，特别值得参考的包括 Chen 等（2001）、Gamerman（1997）、Gilks 等（1996）、Liu（2001）、Neal（1996）以及 Robert 和 Casella（1999）。此外，还有一些综述文章，如 Besag 等（1995）、Brooks（1998）、Diaconis 和 Saloff-Coste（1998）、Jerrum 和 Sinclair（1996）、Neal（1993）、Tierney（1994）以及 Andrieu 等（2003），对统计推断中的采样方法提供了更多信息。关于马尔科夫链蒙特卡罗算法收敛性的诊断测试，可参见 Robert 和 Casella（1999）的总结；而关于在机器学习背景下使用采样方法的一些实践性指导，则可以参考 Bishop 和 Nabney（2008）。

11.1 基本采样算法

本节中，我们将讨论一些从给定分布中生成随机样本的简单策略。由于这些样本是由计算机算法生成的，它们事实上是伪随机数，也就是说是通过确定性方法计算出来的，但仍必须通过合适的随机性检验。关于生成这类数字存在若干细微问题（Press 等，1992），超出了本书的讨论范围。这里我们假设已经有一种算法可以生成在区间 $(0, 1)$ 上均匀分布的伪随机数，并且大多数软件环境都内置了这样的功能。

11.1.1 标准分布

我们首先考虑如何在已有一组均匀分布的随机数的前提下，从一些简单的非均匀分布中生成随机数。假设 z 在区间 $(0, 1)$ 上服从均匀分布，并用某个函数 $f(\cdot)$ 对 z 做变换得到 $y = f(z)$ 。那么 y 的分布由下式给出：


$$p(y) = p(z) \left| \frac{dz}{dy} \right| \quad (11.5)$$

在这里 $p(z) = 1$ 。我们的目标是选择函数 $f(z)$ ，使得变换后的 y 拥有我们所期望的特定分布 $p(y)$ 。将 (11.5) 式积分可得：

$$z = h(y) \equiv \int_{-\infty}^y p(\hat{y}) d\hat{y} \quad (11.6)$$

其中 $h(y)$ 是 $p(y)$ 的不定积分。因此 $y = h^{-1}(z)$ ，也就是说，我们需要用所需分布的不定积分的反函数来变换均匀分布的随机数。这在图 11.2 中给出了示意说明。

图 11.2 用于生成非均匀分布随机数的变换法的几何解释。 $h(y)$ 是目标分布 $p(y)$ 的不定积分。如果将均匀分布的随机变量 z 通过变换 $y = h^{-1}(z)$ 映射，则 y 将服从分布 $p(y)$ 。



例如，考虑指数分布

$$p(y) = \lambda \exp(-\lambda y) \quad (11.7)$$

其中 $0 \leq y < \infty$ 。此时 (11.6) 式中积分的下限为 0，因此 $h(y) = 1 - \exp(-\lambda y)$ 。由此可知，只要将均匀分布的变量 z 通过 $y = -\lambda^{-1} \ln(1 - z)$ 变换，就可以得到服从指数分布的 y 。

另一个可以应用这种变换方法的分布是柯西分布：

$$p(y) = \frac{1}{\pi} \frac{1}{1 + y^2}. \quad (11.8)$$


在这种情况下，不定积分的反函数可以用 $\tan$ 函数来表示。

该方法推广到多变量的情形也很直接，只是需要用到变量变换中的雅可比行列式，从而得到

$$p(y_1, \dots, y_M) = p(z_1, \dots, z_M) \left| \frac{\partial(z_1, \dots, z_M)}{\partial(y_1, \dots, y_M)} \right|. \quad (11.9)$$

作为变换方法的最后一个例子，我们考虑 Box-Muller 方法，用于从高斯分布中采样。首先，生成一对均匀分布的随机数 $z_1, z_2 \in (-1, 1)$ ，这可以通过将区间 $(0, 1)$ 上的均匀变量用变换 $z \rightarrow 2z - 1$ 进行线性映射来得到。然后我们丢弃所有不满足 $z_1^2 + z_2^2 \leq 1$

图 11.3 Box-Muller 方法用于生成高斯分布的随机数，其起始步骤是在单位圆内生成服从均匀分布的样本。



的数对。这样得到的是单位圆内部均匀分布的点，其联合分布为 $p(z_1, z_2) = 1/\pi$ ，如图 11.3 所示。接下来，对于每一对 z_1, z_2 ，我们计算

$$y_1 = z_1 \left(\frac{-2 \ln r^2}{r^2} \right)^{1/2} \quad (11.10)$$

$$y_2 = z_2 \left(\frac{-2 \ln r^2}{r^2} \right)^{1/2} \quad (11.11)$$

其中 $r^2 = z_1^2 + z_2^2$ 。此时 y_1 和 y_2 的联合分布为

$$\begin{aligned} p(y_1, y_2) &= p(z_1, z_2) \left| \frac{\partial(z_1, z_2)}{\partial(y_1, y_2)} \right| \\ &= \left[\frac{1}{\sqrt{2\pi}} \exp(-y_1^2/2) \right] \left[\frac{1}{\sqrt{2\pi}} \exp(-y_2^2/2) \right] \end{aligned} \quad (11.12)$$

因此 y_1 和 y_2 相互独立，且各自服从均值为 0、方差为 1 的高斯分布。

如果 y 服从均值为 0、方差为 1 的高斯分布，则 $\sigma y + \mu$ 将服从均值为 μ 、方差为 σ^2 的高斯分布。要生成具有均值为 μ 、协方差为 Σ 的多元高斯分布的向量值变量，可以使用 Cholesky 分解，将协方差矩阵写成 $\Sigma = \mathbf{L}\mathbf{L}^T$ (Press 等, 1992)。此时如果 $\mathbf{z}$ 是一个各分量互相独立且服从零均值、单位方差高斯分布的向量随机变量，则 $\mathbf{y} = \mu + \mathbf{L}\mathbf{z}$ 的均值为 μ ，协方差为 Σ 。

显然，变换技术的成功依赖于能够计算并求出所需分布不定积分的反函数。这种操作只对少数简单分布是可行的，因此我们需要转向其他方法以寻求更通用的策略。这里我们将讨论两种技术：拒绝采样和重要性采样。尽管它们主要局限于一维分布、因而不能直接应用到高维复杂问题，但在更通用的策略中，它们仍是重要的基础组成部分。

11.1.2 拒绝采样

拒绝采样框架允许我们在一定约束条件下，从相对复杂的分布中抽取样本。我们先考虑一维分布，并在之后讨论其向多维的扩展。


假设我们希望从某个分布 $p(z)$ 中采样，而该分布并非我们迄今讨论过的那些简单标准分布，且无法直接从 $p(z)$ 中采样。此外，假设我们通常情况下可以方便地在任意给定的 z 上计算 $p(z)$ ，精确到某个归一化常数 Z ，也就是说

$$p(z) = \frac{1}{Z_p} \tilde{p}(z) \quad (11.13)$$

其中 $\tilde{p}(z)$ 容易计算，但 Z_p 是未知的。为了应用拒绝采样，我们还需要一个较简单的分布 $q(z)$ ，有时称为提议分布（**proposal distribution**），并且我们能够容易地从 $q(z)$ 中采样。

接着我们引入一个常数 k ，其取值要满足 $kq(z) \geq \tilde{p}(z)$ 对所有 z 成立。函数 $kq(z)$ 称为比较函数，如图 11.4 所示。拒绝采样算法的每一步需要生成两个随机数。首先，从分布 $q(z)$ 中生成一个数 z_0 。然后从区间 $[0, kq(z_0)]$ 上的均匀分布中生成一个数 u_0 。该随机数对在函数 $kq(z)$ 曲线下方服从均匀分布。最后，如果 $u_0 > \tilde{p}(z_0)$ ，则拒绝该样本，否则保留 z_0 。因此，如果样本对落在图 11.4 所示灰色阴影区域内，则被拒绝。其余样本对在 $\tilde{p}(z)$ 曲线下方服从均匀分布，因此相应的 z 值就按照所需分布 $p(z)$ 分布。

图 11.4 在拒绝采样方法中，样本从一个简单分布 $q(z)$ 中抽取，如果它们落在未归一化分布 $\tilde{p}(z)$ 与缩放后的分布 $kq(z)$ 之间的灰色区域内，则会被拒绝。最终得到的样本服从分布 $p(z)$ ，它是 $\tilde{p}(z)$ 的归一化形式。



原始的 z 值是从分布 $q(z)$ 中生成的，然后以概率 $\tilde{p}(z)/kq(z)$ 接受这些样本。因此接受一个样本的概率为


$$\begin{aligned} p(\text{accept}) &= \int \{\tilde{p}(z)/kq(z)\}q(z)dz \\ &= \frac{1}{k} \int \tilde{p}(z)dz. \end{aligned} \quad (11.14)$$

因此，该方法拒绝样本的比例取决于未归一化分布 $\tilde{p}(z)$ 下的面积与曲线 $kq(z)$ 下的面积之比。由此可以看出，常数 k 应尽量取小，但仍要保证 $kq(z)$ 在任何地方都不小于 $\tilde{p}(z)$ 。

作为拒绝采样使用的一个示例，考虑从伽马分布中采样的问题：

$$\text{Gam}(z | a, b) = \frac{b^a z^{a-1} \exp(-bz)}{\Gamma(a)} \quad (11.15)$$

图 11.5 图中绿色曲线表示由式 (11.15) 给出的伽马分布，红色曲线表示经过缩放的柯西提议分布。可以先从柯西分布中采样，然后应用拒绝采样准则，从而得到来自伽马分布的样本。



当 $a > 1$ 时，该分布呈钟形，如图 11.5 所示。因此，合适的提议分布可以选用柯西分布 (11.8)，因为它同样呈钟形，并且我们可以用前面讨论过的变换方法从中采样。我

们需要对柯西分布做一点推广，以确保它在任何地方的取值都不小于伽马分布。可以通过对区间上均匀随机变量 y 做变换 $z = b \tan y + c$ 来实现，此时得到的随机数服从


$$q(z) = \frac{k}{1 + (z - c)^2/b^2} \quad (11.16)$$

当我们取 $c = a - 1$, $b^2 = 2a - 1$, 并选择常数 k 为满足 $kq(z) \geq \tilde{p}(z)$ 的最小值时，得到的比较函数如图 11.5 所示，此时拒绝率最小。

11.1.3 自适应拒绝采样

在许多希望使用拒绝采样的场合，确定一个合适的解析形式的包络分布 $q(z)$ 并不容易。另一种方法是基于对目标分布 $p(z)$ 的若干取值，在采样过程中动态地构造包络函数 (Gilks 和 Wild, 1992)。对于满足对数凹 (log concave) 条件的分布，也就是说当 $\ln p(z)$ 的导数是 z 的非增函数时，构造合适的包络函数尤其容易。这一构造过程在图 11.6 中做了示意性说明。

图 11.6 对于对数凹分布，可以利用在一组网格点处计算 $\ln p(z)$ 得到的切线来构造用于拒绝采样的包络函数。如果某个样本点被拒绝，则将其加入到网格点集合中，并用于进一步细化包络分布。



具体而言，我们在一些初始网格点上计算函数 $\ln p(z)$ 及其梯度，然后利用这些点处切线的交点构造包络函数。接下来，从包络分布中抽取一个样本值。这是直接的，因为包络分布的对数是许多线性函数的拼接，因此包络分布本身就是一个分段指数分布，其形式为


$$q(z) = k_i \lambda_i \exp \{-\lambda_i (z - z_{i-1})\} \quad z_{i-1} < z \leq z_i \quad (11.17)$$

一旦抽取出样本，我们便可以采用通常的拒绝准则。若该样本被接受，则可以视为来自目标分布的样本。而如果被拒绝，则将该样本点加入网格点集合，重新计算相应的切线，从而对包络函数进行精化。随着网格点数目的增多，包络函数就越来越接近目标分布 $p(z)$ ，拒绝概率也随之降低。

该算法存在一个变体，可以避免对导数的计算 (Gilks, 1992)。自适应拒绝采样框架还可以推广到非对数凹的分布，具体方法是在每次拒绝采样步骤之后，追加一个 Metropolis-Hastings 步骤 (将在第 11.2.2 节讨论)，从而得到自适应拒绝 Metropolis 采样 (adaptive rejection Metropolis sampling; Gilks 等, 1995)。

显然，要使拒绝采样在实践中有所价值，我们需要比较函数尽可能接近目标分布，从而将拒绝率保持在较低水平。现在让我们看看在高维空间中使用拒绝采样会发生什么。为便于说明，考虑一个略微理想化的问题：希望从零均值、多元高斯分布、协方

图 11.7 拒绝采样的示例说明，其中目标是从绿色曲线表示的高斯分布 $p(z)$ 中进行采样，通过使用同样为高斯分布的提议分布 $q(z)$ 来进行拒绝采样，其缩放后的形式 $kq(z)$ 由红色曲线表示。



差为 $\sigma_p^2 \mathbf{I}$ （其中 $\mathbf{I}$ 为单位阵）中采样，而我们采用的提议分布本身也是零均值、多元高斯分布、协方差为 $\sigma_q^2 \mathbf{I}$ 的形式。显然，为了存在一个 k 使得 $kq(z) \geq p(z)$ ，我们必须有 $\sigma_q^2 \geq \sigma_p^2$ 。在 D 维空间中，最优的 k 为 $k = (\sigma_q/\sigma_p)^D$ ，如图 11.7 中 $D = 1$ 的情形所示。接受率等于 $p(z)$ 与 $kq(z)$ 下方体积之比，因为这两个分布都已归一化，所以该比值就是 $1/k$ 。因此，接受率会随维数呈指数级下降。即便 σ_q 只比 σ_p 大 1%，在 $D = 1000$ 时，接受率也大约只有 $1/20,000$ 。在这个例子中，比较函数实际上已经很接近目标分布了；在更实际的场景中，目标分布往往是多峰且尖锐的，要找到一个好的提议分布与比较函数就更加困难了。更重要的是，接受率随维度指数级下降是拒绝采样的一般特性。尽管在一维或二维情形下拒绝采样仍然相当有用，但它并不适用于高维问题。然而，在高维空间的更复杂采样算法中，拒绝采样仍可以作为一个子程序发挥作用。

11.1.4 重要性采样

我们希望从复杂概率分布中采样的主要原因之一，是为了计算类似于 (11.1) 形式的期望。重要性采样技术提供了一个直接近似期望的框架，但它本身并不提供从分布 $p(\mathbf{z})$ 中采样的机制。


(11.2) 式中的有限和近似依赖于能够从分布 $p(\mathbf{z})$ 中抽样。假设直接从 $p(\mathbf{z})$ 中采样在实际中不可行，但我们可以对任意给定的 $\mathbf{z}$ 容易地计算 $p(\mathbf{z})$ 。一种过于简单的策略是，将 $\mathbf{z}$ 所在空间离散成均匀网格，并将积分近似成如下求和形式：

$$\mathbb{E}[f] \simeq \sum_{l=1}^L p(\mathbf{z}^{(l)}) f(\mathbf{z}^{(l)}) . \quad (11.18)$$

显而易见的问题是，求和项的数目会随 $\mathbf{z}$ 的维度呈指数增长。此外，如前所述，我们感兴趣的概率分布往往大部分质量集中在 $\mathbf{z}$ 空间中相对较小的区域，因此均匀采样效率极低：在高维问题中，只有极少数样本会对求和结果产生显著贡献。我们真正希望的是，让采样点落在 $p(\mathbf{z})$ 较大的区域，或者更理想地，落在 $p(\mathbf{z})f(\mathbf{z})$ 较大的区域。

与拒绝采样类似，重要性采样也是基于一个提议分布 $q(\mathbf{z})$ ，从该分布中容易抽样，如图 11.8 所示。然后，我们可以将期望写成从 $q(\mathbf{z})$ 中抽样得到的样本 $\{\mathbf{z}^{(l)}\}$ 上的有限

图 11.8 重要性采样用于解决在难以直接从分布 $p(z)$ 中采样的情况下，计算函数 $f(z)$ 关于该分布的期望值的问题。其做法是从一个更简单的分布 $q(z)$ 中抽取样本 $\{z^{(l)}\}$ ，并在求和时用比值 $p(z^{(l)})/q(z^{(l)})$ 对相应项进行加权。



和：

$$\begin{aligned}
 \mathbb{E}[f] &= \int f(\mathbf{z})p(\mathbf{z})d\mathbf{z} \\
 &= \int f(\mathbf{z})\frac{p(\mathbf{z})}{q(\mathbf{z})}q(\mathbf{z})d\mathbf{z} \\
 &\simeq \frac{1}{L} \sum_{l=1}^L \frac{p(\mathbf{z}^{(l)})}{q(\mathbf{z}^{(l)})} f(\mathbf{z}^{(l)}) .
 \end{aligned} \tag{11.19}$$

量 $r_l = p(\mathbf{z}^{(l)})/q(\mathbf{z}^{(l)})$ 被称为重要性权重 (importance weights)，它们用来修正从“错误”分布中采样所引入的偏差。注意，与拒绝采样不同的是，所有生成的样本都被保留。

在许多情形下，分布 $p(\mathbf{z})$ 只能在一个归一化常数内求值，即 $p(\mathbf{z}) = \tilde{p}(\mathbf{z})/Z_p$ ，其中 $\tilde{p}(\mathbf{z})$ 易于计算，但 Z_p 未知。同样，我们可能想使用一个具有同样性质的重要性采样分布 $q(\mathbf{z}) = \tilde{q}(\mathbf{z})/Z_q$ 。此时有

$$\begin{aligned}
 \mathbb{E}[f] &= \int f(\mathbf{z})p(\mathbf{z})d\mathbf{z} \\
 &= \frac{Z_q}{Z_p} \int f(\mathbf{z})\frac{\tilde{p}(\mathbf{z})}{\tilde{q}(\mathbf{z})}q(\mathbf{z})d\mathbf{z} \\
 &\simeq \frac{Z_q}{Z_p} \frac{1}{L} \sum_{l=1}^L \tilde{r}_l f(\mathbf{z}^{(l)})
 \end{aligned} \tag{11.20}$$

其中 $\tilde{r}_l = \tilde{p}(\mathbf{z}^{(l)})/\tilde{q}(\mathbf{z}^{(l)})$ 。我们还可以使用同一组样本来估计比值 Z_p/Z_q ，得到

$$\begin{aligned}
 \frac{Z_p}{Z_q} &= \frac{1}{Z_q} \int \tilde{p}(\mathbf{z})d\mathbf{z} = \int \frac{\tilde{p}(\mathbf{z})}{\tilde{q}(\mathbf{z})}q(\mathbf{z})d\mathbf{z} \\
 &\simeq \frac{1}{L} \sum_{l=1}^L \tilde{r}_l
 \end{aligned} \tag{11.21}$$

于是

$$\mathbb{E}[f] \simeq \sum_{l=1}^L w_l f(\mathbf{z}^{(l)}) \tag{11.22}$$

其中我们定义

$$w_l = \frac{\tilde{r}_l}{\sum_m \tilde{r}_m} = \frac{\tilde{p}(\mathbf{z}^{(l)})/\tilde{q}(\mathbf{z}^{(l)})}{\sum_m \tilde{p}(\mathbf{z}^{(m)})/\tilde{q}(\mathbf{z}^{(m)})} . \tag{11.23}$$

与拒绝采样类似,重要性采样方法的成功关键取决于采样分布 $q(\mathbf{z})$ 与目标分布 $p(\mathbf{z})$ 的匹配程度。如果像通常那样, $p(\mathbf{z})f(\mathbf{z})$ 变化剧烈, 且相当一部分质量集中在 $\mathbf{z}$ 空间的较小区域内, 那么重要性权重集合 $\{r_l\}$ 可能会被少数取值很大的权重主导, 而其余权重相对微不足道。因此, 有效样本数可能远小于表面上的样本数 L 。如果所有样本都未落在 $p(\mathbf{z})f(\mathbf{z})$ 较大的区域内, 问题则更加严重。在这种情况下, r_l 与 $r_l f(\mathbf{z}^{(l)})$ 的表观方差可能很小, 但对期望的估计却可能严重偏差。由此可见, 重要性采样方法的一个重要缺点是: 有可能在没有任何诊断提示的情况下给出任意错误的结果。这也突出了对采样分布 $q(\mathbf{z})$ 的一个关键要求, 即它在 $p(\mathbf{z})$ 可能显著的区域不能太小甚至为 0。

对于用图模型定义分布, 我们可以通过多种方式应用重要性采样。对于离散变量, 一种简单的方法称为均匀采样 (uniform sampling)。有向图的联合分布由 (11.4) 式给出。从联合分布中生成一个样本的做法是: 首先将所有在证据集中的变量 $\mathbf{z}_i$ 置为它们的观测值, 然后对每一个剩余变量, 在其可能取值空间上从均匀分布中独立采样。要计算与样本 $\mathbf{z}^{(l)}$ 对应的权重, 我们注意到采样分布 $\tilde{q}(\mathbf{z})$ 在所有 $\mathbf{z}$ 的可行取值上是均匀的, 而 $\tilde{p}(\mathbf{z} | \mathbf{x}) = \tilde{p}(\mathbf{z})$, 其中 $\mathbf{x}$ 表示观测变量子集, 这里的等号成立是因为每一个生成的样本 $\mathbf{z}$ 都与证据一致。于是权重 r_l 便与 $p(\mathbf{z})$ 成正比。注意, 这些变量可以以任意顺序进行采样。如果后验分布与均匀分布相差甚远 (实际中常常如此), 这一方法的表现会非常糟糕。

对这一方法的一种改进称为似然加权采样 (likelihood weighted sampling) (Fung 和 Chang, 1990; Shachter 和 Peot, 1990), 它基于变量的祖先式采样。对于每个变量, 如果它在证据集中, 则直接赋予其观测值; 否则, 就从条件分布 $p(\mathbf{z}_i | \mathbf{pa}_i)$ 中采样, 其中条件变量取为已采样的当前值。对样本 $\mathbf{z}$ 的权重由下式给出:

$$r(\mathbf{z}) = \prod_{\mathbf{z}_i \notin \mathbf{e}} \frac{p(\mathbf{z}_i | \mathbf{pa}_i)}{p(\mathbf{z}_i | \mathbf{pa}_i)} \prod_{\mathbf{z}_i \in \mathbf{e}} \frac{p(\mathbf{z}_i | \mathbf{pa}_i)}{1} = \prod_{\mathbf{z}_i \in \mathbf{e}} p(\mathbf{z}_i | \mathbf{pa}_i). \quad (11.24)$$

在此基础上, 还可以进一步推广为自重要性采样 (self-importance sampling) (Shachter 和 Peot, 1990), 其中重要性采样分布会不断更新, 以反映当前对后验分布的估计。

11.1.5 采样-重要性-重采样

在第 11.1.2 节讨论的拒绝采样方法中, 其成功在某种程度上依赖于能够确定一个合适的常数 k 。对于很多分布对 $p(\mathbf{z})$ 与 $q(\mathbf{z})$ 来说, 要找出这样的 k 非常不现实, 因为只要选出的 k 足够大以保证对目标分布 $p(\mathbf{z})$ 的包络约束, 就会导致不可接受的低接受率。

与拒绝采样类似, 采样-重要性-重采样 (sampling-importance-resampling, SIR) 方法同样会使用采样分布 $q(\mathbf{z})$, 但它避免了必须确定常数 k 的问题。该方案分为两个阶段: 第一阶段, 从 $q(\mathbf{z})$ 中抽取 L 个样本 $\mathbf{z}^{(1)}, \dots, \mathbf{z}^{(L)}$ 。在第二阶段, 利用 (11.23) 式构造权重 $w_1, \dots, w_L$ 。最后, 从离散分布 $(\mathbf{z}^{(1)}, \dots, \mathbf{z}^{(L)})$ 中再抽取第二批 L 个样本, 其抽取概率由权重 $(w_1, \dots, w_L)$ 给出。

所得的 L 个样本仅近似地服从分布 $p(\mathbf{z})$, 不过当 $L \rightarrow \infty$ 时, 样本分布会收敛为目

标分布。为说明这一点，考虑一维情况。重采样得到的样本的累积分布为

$$\begin{aligned} p(z \leq a) &= \sum_{l: z^{(l)} \leq a} w_l \\ &= \frac{\sum_l I(z^{(l)} \leq a) \tilde{p}(z^{(l)})/q(z^{(l)})}{\sum_l \tilde{p}(z^{(l)})/q(z^{(l)})} \end{aligned} \quad (11.25)$$

其中 $I(\cdot)$ 为指示函数（若其参数为真则取 1，否则取 0）。对 $L \rightarrow \infty$ 取极限，在假设分布满足一定正则性条件的前提下，可以将求和替换为对原始采样分布 $q(z)$ 加权的积分：

$$\begin{aligned} p(z \leq a) &= \frac{\int I(z \leq a) \{\tilde{p}(z)/q(z)\} q(z) dz}{\int \{\tilde{p}(z)/q(z)\} q(z) dz} \\ &= \frac{\int I(z \leq a) \tilde{p}(z) dz}{\int \tilde{p}(z) dz} \\ &= \int I(z \leq a) p(z) dz \end{aligned} \quad (11.26)$$

这正是 $p(z)$ 的累积分布函数。同样可以看出，这一过程中并不需要知道 $p(z)$ 的归一化常数。

对于有限的 L 值和给定的初始样本集合，重采样得到的样本只是近似地来自于目标分布。与拒绝采样一样，当采样分布 $q(\mathbf{z})$ 越接近目标分布 $p(\mathbf{z})$ 时，这种近似就会越好。当 $q(\mathbf{z}) = p(\mathbf{z})$ 时，初始样本 $(z^{(1)}, \dots, z^{(L)})$ 本身就具有目标分布，而此时权重 $w_l = 1/L$ ，所以重采样的样本自然也具有目标分布。

如果我们需要计算 $p(z)$ 下的矩，那么可以直接利用原始样本及其权重来进行估计，因为

$$\begin{aligned} \mathbb{E}[f(\mathbf{z})] &= \int f(\mathbf{z}) p(\mathbf{z}) d\mathbf{z} \\ &= \frac{\int f(\mathbf{z}) [\tilde{p}(\mathbf{z})/q(\mathbf{z})] q(\mathbf{z}) d\mathbf{z}}{\int [\tilde{p}(\mathbf{z})/q(\mathbf{z})] q(\mathbf{z}) d\mathbf{z}} \\ &\simeq \sum_{l=1}^L w_l f(\mathbf{z}^{(l)}) . \end{aligned} \quad (11.27)$$

11.1.6 采样与 EM 算法

除了为贝叶斯框架的直接实现提供机制之外，蒙特卡罗方法在频率派范式中也能发挥作用，例如用于求解最大似然估计。特别地，在 E-STEP 无法解析完成的模型中，采样方法可以用来近似 EM 算法的 E-STEP。考虑一个具有隐藏变量 $\mathbf{Z}$ 、可见（观测）变量 $\mathbf{X}$ 以及参数向量 θ 的模型。在 M-STEP 中要对 θ 优化的是完全数据对数似然的期望，

其形式为

$$Q(\boldsymbol{\theta}, \boldsymbol{\theta}^{\text{old}}) = \int p(\mathbf{Z} | \mathbf{X}, \boldsymbol{\theta}^{\text{old}}) \ln p(\mathbf{Z}, \mathbf{X} | \boldsymbol{\theta}) d\mathbf{Z} \quad (11.28)$$

我们可以使用采样方法将该积分用从当前后验分布 $p(\mathbf{Z} | \mathbf{X}, \boldsymbol{\theta}^{\text{old}})$ 中抽取的样本 $\{\mathbf{Z}^{(l)}\}$ 上的有限和来近似:

$$Q(\boldsymbol{\theta}, \boldsymbol{\theta}^{\text{old}}) \simeq \frac{1}{L} \sum_{l=1}^L \ln p(\mathbf{Z}^{(l)}, \mathbf{X} | \boldsymbol{\theta}) \quad (11.29)$$

然后在 M-STEP 中像往常一样对 Q 函数进行优化。这一过程被称为蒙特卡罗 EM (Monte Carlo EM) 算法。

当我们对参数 $\boldsymbol{\theta}$ 定义了先验分布 $p(\boldsymbol{\theta})$ 时, 将上述方法推广到寻找后验分布峰值 (即 MAP 估计) 是直接的, 只需在执行 M-STEP 之前, 将 $\ln p(\boldsymbol{\theta})$ 加到 $Q(\boldsymbol{\theta}, \boldsymbol{\theta}^{\text{old}})$ 中即可。

蒙特卡罗 EM 算法的一个特例称为随机 EM (stochastic EM), 它出现在有限混合模型的情形中, 并且在每次 E-STEP 中只抽取一个样本。此时, 潜变量 $\mathbf{Z}$ 指示哪一个混合分量对每个数据点负责生成。在 E-STEP 中, 从后验分布 $p(\mathbf{Z} | \mathbf{X}, \boldsymbol{\theta}^{\text{old}})$ (其中 $\mathbf{X}$ 为数据集) 中抽取一个 $\mathbf{Z}$ 的样本, 这实际上相当于对每个数据点进行一次硬分配, 将其归入某个具体混合分量。在 M-STEP 中, 使用这一抽样近似的后验分布, 以通常方式更新模型参数。

现在假设我们从最大似然方法转向完全贝叶斯的处理方式, 希望从参数向量 $\boldsymbol{\theta}$ 的后验分布中采样。原则上, 我们希望从联合后验 $p(\boldsymbol{\theta}, \mathbf{Z} | \mathbf{X})$ 中抽样, 但我们假定这在计算上较为困难。进一步假设, 从完全数据参数后验分布 $p(\boldsymbol{\theta} | \mathbf{Z}, \mathbf{X})$ 中采样则相对容易。这样就启发了数据增强 (data augmentation) 算法, 它在两个步骤之间交替迭代: 即 I-STEP 插补步, imputation step, 对应于 E-STEP) 和 P-STEP (后验步, posterior STEP, 对应于 M-STEP)。

IP 算法

I-STEP. 我们希望从 $p(\mathbf{Z} | \mathbf{X})$ 中采样, 但无法直接做到。因此注意到如下关系

$$p(\mathbf{Z} | \mathbf{X}) = \int p(\mathbf{Z} | \boldsymbol{\theta}, \mathbf{X}) p(\boldsymbol{\theta} | \mathbf{X}) d\boldsymbol{\theta} \quad (11.30)$$

因此, 对 $l = 1, \dots, L$, 我们首先从当前对 $p(\boldsymbol{\theta} | \mathbf{X})$ 的估计中采样得到 $\boldsymbol{\theta}^{(l)}$, 然后利用它从 $p(\mathbf{Z} | \boldsymbol{\theta}^{(l)}, \mathbf{X})$ 中采样得到 $\mathbf{Z}^{(l)}$ 。

P-STEP. 给定关系

$$p(\boldsymbol{\theta} | \mathbf{X}) = \int p(\boldsymbol{\theta} | \mathbf{Z}, \mathbf{X}) p(\mathbf{Z} | \mathbf{X}) d\mathbf{Z} \quad (11.31)$$

我们使用 I-STEP 中得到的样本集合 $\{\mathbf{Z}^{(l)}\}$ 来计算关于 $\boldsymbol{\theta}$ 的后验分布的修正估计:

$$p(\boldsymbol{\theta} | \mathbf{X}) \simeq \frac{1}{L} \sum_{l=1}^L p(\boldsymbol{\theta} | \mathbf{Z}^{(l)}, \mathbf{X}) \quad (11.32)$$

根据假设, 在 I-STEP 中可以从这一近似中进行可行的采样。

需要注意的是，我们在这里对参数 θ 与隐藏变量 $\mathbf{z}$ 做了一个（有些人人为的）区分。从现在起，我们将模糊这种区分，只专注于如何从给定的后验分布中进行采样的问题。

11.2 马尔科夫链蒙特卡罗方法

在上一节中，我们讨论了用拒绝采样与重要性采样来求函数期望的策略，并看到它们存在严重局限性，尤其是在高维空间中。因此，本节我们转向一个非常通用且强大的框架——马尔科夫链蒙特卡罗方法（Markov chain Monte Carlo, MCMC），它可以对一大类分布进行采样，并且在样本空间维度升高时仍能很好地扩展。马尔科夫链蒙特卡罗方法最初起源于物理学（Metropolis and Ulam, 1949），直到 20 世纪 80 年代末才开始在统计学领域产生重要影响。

与拒绝采样和重要性采样一样，我们仍然要从某个提议分布中采样。但这一次，我们保留当前状态 $\mathbf{z}^{(\tau)}$ 的记录，并且提议分布 $q(\mathbf{z} | \mathbf{z}^{(\tau)})$ 依赖于该当前状态，因此样本序列 $\mathbf{z}^{(1)}, \mathbf{z}^{(2)}, \dots$ 构成一条马尔科夫链。同样，如果记 $p(\mathbf{z}) = \tilde{p}(\mathbf{z})/Z_p$ ，则假设我们可以对任意给定的 $\mathbf{z}$ 容易地计算出 $\tilde{p}(\mathbf{z})$ ，但 Z_p 的值可能未知。提议分布本身的选择应足够简单，以便可以直接从中采样。在算法的每一轮中，我们从提议分布中生成一个候选样本 $\mathbf{z}^*$ ，然后按照某个合适的准则来接受该样本。

在基本的 Metropolis 算法（Metropolis et al., 1953）中，我们假设提议分布是对称的，即对所有 $\mathbf{z}_A$ 与 $\mathbf{z}_B$ ，都有 $q(\mathbf{z}_A | \mathbf{z}_B) = q(\mathbf{z}_B | \mathbf{z}_A)$ 。此时，以如下概率接受候选样本：


$$A(\mathbf{z}^*, \mathbf{z}^{(\tau)}) = \min\left(1, \frac{\tilde{p}(\mathbf{z}^*)}{\tilde{p}(\mathbf{z}^{(\tau)})}\right) \quad (11.33)$$

这可以通过在区间 $(0, 1)$ 上生成一个均匀分布的随机数 u 并在 $A(\mathbf{z}^*, \mathbf{z}^{(\tau)}) > u$ 时接受候选样本来实现。注意，如果从 $\mathbf{z}^{(\tau)}$ 到 $\mathbf{z}^*$ 的跃迁使 $p(\mathbf{z})$ 的取值增大，那么该候选点必然被接受。

如果候选样本被接受，则令 $\mathbf{z}^{(\tau+1)} = \mathbf{z}^*$ ；否则，丢弃候选点 $\mathbf{z}^*$ ，并令 $\mathbf{z}^{(\tau+1)} = \mathbf{z}^{(\tau)}$ ，然后再从分布 $q(\mathbf{z} | \mathbf{z}^{(\tau+1)})$ 中抽取新的候选样本。这与拒绝采样不同，后者在拒绝样本后只是简单地丢弃它们。在 Metropolis 算法中，当候选点被拒绝时，上一时刻的样本会再次被纳入最终的样本列表，从而导致样本中出现多次重复。实际实现时，我们通常只保留每个样本的一份拷贝，并附带一个整数权重来记录该状态出现了多少次。我们将看到，只要 $q(\mathbf{z}_A | \mathbf{z}_B)$ 对任意 $\mathbf{z}_A$ 和 $\mathbf{z}_B$ 都为正（这是充分但非必要条件），当 $\tau \rightarrow \infty$ 时， $\mathbf{z}^{(\tau)}$ 的分布就会收敛到 $p(\mathbf{z})$ 。不过需要强调的是，序列 $\mathbf{z}^{(1)}, \mathbf{z}^{(2)}, \dots$ 并不是一组来自 $p(\mathbf{z})$ 的相互独立样本，因为相邻样本之间高度相关。如果希望获得相互独立的样本，可以丢弃序列中的大部分样本，只保留每隔 M 个样本中的一个。当 M 足够大时，保留下来的样本在实际应用中可以视为独立。图 11.9 用一个简单例子展示了在二维高斯分布上使用 Metropolis 算法采样的情形，其中提议分布为一个各向同性高斯分布。

进一步理解马尔科夫链蒙特卡罗算法的性质，可以考察一个具体示例，即简单的随

图 11.9 使用 Metropolis 算法从一个高斯分布中采样的简单示意图，该高斯分布的一标准差等高线由椭圆表示。提议分布是一个各向同性的高斯分布，其标准差为 0.2。被接受的步长用绿色线段表示，被拒绝的步长用红色线段表示。共生成了 150 个候选样本，其中有 43 个被拒绝。



机游走。设状态空间 $\mathbf{z}$ 为整数，其跃迁概率为

$$p(z^{(\tau+1)} = z^{(\tau)}) = 0.5 \quad (11.34)$$

$$p(z^{(\tau+1)} = z^{(\tau)} + 1) = 0.25 \quad (11.35)$$

$$p(z^{(\tau+1)} = z^{(\tau)} - 1) = 0.25 \quad (11.36)$$

其中 $z^{(\tau)}$ 表示第 τ 步时的状态。如果初始状态为 $z^{(1)} = 0$ ，那么由对称性可知在任意时刻 τ 的期望状态也为 0，即 $\mathbb{E}[z^{(\tau)}] = 0$ ，同时容易看出 $\mathbb{E}[(z^{(\tau)})^2] = \tau/2$ 。也就是说，在经过 τ 步之后，随机游走平均移动的距离与 $\sqrt{\tau}$ 成正比。这种平方根依赖关系是随机游走行为的典型特征，说明随机游走在探索状态空间时效率很低。正如我们将看到的，在设计马尔科夫链蒙特卡罗方法时，一个核心目标就是避免随机游走式的行为。

11.2.1 马尔科夫链

在进一步深入讨论马尔科夫链蒙特卡罗方法之前，先详细考察一些关于马尔科夫链的一般性质，尤其是：在何种条件下，一条马尔科夫链会收敛到我们所希望的分布。一个一阶马尔科夫链被定义为随机变量序列 $\mathbf{z}^{(1)}, \dots, \mathbf{z}^{(M)}$ ，它满足如下条件独立性质：对 $m \in \{1, \dots, M-1\}$ ，

$$p(\mathbf{z}^{(m+1)} | \mathbf{z}^{(1)}, \dots, \mathbf{z}^{(m)}) = p(\mathbf{z}^{(m+1)} | \mathbf{z}^{(m)}) . \quad (11.37)$$

当然，这可以表示为一条链形结构的有向图，其示例如图 8.38 所示。我们可以通过给定初始变量的分布 $p(\mathbf{z}^{(0)})$ ，以及后续各变量的条件分布（即跃迁概率）来刻画这一马尔科夫链，其中 $T_m(\mathbf{z}^{(m)}, \mathbf{z}^{(m+1)}) \equiv p(\mathbf{z}^{(m+1)} | \mathbf{z}^{(m)})$ 若对所有 m 的跃迁概率相同，则称该马尔科夫链为齐次的（homogeneous）。

对于特定变量的边际概率可以用链中前一个变量的边缘分布表示为

$$p(\mathbf{z}^{(m+1)}) = \sum_{\mathbf{z}^{(m)}} p(\mathbf{z}^{(m+1)} | \mathbf{z}^{(m)}) p(\mathbf{z}^{(m)}) . \quad (11.38)$$

若一个分布在链的每一步变换后都保持不变，则称它对该马尔科夫链而言是一个不变分布（invariant）或平稳分布（stationary）。因此，对于跃迁概率为 $T(\mathbf{z}', \mathbf{z})$ 的齐次马尔科夫链，若

$$p^*(\mathbf{z}) = \sum_{\mathbf{z}'} T(\mathbf{z}', \mathbf{z}) p^*(\mathbf{z}') \quad (11.39)$$

则分布 $p^*(\mathbf{z})$ 为其平稳分布。注意，一个给定的马尔科夫链可能存在多个不变分布。例如，如果跃迁概率为恒等变换，则任何分布都是不变的。

为保证所需分布 $p(\mathbf{z})$ 是不变分布，一个充分（但非必要）条件是选择跃迁概率满足所谓的详细平衡（detailed balance）条件：

$$p^*(\mathbf{z}) T(\mathbf{z}, \mathbf{z}') = p^*(\mathbf{z}') T(\mathbf{z}', \mathbf{z}) \quad (11.40)$$

其中 $p^*(\mathbf{z})$ 是特定的目标分布。可以很容易地看出，若跃迁概率相对于某个分布满足详细平衡，则它会保持该分布不变，因为

$$\sum_{\mathbf{z}'} p^*(\mathbf{z}') T(\mathbf{z}', \mathbf{z}) = \sum_{\mathbf{z}'} p^*(\mathbf{z}) T(\mathbf{z}, \mathbf{z}') = p^*(\mathbf{z}) \sum_{\mathbf{z}'} p(\mathbf{z}' | \mathbf{z}) = p^*(\mathbf{z}). \quad (11.41)$$

满足详细平衡条件的马尔科夫链被称为可逆的（reversible）。

我们的目标是利用马尔科夫链从给定分布中采样。若我们构造一条使所需分布成为其不变分布的马尔科夫链，这一目标便可实现。然而，我们还需要一个额外的条件：当 $m \rightarrow \infty$ 时， $p(\mathbf{z}^{(m)})$ 必须收敛到所需的不变分布 $p^*(\mathbf{z})$ ，且这一过程与初始分布 $p(\mathbf{z}^{(0)})$ 的选择无关。这个性质称为遍历性（ergodicity），此时的不变分布称为平衡分布（equilibrium distribution）。显然，一条遍历的马尔科夫链至多只有一个平衡分布。可以证明，齐次马尔科夫链在对不变分布与跃迁概率施加较弱条件的情况下是遍历的（Neal, 1993）。

在实践中，我们经常用一组“基”跃迁 $B_1, \dots, B_K$ 来构造跃迁概率。这可以通过如下混合分布来实现：

$$T(\mathbf{z}', \mathbf{z}) = \sum_{k=1}^K \alpha_k B_k(\mathbf{z}', \mathbf{z}) \quad (11.42)$$

其中混合系数 $\alpha_1, \dots, \alpha_K$ 满足 $\alpha_k \geq 0$ 且 $\sum_k \alpha_k = 1$ 。另外，也可以通过连续应用这些基跃迁的方式将它们组合起来，从而得到

$$T(\mathbf{z}', \mathbf{z}) = \sum_{\mathbf{z}_1} \dots \sum_{\mathbf{z}_{K-1}} B_1(\mathbf{z}', \mathbf{z}_1) \dots B_{K-1}(\mathbf{z}_{K-2}, \mathbf{z}_{K-1}) B_K(\mathbf{z}_{K-1}, \mathbf{z}). \quad (11.43)$$

如果某一分布对每一个基跃迁 B_k 都是不变的，那么它显然也会对 (11.42) 或 (11.43) 给出的任一 $T(\mathbf{z}', \mathbf{z})$ 不变。对于混合形式 (11.42)，若每一个基跃迁都满足详细平衡，则混合跃迁 T 也将满足详细平衡。而对 (11.43) 的组合形式，这个性质则不一定成立，不过可以通过对基跃迁应用顺序的对称化（例如 $B_1, B_2, \dots, B_K, B_K, \dots, B_2, B_1$ ）来恢复详细平衡。一个常见的复合跃迁例子是：每个基跃迁只改变变量的一个子集。

11.2.2 Metropolis-Hastings 算法

前面我们介绍了基本的 Metropolis 算法，但尚未证明它确实能从所需分布中采样。在给出证明之前，先讨论一个推广形式，即 Metropolis-Hastings 算法 (Hastings, 1970)，它对应于提议分布不再是自变量的对称函数的情形。具体来说，在算法的第 τ 步中，当当前状态为 $\mathbf{z}^{(\tau)}$ 时，我们从分布 $q_k(\mathbf{z} | \mathbf{z}^{(\tau)})$ 中采样得到 $\mathbf{z}^*$ ，然后以概率 $A_k(\mathbf{z}^*, \mathbf{z}^{(\tau)})$ 接受它，其中

$$A_k(\mathbf{z}^*, \mathbf{z}^{(\tau)}) = \min \left(1, \frac{\tilde{p}(\mathbf{z}^*) q_k(\mathbf{z}^{(\tau)} | \mathbf{z}^*)}{\tilde{p}(\mathbf{z}^{(\tau)}) q_k(\mathbf{z}^* | \mathbf{z}^{(\tau)})} \right) \quad (11.44)$$

这里 k 用于标记正在考虑的跃迁集合中的某个成员。再次注意，判断是否接受的准则无需知道分布 $p(\mathbf{z}) = \tilde{p}(\mathbf{z})/Z_p$ 中归一化常数 Z_p 的具体取值。对称提议分布的情形下，Metropolis-Hastings 准则 (11.44) 会退化为标准的 Metropolis 准则 (11.33)。

我们可以通过验证详细平衡条件 (11.40) 是否成立，来说明 $p(\mathbf{z})$ 是由 Metropolis-Hastings 算法定义的马尔科夫链的不变分布。利用 (11.44)，有

$$\begin{aligned} p(\mathbf{z}) q_k(\mathbf{z} | \mathbf{z}') A_k(\mathbf{z}', \mathbf{z}) &= \min(p(\mathbf{z}) q_k(\mathbf{z} | \mathbf{z}'), p(\mathbf{z}') q_k(\mathbf{z}' | \mathbf{z})) \\ &= \min(p(\mathbf{z}') q_k(\mathbf{z}' | \mathbf{z}), p(\mathbf{z}) q_k(\mathbf{z} | \mathbf{z}')) \\ &= p(\mathbf{z}') q_k(\mathbf{z}' | \mathbf{z}) A_k(\mathbf{z}, \mathbf{z}') \end{aligned} \quad (11.45)$$

这正是所需的详细平衡形式。


提议分布的具体选择会对算法的性能产生显著影响。对于连续状态空间，一个常见的选择是以当前状态为中心的高斯分布，这在选择其方差参数时带来了重要的权衡。如果方差较小，则被接受的跃迁比例会很高，但在状态空间中的前进形式会变成缓慢的随机游走，导致很长的相关时间；而若方差参数较大，则拒绝率会很高，因为在我们考虑的这类复杂问题中，许多提议状态的 $p(\mathbf{z})$ 值都很低。设多元分布 $p(\mathbf{z})$ 在各分量之间存在强相关性，如图 11.10 所示。提议分布的尺度 ρ 应尽可能大，同时又不能导致过高的拒绝率。这表明 ρ 应与最小长度尺度 $\sigma_{\min}$ 同阶。随后，系统会沿着延展方向通过随机游走探索分布，因此，从初始状态达到一个几乎独立的新状态所需的步数大约为 $(\sigma_{\max}/\sigma_{\min})^2$ 。实际上在二维情形中，尽管随着 ρ 的增大拒绝率提高了，但被接受的那些跃迁步长也更大，二者在一定程度上相互抵消；更一般地，对于多元高斯分布，获得相互独立样本所需的步数规模大致为 $(\sigma_{\max}/\sigma_2)^2$ ，其中 σ_2 为次小的标准差 (Neal, 1993)。撇开这些细节不谈，如果分布在不同方向上的变化尺度差异很大，那么 Metropolis-Hastings 算法的收敛速度就会非常慢。

11.3 吉布斯采样

吉布斯采样 (Gibbs sampling; Geman and Geman, 1984) 是一种简单且适用范围很广的马尔科夫链蒙特卡罗算法，可以看作是 Metropolis-Hastings 算法的一个特例。

考虑我们希望从分布 $p(\mathbf{z}) = p(z_1, \dots, z_M)$ 中采样，并假设已经为该马尔科夫链选择了一个初始状态。吉布斯采样的每一步都涉及用某个变量在其余变量取值条件下的

图 11.10 使用 Metropolis-Hastings 算法，通过各向同性高斯提议分布（蓝色圆）从一个相关的多变量高斯分布（红色椭圆）中采样的示意图，该目标分布在不同方向上具有差异很大的标准差。为了保持较低的拒绝率，提议分布的尺度 ρ 应当与最小标准差 $\sigma_{\min}$ 同一量级，这将导致随机游走行为，其中近似相互独立的状态之间所需的步数数量级为 $(\sigma_{\max}/\sigma_{\min})^2$ ，其中 $\sigma_{\max}$ 是最大的标准差。



条件分布来重新采样该变量的值。也就是说，我们用从条件分布 $p(z_i | \mathbf{z}_{\setminus i})$ 中抽取的新值来替换 z_i ，其中 z_i 是向量 $\mathbf{z}$ 的第 i 个分量，而 $\mathbf{z}_{\setminus i}$ 表示 $z_1, \dots, z_M$ 中除 z_i 外的所有变量。如此操作要么按某个固定顺序循环更新各变量，要么在每一步中从某个分布中随机选择要更新的变量。

例如，假设我们有一个三维分布 $p(z_1, z_2, z_3)$ ，在算法的第 τ 步时，当前状态为 $z_1^{(\tau)}, z_2^{(\tau)}, z_3^{(\tau)}$ 。首先，我们用从条件分布

$$p(z_1 | z_2^{(\tau)}, z_3^{(\tau)}) \quad (11.46)$$

中采样得到的新值 $z_1^{(\tau+1)}$ 来替换 $z_1^{(\tau)}$ 。接着，用从条件分布

$$p(z_2 | z_1^{(\tau+1)}, z_3^{(\tau)}) \quad (11.47)$$

中抽得的样本 $z_2^{(\tau+1)}$ 来替换 $z_2^{(\tau)}$ ，此时新得到的 $z_1^{(\tau+1)}$ 会立即在后续采样中被使用。然后，我们从

$$p(z_3 | z_1^{(\tau+1)}, z_2^{(\tau+1)}) \quad (11.48)$$

中抽样得到 $z_3^{(\tau+1)}$ 用于更新 z_3 ，如此循环更新三变量。

吉布斯采样

1. 初始化 $\{z_i : i = 1, \dots, M\}$ 。
2. 对 $\tau = 1, \dots, T$:
 - 采样 $z_1^{(\tau+1)} \sim p(z_1 | z_2^{(\tau)}, z_3^{(\tau)}, \dots, z_M^{(\tau)})$ 。
 - 采样 $z_2^{(\tau+1)} \sim p(z_2 | z_1^{(\tau+1)}, z_3^{(\tau)}, \dots, z_M^{(\tau)})$ 。
 - $\vdots$
 - 采样 $z_j^{(\tau+1)} \sim p(z_j | z_1^{(\tau+1)}, \dots, z_{j-1}^{(\tau+1)}, z_{j+1}^{(\tau)}, \dots, z_M^{(\tau)})$ 。
 - $\vdots$
 - 采样 $z_M^{(\tau+1)} \sim p(z_M | z_1^{(\tau+1)}, z_2^{(\tau+1)}, \dots, z_{M-1}^{(\tau+1)})$ 。

要证明该过程确实能从所需分布中采样，首先注意到分布 $p(\mathbf{z})$ 对吉布斯采样的每一步而言都是不变的，因此对整个马尔科夫链也是不变的。这源于这样一个事实：当

我们从 $p(z_i | \mathbf{z}_{\setminus i})$ 中采样时, 边缘分布 $p(\mathbf{z}_{\setminus i})$ 显然保持不变, 因为 $\mathbf{z}_{\setminus i}$ 的取值没有改变。同时, 每一步按定义都从正确的条件分布 $p(z_i | \mathbf{z}_{\setminus i})$ 中采样。由于这些条件分布与边缘分布共同唯一确定了联合分布, 我们可以看出联合分布本身是不变的。

要使吉布斯采样过程能够从正确分布中采样, 还必须满足第二个条件, 即过程是遍历的。一个充分条件是所有条件分布在任何地方都不为零。如果这一条件成立, 那么在有限步数内, 只要依次更新每个分量变量, 就可以从 $\mathbf{z}$ 空间中的任意一点到达任意另一点。如果这一条件不满足, 从而某些条件分布在某些地方为零, 那么若要证明过程是遍历的, 就必须针对具体情况进行显式论证。

为了完整描述算法, 还必须指定初始状态的分布, 尽管在经过许多次迭代之后, 采样结果在实际中会与这一初始分布几乎无关。当然, 来自马尔科夫链的相邻样本高度相关, 因此若要获得近似独立的样本, 就需要对序列进行子采样。


我们可以如下把吉布斯采样过程看作 Metropolis-Hastings 算法的一个特例。考虑一次针对变量 z_k 的 Metropolis-Hastings 采样步骤, 其中其余变量 $\mathbf{z}_{\setminus k}$ 保持不变, 并且从状态 $\mathbf{z}$ 到候选状态 $\mathbf{z}^*$ 的跃迁概率为 $q_k(\mathbf{z}^* | \mathbf{z}) = p(z_k^* | \mathbf{z}_{\setminus k})$ 。注意这里有 $\mathbf{z}_{\setminus k}^* = \mathbf{z}_{\setminus k}$, 因为这些分量在此次采样步骤中未被改变。同时, $p(\mathbf{z}) = p(z_k | \mathbf{z}_{\setminus k}) p(\mathbf{z}_{\setminus k})$ 。因此, 在 Metropolis-Hastings 准则 (11.44) 中决定接受概率的因子为

$$A(\mathbf{z}^*, \mathbf{z}) = \frac{p(\mathbf{z}^*) q_k(\mathbf{z} | \mathbf{z}^*)}{p(\mathbf{z}) q_k(\mathbf{z}^* | \mathbf{z})} = \frac{p(z_k^* | \mathbf{z}_{\setminus k}^*) p(\mathbf{z}_{\setminus k}^*) p(z_k | \mathbf{z}_{\setminus k}^*)}{p(z_k | \mathbf{z}_{\setminus k}) p(\mathbf{z}_{\setminus k}) p(z_k^* | \mathbf{z}_{\setminus k})} = 1 \quad (11.49)$$

这里我们利用了 $\mathbf{z}_{\setminus k}^* = \mathbf{z}_{\setminus k}$ 。因此 Metropolis-Hastings 的每一步总是被接受。

和 Metropolis 算法一样, 通过考察其在高斯分布上的应用, 我们可以对吉布斯采样的行为获得一些直观认识。考虑一个关于两个变量的相关高斯分布, 如图 11.11 所示, 其条件分布的宽度为 l , 而边缘分布的宽度为 L 。典型步长由条件分布控制, 因而规模约为 l 。由于状态的演化遵循随机游走, 因此要从该分布中获得相互独立的样本, 所需步数约为 $(L/l)^2$ 。当然, 如果该高斯分布是非相关的, 那么吉布斯采样过程将具有最优效率。对这个简单问题, 我们可以通过旋转坐标系来对变量进行去相关。然而, 在实际应用中通常无法找到这样的变换。

图 11.11 通过对两个变量进行交替更新来说明 Gibbs 采样的示意图, 这两个变量的联合分布是一个相关的高斯分布。步长由条件分布 (绿色曲线) 的标准差所控制, 其量级为 $O(l)$, 从而导致在联合分布拉伸方向 (红色椭圆) 上的推进速度较慢。从该分布中获得一个近似独立样本所需的步数为 $O((L/l)^2)$ 。



缓解吉布斯采样中随机游走行为的一种方法称为过松弛 (over-relaxation) (Adler, 1981)。在最初形式中, 它适用于条件分布为高斯的情形, 这已经比多元高斯分布要一


般，因为例如非高斯分布 $p(z, y) \propto \exp(-z^2 y^2)$ 的条件分布就是高斯的。在吉布斯采样算法的每一步中，某个分量 z_i 的条件分布具有均值 μ_i 和方差 σ_i^2 。在过松弛框架中， z_i 的更新规则为

$$z'_i = \mu_i + \alpha(z_i - \mu_i) + \sigma_i(1 - \alpha^2)^{1/2} \nu \quad (11.50)$$

其中 ν 是均值为 0、方差为 1 的高斯随机变量， α 为满足 $-1 < \alpha < 1$ 的参数。当 $\alpha = 0$ 时，该方法与标准吉布斯采样等价；当 $\alpha < 0$ 时，更新步会偏向均值的另一侧。该更新保持目标分布不变，因为如果 z_i 的均值为 μ_i 、方差为 σ_i^2 ，那么 z'_i 的均值与方差也分别为 μ_i 与 σ_i^2 。过松弛的效果是：在变量高度相关时，它鼓励状态在空间中做更具方向性的移动。有序过松弛（ordered over-relaxation; Neal, 1999）的框架则将这一思路推广到非高斯分布。

吉布斯采样在实践中的适用性，取决于我们能多容易地从条件分布 $p(z_k | \mathbf{z}_{\setminus k})$ 中抽样。如果目标分布用图模型来表示，那么各个结点的条件分布只依赖于其马尔科夫毯中的变量，如图 11.12 所示。对于有向图来说，只要在给定父节点条件下为各节点选择合适的条件分布，就可以使吉布斯采样所需的条件分布是对数凹的，于是第 11.1.3 节讨论的自适应拒绝采样方法就为从有向图中进行蒙特卡罗采样提供了一个具有广泛适用性的框架。

图 11.12 Gibbs 采样方法要求从某个变量在给定其余变量条件下的条件分布中进行采样。对于图模型而言，该条件分布只依赖于马尔可夫毯中节点的状态。对于无向图，马尔可夫毯由相邻节点的集合构成，如左图所示；而对于有向图，马尔可夫毯则由父节点、子节点以及共同父节点组成，如右图所示。



如果图中的分布属于指数族，并且父子关系保持共轭性，那么在吉布斯采样中得到的完备条件分布将与定义各个节点的原始条件分布（以父节点为条件）具有相同的函数形式，因此可以使用标准的采样技术。一般而言，完备条件分布会具有较复杂的形式，从而无法使用标准采样算法。不过，如果这些条件分布是对数凹的，那么在对应变量为标量的前提下，可以使用自适应拒绝采样高效地进行采样。

如果在吉布斯采样算法的每一步中，我们不是从对应的条件分布中采样，而是将变量设置为该条件分布的最大值（点估计），那么就得到第 8.3.3 节中讨论的迭代条件模式（iterated conditional modes, ICM）算法。因此，ICM 可以看作是吉布斯采样的一种贪婪近似。

由于基础的吉布斯采样技术每次只更新一个变量，因此相邻样本之间存在很强的依赖性。在另一个极端，如果我们能直接从联合分布中抽样（这正是我们假定在计算上不可行的操作），那么相邻样本就会相互独立。我们可以通过采取中间策略来改进简单的吉布斯采样器，即不再逐个变量采样，而是依次从变量组中采样。这就是分块吉布斯采样（blocking Gibbs sampling）算法的思想：选择若干变量块（它们不必互不相交），然后在每一步中在给定其余变量的情况下，联合地从每个变量块中采样（Jensen et al.,

1995)。

11.4 切片采样

我们已经看到，Metropolis 算法的一个困难在于它对步长的敏感性。如果步长太小，就会因为随机游走行为导致去相关非常缓慢；而如果步长太大，又会由于高拒绝率而效率低下。切片采样 (slice sampling; Neal, 2003) 技术提供了一种自适应步长，它会自动根据分布的特性进行调整。同样，这需要我们能够对未归一化分布 $\tilde{p}(\mathbf{z})$ 进行求值。

先考虑一维情形。切片采样通过将 z 与一个额外变量 u 进行扩展，从而在联合空间 (z, u) 中进行采样。当我们在第 11.5 节讨论混合蒙特卡罗时，还将看到这种做法的另外一个例子。目标是从以下分布下方的区域中进行均匀采样：

$$\hat{p}(z, u) = \begin{cases} 1/Z_p, & \text{如果 } 0 \leq u \leq \tilde{p}(z) \\ 0, & \text{其他情况} \end{cases} \quad (11.51)$$

其中 $Z_p = \int \tilde{p}(z) dz$ 。关于 z 的边缘分布为

$$\int \hat{p}(z, u) du = \int_0^{\tilde{p}(z)} \frac{1}{Z_p} du = \frac{\tilde{p}(z)}{Z_p} = p(z) \quad (11.52)$$

因此，我们可以通过从 $\hat{p}(z, u)$ 中采样并忽略 u 的取值，从而得到服从 $p(z)$ 的样本。这可以通过交替地对 z 和 u 采样来实现。给定当前的 z 值，我们计算 $\tilde{p}(z)$ ，然后在区间 $0 \leq u \leq \tilde{p}(z)$ 上对 u 进行均匀采样，这是很容易做到的。然后将 u 固定，从分布的“切片”中对 z 进行均匀采样，该切片由集合 $\{z : \tilde{p}(z) > u\}$ 定义。这在图 11.13(a) 中作了示意。




图 11.13 切片采样的示意图。(a) 对于给定的值 $z^{(\tau)}$ ，在区域 $0 \leq u \leq \tilde{p}(z^{(\tau)})$ 内均匀地选择一个 u 的值，这由此在分布中定义了一个“切片”，如实线水平线所示。(b) 由于无法直接从该切片中进行采样，因此从一个包含先前取值 $z^{(\tau)}$ 的区域 $z_{\min} \leq z \leq z_{\max}$ 中抽取一个新的 z 样本。

在实践中，直接从切片中采样可能会很困难，因此我们改为定义一种采样方案，使其在 $\hat{p}(z, u)$ 下的均匀分布保持不变，这可以通过保证详细平衡成立来实现。假设当前的 z 值记为 $z^{(\tau)}$ ，并且已经得到对应的 u 样本。下一步的 z 是这样获得的：先考虑一个包含 $z^{(\tau)}$ 的区间 $z_{\min} \leq z \leq z_{\max}$ 。正是在区间选择的过程中，自适应地匹配分布的特征长度尺度。我们希望这个区间尽可能涵盖切片的全部区域，以便在 z 空间中进行较大幅度的移动，同时尽可能减少该区间落在切片之外的部分，因为后者会降低采样效率。

对区间选择的一种方法是：从一个包含 $z^{(\tau)}$ 的区间出发，该区间具有某个宽度 w ，然后分别检查两端点是否落在切片之内。如果某一端点不在切片中，就在该方向上以步

长 w 扩展区间，直到该端点落在切片之外为止。接着，从该区间中均匀选取一个候选值 z' ，若它在切片之内，则将其作为 $z^{(\tau+1)}$ ；如果它不在切片之内，则缩小区间，使得 z' 成为新的端点，并同时保证区间仍然包含 $z^{(\tau)}$ 。然后再从收缩后的区间中均匀选取新的候选点，如此反复，直到找到一个落在切片之内的 z 值为止。

切片采样可以通过类似吉布斯采样的方式推广到多维分布：依次对每一个变量进行采样。这要求我们能够对每个分量 z_i 计算一个与 $p(z_i | \mathbf{z}_{\setminus i})$ 成正比的函数。

11.5 混合蒙特卡罗算法

正如我们已经指出的，Metropolis 算法的一个主要局限在于它可能表现出随机游走行为，此时在状态空间中行进的距离只会随着步数的平方根增长。单纯通过增大步长并不能解决这个问题，因为那会导致很高的拒绝率。

在本节中，我们介绍一类更加复杂的跃迁方法，它基于与物理系统的类比，具有在保持较低拒绝概率的同时对系统状态进行大幅度改变的特性。它适用于这样一类分布：定义在连续变量上，并且我们可以方便地计算对状态变量的对数概率的梯度。我们将在 11.5.1 节讨论动力系统框架，然后在 11.5.2 节说明如何将其与 Metropolis 算法结合，从而得到功能强大的混合蒙特卡罗算法。本节是自包含的，并不需要物理学背景，因为所有关键结果都会从第一性原理推导出来。

11.5.1 动力系统

这种动力学方法的随机采样起源于用于模拟在哈密顿动力学下演化的物理系统行为的算法。在马尔科夫链蒙特卡罗模拟中，我们的目标是从给定的概率分布 $p(\mathbf{z})$ 中采样。哈密顿动力学框架的利用方式是，将概率模拟转化为一个哈密顿系统。为了与相关文献保持一致，我们会在合适的地方使用一些动力系统领域的术语，并在用到时给出定义。

我们考虑的动力学对应于状态变量 $\mathbf{z} = \{z_i\}$ 在连续时间下的演化，将时间记为 τ 。经典动力学由牛顿第二定律描述，即物体的加速度与所受力成正比，对应于关于时间的二阶微分方程。通过引入中间的动量变量 $\mathbf{r}$ （表示状态变量 $\mathbf{z}$ 的变化率），我们可以将一个二阶方程分解为两个耦合的一阶方程，其中各分量

$$r_i = \frac{dz_i}{d\tau} \quad (11.53)$$

在这一动力学视角中， z_i 可以看作位置变量。因此，每个位置变量都有一个对应的动量变量，而位置与动量变量的联合空间称为相空间（phase space）。

不失一般性，我们可以把概率分布 $p(\mathbf{z})$ 写成

$$p(\mathbf{z}) = \frac{1}{Z_p} \exp(-E(\mathbf{z})) \quad (11.54)$$

其中 $E(\mathbf{z})$ 被解释为系统在状态 $\mathbf{z}$ 下的势能。系统的加速度是动量的变化率，它由所受

力给出，而力又等于势能的负梯度：

$$\frac{d\mathbf{r}_i}{d\tau} = -\frac{\partial E(\mathbf{z})}{\partial z_i}. \quad (11.55)$$

用哈密顿框架来重写这一动力系统会更加方便。为此，我们先将动能定义为

$$K(\mathbf{r}) = \frac{1}{2} \|\mathbf{r}\|^2 = \frac{1}{2} \sum_i r_i^2. \quad (11.56)$$

系统的总能量是势能与动能之和：

$$H(\mathbf{z}, \mathbf{r}) = E(\mathbf{z}) + K(\mathbf{r}) \quad (11.57)$$

其中 H 为哈密顿量。根据 (11.53)、(11.55)、(11.56) 和 (11.57)，我们可以用哈密顿方程来表达系统的动力学：

$$\frac{dz_i}{d\tau} = \frac{\partial H}{\partial r_i} \quad (11.58)$$

$$\frac{dr_i}{d\tau} = -\frac{\partial H}{\partial z_i}. \quad (11.59)$$

在该动力系统演化过程中，哈密顿量 H 的取值保持不变，这一点可以通过对时间求导轻易看出：

$$\begin{aligned} \frac{dH}{d\tau} &= \sum_i \left\{ \frac{\partial H}{\partial z_i} \frac{dz_i}{d\tau} + \frac{\partial H}{\partial r_i} \frac{dr_i}{d\tau} \right\} \\ &= \sum_i \left\{ \frac{\partial H}{\partial z_i} \frac{\partial H}{\partial r_i} - \frac{\partial H}{\partial r_i} \frac{\partial H}{\partial z_i} \right\} = 0. \end{aligned} \quad (11.60)$$

哈密顿动力系统的第二个重要性质称为刘维尔定理 (Liouville's Theorem)，它表明相空间中的体积是守恒的。换句话说，如果我们考虑变量 $(\mathbf{z}, \mathbf{r})$ 空间中的某个区域，那么该区域在哈密顿方程所描述的演化下，其形状可能改变，但体积不会改变。这可以通过考察相空间中的流场（位置随时间变化的速度场）来理解：

$$\mathbf{V} = \left(\frac{d\mathbf{z}}{d\tau}, \frac{d\mathbf{r}}{d\tau} \right) \quad (11.61)$$

其散度为零：

$$\begin{aligned} \text{div } \mathbf{V} &= \sum_i \left\{ \frac{\partial}{\partial z_i} \frac{dz_i}{d\tau} + \frac{\partial}{\partial r_i} \frac{dr_i}{d\tau} \right\} \\ &= \sum_i \left\{ -\frac{\partial}{\partial z_i} \frac{\partial H}{\partial r_i} + \frac{\partial}{\partial r_i} \frac{\partial H}{\partial z_i} \right\} = 0. \end{aligned} \quad (11.62)$$

现在考虑相空间上的联合分布，其总能量由哈密顿量给出，即

$$p(\mathbf{z}, \mathbf{r}) = \frac{1}{Z_H} \exp(-H(\mathbf{z}, \mathbf{r})) \quad (11.63)$$

利用相空间体积守恒与 H 守恒这两个结果，可以得出：哈密顿动力学会使分布 $p(\mathbf{z}, \mathbf{r})$ 保持不变。这可以通过考虑相空间中的一个小区域来说明：在该区域内 H 近似

为常数。如果我们沿着哈密顿方程的轨道跟踪其有限时间的演化，则该区域的体积保持不变，而区域内 H 的取值也保持不变，因此只依赖于 H 的概率密度也保持不变。

尽管 H 不变， $\mathbf{z}$ 与 $\mathbf{r}$ 的取值仍会发生变化，因此通过在有限时间内积分哈密顿动力学，就可以以一种系统的方式对 $\mathbf{z}$ 进行大幅度改变，从而避免随机游走行为。

然而，单靠哈密顿动力学无法遍历地（ergodically）从 $p(\mathbf{z}, \mathbf{r})$ 采样，因为 H 的取值是恒定的。为了得到遍历的采样方案，我们可以在相空间中引入额外的跃迁，这些跃迁会改变 H 的取值，但仍保持分布 $p(\mathbf{z}, \mathbf{r})$ 不变。最简单的方法是用从条件分布 $p(\mathbf{r} | \mathbf{z})$ 中抽取的新值来替换当前的 $\mathbf{r}$ 。这可以看作一次吉布斯采样步骤，因此根据 11.3 节可知，它也会保持目标分布不变。注意在分布 $p(\mathbf{z}, \mathbf{r})$ 中， $\mathbf{z}$ 与 $\mathbf{r}$ 是独立的，因此条件分布 $p(\mathbf{r} | \mathbf{z})$ 是一个高斯分布，从中采样是直接的。

在实际应用这一方法时，我们必须解决对哈密顿方程进行数值积分的问题。这必然引入数值误差，因此我们需要设计一种方案，尽量减小这些误差的影响。事实上，可以构造出某些数值积分方案，使得刘维尔定理仍然精确成立。这一性质对混合蒙特卡罗算法来说非常重要，我们将在 11.5.2 节中看到这一点。实现这一目标的一个方案称为“跳蛙离散化”（leapfrog discretization），它通过交替更新位置与动量变量的离散近似 $\hat{\mathbf{z}}$ 和 $\hat{\mathbf{r}}$ 来进行：

$$\hat{r}_i(\tau + \epsilon/2) = \hat{r}_i(\tau) - \frac{\epsilon}{2} \frac{\partial E}{\partial z_i}(\hat{\mathbf{z}}(\tau)) \quad (11.64)$$

$$\hat{z}_i(\tau + \epsilon) = \hat{z}_i(\tau) + \epsilon \hat{r}_i(\tau + \epsilon/2) \quad (11.65)$$

$$\hat{r}_i(\tau + \epsilon) = \hat{r}_i(\tau + \epsilon/2) - \frac{\epsilon}{2} \frac{\partial E}{\partial z_i}(\hat{\mathbf{z}}(\tau + \epsilon)) \quad (11.66)$$

可以看到，这一过程的形式是：先用步长为 $\epsilon/2$ 对动量进行半步更新，然后用步长为 ϵ 对位置进行整步更新，再用步长为 $\epsilon/2$ 对动量进行第二次半步更新。如果连续执行多个跳蛙步骤，可以发现，对动量变量的若干半步更新可以合并为步长为 ϵ 的整步更新；如此一来，对位置与动量的连续更新就像在彼此之间交替“跳跃”。为了将系统的动力学推进时间间隔 τ ，我们需要进行 τ/ϵ 个步长为 ϵ 的跳蛙步骤。对于连续时间动力学，当假定 $E(\mathbf{z})$ 是光滑函数时，在 $\epsilon \rightarrow 0$ 的极限下，离散近似的误差趋于 0。然而在实践中 ϵ 必须为非零，因此总会残留一些误差。我们将在 11.5.2 节中看到，在混合蒙特卡罗算法中可以消除这些误差的影响。

总之，哈密顿动力学方法涉及在一系列跳蛙更新与根据边缘分布重新采样动量变量之间交替进行。

需要注意的是，与基本的 Metropolis 算法不同，哈密顿动力学方法能够利用对数概率分布的梯度信息，而不仅仅是分布本身的信息。类似的情形在函数优化领域中也常见：在大多数可以获得梯度信息的场合，利用梯度信息往往具有明显优势。直观上，这是因为在维度为 D 的空间中，相对于函数值的计算，计算梯度所需的额外代价通常只是一个与 D 无关的固定倍数，而维度为 D 的梯度向量却提供了 D 维的信息，而函数值本身只提供了 1 维的信息。

11.5.2 混合蒙特卡罗

正如上一节所讨论的，当步长 ϵ 为非零时，跳蛙算法的离散化会在哈密顿方程的积分中引入误差。混合蒙特卡罗 (hybrid Monte Carlo; Duane et al., 1987; Neal, 1996) 将哈密顿动力学与 Metropolis 算法相结合，从而消除了由离散化带来的偏差。

更具体地说，该算法使用一条马尔科夫链，该链由动量变量 $\mathbf{r}$ 的随机更新与利用跳蛙算法进行的哈密顿动力学更新交替组成。在每次应用跳蛙算法之后，根据哈密顿量 H 的取值按照 Metropolis 准则来接受或拒绝得到的候选状态。也就是说，如果 $(\mathbf{z}, \mathbf{r})$ 是初始状态，而 $(\mathbf{z}^*, \mathbf{r}^*)$ 是经过跳蛙积分后的状态，那么该候选状态以如下概率被接受：

$$\min(1, \exp\{H(\mathbf{z}, \mathbf{r}) - H(\mathbf{z}^*, \mathbf{r}^*)\}). \quad (11.67)$$

如果跳蛙积分能够完美模拟哈密顿动力学，则每一步候选状态都会自动被接受，因为此时 H 的值保持不变。由于数值误差的存在， H 有时会减小，我们希望 Metropolis 准则可以消除由此产生的任何偏差，并确保最终样本确实来自所需的分布。为使这一点成立，我们需要保证对应于跳蛙积分的更新方程满足详细平衡条件 (11.40)。这可以通过如下方式对跳蛙方案进行简单修改来实现。

在每一次跳蛙积分序列开始之前，我们以相等概率随机决定是沿时间正方向（使用步长 ϵ ）还是反方向（使用步长 $-\epsilon$ ）进行积分。首先注意到，跳蛙积分方案 (11.64)、(11.65) 与 (11.66) 是时间可逆的，因此用步长 $-\epsilon$ 进行 L 步积分会精确抵消用步长 ϵ 进行 L 步积分的效果。接下来，我们证明跳蛙积分精确保持相空间体积。这源于这样一个事实：跳蛙方案中的每一步要么更新某个 z_i ，要么更新某个 r_i ，且更新量仅是另一个变量的函数。如图 11.14 所示，这相当于对相空间区域进行剪切变换，而不改变其体积。




图 11.14 跃蛙算法的每一步 (11.64)-(11.66) 都只修改一个位置变量 z_i 或一个动量变量 r_i 。由于对某一变量的改变仅仅是另一个变量的函数，相空间中的任何区域都会发生剪切，但其体积保持不变。

最后我们利用这些结论来证明详细平衡成立。考虑相空间中的一个小区域 $\mathcal{R}$ ，在步长为 ϵ 的 L 次跳蛙迭代下，它被映射到区域 $\mathcal{R}'$ 。由体积在跳蛙迭代下保持不变可知，如果 $\mathcal{R}$ 的体积为 δV ，则 $\mathcal{R}'$ 的体积也是 δV 。若我们从分布 (11.63) 中抽取初始点，并用 L 次跳蛙迭代对其更新，则从 $\mathcal{R}$ 跃迁到 $\mathcal{R}'$ 的概率为

$$\frac{1}{Z_H} \exp(-H(\mathcal{R})) \delta V \frac{1}{2} \min\{1, \exp(-H(\mathcal{R}) + H(\mathcal{R}'))\} \quad (11.68)$$

其中 $1/2$ 因子来自于选择正步长而非负步长积分的概率。同样地，从区域 $\mathcal{R}'$ 出发，沿时间反方向积分最终到达区域 $\mathcal{R}$ 的概率为

$$\frac{1}{Z_H} \exp(-H(\mathcal{R}')) \delta V \frac{1}{2} \min\{1, \exp(-H(\mathcal{R}') + H(\mathcal{R}))\}. \quad (11.69)$$

可以很容易地看出，(11.68) 与 (11.69) 中的这两个概率是相等的，因此详细平衡条件成立。注意，这一证明忽略了区域 $\mathcal{R}$ 与 $\mathcal{R}'$ 间可能的重叠，但对考虑这种重叠的推广也是很容易实现的。

构造一些例子并不困难：在这些例子中，跳蛙算法经过有限步数后会回到起始位置。在这种情况下，在每次跳蛙积分前随机替换动量值不足以保证遍历性，因为位置变量从未发生变化。只要在每次跳蛙积分之前，从一个较小的区间中随机选择步长的大小，就可以轻易避免此类现象。

通过考察混合蒙特卡罗算法在多元高斯分布上的应用，我们可以对其行为获得一定直观认识。为方便起见，考虑一个具有独立分量的高斯分布 $p(\mathbf{z})$ ，其对应的哈密顿量为

$$H(\mathbf{z}, \mathbf{r}) = \frac{1}{2} \sum_i \frac{1}{\sigma_i^2} z_i^2 + \frac{1}{2} \sum_i r_i^2. \quad (11.70)$$

由于混合蒙特卡罗算法具有旋转各向同性 (rotational isotropy)，我们的结论同样适用于具有相关分量的高斯分布。在跳蛙积分过程中，每一对相空间变量 (z_i, r_i) 独立演化。然而，是否接受候选点则取决于 H 的值，而 H 又依赖所有变量的取值。因此，只要某一变量的积分误差较大，就可能导致较高的拒绝概率。为了使离散的跳蛙积分能较好地近似真实的连续时间动力学，要求跳蛙的步长 ϵ 小于势能发生显著变化的最短长度尺度。该尺度由最小的 σ_i 决定，我们记为 $\sigma_{\min}$ 。回忆一下，在混合蒙特卡罗中进行跳蛙积分的目标是：在相空间中移动足够长的距离，以到达一个与初始状态相对独立的新状态，同时仍保持较高的接受概率。要实现这一点，跳蛙积分必须持续进行若干步，其步数规模约为 $\sigma_{\max}/\sigma_{\min}$ 。

相较之下，考虑前面讨论过的、具有方差 s^2 的各向同性高斯提议分布的简单 Metropolis 算法的行为。为了避免较高的拒绝率， s 的取值必须与 $\sigma_{\min}$ 同阶。此时对状态空间的探索通过随机游走来进行，并且大约需要 $(\sigma_{\max}/\sigma_{\min})^2$ 步才能到达一个大致独立的状态。

11.6 估计配分函数

正如我们已经看到的，本章讨论的大多数采样算法只需要概率分布在一个乘法常数意义下的函数形式。因此，如果我们写成

$$p_E(\mathbf{z}) = \frac{1}{Z_E} \exp(-E(\mathbf{z})) \quad (11.71)$$

那么归一化常数 Z_E （也称为配分函数）的取值在从 $p(\mathbf{z})$ 中抽样时并非必需。然而，对于贝叶斯模型比较来说， Z_E 的值却是有用的，因为它代表模型证据（即给定模型时观测数据的概率），因此如何得到它的取值就成为一个值得关注的问题。这里我们假设，

通过在 $\mathbf{z}$ 的状态空间上直接对函数 $\exp(-E(\mathbf{z}))$ 求和或积分来计算 Z_E 在计算上是不可行的。

在模型比较中,实际需要的是两个模型配分函数之比。将这一比值再乘以先验概率之比,就得到后验概率之比,然后就可以用来进行模型选择或模型平均。

估计配分函数比值的一种方式,是对具有能量函数 $G(\mathbf{z})$ 的分布应用重要性采样:

$$\begin{aligned}\frac{Z_E}{Z_G} &= \frac{\sum_{\mathbf{z}} \exp(-E(\mathbf{z}))}{\sum_{\mathbf{z}} \exp(-G(\mathbf{z}))} \\ &= \frac{\sum_{\mathbf{z}} \exp(-E(\mathbf{z}) + G(\mathbf{z})) \exp(-G(\mathbf{z}))}{\sum_{\mathbf{z}} \exp(-G(\mathbf{z}))} \\ &= \mathbb{E}_{G(\mathbf{z})}[\exp(-E + G)] \\ &\simeq \sum_l \exp(-E(\mathbf{z}^{(l)}) + G(\mathbf{z}^{(l)}))\end{aligned}\tag{11.72}$$

其中 $\{\mathbf{z}^{(l)}\}$ 是从由 $p_G(\mathbf{z})$ 定义的分布中抽取的样本。如果分布 p_G 是一种配分函数可解析求得分布(例如高斯分布),那么就可以得到 Z_E 的绝对值。

这一方法只有在重要性采样分布 p_G 与目标分布 p_E 十分接近、从而比值 p_E/p_G 不会有剧烈波动时才会给出准确结果。在实际中,对于本书所讨论的这类复杂模型,很难找到合适的解析形式的重要性采样分布。

因此,另一种可选的方法是使用从马尔科夫链中获得的样本来定义重要性采样分布。如果马尔科夫链的跃迁概率为 $T(\mathbf{z}, \mathbf{z}')$, 而样本集为 $\mathbf{z}^{(1)}, \dots, \mathbf{z}^{(L)}$, 那么采样分布可以写成

$$\frac{1}{Z_G} \exp(-G(\mathbf{z})) = \sum_{l=1}^L T(\mathbf{z}^{(l)}, \mathbf{z})\tag{11.73}$$

并可直接用于 (11.72) 式。

要使估计两个配分函数之比的方法奏效,要求相应的两个分布彼此之间足够接近。如果我们希望得到复杂分布的配分函数的绝对值,这一点尤其麻烦,因为只有对相对简单的分布,我们才能直接计算配分函数,因此若直接尝试估计配分函数之比,很可能不会成功。该问题可以通过一种称为链式法(chaining)(Neal, 1993; Barber and Bishop, 1997)的技术来缓解,该技术引入一串中间分布 $p_2, \dots, p_{M-1}$, 它们在一个简单分布 $p_1(\mathbf{z})$ (其归一化系数 Z_1 可求) 与目标复杂分布 $p_M(\mathbf{z})$ 之间进行插值。此时有

$$\frac{Z_M}{Z_1} = \frac{Z_2}{Z_1} \frac{Z_3}{Z_2} \dots \frac{Z_M}{Z_{M-1}}\tag{11.74}$$

其中各中间比值可以用前面讨论的蒙特卡罗方法确定。构造这类中间系统序列的一种方式,是使用含有连续参数 $0 \leq \alpha \leq 1$ 的能量函数在两种分布之间插值:

$$E_\alpha(\mathbf{z}) = (1 - \alpha)E_1(\mathbf{z}) + \alpha E_M(\mathbf{z})\tag{11.75}$$

如果要用蒙特卡罗方法来求 (11.74) 中的中间比值,那么与其为每个比值都重新启动一条马尔科夫链,不如使用同一条马尔科夫链运行会更高效一些。在这种情况下,马尔科夫链一开始在系统 p_1 下运行,经过若干步之后再转到序列中的下一个分布。需要注意的是,在每一个阶段,系统都必须保持接近当前分布的平衡态。

12 连续潜在变量

在第 9 章中，我们讨论了具有离散潜在变量的概率模型，例如高斯混合模型。现在我们来探索这样一些模型：其中部分或全部潜在变量是连续的。此类模型的重要动机之一在于，许多数据集都具有这样的性质：所有数据点都靠近一个远低于原始数据空间维度的流形。要理解这种情况为何会出现，可以考虑一个人工构造的数据集：先取一个离线数字图像，用一个 64×64 像素的灰度图来表示它，再将其嵌入到一个 100×100 的更大图像中，周围用取值为 0 的像素（对应白色像素）进行填充，同时随机改变该数字的位置和朝向，如图 12.1 所示。最终得到的每个图像都可以看作是 $100 \times 100 = 10,000$ 维数据空间中的一个点。然而，在这样的一组图像数据中，只有三个自由度的变化，对应于垂直平移、水平平移以及旋转。因此，这些数据点实际上存在于数据空间中的一个子空间上，其内在维度为 3。注意，该流形是非线性的，例如当我们将数字在图像中平移经过某个像素时，该像素的取值会经历从 0（白）到 1（黑）再回到 0 的变化，这显然是数字位置的一个非线性函数。在这个例子中，平移与旋转参数就是潜在变量，因为我们只观测到图像向量，并不知道生成这些图像时采用了哪些具体的平移和旋转取值。




图 12.1 一个通过选取一张离线数字图像并生成多个副本而得到的合成数据集，在每个副本中，数字都在一个更大的图像区域内经历了随机的平移和旋转。最终得到的每幅图像都包含 $100 \times 100 = 10,000$ 个像素。

对于真实的数字图像数据，还会存在一个由缩放带来的自由度。此外，由于个人书写的变化以及不同人的书写风格差异，还会有与更复杂形变相关的多个自由度。尽管如此，这些自由度的数量与数据集的维度相比仍然很小。

另一个例子来自油流数据集。在固定气体、水和油这三相的几何配置的前提下，系统中只有两个自由度，对应于管道中油的体积分数以及水的体积分数（气体的体积分数由此确定）。尽管数据空间包含了 12 个观测量，但数据点集合会靠近嵌入其中的一个二维流形。在这个例子中，该流形由多个不同的片段构成，对应不同的流动状态，每个片段都是一个（带噪声的）连续二维流形。如果我们的目标是数据压缩或密度建模，那么利用这样的流形结构会带来好处。

在实际中，数据点不会严格地被限制在某个光滑的低维流形上，我们可以把数据点偏离该流形的部分解释为“噪声”。这自然引出一种生成式的视角：首先根据某个潜在变量分布在流形上选取一个点，然后在给定该潜在变量的条件下，从数据变量的某个条件分布中抽取噪声，叠加到该点上从而生成观测数据点。

最简单的连续潜在变量模型假设潜在变量与观测变量都服从高斯分布，并在观测变量对潜在变量状态的依赖上采用线性-高斯形式。这会导出一个对著名的主成分分析

(PCA) 技术的概率化表述, 以及一个相关模型——因子分析。


在本章中, 我们将从标准的、非概率形式的 PCA 开始, 然后说明 PCA 如何自然地作为某种线性-高斯潜在变量模型的最大似然解出现。这一概率化重述带来了许多优势, 例如可以使用 EM 算法进行参数估计; 可以有原则地推广到 PCA 模型的混合; 以及能够自动根据数据确定主成分数目的贝叶斯表述。最后, 我们将简要讨论若干超越线性-高斯假设的潜在变量推广形式, 其中包括具有非高斯潜在变量的模型 (从而导出独立成分分析框架) 以及潜在变量与观测变量之间存在非线性关系的模型。

12.1 主成分分析

主成分分析 (principal component analysis, PCA) 是一种被广泛应用于降维、有损数据压缩、特征提取以及数据可视化等任务的技术 (Jolliffe, 2002), 它也被称为 Karhunen-Loève 变换。

对 PCA 有两种常用的定义形式, 它们会导出同一个算法。PCA 可以定义为: 将数据正交投影到一个低维线性空间 (称为主子空间) 上, 使得投影数据的方差最大化 (Hotelling, 1933)。等价地, 它也可以定义为: 寻找一个线性投影, 使平均投影代价 (即数据点与其投影之间的均方距离) 最小化 (Pearson, 1901)。正交投影的过程如图 12.2 所示。下面我们将分别考察这两种定义。

图 12.2 主成分分析旨在寻找一个较低维度的空间, 称为主子空间, 并用洋红色直线表示, 使得数据点 (红点) 在该子空间上的正交投影能够最大化投影点 (绿点) 的方差。另一种对 PCA 的定义是基于最小化投影误差的平方和, 如蓝色线段所示。



12.1.1 最大方差形式

考虑一个由观测值 $\{\mathbf{x}_n\}$ 组成的数据集, 其中 $n = 1, \dots, N$, 每个 $\mathbf{x}_n$ 是一个维度为 D 的欧氏向量。我们的目标是将数据投影到一个维度为 $M < D$ 的空间, 同时使得投影数据的方差最大。这里暂时假定 M 的值是已知的。在本章后面, 我们将讨论如何从数据中确定一个合适的 M 值。

首先考虑投影到一维空间 ($M = 1$) 的情形。我们可以用一个 D 维向量 $\mathbf{u}_1$ 来定义这一空间的方向。为方便起见 (且不失一般性), 我们将其选为单位向量, 即 $\mathbf{u}_1^T \mathbf{u}_1 = 1$ (注意我们只关心 $\mathbf{u}_1$ 所定义的方向, 而不关心其长度)。每个数据点 $\mathbf{x}_n$ 被投影到标量

$\mathbf{u}_1^T \mathbf{x}_n$ 上。投影数据的均值为 $\mathbf{u}_1^T \bar{\mathbf{x}}$, 其中 $\bar{\mathbf{x}}$ 为样本集的均值:

$$\bar{\mathbf{x}} = \frac{1}{N} \sum_{n=1}^N \mathbf{x}_n \quad (12.1)$$

投影数据的方差则为

$$\frac{1}{N} \sum_{n=1}^N \{\mathbf{u}_1^T \mathbf{x}_n - \mathbf{u}_1^T \bar{\mathbf{x}}\}^2 = \mathbf{u}_1^T \mathbf{S} \mathbf{u}_1 \quad (12.2)$$

其中 $\mathbf{S}$ 为数据协方差矩阵:

$$\mathbf{S} = \frac{1}{N} \sum_{n=1}^N (\mathbf{x}_n - \bar{\mathbf{x}})(\mathbf{x}_n - \bar{\mathbf{x}})^T \quad (12.3)$$

现在我们要对 $\mathbf{u}_1$ 最大化投影方差 $\mathbf{u}_1^T \mathbf{S} \mathbf{u}_1$ 。显然, 为防止 $\|\mathbf{u}_1\| \rightarrow \infty$, 必须进行约束最大化。合适的约束来自归一化条件 $\mathbf{u}_1^T \mathbf{u}_1 = 1$ 。为实现这一约束, 我们引入拉格朗日乘子, 记为 λ_1 , 然后对下式进行无约束最大化:

$$\mathbf{u}_1^T \mathbf{S} \mathbf{u}_1 + \lambda_1 (1 - \mathbf{u}_1^T \mathbf{u}_1). \quad (12.4)$$

对 $\mathbf{u}_1$ 求导并令其为零, 可以得到该表达式的驻点满足

$$\mathbf{S} \mathbf{u}_1 = \lambda_1 \mathbf{u}_1 \quad (12.5)$$

这说明 $\mathbf{u}_1$ 必须是 $\mathbf{S}$ 的一个特征向量。左乘 $\mathbf{u}_1^T$ 并结合 $\mathbf{u}_1^T \mathbf{u}_1 = 1$ 可得投影方差为

$$\mathbf{u}_1^T \mathbf{S} \mathbf{u}_1 = \lambda_1 \quad (12.6)$$

因此, 当我们将 $\mathbf{u}_1$ 取为具有最大特征值 λ_1 的特征向量时, 方差达到最大。该特征向量称为第一主成分。

我们可以以增量方式定义后续主成分: 每一个新的方向都选取成在与已有方向正交的方向中使投影方差最大者。对于一般的 M 维投影空间而言, 使投影数据方差最大化的最优线性投影由协方差矩阵 $\mathbf{S}$ 的 M 个特征向量 $\mathbf{u}_1, \dots, \mathbf{u}_M$ 所定义, 它们对应于 M 个最大的特征值 $\lambda_1, \dots, \lambda_M$ 。这一结论可以通过数学归纳法容易地证明。

总之, 主成分分析的过程是: 先计算数据集的均值 $\bar{\mathbf{x}}$ 与协方差矩阵 $\mathbf{S}$, 然后求出 $\mathbf{S}$ 对应于最大 M 个特征值的 M 个特征向量。关于求特征值与特征向量的算法, 以及与特征分解相关的更多定理, 可参见 Golub 和 Van Loan (1996)。注意, 若要对一个大小为 $D \times D$ 的矩阵做完整的特征分解, 其计算代价为 $O(D^3)$ 。如果我们只打算将数据投影到前 M 个主成分上, 就只需求出前 M 个特征值与特征向量, 这可以用更高效的方法实现, 例如幂方法 (Golub 和 Van Loan, 1996), 其计算复杂度为 $O(MD^2)$, 或者我们还可以利用 EM 算法。

12.1.2 最小误差形式

现在我们来讨论另一种基于投影误差最小化的 PCA 形式。为此, 我们引入一组完备的 D 维正交归一基向量 $\{\mathbf{u}_i\}$, 其中 $i = 1, \dots, D$, 它们满足

$$\mathbf{u}_i^T \mathbf{u}_j = \delta_{ij}. \quad (12.7)$$

由于这一基是完备的，每个数据点都可以用这些基向量的线性组合精确表示：

$$\mathbf{x}_n = \sum_{i=1}^D \alpha_{ni} \mathbf{u}_i \quad (12.8)$$

其中系数 α_{ni} 会因数据点不同而变化。这仅仅对应于对坐标系的一个旋转：从原始坐标系转到由 $\{\mathbf{u}_i\}$ 定义的新坐标系，原有的 D 个分量 $\{x_{n1}, \dots, x_{nD}\}$ 被等价的 $\{\alpha_{n1}, \dots, \alpha_{nD}\}$ 所替代。对 $\mathbf{u}_j$ 取内积并利用正交归一条件可得 $\alpha_{nj} = \mathbf{x}_n^T \mathbf{u}_j$ ，因此我们可以不失一般性地写成

$$\mathbf{x}_n = \sum_{i=1}^D (\mathbf{x}_n^T \mathbf{u}_i) \mathbf{u}_i. \quad (12.9)$$

然而，我们的目标是利用一个只包含 $M < D$ 个变量的表示来近似数据点 $\mathbf{x}_n$ ，对应于将其投影到一个低维子空间。这个 M 维线性子空间可以不失一般性地用前 M 个基向量来表示，因此我们用以下形式来近似每个数据点 $\mathbf{x}_n$ ：

$$\tilde{\mathbf{x}}_n = \sum_{i=1}^M z_{ni} \mathbf{u}_i + \sum_{i=M+1}^D b_i \mathbf{u}_i \quad (12.10)$$

其中 $\{z_{ni}\}$ 随数据点变化而变化，而 $\{b_i\}$ 为不随数据点变化的常数。我们可以自由选择 $\{\mathbf{u}_i\}$ 、 $\{z_{ni}\}$ 和 $\{b_i\}$ ，以尽量减小降维所带来的失真。作为失真度量，我们采用原始数据点 $\mathbf{x}_n$ 与近似点 $\tilde{\mathbf{x}}_n$ 之间的平方距离，并在整个数据集上求平均，即我们的目标是最小化

$$J = \frac{1}{N} \sum_{n=1}^N \|\mathbf{x}_n - \tilde{\mathbf{x}}_n\|^2 \quad (12.11)$$

首先考虑对 $\{z_{ni}\}$ 的最小化。将 $\tilde{\mathbf{x}}_n$ 代入上式，对 z_{nj} 求导并令其为零，并利用正交归一条件，可以得到

$$z_{nj} = \mathbf{x}_n^T \mathbf{u}_j \quad (12.12)$$

其中 $j = 1, \dots, M$ 。同样地，对 b_i 求导并令导数为零，再次利用正交归一关系，可得

$$b_j = \bar{\mathbf{x}}^T \mathbf{u}_j \quad (12.13)$$

其中 $j = M+1, \dots, D$ 。如果将 z_{ni} 与 b_i 代入并利用 (12.9) 的一般展开式，可以得到

$$\mathbf{x}_n - \tilde{\mathbf{x}}_n = \sum_{i=M+1}^D \left\{ (\mathbf{x}_n - \bar{\mathbf{x}})^T \mathbf{u}_i \right\} \mathbf{u}_i \quad (12.14)$$

由此我们可以看出，从 $\mathbf{x}_n$ 到 $\tilde{\mathbf{x}}_n$ 的位移向量落在主子空间的正交补中，因为它是 $i = M+1, \dots, D$ 这些 $\{\mathbf{u}_i\}$ 的线性组合，如图 12.2 所示。这也是意料之中的：投影点 $\tilde{\mathbf{x}}_n$ 必须位于主子空间中，但我们可以在主子空间内部自由移动它们，因此最小误差正对应于正交投影。

于是，我们得到一个只关于 $\{\mathbf{u}_i\}$ 的失真度量 J 的表达式：

$$J = \frac{1}{N} \sum_{n=1}^N \sum_{i=M+1}^D (\mathbf{x}_n^T \mathbf{u}_i - \bar{\mathbf{x}}^T \mathbf{u}_i)^2 = \sum_{i=M+1}^D \mathbf{u}_i^T \mathbf{S} \mathbf{u}_i. \quad (12.15)$$

接下来要做的是对 $\{\mathbf{u}_i\}$ 最小化 J ，这必须是一个带约束的最小化问题，否则会得到平凡解 $\mathbf{u}_i = 0$ 。约束来自正交归一条件，正如我们将看到的，解可以用协方差矩阵的特征分解来表示。在给出形式化解答之前，我们先通过一个简单例子获得直观认识：设数据空间为二维（ $D = 2$ ），主子空间为一维（ $M = 1$ ）。此时我们需要选择一个方向 $\mathbf{u}_2$ 来最小化 $J = \mathbf{u}_2^T \mathbf{S} \mathbf{u}_2$ ，同时满足归一化约束 $\mathbf{u}_2^T \mathbf{u}_2 = 1$ 。用拉格朗日乘子 λ_2 来施加约束，我们考虑如下量的最小化：

$$\tilde{J} = \mathbf{u}_2^T \mathbf{S} \mathbf{u}_2 + \lambda_2 (1 - \mathbf{u}_2^T \mathbf{u}_2). \quad (12.16)$$

对 $\mathbf{u}_2$ 求导并令其为零，我们得到 $\mathbf{S} \mathbf{u}_2 = \lambda_2 \mathbf{u}_2$ ，即 $\mathbf{u}_2$ 是 $\mathbf{S}$ 的特征向量，对应特征值为 λ_2 。因此任一特征向量都会给出失真度量的一个驻点。为了找到 J 的最小值，我们将 $\mathbf{u}_2$ 的解代回失真度量表达式，得到 $J = \lambda_2$ 。于是，只要将 $\mathbf{u}_2$ 选为对应较小特征值的特征向量，即可最小化 J 。因此主子空间应与对应较大特征值的特征向量对齐。这一结果也与我们的直觉吻合：要最小化平均平方投影距离，就应当让主成分子空间穿过数据点的均值并与最大方差方向对齐。若两个特征值相等，则任何主方向选择都会导致相同的 J 值。

对于一般的 D 与 $M < D$ 的情形，通过如下方式得到 J 的最小化解：将 $\{\mathbf{u}_i\}$ 选为协方差矩阵的特征向量：

$$\mathbf{S} \mathbf{u}_i = \lambda_i \mathbf{u}_i \quad (12.17)$$

其中 $i = 1, \dots, D$ ，且照常将特征向量 $\{\mathbf{u}_i\}$ 选为正交归一。此时失真度量为

$$J = \sum_{i=M+1}^D \lambda_i \quad (12.18)$$

这正是与主子空间正交的那些特征向量对应的特征值之和。于是，只要把这些特征向量选成对应于 $D - M$ 个最小特征值的向量，就可以得到 J 的最小值，而定义主子空间的特征向量则对应于最大的 M 个特征值。

尽管我们之前假设 $M < D$ ，但在 $M = D$ 时 PCA 分析依然成立，此时不再有降维，而只是将坐标轴旋转对齐到主成分方向而已。

最后值得一提的是，还存在一个与 PCA 密切相关的线性降维技术，称为典型相关分析（canonical correlation analysis, CCA）（Hotelling, 1936; Bach and Jordan, 2002）。PCA 针对的是单个随机变量；而 CCA 处理的是两个（乃至更多个）随机变量，试图为它们找到一对线性子空间，使得两者之间的交叉相关性较强，即一个子空间中的每个分量都与另一个子空间中的某个分量相关联。其解可以用广义特征向量问题来表示。

12.1.3 PCA 的应用

我们可以用离线数字数据集来说明 PCA 在数据压缩上的应用。由于协方差矩阵的每个特征向量本身是原始 D 维空间中的一个向量，因此可以将这些特征向量表示为与数据点同尺寸的图像。前五个特征向量及其对应特征值如图 12.3 所示。按从大到小排序




图 12.3 离线数字数据集中均值向量 $\bar{\mathbf{x}}$ 以及前四个 PCA 特征向量 $\mathbf{u}_1, \dots, \mathbf{u}_4$, 并同时给出了对应的特征值。

的完整特征值谱如图 12.4(a) 所示。对于给定的 M , 其对应的失真度量 J 等于从 $M+1$ 到 D 的特征值之和, 不同 M 下的 J 值绘于图 12.4(b)。




图 12.4 (a) 离线数字数据集的特征值谱图。(b) 被舍弃特征值之和的图, 该量表示将数据投影到维度为 M 的主成分子空间上所引入的平方和失真 J 。

如果将 (12.12) 与 (12.13) 代入 (12.10), 就可以将数据向量 $\mathbf{x}_n$ 的 PCA 近似写成

$$\tilde{\mathbf{x}}_n = \sum_{i=1}^M (\mathbf{x}_n^T \mathbf{u}_i) \mathbf{u}_i + \sum_{i=M+1}^D (\bar{\mathbf{x}}^T \mathbf{u}_i) \mathbf{u}_i \quad (12.19)$$

$$= \bar{\mathbf{x}} + \sum_{i=1}^M (\mathbf{x}_n^T \mathbf{u}_i - \bar{\mathbf{x}}^T \mathbf{u}_i) \mathbf{u}_i \quad (12.20)$$

这里我们使用了

$$\bar{\mathbf{x}} = \sum_{i=1}^D (\bar{\mathbf{x}}^T \mathbf{u}_i) \mathbf{u}_i \quad (12.21)$$

这一关系, 它来自于 $\{\mathbf{u}_i\}$ 的完备性。上述表示对应于对数据集的压缩: 对于每个数据点, 我们用一个 M 维向量来替代原来的 D 维向量 $\mathbf{x}_n$, 其分量为 $(\mathbf{x}_n^T \mathbf{u}_i - \bar{\mathbf{x}}^T \mathbf{u}_i)$ 。 M 越小, 压缩程度越高。图 12.5 展示了对数字数据集应用 PCA 后的部分数据点重构示例。

主成分分析的另一个应用领域是数据预处理。在这种情况下, 目标并不是降维, 而是通过对数据进行变换, 使其某些性质标准化。这对于之后成功应用模式识别算法往往很重要。尤其是在原始变量用不同单位计量, 或者它们的变异程度相差很大时, 预处理尤为关键。例如在 Old Faithful 数据集中, 喷发间隔的时间通常是单次喷发持续时间




图 12.5 离线数字数据集中的原始样本，以及在保留不同数量 M 个主成分时得到的 PCA 重建结果。随着 M 的增大，重建结果变得更加精确，并且当 $M = D = 28 \times 28 = 784$ 时，重建将变得完全一致。

的一个数量级。我们在对该数据集应用 K 均值算法时，首先对两个变量分别做线性缩放，使每个变量都具有零均值和单位方差，这称为对数据进行标准化。标准化后的数据的协方差矩阵的元素为

$$\rho_{ij} = \frac{1}{N} \sum_{n=1}^N \frac{(x_{ni} - \bar{x}_i)}{\sigma_i} \frac{(x_{nj} - \bar{x}_j)}{\sigma_j} \quad (12.22)$$

其中 σ_i 是 x_i 的方差。这就是原始数据的相关矩阵。它具有这样一个性质：如果数据分量 x_i 与 x_j 完全相关，则 $\rho_{ij} = 1$ ；如果它们不相关，则 $\rho_{ij} = 0$ 。

利用 PCA，我们可以对数据进行更彻底的归一化，使其不仅具有零均值，而且协方差矩阵为单位阵，从而使得不同变量之间互相不相关。为此，我们先将特征向量方程 (12.17) 写成矩阵形式：

$$\mathbf{S}\mathbf{U} = \mathbf{U}\mathbf{L} \quad (12.23)$$

其中 $\mathbf{L}$ 是一个 $D \times D$ 的对角矩阵，对角元为 λ_i ， $\mathbf{U}$ 是一个 $D \times D$ 的正交矩阵，其列向量为 $\mathbf{u}_i$ 。然后，对于每个数据点 $\mathbf{x}_n$ ，我们定义一个变换后的值：

$$\mathbf{y}_n = \mathbf{L}^{-1/2} \mathbf{U}^T (\mathbf{x}_n - \bar{\mathbf{x}}) \quad (12.24)$$

其中 $\bar{\mathbf{x}}$ 为 (12.1) 所定义的样本均值。显然，集合 $\{\mathbf{y}_n\}$ 的均值为零，其协方差为单位阵，因为

$$\begin{aligned} \frac{1}{N} \sum_{n=1}^N \mathbf{y}_n \mathbf{y}_n^T &= \frac{1}{N} \sum_{n=1}^N \mathbf{L}^{-1/2} \mathbf{U}^T (\mathbf{x}_n - \bar{\mathbf{x}}) (\mathbf{x}_n - \bar{\mathbf{x}})^T \mathbf{U} \mathbf{L}^{-1/2} \\ &= \mathbf{L}^{-1/2} \mathbf{U}^T \mathbf{S} \mathbf{U} \mathbf{L}^{-1/2} = \mathbf{L}^{-1/2} \mathbf{L} \mathbf{L}^{-1/2} = \mathbf{I} \end{aligned} \quad (12.25)$$

这一操作被称为对数据进行白化 (whitening) 或球化 (sphereing)，在 Old Faithful 数据集上的效果如图 12.6 所示。

将 PCA 与第 4.1.4 节讨论的 Fisher 线性判别进行对比是很有意思的。两者都可以被视为线性降维技术。然而，PCA 是无监督方法，只依赖于各 $\mathbf{x}_n$ 的取值；而 Fisher 线性判别还利用了类别标签信息。这一区别在图 12.7 的例子中体现得很清楚。






图 12.6 线性预处理对 Old Faithful 数据集影响的示意图。左图显示原始数据。中间的图显示将各个变量标准化为零均值、单位方差后的结果，同时还绘制了该归一化数据集的主轴，其范围为 $\pm\lambda_i^{1/2}$ 。右图显示对数据进行白化处理后的结果，使其具有零均值和单位协方差。

图 12.7 主成分分析与 Fisher 线性判别在线性降维方面的比较。这里将属于两个类别（分别用红色和蓝色表示）的二维数据投影到一维空间中。PCA 选择的是最大方差方向，如洋红色曲线所示，这会导致类别之间出现较强的重叠；而 Fisher 线性判别则考虑了类别标签，将数据投影到绿色曲线上，从而得到更好的类别分离效果。



主成分分析的另一个常见应用是数据可视化。在这种情形下，我们将每个数据点投影到一个二维 ($M = 2$) 主子空间中，因此数据点 $\mathbf{x}_n$ 在散点图上的笛卡儿坐标为 $\mathbf{x}_n^T \mathbf{u}_1$ 与 $\mathbf{x}_n^T \mathbf{u}_2$ ，其中 $\mathbf{u}_1$ 与 $\mathbf{u}_2$ 分别为对应于最大与次大特征值的特征向量。图 12.8 展示了对油流数据集这样处理后得到的一个示例图。

图 12.8 通过将数据投影到前两个主成分上得到的油流数据集的可视化结果。红色、蓝色和绿色点分别对应于“层流”、“均匀流”和“环状流”的流动构型。



12.1.4 高维数据上的 PCA

在某些主成分分析的应用中，数据点的数量小于数据空间的维度。例如，我们可能希望对一个只包含几百幅图像的数据集做 PCA，而每幅图像对应于一个维度高达几

百万的向量（对应于图像中每个像素的三个颜色值）。注意，在一个 D 维空间中，当 $N < D$ 时， N 个点所定义的线性子空间的维度最多为 $N - 1$ ，因此在 $M > N - 1$ 的情形下进行 PCA 并没有太大意义。实际上，如果我们执行 PCA，会发现至少有 $D - N + 1$ 个特征值为零，对应的数据集在这些特征向量方向上的方差为零。此外，对一个 $D \times D$ 矩阵求特征向量的典型算法，其计算代价通常随 $O(D^3)$ 缩放，因此对于图像这类高维应用，直接进行 PCA 在计算上是不可行的。

我们可以如下解决这一问题。首先，令 $\mathbf{X}$ 为一个 $(N \times D)$ 维的中心化数据矩阵，其第 n 行为 $(\mathbf{x}_n - \bar{\mathbf{x}})^T$ 。此时协方差矩阵 (12.3) 可以写为 $\mathbf{S} = N^{-1}\mathbf{X}^T\mathbf{X}$ ，相应的特征向量方程为

$$\frac{1}{N}\mathbf{X}^T\mathbf{X}\mathbf{u}_i = \lambda_i\mathbf{u}_i. \quad (12.26)$$

现在在两边左乘 $\mathbf{X}$ ，得到

$$\frac{1}{N}\mathbf{X}\mathbf{X}^T(\mathbf{X}\mathbf{u}_i) = \lambda_i(\mathbf{X}\mathbf{u}_i). \quad (12.27)$$

若定义 $\mathbf{v}_i = \mathbf{X}\mathbf{u}_i$ ，则可得

$$\frac{1}{N}\mathbf{X}\mathbf{X}^T\mathbf{v}_i = \lambda_i\mathbf{v}_i \quad (12.28)$$

这就是对 $N \times N$ 矩阵 $N^{-1}\mathbf{X}\mathbf{X}^T$ 的特征向量方程。可以看出，该矩阵与原协方差矩阵具有相同的 $N - 1$ 个特征值（而协方差矩阵本身还有额外的 $D - N + 1$ 个值为零的特征值）。因此，我们可以在较低维空间中求解特征向量问题，其计算代价由 $O(D^3)$ 降为 $O(N^3)$ 。为了得到原数据空间中的特征向量，我们再对 (12.28) 两边左乘 $\mathbf{X}^T$ ，得到

$$\left(\frac{1}{N}\mathbf{X}^T\mathbf{X}\right)(\mathbf{X}^T\mathbf{v}_i) = \lambda_i(\mathbf{X}^T\mathbf{v}_i) \quad (12.29)$$

由此可见， $(\mathbf{X}^T\mathbf{v}_i)$ 是 $\mathbf{S}$ 的一个特征向量，对应特征值为 λ_i 。不过需要注意，这些特征向量一般并未归一化。为了确定合适的归一化，我们需要按某个常数比例重缩放 $\mathbf{u}_i \propto \mathbf{X}^T\mathbf{v}_i$ ，使得 $\|\mathbf{u}_i\| = 1$ 。假设 $\mathbf{v}_i$ 已归一化为单位长度，则有

$$\mathbf{u}_i = \frac{1}{(N\lambda_i)^{1/2}}\mathbf{X}^T\mathbf{v}_i. \quad (12.30)$$

总之，运用这种方法时，我们首先计算 $\mathbf{X}\mathbf{X}^T$ 并求其特征值与特征向量，然后利用 (12.30) 计算原数据空间中的特征向量。

12.2 概率 PCA

上一节讨论的 PCA 形式是基于将数据线性投影到一个维度低于原数据空间的子空间上。现在我们将说明，PCA 也可以表述为某一概率潜在变量模型的最大似然解。这一重述形式称为概率 PCA (probabilistic PCA)，与传统 PCA 相比有多方面优势：

- 概率 PCA 对高斯分布施加了一种约束形式，使得可以在限制自由参数数量的前提下，仍然让模型捕捉到数据集主导相关结构。
- 我们可以推导出 PCA 的 EM 算法。在只需少数前导特征向量的场景中，该算法在计算上更加高效，并且避免把数据协方差矩阵作为中间步骤显式计算出来。

- 概率模型与 EM 相结合，使我们能够处理数据集中的缺失值。
- 可以以有原则的方式构造概率 PCA 模型的混合模型，并使用 EM 算法进行训练。
- 概率 PCA 为 PCA 的贝叶斯处理奠定了基础，可以从数据中自动确定主子空间的维度。
- 由于存在似然函数，可以直接与其他概率密度模型进行比较；相比之下，传统 PCA 只会对靠近主子空间的点给出较低的重构代价，即便这些点与训练数据相距很远。
- 概率 PCA 可以用来建模类别条件密度，因此可用于分类问题。
- 概率 PCA 模型可以以生成式方式运行，从分布中生成样本。

这种将 PCA 作为概率模型的表述最早由 Tipping 和 Bishop (1997, 1999b) 以及 Roweis (1998) 各自独立提出。正如我们稍后会看到的，它与因子分析 (Basilevsky, 1994) 密切相关。

概率 PCA 是线性-高斯框架的一个简单例子，在该框架中所有的边缘分布与条件分布都是高斯分布。我们可以这样构造概率 PCA：首先引入一个显式的潜在变量 $\mathbf{z}$ ，它对应于主成分空间。然后为潜在变量定义一个高斯先验分布 $p(\mathbf{z})$ ，并为观测变量 $\mathbf{x}$ （在给定潜在变量的条件下）定义一个高斯条件分布 $p(\mathbf{x} | \mathbf{z})$ 。具体来说，潜在变量 $\mathbf{z}$ 的先验分布为零均值、单位协方差的高斯分布：

$$p(\mathbf{z}) = \mathcal{N}(\mathbf{z} | \mathbf{0}, \mathbf{I}). \quad (12.31)$$

类似地，在给定潜在变量 $\mathbf{z}$ 的条件下，观测变量 $\mathbf{x}$ 的条件分布也是高斯分布，形式为

$$p(\mathbf{x} | \mathbf{z}) = \mathcal{N}(\mathbf{x} | \mathbf{W}\mathbf{z} + \boldsymbol{\mu}, \sigma^2 \mathbf{I}) \quad (12.32)$$

其中 $\mathbf{x}$ 的均值是 $\mathbf{z}$ 的一般线性函数，由 $D \times M$ 矩阵 $\mathbf{W}$ 和 D 维向量 $\boldsymbol{\mu}$ 决定。注意，该分布对 $\mathbf{x}$ 的各分量是因子化的，也就是说这是朴素贝叶斯模型的一个例子。正如我们稍后将看到的，矩阵 $\mathbf{W}$ 的列向量张成了数据空间中的一个线性子空间，该子空间就对应于主子空间。模型中的另一个参数是标量 σ^2 ，它控制条件分布的方差。需要注意的是，将潜在分布 $p(\mathbf{z})$ 设为零均值、单位协方差高斯的假设并不损失一般性，因为更一般的高斯先验可以对应到一个等价的概率模型。

我们可以从生成式视角来理解概率 PCA 模型：要得到一个观测变量的样本值，先从潜在变量中抽取一个值，然后在给定该潜在值的条件下对观测变量进行采样。具体来说， D 维观测变量 $\mathbf{x}$ 是 M 维潜在变量 $\mathbf{z}$ 经线性变换并加上高斯噪声后得到的：

$$\mathbf{x} = \mathbf{W}\mathbf{z} + \boldsymbol{\mu} + \boldsymbol{\epsilon} \quad (12.33)$$

其中 $\mathbf{z}$ 是 M 维高斯潜在变量， $\boldsymbol{\epsilon}$ 是 D 维零均值高斯噪声变量，其协方差为 $\sigma^2 \mathbf{I}$ 。该生成过程如图 12.9 所示。注意，这一框架是基于从潜在空间到数据空间的映射，与前面更




图 12.9 概率 PCA 模型生成式观点的示意图，其中数据空间为二维，潜在空间为一维。一个观测数据点 $\mathbf{x}$ 的生成过程是：首先从其先验分布 $p(z)$ 中为潜在变量抽取一个取值 $\hat{z}$ ，然后从一个各向同性高斯分布（由红色圆圈表示）中抽取 $\mathbf{x}$ ，该高斯分布的均值为 $\mathbf{w}\hat{z} + \mu$ ，协方差为 $\sigma^2 \mathbf{I}$ 。绿色椭圆表示边缘分布 $p(\mathbf{x})$ 的密度等高线。

常见的 PCA 视角（从数据空间到潜在空间的线性投影）相反。反向映射——从数据空间到潜在空间——将在稍后通过贝叶斯定理得到。

假设我们希望通过最大似然来确定参数 $\mathbf{W}$ 、 μ 与 σ^2 的取值。要写出似然函数，需要先给出观测变量的边缘分布 $p(\mathbf{x})$ 。根据概率论中的求和与乘积法则，边缘分布可以写作

$$p(\mathbf{x}) = \int p(\mathbf{x} | \mathbf{z}) p(\mathbf{z}) d\mathbf{z} \quad (12.34)$$

由于这是一个线性-高斯模型，对应的边缘分布仍然是高斯分布，其形式为

$$p(\mathbf{x}) = \mathcal{N}(\mathbf{x} | \mu, \mathbf{C}) \quad (12.35)$$

其中 $D \times D$ 协方差矩阵 $\mathbf{C}$ 定义为

$$\mathbf{C} = \mathbf{W}\mathbf{W}^T + \sigma^2 \mathbf{I}. \quad (12.36)$$

这一结果也可以更直接地推导：只需注意到预测分布必然是高斯分布，然后用 (12.33) 求其均值与协方差即可。具体来说，

$$\mathbb{E}[\mathbf{x}] = \mathbb{E}[\mathbf{W}\mathbf{z} + \mu + \epsilon] = \mu \quad (12.37)$$

$$\begin{aligned} \text{cov}[\mathbf{x}] &= \mathbb{E}[(\mathbf{W}\mathbf{z} + \epsilon)(\mathbf{W}\mathbf{z} + \epsilon)^T] \\ &= \mathbb{E}[\mathbf{W}\mathbf{z}\mathbf{z}^T\mathbf{W}^T] + \mathbb{E}[\epsilon\epsilon^T] = \mathbf{W}\mathbf{W}^T + \sigma^2 \mathbf{I} \end{aligned} \quad (12.38)$$

这里我们利用了 $\mathbf{z}$ 与 ϵ 是相互独立的随机变量，因此它们之间不相关。

直观上，我们可以把分布 $p(\mathbf{x})$ 想象为：拿一个各向同性高斯“喷雾器”，在主子空间上移动，用方差为 σ^2 的高斯“墨水”进行喷涂，喷涂密度则由先验分布控制。累积的喷涂结果就形成了“薄饼”形状的分布，即 $p(\mathbf{x})$ 的边缘密度。

预测分布 $p(\mathbf{x})$ 由参数 μ 、 $\mathbf{W}$ 与 σ^2 所决定。然而，在这一参数化中存在冗余，对应于潜在空间坐标的旋转。为说明这一点，考虑矩阵 $\tilde{\mathbf{W}} = \mathbf{W}\mathbf{R}$ ，其中 $\mathbf{R}$ 为正交矩阵。利用 $\mathbf{R}\mathbf{R}^T = \mathbf{I}$ ，可以看出出现在协方差矩阵 $\mathbf{C}$ 中的量 $\tilde{\mathbf{W}}\tilde{\mathbf{W}}^T$ 为

$$\tilde{\mathbf{W}}\tilde{\mathbf{W}}^T = \mathbf{W}\mathbf{R}\mathbf{R}^T\mathbf{W}^T = \mathbf{W}\mathbf{W}^T \quad (12.39)$$

因此它与 $\mathbf{R}$ 无关。也就是说，存在一整族矩阵 $\tilde{\mathbf{W}}$ ，它们对应的预测分布完全相同。这种不变性可以理解为潜在空间内部的旋转。我们稍后会回到该模型中独立参数个数的问题。

在计算预测分布时，我们需要用到 $\mathbf{C}^{-1}$ ，这涉及对一个 $D \times D$ 矩阵求逆。利用矩阵求逆恒等式 (C.7) 可以减少此计算的工作量，从而得到

$$\mathbf{C}^{-1} = \sigma^{-2}\mathbf{I} - \sigma^{-2}\mathbf{W}\mathbf{M}^{-1}\mathbf{W}^T \quad (12.40)$$

其中 $M \times M$ 矩阵 $\mathbf{M}$ 定义为

$$\mathbf{M} = \mathbf{W}^T\mathbf{W} + \sigma^2\mathbf{I}. \quad (12.41)$$

由于我们求逆的是 $\mathbf{M}$ 而非直接对 $\mathbf{C}$ 求逆，因此求 $\mathbf{C}^{-1}$ 的计算代价由 $O(D^3)$ 降为 $O(M^3)$ 。


除了预测分布 $p(\mathbf{x})$ 之外，我们还需要后验分布 $p(\mathbf{z} | \mathbf{x})$ 。同样可以利用线性-高斯模型的结果 (2.116) 直接写出：

$$p(\mathbf{z} | \mathbf{x}) = \mathcal{N}(\mathbf{z} | \mathbf{M}^{-1}\mathbf{W}^T(\mathbf{x} - \boldsymbol{\mu}), \sigma^2\mathbf{M}^{-1}). \quad (12.42)$$

需要注意的是，后验均值依赖于 $\mathbf{x}$ ，而后验协方差则与 $\mathbf{x}$ 无关。

12.2.1 最大似然 PCA

图 12.10 对于包含 N 个观测值 $\mathbf{x}$ 的数据集，其概率 PCA 模型可以表示为一个有向图，其中每个观测 $\mathbf{x}_n$ 都对应于潜在变量的一个取值 z_n 。



接下来我们来讨论如何用最大似然方法确定模型参数。给定一个观测数据点集合 $\mathbf{X} = \{\mathbf{x}_n\}$ ，概率 PCA 模型可以表示为一个有向图，如图 12.10 所示。对应的对数似然函数由 (12.35) 给出：

$$\begin{aligned} \ln p(\mathbf{X} | \boldsymbol{\mu}, \mathbf{W}, \sigma^2) &= \sum_{n=1}^N \ln p(\mathbf{x}_n | \mathbf{W}, \boldsymbol{\mu}, \sigma^2) \\ &= -\frac{ND}{2} \ln(2\pi) - \frac{N}{2} \ln |\mathbf{C}| - \frac{1}{2} \sum_{n=1}^N (\mathbf{x}_n - \boldsymbol{\mu})^T \mathbf{C}^{-1} (\mathbf{x}_n - \boldsymbol{\mu}). \end{aligned} \quad (12.43)$$

对 $\boldsymbol{\mu}$ 求偏导并令其为零，可以得到期望中的结果 $\boldsymbol{\mu} = \bar{\mathbf{x}}$ ，其中 $\bar{\mathbf{x}}$ 为 (12.1) 定义的样本均值。将其代回上式，可以把对数似然函数写为

$$\ln p(\mathbf{X} | \mathbf{W}, \boldsymbol{\mu}, \sigma^2) = -\frac{N}{2} \{D \ln(2\pi) + \ln |\mathbf{C}| + \text{Tr}(\mathbf{C}^{-1}\mathbf{S})\} \quad (12.44)$$

其中 $\mathbf{S}$ 为 (12.3) 定义的数据协方差矩阵。由于 $\ln p$ 对 $\boldsymbol{\mu}$ 为二次函数，因此该解是唯一的最大值，这一点可以通过计算二阶导数来确认。

关于 $\mathbf{W}$ 与 σ^2 的最大化要复杂一些，但仍然存在精确的闭式解。Tipping 与 Bishop (1999b) 证明，对数似然函数的所有驻点都可以写成

$$\mathbf{W}_{\text{ML}} = \mathbf{U}_M (\mathbf{L}_M - \sigma^2 \mathbf{I})^{1/2} \mathbf{R} \quad (12.45)$$

其中 $\mathbf{U}_M$ 为 $D \times M$ 矩阵，其列向量为数据协方差矩阵 $\mathbf{S}$ 的任意一组（大小为 M ）特征向量； $M \times M$ 对角矩阵 $\mathbf{L}_M$ 的对角元为对应的特征值 λ_i ； $\mathbf{R}$ 为任意 $M \times M$ 正交矩阵。

此外，Tipping 与 Bishop (1999b) 还证明，对数似然函数的最大值是在将这 M 个特征向量选为对应最大 M 个特征值时取得的（其余解都是鞍点）。Roweis (1998) 也独立地得出了类似结论，不过并未给出证明。我们依然假定特征向量按特征值从大到小排列，因此前 M 个主特征向量为 $\mathbf{u}_1, \dots, \mathbf{u}_M$ 。此时， $\mathbf{W}$ 的列向量定义了标准 PCA 的主子空间。相应的 σ^2 的最大似然解为

$$\sigma_{\text{ML}}^2 = \frac{1}{D - M} \sum_{i=M+1}^D \lambda_i \quad (12.46)$$

因此 σ_{ML}^2 就是被抛弃维度上的平均方差。

由于 $\mathbf{R}$ 是正交矩阵，可以把它看作 $M \times M$ 潜在空间中的一个旋转矩阵。如果将 $\mathbf{W}$ 的最大似然解代入 $\mathbf{C}$ 的表达式，并利用 $\mathbf{R}\mathbf{R}^T = \mathbf{I}$ ，可以看出 $\mathbf{C}$ 与 $\mathbf{R}$ 无关。这恰好说明，正如前面讨论的那样，预测密度在潜在空间的旋转下保持不变。特别地，当 $\mathbf{R} = \mathbf{I}$ 时， $\mathbf{W}$ 的列向量是主成分特征向量，并由方差项 $\lambda_i - \sigma^2$ 进行缩放。一旦我们意识到对于独立高斯分布的卷积（本例中为潜在空间分布与噪声模型），方差是相加的，便可以很容易理解这些缩放因子的含义：沿特征向量 $\mathbf{u}_i$ 的方差 λ_i 由两部分组成：一部分为从单位方差潜在空间分布通过 $\mathbf{W}$ 的对应列投影到数据空间后的贡献 $\lambda_i - \sigma^2$ ；另一部分为噪声模型在所有方向上添加的各向同性方差 σ^2 。

我们有必要花一点时间来研究 (12.36) 所给出的协方差矩阵形式。考虑预测分布在某一方向上的方差，该方向由单位向量 $\mathbf{v}$ 指定， $\mathbf{v}^T \mathbf{v} = 1$ ，此时方差为 $\mathbf{v}^T \mathbf{C} \mathbf{v}$ 。首先假设 $\mathbf{v}$ 与主子空间正交，也就是说它可以表示为被舍弃特征向量的线性组合。这时有 $\mathbf{v}^T \mathbf{U}_M = 0$ ，于是 $\mathbf{v}^T \mathbf{C} \mathbf{v} = \sigma^2$ 。因此模型在与主子空间正交的方向上预测噪声方差为 σ^2 ，而根据 (12.46)，它正好是被舍弃特征值的平均值。再假设 $\mathbf{v} = \mathbf{u}_i$ ，其中 $\mathbf{u}_i$ 为定义主子空间的保留特征向量之一。此时有 $\mathbf{v}^T \mathbf{C} \mathbf{v} = (\lambda_i - \sigma^2) + \sigma^2 = \lambda_i$ 。换言之，该模型在主轴方向上准确地刻画了数据方差，并用单一的平均值 σ^2 来近似所有剩余方向上的方差。

构造最大似然密度模型的一种方式：先求出数据协方差矩阵的特征向量与特征值，再利用上述结果计算 $\mathbf{W}$ 与 σ^2 。在这种情况下，为简便起见，我们通常取 $\mathbf{R} = \mathbf{I}$ 。然而，如果我们通过直接数值优化对数似然（例如使用共轭梯度法 (Fletcher, 1987; Nocedal and Wright, 1999; Bishop and Nabney, 2008) 或 EM 算法）来寻找最大似然解，则得到的 $\mathbf{R}$ 取值基本上是任意的。这意味着 $\mathbf{W}$ 的列向量未必正交。如果需要一个正交基，可以对矩阵 $\mathbf{W}$ 做后处理 (Golub and Van Loan, 1996)。或者也可以对 EM 算法进行改造，使其直接给出按特征值降序排列的正交主方向 (Ahn and Oh, 2003)。

潜在空间中的旋转不变性体现了一种统计上的不可识别性，这与在离散潜在变量

的混合模型中遇到的情形类似。不同的是，这里存在的是一整条连续的参数族，它们对应的预测密度完全相同，而混合模型中的不可识别性则来自于组件标签的离散重标记。

考虑 $M = D$ 的情形，此时不再进行降维， $\mathbf{U}_M = \mathbf{U}$ 、 $\mathbf{L}_M = \mathbf{L}$ 。利用 $\mathbf{U}\mathbf{U}^T = \mathbf{I}$ 与 $\mathbf{R}\mathbf{R}^T = \mathbf{I}$ ，可以看出观测变量 $\mathbf{x}$ 的边缘分布协方差矩阵 $\mathbf{C}$ 为

$$\mathbf{C} = \mathbf{U} (\mathbf{L} - \sigma^2 \mathbf{I})^{1/2} \mathbf{R}\mathbf{R}^T (\mathbf{L} - \sigma^2 \mathbf{I})^{1/2} \mathbf{U}^T + \sigma^2 \mathbf{I} = \mathbf{U}\mathbf{L}\mathbf{U}^T = \mathbf{S} \quad (12.47)$$

于是我们得到一个无约束高斯分布的标准最大似然解，其中协方差矩阵正是样本协方差矩阵。

传统 PCA 一般被表述为将点从 D 维数据空间投影到 M 维线性子空间上。然而，概率 PCA 则更自然地表述为通过 (12.33) 从潜在空间映射到数据空间。对于可视化和数据压缩这类应用，我们可以利用贝叶斯定理将这一映射反向过来。这样，数据空间中的任意一点 $\mathbf{x}$ 都可以通过其在潜在空间中的后验均值和协方差来进行概括。由 (12.42) 可知，其后验均值为

$$\mathbb{E}[\mathbf{z} | \mathbf{x}] = \mathbf{M}^{-1} \mathbf{W}_{\text{ML}}^T (\mathbf{x} - \bar{\mathbf{x}}) \quad (12.48)$$

其中 $\mathbf{M}$ 由 (12.41) 给出。这一后验均值通过

$$\mathbf{W} \mathbb{E}[\mathbf{z} | \mathbf{x}] + \boldsymbol{\mu} \quad (12.49)$$

投影回数据空间中的一点。注意，这与正则化线性回归的形式相同，这是对线性高斯模型的似然函数进行最大化所带来的结果。同样地，由 (12.42) 可知，后验协方差为 $\sigma^2 \mathbf{M}^{-1}$ ，且与 $\mathbf{x}$ 无关。

如果令 $\sigma^2 \rightarrow 0$ ，则后验均值退化为

$$(\mathbf{W}_{\text{ML}}^T \mathbf{W}_{\text{ML}})^{-1} \mathbf{W}_{\text{ML}}^T (\mathbf{x} - \bar{\mathbf{x}}) \quad (12.50)$$

这表示数据点在潜在空间上的一个正交投影，因此我们就恢复了标准的 PCA 模型。不过在这一极限下，后验协方差为零，相应的概率密度变得奇异。对于 $\sigma^2 > 0$ 的情况，相比于正交投影，潜在空间中的投影会向原点方向偏移。

最后需要指出的是，概率 PCA 模型的一个重要作用，是定义一种多元高斯分布：在这种分布中，可以在控制自由度数量（也就是独立参数的数目）的同时，仍然让模型捕捉到数据中的主导相关结构。回忆一下，一般高斯分布的协方差矩阵中有 $D(D+1)/2$ 个独立参数（外加均值中的 D 个参数）。因此参数数量随 D 的平方增长，在高维空间中会变得过于庞大。如果我们把协方差矩阵限制为对角形式，那么它只有 D 个独立参数，参数数量就随维度线性增长。然而这时模型会把各变量视为相互独立，从而无法表达它们之间的任何相关性。概率 PCA 提供了一种优雅的折中方式：在保持参数数量随 D 线性增长的前提下，仍然可以捕捉最重要的 M 个相关结构。我们可以通过计算 PPCA 模型中的自由度数量来看到这一点。协方差矩阵 $\mathbf{C}$ 依赖于参数 $\mathbf{W}$ 与 σ^2 。其中 $\mathbf{W}$ 的大小为 $D \times M$ ，再加上一个 σ^2 ，总共有 $DM+1$ 个参数。然而，如前所述，这一参数化中与潜在空间坐标旋转相关的部分存在冗余。表示这些旋转的正交矩阵 $\mathbf{R}$ 大小为 $M \times M$ 。

在该矩阵的第一列中，有 $M - 1$ 个独立参数，因为列向量必须归一化为单位长度；第二列中有 $M - 2$ 个独立参数，因为该列既要归一化还要与前一列正交，以此类推。将这一等差数列求和可知， $\mathbf{R}$ 一共有 $M(M - 1)/2$ 个独立参数。因此，协方差矩阵 $\mathbf{C}$ 中的自由度数量为

$$DM + 1 - \frac{M(M - 1)}{2}. \quad (12.51)$$

因此，在固定 M 的前提下，该模型中的独立参数数目只随 D 线性增长。如果取 $M = D - 1$ ，则可以恢复具有完整协方差的高斯分布的标准结果。在这种情况下，沿着 $D - 1$ 个线性无关方向上的方差由 $\mathbf{W}$ 的列向量控制，而剩余方向上的方差为 σ^2 。如果取 $M = 0$ ，则该模型等价于各向同性协方差情形。

12.2.2 PCA 的 EM 算法

正如我们已经看到的，概率 PCA 模型可以通过对连续潜在空间 $\mathbf{z}$ 进行边缘化来表达，其中每个数据点 $\mathbf{x}_n$ 都对应一个潜在变量 $\mathbf{z}_n$ 。因此，我们可以利用 EM 算法来寻找模型参数的最大似然估计。乍一看这似乎有些多余，因为我们已经得到了最大似然参数的精确闭式解。然而在高维空间中，与直接基于样本协方差矩阵进行计算相比，采用迭代的 EM 过程可能在计算上更为有利。此外，该 EM 过程可以推广到因子分析模型，而后者并不存在闭式解。最后，EM 还允许我们以有原则的方式处理数据中的缺失值。

我们可以按照 EM 的通用框架推导概率 PCA 的 EM 算法。也就是说，我们先写出完整数据对数似然，然后对其在“旧”参数下的潜在变量后验分布取期望。最大化这一期望的完整数据对数似然就得到“新”的参数值。由于假设数据点之间相互独立，完整数据对数似然为

$$\ln p(\mathbf{X}, \mathbf{Z} | \boldsymbol{\mu}, \mathbf{W}, \sigma^2) = \sum_{n=1}^N \{\ln p(\mathbf{x}_n | \mathbf{z}_n) + \ln p(\mathbf{z}_n)\} \quad (12.52)$$

其中矩阵 $\mathbf{Z}$ 的第 n 行为 $\mathbf{z}_n$ 。我们已经知道， $\boldsymbol{\mu}$ 的精确最大似然解为 (12.1) 中定义的样本均值 $\bar{\mathbf{x}}$ ，因此在这个阶段用 $\bar{\mathbf{x}}$ 来替代 $\boldsymbol{\mu}$ 会比较方便。利用 (12.31) 与 (12.32) 给出的潜在分布与条件分布，并对潜在变量的后验分布取期望，可以得到

$$\begin{aligned} \mathbb{E} [\ln p(\mathbf{X}, \mathbf{Z} | \boldsymbol{\mu}, \mathbf{W}, \sigma^2)] = & - \sum_{n=1}^N \left\{ \frac{D}{2} \ln(2\pi\sigma^2) + \frac{1}{2} \text{Tr}(\mathbb{E}[\mathbf{z}_n \mathbf{z}_n^T]) \right. \\ & + \frac{1}{2\sigma^2} \|\mathbf{x}_n - \boldsymbol{\mu}\|^2 - \frac{1}{\sigma^2} \mathbb{E}[\mathbf{z}_n]^T \mathbf{W}^T (\mathbf{x}_n - \boldsymbol{\mu}) \\ & \left. + \frac{1}{2\sigma^2} \text{Tr}(\mathbb{E}[\mathbf{z}_n \mathbf{z}_n^T] \mathbf{W}^T \mathbf{W}) \right\}. \end{aligned} \quad (12.53)$$

注意，这里它仅通过高斯分布的充分统计量依赖于后验分布。因此在 E 步中，我们利用旧参数来计算

$$\mathbb{E}[\mathbf{z}_n] = \mathbf{M}^{-1} \mathbf{W}^T (\mathbf{x}_n - \bar{\mathbf{x}}) \quad (12.54)$$

$$\mathbb{E}[\mathbf{z}_n \mathbf{z}_n^T] = \sigma^2 \mathbf{M}^{-1} + \mathbb{E}[\mathbf{z}_n] \mathbb{E}[\mathbf{z}_n]^T \quad (12.55)$$

它们直接来自后验分布 (12.42)，并结合标准结果 $\mathbb{E}[\mathbf{z}_n \mathbf{z}_n^T] = \text{cov}[\mathbf{z}_n] + \mathbb{E}[\mathbf{z}_n] \mathbb{E}[\mathbf{z}_n]^T$ 。其中 $\mathbf{M}$ 由 (12.41) 定义。

在 $\mathbf{M}$ 步中，我们在保持后验统计量不变的前提下，对 $\mathbf{W}$ 与 σ^2 进行最大化。关于 σ^2 的最大化是直接的；而关于 $\mathbf{W}$ 的最大化可以利用 (C.24)，从而得到 $\mathbf{M}$ 步更新方程：

$$\mathbf{W}_{\text{new}} = \left[\sum_{n=1}^N (\mathbf{x}_n - \bar{\mathbf{x}}) \mathbb{E}[\mathbf{z}_n]^T \right] \left[\sum_{n=1}^N \mathbb{E}[\mathbf{z}_n \mathbf{z}_n^T] \right]^{-1} \quad (12.56)$$

$$\begin{aligned} \sigma_{\text{new}}^2 = & \frac{1}{ND} \sum_{n=1}^N \left\{ \|\mathbf{x}_n - \bar{\mathbf{x}}\|^2 - 2 \mathbb{E}[\mathbf{z}_n]^T \mathbf{W}_{\text{new}}^T (\mathbf{x}_n - \bar{\mathbf{x}}) \right. \\ & \left. + \text{Tr}(\mathbb{E}[\mathbf{z}_n \mathbf{z}_n^T] \mathbf{W}_{\text{new}}^T \mathbf{W}_{\text{new}}) \right\}. \end{aligned} \quad (12.57)$$

因此，概率 PCA 的 EM 算法通过初始化参数，然后在 E 步中利用 (12.54) 与 (12.55) 计算潜在空间后验分布的充分统计量，并在 $\mathbf{M}$ 步中利用 (12.56) 与 (12.57) 修正参数值，如此交迭代。

EM 算法用于 PCA 的优点之一是其在大规模应用中的计算效率 (Roweis, 1998)。与基于样本协方差矩阵特征分解的传统 PCA 不同，EM 方法是迭代的，看起来似乎不那么吸引人。不过，在高维空间中，EM 算法每一轮的计算量可能远小于传统 PCA。为说明这一点，我们注意到：协方差矩阵的特征分解需要 $O(D^3)$ 的计算量。通常我们只关心前 M 个特征向量及其对应的特征值，此时可以使用 $O(MD^2)$ 的算法。然而，仅计算协方差矩阵本身就需要 $O(ND^2)$ 的运算量，其中 N 为数据点数目。诸如快照法 (snapshot method; Sirovich, 1987) 这类算法假设特征向量是数据向量的线性组合，从而避免了直接构造协方差矩阵，但其复杂度为 $O(N^3)$ ，不适用于大数据集。这里所述的 EM 算法同样不显式构造协方差矩阵。它计算量最大的一部分是对数据集求和的步骤，这些步骤的复杂度为 $O(NDM)$ 。在 D 很大且 $M \ll D$ 的情况下，这一复杂度相较于 $O(ND^2)$ 可显著降低，从而抵消 EM 算法迭代性的代价。

需要注意的是，这一 EM 算法可以以在线形式实现：每次读入并处理一个 D 维数据点，然后在处理下一个数据点之前将其丢弃。为说明这一点，注意在 E 步中我们为每个数据点分别计算一个 M 维向量和一个 $M \times M$ 矩阵；而在 $\mathbf{M}$ 步中，我们需要累加对各数据点的求和，这可以增量完成。当 N 与 D 都很大时，这种做法会很有优势。

由于我们现在拥有一个完整的 PCA 概率模型，因此可以处理随机缺失的数据，只要缺失是随机发生的。处理方法是对未观测变量的分布进行边缘化，同样可以借助 EM 算法。我们在图 12.11 中给出了这一方法在数据可视化中的一个示例。

EM 方法的另一个优雅特性是：即便我们取极限 $\sigma^2 \rightarrow 0$ (对应标准 PCA)，仍然可以得到一个有效的类似 EM 的算法 (Roweis, 1998)。由 (12.55) 可知，在该极限下，E 步中唯一需要计算的量就是 $\mathbb{E}[\mathbf{z}_n]$ ，并且此时 $\mathbf{M}$ 步变得更为简单，因为 $\mathbf{M} = \mathbf{W}^T \mathbf{W}$ 。为凸显算法的简洁性，我们定义大小为 $N \times D$ 的矩阵 $\tilde{\mathbf{X}}$ ，其第 n 行为向量 $\mathbf{x}_n - \bar{\mathbf{x}}$ ；同时定义大小为 $D \times M$ 的矩阵 Ω ，其第 n 行为向量 $\mathbb{E}[\mathbf{z}_n]$ 。此时，PCA 的 EM 算法在 E 步




图 12.11 对油流数据集中前 100 个数据点进行的概率 PCA 可视化。左图显示了数据点在主子空间上的后验均值投影。右图则是先随机省略 30% 的变量取值，然后使用 EM 算法来处理缺失值后得到的结果。需要注意的是，此时每个数据点至少都有一个缺失测量值，但所得图像与在没有缺失值情况下得到的结果非常相似。

(12.54) 中变为

$$\Omega = (\mathbf{W}_{\text{old}}^T \mathbf{W}_{\text{old}})^{-1} \mathbf{W}_{\text{old}}^T \tilde{\mathbf{X}} \quad (12.58)$$

而 M 步 (12.56) 则为

$$\mathbf{W}_{\text{new}} = \tilde{\mathbf{X}}^T \Omega^T (\Omega \Omega^T)^{-1}. \quad (12.59)$$

同样地，这些步骤也可以以在线形式实现。这些方程的含义可以作如下简单解释：根据前面的讨论可知，E 步对应于将各数据点正交投影到当前估计的主子空间上；相应地，M 步则是在保持这些投影固定的前提下，重新估计主子空间以最小化重构误差平方和。

我们可以给出一个简单的物理类比来帮助直观理解这一 EM 算法，这在 $D = 2$ 且 $M = 1$ 的情形下非常容易可视化。设想在二维空间中有一堆数据点，用一根实心杆表示一维主子空间。现在将每个数据点通过一根服从胡克定律（存储能量与弹簧长度的平方成正比）的弹簧连接到杆上。在 E 步中，我们固定住杆，让各个连接点沿着杆上下滑动以最小化系统能量。这会使每个连接点（相互独立地）来到对应数据点在杆上的正交投影位置。在 M 步中，我们固定住所有连接点，释放杆并让它自由移动到能量最低的位置。接着不断重复 E 步和 M 步，直至满足某个收敛准则，如图 12.12 所示。

12.2.3 贝叶斯 PCA

到目前为止，在关于 PCA 的讨论中，我们都假设主子空间的维度 M 是已知的。在实际应用中，我们必须根据具体任务选择一个合适的 M 。对于可视化，一般取 $M = 2$ ；而对其他应用来说，合适的 M 可能并不明显。一种常用方法是，对数据集绘制特征值谱，类似于图 12.4 中离线数字数据集的例子，观察特征值是否自然分成两组：一组较小的特征值与一组较大的特征值之间存在显著“间隙”，则该间隙可以作为一个自然的维度截断点，给出 M 的选择。然而在实践中，这样的间隙往往并不明显。




图 12.12 用于说明由 (12.58) 和 (12.59) 定义的 PCA 的 EM 算法的合成数据。(a) 数据集 X ，其中数据点以绿色显示，同时给出了真实的主成分（表示为特征向量，并按特征值的平方根进行缩放）。(b) 由 $\mathbf{W}$ 定义的主子空间的初始配置，以红色显示，同时还给出了潜在点 $\mathbf{Z}$ 投影到数据空间后的结果，即 $\mathbf{ZW}^T$ ，以青色显示。(c) 经过一次 M 步之后，在保持 $\mathbf{Z}$ 固定的情况下更新了潜在空间。(d) 随后的 E 步中，在保持 $\mathbf{W}$ 固定的情况下更新了 $\mathbf{Z}$ 的取值，从而得到正交投影。(e) 第二次 M 步之后。(f) 第二次 E 步之后。

由于概率 PCA 模型具有良定义的似然函数，我们可以借助交叉验证来确定维度：在验证集上选取使对数似然最大的 M 值。不过，这种方法在计算上可能代价昂贵，特别是当我们考虑概率 PCA 混合模型（Tipping and Bishop, 1999a）时，因为此时我们希望为混合中的每个分量单独确定合适的维度。


既然已经有了 PCA 的概率表述，寻找一种贝叶斯的模型选择方法就显得自然而然。为此，我们需要对模型参数 $\boldsymbol{\mu}$ 、 $\mathbf{W}$ 与 σ^2 分别引入合适的先验分布，并对它们进行积分（边缘化）。这些积分在解析上是难以完成的，因此可以使用变分框架来近似这些边缘化（Bishop, 1999b）。由此得到的变分下界即为对数边缘似然的下界，可以对不同的 M 取值计算该下界并进行比较，选取使边缘似然最大的 M 。

这里我们考虑一种更简单的方法，它基于证据近似（evidence approximation），适用于数据点数目相对较大且对应后验分布高度尖锐的情形（Bishop, 1999a）。它采用对 $\mathbf{W}$ 的一种特殊先验，以便自动从模型中“剪除”主子空间中多余的维度。这是自动相关性确定（automatic relevance determination, ARD；参见 7.2.2 节）的一个例子。具体而言，我们对 $\mathbf{W}$ 的每一列（即定义主子空间的向量）分别定义独立高斯先验。每个高斯的方差由一个精度超参数 α_i 控制，从而有

$$p(\mathbf{W} | \boldsymbol{\alpha}) = \prod_{i=1}^M \left(\frac{\alpha_i}{2\pi} \right)^{D/2} \exp \left\{ -\frac{1}{2} \alpha_i \mathbf{w}_i^T \mathbf{w}_i \right\} \quad (12.60)$$

其中 $\mathbf{w}_i$ 是 $\mathbf{W}$ 的第 i 列。由此得到的模型可用图 12.13 所示的有向图来表示。

图 12.13 用于贝叶斯 PCA 的概率图模型，其中参数矩阵 $\mathbf{W}$ 上的分布由超参数向量 α 所控制。



通过最大化将 $\mathbf{W}$ 积分掉后的边缘似然，我们可以迭代求解 α_i 的值。在这一优化过程中，一些 α_i 会被推向无穷大，对应的参数向量 $\mathbf{w}_i$ 会被推向 0（后验分布收缩为在原点的 **delta** 函数），从而得到稀疏解。主子空间的有效维度由那些取有限值的 α_i 的个数决定，此时对应的 $\mathbf{w}_i$ 向量可以被视为对建模数据分布“相关”的向量。通过这种方式，贝叶斯方法会自动在以下两者之间进行权衡：一方面，通过使用更多的向量 $\mathbf{w}_i$ （以及相应的、针对数据调整的特征值 λ_i ）来提高对数据的拟合程度；另一方面，通过压制部分 $\mathbf{w}_i$ 向量来降低模型复杂度。这种稀疏性的来源在之前关于相关性向量机的讨论中已经提到过。

在训练过程中，通过最大化对数边缘似然来重新估计 α_i ，其形式为

$$p(\mathbf{X} | \alpha, \mu, \sigma^2) = \int p(\mathbf{X} | \mathbf{W}, \mu, \sigma^2) p(\mathbf{W} | \alpha) d\mathbf{W} \quad (12.61)$$

其中 $\ln p(\mathbf{X} | \mathbf{W}, \mu, \sigma^2)$ 的形式由 (12.43) 给出。注意，为了简化，在这里我们将 μ 与 σ^2 也视为待估参数，而不是再对它们引入先验。

由于上述积分在解析上是不可行的，我们采用拉普拉斯近似。假设后验分布高度尖锐（这在数据量足够大时会成立），则通过最大化边缘似然对 α_i 的重新估计方程会简化为

$$\alpha_i^{\text{new}} = \frac{D}{\mathbf{w}_i^T \mathbf{w}_i} \quad (12.62)$$

这一结果由 (3.98) 而来，并注意到 $\mathbf{w}_i$ 的维度为 D 。在训练过程中，这些重新估计与求解 $\mathbf{W}$ 与 σ^2 的 EM 更新交替进行。E 步的更新仍由 (12.54) 与 (12.55) 给出，同样地， σ^2 的 M 步更新仍由 (12.57) 给出。唯一的变化是关于 $\mathbf{W}$ 的 M 步更新方程变为

$$\mathbf{W}_{\text{new}} = \left[\sum_{n=1}^N (\mathbf{x}_n - \bar{\mathbf{x}}) \mathbb{E}[\mathbf{z}_n]^T \right] \left[\sum_{n=1}^N \mathbb{E}[\mathbf{z}_n \mathbf{z}_n^T] + \sigma^2 \mathbf{A} \right]^{-1} \quad (12.63)$$

其中 $\mathbf{A} = \text{diag}(\alpha_i)$ 。 μ 的取值仍然由样本均值给出。

如果取 $M = D - 1$ ，那么当所有 α_i 都为有限值时，该模型对应于具有完整协方差的高斯分布；当所有 α_i 都趋于无穷大时，则等价于各向同性高斯分布。因此，模型可以涵盖主子空间有效维度的所有可能取值。当然，也可以考虑更小的 M 值，这样虽能减少计算代价，但会限制子空间的最大维度。图 12.14 对该算法与标准概率 PCA 的结果做出了对比。

贝叶斯 PCA 还为我们提供了一个说明吉布斯采样算法（11.3 节）应用的机会。图 12.15 展示了在 $D = 4$ 维数据集上的一个例子，其中潜在空间维度为 $M = 3$ ，但数据是由一个概率 PCA 模型生成的，该模型具有一个高方差方向，其余方向为低方差噪声。





图 12.14 矩阵 $\mathbf{W}$ 的“Hinton”图，其中矩阵的每个元素都表示为一个方块（正值为白色，负值为黑色），其面积与该元素的幅值成正比。该合成数据集包含 300 个数据点，位于 $D = 10$ 维空间中，数据采样自一个高斯分布，在其中 3 个方向上的标准差为 1.0，其余 7 个方向上的标准差为 0.5，因此这是一个在 $D = 10$ 维空间中具有 $M = 3$ 个方差大于其余 7 个方向的数据集。左图显示的是最大似然概率 PCA 的结果，而右图显示的是贝叶斯 PCA 的对应结果。可以看到，贝叶斯模型能够通过抑制多余的 6 个自由度来发现合适的维数。

从图中可以清楚地看到后验分布的三个不同模态。在每一次迭代中，三个超参数中的一个取较小值，另两个取较大值，从而使三个潜在变量中的两个被抑制。在吉布斯采样的过程中，解在这三个模态之间发生尖锐的跳跃。

图 12.15 用于贝叶斯 PCA 的 Gibbs 采样，给出了三个 α 值下 $\ln \alpha_i$ 随迭代次数变化的曲线，展示了在后验分布的三个模态之间发生的转变。



这里描述的模型只对矩阵 $\mathbf{W}$ 引入了先验。对 $\boldsymbol{\mu}$ 、 σ^2 与 $\boldsymbol{\alpha}$ 等也一并引入先验，并使用变分方法求解的 PCA 全贝叶斯处理可参见 Bishop (1999b)。关于各种贝叶斯方法用于决定 PCA 模型合适维度的讨论，可见 Minka (2001c)。

12.2.4 因子分析

因子分析 (factor analysis) 是一种线性-高斯潜在变量模型，与概率 PCA 密切相关。它与概率 PCA 的定义唯一不同之处在于：在给定潜在变量 $\mathbf{z}$ 的条件下，观测变量 $\mathbf{x}$ 的条件分布协方差不再是各向同性，而是对角矩阵，即

$$p(\mathbf{x} | \mathbf{z}) = \mathcal{N}(\mathbf{x} | \mathbf{W}\mathbf{z} + \boldsymbol{\mu}, \boldsymbol{\Psi}) \quad (12.64)$$

其中 Ψ 为 $D \times D$ 对角矩阵。注意，因子分析模型与概率 PCA 一样，都假设在给定潜在变量 $\mathbf{z}$ 的条件下，观测变量 $x_1, \dots, x_D$ 之间是相互独立的。本质上，因子分析模型通过以下方式来解释数据的协方差结构：各坐标对应的独立方差由对角矩阵 Ψ 来表示，而变量之间的协方差则由矩阵 $\mathbf{W}$ 来捕捉。在因子分析的术语中， $\mathbf{W}$ 的列向量（捕捉观测变量之间的相关性）被称为因子载荷（factor loadings），而对角矩阵 Ψ 的元素（表示每个变量的独立噪声方差）被称为独特性（uniquenesses）。

因子分析的起源与 PCA 一样悠久，可参见 Everitt (1984)、Bartholomew (1987) 和 Basilevsky (1994) 等书。Lawley (1953) 和 Anderson (1963) 研究了因子分析与 PCA 之间的联系，他们证明：在因子分析模型的似然函数驻点处，对于 $\Psi = \sigma^2 \mathbf{I}$ 的情形， $\mathbf{W}$ 的列向量是样本协方差矩阵的缩放特征向量，而 σ^2 则是被舍弃特征值的平均值。之后，Tipping 与 Bishop (1999b) 进一步表明，当 $\mathbf{W}$ 中的特征向量选择为主特征向量时，对数似然函数达到最大值。

利用 (2.115)，可以看出观测变量的边缘分布为 $p(\mathbf{x}) = \mathcal{N}(\mathbf{x} | \boldsymbol{\mu}, \mathbf{C})$ ，其中

$$\mathbf{C} = \mathbf{W}\mathbf{W}^T + \Psi. \quad (12.65)$$

与概率 PCA 一样，该模型对潜在空间旋转是不变的。

从历史上看，当人们试图对单个因子（即 $\mathbf{z}$ 空间中的坐标）进行解释时，因子分析曾引发过不少争议，因为潜在空间的旋转不唯一，导致因子分析的不可识别性问题。相反，在本书的视角下，我们更把因子分析看作一种潜在变量密度模型，其关注点在于潜在空间本身的结构，而不是用于描述它的某个具体坐标系。如果我们希望消除与潜在空间旋转相关的退化，就必须考虑非高斯的潜在变量分布，从而得到独立成分分析（ICA）模型。

因子分析模型中的参数 $\boldsymbol{\mu}$ 、 $\mathbf{W}$ 与 Ψ 可以通过最大似然来确定。 $\boldsymbol{\mu}$ 的解仍然为样本均值。然而，与概率 PCA 不同的是，这里不再存在 $\mathbf{W}$ 的闭式最大似然解，因此必须采用迭代方法。由于因子分析是潜在变量模型，可以使用 EM 算法（Rubin and Thayer, 1982），其形式与概率 PCA 的 EM 算法类似。具体而言，E 步更新公式为

$$\mathbb{E}[\mathbf{z}_n] = \mathbf{G}\mathbf{W}^T\Psi^{-1}(\mathbf{x}_n - \bar{\mathbf{x}}) \quad (12.66)$$

$$\mathbb{E}[\mathbf{z}_n\mathbf{z}_n^T] = \mathbf{G} + \mathbb{E}[\mathbf{z}_n]\mathbb{E}[\mathbf{z}_n]^T \quad (12.67)$$

其中

$$\mathbf{G} = (\mathbf{I} + \mathbf{W}^T\Psi^{-1}\mathbf{W})^{-1} \quad (12.68)$$

注意该表达式只涉及 $M \times M$ 级别矩阵的求逆（除了 $D \times D$ 的对角矩阵 Ψ ，其逆在 $O(D)$ 的时间内就可求得），这很方便，因为通常 $M \ll D$ 。对应的 M 步更新为

$$\mathbf{W}_{\text{new}} = \left[\sum_{n=1}^N (\mathbf{x}_n - \bar{\mathbf{x}}) \mathbb{E}[\mathbf{z}_n]^T \right] \left[\sum_{n=1}^N \mathbb{E}[\mathbf{z}_n\mathbf{z}_n^T] \right]^{-1} \quad (12.69)$$

$$\Psi_{\text{new}} = \text{diag} \left\{ \mathbf{S} - \mathbf{W}_{\text{new}} \frac{1}{N} \sum_{n=1}^N \mathbb{E}[\mathbf{z}_n] (\mathbf{x}_n - \bar{\mathbf{x}})^T \right\} \quad (12.70)$$

其中“diag”运算符表示将矩阵中所有非对角元素置零。对因子分析模型进行贝叶斯处理，只需直接应用本书前面讨论过的技术即可。

概率 PCA 与因子分析之间的另一差别在于，当我们对数据集做变换时二者的行为不同。对于 PCA 和概率 PCA，如果我们对数据空间的坐标系做旋转，可以得到对数据完全相同的拟合，只不过 $\mathbf{W}$ 矩阵会随之乘上相应的旋转矩阵。而对于因子分析，如果对数据向量作分量上的重新缩放，那么该变换会被吸收到 Ψ 的对应元素的重新缩放之中。

12.3 核 PCA

在第 6 章中，我们看到核替换（kernel substitution）技术如何使我们能够将一个以标量积 $\mathbf{x}^T \mathbf{x}'$ 形式表达的算法，推广为通过用非线性核替换这些标量积而得到的更一般的算法。在这里，我们将这种核替换技术应用到主成分分析，从而得到一种称为核 PCA（Schölkopf 等，1998）的非线性推广。

考虑一个观测数据集 $\{\mathbf{x}_n\}$ ，其中 $n = 1, \dots, N$ ，数据所在空间的维度为 D 。为了使记号更简洁，我们将假定已经对每个向量 $\mathbf{x}_n$ 减去了样本均值，即满足 $\sum_n \mathbf{x}_n = 0$ 。第一步是把传统的 PCA 表达成这样一种形式：数据向量 $\{\mathbf{x}_n\}$ 只以标量积 $\mathbf{x}_n^T \mathbf{x}_m$ 的形式出现。回顾一下，主成分由协方差矩阵的特征向量 $\mathbf{u}_i$ 所定义：

$$\mathbf{S} \mathbf{u}_i = \lambda_i \mathbf{u}_i \quad (12.71)$$

其中 $i = 1, \dots, D$ 。这里 $D \times D$ 的样本协方差矩阵 $\mathbf{S}$ 定义为

$$\mathbf{S} = \frac{1}{N} \sum_{n=1}^N \mathbf{x}_n \mathbf{x}_n^T, \quad (12.72)$$

并且特征向量经过归一化，满足 $\mathbf{u}_i^T \mathbf{u}_i = 1$ 。

现在考虑一个非线性变换 $\phi(\mathbf{x})$ ，将数据映射到一个 M 维的特征空间中，使得每个数据点 $\mathbf{x}_n$ 被映射为一个点 $\phi(\mathbf{x}_n)$ 。我们现在可以在特征空间中执行标准 PCA，这在原始数据空间中隐式地定义了一个非线性主成分模型，如图 12.16 所示。

暂时假设投影后的数据集也具有零均值，即 $\sum_n \phi(\mathbf{x}_n) = 0$ 。我们稍后将回到这个问题。特征空间中 $M \times M$ 的样本协方差矩阵为

$$\mathbf{C} = \frac{1}{N} \sum_{n=1}^N \phi(\mathbf{x}_n) \phi(\mathbf{x}_n)^T \quad (12.73)$$

它的特征分解由下式定义：

$$\mathbf{C} \mathbf{v}_i = \lambda_i \mathbf{v}_i \quad (12.74)$$

其中 $i = 1, \dots, M$ 。我们的目标是在不显式地在特征空间中工作的前提下求解这个特征值问题。由 $\mathbf{C}$ 的定义，特征向量方程告诉我们 $\mathbf{v}_i$ 满足

$$\frac{1}{N} \sum_{n=1}^N \phi(\mathbf{x}_n) \{\phi(\mathbf{x}_n)^T \mathbf{v}_i\} = \lambda_i \mathbf{v}_i \quad (12.75)$$




图 12.16 核 PCA 的示意图。原始数据空间中的数据集（左图）通过非线性变换 $\phi(\mathbf{x})$ 投影到特征空间中（右图）。在特征空间中执行 PCA，可以得到主成分，其中第一个主成分以蓝色表示，并记为向量 $\mathbf{v}_1$ 。特征空间中的绿色直线表示到第一主成分的线性投影，而这些投影在原始数据空间中对应的是非线性投影。需要注意的是，一般情况下，无法用 x 空间中的一个向量来表示这种非线性主成分。

因此我们可以看到（只要 $\lambda_i > 0$ ），向量 $\mathbf{v}_i$ 可以由 $\{\phi(\mathbf{x}_n)\}$ 的线性组合给出，因此可写为

$$\mathbf{v}_i = \sum_{n=1}^N a_{in} \phi(\mathbf{x}_n). \quad (12.76)$$

将这一展开式代回特征向量方程，我们得到

$$\frac{1}{N} \sum_{n=1}^N \phi(\mathbf{x}_n) \phi(\mathbf{x}_n)^T \sum_{m=1}^N a_{im} \phi(\mathbf{x}_m) = \lambda_i \sum_{n=1}^N a_{in} \phi(\mathbf{x}_n). \quad (12.77)$$

关键的一步是将其用核函数 $k(\mathbf{x}_n, \mathbf{x}_m) = \phi(\mathbf{x}_n)^T \phi(\mathbf{x}_m)$ 来表示，我们通过等式两边左乘 $\phi(\mathbf{x}_l)^T$ 来实现：

$$\frac{1}{N} \sum_{n=1}^N k(\mathbf{x}_l, \mathbf{x}_n) \sum_{m=1}^N a_{im} k(\mathbf{x}_n, \mathbf{x}_m) = \lambda_i \sum_{n=1}^N a_{in} k(\mathbf{x}_l, \mathbf{x}_n). \quad (12.78)$$

这可以用矩阵形式写为

$$\mathbf{K}^2 \mathbf{a}_i = \lambda_i N \mathbf{K} \mathbf{a}_i \quad (12.79)$$

其中 $\mathbf{a}_i$ 是一个 N 维列向量，分量为 a_{ni} ， $n = 1, \dots, N$ 。我们可以通过求解如下特征值问题来得到 $\mathbf{a}_i$ 的解：

$$\mathbf{K} \mathbf{a}_i = \lambda_i N \mathbf{a}_i \quad (12.80)$$

这里我们在等式 (12.79) 的两边消去了一个 $\mathbf{K}$ 因子。注意，(12.79) 和 (12.80) 的解只在 $\mathbf{K}$ 的零特征值对应的特征向量上有差异，而这些并不影响主成分投影。

系数 $\mathbf{a}_i$ 的归一化条件由要求特征空间中的特征向量归一化得到。利用 (12.76) 和 (12.80)，我们有

$$1 = \mathbf{v}_i^T \mathbf{v}_i = \sum_{n=1}^N \sum_{m=1}^N a_{in} a_{im} \phi(\mathbf{x}_n)^T \phi(\mathbf{x}_m) = \mathbf{a}_i^T \mathbf{K} \mathbf{a}_i = \lambda_i N \mathbf{a}_i^T \mathbf{a}_i. \quad (12.81)$$

在求解了特征向量问题之后，得到的主成分投影也可以用核函数来表示，因此根据 (12.76)，点 $\mathbf{x}$ 在第 i 个特征向量方向上的投影为

$$y_i(\mathbf{x}) = \phi(\mathbf{x})^T \mathbf{v}_i = \sum_{n=1}^N a_{in} \phi(\mathbf{x})^T \phi(\mathbf{x}_n) = \sum_{n=1}^N a_{in} k(\mathbf{x}, \mathbf{x}_n) \quad (12.82)$$

同样是用核函数来表示的。

在原始的 D 维 $\mathbf{x}$ 空间中，有 D 个正交特征向量，因此最多可以找到 D 个线性主成分。然而特征空间的维度 M 可以远大于 D （甚至可以是无穷维），因此我们可以找到多于 D 个的非线性主成分。不过需要注意的是，非零特征值的个数不能超过数据点的数量 N ，因为即便 $M > N$ ，特征空间中的协方差矩阵的秩最多也只能等于 N 。这一点反映在核 PCA 需要对 $N \times N$ 的矩阵 $\mathbf{K}$ 做特征分解上。

到目前为止，我们一直假设由 $\phi(\mathbf{x}_n)$ 给出的投影数据集具有零均值，但总体上这并不会自动成立。我们不能简单地先计算再减去均值，因为我们希望避免直接在特征空间中工作，因此再次仅用核函数来表述算法。中心化之后的投影数据点记为 $\tilde{\phi}(\mathbf{x}_n)$ ，给定为

$$\tilde{\phi}(\mathbf{x}_n) = \phi(\mathbf{x}_n) - \frac{1}{N} \sum_{l=1}^N \phi(\mathbf{x}_l) \quad (12.83)$$

相应的 Gram 矩阵的元素为

$$\begin{aligned} \tilde{K}_{nm} &= \tilde{\phi}(\mathbf{x}_n)^T \tilde{\phi}(\mathbf{x}_m) \\ &= \phi(\mathbf{x}_n)^T \phi(\mathbf{x}_m) - \frac{1}{N} \sum_{l=1}^N \phi(\mathbf{x}_n)^T \phi(\mathbf{x}_l) \\ &\quad - \frac{1}{N} \sum_{l=1}^N \phi(\mathbf{x}_l)^T \phi(\mathbf{x}_m) + \frac{1}{N^2} \sum_{j=1}^N \sum_{l=1}^N \phi(\mathbf{x}_j)^T \phi(\mathbf{x}_l) \\ &= k(\mathbf{x}_n, \mathbf{x}_m) - \frac{1}{N} \sum_{l=1}^N k(\mathbf{x}_l, \mathbf{x}_m) \\ &\quad - \frac{1}{N} \sum_{l=1}^N k(\mathbf{x}_n, \mathbf{x}_l) + \frac{1}{N^2} \sum_{j=1}^N \sum_{l=1}^N k(\mathbf{x}_j, \mathbf{x}_l). \end{aligned} \quad (12.84)$$

这可以用矩阵形式表示为

$$\tilde{\mathbf{K}} = \mathbf{K} - \mathbf{1}_N \mathbf{K} - \mathbf{K} \mathbf{1}_N + \mathbf{1}_N \mathbf{K} \mathbf{1}_N \quad (12.85)$$

其中 $\mathbf{1}_N$ 表示一个 $N \times N$ 的矩阵，其每个元素都等于 $1/N$ 。因此我们可以仅用核函数来计算 $\tilde{\mathbf{K}}$ ，然后用 $\tilde{\mathbf{K}}$ 来确定特征值和特征向量。注意，如果我们使用线性核 $k(\mathbf{x}, \mathbf{x}') = \mathbf{x}^T \mathbf{x}'$ ，则可以把标准的 PCA 算法作为一个特例恢复出来。图 12.17 展示了将核 PCA 应用于一个合成数据集的示例（Schölkopf 等，1998）。这里使用了如下形式的“高斯”核：

$$k(\mathbf{x}, \mathbf{x}') = \exp(-\|\mathbf{x} - \mathbf{x}'\|^2/0.1) \quad (12.86)$$

并将其应用于一个合成数据集。图中的线对应于将数据投影到相应主成分上的值

$$\phi(\mathbf{x})^T \mathbf{v}_i = \sum_{n=1}^N a_{in} k(\mathbf{x}, \mathbf{x}_n) \quad (12.87)$$

保持常数的等高线。




图 12.17 核 PCA 的一个示例，对一个二维合成数据集应用高斯核，展示了前八个特征函数及其对应的特征值。等高线表示在这些线上投影到相应主成分上的值保持不变。可以看到，前两个特征向量将三个簇分离开来，接下来的三个特征向量将每个簇分成两半，而随后的三个特征向量又沿着与先前分割方向正交的方向再次将这些簇分成两半。

核 PCA 的一个明显缺点在于，它需要对 $N \times N$ 的矩阵 $\mathbf{K}$ 求特征向量，而不是对传统线性 PCA 中的 $D \times D$ 矩阵 $\mathbf{S}$ 求特征向量，因此在实际中，对于大规模数据集往往需要采用近似方法。

最后，我们注意到，在标准的线性 PCA 中，我们常常只保留少数 $L < D$ 个特征向量，然后用数据向量 $\mathbf{x}_n$ 在 L 维主子空间上的投影 $\hat{\mathbf{x}}_n$ 来近似它，定义为

$$\hat{\mathbf{x}}_n = \sum_{i=1}^L (\mathbf{x}_n^T \mathbf{u}_i) \mathbf{u}_i. \quad (12.88)$$

在核 PCA 中，一般来说这是做不到的。要理解这一点，注意映射 $\phi(\mathbf{x})$ 把 D 维的 $\mathbf{x}$ 空间映射到特征空间中一个 D 维的流形上。向量 $\mathbf{x}$ 被称为对应点 $\phi(\mathbf{x})$ 的原像 (pre-image)。然而，在特征空间中将点投影到该空间中的线性 PCA 子空间后，这些投影点通常不会落在该非线性的 D 维流形上，因此在数据空间中一般不存在对应的原像。于是，人们提出了一些技术来寻找近似的原像 (Bakir 等, 2004)。

12.4 非线性潜在变量模型

在本章中，我们一直关注具有连续潜在变量的最简单一类模型，即基于线性-高斯分布的模型。除了具有重要的实际意义之外，这类模型还相对容易分析并拟合数据，而

且也可以作为更复杂模型的组成部分。在这里，我们简要地考察对该框架的一些推广，这些推广得到的模型要么是非线性的，要么是非高斯的，或者两者兼具。

事实上，非线性与非高斯性这两个问题是相关的，因为通过对变量进行非线性变换，可以从一个简单的固定参考分布（例如高斯分布）得到一个一般的概率密度。正如我们很快会看到的，这一思想构成了若干实用潜在变量模型的基础。

12.4.1 独立成分分析

我们首先考虑这样一类模型：观测变量与潜在变量之间是线性关系，但潜在分布是非高斯的。当我们考虑潜在变量的分布可因子化时，会得到一类重要的模型，称为独立成分分析（independent component analysis, ICA），此时

$$p(\mathbf{z}) = \prod_{j=1}^M p(z_j) \quad (12.89)$$

为了理解这类模型的作用，考虑这样一种情形：两个人同时说话，我们使用两个麦克风录下他们的声音。如果忽略时间延迟和回声等效应，那么在任一时刻麦克风接收到的信号可以看作是这两个人声音振幅的线性组合。该线性组合的系数是常数，如果我们能从样本数据中推断出它们的值，那么就可以对混合过程求逆（假设它是非奇异的），从而得到两个“干净”的信号，每个信号只包含其中一个人的声音。这是一个称为盲源分离（blind source separation）的问题的例子，其中“盲”是指我们只给定混合后的数据，而原始的信号源以及混合系数都不可观测（Cardoso, 1998）。

这种类型的问题有时会采用如下方法来处理（MacKay, 2003），其中我们忽略信号的时间特性，把连续样本视为独立同分布。我们考虑一个生成式模型，它包含两个潜在变量，对应于不可观测的语音信号振幅，并有两个观测变量，对应于两个麦克风处测得的信号值。潜在变量的联合分布如上式那样可因子化，而观测变量由潜在变量的线性组合给出。由于潜在变量的数量等于观测变量的数量，因此无需显式地引入噪声分布；观测变量的边缘分布一般不会是奇异的，因此观测变量只是潜在变量的确定性线性组合。给定一个观测数据集，该模型的似然函数是线性组合系数的函数。可以使用基于梯度的优化来最大化对数似然，从而得到独立成分分析的一种具体形式。

这种方法取得成功的一个前提是潜在变量具有非高斯分布。要理解这一点，回忆在概率 PCA（以及因子分析）中，潜在空间的分布是零均值各向同性高斯分布。因此，该模型不能区分在潜在空间中仅由一个旋转变换相互得到的两种不同的潜在变量表示。这一点可以直接验证：注意到边缘密度（式 (12.35)），以及因此的似然函数，在我们进行变换 $\mathbf{W} \rightarrow \mathbf{W}\mathbf{R}$ 时保持不变，这里 $\mathbf{R}$ 是一个满足 $\mathbf{R}\mathbf{R}^T = \mathbf{I}$ 的正交矩阵，因为由式 (12.36) 给出的矩阵 $\mathbf{C}$ 本身是不变的。将模型扩展到更一般的高斯潜在分布并不会改变这一结论，因为正如我们已经看到的，这样的模型与零均值各向同性高斯潜在变量模型是等价的。

从另一种角度来看，为什么在线性模型中使用高斯潜在变量分布不足以找到独立成分？注意主成分对应于数据空间中坐标系的一个旋转，使得协方差矩阵被对角化，从

而新的坐标中数据分布是去相关的。虽然零相关是独立性的必要条件，但并不是充分条件。在实践中，一个常用的潜在变量分布的选择是

$$p(z_j) = \frac{1}{\pi \cosh(z_j)} = \frac{1}{\pi(e^{z_j} + e^{-z_j})} \quad (12.90)$$


与高斯分布相比，这个分布具有更重的尾部，这反映出许多现实世界的分布也具有这种性质。

最初的 ICA 模型 (Bell and Sejnowski, 1995) 基于信息最大化所定义的目标函数的优化。采用概率潜在变量的表述具有一个优势，即它有助于推动和形式化对基本 ICA 的推广。例如，独立因子分析 (independent factor analysis, Attias, 1999a) 考虑这样的模型：潜在变量和观测变量的数量可以不同，观测变量是带噪声的，各个潜在变量具有由高斯混合模型刻画的灵活分布。该模型的对数似然通过 EM 算法最大化，而潜在变量的重构则使用变分方法进行近似。已经有人提出了许多其他类型的模型，如今关于 ICA 及其应用的文献极为丰富 (Jutten and Herault, 1991; Comon et al., 1991; Amari et al., 1996; Pearlmutter and Parra, 1997; Hyvärinen and Oja, 1997; Hinton et al., 2001; Miskin and MacKay, 2001; Hojen-Sorensen et al., 2002; Choudrey and Roberts, 2003; Chan et al., 2003; Stone, 2004)。

12.4.2 自联想神经网络

在第 5 章中，我们是在监督学习的背景下考察神经网络的，其中网络的作用是：给定输入变量的取值，预测输出变量。然而，神经网络同样也被用于无监督学习，尤其是在降维问题上。其做法是使用一个输出单元数量与输入单元数量相同的网络，并通过优化权值，使得在一组训练数据上输入与输出之间某种重构误差度量最小化。

图 12.18 一种具有两层权重的自关联多层感知机。该网络通过最小化平方和误差来训练，使其将输入向量映射为其自身。即使在隐含层中使用非线性单元，这样的网络仍然等价于线性主成分分析。为简洁起见，表示偏置参数的连接已被省略。




先考虑图 12.18 中所示形式的多层感知机，它具有 D 个输入、 D 个输出单元以及 M 个隐含单元，并且满足 $M < D$ 。用来训练网络的目标值就是输入向量本身，因此网络试图将每个输入向量映射到其自身。这样的网络被称为形成了一个自联想 (autoassociative) 映射。由于隐含单元的数量少于输入单元的数量，一般来说不可能对所有输入向量都进行完美重构。因此，我们通过最小化一个能够刻画输入向量与其重构之间不匹配程度的误差函数来确定网络参数 $\mathbf{w}$ 。特别地，我们选择如下形式的平方和误差函数：

$$E(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N \|\mathbf{y}(\mathbf{x}_n, \mathbf{w}) - \mathbf{x}_n\|^2 \quad (12.91)$$

如果隐含单元具有线性激活函数，则可以证明该误差函数具有唯一的全局最小值，并且在这一最小值处，网络实现的是对由前 M 个主成分所张成的 M 维子空间的投影 (Bourlard and Kamp, 1988; Baldi and Hornik, 1989)。因此，在图 12.18 中导入隐含单元的权向量形成了一组基向量，它们张成了主子空间。不过要注意的是，这些向量不必是正交或归一化的。这个结果并不让人意外，因为主成分分析和神经网络都使用线性降维，并都在最小化相同的平方和误差函数。

或许会有人认为，通过在图 12.18 的网络中使用非线性（S 型）激活函数来替代线性隐含单元，就能克服线性降维的限制。然而，即使隐含单元是非线性的，最小误差解仍然是投影到主成分子空间上 (Bourlard and Kamp, 1988)。因此，使用两层神经网络进行降维并没有优势。对于主成分分析的标准技术（基于奇异值分解），我们可以保证在有限时间内得到正确解，而且还能得到一组按序排列的特征值及其对应的正交归一特征向量。

图 12.19 通过增加额外的非线性隐含层，可以得到一种能够执行非线性降维的自关联网络。



然而，如果允许在网络中添加额外的隐含层，情形就不同了。考虑图 12.19 所示的四层自联想网络。这里输出单元是线性的，第二隐含层中的 M 个单元也可以是线性的，但是第一和第三隐含层具有 S 型非线性激活函数。网络同样通过最小化误差函数 (12.91) 来训练。我们可以将该网络视为两个连续的函数映射 $\mathbf{F}_1$ 和 $\mathbf{F}_2$ （如图 12.19 所示）。第一个映射 $\mathbf{F}_1$ 将原始 D 维数据投影到一个 M 维子空间 $\mathcal{S}$ 上，该子空间由第二隐含层单元的激活所定义。由于存在第一层非线性隐含单元，这个映射非常一般，尤其不再局限于线性映射。同样，网络的后半部分则定义了从该 M 维空间回到原始 D 维输入空间的任意函数映射。对于 $D = 3$ 且 $M = 2$ 的情形，这有一个简单的几何解释，如图 12.20 所示。

这样的网络实质上执行了非线性主成分分析。它的优点在于不再局限于线性变换，虽然其中仍把标准的主成分分析作为一个特殊情况。然而，如今训练该网络涉及的是一个非线性优化问题，因为误差函数 (12.91) 不再是网络参数的二次函数。必须使用计算代价很高的非线性优化技术，并且有可能陷入误差函数的次优局部极小值。此外，子空间的维度必须在训练网络之前给定。

12.4.3 非线性流形建模

正如我们已经指出的，许多自然数据源对应于嵌入在高维观测数据空间中的低维、可能带噪声的非线性流形。显式地刻画这一性质，相比于更一般的方法，可以带来更好




图 12.20 图 12.19 所示网络在 $D = 3$ 个输入、且中间隐含层包含 $M = 2$ 个单元情况下所执行映射的几何解释。函数 F_2 将一个 M 维空间 S 映射到一个 D 维空间中，因此定义了空间 S 在原始 x 空间中的嵌入方式。由于映射 F_2 可以是非线性的， S 的嵌入可以是非平面的，如图中所示。随后，映射 F_1 定义了将原始 D 维空间中的点投影到 M 维子空间 S 中的过程。

的密度建模效果。在这里，我们简要地考察一系列尝试实现这一目标的技术。

一种建模非线性结构的方法是通过若干线性模型的组合，从而对流形进行分段线性近似。例如，可以使用基于欧式距离的聚类技术（如 K 均值）将数据集划分为若干局部簇，然后对每个簇应用标准 PCA。一个更好的方法是使用重构误差来进行簇分配（Kambhatla and Leen, 1997; Hinton et al., 1997），这样在每个阶段优化的都是同一个代价函数。然而，这些方法仍然受限于缺乏一个整体的密度模型。通过使用概率 PCA，我们可以很容易地定义一个完全概率化的模型，只需考虑一个混合分布，其各个分量都是概率 PCA 模型（Tipping and Bishop, 1999a）。这样一个模型同时具有离散潜在变量（对应于离散混合）和连续潜在变量，其似然函数可以使用 EM 算法最大化。基于变分推断的完全贝叶斯处理（Bishop and Winn, 2000）可以使混合分量的数量以及各个模型的有效维度从数据中自动推断出来。该模型有很多变体，例如在混合各分量间对 $\mathbf{W}$ 矩阵或噪声方差等参数进行绑定，或者用对角噪声分布替代各向同性噪声分布，从而得到因子分析器混合（mixture of factor analysers, Ghahramani and Hinton, 1996a; Ghahramani and Beal, 2000）。概率 PCA 模型的混合还可以分层扩展，从而产生一种交互式数据可视化算法（Bishop and Tipping, 1998）。

另一种替代线性模型混合的方法，是考虑单一的非线性模型。回顾一下，常规 PCA 会在最小二乘意义下找到一条尽量靠近数据的线性子空间。这个概念可以推广到一维非线性曲面，形成主曲线（principal curves, Hastie and Stuetzle, 1989）。我们可以用一个向量值函数 $\mathbf{f}(\lambda)$ 来描述 D 维数据空间中的一条曲线，其中该向量的每个分量都是标量 λ 的函数。曲线有多种参数化方式，其中一个自然的选择是沿曲线的弧长。对于数据空间中的任意一点 $\mathbf{x}$ ，我们都可以找到曲线上与之欧氏距离最近的点。由于这个最近点依赖于具体的曲线 $\mathbf{f}(\lambda)$ ，我们把该点对应的参数记为 $\lambda = g_{\mathbf{f}}(\mathbf{x})$ 。对于一个连续数据密度 $p(\mathbf{x})$ ，主曲线定义为：曲线上的每个点都是所有在数据空间中投影到该点的样本的均值，即

$$\mathbb{E}[\mathbf{x} \mid g_{\mathbf{f}}(\mathbf{x}) = \lambda] = \mathbf{f}(\lambda). \quad (12.92)$$

对于给定的连续密度，可以存在多条主曲线。在实际中，我们关心的是有限数据集，并且希望只考虑光滑的曲线。Hastie 和 Stuetzle (1989) 提出了一个两阶段的迭代过程来寻找这样的主曲线，这在形式上与 PCA 的 EM 算法有些相似。首先用第一主成分来初始化曲线，然后算法在数据投影步骤与曲线再估计步骤之间交替进行。在投影步骤中，将每个数据点分配给曲线上与其最近的点所对应的 λ 值。然后在再估计步骤中，曲线上每个点由投影到其附近的那些数据点的加权平均给出，曲线上距离越近的数据点权重越大。当子空间被约束为线性时，该过程收敛到第一主成分，并等价于用幂法来寻找协方差矩阵的最大特征向量。主曲线可以推广到称为主曲面 (principal surfaces) 的多维流形，然而由于即使在二维流形的情形下，在高维空间中进行数据平滑也较为困难，因此主曲面的应用相对有限。

PCA 经常被用来将数据集投影到较低维空间，例如二维，以便进行可视化。另一种具有类似目标的线性技术是多维标度 (multidimensional scaling, MDS, Cox and Cox, 2000)。它通过寻找一个低维投影，使得数据点之间的成对距离尽可能得到保留，并且需要对距离矩阵求特征向量。在距离为欧氏距离的情形下，它给出的结果等价于 PCA。MDS 的概念可以扩展到更广泛的数据类型，只要这些数据能用相似度矩阵表示，就可以得到非度量 MDS (nonmetric MDS)。

另外两种用于降维和数据可视化的非概率方法也值得一提。局部线性嵌入 (locally linear embedding, LLE, Roweis and Saul, 2000) 首先计算一组系数，使得每个数据点可以由其邻居尽可能好地重构。这些系数被构造为对该数据点及其邻居的旋转、平移与缩放变化不敏感，因此它们刻画了局部邻域的几何性质。随后，LLE 将高维数据点映射到低维空间，同时保持这些邻域系数不变。如果某个数据点的局部邻域可以视为线性，那么该变换可以通过平移、旋转与缩放的组合来实现，以保持数据点与其邻居之间所形成的角度。因为这些权重对上述变换是不变的，我们期望在低维空间中使用与高维数据空间中相同的权重值来重构数据点。尽管该方法本质上是非线性的，LLE 的优化过程并不存在局部极小值问题。

在等距特征映射 (isometric feature mapping, isomap, Tenenbaum et al., 2000) 中，目标是使用 MDS 将数据投影到低维空间，但是这里的不相似度是通过沿流形的测地距离来定义的。举例来说，如果两个点位于一个圆上，那么测地距离就是沿圆周弧长测量的距离，而不是连接这两个点的弦的直线距离。该算法首先为每个数据点定义其邻域，可以通过寻找 K 近邻，或者寻找所有落在半径为 ϵ 的球内的点来实现。随后构造一个图，将所有邻近点两两相连，并以它们的欧氏距离作为边的权重。任意两点之间的测地距离由连接它们的最短路径上各弧段长度之和来近似 (最短路径本身可用标准算法求得)。最后，对测地距离矩阵应用度量 MDS，以获得低维投影。

本章的重点始终放在观测变量为连续的模型上。我们也可以考虑具有连续潜在变量而观测变量为离散的模型，从而得到潜在特质模型 (latent trait models, Bartholomew, 1987)。在这种情形下，即便潜在变量与观测变量之间是线性关系，对连续潜在变量进行边缘化也无法解析地完成，因此需要更为复杂的技术。Tipping (1999) 在一个二维

潜在空间的模型中使用了变分推断，使得二值数据集可以类似于用 PCA 可视化连续数据那样被可视化。需要注意的是，该模型是第 4.5 节中讨论的贝叶斯逻辑回归问题的对偶。在逻辑回归的情形中，我们有 N 个特征向量 ϕ_n 的观测，它们由一个参数向量 $\mathbf{w}$ 参数化；而在潜在空间可视化模型中，则是只有一个潜在空间变量 $\mathbf{x}$ （与 ϕ 类似）以及 N 个潜在变量副本 $\mathbf{w}_n$ 。Collins et al. (2002) 介绍了对一般指数族分布的概率潜在变量模型的一种推广。

我们已经指出，可以通过对高斯随机变量施加适当的非线性变换来构造任意分布。这一思想被用于一个通用的潜在变量模型，即密度网络 (density network, MacKay, 1995; MacKay and Gibbs, 1999)，其中该非线性函数由多层神经网络来刻画。如果网络具有足够多的隐含单元，它就可以以任意精度逼近给定的非线性函数。拥有如此灵活的模型的缺点在于：为了得到似然函数所需的潜在变量边缘化不再可以解析地完成。取而代之的是，用蒙特卡罗方法来近似似然：从高斯先验中抽取样本点，潜在变量上的边缘化便转化为一个简单的求和，每个样本对应一项。然而，由于可能需要大量样本点才能准确表示该边缘分布，这一过程在计算上会十分昂贵。

如果我们对非线性函数的形式做一些限制，并对潜在变量分布作出合适选择，就可以构建一种既非线性又易于训练的潜在变量模型。生成拓扑映射 (generative topographic mapping, GTM, Bishop et al., 1996; Bishop et al., 1997a; Bishop et al., 1998b) 使用的潜在分布是定义在（通常是二维的）潜在空间上一个有限规则网格上的一组 Delta 函数。对潜在空间进行边缘化于是简化为对各个网格点贡献的求和。非线性映射由一个线性回归模型给出，该模型允许一般非线性，但在自适应参数上保持线性。需要注意的是，线性回归模型通常在高维空间中会受到维度灾难的限制，而在 GTM 的背景下这种限制并不存在，因为该流形通常是二维的，与数据空间的维度无关。由这两点选择带来的结果是：似然函数可以用解析的闭式形式表示，并可以通过 EM 算法高效优化。最终得到的 GTM 模型为数据集拟合了一个二维非线性流形，并且通过对潜在空间上的后验分布进行求解，可以将数据点再投影到潜在空间中以进行可视化。图 12.21 展示了油田数据集分别用线性 PCA 和非线性 GTM 进行可视化的对比。

GTM 可以看作是一个早期模型——自组织映射 (self organizing map, SOM, Kohonen, 1982; Kohonen, 1995)——的概率版本，后者同样通过一个规则的离散点阵来表示二维非线性流形。SOM 在某种程度上与 K 均值算法相似：数据点被分配到附近的原型向量，然后这些原型向量被不断更新。最初，这些原型是随机分布的，在训练过程中，它们“自组织”成近似光滑流形的形状。然而，与 K 均值不同的是，SOM 并未优化任何明确的代价函数 (Erwin et al., 1992)，这使得设定模型参数以及判断收敛变得困难。此外，“自组织”是否真的会发生，还依赖于针对具体数据集所选择的参数是否合适，没有任何保证。

相比之下，GTM 优化的是对数似然函数，并且所得模型在数据空间中定义了一个概率密度。事实上，它可以看作是一种受约束的高斯混合模型，其中所有分量共享同一方差，并且均值被约束在一个光滑二维流形上。这样的概率基础也使得对 GTM 进行推




图 12.21 油流数据集的可视化结果，左图使用 PCA，右图使用 GTM。对于 GTM 模型，每个数据点都绘制在其潜在空间后验分布的均值位置上。GTM 模型的非线性特性使得不同数据点组之间的分离更加清晰可见。


广变得十分自然 (Bishop et al., 1998a)，包括贝叶斯处理、缺失值处理、向离散变量的严格扩展、用高斯过程来定义流形，或者构造分层 GTM 模型 (Tino and Nabney, 2002)。

由于在 GTM 中流形被定义为整个连续曲面，而不是像 SOM 那样只在原型向量处定义，因此可以计算为拟合数据而需要的流形局部伸缩因子 (magnification factors, Bishop et al., 1997b)，以及流形的方向曲率 (directional curvatures, Tino et al., 2001)。这些量可以与投影后的数据一起进行可视化，从而为模型提供更多的洞见。

13 序列数据

到目前为止，本书主要关注的是这样一类数据点集合：它们被假设为独立同分布（i.i.d.）。这一假设使我们可以把似然函数写成在每个数据点处评估得到的概率分布在所有数据点上的乘积。然而，在许多应用中，i.i.d. 假设会非常不合理。这里我们考虑其中一类特别重要的数据集，即描述序列数据的数据集。这类数据常常通过对时间序列的测量而产生，例如在某个特定位置连续几天的降雨量测量、某种货币汇率的日度数值，或者在连续时间帧上用于语音识别的声学特征。一个关于语音数据的例子如图 13.1 所示。序列数据也可以出现在时间序列以外的情境中，例如一段 DNA 链上的核苷酸碱基序列，或者一段英文句子中的字符序列。为方便起见，我们有时会把序列中的观测称为“过去”和“未来”的观测。不过，本章所讨论的模型同样适用于所有形式的序列数据，而不仅仅是时间序列。

图 13.1 口语单词“Bayes 定理”的声谱图示例，显示了谱系数强度随时间索引变化的曲线。



有必要区分平稳（stationary）与非平稳（nonstationary）的序列分布。在平稳情形下，数据随时间变化，但它生成所用的分布保持不变。而在更加复杂的非平稳情形中，生成分布本身会随时间演化。这里我们将集中讨论平稳情形。


在许多应用中，例如金融预测，我们希望在给定前面观测到的取值的情况下，能够预测时间序列中的下一个取值。从直觉上看，我们认为最近的观测在预测未来值时比更久远的观测更有用。图 13.1 中的例子表明，语音谱的连续观测之间确实具有很强的相关性。此外，若考虑未来观测对所有先前观测的一般依赖关系，在实践中也不切实际，因为随着观测数量的增加，这样一个模型的复杂度将无限增长。这就引导我们考虑马尔可夫模型，其中我们假设对未来的预测只依赖于最近的一些观测，而与更久远的观测无关。

尽管这样的模型是可处理的，但它们也有很大的局限性。通过引入潜在变量，我们可以在保持可处理性的同时，得到一个更一般的框架，从而得到状态空间模型。就像在第 9 章和第 12 章中所看到的那样，我们可以用简单的组成部分（特别是属于指数族的分布）构建出复杂的模型，并可以利用概率图模型的框架来方便地刻画它们。在这里，我们重点讨论状态空间模型的两个最重要的例子：隐藏马尔可夫模型（hidden Markov model），其中潜在变量是离散的；以及线性动态系统（linear dynamical system），其中潜在变量为高斯分布。这两个模型都由有向图描述，并具有树结构（没有环），因此可以用和-积算法（sum-product algorithm）高效地进行推断。

13.1 马尔可夫模型

最简单的一种处理序列数据的方法是完全忽略其序列特性，把观测视为 i.i.d.，这对应于图 13.2 中的图模型。然而，这种方法无法利用数据中的序列模式，比如序列中相邻观测之间的相关性。假设我们观测到一个二值变量，用来表示在某一天是否下雨。给定一段关于该变量的近期时间序列观测，我们希望预测第二天是否会下雨。如果我们把数据视为 i.i.d.，那么从数据中唯一可以得到的信息就是“下雨天所占的频率”。然而在实际中，我们知道天气往往会表现出持续几天的趋势。观察“今天是否下雨”对于预测“明天是否下雨”就非常有帮助。


图 13.2 对一系列观测进行建模的最简单方法是将它们视为相互独立，这对应于一个没有连接的图。



要在概率模型中表达这种效应，我们就需要放宽 i.i.d. 假设，其中最简单的方法之一就是考虑马尔可夫模型。首先，我们注意到，在不失一般性的前提下，我们可以用乘积法则把一个观测序列的联合分布写成

$$p(\mathbf{x}_1, \dots, \mathbf{x}_N) = \prod_{n=1}^N p(\mathbf{x}_n \mid \mathbf{x}_1, \dots, \mathbf{x}_{n-1}). \quad (13.1)$$

图 13.3 一阶马尔可夫观测序列 $\{\mathbf{x}_n\}$ ，其中某一观测 $\mathbf{x}_n$ 的分布 $p(\mathbf{x}_n \mid \mathbf{x}_{n-1})$ 以先前观测 $\mathbf{x}_{n-1}$ 的取值为条件。



如果我们现在假设右端各个条件分布都只依赖于最近一次观测而与更早的观测无关，就得到一阶马尔可夫链，其图模型见图 13.3。在该模型下，对 N 个观测序列的联合分布为

$$p(\mathbf{x}_1, \dots, \mathbf{x}_N) = p(\mathbf{x}_1) \prod_{n=2}^N p(\mathbf{x}_n \mid \mathbf{x}_{n-1}). \quad (13.2)$$

利用 d-分离性质，我们可以看到，给定截至时刻 n 的所有观测，观测 $\mathbf{x}_n$ 的条件分


布为

$$p(\mathbf{x}_n | \mathbf{x}_1, \dots, \mathbf{x}_{n-1}) = p(\mathbf{x}_n | \mathbf{x}_{n-1}), \quad (13.3)$$

这可以从式 (13.2) 出发，利用概率的乘积法则直接验证。因此，如果我们用这样的模型来预测序列中的下一个观测，那么预测的分布只依赖于紧接在前的观测值，而与更早的观测无关。

在这类模型的大多数应用中，用于定义模型的条件分布 $p(\mathbf{x}_n | \mathbf{x}_{n-1})$ 会被约束为相同，这对应于时间序列平稳的假设。这时模型被称为齐次马尔可夫链（homogeneous Markov chain）。例如，如果条件分布依赖于一些可调参数（其取值可以从一组训练数据中推断），那么链中所有的条件分布将共享同一组参数值。

图 13.4 二阶马尔可夫链，其中某一观测 $\mathbf{x}_n$ 的条件分布依赖于前两个观测 $\mathbf{x}_{n-1}$ 和 $\mathbf{x}_{n-2}$ 的取值。



尽管这一模型比独立模型更一般，但仍然非常受限。对于许多序列观测，我们预期连续多个观测中的趋势会对预测下一个取值提供重要信息。让更早的观测产生影响的一种方法是使用高阶马尔可夫链。如果我们还允许预测依赖于倒数第二个观测，就得到二阶马尔可夫链，其图见图 13.4。此时联合分布为


$$p(\mathbf{x}_1, \dots, \mathbf{x}_N) = p(\mathbf{x}_1)p(\mathbf{x}_2 | \mathbf{x}_1) \prod_{n=3}^N p(\mathbf{x}_n | \mathbf{x}_{n-2}, \mathbf{x}_{n-1}). \quad (13.4)$$

同样，通过 d-分离或直接计算可以看到，在给定 $\mathbf{x}_{n-1}$ 和 $\mathbf{x}_{n-2}$ 的条件下， $\mathbf{x}_n$ 的条件分布与所有更早的观测 $\mathbf{x}_1, \dots, \mathbf{x}_{n-3}$ 相互独立。于是，每个观测现在会受到前两个观测的影响。类似地，我们可以把模型推广到 M 阶马尔可夫链，其中某个变量的条件分布依赖于前 M 个变量。

不过，为了获得这种更大的灵活性，我们付出了代价：模型中的参数数目大幅增加。假设观测是具有 K 个状态的离散变量。那么在一阶马尔可夫链中，条件分布 $p(\mathbf{x}_n | \mathbf{x}_{n-1})$ 对 $\mathbf{x}_{n-1}$ 的每个状态都由一组 $K-1$ 个参数来刻画，总共需要 $K(K-1)$ 个参数。现在假设我们把模型扩展到 M 阶马尔可夫链，使得联合分布由条件分布 $p(\mathbf{x}_n | \mathbf{x}_{n-M}, \dots, \mathbf{x}_{n-1})$ 构成。如果这些变量是离散的，并且条件分布用完全一般的条件概率表来表示，那么这样的模型所需要的参数个数为 $K^{M-1}(K-1)$ 。由于它随 M 指数式增长，在 M 较大的情形下这种方法往往变得不切实际。

对于连续变量，我们可以使用线性-高斯条件分布，其中每个结点都具有高斯分布，其均值是父结点的线性函数。这被称为自回归（autoregressive）或 AR 模型（Box et al., 1994; Thiesson et al., 2004）。另一种方法是为 $p(\mathbf{x}_n | \mathbf{x}_{n-M}, \dots, \mathbf{x}_{n-1})$ 使用一个参数化模型，例如神经网络。这种技术有时被称为“抽头延时线”（tapped delay line），因为它对应于存储（延时）过去的 M 个观测值，用它们来预测下一个值。在这种情形下，参数个数可以远小于完全一般的模型（例如它可能只随 M 线性增长），不过代价是被限制在一个较窄的条件分布族内。

图 13.5 我们可以使用由潜变量构成的马尔可夫链来表示序列数据，其中每个观测都以相应潜变量的状态为条件。这一重要的图结构构成了隐马尔可夫模型和线性动力系统的共同基础。



假设我们希望构建一个序列模型，不受任何阶数的马尔可夫假设限制，同时又能用有限个自由参数来刻画。我们可以通过引入额外的潜在变量来实现这一点，从而用简单的成分构建出一类丰富的模型，就像我们在第 9 章中的混合分布以及第 12 章中的连续潜在变量模型中所做的那样。对每个观测 $\mathbf{x}_n$ ，我们引入一个对应的潜在变量 $\mathbf{z}_n$ （它可以与观测变量类型不同或维度不同）。我们现在假设潜在变量构成一条马尔可夫链，从而得到一个称为状态空间模型（state space model）的图结构，如图 13.5 所示。它满足一个关键的条件独立性质：给定 $\mathbf{z}_n$ ， $\mathbf{z}_{n-1}$ 与 $\mathbf{z}_{n+1}$ 相互独立，也就是

$$\mathbf{z}_{n+1} \perp \mathbf{z}_{n-1} \mid \mathbf{z}_n. \quad (13.5)$$

该模型的联合分布为

$$p(\mathbf{x}_1, \dots, \mathbf{x}_N, \mathbf{z}_1, \dots, \mathbf{z}_N) = p(\mathbf{z}_1) \left[\prod_{n=2}^N p(\mathbf{z}_n \mid \mathbf{z}_{n-1}) \right] \prod_{n=1}^N p(\mathbf{x}_n \mid \mathbf{z}_n). \quad (13.6)$$

利用 d-分离准则，我们可以看到，在任意两个观测变量 $\mathbf{x}_n$ 和 $\mathbf{x}_m$ 之间总存在一条经由潜在变量相连的路径，并且这条路径从不会被阻断。因此，对观测 $\mathbf{x}_{n+1}$ 的预测分布 $p(\mathbf{x}_{n+1} \mid \mathbf{x}_1, \dots, \mathbf{x}_n)$ 在给定此前所有观测的条件下，不再表现出任何条件独立性质，因此我们对 $\mathbf{x}_{n+1}$ 的预测依赖于所有先前的观测。不过，观测变量本身在任意阶数上都不满足马尔可夫性质。我们将在本章后面的部分讨论如何计算这样的预测分布。

有两个重要的序列数据模型可以用上述图结构来描述。如果潜在变量是离散的，我们就得到隐藏马尔可夫模型（hidden Markov model, HMM, Elliott et al., 1995）。注意在 HMM 中，观测变量可以是离散或连续的，而且可以使用多种不同形式的条件分布来刻画它们。如果潜在变量与观测变量都是高斯分布（并且条件分布对其父结点的依赖为线性-高斯形式），那么我们就得到线性动态系统（linear dynamical system）。

13.2 隐马尔可夫模型

隐马尔可夫模型可以看作图 13.5 状态空间模型的一种特例，其中潜在变量是离散的。不过，如果我们只考察模型的单个时间切片，会发现它对应于一个混合分布，其分量密度由 $p(\mathbf{x} \mid \mathbf{z})$ 给出。因此，它也可以被解释为混合模型的一种扩展：对每个观测所选取的混合分量不再彼此独立，而是依赖于前一个观测所选取的分量。隐马尔可夫模型在语音识别（Jelinek, 1997; Rabiner and Juang, 1993）、自然语言建模（Manning and Schütze, 1999）、在线手写识别（Nag et al., 1986）以及蛋白质和 DNA 等生物序列的分析（Krogh et al., 1994; Durbin et al., 1998; Baldi and Brunak, 2001）中被广泛应用。

与标准混合模型一样，潜在变量是表示“哪一个混合分量负责生成对应观测 $\mathbf{x}_n$ ”的离散多项式变量 $\mathbf{z}_n$ 。同第 9 章的混合模型一样，我们仍然采用 1-of- K 编码方案。现在我们允许 $\mathbf{z}_n$ 的概率分布通过条件分布 $p(\mathbf{z}_n | \mathbf{z}_{n-1})$ 依赖于前一个潜在变量 $\mathbf{z}_{n-1}$ 的状态。由于潜在变量是 K 维二值变量，这个条件分布对应于一个数表，我们记为矩阵 $\mathbf{A}$ ，其中的元素称为转移概率。它们定义为 $A_{jk} \equiv p(z_{nk} = 1 | z_{n-1,j} = 1)$ ，因为它们是概率，满足 $0 \leq A_{jk} \leq 1$ 且 $\sum_k A_{jk} = 1$ ，所以矩阵 $\mathbf{A}$ 有 $K(K-1)$ 个独立参数。于是我们可以把条件分布写成显式形式

$$p(\mathbf{z}_n | \mathbf{z}_{n-1}, \mathbf{A}) = \prod_{k=1}^K \prod_{j=1}^K A_{jk}^{z_{n-1,j} z_{nk}}. \quad (13.7)$$


初始潜在结点 $\mathbf{z}_1$ 比较特殊，因为它没有父结点，因此它具有边缘分布 $p(\mathbf{z}_1)$ ，用一个概率向量 $\boldsymbol{\pi}$ 表示，其分量为 $\pi_k \equiv p(z_{1k} = 1)$ ，从而

$$p(\mathbf{z}_1 | \boldsymbol{\pi}) = \prod_{k=1}^K \pi_k^{z_{1k}}, \quad (13.8)$$

并且满足 $\sum_k \pi_k = 1$ 。

转移矩阵有时可以用状态转移图的方式来示意：将状态画成结点，如图 13.6 所示的 $K=3$ 情形。需要注意的是，这并不是一个概率图模型，因为这些结点并不是独立的变量，而是同一个变量的不同状态，因此我们用方框而不是圆圈来表示这些状态。


图 13.6 转移图展示了一个模型，其中潜变量具有三个可能的状态，对应于三个方框。黑色连线表示转移矩阵 A_{jk} 的各个元素。



有时，我们会把图 13.6 那样的状态转移图在时间轴上展开。这提供了另一种表示状态之间转移的方式，称为格状图或网格图 (lattice 或 trellis diagram)，在隐马尔可夫模型的情形下如图 13.7 所示。

通过定义观测变量的条件分布 $p(\mathbf{x}_n | \mathbf{z}_n, \phi)$ (其中 ϕ 是控制该分布的一组参数)，我们就完成了概率模型的规范。这些分布被称为发射概率。举例来说，如果 $\mathbf{x}$ 的各个分量是连续变量，发射概率可以用类似式 (9.11) 的高斯分布给出；如果 $\mathbf{x}$ 为离散变量，则可以用条件概率表来表示。由于 $\mathbf{x}_n$ 是观测到的，对于给定的 ϕ ，分布 $p(\mathbf{x}_n | \mathbf{z}_n, \phi)$ 对应于一个包含 K 个数的向量，分别对应二值向量 $\mathbf{z}_n$ 的 K 个可能状态。我们可以将发射概

图 13.7 如果我们将图 13.6 的状态转移图沿时间展开，就得到潜在状态的一个格状（或称为栅格、trellis）表示。该图中的每一列对应一个潜变量 z_n 。



率写成

$$p(\mathbf{x}_n | \mathbf{z}_n, \phi) = \prod_{k=1}^K p(\mathbf{x}_n | \phi_k)^{z_{nk}}. \quad (13.9)$$

我们将重点讨论齐次模型，即所有控制潜在变量的条件分布共享同一组参数 $\mathbf{A}$ ，同样所有发射分布共享同一组参数 ϕ （推广到更一般情形是直接的）。注意，对于 i.i.d. 数据的混合模型，是一个特殊情形：其中所有 A_{jk} 在 j 上都相同，使得条件分布 $p(\mathbf{z}_n | \mathbf{z}_{n-1})$ 与 $\mathbf{z}_{n-1}$ 无关。这相当于删除图 13.5 所示图模型中的水平连线。

这样，隐变量与观测变量的联合概率分布可以写为

$$p(\mathbf{X}, \mathbf{Z} | \theta) = p(\mathbf{z}_1 | \pi) \left[\prod_{n=2}^N p(\mathbf{z}_n | \mathbf{z}_{n-1}, \mathbf{A}) \right] \prod_{m=1}^N p(\mathbf{x}_m | \mathbf{z}_m, \phi), \quad (13.10)$$

其中 $\mathbf{X} = \{\mathbf{x}_1, \dots, \mathbf{x}_N\}$ ， $\mathbf{Z} = \{\mathbf{z}_1, \dots, \mathbf{z}_N\}$ ，而 $\theta = \{\pi, \mathbf{A}, \phi\}$ 表示控制模型的一组参数。我们对隐马尔可夫模型的大部分讨论都将与发射概率的具体形式无关。事实上，对很多类型的发射分布该模型都是可处理的，包括离散表、高斯以及高斯混合等分布。还可以利用诸如神经网络之类的判别式模型。这些模型可以直接对发射密度 $p(\mathbf{x} | \mathbf{z})$ 进行建模，或者为 $p(\mathbf{z} | \mathbf{x})$ 提供一个表示，随后利用贝叶斯定理将其转化为所需的发射密度 $p(\mathbf{x} | \mathbf{z})$ (Bishop et al., 2004)。

通过从生成式的角度来考察隐马尔可夫模型，我们可以更好地理解它。回顾一下，从高斯混合中生成样本的过程是这样的：我们首先根据混合系数 π_k 的概率随机选择一个分量，然后从相应的高斯分量中生成一个样本向量 $\mathbf{x}$ 。重复这一过程 N 次，就可以生成一个包含 N 个独立样本的数据集。在隐马尔可夫模型中，这一过程被如下方式修改：首先根据参数 π_k 决定初始潜在变量 $\mathbf{z}_1$ 的状态，然后生成对应的观测 $\mathbf{x}_1$ 。接着，我们使用已生成出来的 $\mathbf{z}_1$ 的取值，根据转移概率 $p(\mathbf{z}_2 | \mathbf{z}_1)$ 来决定变量 $\mathbf{z}_2$ 的状态。假设 $\mathbf{z}_1$ 的样本对应状态 j ，那么就以概率 A_{jk} ($k = 1, \dots, K$) 来选择 $\mathbf{z}_2$ 的状态 k 。一旦确定了 $\mathbf{z}_2$ ，我们就可以为 $\mathbf{x}_2$ 抽取一个样本，并继续为下一个潜在变量 $\mathbf{z}_3$ 抽样，如此往复。这是有向图模型中祖先采样 (ancestral sampling) 的一个例子。如果我们有一个模型，其中对角转移元素 A_{kk} 明显大于非对角元素，那么一个典型的数据序列将呈现出：长时间从同一分量生成样本，仅偶尔从一个分量转移到另一个分量。从隐马尔可夫模型中生成样本的过程如图 13.8 所示。





图 13.8 从具有三状态潜变量 z 且采用高斯发射模型 $p(x|z)$ (其中 x 为二维) 的隐马尔可夫模型中进行采样的示意图。(a) 对应于潜变量三个状态中每一个的发射分布的等概率密度轮廓。(b) 从该隐马尔可夫模型中抽取的 50 个样本点, 按照生成它们的成分进行颜色编码, 并用线条连接连续的观测。这里转移矩阵被设定为: 在任一状态下, 以 5% 的概率转移到其他每一个状态, 因此以 90% 的概率保持在同一状态。

对标准 HMM 模型有很多变体, 例如通过对转移矩阵 $\mathbf{A}$ 的形式施加约束来得到 (Rabiner, 1989)。这里我们提到一种在实践中特别重要的变体, 称为从左到右的 HMM (left-to-right HMM)。这种模型通过令当 $k < j$ 时 $A_{jk} = 0$ 来得到, 对应一个如图 13.9 所示的三状态 HMM 的状态转移图。通常对于这样的模型, 还会对初始状态分布 $p(\mathbf{z}_1)$ 进行修改, 使得 $p(z_{11}) = 1$ 且对 $j \neq 1$ 有 $p(z_{1j}) = 0$, 也就是说每个序列都被约束为从状态 $j = 1$ 开始。为了确保状态索引不会发生过大的跳变, 转移矩阵还可以进一步约束为当 $k > j + \Delta$ 时 $A_{jk} = 0$ 。这种模型通过格状图示意时如图 13.10 所示。

图 13.9 三状态从左到右隐马尔可夫模型的状态转移图示例。


注意, 一旦离开某个状态, 之后就不能再次进入该状态。



在许多隐马尔可夫模型的应用中, 例如语音识别或在线字符识别, 都采用从左到右的结构。作为左到右隐马尔可夫模型的一个例子, 我们来看手写数字问题。这里使用的是“在线”数据, 也就是说, 每个数字由笔尖随时间运动的轨迹来表示, 是一系列笔尖坐标的序列; 这与附录 A 中讨论的“离线”数字数据不同, 后者由静态的、二维像素化的墨迹图像构成。在线数字的例子如图 13.11 所示。在该例中, 我们用 45 个数字“2”的样本子集来训练隐马尔可夫模型。这里 $K = 16$, 每个状态可以生成一段固定长度的线段, 而线段的角度可以取 16 个可能值, 因此发射分布只是一个 16×16 概率表, 用来刻画对每个状态索引值而言各个允许角度的概率。除了保持状态索引 k 不变或将其加 1 的转移概率外, 其他所有转移概率都设为零, 并使用 EM 算法进行 25 次迭代来优化模型参数。通过对训练好的模型进行生成式运行 (如图 13.11 所示), 我们可以对模型有


图 13.10 三状态从左到右 HMM 的格状

图，其中状态索引 k 在每一次转移时最多只允许增加 1。



更直观的理解。

图 13.11 上排：在线手写数字的示例。下排：从一个从左到右的隐马尔可夫模型中以生成方式采样得到的合成数字，该模型是在一个包含 45 个手写数字的数据集上训练得到的。



隐马尔可夫模型最强大的性质之一，就是它能在一定程度上对时间轴上的局部扭曲（压缩与拉伸）保持不变性。为了理解这一点，再次考虑在线手写数字示例中书写数字“2”的方式。一个典型的“2”包含两个通过尖点连接的部分。数字的第一部分从左上开始，有一个向左下的弧线，到达左下的尖部或小环，然后是第二部分，即一段大致直线段，向右下延伸到右下角。书写风格的自然变化会导致这两部分的相对长度发生变化，从而尖点或小环在时间序列上的位置也会变化。从生成式的角度看，这种变化可以通过隐马尔可夫模型中“停留在同一状态的转移次数”和“转移到后继状态的次数”的变化来适应。然而要注意的是，如果“2”字是反向书写的，即从右下角开始并最终到达左上角，那么即便笔尖轨迹的坐标可能与训练集中的某个例子完全相同，在该模型下观测的概率仍会极小。在语音识别的背景下，时间轴的扭曲与说话速度的自然变化相关，隐马尔可夫模型同样可以容纳这种扭曲，并不会对其施加过重的惩罚。

13.2.1 HMM 的极大似然估计

如果我们观测到一个数据集 $\mathbf{X} = \{\mathbf{x}_1, \dots, \mathbf{x}_N\}$ ，就可以通过极大似然来估计 HMM 的参数。似然函数由联合分布 (13.10) 对潜在变量积分（求和）得到：

$$p(\mathbf{X} | \boldsymbol{\theta}) = \sum_{\mathbf{Z}} p(\mathbf{X}, \mathbf{Z} | \boldsymbol{\theta}). \quad (13.11)$$

由于联合分布 $p(\mathbf{X}, \mathbf{Z} | \boldsymbol{\theta})$ 并不能在 n 上因子化（与第 9 章中讨论的混合分布不同），我们不能简单地把对各个 $\mathbf{z}_n$ 的求和分别独立处理。我们也无法显式地进行这个求和，因为需要对 N 个变量求和，其中每个变量都有 K 个状态，这将产生总共 K^N 项。因此求和项的数量随链的长度呈指数级增长。事实上，式 (13.11) 中的求和对应于对图 13.7 中格状图上的指数多条路径求和。

我们在第 8.32 图中简单链的推断问题时已经遇到过类似困难。当时，我们利用图的条件独立性，把求和顺序重新排列，从而得到一个算法，其计算代价随链长线性增长，而不是指数增长。我们将在隐马尔可夫模型中采用类似的技巧。

式 (13.11) 中的似然函数还存在另一个困难，即它作为混合分布的一般化，表示对不同潜在变量设置下的各个发射模型进行求和。因而对似然函数进行直接最大化会得到复杂的表达式，没有封闭形式的解，就像简单混合模型那样（回忆一下，对 i.i.d. 数据的混合模型是 HMM 的一个特例）。

因此，我们转向使用期望最大化（EM）算法，为在隐马尔可夫模型中最大化似然函数提供一个高效的框架。EM 算法从某个模型参数的初始选择开始，记为 $\boldsymbol{\theta}^{\text{old}}$ 。在 E 步中，我们利用这些参数值求出潜在变量的后验分布 $p(\mathbf{Z} | \mathbf{X}, \boldsymbol{\theta}^{\text{old}})$ 。然后用该后验分布来计算关于参数 $\boldsymbol{\theta}$ 的完整数据对数似然的期望，从而得到函数 $Q(\boldsymbol{\theta}, \boldsymbol{\theta}^{\text{old}})$ ：

$$Q(\boldsymbol{\theta}, \boldsymbol{\theta}^{\text{old}}) = \sum_{\mathbf{Z}} p(\mathbf{Z} | \mathbf{X}, \boldsymbol{\theta}^{\text{old}}) \ln p(\mathbf{X}, \mathbf{Z} | \boldsymbol{\theta}). \quad (13.12)$$

在这里，引入一些记号会更方便。我们用 $\gamma(\mathbf{z}_n)$ 表示潜在变量 $\mathbf{z}_n$ 的边缘后验分布，用 $\xi(\mathbf{z}_{n-1}, \mathbf{z}_n)$ 表示相邻两潜在变量的联合后验分布，即

$$\gamma(\mathbf{z}_n) = p(\mathbf{z}_n | \mathbf{X}, \boldsymbol{\theta}^{\text{old}}), \quad (13.13)$$

$$\xi(\mathbf{z}_{n-1}, \mathbf{z}_n) = p(\mathbf{z}_{n-1}, \mathbf{z}_n | \mathbf{X}, \boldsymbol{\theta}^{\text{old}}). \quad (13.14)$$

对于每一个 n ，我们可以用一组 K 个非负且和为 1 的数来存储 $\gamma(\mathbf{z}_n)$ ；类似地，用一个 $K \times K$ 的非负矩阵来存储 $\xi(\mathbf{z}_{n-1}, \mathbf{z}_n)$ ，其元素之和也为 1。我们还用 $\gamma(z_{nk})$ 表示 $z_{nk} = 1$ 的条件概率，对 $\xi(z_{n-1,j}, z_{nk})$ 和后续引入的其他概率变量也作类似记号。由于二值随机变量的期望就是它取值为 1 的概率，我们有

$$\gamma(z_{nk}) = \mathbb{E}[z_{nk}] = \sum_{\mathbf{z}} \gamma(\mathbf{z}) z_{nk}, \quad (13.15)$$

$$\xi(z_{n-1,j}, z_{nk}) = \mathbb{E}[z_{n-1,j} z_{nk}] = \sum_{\mathbf{z}} \gamma(\mathbf{z}) z_{n-1,j} z_{nk}. \quad (13.16)$$

如果将 (13.10) 给出的联合分布 $p(\mathbf{X}, \mathbf{Z} | \boldsymbol{\theta})$ 代入式 (13.12)，并利用 γ 与 ξ 的定义，可得

$$\begin{aligned} Q(\boldsymbol{\theta}, \boldsymbol{\theta}^{\text{old}}) &= \sum_{k=1}^K \gamma(z_{1k}) \ln \pi_k + \sum_{n=2}^N \sum_{j=1}^K \sum_{k=1}^K \xi(z_{n-1,j}, z_{nk}) \ln A_{jk} \\ &\quad + \sum_{n=1}^N \sum_{k=1}^K \gamma(z_{nk}) \ln p(\mathbf{x}_n | \phi_k). \end{aligned} \quad (13.17)$$

E-STEP 的目标就是高效地计算 $\gamma(\mathbf{z}_n)$ 和 $\xi(\mathbf{z}_{n-1}, \mathbf{z}_n)$ ，我们随后将详细讨论这一点。

在 M-STEP 中，我们在把 $\gamma(\mathbf{z}_n)$ 和 $\xi(\mathbf{z}_{n-1}, \mathbf{z}_n)$ 视为常数的前提下，对参数 $\theta = \{\pi, \mathbf{A}, \phi\}$ 最大化 $Q(\theta, \theta^{\text{old}})$ 。对 π 和 $\mathbf{A}$ 的最大化可以用合适的拉格朗日乘子轻松实现，得到的结果为

$$\pi_k = \frac{\gamma(z_{1k})}{\sum_{j=1}^K \gamma(z_{1j})}, \quad (13.18)$$

$$A_{jk} = \frac{\sum_{n=2}^N \xi(z_{n-1,j}, z_{nk})}{\sum_{l=1}^K \sum_{n=2}^N \xi(z_{n-1,j}, z_{nl})}. \quad (13.19)$$

EM 算法必须通过为 π 和 $\mathbf{A}$ 选择初始值来进行初始化，这些初始值当然满足它们作为概率分布的归一化约束。注意：任何在初始化时被设为 0 的 π 或 $\mathbf{A}$ 的元素在随后的 EM 更新中都会保持为 0。一种典型的初始化过程是，在满足归一化与非负约束的条件下，为这些参数随机选择起始值。需要指出的是，对于从左到右模型，并不需要对 EM 结果做特别修改，只需在为 A_{jk} 赋初值时，将相应的元素设为 0 即可，因为它们在整个训练过程中都将保持为 0。

为了对 ϕ_k 最大化 $Q(\theta, \theta^{\text{old}})$ ，我们注意到只有式 (13.17) 中的最后一项依赖于 ϕ_k ，并且这项与 i.i.d. 数据的标准混合模型对应函数中的数据相关项形式完全一致（可与高斯混合情形下的式 (9.40) 比较）。此时， $\gamma(z_{nk})$ 起到了“责任度”的作用。如果各分量的参数 ϕ_k 彼此独立，那么这项会分解成 K 项之和，每个 k 一项，并且每项都可以独立最大化。这样我们就是在对发射密度 $p(\mathbf{x} | \phi_k)$ 的加权对数似然函数进行最大化，权重为 $\gamma(z_{nk})$ 。在此我们假定这一最大化过程是可以高效完成的。例如，在高斯发射密度的情形中， $p(\mathbf{x} | \phi_k) = \mathcal{N}(\mathbf{x} | \mu_k, \Sigma_k)$ ，此时对 $Q(\theta, \theta^{\text{old}})$ 进行最大化可以得到

$$\mu_k = \frac{\sum_{n=1}^N \gamma(z_{nk}) \mathbf{x}_n}{\sum_{n=1}^N \gamma(z_{nk})}, \quad (13.20)$$

$$\Sigma_k = \frac{\sum_{n=1}^N \gamma(z_{nk}) (\mathbf{x}_n - \mu_k)(\mathbf{x}_n - \mu_k)^T}{\sum_{n=1}^N \gamma(z_{nk})}. \quad (13.21)$$

对于离散多项式观测变量，观测的条件分布为

$$p(\mathbf{x} | \mathbf{z}) = \prod_{i=1}^D \prod_{k=1}^K \mu_{ik}^{x_i z_k}, \quad (13.22)$$

对应的 M 步更新公式为

$$\mu_{ik} = \frac{\sum_{n=1}^N \gamma(z_{nk}) x_{ni}}{\sum_{n=1}^N \gamma(z_{nk})}. \quad (13.23)$$

对于伯努利观测变量，也可以得到类似的结果。

EM 算法还需要为发射分布的参数设定初始值。一个办法是：首先把数据当作 i.i.d. 数据来处理，通过极大似然拟合发射密度，然后用得到的参数值来初始化 HMM 的发射参数。

13.2.2 前向-后向算法

接下来我们要寻找一种高效的过程来计算 $\gamma(z_{nk})$ 和 $\xi(z_{n-1,j}, z_{nk})$ ，这对应于 EM 算法的 E 步。隐马尔可夫模型的图结构如图 13.5 所示，是一棵树，因此我们知道，可以用两阶段的消息传递算法高效地求出潜在变量的后验分布。在隐马尔可夫模型的具体背景下，这个算法被称为前向-后向算法（forward-backward algorithm, Rabiner, 1989），或 Baum-Welch 算法（Baum, 1972）。实际上，该基本算法有若干变体，它们对消息在链上如何传播的具体形式略有不同，但都能得到精确的边缘分布（Jordan, 2007）。我们将集中讨论其中使用最广泛的一种，即所谓的 α - β 算法。

前向-后向算法本身在实践中就非常重要，同时它也很好展示了前几章引入的许多概念。因此，在本节中我们先给出一套“常规”的前向-后向方程推导方法，利用概率的加法与乘法法则，并借助 d-分离从对应的图模型中得到条件独立性质。然后在 13.2.3 节中，我们将看到如何把前向-后向算法简洁地理解为第 8.4.4 节中介绍的和-积算法的一个具体实例。

值得强调的是，潜在变量后验分布的计算与发射密度 $p(x | z)$ 的具体形式无关，也与观测变量是连续还是离散无关。我们唯一需要的是对每个 n 、每个 $\mathbf{z}_n$ 的 $p(\mathbf{x}_n | \mathbf{z}_n)$ 的数值。此外，在本节及下一节中，我们将省略对模型参数 θ^{old} 的显式依赖，因为它们在整个过程中都是固定的。

因此，我们先写下如下条件独立性质（Jordan, 2007）：

$$\begin{aligned} p(\mathbf{X} | \mathbf{z}_n) &= p(\mathbf{x}_1, \dots, \mathbf{x}_N | \mathbf{z}_n), \\ &= p(\mathbf{x}_{n+1}, \dots, \mathbf{x}_N | \mathbf{z}_n), \end{aligned} \quad (13.24)$$

$$p(\mathbf{x}_1, \dots, \mathbf{x}_{n-1} | \mathbf{x}_n, \mathbf{z}_n) = p(\mathbf{x}_1, \dots, \mathbf{x}_{n-1} | \mathbf{z}_n), \quad (13.25)$$

$$p(\mathbf{x}_1, \dots, \mathbf{x}_{n-1} | \mathbf{z}_{n-1}, \mathbf{z}_n) = p(\mathbf{x}_1, \dots, \mathbf{x}_{n-1} | \mathbf{z}_{n-1}), \quad (13.26)$$

$$p(\mathbf{x}_{n+1}, \dots, \mathbf{x}_N | \mathbf{z}_n, \mathbf{z}_{n+1}) = p(\mathbf{x}_{n+1}, \dots, \mathbf{x}_N | \mathbf{z}_{n+1}), \quad (13.27)$$

$$p(\mathbf{x}_{n+2}, \dots, \mathbf{x}_N | \mathbf{z}_{n+1}, \mathbf{x}_{n+1}) = p(\mathbf{x}_{n+2}, \dots, \mathbf{x}_N | \mathbf{z}_{n+1}), \quad (13.28)$$

$$\begin{aligned} p(\mathbf{X} | \mathbf{z}_{n-1}, \mathbf{z}_n) &= p(\mathbf{x}_1, \dots, \mathbf{x}_{n-1} | \mathbf{z}_{n-1}) \\ &\quad p(\mathbf{x}_n | \mathbf{z}_n) p(\mathbf{x}_{n+1}, \dots, \mathbf{x}_N | \mathbf{z}_n), \end{aligned} \quad (13.29)$$

$$p(\mathbf{x}_{N+1} | \mathbf{X}, \mathbf{z}_{N+1}) = p(\mathbf{x}_{N+1} | \mathbf{z}_{N+1}), \quad (13.30)$$

$$p(\mathbf{z}_{N+1} | \mathbf{z}_N, \mathbf{X}) = p(\mathbf{z}_{N+1} | \mathbf{z}_N), \quad (13.31)$$

其中 $\mathbf{X} = \{\mathbf{x}_1, \dots, \mathbf{x}_N\}$ 。这些关系用 $\mathbf{d}$ -分离来证明最为简洁。以第一条为例，我们注意到从任意一个结点 $\mathbf{x}_1, \dots, \mathbf{x}_{n-1}$ 到结点 $\mathbf{x}_n$ 的每一条路径都经过结点 $\mathbf{z}_n$ ，而 $\mathbf{z}_n$ 是已知（被条件化）的。由于所有这类路径都是“尾-尾”结构，因此相应的条件独立性结论成立。读者不妨花一些时间逐条验证这些性质，作为练习 $\mathbf{d}$ -分离应用的一个例子。也可以直接从隐马尔可夫模型的联合分布出发，利用概率的加法与乘法法则来证明这些关系，不过这会困难得多。

下面我们从计算 $\gamma(z_{nk})$ 入手。回忆一下，对于离散多项式随机变量，它的某个分量的期望就是该分量取值为 1 的概率。因此，我们感兴趣的是潜在变量 $\mathbf{z}_n$ 在给定观测数据集 $\mathbf{x}_1, \dots, \mathbf{x}_N$ 时的后验分布 $p(\mathbf{z}_n | \mathbf{x}_1, \dots, \mathbf{x}_N)$ 。这是一个长度为 K 的向量，其各个分量正是 z_{nk} 的期望值。利用贝叶斯定理，有

$$\gamma(\mathbf{z}_n) = p(\mathbf{z}_n | \mathbf{X}) = \frac{p(\mathbf{X} | \mathbf{z}_n) p(\mathbf{z}_n)}{p(\mathbf{X})}. \quad (13.32)$$

注意，分母 $p(\mathbf{X})$ 隐含地以 HMM 的参数 θ^{old} 为条件，因此它就是似然函数。利用条件独立性质 (13.24) 以及概率的乘法法则，我们得到

$$\gamma(\mathbf{z}_n) = \frac{p(\mathbf{x}_1, \dots, \mathbf{x}_n, \mathbf{z}_n) p(\mathbf{x}_{n+1}, \dots, \mathbf{x}_N | \mathbf{z}_n)}{p(\mathbf{X})} = \frac{\alpha(\mathbf{z}_n) \beta(\mathbf{z}_n)}{p(\mathbf{X})}, \quad (13.33)$$

其中我们定义

$$\alpha(\mathbf{z}_n) \equiv p(\mathbf{x}_1, \dots, \mathbf{x}_n, \mathbf{z}_n), \quad (13.34)$$

$$\beta(\mathbf{z}_n) \equiv p(\mathbf{x}_{n+1}, \dots, \mathbf{x}_N | \mathbf{z}_n). \quad (13.35)$$

量 $\alpha(\mathbf{z}_n)$ 表示：观测到截至时刻 n 的全部数据并且潜在变量 $\mathbf{z}_n$ 取某个值的联合概率；而 $\beta(\mathbf{z}_n)$ 表示：在给定 $\mathbf{z}_n$ 的取值条件下，从时刻 $n+1$ 到 N 的全部未来数据的条件概率。同样， $\alpha(\mathbf{z}_n)$ 和 $\beta(\mathbf{z}_n)$ 都可以用 K 个数来表示，分别对应 1-of- K 编码二值向量

$\mathbf{z}_n$ 的所有可能取值。我们用 $\alpha(z_{nk})$ 表示在 $z_{nk} = 1$ 时 $\alpha(\mathbf{z}_n)$ 的值，对 $\beta(z_{nk})$ 也做类似记号。

现在我们推导递推关系，使得可以高效地计算 $\alpha(\mathbf{z}_n)$ 和 $\beta(\mathbf{z}_n)$ 。同样，我们将利用条件独立性质，具体而言是 (13.25) 和 (13.26)，再结合加法与乘法法则，从而把 $\alpha(\mathbf{z}_n)$ 表示为 $\alpha(\mathbf{z}_{n-1})$ 的函数如下：


$$\begin{aligned}
 \alpha(\mathbf{z}_n) &= p(\mathbf{x}_1, \dots, \mathbf{x}_n, \mathbf{z}_n) \\
 &= p(\mathbf{x}_1, \dots, \mathbf{x}_n \mid \mathbf{z}_n) p(\mathbf{z}_n) \\
 &= p(\mathbf{x}_n \mid \mathbf{z}_n) p(\mathbf{x}_1, \dots, \mathbf{x}_{n-1} \mid \mathbf{z}_n) p(\mathbf{z}_n) \\
 &= p(\mathbf{x}_n \mid \mathbf{z}_n) p(\mathbf{x}_1, \dots, \mathbf{x}_{n-1}, \mathbf{z}_n) \\
 &= p(\mathbf{x}_n \mid \mathbf{z}_n) \sum_{\mathbf{z}_{n-1}} p(\mathbf{x}_1, \dots, \mathbf{x}_{n-1}, \mathbf{z}_{n-1}, \mathbf{z}_n) \\
 &= p(\mathbf{x}_n \mid \mathbf{z}_n) \sum_{\mathbf{z}_{n-1}} p(\mathbf{x}_1, \dots, \mathbf{x}_{n-1}, \mathbf{z}_n \mid \mathbf{z}_{n-1}) p(\mathbf{z}_{n-1}) \\
 &= p(\mathbf{x}_n \mid \mathbf{z}_n) \sum_{\mathbf{z}_{n-1}} p(\mathbf{x}_1, \dots, \mathbf{x}_{n-1} \mid \mathbf{z}_{n-1}) p(\mathbf{z}_n \mid \mathbf{z}_{n-1}) p(\mathbf{z}_{n-1}) \\
 &= p(\mathbf{x}_n \mid \mathbf{z}_n) \sum_{\mathbf{z}_{n-1}} p(\mathbf{x}_1, \dots, \mathbf{x}_{n-1}, \mathbf{z}_{n-1}) p(\mathbf{z}_n \mid \mathbf{z}_{n-1}).
 \end{aligned}$$

利用 $\alpha(\mathbf{z}_n)$ 的定义 (13.34)，最终得到

$$\alpha(\mathbf{z}_n) = p(\mathbf{x}_n \mid \mathbf{z}_n) \sum_{\mathbf{z}_{n-1}} \alpha(\mathbf{z}_{n-1}) p(\mathbf{z}_n \mid \mathbf{z}_{n-1}). \quad (13.36)$$

值得花点时间仔细体会这个递推式。注意求和中 K 项，而右侧对于 $\mathbf{z}_n$ 的每一个取值都必须计算一次，因此 α 递推的每一步计算量为 $O(K^2)$ 。用于计算 $\alpha(\mathbf{z}_n)$ 的前向递推方程在格状图上的示意如图 13.12 所示。

图 13.12 用于计算 α 变量的前向递推式 (13.36) 的示意图。在该格状图的这一部分中，可以看到量 $\alpha(\mathbf{z}_{n1})$ 是通过取第 $n-1$ 步中 $\alpha(\mathbf{z}_{n-1})$ 的各个元素 $\alpha(z_{n-1,j})$ ，按权重 A_{j1} （对应于 $p(z_n \mid z_{n-1})$ 的取值）加权求和，然后再乘以数据项 $p(\mathbf{x}_n \mid z_{n1})$ 得到的。



为了启动这一递推，我们需要一个初始条件：

$$\alpha(\mathbf{z}_1) = p(\mathbf{x}_1, \mathbf{z}_1) = p(\mathbf{z}_1) p(\mathbf{x}_1 \mid \mathbf{z}_1) = \prod_{k=1}^K \{\pi_k p(\mathbf{x}_1 \mid \phi_k)\}^{z_{1k}}, \quad (13.37)$$

这告诉我们，当 $k = 1, \dots, K$ 时， $\alpha(z_{1k})$ 的取值为 $\pi_k p(\mathbf{x}_1 | \phi_k)$ 。从链的第一个结点开始，我们就可以沿链向前递推，对每个潜在结点计算 $\alpha(\mathbf{z}_n)$ 。由于每一步递推都需要乘以一个 $K \times K$ 矩阵，因此对整个链计算这些量的总费用为 $O(K^2 N)$ 。

类似地，我们可以利用条件独立性质 (13.27) 和 (13.28) 推导出 $\beta(\mathbf{z}_n)$ 的递推关系：


$$\begin{aligned}
 \beta(\mathbf{z}_n) &= p(\mathbf{x}_{n+1}, \dots, \mathbf{x}_N | \mathbf{z}_n) \\
 &= \sum_{\mathbf{z}_{n+1}} p(\mathbf{x}_{n+1}, \dots, \mathbf{x}_N, \mathbf{z}_{n+1} | \mathbf{z}_n) \\
 &= \sum_{\mathbf{z}_{n+1}} p(\mathbf{x}_{n+1}, \dots, \mathbf{x}_N | \mathbf{z}_n, \mathbf{z}_{n+1}) p(\mathbf{z}_{n+1} | \mathbf{z}_n) \\
 &= \sum_{\mathbf{z}_{n+1}} p(\mathbf{x}_{n+1}, \dots, \mathbf{x}_N | \mathbf{z}_{n+1}) p(\mathbf{z}_{n+1} | \mathbf{z}_n) \\
 &= \sum_{\mathbf{z}_{n+1}} p(\mathbf{x}_{n+2}, \dots, \mathbf{x}_N | \mathbf{z}_{n+1}) p(\mathbf{x}_{n+1} | \mathbf{z}_{n+1}) p(\mathbf{z}_{n+1} | \mathbf{z}_n).
 \end{aligned}$$

利用 $\beta(\mathbf{z}_n)$ 的定义 (13.35)，我们得到

$$\beta(\mathbf{z}_n) = \sum_{\mathbf{z}_{n+1}} \beta(\mathbf{z}_{n+1}) p(\mathbf{x}_{n+1} | \mathbf{z}_{n+1}) p(\mathbf{z}_{n+1} | \mathbf{z}_n). \quad (13.38)$$

注意在这里，我们得到的是一个将 $\beta(\mathbf{z}_n)$ 表示为 $\beta(\mathbf{z}_{n+1})$ 的反向消息传递算法。在每一步中，我们通过发射概率 $p(\mathbf{x}_{n+1} | \mathbf{z}_{n+1})$ 吸收入观测 $\mathbf{x}_{n+1}$ 的影响，再乘以转移矩阵 $p(\mathbf{z}_{n+1} | \mathbf{z}_n)$ ，最后对 $\mathbf{z}_{n+1}$ 求和（边缘化）。这一过程如图 13.13 所示。

图 13.13 用于计算 β 变量的后向递推式 (13.38) 的示意图。在该格状图的这一部分中，可以看到量 $\beta(z_{n1})$ 是通过取第 $n+1$ 步中 $\beta(\mathbf{z}_{n+1})$ 的各个分量 $\beta(z_{n+1,k})$ ，按权重进行求和，这些权重由 A_{1k} （对应于 $p(\mathbf{z}_{n+1} | \mathbf{z}_n)$ 的取值）与相应的发射密度 $p(\mathbf{x}_n | z_{n+1,k})$ 的乘积给出。



同样，我们需要该递推的初始条件，也就是 $\beta(\mathbf{z}_N)$ 的取值。这可以通过在式 (13.33) 中令 $n = N$ ，并用 (13.34) 中 $\alpha(\mathbf{z}_N)$ 的定义代入得到：

$$p(\mathbf{z}_N | \mathbf{X}) = \frac{p(\mathbf{X}, \mathbf{z}_N) \beta(\mathbf{z}_N)}{p(\mathbf{X})}, \quad (13.39)$$

可以看出，只要对每一个 $\mathbf{z}_N$ 的取值令 $\beta(\mathbf{z}_N) = 1$ ，该式就成立。

在 M 步的方程中， $p(\mathbf{X})$ 将会相互抵消。例如，在式 (13.20) 给出的 μ_k 的 M 步更新中，有

$$\mu_k = \frac{\sum_{n=1}^N \gamma(z_{nk}) \mathbf{x}_n}{\sum_{n=1}^N \gamma(z_{nk})} = \frac{\sum_{n=1}^N \alpha(z_{nk}) \beta(z_{nk}) \mathbf{x}_n}{\sum_{n=1}^N \alpha(z_{nk}) \beta(z_{nk})}. \quad (13.40)$$

不过, $p(\mathbf{X})$ 是我们通常希望在 EM 优化过程中加以监控的似然函数, 因此能够计算它的值是非常有用的。如果我们对式 (13.33) 的两边在 $\mathbf{z}_n$ 上求和, 并利用左边是一个归一化分布这一事实, 就得到

$$p(\mathbf{X}) = \sum_{\mathbf{z}_n} \alpha(\mathbf{z}_n) \beta(\mathbf{z}_n). \quad (13.41)$$

因此, 我们可以通过计算该和来得到似然函数的值, 对 n 的取值可以任选一个方便的位置。例如, 如果我们只想计算似然函数, 那么可以从链的起点到终点运行一次 α 递推, 然后在 $n = N$ 处使用这个结果, 并利用 $\beta(\mathbf{z}_N)$ 是全 1 向量这一事实。这样就不需要运行 β 递推, 直接得到

$$p(\mathbf{X}) = \sum_{\mathbf{z}_N} \alpha(\mathbf{z}_N). \quad (13.42)$$

让我们花一点时间来理解关于 $p(\mathbf{X})$ 的这个结果。回忆一下, 为了计算似然, 我们应该取联合分布 $p(\mathbf{X}, \mathbf{Z})$ 并对 $\mathbf{Z}$ 的所有可能取值求和。每一个这样的取值表示在每一个时间步上对隐状态的一种具体选择, 换句话说, 求和中的每一项都是格状图 (lattice) 中的一条路径, 并且回忆一下, 这样的路径有指数多个。通过把似然函数写成式 (13.42) 的形式, 我们实际上是通过交换求和与乘法的顺序, 将计算代价从随链长指数增长降为随链长线性增长: 在每一个时间步 n , 我们对所有通过各个状态 z_{nk} 的路径的贡献求和, 从而得到中间量 $\alpha(\mathbf{z}_n)$ 。

接下来, 我们考虑计算 $\xi(\mathbf{z}_{n-1}, \mathbf{z}_n)$, 它对应于条件概率 $p(\mathbf{z}_{n-1}, \mathbf{z}_n | \mathbf{X})$ 在 $(\mathbf{z}_{n-1}, \mathbf{z}_n)$ 的每一个 $K \times K$ 可能取值上的数值。利用 $\xi(\mathbf{z}_{n-1}, \mathbf{z}_n)$ 的定义并应用贝叶斯定理, 有

$$\begin{aligned} \xi(\mathbf{z}_{n-1}, \mathbf{z}_n) &= p(\mathbf{z}_{n-1}, \mathbf{z}_n | \mathbf{X}) \\ &= \frac{p(\mathbf{X} | \mathbf{z}_{n-1}, \mathbf{z}_n) p(\mathbf{z}_{n-1}, \mathbf{z}_n)}{p(\mathbf{X})} \\ &= \frac{p(\mathbf{x}_1, \dots, \mathbf{x}_{n-1} | \mathbf{z}_{n-1}) p(\mathbf{x}_n | \mathbf{z}_n) p(\mathbf{x}_{n+1}, \dots, \mathbf{x}_N | \mathbf{z}_n) p(\mathbf{z}_n | \mathbf{z}_{n-1}) p(\mathbf{z}_{n-1})}{p(\mathbf{X})} \\ &= \frac{\alpha(\mathbf{z}_{n-1}) p(\mathbf{x}_n | \mathbf{z}_n) p(\mathbf{z}_n | \mathbf{z}_{n-1}) \beta(\mathbf{z}_n)}{p(\mathbf{X})}, \end{aligned} \quad (13.43)$$

这里我们利用了条件独立性质 (13.29), 以及 (13.34) 与 (13.35) 中对 $\alpha(\mathbf{z}_n)$ 与 $\beta(\mathbf{z}_n)$ 的定义。因此, 我们可以直接利用 α 与 β 递推的结果来计算 $\xi(\mathbf{z}_{n-1}, \mathbf{z}_n)$ 。

下面我们总结一下用 EM 算法训练隐马尔可夫模型所需的步骤。首先对参数 θ^{old} 做一个初始选择, 其中 $\theta \equiv (\pi, \mathbf{A}, \phi)$ 。参数 $\mathbf{A}$ 与 π 通常被初始化为均匀分布, 或者从均匀分布随机初始化 (同时满足非负性和归一化约束)。参数 ϕ 的初始化将依赖于具体分布的形式。例如在高斯情形下, 可以先对数据运行 K 均值算法, 用聚类得到的质心来初始化 μ_k , 并用对应簇的协方差矩阵来初始化 Σ_k 。然后, 我们运行前向的 α 递推与后向的 β 递推, 并利用结果来计算 $\gamma(\mathbf{z}_n)$ 和 $\xi(\mathbf{z}_{n-1}, \mathbf{z}_n)$ 。在这个阶段我们也可以计算似然函数。

这就完成了 E 步, 然后我们利用这些结果通过 13.2.1 节中的 M 步方程来求得一组更新后的参数 θ^{new} 。接着在 E 步与 M 步之间不断交替, 直到满足某种收敛准则, 例如

似然函数的变化低于某个阈值。

需要注意的是，在这些递推关系中，观测数据只通过形如 $p(\mathbf{x}_n | \mathbf{z}_n)$ 的条件分布进入。因而，只要对于 $\mathbf{z}_n$ 的每一个可能状态，都可以计算出 $p(\mathbf{x}_n | \mathbf{z}_n)$ 的数值，这些递推就与观测变量的类型、维数以及条件分布的具体形式无关。由于观测变量 $\{\mathbf{x}_n\}$ 是固定的， $p(\mathbf{x}_n | \mathbf{z}_n)$ 这些量可以在 EM 算法开始时就作为 $\mathbf{z}_n$ 的函数预先计算好，并在整个过程中保持不变。

我们在前几章中已经看到，最大似然方法在数据点数目相对于参数个数足够大时效果最好。这里需要指出，当训练序列足够长时，可以通过最大似然有效地训练隐马尔可夫模型。或者，我们也可以使用多条较短的序列，此时只需要对 HMM 的 EM 算法做一个直接的修改。在从左到右模型的情形下，这一点尤其重要，因为在一条给定的观测序列中，对应于转移矩阵 $\mathbf{A}$ 中某个非对角元素的状态转移顶多只会出现一次。

另一个感兴趣的量是预测分布。此时观测数据为 $\mathbf{X} = \{\mathbf{x}_1, \dots, \mathbf{x}_N\}$ ，而我们希望预测 $\mathbf{x}_{N+1}$ ，这在诸如金融预测等实时应用中非常重要。同样，我们利用加法与乘法法则以及条件独立性质 (13.29) 与 (13.31)，得到

$$\begin{aligned}
 p(\mathbf{x}_{N+1} | \mathbf{X}) &= \sum_{\mathbf{z}_{N+1}} p(\mathbf{x}_{N+1}, \mathbf{z}_{N+1} | \mathbf{X}) \\
 &= \sum_{\mathbf{z}_{N+1}} p(\mathbf{x}_{N+1} | \mathbf{z}_{N+1}) p(\mathbf{z}_{N+1} | \mathbf{X}) \\
 &= \sum_{\mathbf{z}_{N+1}} p(\mathbf{x}_{N+1} | \mathbf{z}_{N+1}) \sum_{\mathbf{z}_N} p(\mathbf{z}_{N+1}, \mathbf{z}_N | \mathbf{X}) \\
 &= \sum_{\mathbf{z}_{N+1}} p(\mathbf{x}_{N+1} | \mathbf{z}_{N+1}) \sum_{\mathbf{z}_N} p(\mathbf{z}_{N+1} | \mathbf{z}_N) p(\mathbf{z}_N | \mathbf{X}) \\
 &= \sum_{\mathbf{z}_{N+1}} p(\mathbf{x}_{N+1} | \mathbf{z}_{N+1}) \sum_{\mathbf{z}_N} p(\mathbf{z}_{N+1} | \mathbf{z}_N) \frac{p(\mathbf{z}_N, \mathbf{X})}{p(\mathbf{X})} \\
 &= \frac{1}{p(\mathbf{X})} \sum_{\mathbf{z}_{N+1}} p(\mathbf{x}_{N+1} | \mathbf{z}_{N+1}) \sum_{\mathbf{z}_N} p(\mathbf{z}_{N+1} | \mathbf{z}_N) \alpha(\mathbf{z}_N),
 \end{aligned} \tag{13.44}$$

通过先运行一次前向的 α 递推，然后对 $\mathbf{z}_N$ 与 $\mathbf{z}_{N+1}$ 做最后的求和，就可以对这一式子进行计算。第一次对 $\mathbf{z}_N$ 的求和结果可以保存下来：在观测到 $\mathbf{x}_{N+1}$ 的值之后，用它来把 α 递推向前推进一步，以便预测之后的值 $\mathbf{x}_{N+2}$ 。注意，在式 (13.44) 中，从 $\mathbf{x}_1$ 到 $\mathbf{x}_N$ 的全部数据对预测的影响都浓缩在 $\alpha(\mathbf{z}_N)$ 的 K 个数中。因此，在实时应用中，预测分布可以在仅使用固定存储量的前提下无限向前推进。

到目前为止，我们讨论的是用最大似然方法来估计 HMM 的参数。这一框架可以很容易扩展到正则化的最大似然：为模型参数 $\pi, \mathbf{A}$ 与 ϕ 引入先验分布，然后通过最大化它们的后验概率来估计参数取值。这同样可以用 EM 算法来实现，其中 E 步与前面讨论的一样，M 步则是在最大化之前把先验分布 $p(\theta)$ 的对数加到 $Q(\theta, \theta^{\text{old}})$ 上，这与本书其他部分多次使用的技术是直接类似的。此外，我们还可以使用变分方法给出 HMM 的完全贝叶斯处理，在其中要对参数的分布进行边缘化 (MacKay, 1997)。就像最大似然方法一样，这也会导致一个两遍的前向-后向递推来计算后验概率。

13.2.3 HMM 的和-积算法

表示隐马尔可夫模型的有向图（见图 13.5）是一棵树，因此我们可以用和-积算法来求解隐变量局部边缘分布的问题。毫不意外，这恰好等价于上一节中的前向-后向算法，因此和-积算法为我们提供了一种简洁的方法来推导 α - β 递推公式。

图 13.14 隐马尔可夫模型的因子图表示中的一个片段。





图 13.15 用于描述隐马尔可夫模型的一种简化形式的因子图。



我们先将图 13.5 中的有向图转换为因子图，其一部分示意如图 13.14 所示。这种因子图形式把所有变量（包括潜在与观测变量）都显式地画出来。不过，为了求解推断问题，我们总是要对变量 $\mathbf{x}_1, \dots, \mathbf{x}_N$ 进行条件化，因此我们可以通过把发射概率吸收入转移概率因子来简化因子图。于是得到图 13.15 所示的简化因子图，其中各个因子定义为

$$h(\mathbf{z}_1) = p(\mathbf{z}_1)p(\mathbf{x}_1 | \mathbf{z}_1), \quad (13.45)$$

$$f_n(\mathbf{z}_{n-1}, \mathbf{z}_n) = p(\mathbf{z}_n | \mathbf{z}_{n-1})p(\mathbf{x}_n | \mathbf{z}_n). \quad (13.46)$$

为了推导 α - β 算法，我们把最后一个隐变量 $\mathbf{z}_N$ 视为根结点，并首先从叶结点 h 向根结点传递消息。根据 (8.66) 与 (8.69) 给出的通用消息传递规则，我们看到在隐马尔可夫模型中传播的消息满足

$$\mu_{\mathbf{z}_{n-1} \rightarrow f_n}(\mathbf{z}_{n-1}) = \mu_{f_{n-1} \rightarrow \mathbf{z}_{n-1}}(\mathbf{z}_{n-1}), \quad (13.47)$$

$$\mu_{f_n \rightarrow \mathbf{z}_n}(\mathbf{z}_n) = \sum_{\mathbf{z}_{n-1}} f_n(\mathbf{z}_{n-1}, \mathbf{z}_n) \mu_{\mathbf{z}_{n-1} \rightarrow f_n}(\mathbf{z}_{n-1}). \quad (13.48)$$

这些方程表示沿链向前传播消息，并且等价于上一节中推导的 α 递推，我们马上会加以说明。注意，因为变量结点 $\mathbf{z}_n$ 只有两个邻居，它们本身并不进行计算。

我们可以利用 (13.47) 消去 (13.48) 中的 $\mu_{\mathbf{z}_{n-1} \rightarrow f_n}(\mathbf{z}_{n-1})$ ，从而得到关于 $f \rightarrow \mathbf{z}$ 消息的递推式：

$$\mu_{f_n \rightarrow \mathbf{z}_n}(\mathbf{z}_n) = \sum_{\mathbf{z}_{n-1}} f_n(\mathbf{z}_{n-1}, \mathbf{z}_n) \mu_{f_{n-1} \rightarrow \mathbf{z}_{n-1}}(\mathbf{z}_{n-1}). \quad (13.49)$$

如果我们回忆 (13.46) 中的定义，并令

$$\alpha(\mathbf{z}_n) = \mu_{f_n \rightarrow \mathbf{z}_n}(\mathbf{z}_n), \quad (13.50)$$

就得到与 (13.36) 相同的 α 递推。我们还需要验证这些 $\alpha(\mathbf{z}_n)$ 本身与之前定义的一致。这一点很容易：利用初始条件 (8.71)，可以看到 $\alpha(\mathbf{z}_1)$ 由 $h(\mathbf{z}_1) = p(\mathbf{z}_1)p(\mathbf{x}_1 | \mathbf{z}_1)$ 给

出，这与 (13.37) 完全相同。由于初始的 α 相同，并且在之后的每一步中使用相同的方程递推，那么所有后续的 α 量必然相同。

接下来我们考虑从根结点向叶结点传播的消息。它们满足

$$\mu_{f_{n+1} \rightarrow f_n}(\mathbf{z}_n) = \sum_{\mathbf{z}_{n+1}} f_{n+1}(\mathbf{z}_n, \mathbf{z}_{n+1}) \mu_{f_{n+2} \rightarrow f_{n+1}}(\mathbf{z}_{n+1}), \quad (13.51)$$

这里与之前一样，我们消去了 $\mathbf{z} \rightarrow f$ 类型的消息，因为变量结点本身不进行计算。利用 (13.46) 所给出的 $f_{n+1}(\mathbf{z}_n, \mathbf{z}_{n+1})$ 的定义，并令

$$\beta(\mathbf{z}_n) = \mu_{f_{n+1} \rightarrow \mathbf{z}_n}(\mathbf{z}_n), \quad (13.52)$$

就得到了 (13.38) 中 β 的递推。同样，我们可以验证这些 β 变量本身也是等价的：式 (8.70) 表明，根变量结点发送的初始消息为 $\mu_{\mathbf{z}_N \rightarrow f_N}(\mathbf{z}_N) = 1$ ，这与 13.2.2 节中对 $\beta(\mathbf{z}_N)$ 的初始化完全一致。

和-积算法还给出了在所有消息都计算完成以后如何求边缘分布的规则。尤其是，结果 (8.63) 表明，结点 $\mathbf{z}_n$ 的局部边缘分布等于流入该结点的所有消息的乘积。由于我们对 $\mathbf{X} = \{\mathbf{x}_1, \dots, \mathbf{x}_N\}$ 条件化，因此实际计算的是联合分布

$$p(\mathbf{z}_n, \mathbf{X}) = \mu_{f_n \rightarrow \mathbf{z}_n}(\mathbf{z}_n) \mu_{f_{n+1} \rightarrow \mathbf{z}_n}(\mathbf{z}_n) = \alpha(\mathbf{z}_n) \beta(\mathbf{z}_n). \quad (13.53)$$

两边同除以 $p(\mathbf{X})$ ，即可得到

$$\gamma(\mathbf{z}_n) = \frac{p(\mathbf{z}_n, \mathbf{X})}{p(\mathbf{X})} = \frac{\alpha(\mathbf{z}_n) \beta(\mathbf{z}_n)}{p(\mathbf{X})}, \quad (13.54)$$

这与式 (13.33) 完全一致。式 (13.43) 也可以类似地由 (8.72) 推导出来。

13.2.4 缩放因子

在实际使用前向-后向算法之前，必须先处理一个重要的问题。由递推关系式 (13.36) 可知，在每一步中，新值 $\alpha(\mathbf{z}_n)$ 是通过在前一步的 $\alpha(\mathbf{z}_{n-1})$ 的基础上乘上 $p(\mathbf{z}_n | \mathbf{z}_{n-1})$ 和 $p(\mathbf{x}_n | \mathbf{z}_n)$ 得到的。由于这些概率通常远小于 1，当我们沿着链向前推进时， $\alpha(\mathbf{z}_n)$ 的值会指数式地趋近于 0。对于中等长度的链（比如长度在 100 左右），即使使用双精度浮点数，对 $\alpha(\mathbf{z}_n)$ 的计算也很快会超出计算机的动态范围。

在 i.i.d. 数据的情形下，我们通过对似然函数取对数，实际上规避了这个问题。不幸的是，这里这样做并没有帮助，因为我们要计算的是许多小数乘积的和（我们其实是在隐式地对图 13.7 的格状图中所有可能路径求和）。因此，我们改用重新缩放后的 $\alpha(\mathbf{z}_n)$ 和 $\beta(\mathbf{z}_n)$ ，使它们维持在数量级为 1 的范围内。正如将要看到的，当我们在 EM 算法中使用这些重新缩放后的量时，相应的缩放因子会相互抵消。

在式 (13.34) 中，我们定义了 $\alpha(\mathbf{z}_n) = p(\mathbf{x}_1, \dots, \mathbf{x}_n, \mathbf{z}_n)$ ，表示截至 $\mathbf{x}_n$ 的所有观测与潜在变量 $\mathbf{z}_n$ 的联合分布。现在我们定义一个归一化的 α 版本：

$$\hat{\alpha}(\mathbf{z}_n) = p(\mathbf{z}_n | \mathbf{x}_1, \dots, \mathbf{x}_n) = \frac{\alpha(\mathbf{z}_n)}{p(\mathbf{x}_1, \dots, \mathbf{x}_n)}, \quad (13.55)$$

由于对任意 n 而言，它都是关于 K 个变量的概率分布，因此我们期望它在数值上表现良好。为了关联缩放前后的 α 变量，我们引入由观测变量的条件分布定义的缩放因子：

$$c_n = p(\mathbf{x}_n \mid \mathbf{x}_1, \dots, \mathbf{x}_{n-1}). \quad (13.56)$$

由乘法法则可得

$$p(\mathbf{x}_1, \dots, \mathbf{x}_n) = \prod_{m=1}^n c_m, \quad (13.57)$$

因此

$$\alpha(\mathbf{z}_n) = p(\mathbf{z}_n \mid \mathbf{x}_1, \dots, \mathbf{x}_n) p(\mathbf{x}_1, \dots, \mathbf{x}_n) = \left(\prod_{m=1}^n c_m \right) \hat{\alpha}(\mathbf{z}_n). \quad (13.58)$$

我们于是可以把 α 的递推式 (13.36) 转换为 $\hat{\alpha}$ 的递推式：

$$c_n \hat{\alpha}(\mathbf{z}_n) = p(\mathbf{x}_n \mid \mathbf{z}_n) \sum_{\mathbf{z}_{n-1}} \hat{\alpha}(\mathbf{z}_{n-1}) p(\mathbf{z}_n \mid \mathbf{z}_{n-1}). \quad (13.59)$$

注意，在前向消息传递阶段的每一步，为了计算 $\hat{\alpha}(\mathbf{z}_n)$ ，我们都必须计算并存储 c_n ，这很容易做到，因为它正是将 (13.59) 右端归一化为 $\hat{\alpha}(\mathbf{z}_n)$ 所需的系数。

类似地，我们可以通过

$$\beta(\mathbf{z}_n) = \left(\prod_{m=n+1}^N c_m \right) \hat{\beta}(\mathbf{z}_n) \quad (13.60)$$

来定义重新缩放的变量 $\hat{\beta}(\mathbf{z}_n)$ ，它同样会保持在机器精度范围之内。由 (13.35) 可知，这些 $\hat{\beta}(\mathbf{z}_n)$ 只是两个条件概率之比：

$$\hat{\beta}(\mathbf{z}_n) = \frac{p(\mathbf{x}_{n+1}, \dots, \mathbf{x}_N \mid \mathbf{z}_n)}{p(\mathbf{x}_{n+1}, \dots, \mathbf{x}_N \mid \mathbf{x}_1, \dots, \mathbf{x}_n)}. \quad (13.61)$$

将 β 的递推结果 (13.38) 代入，即可得到重新缩放变量的递推式：

$$c_{n+1} \hat{\beta}(\mathbf{z}_n) = \sum_{\mathbf{z}_{n+1}} \hat{\beta}(\mathbf{z}_{n+1}) p(\mathbf{x}_{n+1} \mid \mathbf{z}_{n+1}) p(\mathbf{z}_{n+1} \mid \mathbf{z}_n). \quad (13.62)$$

在应用这个递推式时，我们要利用在 α 阶段已经计算好的缩放因子 c_n 。

由式 (13.57) 可知，似然函数可以用下式表示：

$$p(\mathbf{X}) = \prod_{n=1}^N c_n. \quad (13.63)$$

类似地，结合 (13.33) 和 (13.43)，再利用 (13.63)，可以发现所需的边缘分布由下式给出：

$$\gamma(\mathbf{z}_n) = \hat{\alpha}(\mathbf{z}_n) \hat{\beta}(\mathbf{z}_n), \quad (13.64)$$

$$\xi(\mathbf{z}_{n-1}, \mathbf{z}_n) = c_n \hat{\alpha}(\mathbf{z}_{n-1}) p(\mathbf{x}_n \mid \mathbf{z}_n) p(\mathbf{z}_n \mid \mathbf{z}_{n-1}) \hat{\beta}(\mathbf{z}_n). \quad (13.65)$$


最后，我们注意到前向-后向算法还有另一种形式 (Jordan, 2007)，其中后向递推是基于 $\gamma(\mathbf{z}_n) = \hat{\alpha}(\mathbf{z}_n)\hat{\beta}(\mathbf{z}_n)$ 而不是基于 $\hat{\beta}(\mathbf{z}_n)$ 来定义的。这种 α - γ 递推形式要求先完成前向递推，以便在后向递推中可以使用所有的 $\hat{\alpha}(\mathbf{z}_n)$ ；而在 α - β 算法中，前向与后向两个阶段可以独立完成。尽管这两种算法在计算复杂度上大致相同，但在隐马尔可夫模型中，更常用的是 α - β 形式；相比之下，对于线性动态系统，更常使用与 α - γ 形式类似的递推。

13.2.5 Viterbi 算法

在隐马尔可夫模型的许多应用中，潜在变量都具有一定的实际意义，因此对给定的观测序列找到最可能的隐状态序列往往极具意义。例如在语音识别中，我们可能希望针对一段声学观测序列找到最可能的音素序列。由于隐马尔可夫模型的图是一个有向树，这个问题可以用 max-sum 算法精确求解。回忆第 8.4.5 节中的讨论，寻找最可能的隐状态序列的问题，与“对每一个时间步分别选择单点上最可能的状态”是不同的。后者可以通过先运行前向-后向（和-积）算法求得潜在变量的边缘分布 $\gamma(\mathbf{z}_n)$ ，再对每个时间步分别取最大值来解 (Duda et al., 2001)。然而，这样得到的状态集合通常并不对应于整体最可能的状态序列。实际上，如果两个相邻时间步上各自单点最可能的状态之间的转移概率为 0，那么这一整组状态甚至可能对应于一个概率为 0 的序列。

在实践中，我们通常更关心最可能的状态序列，这可以用 max-sum 算法高效求解。在隐马尔可夫模型的语境下，该算法通常被称作 Viterbi 算法 (Viterbi, 1967)。注意，max-sum 算法是基于对数概率工作的，因此不需要像前向-后向算法那样使用重新缩放的变量。图 13.16 显示了展开为格状图后的隐马尔可夫模型片段。正如我们已经指出的，格状图中可能路径的数量会随链的长度指数式增长。Viterbi 算法则在这一路径空间中高效搜索出最可能的那一条路径，其计算代价仅随链长线性增长。

图 13.16 HMM 格状图的一个片段，展示了两条可能的路径。Viterbi 算法能够在指数数量的可能性中高效地确定最可能的路径。对于任意给定的一条路径，其对应的概率由转移矩阵 A_{jk} 的各个元素的乘积给出，这些元素对应于路径中每一段的转移概率 $p(z_{n+1} | z_n)$ ，同时还包括与路径上每个节点相关联的发射密度 $p(x_n | k)$ 。



与和-积算法类似，我们首先把隐马尔可夫模型表示为因子图，如图 13.15 所示。仍然把变量结点 $\mathbf{z}_N$ 视为根结点，并从叶结点开始向根结点传递消息。由 (8.93) 与 (8.94) 可以看出，max-sum 算法中传递的消息为

$$\mu_{\mathbf{z}_n \rightarrow f_{n+1}}(\mathbf{z}_n) = \mu_{f_n \rightarrow \mathbf{z}_n}(\mathbf{z}_n), \quad (13.66)$$

$$\mu_{f_{n+1} \rightarrow \mathbf{z}_{n+1}}(\mathbf{z}_{n+1}) = \max_{\mathbf{z}_n} \{ \ln f_{n+1}(\mathbf{z}_n, \mathbf{z}_{n+1}) + \mu_{\mathbf{z}_n \rightarrow f_{n+1}}(\mathbf{z}_n) \}. \quad (13.67)$$

如果消去这两个方程中的 $\mu_{\mathbf{z}_n \rightarrow f_{n+1}}(\mathbf{z}_n)$, 并利用 (13.46), 我们就得到关于 $f \rightarrow \mathbf{z}$ 消息的递推式:

$$\omega(\mathbf{z}_{n+1}) = \ln p(\mathbf{x}_{n+1} | \mathbf{z}_{n+1}) + \max_{\mathbf{z}_n} \{ \ln p(\mathbf{z}_{n+1} | \mathbf{z}_n) + \ln p(\mathbf{x}_n | \mathbf{z}_n) + \omega(\mathbf{z}_n) \}, \quad (13.68)$$

其中我们引入了记号 $\omega(\mathbf{z}_n) \equiv \mu_{f_n \rightarrow \mathbf{z}_n}(\mathbf{z}_n)$ 。

根据 (8.95) 与 (8.96), 这些消息的初始化为

$$\omega(\mathbf{z}_1) = \ln p(\mathbf{z}_1) + \ln p(\mathbf{x}_1 | \mathbf{z}_1), \quad (13.69)$$

这里我们用了 (13.45)。为简化记号, 我们省略了对模型参数 θ 的显式依赖; 在寻找最可能状态序列时, 这些参数是固定不变的。

Viterbi 算法也可以直接从联合分布的定义式 (13.6) 出发, 通过对其取对数并交换“最大化”与“求和”的次序推导出来。不难看出, 量 $\omega(\mathbf{z}_n)$ 有如下概率意义:

$$\omega(\mathbf{z}_n) = \max_{\mathbf{z}_1, \dots, \mathbf{z}_{n-1}} \ln p(\mathbf{x}_1, \dots, \mathbf{x}_n, \mathbf{z}_1, \dots, \mathbf{z}_n). \quad (13.70)$$

一旦完成了对 $\mathbf{z}_N$ 的最终最大化, 就得到了对应于最可能路径的联合分布 $p(\mathbf{X}, \mathbf{Z})$ 的数值。同时我们还希望得到这一路径对应的潜在变量取值序列。为此, 可以使用第 8.4.5 节中讨论的回溯 (back-tracking) 过程。具体来说, 注意对每一个可能的 $\mathbf{z}_{n+1}$, 都需要对 $\mathbf{z}_n$ 进行一遍“最大化”。如果我们为每个 $\mathbf{z}_{n+1}$ 的 K 个可能取值, 记录下使上述最大值成立的 $\mathbf{z}_n$ 的取值, 就可以把这些记录合成为一个函数 $\psi(k_n)$, 其中 $k \in \{1, \dots, K\}$ 。当我们完成了沿链的消息传递, 从而找到了最可能的终端状态 z_N 之后, 就可以利用这个函数按如下递推式回溯:

$$k_n^{\max} = \psi(k_{n+1}^{\max}). \quad (13.71)$$

从直观上理解 Viterbi 算法如下。一个朴素的方法是显式枚举格状图中的所有指数多个路径, 对每条路径计算其概率, 然后选出概率最大的那一条。然而, 我们可以大大节省计算代价。假设对于每一条路径, 我们在沿着路径向前推进时, 将转移概率和发射概率不断相乘, 并以此得到路径的概率。考虑某个具体时间步 n 和该时间步的某个具体状态 k 。会有许多条路径在格状图中汇聚到这个结点。然而, 我们只需要保留其中“到目前为止概率最大”的那条路径。因为在时间步 n 有 K 个状态, 所以我们只需要跟踪 K 条这样的路径。在时间步 $n+1$, 可能路径数为 K^2 , 因为从当前的每一个状态有 K 条可能的转移, 但我们仍然只需要保留 K 条路径, 即在时间步 $n+1$ 对每个状态保留其中概率最大的一条。当到达最后一步 N 时, 我们就可以知道哪一个状态对应于整体上的最可能的路径。由于对应这一状态的前驱是唯一的, 我们可以回溯到 $N-1$ 步查看当时的状态, 以此类推, 最终回溯到 $n=1$ 的初始状态。

13.2.6 隐马尔可夫模型的扩展

基本的隐马尔可夫模型及其基于最大似然的标准训练算法, 已经在众多方面得到了扩展, 以适应具体应用的需求。这里我们仅讨论其中几个较为重要的例子。

从图 13.11 的数字示例中可以看到，作为数据的生成模型，隐马尔可夫模型的效果可能相当有限，因为很多合成出来的数字看起来与训练数据并不相似。如果目标是序列分类，那么利用判别式方法而非最大似然来确定隐马尔可夫模型的参数，可能会带来显著收益。设我们有一个训练集，由 R 条观测序列 $\mathbf{X}_r$ 组成，其中 $r = 1, \dots, R$ ，每条序列都按照其类别 m 进行了标注， $m = 1, \dots, M$ 。对每个类别，我们采用一个单独的隐马尔可夫模型及其参数 θ_m ，并将参数估计问题视为一个标准的分类问题，在其中我们优化交叉熵：

$$\sum_{r=1}^R \ln p(m_r | \mathbf{X}_r). \quad (13.72)$$

利用贝叶斯定理，这一目标可以用与隐马尔可夫模型相关的序列概率来重写为

$$\sum_{r=1}^R \ln \left\{ \frac{p(\mathbf{X}_r | \theta_{m_r}) p(m_r)}{\sum_{l=1}^M p(\mathbf{X}_r | \theta_l) p(l)} \right\}, \quad (13.73)$$

其中 $p(m)$ 是类别 m 的先验概率。与最大似然相比，优化这一代价函数要复杂得多 (Kapadia, 1998)，尤其在于需要把每一条训练序列分别代入每一个模型中进行评估，以便计算 (13.73) 中的分母。隐马尔可夫模型与判别式训练方法相结合，在语音识别中得到了广泛应用 (Kapadia, 1998)。

隐马尔可夫模型的一个重要弱点在于它对系统停留在某个状态时长的分布的刻画方式。要理解这一问题，注意从给定的隐马尔可夫模型中采样得到的一个状态序列，其在状态 k 上恰好停留 T 个时间步，然后转移到不同状态的概率为


$$p(T) = (A_{kk})^T (1 - A_{kk}) \propto \exp(-T \ln A_{kk}), \quad (13.74)$$

因此是关于 T 的指数衰减函数。对许多应用而言，这种状态持续时间模型非常不现实。我们可以通过直接对状态持续时间建模来解决这一问题：将所有对角元素 A_{kk} 设为 0，并为每个状态 k 显式引入一个关于持续时间 T 的概率分布 $p(T | k)$ 。从生成的角度看，当进入状态 k 时，从 $p(T | k)$ 中抽取一个 T ，表示系统将停留在该状态的时间步数。然后模型生成 T 个观测值 $\mathbf{x}_t$ ，通常假设这些观测条件独立，于是对应的发射密度为 $\prod_{t=1}^T p(\mathbf{x}_t | k)$ 。这种方法需要对 EM 优化过程做一些直接的修改 (Rabiner, 1989)。

标准 HMM 的另一个局限是难以捕捉观测变量之间的长程相关性（即跨越多个时间步的相关性），因为这些相关性只能通过一阶马尔可夫链上的隐藏状态来传递。原则上可以通过在图 13.5 的图模型上增添额外的边来引入更长距离的依赖。解决这一问题的一种办法是将 HMM 推广为自回归隐马尔可夫模型 (autoregressive HMM, Ephraim et al., 1989)，其一个例子如图 13.17 所示。对离散观测而言，这相当于扩展发射分布的条件概率表。在高斯发射密度的情形中，我们可以采用线性-高斯框架：给定前若干观测值与 $\mathbf{z}_n$ 的取值， $\mathbf{x}_n$ 的条件分布为一个高斯，其均值是各条件变量的线性组合。显然，为避免参数个数过多，图中额外边的数量必须受到限制。在图 13.17 所示的例子中，每个观测除了依赖于隐藏状态外，还依赖于它之前的两个观测。

尽管这样的图看上去较为复杂，但利用 d-分离可以发现其概率结构仍然很简单。特别是，如果我们设想对 $\mathbf{z}_n$ 条件化，那么与标准 HMM 一样， $\mathbf{z}_{n-1}$ 与 $\mathbf{z}_{n+1}$ 是相互独立的，


图 13.17 自回归隐马尔可夫模型的一个片段，其中观测 $\mathbf{x}_n$ 的分布不仅依赖于隐藏状态 $\mathbf{z}_n$ ，还依赖于先前观测的一个子集。在该示例中， $\mathbf{x}_n$ 的分布依赖于前两个观测 $\mathbf{x}_{n-1}$ 和 $\mathbf{x}_{n-2}$ 。



这对应于条件独立性质 (13.5)。这一点可以通过以下事实来验证：从结点 $\mathbf{z}_{n-1}$ 至 $\mathbf{z}_{n+1}$ 的每条路径都至少经过一个观测结点，且该观测结点对于该路径而言是“尾-尾”结构。结果，我们仍可以在 EM 算法的 E 步中使用前向-后向递推来求得潜在变量的后验分布，其计算时间随链长线性增长。类似地，M 步只是对标准的 M 步方程做些轻微修改。在高斯发射密度的情形下，这就演变为使用第 3 章讨论过的标准线性回归公式来估计参数。

我们已经看到，将 HMM 视为图模型时，自回归 HMM 会自然地出现为标准 HMM 的一种扩展。而实际上，从概率图模型的视角出发，可以构建出大量基于 HMM 的图结构。例如输入-输出隐马尔可夫模型 (input-output HMM, Bengio and Frasconi, 1995)，除了输出变量 $\mathbf{x}_1, \dots, \mathbf{x}_N$ 外，还包含一系列观测变量 $\mathbf{u}_1, \dots, \mathbf{u}_N$ ，这些变量会影响潜在变量、输出变量，或二者皆影响。一个示例图如图 13.18 所示。这将 HMM 框架扩展到了针对序列数据的监督学习情景。利用 d-分离准则可以轻松证明，此时潜在变量链仍然满足马尔可夫性质 (13.5)。验证方法很简单：从结点 $\mathbf{z}_{n-1}$ 到结点 $\mathbf{z}_{n+1}$ 只有一条路径，并且对于观测结点 $\mathbf{z}_n$ 来说，该路径为“尾-尾”结构。因此这个条件独立性质仍然成立，从而再次确保可构造一个计算高效的学习算法。具体而言，我们可以通过最大化似然函数 $L(\theta) = p(\mathbf{X} | \mathbf{U}, \theta)$ 来估计模型参数 θ ，其中 $\mathbf{U}$ 是一个矩阵，其第 n 行为 $\mathbf{u}_n^T$ 。正是由于条件独立性质 (13.5)，该似然函数可以用 EM 算法高效地最大化，其 E 步涉及前向与后向递推。


图 13.18 输入-输出隐马尔可夫模型的一个示例。在这种情况下，发射概率和转移概率都依赖于一系列观测 $\mathbf{u}_1, \dots, \mathbf{u}_N$ 的取值。



另一个值得一提的 HMM 变体是分解隐马尔可夫模型 (factorial HMM, Ghahramani and Jordan, 1997)。在该模型中，存在多个彼此独立的潜在马尔可夫链，而每个时间步上的观测变量的分布则同时依赖于该时间步上所有潜在变量的状态。对应的图模型如图 13.19 所示。考虑分解 HMM 的动机时，可以注意到：如果我们希望在某一时间步上


表示大约 10 比特的信息，那么标准 HMM 需要 $K = 2^{10} = 1024$ 个潜在状态，而分解 HMM 则可以使用 10 条二值潜在链来实现。

图 13.19 一个因子化隐马尔可夫模型，由两条潜在变量的马尔可夫链组成。对于连续观测变量 $\mathbf{x}$ ，一种可能的发射模型选择是线性—高斯分布，其中高斯分布的均值是相应潜在变量状态的线性组合。



然而，分解 HMM 的主要缺点在于训练时的额外复杂度。 M 步本身相对简单，但对 $\mathbf{x}$ 的观测会在各条潜在链之间引入依赖，从而使 E 步变得困难。这一点可以通过观察图 13.19 来看出：变量 $z_n^{(1)}$ 与 $z_n^{(2)}$ 之间存在一条经由 x_n 的路径，并且在 x_n 结点处是“头-头”结构，因此它们并不 d -分离。因而，该模型的精确 E 步不再能通过沿着 M 条马尔可夫链分别独立地运行前向-后向递推来完成。这一点也可通过观察：分解 HMM 中单条马尔可夫链并不满足关键的条件独立性质 (13.5)，如图 13.20 所示的 d -分离分析所揭示。

图 13.20 一条路径示例（以绿色高亮显示），在观测节点 x_{n-1} 和 x_{n+1} 处为头对头结构，而在未观测节点 $z_{n-1}^{(2)}$ 、 $z_n^{(2)}$ 和 $z_{n+1}^{(2)}$ 处为头对尾结构。因此，该路径未被阻断，条件独立性性质 (13.5) 对因子化 HMM 模型中的各个单独潜在变量链并不成立。其结果是，该模型不存在高效的精确 E 步。



设有 M 条隐藏链，且为简单起见假定所有潜在变量都有同样的 K 个状态。一种方法是注意到在某一时间步上，总共有 K^M 种潜在变量组合，于是我们可以把该模型等价地转化为一个标准 HMM：其隐变量为单条链，但每个时间步上的状态数为 K^M 。这时 E 步中可以运行标准的前向-后向递推。这样做的计算代价为 $O(NK^{2M})$ ，随着潜在链条数 M 指数式增长，因此除了在非常小的 M 情况下，一般是难以接受的。

一种解决办法是使用采样方法（第 11 章中讨论）。作为优雅的确定性替代方案，Ghahramani 和 Jordan（1997）利用变分推断技术，为近似推断提出了一种可处理的算法。可以使用一个对所有潜在变量完全因子的简单变分后验分布，或者采用更强大的方法：令变分分布本身由若干独立马尔可夫链组成，对应原模型中的隐藏链。在后者情形中，变分推断算法需要沿每个链独立地运行前向与后向递推，计算上十分高效，同时又

能够捕捉同一条链内变量之间的相关性。

显然，可以根据具体应用的需求构建出多种多样的概率结构。图模型为我们提供了一种统一的方法来构思、描述和分析这些结构，而变分方法则为在那些精确求解不可行的模型中进行推断提供了强有力的框架。

13.3 线性动态系统

为了引出线性动态系统的概念，我们先来看一个在实际中经常出现的简单问题。假设我们希望用一个含噪传感器来测量某个未知量 z ，该传感器返回的观测 x 等于 z 加上零均值高斯噪声。对单次测量而言，我们对 z 的最佳估计就是假设 $z = x$ 。不过，如果我们进行多次测量并对这些测量求平均，就可以改进对 z 的估计，因为随机噪声项会相互抵消。

现在让我们使问题稍微复杂一点，假设我们希望测量的是一个随时间变化的量 z 。我们对 $\mathbf{x}$ 做定期测量，于是在某个时间点，我们已经获得了 $\mathbf{x}_1, \dots, \mathbf{x}_N$ ，并希望求出对应的取值 $\mathbf{z}_1, \dots, \mathbf{z}_N$ 。如果我们简单地对所有测量求平均，虽然由随机噪声造成的误差会减小，但我们只会得到一个单一的平均估计，其中把原本随时间变化的 z 也一并平均掉，从而引入了新的误差来源。

从直觉上看，我们可以稍微改进如下：为了估计 $\mathbf{z}_N$ ，我们只取最近的若干次测量，比如 $\mathbf{x}_{N-L}, \dots, \mathbf{x}_N$ ，然后仅对这些求平均。如果 z 的变化较慢，而传感器中的随机噪声水平较高，那么取一个较长的观测窗口来平均是合理的。相反，如果信号变化很快，而噪声较小，那么最好可能是直接使用 $\mathbf{x}_N$ 作为对 $\mathbf{z}_N$ 的估计。也许，如果采用加权平均、并让近期观测比较早观测贡献更大，我们还能进一步改进估计。

虽然这类直观论证听起来有道理，但并没有告诉我们如何构造加权平均，任何“手工设计”的权重方案都很难是最优的。幸运的是，我们可以通过构建一个刻画时间演化与测量过程的概率模型，再应用前几章发展出的推断与学习方法，更系统地解决这类问题。在这里，我们将集中讨论一种应用广泛的模型——线性动态系统（linear dynamical system, LDS）。

正如前面所见，HMM 对应于图 13.5 所示的状态空间模型，其中潜在变量是离散的，而发射分布则可以任意选择。当然，该图本身描述的是一个更广泛的概率分布类，它们都按式 (13.6) 的方式因子化。现在我们考虑对潜在变量的分布作进一步扩展。特别地，我们将考虑连续潜在变量，此时和-积算法中的求和将变为积分。然而，推断算法的一般形式将与隐马尔可夫模型完全相同。有趣的是，从历史上看，隐马尔可夫模型与线性动态系统是各自独立发展起来的，但一旦把它们统一表述为图模型，两者之间的深刻联系就一目了然。

一个关键要求是：我们要保持推断算法的高效性，使其计算量在链长上是线性的。这要求例如，当我们取 $\hat{\alpha}(\mathbf{z}_{n-1})$ （表示给定观测 $\mathbf{x}_1, \dots, \mathbf{x}_n$ 时 $\mathbf{z}_{n-1}$ 的后验分布），并乘以转移概率 $p(\mathbf{z}_n | \mathbf{z}_{n-1})$ 与发射概率 $p(\mathbf{x}_n | \mathbf{z}_n)$ ，然后对 $\mathbf{z}_{n-1}$ 积分之后，得到的关于 $\mathbf{z}_n$ 的分布，其函数形式应与 $\hat{\alpha}(\mathbf{z}_{n-1})$ 相同。也就是说，分布在每一步不能变得更复杂，只能改变参数值。并不意外，具有在乘法下封闭这一性质的分布类只有指数族。

在这里，我们考虑实际中最重要的一个例子，即高斯分布。更具体地，我们考虑线性-高斯状态空间模型，即潜在变量 $\{\mathbf{z}_n\}$ 以及观测变量 $\{\mathbf{x}_n\}$ 都服从多元高斯分布，并且它们的均值是其父结点状态的线性函数。我们已经看到，一张由线性-高斯单元构成的有向图等价于对所有变量的一个联合高斯分布。此外，诸如 $\hat{\alpha}(\mathbf{z}_n)$ 这样的边缘分布也都是高斯的，因此消息的函数形式得以保持不变，我们就能得到一个高效的推断算法。与此相对，假设发射密度 $p(\mathbf{x}_n | \mathbf{z}_n)$ 是 K 个高斯分布的混合，每个分量的均值都是 $\mathbf{z}_n$ 的线性函数。那么即使 $\hat{\alpha}(\mathbf{z}_1)$ 是高斯分布， $\hat{\alpha}(\mathbf{z}_2)$ 也会变成 K 个高斯分布的混合， $\hat{\alpha}(\mathbf{z}_3)$ 则是 K^2 个高斯分布的混合，如此下去。这样一来，精确推断在实践中就不再有价值。

我们已经看到，可以把隐马尔可夫模型视为第 9 章混合模型的一种扩展，用以刻画数据中的序列相关性。类似地，线性动态系统也可以看作第 12 章连续潜在变量模型（如概率 PCA 与因子分析）的推广。每一对结点 $\{\mathbf{z}_n, \mathbf{x}_n\}$ 都代表了该观测点的一个线性-高斯潜在变量模型。然而，潜在变量 $\{\mathbf{z}_n\}$ 不再相互独立，而是构成了一条马尔可夫链。

由于该模型由一棵树状的有向图来表示，因此可以使用和-积算法高效地解决推断问题。与 HMM 中的 α 消息对应的前向递推在这里称为卡尔曼滤波（Kalman filter）方程（Kalman, 1960; Zarchan and Musoff, 2005）；与 β 消息对应的后向递推则称为卡尔曼平滑（Kalman smoother）方程，或 Rauch-Tung-Striebel (RTS) 方程（Rauch et al., 1965）。卡尔曼滤波在许多实时跟踪应用中都有广泛使用。

由于线性动态系统是一个线性-高斯模型，对所有变量的联合分布以及所有边缘分布和条件分布都是高斯分布。因此，可以推知：逐点最可能的潜在变量值序列与整体最可能的潜在状态序列是相同的。于是就不需要像 HMM 那样考虑 Viterbi 算法的类比形式。

由于该模型具有线性-高斯条件分布，我们可以把转移分布和发射分布写成一般形式：

$$p(\mathbf{z}_n | \mathbf{z}_{n-1}) = \mathcal{N}(\mathbf{z}_n | \mathbf{A}\mathbf{z}_{n-1}, \Gamma), \quad (13.75)$$

$$p(\mathbf{x}_n | \mathbf{z}_n) = \mathcal{N}(\mathbf{x}_n | \mathbf{C}\mathbf{z}_n, \Sigma). \quad (13.76)$$

初始潜在变量也服从高斯分布，我们写为

$$p(\mathbf{z}_1) = \mathcal{N}(\mathbf{z}_1 | \mu_0, \mathbf{V}_0). \quad (13.77)$$

为简化记号，我们从高斯均值中省略了加性常数项；事实上，如有需要，加入这些常数项是很容易的。传统上，这些分布更常用等价的噪声线性方程形式表示为

$$\mathbf{z}_n = \mathbf{A}\mathbf{z}_{n-1} + \mathbf{w}_n, \quad (13.78)$$

$$\mathbf{x}_n = \mathbf{C}\mathbf{z}_n + \mathbf{v}_n, \quad (13.79)$$

$$\mathbf{z}_1 = \mu_0 + \mathbf{u}, \quad (13.80)$$

其中噪声项的分布为

$$\mathbf{w} \sim \mathcal{N}(\mathbf{w} \mid 0, \Gamma), \quad (13.81)$$

$$\mathbf{v} \sim \mathcal{N}(\mathbf{v} \mid 0, \Sigma), \quad (13.82)$$

$$\mathbf{u} \sim \mathcal{N}(\mathbf{u} \mid 0, \mathbf{V}_0). \quad (13.83)$$

模型的参数记为 $\theta = \{\mathbf{A}, \Gamma, \mathbf{C}, \Sigma, \mu_0, \mathbf{V}_0\}$ ，可以通过 EM 算法下的最大似然估计来确定。在 E 步中，我们需要解决对潜在变量局部后验边缘分布的推断问题，这可以利用和-积算法高效完成，我们将在下一节对此进行讨论。

13.3.1 线性动态系统中的推断

现在我们转向这样一个问题：在给定观测序列的条件下，求潜在变量的边缘分布。对给定的参数设置，我们还希望在实时应用中，根据已有观测 $\mathbf{x}_1, \dots, \mathbf{x}_{n-1}$ 来预测下一个潜在状态 $\mathbf{z}_n$ 以及下一个观测 $\mathbf{x}_n$ 。这些推断问题都可以通过和-积算法高效求解，而在线性动态系统的背景下，这就产生了卡尔曼滤波和卡尔曼平滑方程。

需要强调的是，由于线性动态系统是线性-高斯模型，所有潜在变量与观测变量的联合分布都是一个高斯分布，因此从原理上讲，我们完全可以使用前几章推导出的多元高斯分布边缘与条件的标准结果来解决推断问题。和-积算法在这里的作用，是为这些计算提供一种更高效的实现方法。

线性动态系统的因子化形式与隐马尔可夫模型完全相同，均由式 (13.6) 给出，相应的因子图也就是图 13.14 与图 13.15。因此，推断算法的形式也完全一致，只是将对潜在变量的求和改为积分。我们先考虑前向方程，将 $\mathbf{z}_N$ 视作根结点，并从叶结点 $h(\mathbf{z}_1)$ 向根结点传递消息。由 (13.77) 可知，初始消息是高斯分布，并且由于每个因子都是高斯分布，因此所有后续消息都将是高斯分布。按照惯例，我们传递的是归一化的边缘分布，对应于 $p(\mathbf{z}_n \mid \mathbf{x}_1, \dots, \mathbf{x}_n)$ ，记为

$$\hat{\alpha}(\mathbf{z}_n) = \mathcal{N}(\mathbf{z}_n \mid \mu_n, \mathbf{V}_n). \quad (13.84)$$

这与离散情形下 HMM 中的缩放变量 $\hat{\alpha}(\mathbf{z}_n)$ （式 (13.59)）完全类似，因此递推方程现在变为

$$c_n \hat{\alpha}(\mathbf{z}_n) = p(\mathbf{x}_n \mid \mathbf{z}_n) \int \hat{\alpha}(\mathbf{z}_{n-1}) p(\mathbf{z}_n \mid \mathbf{z}_{n-1}) d\mathbf{z}_{n-1}. \quad (13.85)$$

将 (13.75) 与 (13.76) 中的 $p(\mathbf{z}_n \mid \mathbf{z}_{n-1})$ 和 $p(\mathbf{x}_n \mid \mathbf{z}_n)$ 代入，并利用 (13.84)，式 (13.85) 就变为

$$c_n \mathcal{N}(\mathbf{z}_n \mid \mu_n, \mathbf{V}_n) = \mathcal{N}(\mathbf{x}_n \mid \mathbf{C}\mathbf{z}_n, \Sigma) \int \mathcal{N}(\mathbf{z}_n \mid \mathbf{A}\mathbf{z}_{n-1}, \Gamma) \mathcal{N}(\mathbf{z}_{n-1} \mid \mu_{n-1}, \mathbf{V}_{n-1}) d\mathbf{z}_{n-1}. \quad (13.86)$$

在此我们假设 μ_{n-1} 与 $\mathbf{V}_{n-1}$ 已知，希望通过计算 (13.86) 中的积分来确定 μ_n 与 $\mathbf{V}_n$ 。

利用结果 (2.115)，该积分可以直接求出：

$$\int \mathcal{N}(\mathbf{z}_n | \mathbf{A}\mathbf{z}_{n-1}, \Gamma) \mathcal{N}(\mathbf{z}_{n-1} | \mu_{n-1}, \mathbf{V}_{n-1}) d\mathbf{z}_{n-1} = \mathcal{N}(\mathbf{z}_n | \mathbf{A}\mu_{n-1}, \mathbf{P}_{n-1}), \quad (13.87)$$

其中我们定义

$$\mathbf{P}_{n-1} = \mathbf{A}\mathbf{V}_{n-1}\mathbf{A}^T + \Gamma. \quad (13.88)$$

然后，我们可以利用 (2.115) 与 (2.116) 把这一结果与 (13.86) 右端的第一个因子相结合，得到

$$\mu_n = \mathbf{A}\mu_{n-1} + \mathbf{K}_n(\mathbf{x}_n - \mathbf{C}\mathbf{A}\mu_{n-1}), \quad (13.89)$$

$$\mathbf{V}_n = (\mathbf{I} - \mathbf{K}_n\mathbf{C})\mathbf{P}_{n-1}, \quad (13.90)$$

$$c_n = \mathcal{N}(\mathbf{x}_n | \mathbf{C}\mathbf{A}\mu_{n-1}, \mathbf{C}\mathbf{P}_{n-1}\mathbf{C}^T + \Sigma), \quad (13.91)$$

其中我们使用了矩阵逆的恒等式 (C.5) 与 (C.7)，并定义了卡尔曼增益 (Kalman gain) 矩阵：

$$\mathbf{K}_n = \mathbf{P}_{n-1}\mathbf{C}^T(\mathbf{C}\mathbf{P}_{n-1}\mathbf{C}^T + \Sigma)^{-1}. \quad (13.92)$$

因此，只要给定 μ_{n-1} 与 $\mathbf{V}_{n-1}$ ，加上新的观测 $\mathbf{x}_n$ ，我们就可以计算出潜在变量 $\mathbf{z}_n$ 的高斯边缘分布，其均值为 μ_n 、协方差为 $\mathbf{V}_n$ ，以及归一化系数 c_n 。

这些递推方程的初始条件由下式给出：

$$c_1 \hat{\alpha}(\mathbf{z}_1) = p(\mathbf{z}_1)p(\mathbf{x}_1 | \mathbf{z}_1). \quad (13.93)$$

由于 $p(\mathbf{z}_1)$ 由 (13.77) 给出，而 $p(\mathbf{x}_1 | \mathbf{z}_1)$ 由 (13.76) 给出，我们可以再次利用 (2.115) 来计算 c_1 ，利用 (2.116) 来计算 μ_1 与 $\mathbf{V}_1$ ，得到

$$\mu_1 = \mu_0 + \mathbf{K}_1(\mathbf{x}_1 - \mathbf{C}\mu_0), \quad (13.94)$$

$$\mathbf{V}_1 = (\mathbf{I} - \mathbf{K}_1\mathbf{C})\mathbf{V}_0, \quad (13.95)$$

$$c_1 = \mathcal{N}(\mathbf{x}_1 | \mathbf{C}\mu_0, \mathbf{C}\mathbf{V}_0\mathbf{C}^T + \Sigma), \quad (13.96)$$

其中

$$\mathbf{K}_1 = \mathbf{V}_0\mathbf{C}^T(\mathbf{C}\mathbf{V}_0\mathbf{C}^T + \Sigma)^{-1}. \quad (13.97)$$

同样，线性动态系统的似然函数由式 (13.63) 给出，其中各个 c_n 项由卡尔曼滤波方程确定。

我们可以对从节点 $\mathbf{z}_{n-1}$ 的后验边缘分布到节点 $\mathbf{z}_n$ 的后验边缘分布这一过程的步骤做如下解释。在 (13.89) 中，我们可以把 $\mathbf{A}\mu_{n-1}$ 看作对 $\mathbf{z}_n$ 的均值预测，它是基于 $\mathbf{z}_{n-1}$ 的均值，并通过转移概率矩阵 $\mathbf{A}$ 向前推进一步所得。该预测均值又给出了对 $\mathbf{x}_n$ 的预测值 $\mathbf{C}\mathbf{A}\mu_{n-1}$ ，这是把发射概率矩阵 $\mathbf{C}$ 作用在预测的隐状态均值上的结果。我们可以把 (13.89) 中隐变量均值的更新方程理解为：先取预测均值 $\mathbf{A}\mu_{n-1}$ ，再加上一个修正项，该修正项与“预测观测”与“实际观测”之间的误差 $\mathbf{x}_n - \mathbf{C}\mathbf{A}\mu_{n-1}$ 成正比。这个修正的系





图 13.21 线性动力系统可以看作是一系列步骤：由于扩散导致状态变量不确定性不断增加，而这一不确定性通过新数据的到来得到补偿。在左侧图中，蓝色曲线表示分布 $p(z_{n-1} | x_1, \dots, x_{n-1})$ ，它包含了直到第 $n-1$ 步为止的所有数据。由于转移概率 $p(z_n | z_{n-1})$ 具有非零方差而产生的扩散，得到分布 $p(z_n | x_1, \dots, x_{n-1})$ ，在中间图中用红色表示。注意，与蓝色曲线相比，该分布更加宽广并且发生了平移（蓝色曲线以虚线形式在中间图中给出以便比较）。接下来的数据观测 x_n 通过发射密度 $p(x_n | z_n)$ 产生作用，该密度在右侧图中以 z_n 的函数形式用绿色表示。注意，这并不是关于 z_n 的概率密度，因此并未归一化为 1。将这一新的数据点纳入后，得到状态分布的修正形式 $p(z_n | x_1, \dots, x_n)$ ，以蓝色显示。可以看到，与 $p(z_n | x_1, \dots, x_{n-1})$ （在右侧图中以虚线表示以作比较）相比，观测数据使该分布发生了平移并变得更加狭窄。

数就是卡尔曼增益矩阵。因此，可以将卡尔曼滤波看作一种不断进行预测并根据新观测修正预测的过程，如图 13.21 所示。

如果我们考虑一种情形：测量噪声相对于潜在变量演化速率来说很小，那么会发现关于 z_n 的后验分布几乎只依赖于当前测量 x_n ，这与本节开头简单例子中得到的直观结论相一致。类似地，如果潜在变量的演化相对于观测噪声水平很慢，那么对 z_n 的后验均值就近似等于截至该时刻所有观测的平均值。

卡尔曼滤波最重要的应用之一在于目标跟踪，这在图 13.22 所示的二维运动目标简单例子中得到了说明。

图 13.22 线性动力系统用于跟踪运动物体的示意图。蓝色点表示物体在二维空间中连续时间步上的真实位置，绿色点表示位置的含噪观测值，红色叉号表示通过运行卡尔曼滤波方程得到的位置后验分布的均值。推断得到的位置协方差由红色椭圆表示，这些椭圆对应于一个标准差的等值轮廓。



到目前为止，我们已经解决了这样的推断问题：在给定从 x_1 到 x_n 的观测的条件下，求某个结点 z_n 的后验边缘分布。接下来，我们要解决在给定所有观测 x_1 到 x_N 的条件下，求结点 z_n 的边缘分布的问题。对时间数据而言，这相当于同时利用过去和未来的观测。虽然这不能用来进行实时预测，但在学习模型参数时起着关键作用。与 HMM 完

全类似，这个问题可以通过从结点 $\mathbf{x}_N$ 向结点 $\mathbf{x}_1$ 反向传播消息，并将其与前向消息传递阶段（该阶段计算了各个 $\hat{\alpha}(\mathbf{z}_n)$ ）所获得的信息结合起来解决。

在 LDS 文献中，通常用 $\gamma(\mathbf{z}_n) = \hat{\alpha}(\mathbf{z}_n)\hat{\beta}(\mathbf{z}_n)$ 而不是 $\hat{\beta}(\mathbf{z}_n)$ 来表示后向递推。由于 $\gamma(\mathbf{z}_n)$ 也必须是高斯分布，我们将其写为

$$\gamma(\mathbf{z}_n) = \hat{\alpha}(\mathbf{z}_n)\hat{\beta}(\mathbf{z}_n) = \mathcal{N}(\mathbf{z}_n | \hat{\mu}_n, \hat{\mathbf{V}}_n). \quad (13.98)$$

为了推导所需的递推式，我们从 $\hat{\beta}(\mathbf{z}_n)$ 的后向递推式 (13.62) 出发，在连续潜在变量情形下可写为

$$c_{n+1}\hat{\beta}(\mathbf{z}_n) = \int \hat{\beta}(\mathbf{z}_{n+1})p(\mathbf{x}_{n+1} | \mathbf{z}_{n+1})p(\mathbf{z}_{n+1} | \mathbf{z}_n)d\mathbf{z}_{n+1}. \quad (13.99)$$

现在我们把 (13.99) 两边都乘以 $\hat{\alpha}(\mathbf{z}_n)$ ，并利用 (13.75) 与 (13.76) 替换 $p(\mathbf{x}_{n+1} | \mathbf{z}_{n+1})$ 和 $p(\mathbf{z}_{n+1} | \mathbf{z}_n)$ 。然后结合 (13.89)、(13.90) 与 (13.91) 以及 (13.98)，经过一些推导，可以得到

$$\hat{\mu}_n = \mu_n + \mathbf{J}_n(\hat{\mu}_{n+1} - \mathbf{A}\mu_n), \quad (13.100)$$

$$\hat{\mathbf{V}}_n = \mathbf{V}_n + \mathbf{J}_n(\hat{\mathbf{V}}_{n+1} - \mathbf{P}_n)\mathbf{J}_n^T, \quad (13.101)$$

其中我们定义

$$\mathbf{J}_n = \mathbf{V}_n\mathbf{A}^T(\mathbf{P}_n)^{-1}, \quad (13.102)$$

并使用了 $\mathbf{A}\mathbf{V}_n = \mathbf{P}_n\mathbf{J}_n^T$ 这一关系。需要注意的是，这些递推要求先完成前向遍历，以便在后向遍历时能够使用 μ_n 与 $\mathbf{V}_n$ 的值。

在 EM 算法中，我们还需要成对的后验边缘分布，它们可以由式 (13.65) 推出：

$$\begin{aligned} \xi(\mathbf{z}_{n-1}, \mathbf{z}_n) &= (c_n)^{-1}\hat{\alpha}(\mathbf{z}_{n-1})p(\mathbf{x}_n | \mathbf{z}_n)p(\mathbf{z}_n | \mathbf{z}_{n-1})\hat{\beta}(\mathbf{z}_n) \\ &= \frac{\mathcal{N}(\mathbf{z}_{n-1} | \mu_{n-1}, \mathbf{V}_{n-1})\mathcal{N}(\mathbf{z}_n | \mathbf{A}\mathbf{z}_{n-1}, \Gamma)\mathcal{N}(\mathbf{x}_n | \mathbf{C}\mathbf{z}_n, \Sigma)\mathcal{N}(\mathbf{z}_n | \hat{\mu}_n, \hat{\mathbf{V}}_n)}{c_n\hat{\alpha}(\mathbf{z}_n)}. \end{aligned} \quad (13.103)$$

用 (13.84) 中对 $\hat{\alpha}(\mathbf{z}_n)$ 的表达式替换之，并整理后不难发现， $\xi(\mathbf{z}_{n-1}, \mathbf{z}_n)$ 是一个高斯分布，其均值由 $\gamma(\mathbf{z}_{n-1})$ 和 $\gamma(\mathbf{z}_n)$ 的分量给出，而 $\mathbf{z}_n$ 与 $\mathbf{z}_{n-1}$ 之间的协方差则为

$$\text{cov}[\mathbf{z}_n, \mathbf{z}_{n-1}] = \mathbf{J}_{n-1}\hat{\mathbf{V}}_n. \quad (13.104)$$

13.3.2 线性动态系统中的学习

到目前为止，我们在讨论线性动态系统的推断问题时，都假设模型参数 $\boldsymbol{\theta} = \{\mathbf{A}, \Gamma, \mathbf{C}, \Sigma, \mu_0, \mathbf{V}_0\}$ 已知。接下来，我们考虑如何使用最大似然来确定这些参数（Ghahramani and Hinton, 1996b）。由于模型中包含潜在变量，这个问题可以用第 9 章中已一般性讨论过的 EM 算法来解决。

我们可以如下推导线性动态系统的 EM 算法。设算法在某一轮迭代中参数估计值为 $\boldsymbol{\theta}^{\text{old}}$ 。对于这组参数值，我们可以运行推断算法，求出潜在变量的后验分布 $p(\mathbf{Z} | \mathbf{X}, \boldsymbol{\theta}^{\text{old}})$ ，

更准确地说，是求出 $\mathbf{M}$ 步中所需的那些局部后验边缘分布。特别地，我们将需要以下期望：

$$\mathbb{E}[\mathbf{z}_n] = \hat{\mu}_n, \quad (13.105)$$

$$\mathbb{E}[\mathbf{z}_n \mathbf{z}_{n-1}^T] = \mathbf{J}_{n-1} \hat{\mathbf{V}}_n + \hat{\mu}_n \hat{\mu}_{n-1}^T, \quad (13.106)$$

$$\mathbb{E}[\mathbf{z}_n \mathbf{z}_n^T] = \hat{\mathbf{V}}_n + \hat{\mu}_n \hat{\mu}_n^T, \quad (13.107)$$

这里我们使用了式 (13.104)。

现在我们考虑完全数据对数似然函数，它由式 (13.6) 取对数得到，因此为

$$\begin{aligned} \ln p(\mathbf{X}, \mathbf{Z} | \boldsymbol{\theta}) &= \ln p(\mathbf{z}_1 | \mu_0, \mathbf{V}_0) + \sum_{n=2}^N \ln p(\mathbf{z}_n | \mathbf{z}_{n-1}, \mathbf{A}, \Gamma) \\ &+ \sum_{n=1}^N \ln p(\mathbf{x}_n | \mathbf{z}_n, \mathbf{C}, \Sigma), \end{aligned} \quad (13.108)$$

其中我们已经将对参数的依赖显式写出。接着，我们对完全数据对数似然在后验分布 $p(\mathbf{Z} | \mathbf{X}, \boldsymbol{\theta}^{\text{old}})$ 下取期望，从而定义函数

$$Q(\boldsymbol{\theta}, \boldsymbol{\theta}^{\text{old}}) = \mathbb{E}_{\mathbf{Z} | \boldsymbol{\theta}^{\text{old}}} [\ln p(\mathbf{X}, \mathbf{Z} | \boldsymbol{\theta})]. \quad (13.109)$$

在 $\mathbf{M}$ 步中，我们对 $Q(\boldsymbol{\theta}, \boldsymbol{\theta}^{\text{old}})$ 关于 $\boldsymbol{\theta}$ 的各个分量进行最大化。

首先考虑参数 μ_0 和 $\mathbf{V}_0$ 。若将 (13.77) 中的 $p(\mathbf{z}_1 | \mu_0, \mathbf{V}_0)$ 代入 (13.108)，然后对 $\mathbf{Z}$ 取期望，得到

$$Q(\boldsymbol{\theta}, \boldsymbol{\theta}^{\text{old}}) = -\frac{1}{2} \ln |\mathbf{V}_0| - \mathbb{E}_{\mathbf{Z} | \boldsymbol{\theta}^{\text{old}}} \left[\frac{1}{2} (\mathbf{z}_1 - \mu_0)^T \mathbf{V}_0^{-1} (\mathbf{z}_1 - \mu_0) \right] + \text{const},$$

其中所有与 μ_0 或 $\mathbf{V}_0$ 无关的项都被吸收入加性常数中。利用第 2.3.4 节中关于高斯分布最大似然解的结论，可以方便地对 μ_0 和 $\mathbf{V}_0$ 做最大化，得到

$$\mu_0^{\text{new}} = \mathbb{E}[\mathbf{z}_1], \quad (13.110)$$

$$\mathbf{V}_0^{\text{new}} = \mathbb{E}[\mathbf{z}_1 \mathbf{z}_1^T] - \mathbb{E}[\mathbf{z}_1] \mathbb{E}[\mathbf{z}_1]^T. \quad (13.111)$$

类似地，为了优化 $\mathbf{A}$ 和 Γ ，将 (13.75) 中的 $p(\mathbf{z}_n | \mathbf{z}_{n-1}, \mathbf{A}, \Gamma)$ 代入 (13.108)，得到

$$\begin{aligned} Q(\boldsymbol{\theta}, \boldsymbol{\theta}^{\text{old}}) &= -\frac{N-1}{2} \ln |\Gamma| \\ &- \mathbb{E}_{\mathbf{Z} | \boldsymbol{\theta}^{\text{old}}} \left[\frac{1}{2} \sum_{n=2}^N (\mathbf{z}_n - \mathbf{A} \mathbf{z}_{n-1})^T \Gamma^{-1} (\mathbf{z}_n - \mathbf{A} \mathbf{z}_{n-1}) \right] + \text{const}, \end{aligned} \quad (13.112)$$

其中常数项包含所有与 $\mathbf{A}$ 和 Γ 无关的项。对这两个参数做最大化得到

$$\mathbf{A}^{\text{new}} = \left(\sum_{n=2}^N \mathbb{E}[\mathbf{z}_n \mathbf{z}_{n-1}^T] \right) \left(\sum_{n=2}^N \mathbb{E}[\mathbf{z}_{n-1} \mathbf{z}_{n-1}^T] \right)^{-1}, \quad (13.113)$$

$$\begin{aligned} \Gamma^{\text{new}} &= \frac{1}{N-1} \sum_{n=2}^N \left\{ \mathbb{E}[\mathbf{z}_n \mathbf{z}_n^T] - \mathbf{A}^{\text{new}} \mathbb{E}[\mathbf{z}_{n-1} \mathbf{z}_n^T] \right. \\ &\quad \left. - \mathbb{E}[\mathbf{z}_n \mathbf{z}_{n-1}^T] (\mathbf{A}^{\text{new}})^T + \mathbf{A}^{\text{new}} \mathbb{E}[\mathbf{z}_{n-1} \mathbf{z}_{n-1}^T] (\mathbf{A}^{\text{new}})^T \right\}. \end{aligned} \quad (13.114)$$

注意必须先计算 $\mathbf{A}^{\text{new}}$ ，再用此结果来求 Γ^{new} 。

最后，为了确定 $\mathbf{C}$ 和 Σ 的新值，我们将 (13.76) 中的 $p(\mathbf{x}_n | \mathbf{z}_n, \mathbf{C}, \Sigma)$ 代入 (13.108)，得到

$$Q(\boldsymbol{\theta}, \boldsymbol{\theta}^{\text{old}}) = -\frac{N}{2} \ln |\Sigma| - \mathbb{E}_{\mathbf{z}|\boldsymbol{\theta}^{\text{old}}} \left[\frac{1}{2} \sum_{n=1}^N (\mathbf{x}_n - \mathbf{C}\mathbf{z}_n)^T \Sigma^{-1} (\mathbf{x}_n - \mathbf{C}\mathbf{z}_n) \right] + \text{const.}$$

对 $\mathbf{C}$ 和 Σ 进行最大化可得

$$\mathbf{C}^{\text{new}} = \left(\sum_{n=1}^N \mathbf{x}_n \mathbb{E}[\mathbf{z}_n]^T \right) \left(\sum_{n=1}^N \mathbb{E}[\mathbf{z}_n \mathbf{z}_n^T] \right)^{-1}, \quad (13.115)$$

$$\Sigma^{\text{new}} = \frac{1}{N} \sum_{n=1}^N \left\{ \mathbf{x}_n \mathbf{x}_n^T - \mathbf{C}^{\text{new}} \mathbb{E}[\mathbf{z}_n] \mathbf{x}_n^T - \mathbf{x}_n \mathbb{E}[\mathbf{z}_n]^T (\mathbf{C}^{\text{new}})^T + \mathbf{C}^{\text{new}} \mathbb{E}[\mathbf{z}_n \mathbf{z}_n^T] (\mathbf{C}^{\text{new}})^T \right\}. \quad (13.116)$$

我们已经用最大似然的方法来推导线性动态系统中的参数学习。若要引入先验从而得到 MAP 估计是很直接的，而若要进行完全贝叶斯处理，则可以使用第 10 章中讨论的解析近似技术。不过，由于篇幅所限，这里不再展开。

13.3.3 线性动态系统的扩展

与隐马尔可夫模型一样，人们也很关心如何扩展基本的线性动态系统以增强它的能力。线性-高斯模型的假设带来了高效的推断与学习算法，但也意味着观测变量的边缘分布只是一个高斯分布，这在表达能力上是一个重要限制。对线性动态系统的一种简单扩展是对 $\mathbf{z}_1$ 使用高斯混合作为初始分布。如果这个混合有 K 个分量，那么前向递推方程 (13.85) 将使每个隐变量 $\mathbf{z}_n$ 的分布都变成 K 个高斯分布的混合，因此模型仍然是可处理的。

对于许多应用而言，高斯发射密度是一个较差的近似。如果我们尝试用 K 个高斯分布的混合作为发射密度，那么 $\hat{\alpha}(\mathbf{z}_1)$ 的后验分布也将是 K 个高斯分布的混合。然而由 (13.85) 可知， $\hat{\alpha}(\mathbf{z}_2)$ 将由 K^2 个高斯分布的混合组成，如此类推， $\hat{\alpha}(\mathbf{z}_n)$ 将是由 K^n 个高斯分布构成的混合。因此分量数目随链长指数式增长，使得这种模型在实践中不可行。

更一般地说，只要在转移或发射模型中偏离线性-高斯（或其他指数族）形式，就会导致一个难以处理的推断问题。我们可以采用确定性近似方法，例如假设密度滤波（assumed density filtering）或期望传播，也可以采用第 13.3.4 节中要讨论的采样方法。一种应用广泛的办法是通过在预测分布的均值附近线性化来做高斯近似，从而得到扩展卡尔曼滤波（extended Kalman filter, Zarchan and Musoff, 2005）。

与 HMM 一样，我们可以通过扩展线性动态系统的图表示来构造一些有趣的扩展模型。例如，切换状态空间模型（switching state space model, Ghahramani and Hinton, 1998）可以看作是隐藏马尔可夫模型与一组线性动态系统的组合。该模型包含多条连

续线性-高斯潜在变量的马尔可夫链，每一条都类似于先前讨论的线性动态系统中的潜在链；此外，还有一条由离散变量组成的马尔可夫链，其形式与 HMM 所用的一样。每一个时间步的输出由一个随机选取的连续潜在链决定，这一选择由离散潜在变量的状态作为“开关”来控制，然后从对应的条件输出分布中发出观测值。该模型中的精确推断是不可行的，但利用变分方法可以得到一种高效推断方案：对每一条连续和离散的马尔可夫链独立地执行前向-后向递推。注意，如果我们考虑多条离散潜在变量链，并用其中一条作为开关来在其余各链之间做选择，就得到一个仅具有离散潜在变量的类似模型，称为切换隐马尔可夫模型（switching HMM）。

13.3.4 粒子滤波器

对于那些不是线性-高斯的动态系统，例如使用非高斯发射密度的系统，我们可以转而使用采样方法来构造可行的推断算法。特别是，我们可以采用第 11.1.5 节中的“采样-重要性-重采样”（sampling-importance-resampling）框架，从而得到一种序列蒙特卡罗算法，称为粒子滤波器（particle filter）。

考虑图 13.5 所表示的一类分布，并假设给定了观测值 $\mathbf{X}_n = (\mathbf{x}_1, \dots, \mathbf{x}_n)$ ，我们希望从后验分布 $p(\mathbf{z}_n | \mathbf{X}_n)$ 中抽取 L 个样本。利用贝叶斯定理，有

$$\begin{aligned} \mathbb{E}[f(\mathbf{z}_n)] &= \int f(\mathbf{z}_n) p(\mathbf{z}_n | \mathbf{X}_n) d\mathbf{z}_n \\ &= \int f(\mathbf{z}_n) p(\mathbf{z}_n | \mathbf{x}_n, \mathbf{X}_{n-1}) d\mathbf{z}_n \\ &= \frac{\int f(\mathbf{z}_n) p(\mathbf{x}_n | \mathbf{z}_n) p(\mathbf{z}_n | \mathbf{X}_{n-1}) d\mathbf{z}_n}{\int p(\mathbf{x}_n | \mathbf{z}_n) p(\mathbf{z}_n | \mathbf{X}_{n-1}) d\mathbf{z}_n} \\ &\simeq \sum_{l=1}^L w_n^{(l)} f(\mathbf{z}_n^{(l)}), \end{aligned} \quad (13.117)$$

其中 $\{\mathbf{z}_n^{(l)}\}$ 是从 $p(\mathbf{z}_n | \mathbf{X}_{n-1})$ 抽取的一组样本，并且我们利用了条件独立性质 $p(\mathbf{x}_n | \mathbf{z}_n, \mathbf{X}_{n-1}) = p(\mathbf{x}_n | \mathbf{z}_n)$ ，该性质可由图 13.5 得出。采样的权重 $\{w_n^{(l)}\}$ 定义为

$$w_n^{(l)} = \frac{p(\mathbf{x}_n | \mathbf{z}_n^{(l)})}{\sum_{m=1}^L p(\mathbf{x}_n | \mathbf{z}_n^{(m)})}, \quad (13.118)$$

这里分子与分母中使用的是同一组样本。于是，后验分布 $p(\mathbf{z}_n | \mathbf{X}_n)$ 可以由样本集合 $\{\mathbf{z}_n^{(l)}\}$ 及其对应的权重 $\{w_n^{(l)}\}$ 来表示。注意这些权重满足 $0 \leq w_n^{(l)} \leq 1$ 且 $\sum_l w_n^{(l)} = 1$ 。

由于我们希望构造一种顺序采样方案，接下来假定：在时间步 n ，我们已经有一组样本和权重；随后观测到新的值 $\mathbf{x}_{n+1}$ ，并希望求出时间步 $n+1$ 时的样本与权重。我们

首先需要从分布 $p(\mathbf{z}_{n+1} | \mathbf{X}_n)$ 中采样。利用贝叶斯定理，这可以按如下方式进行：

$$\begin{aligned}
 p(\mathbf{z}_{n+1} | \mathbf{X}_n) &= \int p(\mathbf{z}_{n+1} | \mathbf{z}_n, \mathbf{X}_n) p(\mathbf{z}_n | \mathbf{X}_n) d\mathbf{z}_n \\
 &= \int p(\mathbf{z}_{n+1} | \mathbf{z}_n) p(\mathbf{z}_n | \mathbf{X}_n) d\mathbf{z}_n \\
 &= \int p(\mathbf{z}_{n+1} | \mathbf{z}_n) p(\mathbf{z}_n | \mathbf{x}_n, \mathbf{X}_{n-1}) d\mathbf{z}_n \\
 &= \frac{\int p(\mathbf{z}_{n+1} | \mathbf{z}_n) p(\mathbf{x}_n | \mathbf{z}_n) p(\mathbf{z}_n | \mathbf{X}_{n-1}) d\mathbf{z}_n}{\int p(\mathbf{x}_n | \mathbf{z}_n) p(\mathbf{z}_n | \mathbf{X}_{n-1}) d\mathbf{z}_n} \\
 &= \sum_l w_n^{(l)} p(\mathbf{z}_{n+1} | \mathbf{z}_n^{(l)}),
 \end{aligned} \tag{13.119}$$

这里我们用到了下列条件独立性质：

$$p(\mathbf{z}_{n+1} | \mathbf{z}_n, \mathbf{X}_n) = p(\mathbf{z}_{n+1} | \mathbf{z}_n), \tag{13.120}$$

$$p(\mathbf{x}_n | \mathbf{z}_n, \mathbf{X}_{n-1}) = p(\mathbf{x}_n | \mathbf{z}_n), \tag{13.121}$$

它们都可以通过对图 13.5 应用 d-分离准则得到。式 (13.119) 所给出的分布是一个混合分布，从中采样的方法是：先以权重 $w_n^{(l)}$ 的概率选择某个分量 l ，再从对应的分量 $p(\mathbf{z}_{n+1} | \mathbf{z}_n^{(l)})$ 中抽样。

总结起来，我们可以把粒子滤波算法在每个时间步的过程看作包含两个阶段。在时间步 n ，我们有后验分布 $p(\mathbf{z}_n | \mathbf{X}_n)$ 的样本表示，即样本 $\{\mathbf{z}_n^{(l)}\}$ 及对应的权重 $\{w_n^{(l)}\}$ 。这可以视为式 (13.119) 那样的混合表示。要得到下一时间步的表示，我们首先从混合分布 (13.119) 中抽取 L 个样本，然后对每个样本使用新的观测 $\mathbf{x}_{n+1}$ 来计算对应的权重 $w_{n+1}^{(l)} \propto p(\mathbf{x}_{n+1} | \mathbf{z}_{n+1}^{(l)})$ 。对于单一变量 z 的情形，这个过程在图 13.23 中给出示意。




图 13.23 一维潜在空间中粒子滤波操作的示意图。在时间步 n ，后验分布 $p(z_n | x_n)$ 被表示为一个混合分布，示意性地画成若干圆，其大小与权重 $w_n^{(l)}$ 成正比。随后从该分布中抽取 L 个样本，并利用 $p(\mathbf{x}_{n+1} | \mathbf{z}_{n+1}^{(l)})$ 计算新的权重 $w_{n+1}^{(l)}$ 。

粒子滤波（或序列蒙特卡罗）方法在文献中还有其他名称，例如 bootstrap 滤波器（Gordon et al., 1993）、survival of the fittest（Kanazawa et al., 1995）以及 condensation 算

法 (Isard and Blake, 1998)。

14 组合模型

在前面的章节中，我们已经探讨了多种用于解决分类和回归问题的不同模型。人们经常发现，与单独使用某一个模型相比，通过某种方式将多个模型组合起来，往往可以得到更好的性能。例如，我们可以训练 L 个不同的模型，然后用这 L 个模型预测结果的平均值作为最终预测。这类模型组合有时被称为“委员会”（committee）。在 14.2 节中，我们将讨论如何在实践中应用委员会的概念，并且还会给出它在某些情况下之所以有效的一些直观解释。

委员会方法的一个重要变体称为“提升”（boosting），它是按序训练多个模型，其中用于训练某个模型的误差函数会依赖于前面那些模型的表现。这种方法相对于仅使用单一模型可以带来显著的性能提升，将在 14.3 节中讨论。

与平均一组模型的预测不同，另一种模型组合方式是：从多个模型中选择其中一个来做预测，而这个选择本身是输入变量的函数。这样，不同模型就分别负责输入空间中不同区域的预测。一种广泛使用的这类框架叫作决策树（decision tree）。在决策树中，模型的选择过程可以描述为一串二元选择，对应于在树结构中的逐层遍历，将在 14.4 节讨论。在这种方法中，单个模型一般都被选得很简单，而整个模型的灵活性则来自于依赖输入的选择过程。决策树既可以用于分类问题，也可以用于回归问题。

决策树的一个局限在于，它对输入空间的划分基于“硬切分”：对任一给定的输入变量取值，只有一个模型负责做预测。通过转向一个概率化的模型组合框架，可以使得决策过程“软化”，这将在 14.5 节中讨论。例如，如果我们有一组 K 个条件分布模型 $p(t | \mathbf{x}, k)$ ，其中 $\mathbf{x}$ 是输入变量， t 是目标变量， $k = 1, \dots, K$ 是模型索引，那么我们可以构造如下的概率混合：

$$p(t | \mathbf{x}) = \sum_{k=1}^K \pi_k(\mathbf{x}) p(t | \mathbf{x}, k) \quad (14.1)$$

其中 $\pi_k(\mathbf{x}) = p(k | \mathbf{x})$ 表示依赖输入的混合系数。这类模型可以被视为一种混合分布：其中各分量密度以及混合系数都以输入变量为条件，称为专家混合（mixtures of experts）。它们与第 5.6 节中讨论的混合密度网络模型有着密切关系。

14.1 贝叶斯模型平均

有必要区分模型组合方法与贝叶斯模型平均（Bayesian model averaging），因为两者常常被混淆。为了理解差异，考虑用高斯混合模型进行密度估计的例子，其中若干个高斯分量以概率的方式组合在一起。模型包含一个二值潜在变量 $\mathbf{z}$ ，用来指示哪个分量负责生成相应的数据点。因此，模型是通过联合分布

$$p(\mathbf{x}, \mathbf{z}) \quad (14.2)$$

来刻画的，对观测变量 $\mathbf{x}$ 的对应密度则通过对潜在变量进行边缘化得到

$$p(\mathbf{x}) = \sum_{\mathbf{z}} p(\mathbf{x}, \mathbf{z}). \quad (14.3)$$

在高斯混合的例子中，这会得到如下形式的分布：

$$p(\mathbf{x}) = \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x} \mid \mu_k, \Sigma_k) \quad (14.4)$$

其中各符号具有通常意义。这就是模型组合的一个例子。对于独立同分布的数据，可以利用式 (14.3) 将数据集 $\mathbf{X} = \{\mathbf{x}_1, \dots, \mathbf{x}_N\}$ 的边缘概率写成

$$p(\mathbf{X}) = \prod_{n=1}^N p(\mathbf{x}_n) = \prod_{n=1}^N \left[\sum_{\mathbf{z}_n} p(\mathbf{x}_n, \mathbf{z}_n) \right]. \quad (14.5)$$

因此，我们看到：每一个观测数据点 $\mathbf{x}_n$ 都有一个对应的潜在变量 $\mathbf{z}_n$ 。

现在假设我们有若干个不同的模型，以 $h = 1, \dots, H$ 标号，并具有先验概率 $p(h)$ 。例如，其中一个模型可以是高斯混合，另一个模型可以是柯西混合 (mixture of Cauchys)。数据集的边缘分布则为

$$p(\mathbf{X}) = \sum_{h=1}^H p(\mathbf{X} \mid h) p(h). \quad (14.6)$$

这就是贝叶斯模型平均的一个例子。对 h 求和的解释是：整个数据集是由某一个模型生成的，而关于 h 的概率分布仅反映了我们对到底是哪一个模型的“不确定性”。随着数据集规模的增大，这种不确定性会减小，后验概率 $p(h \mid \mathbf{X})$ 会越来越集中在某一个模型上。

这就凸显了贝叶斯模型平均与模型组合之间的关键区别：在贝叶斯模型平均中，整个数据集是由单一模型生成的。相比之下，在像式 (14.5) 那样组合多个模型时，我们看到数据集中不同的数据点可能由潜在变量 $\mathbf{z}$ 的不同取值生成，从而由不同分量所生成。

虽然我们只考虑了边缘概率 $p(\mathbf{X})$ ，但对于预测密度 $p(\mathbf{x} \mid \mathbf{X})$ 或条件分布（例如 $p(t \mid \mathbf{x}, \mathbf{X}, \mathbf{T})$ ）而言，同样的分析也适用。

14.2 委员会 (Committees)

构造委员会最简单的方式，就是对一组单独模型的预测结果取平均。这类过程可以从频率学派的角度进行动机分析，方法是考虑偏差-方差之间的权衡：把模型误差分解为由模型与真实待预测函数之间差异引起的偏差部分，以及反映模型对具体数据点敏感程度的方差部分。回顾图 3.5：当我们用同一组正弦数据训练多个多项式模型，并对得到的函数取平均时，来自方差项的贡献往往会相互抵消，从而得到更好的预测结果。当我们对一组偏差较小（对应于高阶多项式）的模型进行平均时，就能对生成数据的真实正弦函数做出准确的预测。

当然，在实际中我们只有一个数据集，因此必须找到在委员会中不同模型之间引入变异性的方法。一个办法是使用第 1.2.3 节讨论过的自助 (bootstrap) 数据集。考虑一个回归问题，我们要预测某个连续变量的取值。假设我们生成了 M 个自助数据集，并分别用它们训练出 M 个预测模型 $y_m(\mathbf{x})$ ，其中 $m = 1, \dots, M$ 。委员会的预测由下式给出：

$$y_{\text{COM}}(\mathbf{x}) = \frac{1}{M} \sum_{m=1}^M y_m(\mathbf{x}). \quad (14.7)$$

这一过程被称为自助聚合 (bootstrap aggregation), 或 bagging (Breiman, 1996)。

设我们试图预测的真实回归函数为 $h(\mathbf{x})$, 则每个模型的输出可以写为真值加误差的形式:

$$y_m(\mathbf{x}) = h(\mathbf{x}) + \epsilon_m(\mathbf{x}). \quad (14.8)$$

平均平方误差于是为

$$\mathbb{E}_{\mathbf{x}}[\{y_m(\mathbf{x}) - h(\mathbf{x})\}^2] = \mathbb{E}_{\mathbf{x}}[\epsilon_m(\mathbf{x})^2], \quad (14.9)$$

其中 $\mathbb{E}_{\mathbf{x}}[\cdot]$ 表示关于输入向量 $\mathbf{x}$ 分布的频率学派意义下的期望。因此, 各模型单独使用时的平均误差为

$$E_{AV} = \frac{1}{M} \sum_{m=1}^M \mathbb{E}_{\mathbf{x}}[\epsilon_m(\mathbf{x})^2]. \quad (14.10)$$

类似地, 委员会 (14.7) 的期望误差为

$$\begin{aligned} E_{COM} &= \mathbb{E}_{\mathbf{x}} \left[\left\{ \frac{1}{M} \sum_{m=1}^M y_m(\mathbf{x}) - h(\mathbf{x}) \right\}^2 \right] \\ &= \mathbb{E}_{\mathbf{x}} \left[\left\{ \frac{1}{M} \sum_{m=1}^M \epsilon_m(\mathbf{x}) \right\}^2 \right]. \end{aligned} \quad (14.11)$$

如果我们假设这些误差具有零均值且彼此不相关, 即

$$\mathbb{E}_{\mathbf{x}}[\epsilon_m(\mathbf{x})] = 0, \quad (14.12)$$

$$\mathbb{E}_{\mathbf{x}}[\epsilon_m(\mathbf{x})\epsilon_l(\mathbf{x})] = 0, \quad m \neq l, \quad (14.13)$$

那么就得到

$$E_{COM} = \frac{1}{M} E_{AV}. \quad (14.14)$$

这个看似“惊人”的结果暗示: 只要对 M 个模型进行平均, 就能把模型的平均误差缩小 M 倍。不幸的是, 这一结论依赖于一个关键假设, 即各个模型的误差之间是无相关的。而在实际中, 各模型的误差往往高度相关, 因此总误差的下降通常并不显著。然而可以证明, 期望委员会误差不会超过组成模型误差的期望值, 即 $E_{COM} \leq E_{AV}$ 。为了获得更显著的提升, 我们转向一种更为复杂的委员会构建技术, 即提升 (boosting)。


14.3 提升法 (Boosting)

提升法是一种强大的技术, 用来组合多个“基”分类器, 从而形成一种委员会, 其性能可以显著优于任一单个基分类器。在这里, 我们介绍最广泛使用的一种提升算法——AdaBoost (“adaptive boosting” 的缩写), 由 Freund 和 Schapire (1996) 提出。提升法即使在基分类器的性能只略优于随机猜测时也能取得良好效果, 因此基分类器有时也被称为“弱学习器” (weak learners)。提升法最初是为分类问题设计的, 但也可以推广到回归问题 (Friedman, 2001)。

提升法与上文讨论的 bagging 等委员会方法的主要区别在于: 基分类器是按序列方式依次训练的, 并且每个基分类器都使用“加权版”的数据集进行训练。数据集中每个

样本的权重系数依赖于前面分类器的表现。特别地，被某个基分类器误分类的点，在训练序列中下一个分类器时会被赋予更大的权重。当所有分类器训练完毕之后，它们的预测结果将通过加权多数表决的方式组合起来，如图 14.1 所示。

图 14.1 提升框架的示意图。每一个基分类器 $y_m(\mathbf{x})$ 都是在训练集的加权形式上进行训练的（蓝色箭头），其中权重 $w_n^{(m)}$ 依赖于前一个基分类器 $y_{m-1}(\mathbf{x})$ 的性能（绿色箭头）。当所有基分类器训练完成后，将它们组合起来得到最终分类器 $Y_M(\mathbf{x})$ （红色箭头）。



考虑一个二分类问题，训练数据由输入向量 $\mathbf{x}_1, \dots, \mathbf{x}_N$ 以及对应的二值标记 $t_1, \dots, t_N$ 组成，其中 $t_n \in \{-1, 1\}$ 。为每个数据点赋予一个权重参数 w_n ，初始时对所有数据点都取 $1/N$ 。我们假设手头有一个训练基分类器的过程，它可以在加权数据上进行训练，得到一个函数 $y(\mathbf{x}) \in \{-1, 1\}$ 。在算法的每一步，AdaBoost 都用一套新的样本权重来训练新的分类器，其中这些权重会根据前一分类器的表现进行调整，以便对被误分类的数据点给予更大权重。最后，当训练完期望数量的基分类器后，再利用不同的系数对这些基分类器加权组合成一个委员会。AdaBoost 算法的具体形式如下。

AdaBoost

1. 初始化数据权重系数集合 $\{w_n\}$ ，令 $w_n^{(1)} = 1/N$ ，其中 $n = 1, \dots, N$ 。
2. 对 $m = 1, \dots, M$:

(a) 在训练数据上拟合一个分类器 $y_m(\mathbf{x})$ ，使得下式加权误差函数最小：

$$J_m = \sum_{n=1}^N w_n^{(m)} I(y_m(\mathbf{x}_n) \neq t_n) \quad (14.15)$$

其中指示函数 $I(y_m(\mathbf{x}_n) \neq t_n)$ 在 $y_m(\mathbf{x}_n) \neq t_n$ 时取 1，否则取 0。

(b) 计算

$$\epsilon_m = \frac{\sum_{n=1}^N w_n^{(m)} I(y_m(\mathbf{x}_n) \neq t_n)}{\sum_{n=1}^N w_n^{(m)}} \quad (14.16)$$

然后用此来计算

$$\alpha_m = \ln \left\{ \frac{1 - \epsilon_m}{\epsilon_m} \right\}. \quad (14.17)$$

(c) 更新数据权重系数：

$$w_n^{(m+1)} = w_n^{(m)} \exp \{ \alpha_m I(y_m(\mathbf{x}_n) \neq t_n) \}. \quad (14.18)$$

3. 利用最终模型进行预测，该模型为

$$Y_M(\mathbf{x}) = \text{sign} \left(\sum_{m=1}^M \alpha_m y_m(\mathbf{x}) \right). \quad (14.19)$$

可以看到，第一个基分类器 $y_1(\mathbf{x})$ 是在所有权重 $w_n^{(1)}$ 均相等的情况下训练的，这相当于平常训练单个分类器的做法。由式 (14.18) 可以看出，在后续迭代中，对于被误分类的数据点，其权重 $w_n^{(m)}$ 会被放大；对于被正确分类的数据点，权重会被缩小。因此，后续分类器被迫对前面分类器误分类的点给予更大关注，而那些被多个分类器连续误分类的点，其权重会不断变大。式中的 ϵ_m 是每个基分类器在数据集上错误率的加权重度，因此式 (14.17) 中定义的权重系数 α_m 会对更准确的分类器赋予更大的权重，而这正是在式 (14.19) 中计算整体输出时所使用的权重。




图 14.2 提升方法的示意图，其中基学习器由作用在某一坐标轴上的简单阈值构成。每一幅图显示了当前已经训练完成的基学习器数量 m ，以及最新基学习器的决策边界（黑色虚线）和集成模型的组合决策边界（绿色实线）。每个数据点用一个圆表示，其半径表示在训练最近加入的基学习器时分配给该数据点的权重。因此，例如可以看到，被 $m=1$ 的基学习器误分类的点，在训练 $m=2$ 的基学习器时被赋予了更大的权重。

图 14.2 用 30 个样本（取自图 A.7 所示玩具分类数据集的一部分）对 AdaBoost 算法做了说明。这里每个基学习器由一个单变量阈值组成。这样的简单分类器对应于一种决策树，被称为“决策树桩”（decision stump），即只有一个节点的决策树。这样，每个基学习器都按某个输入特征是否超过某个阈值来分类，因此在输入空间中仅用一条与坐标轴平行的直线把空间划分成两个区域。

14.3.1 指数误差的最小化

提升法最初是在统计学习理论框架下被提出的，那个框架给出了泛化误差的上界。然而，这些上界往往太宽松，缺乏实际意义，而提升法的真实表现远好于这些上界本身所暗示的。Friedman 等（2000）给出了对提升法的另一种非常简单的解释：把它看作是

对指数误差函数的序列最小化过程。

考虑如下定义的指数误差函数：

$$E = \sum_{n=1}^N \exp\{-t_n f_m(\mathbf{x}_n)\}, \quad (14.20)$$

其中 $f_m(\mathbf{x})$ 是由基分类器 $y_l(\mathbf{x})$ 线性组合而成的分类器：

$$f_m(\mathbf{x}) = \frac{1}{2} \sum_{l=1}^m \alpha_l y_l(\mathbf{x}), \quad (14.21)$$

并且 $t_n \in \{-1, 1\}$ 是训练集的目标值。我们的目标是对所有系数 α_l 以及基分类器 $y_l(\mathbf{x})$ 的参数进行优化，以最小化 E 。

然而，我们并不做全局的误差函数最小化，而是假设前 $m-1$ 个基分类器 $y_1(\mathbf{x}), \dots, y_{m-1}(\mathbf{x})$ 以及它们的系数 $\alpha_1, \dots, \alpha_{m-1}$ 都已经固定，这样就只对 α_m 和 $y_m(\mathbf{x})$ 做优化。把第 m 个基分类器的贡献单独分离出来，误差函数可以写成

$$\begin{aligned} E &= \sum_{n=1}^N \exp\left\{-t_n f_{m-1}(\mathbf{x}_n) - \frac{1}{2} t_n \alpha_m y_m(\mathbf{x}_n)\right\} \\ &= \sum_{n=1}^N w_n^{(m)} \exp\left\{-\frac{1}{2} t_n \alpha_m y_m(\mathbf{x}_n)\right\}, \end{aligned} \quad (14.22)$$

其中 $w_n^{(m)} = \exp\{-t_n f_{m-1}(\mathbf{x}_n)\}$ 在只优化 α_m 与 $y_m(\mathbf{x})$ 的前提下可以看作常数。设 $\mathcal{T}_m$ 为被 $y_m(\mathbf{x})$ 正确分类的样本集合， $\mathcal{M}_m$ 为被误分类的样本集合，那么误差函数可以进一步写为

$$\begin{aligned} E &= e^{-\alpha_m/2} \sum_{n \in \mathcal{T}_m} w_n^{(m)} + e^{\alpha_m/2} \sum_{n \in \mathcal{M}_m} w_n^{(m)} \\ &= (e^{\alpha_m/2} - e^{-\alpha_m/2}) \sum_{n=1}^N w_n^{(m)} I(y_m(\mathbf{x}_n) \neq t_n) + e^{-\alpha_m/2} \sum_{n=1}^N w_n^{(m)}. \end{aligned} \quad (14.23)$$

当对 $y_m(\mathbf{x})$ 做最小化时，第二项是常数，因此这等价于最小化式 (14.15)，而其前面的整体乘法因子不会影响最小值的位置。类似地，对 α_m 做最小化，则得到式 (14.17)，其中 ϵ_m 由式 (14.16) 定义。

由式 (14.22) 可知，一旦求得了 α_m 和 $y_m(\mathbf{x})$ ，数据点的权重更新为

$$w_n^{(m+1)} = w_n^{(m)} \exp\left\{-\frac{1}{2} t_n \alpha_m y_m(\mathbf{x}_n)\right\}. \quad (14.24)$$

注意到

$$t_n y_m(\mathbf{x}_n) = 1 - 2I(y_m(\mathbf{x}_n) \neq t_n), \quad (14.25)$$

于是下一次迭代中权重更新为

$$w_n^{(m+1)} = w_n^{(m)} \exp(-\alpha_m/2) \exp\{\alpha_m I(y_m(\mathbf{x}_n) \neq t_n)\}. \quad (14.26)$$

由于 $\exp(-\alpha_m/2)$ 与 n 无关，它对所有样本点的权重都是同样的缩放因子，因此可以忽略。这样就得到式 (14.18)。

最后，当所有基分类器训练完毕后，新样本的分类方式是对式 (14.21) 中定义的组合函数取符号：因为系数 $1/2$ 并不影响符号，因此可以忽略，得到式 (14.19)。

14.3.2 提升法的误差函数

AdaBoost 所最小化的指数误差函数不同于前几章中考虑的那些误差函数。为了更好地理解指数误差函数的性质，我们先看期望误差


$$\mathbb{E}_{\mathbf{x},t}[\exp\{-ty(\mathbf{x})\}] = \sum_t \int \exp\{-ty(\mathbf{x})\} p(t | \mathbf{x}) p(\mathbf{x}) d\mathbf{x}. \quad (14.27)$$

对所有可能的函数 $y(\mathbf{x})$ 做变分最小化，可以得到

$$y(\mathbf{x}) = \frac{1}{2} \ln \left\{ \frac{p(t=1 | \mathbf{x})}{p(t=-1 | \mathbf{x})} \right\}, \quad (14.28)$$

也就是对数优势比的一半。因此，AdaBoost 实际上是在“线性组合基分类器”所构成的函数空间内，寻求对对数优势比的最佳近似，而前面描述的序列优化策略则为这种最小化施加了约束。这个结果也就解释了为什么在式 (14.19) 中要对最终的组合函数取符号，从而得到分类决策。

图 14.3 指数误差函数 (绿色) 和重新缩放的交叉熵误差函数 (红色) 的曲线图，同时还给出了支持向量机中使用的合页误差 (蓝色) 以及误分类误差 (黑色)。注意，对于 $z = t_y(\mathbf{x})$ 的较大负值，交叉熵给出的是线性增长的惩罚，而指数损失给出的是指数增长的惩罚。




我们已经看到，在二分类问题中，交叉熵误差 (式 (4.90)) 的最小化，使得 $y(\mathbf{x})$ 的最优解是后验类别概率的变换。在 $t \in \{-1, 1\}$ 的情形下，交叉熵误差为 $\ln(1 + \exp(-yt))$ 。在图 14.3 中，我们把它与指数误差函数做了对比。为了方便比较，我们将交叉熵误差除以常数因子 $\ln(2)$ ，使它在点 $(0, 1)$ 处过原点。可以看到，这两种误差函数都可以视为对理想“误分类误差函数”的连续逼近。指数误差的一个优点是：在其之下做序列最小化，会自然引出形式简单的 AdaBoost 算法。不过，其缺点也很明显：对于 $ty(\mathbf{x})$ 的大负值，它的惩罚程度远高于交叉熵。特别是，当 ty 取值很大的负数时，交叉熵误差随 $|ty|$ 线性增长，而指数误差则随 $|ty|$ 指数式增长。因此指数误差对异常点或被误分类的样本点的鲁棒性要差得多。

交叉熵与指数误差之间的另一个重要差别是：指数误差无法被解释为某个概率模型的对数似然函数。更进一步地说，指数误差不能自然推广到 $K > 2$ 的多类分类问题，而相比之下，交叉熵在概率模型背景下很容易推广为式 (4.108)。

把提升法解释为在指数误差下对加性模型做序列优化 (Friedman et al., 2000), 为构造各种“类提升算法”打开了大门。通过改变误差函数, 可以得到多种提升法变体, 包括多类扩展。这一观点还为提升法在回归问题上的扩展提供了动机 (Friedman, 2001)。如果我们在回归中使用平方和误差, 那么在形式如 (14.21) 的加性模型下做序列最小化, 就等价于让每一个新的基分类器去拟合上一次模型的残差 $t_n - f_{m-1}(\mathbf{x}_n)$ 。正如我们已经指出的, 平方和误差对异常点并不鲁棒, 于是可以改为基于绝对偏差 $|y - t|$ 的提升算法。图 14.4 对这两种误差函数进行了对比。

图 14.4 平方误差 (绿色) 与绝对误差 (红色) 的比较, 显示出后者对大误差的强调要小得多, 因此对离群点和被错误标记的数据点更加鲁棒。



14.4 基于树的模型

有多种简单但广泛使用的模型通过将输入空间划分为边与坐标轴对齐的长方体区域来工作, 然后在每个区域内指定一个简单的模型 (例如一个常数)。它们可以看作是一种模型组合方法, 其中在输入空间中的任意一点上, 只有一个模型负责做出预测。给定一个新的输入 $\mathbf{x}$, 选择具体模型的过程可以描述为一个顺序决策过程, 对应于遍历一棵二叉树 (即每个节点分裂为两个分支)。在这里, 我们重点关注一种特定的树模型框架, 称为分类与回归树 (classification and regression trees, CART, Breiman et al., 1984), 虽然还有许多其他变体, 如 ID3 与 C4.5 (Quinlan, 1986; Quinlan, 1993)。

图 14.5 使用与坐标轴对齐的边界将二维输入空间划分为五个区域的示意图。





图 14.5 展示了输入空间递归二分划分的示意图及其对应的树结构。在该例中, 第一步将整个输入空间划分为两块: 一块满足 $x_1 \leq \theta_1$, 另一块满足 $x_1 > \theta_1$, 其中 θ_1 是模型的一个参数。这样就产生了两个子区域, 每个子区域又可以被进一步独立划分。例如, 区域 $x_1 \leq \theta_1$ 又根据 $x_2 \leq \theta_2$ 或 $x_2 > \theta_2$ 划分, 从而得到图中记为 A 和 B 的两个区域。这样的递归划分可以用图 14.6 所示的二叉树遍历来描述。对于任意新的输入 $\mathbf{x}$, 我们从树顶端的根节点开始, 根据每个节点上的判定条件沿路径向下, 直至到达某个具体

叶节点，以此确定 $\mathbf{x}$ 所落入的区域。需要注意的是，这样的决策树并不是概率图模型。

图 14.6 与图 14.5 所示输入空间划分相对应的二叉树。



在每个区域内部，会有一个独立的模型用于预测目标变量。例如，在回归问题中，我们可以在每个区域内预测一个常数；在分类问题中，我们可以将某个区域全部归为某一个类别。树模型的一个重要特性，也是它们在诸如医学诊断等领域广受欢迎的原因之一，是它们易于被人类解释，因为它们对应于对各个输入变量的一系列二元决策。例如，为预测病人的疾病，首先可以问“他的体温是否高于某个阈值？”。若回答为是，则下一步可能问“他的血压是否低于某个阈值？”。树的每一个叶节点都对应一个具体的诊断结果。

为了从训练集学习这样的模型，我们必须确定树的结构，包括在每个节点选择哪个输入变量来作为划分标准，以及用作划分阈值的参数 θ_i 的取值。同时我们还要确定各个区域中用于预测的输出值。

先考虑一个回归问题，其目标是从 D 维输入向量 $\mathbf{x} = (x_1, \dots, x_D)^T$ 预测一个单一目标变量 t 。训练数据由输入向量集合 $\{\mathbf{x}_1, \dots, \mathbf{x}_N\}$ 及对应的连续标签 $\{t_1, \dots, t_N\}$ 构成。若输入空间的划分已知，并且我们最小化平方和误差函数，那么在任意给定区域内，预测值的最优取值就是落在该区域内数据点的 t_n 的平均值。

接下来考虑如何确定决策树的结构。即便在树的节点数目固定的情况下，若要通过优化平方和误差来找到最优结构（包括每个划分所用的输入变量以及对应阈值），往往都是计算上不可行的，因为可能的解的数量呈组合爆炸。因此，通常采用贪心优化策略：从一个单一的根节点开始（对应于整个输入空间），然后一次添加一个节点来逐步扩展这棵树。在每一步上，都会有若干个候选区域可以被进一步划分，这些区域对应于在现有树上添加一对新的叶节点。对于每一个候选区域，我们可以选择 D 个输入变量中的任意一个来进行划分，并需要决定划分阈值的具体取值。对于“选择哪一个区域来划分、在哪个输入变量上划分以及阈值是多少”等联合优化问题，可以通过穷举搜索高效完成，其前提是：在给定划分变量与阈值的前提下，对应区域内预测值的最优选择就是该区域数据的局部平均。于是，我们对所有可能的划分变量进行尝试，将给出最小残差平方和误差的那个划分保留。

在采用贪心策略扩展树的前提下，还需要解决何时停止添加新节点的问题。一种简单的方法是：当残差误差的减小幅度低于某个阈值时停止。然而，经验上发现，即便在某一步中所有可用的划分都不能显著降低误差，再继续做若干步划分之后，有时却会出现显著的误差下降。基于这个原因，常见的做法是先利用一种与叶节点所包含数据点数

量相关的停止准则来长大一棵较大的树，然后再将其进行剪枝。剪枝基于的准则需要在残差误差与模型复杂度之间进行权衡。设剪枝起始树为 T_0 ，若一棵子树 $T \subset T_0$ 可以通过对 T_0 进行剪枝得到（也就是说，通过合并相应区域来折叠掉内部节点），则称 T 是 T_0 的一个子树。设叶节点按 $\tau = 1, \dots, |T|$ 编号，其中叶节点 τ 代表输入空间中的一个区域 $\mathcal{R}_\tau$ ，在该区域中包含 N_τ 个数据点，而 $|T|$ 表示叶节点总数。区域 $\mathcal{R}_\tau$ 的最优预测值为

$$y_\tau = \frac{1}{N_\tau} \sum_{\mathbf{x}_n \in \mathcal{R}_\tau} t_n, \quad (14.29)$$

对应的残差平方和贡献为

$$Q_\tau(T) = \sum_{\mathbf{x}_n \in \mathcal{R}_\tau} \{t_n - y_\tau\}^2. \quad (14.30)$$

剪枝准则则定义为

$$C(T) = \sum_{\tau=1}^{|T|} Q_\tau(T) + \lambda |T|, \quad (14.31)$$

其中正则化参数 λ 控制整体残差平方和误差与模型复杂度（由叶节点个数 $|T|$ 衡量）之间的权衡，其取值可通过交叉验证来选择。

对于分类问题，树的生长与剪枝过程与回归类似，只是平方和误差被更合适的性能度量所替代。如果定义 $p_{\tau k}$ 为区域 $\mathcal{R}_\tau$ 中被分配到第 k 类的数据点所占比例（ $k = 1, \dots, K$ ），那么两种常用的度量分别是交叉熵

$$Q_\tau(T) = \sum_{k=1}^K p_{\tau k} \ln p_{\tau k} \quad (14.32)$$

以及基尼指数

$$Q_\tau(T) = \sum_{k=1}^K p_{\tau k} (1 - p_{\tau k}). \quad (14.33)$$

当 $p_{\tau k} = 0$ 或 $p_{\tau k} = 1$ 时，这两种度量都为 0，并且在 $p_{\tau k} = 0.5$ 时取最大值。它们鼓励形成这样的区域：其中大部分数据点都被归为某一个类别。相对于误分类率而言，交叉熵和基尼指数在树的生长阶段是更好的度量，因为它们对节点概率更加敏感。此外，不同于误分类率，它们是可微的，因此更适合于基于梯度的优化方法。而在后续的剪枝阶段，一般会使用误分类率作为评估标准。

像 CART 这样的树模型，常被认为具有很强的可解释性，这是它们的一大优势。然而，实践中往往发现，学习到的树结构对数据集的细节非常敏感：对训练数据做出很小的修改，都会导致一个完全不同的划分集合（Hastie et al., 2001）。

本节所讨论的树模型还有其他一些问题。其一是划分都是与特征空间坐标轴对齐的，这在某些情况下可能非常不理想。比如，要分开两个类别，而它们的最优决策边界以 45° 角倾斜于坐标轴，此时若仅允许轴对齐划分，就需要许多次划分才能近似该边界，而如果可以做非轴对齐的划分，则只需一次。其次，决策树中的划分是“硬切分”的，即输入空间的每个区域只与一个、且仅有一个叶节点模型相关联。最后这一点在回归问

题中尤其成问题：我们通常希望拟合的是平滑函数，而树模型却给出分段常数预测，并在划分边界处产生不连续性。

14.5 条件混合模型

我们已经看到，标准决策树受限于输入空间的硬、轴对齐划分。这些约束可以通过允许“软”的、概率形式的划分来放宽，这些划分可以是所有输入变量的函数，而不再局限于一次只使用一个输入变量。如果我们还为叶节点模型赋予概率解释，就得到了一种完全概率化的树模型，称为层次专家混合（hierarchical mixture of experts），我们将在 14.5.3 节中讨论。

另一种引出层次专家混合模型的方式，是从标准的“无条件密度”概率混合模型（如高斯混合）出发，将其中的分量密度替换为条件分布。在本节中，我们先讨论线性回归模型的混合（14.5.1 节）以及逻辑回归模型的混合（14.5.2 节）。在最简单的情形下，混合系数与输入变量无关。如果进一步推广，使混合系数也依赖于输入，就得到专家混合模型（mixture of experts）。最后，如果混合模型中的每个分量本身又是一个专家混合模型，就得到层次专家混合模型。

14.5.1 线性回归模型的混合

对线性回归模型赋予概率解释的众多好处之一，是它可以作为构建更复杂概率模型的组成部分。例如，我们可以把线性回归模型所对应的条件分布视为有向概率图中的一个结点。在这里，我们考虑一个简单的例子：线性回归模型的混合，它是第 9.2 节所讨论的高斯混合模型向“条件高斯分布”情形的直接推广。

因此，我们考虑 K 个线性回归模型，每个模型都有自己的权重参数 $\mathbf{w}_k$ 。在许多应用中，使用一个对所有 K 个分量都共享的噪声方差（由精度参数 β 控制）是合适的，这也是我们在此采用的设定。为简便起见，我们仍然只考虑一个目标变量 t ，扩展到多输出情形是直接的。设混合系数为 π_k ，则混合分布可以写为

$$p(t | \boldsymbol{\theta}) = \sum_{k=1}^K \pi_k \mathcal{N}(t | \mathbf{w}_k^T \boldsymbol{\phi}, \beta^{-1}), \quad (14.34)$$


其中 $\boldsymbol{\theta}$ 表示模型中所有自适应参数的集合，即 $\mathbf{W} = \{\mathbf{w}_k\}$ 、 $\pi = \{\pi_k\}$ 以及 β 。给定一组观测数据 $\{(\boldsymbol{\phi}_n, t_n)\}$ ，该模型的对数似然函数为

$$\ln p(\mathbf{t} | \boldsymbol{\theta}) = \sum_{n=1}^N \ln \left(\sum_{k=1}^K \pi_k \mathcal{N}(t_n | \mathbf{w}_k^T \boldsymbol{\phi}_n, \beta^{-1}) \right), \quad (14.35)$$

其中 $\mathbf{t} = (t_1, \dots, t_N)^T$ 表示所有目标值构成的向量。

为最大化这一似然函数，我们可以再次借助 EM 算法，而它会被证明只是第 9.2 节无条件高斯混合 EM 算法的一个简单扩展。因此，我们可以在无条件混合模型的经验基础上，引入一组二值潜在变量 $\mathbf{Z} = \{\mathbf{z}_n\}$ ，其中 $z_{nk} \in \{0, 1\}$ ，并且对每个数据点 n ， $k = 1, \dots, K$ 中只有一个元素等于 1，用以指示是哪一个混合分量负责生成该数据点。潜在与观测变量的联合分布对应的图模型如图 14.7 所示。

图 14.7 表示由式 (14.35) 定义的线性回归模型混合的概率有向图。



完全数据对数似然函数为

$$\ln p(\mathbf{t}, \mathbf{Z} | \boldsymbol{\theta}) = \sum_{n=1}^N \sum_{k=1}^K z_{nk} \ln \{ \pi_k \mathcal{N}(t_n | \mathbf{w}_k^T \boldsymbol{\phi}_n, \beta^{-1}) \}. \quad (14.36)$$

EM 算法首先选取一组模型参数初值 $\boldsymbol{\theta}^{\text{old}}$ 。在 E 步中，用这组参数值来计算每个分量 k 对每个数据点 n 的后验概率（或“责任度”）：

$$\gamma_{nk} = \mathbb{E}[z_{nk}] = p(k | \boldsymbol{\phi}_n, \boldsymbol{\theta}^{\text{old}}) = \frac{\pi_k \mathcal{N}(t_n | \mathbf{w}_k^T \boldsymbol{\phi}_n, \beta^{-1})}{\sum_j \pi_j \mathcal{N}(t_n | \mathbf{w}_j^T \boldsymbol{\phi}_n, \beta^{-1})}. \quad (14.37)$$

然后，利用这些责任度，对完全数据对数似然在后验分布 $p(\mathbf{Z} | \mathbf{t}, \boldsymbol{\theta}^{\text{old}})$ 下求期望，得到

$$Q(\boldsymbol{\theta}, \boldsymbol{\theta}^{\text{old}}) = \mathbb{E}_{\mathbf{Z}}[\ln p(\mathbf{t}, \mathbf{Z} | \boldsymbol{\theta})] = \sum_{n=1}^N \sum_{k=1}^K \gamma_{nk} \{ \ln \pi_k + \ln \mathcal{N}(t_n | \mathbf{w}_k^T \boldsymbol{\phi}_n, \beta^{-1}) \}.$$

在 M 步中，我们在保持 γ_{nk} 固定的前提下，对 $\boldsymbol{\theta}$ 最大化 $Q(\boldsymbol{\theta}, \boldsymbol{\theta}^{\text{old}})$ 。首先对混合系数 π_k 优化时必须考虑约束 $\sum_k \pi_k = 1$ ，可以通过拉格朗日乘子来实现，从而得到 π_k 的 M 步重估公式：

$$\pi_k = \frac{1}{N} \sum_{n=1}^N \gamma_{nk}. \quad (14.38)$$

注意这一形式与无条件高斯混合中式 (9.22) 得到的结果完全相同。

接下来考虑对第 k 个线性回归模型的参数向量 $\mathbf{w}_k$ 的最大化。将高斯分布显式展开，可以看出， $Q(\boldsymbol{\theta}, \boldsymbol{\theta}^{\text{old}})$ 关于 $\mathbf{w}_k$ 的部分为

$$Q(\boldsymbol{\theta}, \boldsymbol{\theta}^{\text{old}}) = \sum_{n=1}^N \gamma_{nk} \left\{ -\frac{\beta}{2} (t_n - \mathbf{w}_k^T \boldsymbol{\phi}_n)^2 \right\} + \text{const}, \quad (14.39)$$

其中常数项包括其它权重向量 $\mathbf{w}_j$ ($j \neq k$) 的贡献。可以看到，我们要最大化的量，与单一线性回归模型的标准平方和误差 (3.12) 的负值非常相似，只是在这里额外包含了责任度 γ_{nk} 。这就构成了一个加权最小二乘问题，其中与第 n 个数据点相关的误差项带有加权系数 $\beta \gamma_{nk}$ ，可解释为每个数据点的“有效精度”。我们看到，在 M 步中，每个线性回归子模型（由各自的参数向量 $\mathbf{w}_k$ 决定）都是在整个数据集上单独拟合的，只不过每个数据点 n 的权重由该模型对该点的责任度 γ_{nk} 决定。

令 (14.39) 对 $\mathbf{w}_k$ 的导数为零可得

$$0 = \sum_{n=1}^N \gamma_{nk} (t_n - \mathbf{w}_k^T \boldsymbol{\phi}_n) \boldsymbol{\phi}_n. \quad (14.40)$$

用矩阵形式表示为

$$0 = \Phi^T \mathbf{R}_k (\mathbf{t} - \Phi \mathbf{w}_k), \quad (14.41)$$

其中 $\mathbf{R}_k = \text{diag}(\gamma_{nk})$ 是一个 $N \times N$ 的对角矩阵。对 $\mathbf{w}_k$ 求解得

$$\mathbf{w}_k = (\Phi^T \mathbf{R}_k \Phi)^{-1} \Phi^T \mathbf{R}_k \mathbf{t}. \quad (14.42)$$

这是一组加权最小二乘问题的修正“正规方程”，形式上与逻辑回归背景下的 (4.99) 完全类似。需要注意的是，每完成一次 E 步，矩阵 $\mathbf{R}_k$ 的元素就会改变，因此在后续的 M 步中必须重新求解相应的正规方程。

最后，我们对 β 最大化 $Q(\theta, \theta^{\text{old}})$ 。只保留与 β 有关的项，可以把 Q 写为

$$Q(\theta, \theta^{\text{old}}) = \sum_{n=1}^N \sum_{k=1}^K \gamma_{nk} \left\{ \frac{1}{2} \ln \beta - \frac{\beta}{2} (t_n - \mathbf{w}_k^T \phi_n)^2 \right\}. \quad (14.43)$$

令其对 β 的导数为零，并加以整理，得到 β 的 M 步更新公式：

$$\frac{1}{\beta} = \frac{1}{N} \sum_{n=1}^N \sum_{k=1}^K \gamma_{nk} (t_n - \mathbf{w}_k^T \phi_n)^2. \quad (14.44)$$




图 14.8 一个合成数据集的示例，用绿色点表示，包含一个输入变量 x 和一个目标变量 t ，以及由两个线性回归模型组成的混合模型，其均值函数 $y(x, w_k)$ （其中 $k \in \{1, 2\}$ ）分别由蓝色和红色直线表示。上面三幅图分别显示了初始配置（左）、运行 30 次 EM 迭代后的结果（中）以及运行 50 次 EM 迭代后的结果（右）。这里， β 被初始化为目标值集合真实方差的倒数。下面三幅图给出了相应的责任度表示方式：对每个数据点绘制一条竖直线，其中蓝色线段的长度表示该数据点属于蓝色直线的后验概率（红色线段同理）。

在图 14.8 中，我们用一个简单例子对这一 EM 算法做了说明：我们用两个直线分量的混合来拟合一个只有一个输入变量 x 和一个目标变量 t 的数据集。利用 EM 算法收敛后得到的参数（对应图 14.8 右图），由式 (14.34) 给出的预测密度在图 14.9 中绘出。同时，该图也给出了拟合单一线性回归模型的结果，其对应的预测密度是单峰的。可以看到，混合模型更好地刻画了数据的分布，这也反映在其更高的似然值上。然而，由于该混合模型对任意 x 都给出双峰预测分布，它也在没有数据的区域上赋予了相当多的

概率质量。通过扩展模型，使混合系数本身也成为 x 的函数，可以缓解这一问题，从而得到类似第 5.6 节中讨论的混合密度网络（mixture density networks）以及第 14.5.3 节中讨论的层次专家混合模型等更灵活的模型。




图 14.9 左图显示了与图 14.8 中收敛解相对应的预测条件密度，其对数似然值为 -3.0 。在其中某一固定 x 值处对该图作一条竖直切片，就得到了相应的条件分布 $p(t|x)$ ，可以看到该分布是双峰的。右图显示了使用最大似然方法在同一数据集上拟合得到的单一线性回归模型的预测密度，该模型的对数似然值较小，为 -27.6 。

14.5.2 逻辑模型的混合

由于逻辑回归模型给出了在给定输入向量条件下目标变量的条件分布，因此很容易把它作为混合模型中的分量分布使用，从而相比单一逻辑回归模型得到更丰富的一族条件分布。本例是对前面章节中若干思想的直接组合，有助于读者对这些内容进行巩固。

对于由 K 个逻辑回归模型组成的概率混合，其目标变量的条件分布为

$$p(t|\phi, \theta) = \sum_{k=1}^K \pi_k y_k^t [1 - y_k]^{1-t} \quad (14.45)$$

其中 ϕ 为特征向量， $y_k = \sigma(\mathbf{w}_k^T \phi)$ 是第 k 个分量的输出， θ 表示可调参数，即 $\{\pi_k\}$ 和 $\{\mathbf{w}_k\}$ 。

现在假设给定一个数据集 $\{(\phi_n, t_n)\}$ 。对应的似然函数为

$$p(\mathbf{t}|\theta) = \prod_{n=1}^N \left(\sum_{k=1}^K \pi_k y_{nk}^{t_n} [1 - y_{nk}]^{1-t_n} \right) \quad (14.46)$$

其中 $y_{nk} = \sigma(\mathbf{w}_k^T \phi_n)$ ， $\mathbf{t} = (t_1, \dots, t_N)^T$ 。我们可以通过 EM 算法迭代地最大化这一似然函数。与前面相同，这需要引入潜在变量 z_{nk} ，对每个数据点 n 构成一个 1-of- K 编码的二值指示变量。完全数据似然函数为

$$p(\mathbf{t}, \mathbf{Z}|\theta) = \prod_{n=1}^N \prod_{k=1}^K \left\{ \pi_k y_{nk}^{t_n} [1 - y_{nk}]^{1-t_n} \right\}^{z_{nk}} \quad (14.47)$$

其中 $\mathbf{Z}$ 为潜在变量矩阵，元素为 z_{nk} 。我们通过为模型参数选择初始值 θ^{old} 来初始化 EM 算法。在 E 步中，用这组参数值来计算每个数据点 n 对每个分量 k 的后验概率（责

任度)：

$$\gamma_{nk} = \mathbb{E}[z_{nk}] = p(k | \phi_n, \theta^{\text{old}}) = \frac{\pi_k y_{nk}^{t_n} [1 - y_{nk}]^{1-t_n}}{\sum_j \pi_j y_{nj}^{t_n} [1 - y_{nj}]^{1-t_n}}. \quad (14.48)$$

然后利用这些责任度来计算关于 θ 的完全数据对数似然的期望：

$$\begin{aligned} Q(\theta, \theta^{\text{old}}) &= \mathbb{E}_{\mathbf{Z}}[\ln p(\mathbf{t}, \mathbf{Z} | \theta)] \\ &= \sum_{n=1}^N \sum_{k=1}^K \gamma_{nk} \{ \ln \pi_k + t_n \ln y_{nk} + (1 - t_n) \ln(1 - y_{nk}) \}. \end{aligned} \quad (14.49)$$

M 步在保持 θ^{old} (因此 γ_{nk}) 不变的前提下, 对 θ 最大化上述 Q 函数。对 π_k 的最大化可以照常处理：使用拉格朗日乘子强制约束 $\sum_k \pi_k = 1$, 得到熟悉的结果：

$$\pi_k = \frac{1}{N} \sum_{n=1}^N \gamma_{nk}. \quad (14.50)$$

为了确定各向量 $\{\mathbf{w}_k\}$, 注意到 $Q(\theta, \theta^{\text{old}})$ 是一个关于 k 的求和, 而每一项只依赖于对应的 $\mathbf{w}_k$ 。因此在 EM 算法的 M 步中, 各个权向量之间是解耦的。换句话说, 各分量之间仅通过责任度产生相互作用, 而在 M 步中责任度是固定的。需要注意的是, M 步对 $\mathbf{w}_k$ 的优化没有封闭形式解, 必须使用迭代方法求解, 例如迭代加权最小二乘 (IRLS) 算法。对 $\mathbf{w}_k$ 的梯度与 Hessian 为

$$\nabla_k Q = \sum_{n=1}^N \gamma_{nk} (t_n - y_{nk}) \phi_n, \quad (14.51)$$

$$\mathbf{H}_k = -\nabla_k \nabla_k Q = \sum_{n=1}^N \gamma_{nk} y_{nk} (1 - y_{nk}) \phi_n \phi_n^T, \quad (14.52)$$

其中 ∇_k 表示对 $\mathbf{w}_k$ 的梯度。对固定的 γ_{nk} , 上述量与其他分量 $\{\mathbf{w}_j\}_{j \neq k}$ 无关, 因此我们可以对每个 $\mathbf{w}_k$ 独立地应用 IRLS 算法求解。于是, 对第 k 个分量而言, 其 M 步方程与“在一个加权数据集上拟合单一逻辑回归模型”的情形完全相同, 其中第 n 个数据点的权重为 γ_{nk} 。图 14.10 展示了将逻辑回归模型混合用于一个简单分类问题的例子。将该模型推广为多类情形 (softmax 模型的混合) 也是直接的。

14.5.3 专家混合模型

在 14.5.1 节中, 我们讨论了线性回归模型的混合; 在 14.5.2 节中, 我们讨论了对应的线性分类器混合。尽管这些简单混合把线性模型的灵活性扩展到了更加复杂 (例如多峰) 的预测分布, 但依然具有显著局限。进一步的提升是使混合系数本身也成为输入变量的函数, 即

$$p(\mathbf{t} | \mathbf{x}) = \sum_{k=1}^K \pi_k(\mathbf{x}) p_k(\mathbf{t} | \mathbf{x}). \quad (14.53)$$

这就是所谓的专家混合模型 (mixture of experts, Jacobs et al., 1991), 其中混合系数 $\pi_k(\mathbf{x})$ 被称为门控函数 (gating functions), 各分量密度 $p_k(\mathbf{t} | \mathbf{x})$ 被称为专家 (experts)。“专




图 14.10 逻辑回归模型混合的示意图。左图显示了从两个类别中抽取的数据点，分别用红色和蓝色表示，其中背景颜色（从纯红到纯蓝变化）表示类别标签的真实概率。中间图显示了使用最大似然方法拟合单一逻辑回归模型的结果，其中背景颜色表示相应的类别概率。由于颜色几乎均匀为紫色，可以看出该模型在输入空间的大部分区域内对每个类别都赋予了大约 0.5 的概率。右图显示了拟合由两个逻辑回归模型组成的混合模型的结果，此时对于蓝色类别中的许多点，模型赋予了正确标签更高的概率。

家”一词的含义在于，不同分量可以在输入空间的不同区域对分布进行建模（即在各自的区域内更“擅长”预测），而门控函数决定了在不同区域中哪些分量占主导地位。

门控函数 $\pi_k(\mathbf{x})$ 必须满足混合系数的一般约束，即 $0 \leq \pi_k(\mathbf{x}) \leq 1$ 且 $\sum_k \pi_k(\mathbf{x}) = 1$ 。因此，它们可以用线性 softmax 模型来表示（参见式 (4.104) 与 (4.105)）。如果专家模型本身也是线性模型（回归或分类），则整个专家混合模型可以使用 EM 算法高效拟合，并在 M 步中采用 IRLS（Jordan and Jacobs, 1994）。

尽管如此，这样的模型由于门控函数与专家函数都采用线性模型，仍存在显著局限。一个更灵活的模型是采用多层门控函数，从而得到层次专家混合模型（hierarchical mixture of experts, HME）（Jordan and Jacobs, 1994）。要理解该模型的结构，可以想象一个混合分布，其中每个分量本身又是一个混合分布。对于简单的无条件混合而言，这种层次混合在数学上与一个“扁平”的单层混合是等价的。然而，当混合系数依赖于输入时，这一层次结构就不再是平凡的。HME 模型也可以看作是 14.4 节中决策树的概率化版本，同样可以通过最大似然和 EM 算法（在 M 步中使用 IRLS）高效训练。Bishop 与 Svensén（2003）基于变分推断给出了 HME 的贝叶斯处理。

我们不会在此详细讨论 HME。不过值得指出它与第 5.6 节中讨论的混合密度网络（mixture density network）之间的紧密联系。专家混合模型的主要优势在于，它可以用 EM 算法来优化，其中每个混合分量和门控模型的 M 步都是一个凸优化问题（尽管整体优化问题是非凸的）。相比之下，混合密度网络的优势在于，各分量密度与混合系数共享神经网络的隐藏单元。此外，在混合密度网络中，相对于 HME 模型，输入空间的划分被进一步放宽：不仅划分是软的、不受轴对齐限制，而且还可以是非线性的。